

دانشگاه آزاد اسلامی

واحد تهران شمال

پایان نامه کارشناسی ارشد

گرایش مهندسی نرم افزار

چندسطحی درمانی با یادگیری few-shot:
پیش‌بینی هوشمند امکان‌پذیری درمان با توکن‌های علامت
از داده‌های تجمیع‌شده

محمد شرفی

Mohammad Sharafi

مهندسی کامپیوتر، گرایش نرم‌افزار

دانشگاه آزاد اسلامی، واحد تهران شمال

استاد راهنما: دکتر علی محمدزاده

اسفند ۱۴۰۴ / مارس ۲۰۲۶

Master's Thesis

**Therapeutic Few-Shot: Intelligent Prediction
of Treatment Feasibility
with Symptom Tokens from Aggregated Data**

Mohammad Sharafi

Computer Engineering — Software

Islamic Azad University, Tehran North Branch

Supervisor: Dr. Alimohammadzadeh

March 2026

تعهدنامه

بدین وسیله متعهد می‌شوم که این پایان‌نامه حاصل پژوهش و تلاش شخصی بنده بوده و در مواردی که از اندیشه یا نتایج دیگران استفاده شده، مرجع به‌درستی ذکر گردیده است. همچنین تعهد می‌دهم که این پایان‌نامه پیش‌تر برای اخذ هیچ مدرکی ارائه نشده است.

نام و امضای دانشجو: _____

تقديم

به خانواده‌ام که همواره پشتیبان من بودند.

قدردانی

خاستگاه این پژوهش به تجربه کاری من در بستر Mayo Clinic بازمی‌گردد؛ جایی که از نزدیک با دو واقعیت همزمان روبه‌رو شدم: نیاز روزافزون به پیش‌بینی هوشمند در سلامت، و دشواری جدی دسترسی به داده بالینی حساس. در آن تجربه، آنچه در دسترس بود عمدتاً شناسه‌ها و کدها بود، نه پرونده‌های بالینی خام. همین محدودیت برای من روشن کرد که اگر قرار است مدل‌های پیش‌بینی در پزشکی کاربرد واقعی پیدا کنند، باید بتوانند بدون تجمیع مستقیم داده و با احترام به حریم خصوصی بیمار آموزش ببینند. این پایان‌نامه از همان دغدغه شکل گرفت و سه مسیر یادگیری فدرال، سازگاری few-shot و بازنمایی فشرده با Symptom Tokens را دنبال کرد. از استاد راهنما، دکتر علی‌محمدزاده، برای راهنمایی‌های ارزشمندشان و از همه کسانی که در این مسیر همراه من بودند، صمیمانه سپاسگزارم.

چکیده

پیش‌بینی امکان‌پذیری درمان بر پایه داده بالینی محدود و حساس، یکی از مسائل مهم در پشتیبانی تصمیم فردمحور است. در این پایان‌نامه، چارچوبی ترکیبی بررسی می‌شود که از چند جزء اصلی تشکیل شده است: توکن‌های علامت (Symptom Tokens) برای بازنمایی فشرده آزمایش‌ها و علائم حیاتی، رمزگذار ETHOS، یادگیری few-shot و آموزش فدرال. آزمایش‌ها روی نمونه ۲,۰۰۰ بیمار از MIMIC-IV v3.1 و پنج گره بیماری شامل سپسیس، بیماری‌های قلبی، تنفسی، کلیوی و دیابت انجام شده است.

برای تعیین مرجع عملکرد، ابتدا یک مدل جدولی قوی گزارش می‌شود. فرایند SOTA جدولی (`exp_tabular_sota.py`) در مجموعه آزمون به AUROC برابر ۰.۷۴۸، F1 برابر ۰.۶۷۴ و دقت ۰.۷۰۰ می‌رسد. بهترین اجرای ترکیبی few-shot با انباشت (`exp_fewshot_best.py`) AUROC برابر ۰.۷۴۶ با بازه اطمینان بوت‌استرپ ۹۵٪ [0.699, 0.797] دارد؛ بنابراین از نظر برآورد نقطه‌ای، به سقف جدولی بسیار نزدیک است. در مقابل، زیرمدل few-shot به‌تنهایی AUROC برابر ۰.۶۷۰ به‌دست می‌آورد. در آزمایش جداگانه `Exp1` (`exp1_main.py`) نیز `Proposed_FewShot` به ۰.۶۱۱ و `Random Forest` به ۰.۷۶۲ می‌رسند؛ از این‌رو نتایج اپیزودیک و نتایج انباشتی نباید به‌جای یکدیگر تفسیر شوند. هزینه آموزش فدرال نسبت به آموزش متمرکز نیز حدود ۰.۵ واحد درصد AUROC است.

اجزای اصلی روش شامل سازگاری به سبک Proto-MAML، تقطیر دانش از معلم `Random Forest`، پیش‌آموزش `contrastive` نظارت‌شده، ویژگی‌های جدولی مهندسی‌شده، توجه درگاهی به ویژگی، نمونه‌های `cross-attention` و یک `meta-learner` انباشتی است که پیش‌بینی‌های few-shot و مدل‌های کلاسیک را با هم ترکیب می‌کند.

مشارکت‌های این پایان‌نامه عبارت‌اند از: (۱) ارائه بنچمارکی بازتولیدپذیر برای امکان‌پذیری درمان بر MIMIC-IV با سلسله‌مراتب شفاف گزارش نتایج؛ (۲) استفاده از Symptom Tokens همراه با ETHOS برای یادگیری few-shot؛ (۳) نشان دادن نقش انباشت در کاهش فاصله تا سقف جدولی؛ و (۴) فراهم کردن کد و جداول خروجی برای بازتولید نتایج.

کلیدواژه‌ها: امکان‌پذیری درمان؛ یادگیری چندنمونه‌ای؛ یادگیری فدرال؛ MIMIC-IV؛ Symptom Tokens؛ ETHOS؛ یادگیری ماشین بالینی.

فهرست مطالب

تعهدنامه

تقدیم

قدردانی

الف

۱	۱	کلیات تحقیق
۱	۱.۱	بستر بالینی
۱	۱.۱.۱	محیط بخش مراقبت ویژه و تصمیم‌گیری
۱	۲.۱.۱	گردش کار بالینی و نقاط تصمیم
۲	۳.۱.۱	برنامه‌ریزی ترخیص و امکان‌پذیری درمان
۲	۲.۱	تحول دیجیتال در سلامت
۳	۱.۲.۱	از سیلوهای داده تا هوش تجمیعی
۳	۲.۲.۱	وعده و خطر هوش مصنوعی بالینی
۴	۳.۲.۱	امکان‌پذیری درمان در عصر مراقبت مبتنی بر ارزش
۴	۳.۱	انگیزه
۵	۴.۱	بیان مسئله
۷	۵.۱	شکاف پژوهشی
۷	۱.۵.۱	شکاف ۱: یادگیری چندنمونه‌ای بر داده بالینی جدولی
۷	۲.۵.۱	شکاف ۲: یادگیری فدرال چندنمونه‌ای برای مراقبت‌های بهداشتی
	۳.۵.۱	شکاف ۳: ارزیابی صادقانه روش‌های عصبی بر مجموعه داده‌های بالینی
۸		کوچک
۸	۴.۵.۱	شکاف ۴: بازنمایی‌های بالینی مبتنی بر token

۶.۱	اصطلاحات و تعاریف	۸
۷.۱	مرور کلی روش پژوهش	۹
۸.۱	اهداف پژوهش و مفروضات	۹
۱.۸.۱	تطبیق با پروپوزال اولیه	۱۰
۹.۱	پرسش‌های پژوهش	۱۰
۱۰.۱	نوآوری‌ها و مشارکت‌ها	۱۱
۱۱.۱	ساختار پایان‌نامه	۱۳
۱۲.۱	بستر مقرراتی و اخلاقی	۱۴
۱۳.۱	تحلیل ذی‌نفعان	۱۴
۱۴.۱	خلاصه فصل	۱۵
۱۵.۱	دامنه و محدودیت‌ها	۱۵
۱۶.۱	اهمیت در بستر پزشکی دقیق	۱۵
۱.۱۶.۱	از میانگین‌های جمعیتی تا پیش‌بینی فردی	۱۵
۲.۱۶.۱	سازگاری چندنمونه‌ای به‌عنوان شخصی‌سازی	۱۶
۳.۱۶.۱	تعمیم بین‌نهادی	۱۶

۲ پیشینه و کارهای مرتبط ۱۷

۱.۲	یادگیری چندنمونه‌ای (few-shot)	۱۷
۱.۱.۲	تاریخچه و تحول	۱۷
۲.۱.۲	فرمول‌بندی مسئله	۱۸
۳.۱.۲	شبکه‌های نمونه‌ای	۱۸
۴.۱.۲	شبکه‌های تطبیقی	۱۸
۵.۱.۲	شبکه‌های رابطه‌ای	۱۹
۶.۱.۲	شبکه‌های سیامی	۲۰
۷.۱.۲	فرا یادگیری مستقل از مدل (MAML)	۲۰
۸.۱.۲	آموزش اپیزودیک	۲۱
۹.۱.۲	تضمین‌های نظری	۲۱
۱۰.۱.۲	کاربردها در سلامت	۲۱

۲۲	یادگیری فدرال	۲.۲
۲۲	انگیزه	۱.۲.۲
۲۲	میانگین‌گیری فدرال (FedAvg)	۲.۲.۲
۲۲	حریم خصوصی و امنیت	۳.۲.۲
۲۲	همگرایی و ارتباطات	۴.۲.۲
۲۳	FedProx: مدیریت ناهمگونی	۵.۲.۲
۲۳	SCAFFOLD: کاهش واریانس	۶.۲.۲
۲۴	کارایی ارتباطات	۷.۲.۲
۲۴	داده غیر IID	۸.۲.۲
۲۵	کاربردها در سلامت	۹.۲.۲
۲۵	بازنمایی داده بالینی	۳.۲
۲۵	داده بالینی خام	۱.۳.۲
۲۶	راهبردهای نرمال‌سازی	۲.۳.۲
۲۶	بازنمایی‌های مبتنی بر توکن	۳.۳.۲
۲۶	جدولی در برابر دنباله‌ای	۴.۳.۲
۲۷	مجموعه داده MIMIC-IV	۴.۲
۲۷	مرور کلی	۱.۴.۲
۲۷	ساختار داده	۲.۴.۲
۲۸	تعریف کوهورت	۳.۴.۲
۲۸	تعریف برچسب	۴.۴.۲
۲۸	گره‌های بیماری	۵.۴.۲
۲۹	کارهای مرتبط: پیش‌بینی بالینی	۵.۲
۲۹	پیش‌بینی مبتنی بر EHR	۱.۵.۲
۲۹	پیش‌بینی ترخیص	۲.۵.۲
۲۹	یادگیری عمیق در برابر جدولی	۳.۵.۲
۲۹	یادگیری few-shot روی داده جدولی	۴.۵.۲
۳۰	مکانیزم‌های توجه برای داده بالینی	۵.۵.۲
۳۱	جزئیات معماری ETHOS	۶.۵.۲

۷.۵.۲	رویکردهای توکن‌سازی علامت در ادبیات	۳۲
۶.۲	جمع‌بندی	۳۳
۷.۲	جدول مقایسه کارهای پیشین	۳۳
۸.۲	ادبیات تفصیلی: مقالات کلیدی	۳۵
۹.۲	خلاصه مبانی نظری	۳۵
۱۰.۲	مرور گسترده ادبیات	۳۶
۱.۱۰.۲	مبانی فرا یادگیری	۳۶
۲.۱۰.۲	یادگیری انتقالی و سازگاری دامنه	۳۶
۳.۱۰.۲	یادگیری متضاد و یادگیری متریک	۳۶
۴.۱۰.۲	چالش‌های ویژه سلامت	۳۶
۱۱.۲	ترنسفورمرها در داده بالینی	۳۷
۱.۱۱.۲	مکانیزم‌های توجه	۳۷
۲.۱۱.۲	رمزگذاری موقعیتی	۳۷
۳.۱۱.۲	ترنسفورمرهای بالینی	۳۷
۱۲.۲	یادگیری در شرایط نامتوازن	۳۷
۱.۱۲.۲	نامتوازنی کلاس در داده بالینی	۳۷
۲.۱۲.۲	SMOTE و نمونه‌برداری مجدد	۳۸
۳.۱۲.۲	معیارهای ارزیابی	۳۸
۱۳.۲	تفسیرپذیری در یادگیری ماشین سلامت	۳۸
۱.۱۳.۲	اهمیت ویژگی	۳۸
۲.۱۳.۲	تصویرسازی توجه	۳۸
۳.۱۳.۲	اعتبارسنجی بالینی	۳۸
۱۴.۲	مرور جامع ادبیات	۳۹
۱.۱۴.۲	تحول و بنچمارک‌های یادگیری چندنمونه‌ای (few-shot)	۳۹
۲.۱۴.۲	یادگیری فدرال: سامانه‌ها و نظریه	۳۹
۳.۱۴.۲	پیش‌بینی بالینی: وضعیت هنر	۳۹
۴.۱۴.۲	یادگیری عمیق جدولی	۴۰
۵.۱۴.۲	مجموعه‌های داده بنچمارک در ML بالینی	۴۰

۴۱	پیش‌بینی ترخیص: نتایج پیشین	۶.۱۴.۲
۴۱	AI اخلاقی در سلامت	۷.۱۴.۲
۴۲	جزئیات معماری ترنسفورمر	۱۵.۲
۴۲	پروتکل ارزیابی و واریانس K-شات	۱۶.۲
۴۲	بنچمارک‌های یادگیری few-shot	۱۷.۲
۴۳	یادگیری فدرال: ارتباطات و حریم خصوصی	۱۸.۲
۴۳	پیش‌بینی بالینی: فرمول‌بندی وظیفه	۱۹.۲
۴۴	جایگزینی و مدیریت داده گمشده	۲۰.۲
۴۴	جمع‌بندی فصل	۲۱.۲

۴۵	۳ روش‌شناسی	
۴۵	نمادگذاری	۱.۳
۴۶	نمای کلی فرایند	۲.۳
۴۶	مجموعه داده و پیش‌پردازش	۳.۳
۴۶	استخراج کوهورت	۱.۳.۳
۴۷	فرایند تفصیلی استخراج MIMIC-IV	۲.۳.۳
۴۸	استخراج آزمایشگاه و علائم حیاتی	۳.۳.۳
۴۹	مهندسی ویژگی	۴.۳.۳
۵۰	راهبرد داده گمشده	۵.۳.۳
۵۱	تقسیم داده	۶.۳.۳
۵۲	توکن‌سازی علائم	۴.۳
۵۲	ساختار توکن	۱.۴.۳
۵۲	ساخت دنباله	۲.۴.۳
۵۲	ارتباط با ویژگی‌های جدولی	۳.۴.۳
۵۳	معماری رمزگذار ETHOS	۵.۳
۵۳	نمای کلی	۱.۵.۳
۵۳	پیکربندی	۲.۵.۳
۵۳	خروجی	۳.۵.۳

۴.۵.۳	جزئیات مکانیزم توجه	۵۴
۶.۳	پیش‌بینی درمان چندنمونه‌ای	۵۴
۱.۶.۳	پروتکل اپیزودیک	۵۴
۲.۶.۳	سر نمونه اولیه‌ای	۵۴
۳.۶.۳	تابع هزینه	۵۵
۴.۶.۳	تصویر فضای متریک	۵۵
۵.۶.۳	آموزش	۵۵
۷.۳	سر شبکه رابطه (جایگزین)	۵۶
۸.۳	آموزش فدرال	۵۷
۱.۸.۳	افراز گره	۵۷
۲.۸.۳	پروتکل FedAvg	۵۷
۳.۸.۳	پارامترهای مشترک در برابر محلی	۵۸
۴.۸.۳	پایش همگرایی	۵۸
۹.۳	معماری ترکیبی: ETHOS_RF_Hybrid	۵۸
۱۰.۳	پروتکل ارزیابی	۵۹
۱.۱۰.۳	معیارها	۵۹
۱.۱.۱۰.۳	AUROC (مساحت زیر منحنی مشخصه عملیاتی گیرنده)	۵۹
۲.۱.۱۰.۳	دقت، فراخوانی، و نمره F1	۶۰
۳.۱.۱۰.۳	ضریب همبستگی متیوز (MCC)	۶۰
۴.۱.۱۰.۳	دقت (Accuracy)	۶۰
۵.۱.۱۰.۳	نمره Brier	۶۱
۶.۱.۱۰.۳	معناداری آماری	۶۱
۷.۱.۱۰.۳	پایداری (واریانس)	۶۱
۲.۱۰.۳	خط پایه‌ها	۶۲
۳.۱۰.۳	تنظیم آستانه	۶۲
۱۱.۳	جزئیات پیاده‌سازی	۶۲
۱.۱۱.۳	بهینه‌سازی	۶۲
۲.۱۱.۳	منظم‌سازی	۶۳

۶۳	بازتولیدپذیری	۳.۱۱.۳
۶۳	شبه‌کد الگوریتم	۱۲.۳
۶۳	آموزش چندنمونه‌ای نمونه اولیه‌ای	۱.۱۲.۳
۶۳	میانگین‌گیری فدرال	۲.۱۲.۳
۶۴	یادداشت درباره محیط الگوریتم	۳.۱۲.۳
۶۴	پیچیدگی محاسباتی	۱۳.۳
۶۴	رمزگذار ETHOS	۱.۱۳.۳
۶۴	ارتباط فدرال	۲.۱۳.۳
۶۵	جایگزین‌های توکن‌سازی	۳.۱۳.۳
۶۵	خط پایه‌های کلاسیک	۴.۱۳.۳
۶۵	استنتاج‌های ریاضی	۱۴.۳
۶۵	گرادیان هزینه نمونه اولیه‌ای	۱.۱۴.۳
۶۶	Focal Loss	۲.۱۴.۳
۶۶	فواصل اطمینان bootstrap	۳.۱۴.۳
۶۶	استنتاج جایگزین SOFA و شاخص شوک	۴.۱۴.۳
۶۶	نمای کلی معماری نرم‌افزار	۱۵.۳
۶۷	معماری V5: توجه ویژگی دروازه‌ای با نمونه‌های اولیه متقاطع	۱۶.۳
۶۷	توجه ویژگی دروازه‌ای (GFA)	۱.۱۶.۳
۶۸	سر نمونه اولیه‌ای متقاطع	۲.۱۶.۳
۶۸	معماری V6: گروه عمیق ناهمگن	۱۷.۳
۶۹	معماری‌های جایگزین مورد بررسی	۱۸.۳
۶۹	پیاده‌سازی و بازتولیدپذیری	۱۹.۳
۶۹	فرایند داده و گام‌های پیش‌پردازش	۲۰.۳
۷۰	جزئیات پروتکل ارزیابی	۲۱.۳
۷۰	خلاصه فصل	۲۲.۳

۴ آزمایش‌ها

۷۱	چیدمان تجربی	۱.۴
----	--------------	-----

۷۱	پیاده‌سازی و معماری نرم‌افزار	۱.۱.۴
۷۲	پیکربندی داده	۲.۱.۴
۷۲	پیکربندی FewShot+ETHOS	۳.۱.۴
۷۲	پیکربندی خط پایه کلاسیک	۴.۱.۴
۷۲	فرضیات آزمایش	۲.۴
۷۳	توان آماری و اندازه نمونه	۳.۴
۷۳	مشخصات سخت‌افزار و نرم‌افزار	۴.۴
۷۴	فلسفه طراحی آزمایش	۵.۴
۷۴	رویه اجرای آزمایش	۶.۴
۷۴	پیکربندی‌های مدل خط پایه	۷.۴
۷۵	معیارهای ارزیابی و گزارش	۸.۴
۷۵	آزمایش ۱: مقایسه مدل اصلی	۹.۴
۷۵	هدف ۱.۹.۴	۱.۹.۴
۷۵	مدل‌ها ۲.۹.۴	۲.۹.۴
۷۶	خلاصه نتایج ۳.۹.۴	۳.۹.۴
۷۶	آزمایش ۲: حساسیت K-shot	۱۰.۴
۷۶	هدف ۱.۱۰.۴	۱.۱۰.۴
۷۶	جزئیات طراحی ۲.۱۰.۴	۲.۱۰.۴
۷۷	طراحی ۳.۱۰.۴	۳.۱۰.۴
۷۷	خلاصه نتایج ۴.۱۰.۴	۴.۱۰.۴
۷۷	آزمایش ۳: فدرال در برابر متمرکز	۱۱.۴
۷۷	هدف ۱.۱۱.۴	۱.۱۱.۴
۷۷	طراحی ۲.۱۱.۴	۲.۱۱.۴
۷۸	خلاصه نتایج ۳.۱۱.۴	۳.۱۱.۴
۷۸	آزمایش ۴: مطالعه حذف تدریجی	۱۲.۴
۷۸	هدف ۱.۱۲.۴	۱.۱۲.۴
۷۸	گونه‌ها ۲.۱۲.۴	۲.۱۲.۴
۷۸	خلاصه نتایج ۳.۱۲.۴	۳.۱۲.۴

۷۹	آزمایش ۵: تعمیم بین‌بیماری	۱۳.۴
۷۹	هدف	۱.۱۳.۴
۷۹	طراحی	۲.۱۳.۴
۷۹	خلاصه نتایج	۳.۱۳.۴
۷۹	رویه جستجوی ابرپارامتر	۱۴.۴
۸۰	آزمایش ۵.۸: گسترش‌های حذف تدریجی ETHOS	۱۵.۴
۸۰	هدف	۱.۱۵.۴
۸۰	طراحی	۲.۱۵.۴
۸۰	خلاصه نتایج	۳.۱۵.۴
۸۱	آزمایش ۵.۹: معماری‌های ترکیبی	۱۶.۴
۸۱	هدف	۱.۱۶.۴
۸۱	طراحی	۲.۱۶.۴
۸۱	خلاصه نتایج	۳.۱۶.۴
۸۱	جمع‌بندی فصل	۱۷.۴

۵ نتایج ۸۳

۸۴	بهترین مدل کلاسیک نهایی	۱.۵
۸۴	عملکرد FewShot+ETHOS	۲.۵
۸۶	آزمایش ۱: مقایسه مدل اصلی	۳.۵
۸۷	آزمایش ۲: حساسیت K-Shot	۴.۵
۸۸	آزمایش ۳: فدرال در برابر متمرکز	۵.۵
۸۸	آزمایش ۴: حذف تدریجی	۶.۵
۹۰	آزمایش ۵: تعمیم بین‌بیماری	۷.۵
۹۱	مقایسه گسترده مدل‌ها (۱۱ مدل)	۸.۵
۹۱	مقایسه مدل با بازه‌های اطمینان	۹.۵
۹۲	خلاصه یافته‌های کلیدی	۱۰.۵
۹۲	معناداری آماری	۱۱.۵
۹۲	تفسیرپذیری	۱۲.۵

۱۳.۵	مطالعات موردی بالینی	۹۶
۱۴.۵	تحلیل توزیع اطمینان	۹۶
۱۵.۵	معیارهای تفصیلی به تفکیک بیماری	۹۶
۱۶.۵	کالیبراسیون و تحلیل حساسیت	۹۷
۱۷.۵	تحلیل خطا به ازای ویژگی	۹۷
۱۸.۵	تحلیل ROC و دقت-بازخوانی	۹۸
۱۹.۵	منحنی‌های یادگیری و کارایی داده	۹۸
۲۰.۵	نتایج حساسیت ابرپارامتر	۹۸
۲۱.۵	تاب‌آوری تقسیم جایگزین	۹۹
۲۲.۵	تحلیل معماری مدل تقویت‌شده	۹۹
۲۳.۵	راهنمای آموزش بهبودیافته	۱۰۰
۱.۲۳.۵	راهنبرد ۱: سر نمونه‌اولیه-رابطه ترکیبی با پیش‌تنظیم نظارت‌شده	۱۰۰
۲.۲۳.۵	راهنبرد ۲: ترکیبی بهبودیافته (XGBoost + ETHOS)	۱۰۱
۳.۲۳.۵	راهنبرد ۳: طبقه‌بند نظارت‌شده ETHOS	۱۰۱
۴.۲۳.۵	راهنبرد ۴: FewShot V2؛ آموزش چندفازی با SupCon	۱۰۱
۵.۲۳.۵	راهنبرد ۵: FewShot V3؛ تقطیر دانش از Random Forest	۱۰۲
۶.۲۳.۵	راهنبرد ۶: FewShot V4؛ Proto-MAML، ترنسفورمر ویژگی	
۱۰۳	گروه‌بندی‌شده، و فرا یادگیر انباشتی	
۷.۲۳.۵	راهنبرد ۷: FewShot V5؛ توجه درگاهی به ویژگی، نمونه‌های cross-	
۱۰۴	attention، و تقطیر عمیق	
۸.۲۳.۵	راهنبرد ۸: FewShot V6؛ ensemble عمیق ناهمگن با انباشت XGBoost	۱۰۵
۹.۲۳.۵	تحلیل بهبودها	۱۰۶
۲۴.۵	جمع‌بندی فصل	۱۰۹

۱۱۰	۶ تحلیل داده و یافته‌های اکتشافی
۱۱۰	۱.۶ طرحواره و گردش داده MIMIC-IV
۱۱۱	۲.۶ جمعیت‌شناسی کوهورت
۱۱۲	۳.۶ توزیع گره بیماری

۴.۶	همبستگی آزمایشگاه و علائم حیاتی	۱۱۳
۵.۶	پراکسی SOFA و شدت بالینی	۱۱۴
۶.۶	عملکرد لایه‌بندی شده بر اساس سن	۱۱۴
۷.۶	تحلیل خطا: کراتینین	۱۱۴
۸.۶	تصویرسازی جاسازی (t-SNE)	۱۱۵
۹.۶	تحلیل نمونه	۱۱۶
۱۰.۶	نمونه خط زمانی بیمار	۱۱۶
۱۱.۶	تعادل کلاس	۱۱۸
۱۲.۶	فقدان داده و کیفیت داده	۱۱۸
۱۳.۶	ارزیابی کیفیت داده	۱۱۸
۱۴.۶	الگوهای زمانی	۱۱۹
۱۵.۶	توزیع مقادیر آزمایشگاه و علائم حیاتی	۱۱۹
۱۶.۶	نوع پذیرش و مقصد ترخیص	۱۱۹
۱۷.۶	ساختار همبستگی و افزونگی ویژگی	۱۲۰
۱۸.۶	جمع‌بندی فصل	۱۲۰

۷ بحث و گفتگو

۱.۷	تفسیر عملکرد	۱۲۱
۱.۱.۷	از نتیجه منفی تا نزدیکی به تساوی	۱۲۱
۲.۱.۷	سقف تجربی و بستن تدریجی فاصله	۱۲۱
۲.۷	محدودیت‌های فرا یادگیری few-shot	۱۲۲
۱.۲.۷	ناسازگاری اپیزودیک	۱۲۲
۲.۲.۷	ناسازگاری سوگیری القایی	۱۲۲
۳.۲.۷	مقیاس داده	۱۲۳
۴.۲.۷	بازنمایی	۱۲۴
۳.۷	تحلیل تفصیلی: چرا خط پایه اولیه few-shot ضعیف‌تر بود	۱۲۴
۱.۳.۷	عامل ۱: گلوگاه فشرده‌سازی بازنمایی	۱۲۴
۲.۳.۷	عامل ۲: هندسه نمونه اولیه در فضاها کم بعد	۱۲۵

۳.۳.۷	عامل ۳: واریانس نمونه برداری اپیزودیک	۱۲۵
۴.۳.۷	عامل ۴: مدل سازی تعامل ویژگی	۱۲۶
۵.۳.۷	عامل ۵: منظره بهینه سازی	۱۲۶
۴.۷	معامله ها و پیامدهای عملی	۱۲۶
۱.۴.۷	چه وقت از FewShot+ETHOS استفاده کنیم	۱۲۶
۲.۴.۷	چه وقت از مدل های کلاسیک استفاده کنیم	۱۲۷
۳.۴.۷	از ترکیبی به انباشت: مسیر تا تساوی	۱۲۷
۵.۷	تحلیل علی (اکتشافی)	۱۲۸
۱.۵.۷	تطبیق امتیاز گرایش	۱۲۸
۲.۵.۷	تحلیل متغیر ابزاری	۱۲۸
۶.۷	یادگیری چندوظیفه (اکتشافی)	۱۲۸
۷.۷	تحلیل حساسیت	۱۲۹
۱.۷.۷	حساسیت ابرپارامتر	۱۲۹
۲.۷.۷	حساسیت شات پشتیبان K	۱۲۹
۳.۷.۷	اثر ترکیب ماژول ها	۱۳۰
۸.۷	تحلیل ROI (نمایشی)	۱۳۰
۹.۷	گسترش سری زمانی (اکتشافی)	۱۳۰
۱۰.۷	تحلیل خطا	۱۳۱
۱۱.۷	ملاحظات استقرار	۱۳۱
۱۲.۷	مشخصات API	۱۳۱
۱۳.۷	تحلیل تفصیلی خطا به تفکیک زیرگروه	۱۳۲
۱۴.۷	مقایسه با کار پیشین	۱۳۲
۱.۱۴.۷	ادبیات پیش بینی ترخیص	۱۳۲
۲.۱۴.۷	یادگیری چندنمونه ای (few-shot) در بهداشت	۱۳۲
۳.۱۴.۷	بهداشت فدرال	۱۳۳
۱۵.۷	ملاحظات نظری	۱۳۴
۱.۱۵.۷	چرا شبکه های نمونه اولیه ممکن است ضعیف تر عمل کنند	۱۳۴
۲.۱۵.۷	کارایی داده	۱۳۴

۳.۱۵.۷	تهدیدهای اعتبار	۱۳۵
۴.۱۵.۷	گلوگاه بازنمایی: تحلیل عمیق تر	۱۳۵
۱۶.۷	مقایسه بین حوزه‌ای: یادگیری few-shot در انواع داده	۱۳۶
۱.۱۶.۷	حوزه بینش	۱۳۶
۲.۱۶.۷	حوزه NLP	۱۳۷
۳.۱۶.۷	حوزه کشف دارو	۱۳۷
۴.۱۶.۷	حوزه جدولی	۱۳۷
۵.۱۶.۷	ترکیب	۱۳۷
۱۷.۷	پیامدهای بالینی و تحلیل استقرار	۱۳۸
۱.۱۷.۷	تأثیر بر گردش کار بالینی	۱۳۸
۲.۱۷.۷	اعتماد و پذیرش بالینی	۱۳۸
۳.۱۷.۷	معماری استقرار فدرال	۱۳۹
۴.۱۷.۷	مسیر نظارتی	۱۴۰
۱۸.۷	نوآوری و مشارکت‌های اصلی	۱۴۰
۱۹.۷	جدول مقایسه: کار ما در برابر پیشین	۱۴۲
۲۰.۷	ملاحظات اخلاقی و انصاف	۱۴۲
۲۱.۷	چک‌لیست بازتولیدپذیری	۱۴۳
۲۲.۷	درس‌های آزمایش‌های V5 و V6	۱۴۳
۲۳.۷	کارهای آینده	۱۴۴
۲۴.۷	خلاصه نکات کلیدی و درس‌های آموخته‌شده	۱۴۵
۲۵.۷	خلاصه محدودیت‌ها	۱۴۶
۲۶.۷	جمع‌بندی فصل	۱۴۷

۸ نتیجه‌گیری

۱.۸	خلاصه مشارکت‌ها	۱۴۹
۱.۱.۸	پیامدها برای استقرار بالینی	۱۴۹
۲.۱.۸	تطبیق نهایی با پروپوزال	۱۵۱
۳.۱.۸	توصیه‌ها برای پژوهشگران و عملگران	۱۵۱

۴.۱.۸	اهمیت برای حوزه	۱۵۲
۵.۱.۸	جمع‌بندی	۱۵۲
۶.۱.۸	پاسخ به پرسش‌های پژوهشی	۱۵۲

آ ابرپارامترها ۱۵۴

۱.آ	رمزگذار ETHOS	۱۵۴
۲.آ	یادگیری کم‌نمونه (Few-Shot)	۱۵۴
۳.آ	یادگیری فدرال (Federated)	۱۵۴
۴.آ	بهترین مدل نهایی (Random Forest)	۱۵۴

ب پرس‌وجوهای SQL برای MIMIC-IV ۱۵۶

۱.ب	استخراج کوهورت	۱۵۶
۲.ب	استخراج آزمایشگاه	۱۵۷
۳.ب	استخراج علائم حیاتی	۱۵۷
۴.ب	برچسب: محل ترخیص	۱۵۷
۵.ب	تشخیص اولیه برای گره‌های بیماری	۱۵۸
۶.ب	تجمیع: اولین مقدار به‌ازای هر بستری	۱۵۸

پ قطعه‌کدهای برنامه ۱۶۰

۱.پ	Tokenization علائم	۱۶۰
۲.پ	سر Prototypical	۱۶۰
۳.پ	Focal Loss	۱۶۱
۴.پ	عبور رو به جلوی رمزگذار ETHOS	۱۶۱
۵.پ	به‌روزرسانی سرور FedAvg	۱۶۲

ت جداول کامل نتایج ۱۶۳

۱.ت	Tabular SOTA: همه مدل‌ها	۱۶۳
۲.ت	نتایج Ensemble	۱۶۳
۳.ت	شناسه‌های آیتم آزمایشگاه و علائم حیاتی	۱۶۴

۱۶۶	ت	استنتاج‌های ریاضی
۱۶۶	۱.ث	تعریف AUROC
۱۶۷	۲.ث	F1-Macro
۱۶۷	۳.ث	ضریب همبستگی متیوز (MCC)
۱۶۷	۴.ث	گرادیان تابع زیان شبکه نمونه‌اولیه‌ای (Prototypical)
۱۶۸	۵.ث	Focal Loss
۱۶۸	۶.ث	قانون به‌روزرسانی FedAvg
۱۶۸	۷.ث	خودتوجه (Self-Attention)
۱۶۹	۸.ث	بازه اطمینان bootstrap
۱۶۹	۹.ث	آزمون DeLong
۱۷۰	ج	زمان‌بندی پروژه (نمودار گانت)
۱۷۰	۱.ج	زمان‌بندی ۱۲ ماهه
۱۷۰	۲.ج	نمای کلی فازها
۱۷۰	۳.ج	نقاط عطف کلیدی
۱۷۱	۴.ج	گرافیک نقشه راه
۱۷۱	۵.ج	مدیریت ریسک
۱۷۳	چ	واژه‌نامه (۵۰ واژه)
۱۷۳	۱.چ	مفاهیم هسته
۱۷۳	۲.چ	واژه‌نامه تفصیلی (فهرست کامل)
۱۷۷	ح	تهدیدهای اعتبار و کاهش اثر
۱۷۷	۱.ح	اعتبار درونی
۱۷۷	۲.ح	محدودیت‌ها
۱۷۹	خ	چک‌لیست تکرارپذیری
۱۷۹	۱.خ	چک‌لیست
۱۷۹	۲.خ	فهرست کد

خ.۳ دسترسی به داده ۱۸۰

خ.۴ محیط و وابستگی‌ها ۱۸۰

د جداول نتایج صادرشده از خط لوله ۱۸۲

ذ ملاحظات اخلاقی ۱۸۴

ذ.۱ چارچوب اخلاقی ۱۸۴

ذ.۲ پیامدهای سیاست ۱۸۴

ذ.۳ ادعاهای به‌سبک ثبت اختراع ۱۸۵

ر عناصر خلاقانه و تجسم‌ها ۱۸۶

ر.۱ پوستره‌های معماری ۱۸۶

ر.۲ اینفوگرافیک سفر بیمار ۱۸۶

ر.۳ تحلیل SWOT ۱۸۷

ر.۴ دمو‌ی تعاملی ۱۸۷

ر.۵ نمودار گردباد حساسیت ۱۸۷

ر.۶ مختصات موازی ۱۸۷

ز مشخصات API ۱۸۸

ز.۱ نمای کلی ۱۸۸

ز.۲ نقاط پایانی ۱۸۸

ز.۲.۱ POST /predict ۱۸۸

ز.۲.۲ GET /model ۱۸۹

ز.۲.۳ POST /explain ۱۸۹

ز.۳ خلاصه OpenAPI ۱۸۹

ژ جداول تفصیلی جستجوی ابرپارامتر و حذف اجزا ۱۹۰

ژ.۱ شبکه ابرپارامتر Random Forest ۱۹۰

ژ.۲ شبکه ابرپارامتر XGBoost ۱۹۲

ژ.۳ حذف اجزای ETHOS: نتایج کامل ۱۹۲

۴.ژ	حساسیت K-Shot: جدول کامل	۱۹۲
۵.ژ	دورهای فدرال: معیارها به تفکیک دور	۱۹۲
۶.ژ	چندبیماری: نتایج کامل همه گره‌ها	۱۹۲

س خلاصه معادلات کلیدی ۱۹۴

۱.س	پیش‌پردازش داده	۱۹۴
۲.س	Symptom Token	۱۹۴
۳.س	شبکه‌های نمونه‌اولیه‌ای	۱۹۴
۴.س	Focal Loss	۱۹۵
۵.س	FedAvg	۱۹۵
۶.س	معیارها	۱۹۵
۷.س	ویژگی‌های مهندسی‌شده	۱۹۵
۸.س	خودتوجه	۱۹۶

ش فهرست اختصارات ۱۹۷

ص مرور ادبیات تفصیلی ۱۹۹

۱.ص	یادگیری کم‌نمونه: مقالات کلیدی	۱۹۹
۲.ص	یادگیری فدرال: کاربردهای مراقبت سلامت	۲۰۰
۳.ص	پیش‌بینی بالینی: نتایج معیار	۲۰۰
۴.ص	جزئیات معماری Transformer	۲۰۰
۵.ص	جزئیات پروتکل ارزیابی	۲۰۱
۶.ص	مقایسه با کارهای پیشین MIMIC-III	۲۰۱

ض ارزیابی تفصیلی و تحلیل حساسیت ۲۰۲

۱.ض	معیارهای تفصیلی به تفکیک بیماری	۲۰۲
۲.ض	شبکه حساسیت ابرپارامتر	۲۰۳
۳.ض	تحلیل منحنی یادگیری	۲۰۳
۴.ض	کالیبراسیون به تفکیک مدل	۲۰۳

۲۰۳	۵.ض تقسیم‌های ارزیابی جایگزین
۲۰۴	۶.ض پایداری اهمیت ویژگی
۲۰۴	۷.ض نتایج تفصیلی V5 و V6
۲۰۴	۸.ض تحلیل به تفکیک بذر برای V5
۲۰۵	۹.ض تحلیل به تفکیک معماری برای V6
۲۰۵	۱۰.ض تحلیل پیش‌بینی مطابق (V6)
۲۰۶	۱۱.ض خلاصه بهبود تدریجی

ط استنتاج‌ها و اثبات‌های ریاضی ۲۰۷

۲۰۷	۱.ط گرادیان تابع زیان نمونه‌اولیه‌ای
۲۰۷	۲.ط فرمول‌بندی Focal Loss
۲۰۸	۳.ط آزمون DeLong برای مقایسه ROC
۲۰۸	۴.ط بازه‌های اطمینان bootstrap
۲۰۸	۵.ط استنتاج پراکسی SOFA
۲۰۹	۶.ط شاخص شوک

چکیده انگلیسی ۲۱۹

فهرست تصاویر

۴۶	۱.۳ فرایند انتها به انتها: استخراج داده، بازنمایی دوگانه (جدولی و مبتنی بر توکن)، و شاخه‌های مدل
	۱.۵ منحنی‌های ROC (خروجی تولیدشده): کلاسیک در برابر ETHOS در برابر اجرای انباشتی few-shot (AUROC دقیق در جداول)
۸۵	۲.۵ منحنی‌های دقت-بازخوانی برای ETHOS و Random Forest
	۳.۵ منحنی‌های یادگیری: AUROC در برابر اندازه آموزش برای RF و ETHOS+FewShot خط پایه
۸۶	(V0). بهبودهای V4 و V5 در بازه ۰.۷۴-۰.۷۱ نمایش داده نشده‌اند.

۴.۵	حساسیت K-shot AUROC: در برابر K با باندهای بازه اطمینان ۹۵٪.	۸۸
۵.۵	همگرایی فدرال: AUROC اعتبارسنجی در برابر دور.	۸۹
۶.۵	مطالعه حذف تدریجی به صورت رادار: سهم هر جزء.	۹۰
۷.۵	مقایسه اصلی مدل‌ها: AUROC در برابر همه خطوط پایه و مدل‌های پیشنهادی.	۹۱
۸.۵	اهمیت ویژگی (Random Forest). کراتینین، گلوکز، هموگلوبین بالاترین رتبه را دارند.	۹۴
۹.۵	آبشار SHAP برای یک بیمار برتر (Random Forest). سهم ویژگی‌ها در پیش‌بینی.	۹۵
۱۰.۵	منحنی‌های کالیبراسیون: احتمال پیش‌بینی‌شده در برابر فراوانی مشاهده‌شده. RF نسبتاً خوب	
۹۵	کالیبره است؛ ETHOS گرایش به بیش‌اعتمادی دارد.	
۱.۶	طرح استخراج MIMIC-IV: جدول‌های منبع، کلیدهای اتصال، و پیش‌پردازش به بازنمایی‌های	
۱۱۰	جدولی و توکنی (نمودار برداری؛ تک‌رنگ برای چاپ).	
۲.۶	ماتریس همبستگی پیرسون برای آزمایشگاه‌ها و علائم حیاتی (ساختار گویای کوهورت آموزش).	۱۱۳
۳.۶	پراکسی SOFA در برابر کراتینین (نرمال‌شده) به تفکیک برچسب امکان‌پذیری؛ SOFA و کراتینین	
۱۱۴	بالاتر با تریخیص ناممکن همراه‌اند.	
۴.۶	AUROC آزمون لایه بندی شده بر سن: Random Forest، انباشت V4، و خط پایه	
۱۱۵	FewShot+ETHOS.	
۵.۶	نرخ خطای طبقه‌بندی به تفکیک بازه کراتینین (RF در برابر ETHOS) با شمار بیماران.	۱۱۵
۶.۶	t-SNE جاسازی‌های ETHOS (بیماران آزمون): هم‌پوشانی جزئی کلاس‌های ممکن در برابر ناممکن.	۱۱۶
۷.۶	شماتیک مجموعه‌های پشتیبان، نمونه‌های کلاس، و طبقه‌بندی پرس‌وجو در فضای جاسازی	
۱۱۷	(پیش‌نمایش دوبعدی).	
۸.۶	نمونه مسیر ۲۴ ساعت اول ICU: ضربان قلب، فشار خون، و کراتینین (گویای).	۱۱۷
۱.ج	فازهای کار آینده (۱ تا ۵ سال)	۱۷۱

فهرست جداول

۱.۱	تطبیق اجزای پروپوزال با اجرای نهایی پایان‌نامه	۱۰
-----	--	----

۳۲	ETHOS در برابر رمزگذار ترنسفورمر عمومی	۱.۲
۳۴	مقایسه کارهای پیشین در پیش‌بینی بالینی	۲.۲
۴۰	مجموعه‌های داده بنچمارک ML بالینی	۳.۲
۴۵	خلاصه نمادگذاری	۱.۳
۴۷	آمار جمعیت‌شناختی کوهورت MIMIC-IV	۲.۳
۴۸	بازه‌های آزمایشگاهی منتخب (۱۵ آزمایش)	۳.۳
۴۹	بازه‌های علائم حیاتی منتخب (۷ علامت حیاتی)	۴.۳
۵۰	خلاصه بردار ویژگی 25-بعدی	۵.۳
۵۷	افراز گره فدرال (مجموعه آموزش)	۶.۳
۷۳	فرضیات آزمایش و پیامدهای مورد انتظار	۱.۴
۸۴	فرایند جدولی SOTA؛ بهترین پیکربندی آزمون (فاز ۴)	۱.۵
۲.۵	بهترین اجرای few-shot (exp_fewshot_best.py، مجموعه آزمون)؛ few-shot در برابر	
۸۶	انباشتی	
۸۷	آزمایش ۱: مقایسه مدل اصلی (مجموعه آزمون)؛ exp1_main.py	۳.۵
۸۷	آزمایش ۲: حساسیت K-shot (exp2_shots.py، پروتکل اپیزودیک)	۴.۵
۸۸	آزمایش ۳: فدرال در برابر متمرکز (exp3_federated.py)	۵.۵
۸۹	جریان ارتباطی FedAvg ($T = 20$ دور، ۵ گره)	۶.۵
۸۹	آزمایش ۴: مطالعه حذف تدریجی (exp4_ablation.py)	۷.۵
۹۰	آزمایش ۵: تعمیم بین‌بیماری (AUROC به تفکیک گره آزمون)	۸.۵
۹۱	مقایسه گسترده مدل‌ها؛ معیارهای نماینده آزمون (همگام با خروجی‌های مخزن)	۹.۵
۱۰.۵	مدل‌های منتخب با بازه‌های مستند (بوت‌استرپ از exp_fewshot_best.json؛ سطر RF	
۹۲	Exp1 برآورد نقطه‌ای از تقسیم ثابت است).	
۹۳	خلاصه یافته‌های کلیدی (مجموعه آزمون، همگام‌شده)	۱۱.۵
۹۴	تفسیر بالینی ویژگی‌های برتر (Random Forest)	۱۲.۵
۹۷	معیارها به تفکیک بیماری (RF در برابر Proposed_FewShot)	۱۳.۵
۹۹	تحلیل اولیه تقویت معماری برای FewShot+ETHOS (روایت تاریخی توسعه، فقط نمونه‌اولیه)	۱۴.۵

۱۵.۵	راهنمادهای آموزش بهبودیافته در کمپین تاریخی V0-V6؛ همه مدل‌ها روی همان مجموعه آزمون	۱۰۶
۱.۶	گردش استخراج و پردازش داده MIMIC-IV	۱۱۱
۲.۶	جمعیت‌شناسی گسترده کوهورت	۱۱۲
۳.۶	نمونه‌هایی از کدهای ICD-10 به تفکیک گره بیماری	۱۱۲
۴.۶	توزیع بیماران به تفکیک گره بیماری	۱۱۳
۵.۶	نرخ فقدان به تفکیک دسته ویژگی (۲۴ ساعت اول)	۱۱۸
۱.۷	راهنمای انتخاب مدل	۱۲۷
۲.۷	عملکرد تک‌وظیفه در برابر چندوظیفه (اکتشافی؛ مبتنی بر پیکربندی تاریخی ETHOS)	۱۲۹
۳.۷	مقایسه با نتایج پیشین ترخیص/پیامد	۱۳۳
۴.۷	عملکرد یادگیری few-shot در حوزه‌های مختلف	۱۳۸
۵.۷	مقایسه با کار پیشین	۱۴۲
۶.۷	نقشه‌راه کار آینده	۱۴۵
۱.۸	خلاصه مشارکت‌ها	۱۵۰
۲.۸	خلاصه پاسخ به پرسش‌های پژوهشی	۱۵۳
۱.آ	پیکربندی رمزگذار ETHOS	۱۵۴
۲.آ	پیکربندی Few-Shot	۱۵۵
۳.آ	پیکربندی فدرال	۱۵۵
۴.آ	ابزارهای RandomForest_threshold_tuned	۱۵۵
۱.ت	خط لوله Tabular SOTA: مدل‌های تکی (مجموعه آزمون)	۱۶۳
۲.ت	مدل‌های Ensemble (مجموعه آزمون)	۱۶۳
۳.ت	شناسه‌های آیتیم آزمایشگاه MIMIC-IV	۱۶۴
۴.ت	شناسه‌های آیتیم علائم حیاتی MIMIC-IV	۱۶۵
۱.ج	نمای کلی گانت پروژه	۱۷۱
۲.ج	مدیریت ریسک پروژه	۱۷۲
۱.چ	واژه‌نامه (واژه‌های منتخب)	۱۷۶

۱۷۸	تهدیدهای اعتبار و کاهش اثر	ح.۱
۱۷۹	چک لیست تکرارپذیری	خ.۱
۱۸۲	Experiment 1: Main Model Comparison	د.۱
۱۸۳	Experiment 2: K-Shot Sensitivity	د.۲
۱۸۳	Experiment 3: Federated vs Centralized	د.۳
۱۸۳	Experiment 4: Ablation Study	د.۴
۱۸۳	Experiment 5: Cross-Disease Generalization	د.۵
۱۸۴	ملاحظات اخلاقی	د.۱
۱۸۷	SWOT: یادگیری ماشین جدولی در برابر یادگیری عمیق	ر.۱
۱۸۹	خلاصه نقاط پایانی API	ز.۱
۱۹۰	شبکه RandomizedSearchCV برای Random Forest	ژ.۱
۱۹۱	شبکه RandomizedSearchCV برای XGBoost	ژ.۲
۱۹۱	مطالعه حذف اجزا (همگام با خروجی فعلی مخزن)	ژ.۳
۱۹۲	حساسیت K-shot (همه مقادیر آزموده شده)	ژ.۴
۱۹۲	آموزش فدرال: AUROC اعتبارسنجی به تفکیک دور (نمونه)	ژ.۵
۱۹۳	تعمیم بین بیماری (همه گره ها)	ژ.۶
۱۹۸	اختصارات به کاررفته در این پایان نامه	ش.۱
۱۹۹	مقالات کلیدی یادگیری کم نمونه	ص.۱
۲۰۲	معیارها به تفکیک بیماری (RF در برابر Proposed_FewShot)	ص.۱
۲۰۴	معیارهای تفصیلی V5 و V6 (مجموعه آزمون)	ص.۲
۲۰۴	AUROC به تفکیک بذر V5 (5-Seed Ensemble)	ص.۳
۲۰۵	AUROC به تفکیک معماری V6 (۲ بذر برای هر کدام)	ص.۴
۲۰۶	بهبود تدریجی کامل: V0 تا V6	ص.۵

فصل ۱

کلیات تحقیق

۱.۱ بستر بالینی

۱.۱.۱ محیط بخش مراقبت ویژه و تصمیم‌گیری

بخش مراقبت‌های ویژه (ICU) محیطی پرخطر و زمان‌حساس است؛ جایی که تصمیم‌های بالینی باید با اتکا به داده‌های ناقص اما پیوسته به‌روز گرفته شوند. بیماران این بخش معمولاً وضعیت ناپایدارتری دارند و تحت پایش مداوم علائم حیاتی، آزمایش‌های مکرر و مراقبت تیم‌های چندرشته‌ای قرار می‌گیرند. تصمیم‌هایی که در ۲۴ تا ۴۸ ساعت نخست بستری گرفته می‌شود، اغلب مسیر کل بستری را تعیین می‌کند؛ از تحرک‌دهی زودهنگام و جداسازی از ونتیلاسیون مکانیکی تا برنامه‌ریزی ترخیص، همگی به برآورد دقیق پایداری بالینی و ظرفیت بهبود بیمار وابسته‌اند.

۲.۱.۱ گردش کار بالینی و نقاط تصمیم

گردش کار معمول ICU را می‌توان در چهار گام خلاصه کرد: (۱) پذیرش و ارزیابی اولیه؛ (۲) تثبیت وضعیت در ۲۴ تا ۴۸ ساعت نخست؛ (۳) پایش و درمان مداوم؛ و (۴) برنامه‌ریزی ترخیص. ارزیابی امکان‌پذیری درمان معمولاً در مرحله تثبیت انجام می‌شود، زمانی که نخستین روندهای آزمایشگاهی و علائم حیاتی در دسترس قرار گرفته‌اند. بالین‌گران در این مرحله چند جریان داده را کنار هم می‌گذارند: پانل‌های آزمایشگاهی مانند کراتینین، لاکتات و گلوکز؛ علائم حیاتی مانند ضربان قلب، فشار خون و SpO_2 ؛ و یادداشت‌های بالینی. مدلی که بتواند این داده‌ها را به‌صورت منسجم ترکیب کند، می‌تواند

بیمارانی را که شانس ترخیص ایمن زودهنگام دارند زودتر شناسایی کند و برنامه‌ریزی ترخیص را دقیق‌تر سازد.

۳.۱.۱ برنامه‌ریزی ترخیص و امکان‌پذیری درمان

برنامه‌ریزی ترخیص از آغاز بستری در ICU آغاز می‌شود. بالین‌گران باید به‌طور مداوم ارزیابی کنند که آیا بیمار می‌تواند به‌صورت ایمن به منزل، توان‌بخشی یا مرکز دیگری ترخیص شود. این ارزیابی (امکان‌پذیری درمان)، روندهای آزمایشگاهی (مثلاً بهبود کراتینین در نارسایی کلیوی)، پایداری علائم حیاتی (مثلاً جداسازی از وازوپرسورها)، وضعیت عملکردی و عوامل اجتماعی تعیین‌کننده سلامت را یکپارچه می‌کند. ترخیص زودهنگام خطر بستری مجدد را افزایش می‌دهد؛ تأخیر در ترخیص ظرفیت ICU را تحت فشار قرار می‌دهد و هزینه‌ها را بالا می‌برد.

مراقبت‌های بهداشتی مدرن به‌طور فزاینده‌ای به داده‌های تجمیع‌شده (پایگاه‌های داده بیمارستانی، پرونده‌های ICU، دستگاه‌های پوشیدنی و گزارش علائم از منابع متعدد) برای پشتیبانی از پیش‌بینی سلامت فردی تکیه دارد. امکان‌پذیری درمان، که به‌صورت ارزیابی دودویی دستیابی به ترخیص ایمن در بازه زمانی معقول تعریف می‌شود، نقطه تصمیم‌گیری است. مدل‌های یادگیری ماشین که امکان‌پذیری را از داده‌های اولیه ICU پیش‌بینی کنند می‌توانند به بالین‌گران در برنامه‌ریزی ترخیص کمک کنند، به‌شرط آنکه دقیق، قابل‌تفسیر و قابل‌استقرار در شرایط واقعی باشند.

۲.۱ تحول دیجیتال در سلامت

نظام سلامت در سال‌های اخیر دگرگونی دیجیتال گسترده‌ای را تجربه کرده است. گسترش پرونده الکترونیک سلامت (EHR)، ابزارهای پوشیدنی پایش سلامت، پزشکی از راه دور و استانداردهای تبادل داده مانند HL7 FHIR باعث شده حجم و تنوع داده‌های بالینی به‌طور چشمگیری افزایش یابد. پیش‌بینی‌ها نشان می‌دهند بازار جهانی سلامت دیجیتال تا سال ۲۰۲۸ از ۵۰۰ میلیارد دلار فراتر خواهد رفت؛ رشدی که نشان‌دهنده اهمیت روزافزون سامانه‌های پشتیبان تصمیم‌مبتنی بر داده است. این تحول، هم فرصت‌های تازه‌ای برای یادگیری ماشین ایجاد می‌کند و هم چالش‌های جدی درباره کیفیت، حریم خصوصی و قابلیت تعمیم داده‌ها پیش می‌کشد.

۱.۲.۱ از سیلوهای داده تا هوش تجمیعی

از نظر تاریخی، داده‌های بالینی در سیلوهای نهادی قرار داشت؛ هر بیمارستان سامانه EHR خود را با طرحواره‌های اختصاصی، قراردادهای کدگذاری و کنترل‌های دسترسی نگه می‌داشت. ظهور تبادلات اطلاعات سلامت (HIE) و شبکه‌های داده فدرال شروع به شکستن این موانع کرده است و پژوهش‌چندنهادی را بدون متمرکزسازی کامل داده ممکن می‌سازد. ابتکارهایی مانند PCORnet، OHDSI (Observational Health Data Sciences and Informatics) و برنامه UK NHS Digital پتانسیل هوش بالینی تجمیعی را نشان می‌دهند. با این حال، این شبکه‌ها با چالش‌های پایدار روبه‌رو هستند: قالب‌های ناهمگون داده، کیفیت متغیر داده، امتناع نهادی از اشتراک پرونده‌های حساس و محدودیت‌های مقرراتی که در حوزه‌های قضایی مختلف متفاوت است.

این پایان‌نامه در همین بستر تعریف می‌شود. ایده اصلی آن است که یادگیری فدرال با سازگاری چندنمونه‌ای (few-shot) ترکیب شود تا مدل بتواند از داده‌های بالینی توزیع شده بیاموزد، بدون آنکه داده‌های خام در یک مرکز تجمع شوند. بازنمایی symptom token نیز نقش یک لایه میانی استاندارد را دارد؛ یعنی داده‌های ناهمگون را به قالبی تبدیل می‌کند که برای مدل قابل استفاده باشد و در عین حال وابستگی مستقیم به قالب خام هر نهاد را کاهش دهد.

۲.۲.۱ وعده و خطر هوش مصنوعی بالینی

هوش مصنوعی در مراقبت‌های بهداشتی در حوزه‌های مشخص نتایج چشمگیر به دست آورده است: رادیولوژی (مثلاً غربالگری رتینوپاتی دیابتی)، پاتولوژی (مثلاً تشخیص تومور) و پردازش زبان طبیعی (مثلاً خلاصه‌سازی یادداشت بالینی). با این حال، انتقال پژوهش AI به عمل بالینی کند مانده است. موانع کلیدی عبارت‌اند از: (۱) شکاف‌های اعتبارسنجی؛ مدل‌های آموزش دیده بر داده گذشته‌نگر ممکن است به استقرار آینده‌نگر تعمیم نیابند؛ (۲) عدم قطعیت مقرراتی؛ چارچوب در حال تکامل FDA برای نرم‌افزار به عنوان دستگاه پزشکی (SaMD) ابهام ایجاد می‌کند؛ (۳) اعتماد بالین‌گر؛ مدل‌های مبهم با مقاومت پزشکانی روبه‌رو می‌شوند که مسئولیت پیامدهای بیمار را بر عهده دارند؛ و (۴) دسترسی به داده؛ مقررات حریم خصوصی داده موجود برای توسعه مدل را محدود می‌کند.

این پایان‌نامه به طور مستقیم به دو مانع مهم می‌پردازد: محدودیت دسترسی به داده از طریق یادگیری فدرال، و شکاف اعتبارسنجی از طریق طراحی آزمایش و گزارش دقیق. نتیجه منفی اولیه، یعنی عملکرد ضعیف‌تر مدل چندنمونه‌ای نسبت به مدل‌های کلاسیک، پنهان نشده است؛ بلکه به عنوان نقطه

شروع تحلیل مطرح می‌شود. سپس با چند دور بهبود مهندسی و مدل‌سازی، فاصله با سقف جدولی کاهش می‌یابد. این رویکرد با روح ارزیابی مسئولانه AI در سلامت سازگار است، زیرا اعتماد بالینی زمانی شکل می‌گیرد که هم موفقیت‌ها و هم محدودیت‌ها شفاف گزارش شوند.

۳.۲.۱ امکان‌پذیری درمان در عصر مراقبت مبتنی بر ارزش

گذار از مدل کارمزد به‌ازای خدمت به مدل‌های مراقبت مبتنی بر ارزش، برنامه‌ریزی ترخیص را به اولویت مالی و بالینی تبدیل کرده است. در برنامه‌های پرداخت تجمیعی (مثلاً CMS Bundled Payments for Care Improvement)، بیمارستان‌ها مسئولیت مالی بستری مجدد در ۳۰ روز را بر عهده دارند. پیش‌بینی دقیق امکان‌پذیری درمان (اینکه آیا بیمار می‌تواند در بازه زمانی بالینی مناسب به ترخیص ایمن دست یابد) مستقیماً بر تخصیص منابع، مدیریت تخت و بازپرداخت اثر می‌گذارد. شناسایی زودهنگام بیمارانی که احتمال ترخیص ممکن را دارند، هماهنگی مراقبت پیشگیرانه را ممکن می‌سازد: ترتیب خدمات بهداشت خانگی، زمان‌بندی ارزیابی‌های توان‌بخشی و ارتباط با خانواده‌ها درباره جدول زمانی مورد انتظار.

بستر ICU به‌ویژه سرنوشت‌ساز است؛ هزینه هر روز بستری در ICU حدوداً ۳ تا ۵ برابر هزینه روز بستری در بخش عمومی است و ظرفیت ICU در اوج موج‌ها محدودیت الزام‌آور است (همان‌طور که در همه‌گیری COVID-19 نشان داده شد). ابزار پشتیبان تصمیم که زمان‌بندی ترخیص را حتی یک روز بهبود دهد می‌تواند صرفه‌جویی هزینه قابل توجه و جریان بهتر بیمار را به همراه داشته باشد.

۳.۱ انگیزه

انگیزه اصلی این کار از یک تجربه عملی شکل گرفت. هنگام کار با پلتفرم Mayo Clinic روشن شد که دسترسی به داده سلامت، حتی برای هدف‌های پژوهشی، بسیار محدود است: در بسیاری موارد تنها شناسه‌ها و کدها در دسترس‌اند و پرونده‌های بالینی زیربنایی قابل استفاده نیستند. این تجربه پرسش اصلی پایان‌نامه را برجسته کرد: اگر داده را نتوان متمرکز یا آزادانه مبادله کرد، چگونه می‌توان سامانه‌های پیش‌بین قابل اعتماد ساخت؟ پاسخ این پایان‌نامه بررسی ترکیب یادگیری فدرال، سازگاری چندمنه‌ای و بازنمایی‌های فشرده مانند Symptom Tokens است.

بخش مراقبت ویژه (ICU) یکی از غنی‌ترین محیط‌های داده‌ای و در عین حال بحرانی‌ترین محیط‌های تصمیم در مراقبت‌های مدرن است. بالین‌گران باید به‌طور مداوم پایداری بیمار، پیامدها و

مقصد مناسب ترخیص را بر اساس مشاهدات اولیه محدود ارزیابی کنند. امکان پذیری درمان (پرسش دودویی اینکه آیا بیمار می تواند به صورت ایمن به منزل، توان بخشی یا سایر بسترهای غیرحاد ترخیص شود) به مقادیر آزمایشگاهی، علائم حیاتی و مسیرهای بالینی مشاهده شده در ساعات نخست بستری ICU وابسته است.

علیرغم پیشرفت ها در EHR و یادگیری ماشین، چند چالش بنیادین پابرجاست. نخست، کمیابی داده: بسیاری از زیرگروه های بیماری نمونه های برچسب خورده اندک دارند و یادگیری نظارت شده استاندارد را دشوار می کند. دوم، حریم خصوصی: داده بهداشتی به دلیل محدودیت های مقرراتی (مثلاً HIPAA، GDPR) را نمی توان بین نهادها متمرکز کرد. سوم، بازنمایی: داده بالینی خام ناهمگون است (آزمایشگاه، علائم حیاتی، جمعیت شناسی) و برای مدل های پایین دست پیش پردازش دقیق می طلبد. چهارم، تعمیم: مدل های آموزش دیده بر یک گروه بیماری ممکن است به گروه های دیگر منتقل نشوند. یادگیری چندنمونه ای [Vinyals et al., 2016, Snell et al., 2017] این امکان را فراهم می کند که مدل با تعداد کمی نمونه پشتیبان برای هر دسته، بیماران جدید را طبقه بندی کند. از سوی دیگر، یادگیری فدرال [McMahan et al., 2017] آموزش بر داده توزیع شده را بدون انتقال نمونه های خام ممکن می سازد. ترکیب این دو رویکرد می تواند مدلی ایجاد کند که از داده محدود بیاموزد، حریم خصوصی را حفظ کند و بین گروه های بیماری تعمیم یابد. این پایان نامه بررسی می کند که آیا چنین ترکیبی برای پیش بینی امکان پذیری درمان روی MIMIC-IV [Johnson et al., 2023] عملی و قابل دفاع است یا خیر.

۴.۱ بیان مسئله

پیش بینی امکان پذیری درمان را به عنوان وظیفه طبقه بندی دودویی صورت بندی می کنیم. با مشاهدات بالینی بیمار از ۲۴ ساعت نخست بستری در ICU، پیش بینی می کنیم که آیا بیمار به ترخیص ممکن دست خواهد یافت؛ تعریف شده به عنوان ترخیص به منزل، مراقبت خانگی یا توان بخشی ظرف ۳۰ روز از پذیرش ICU، بدون بستری مجدد ظرف ۳۰ روز. برچسب از سوابق ترخیص و بستری مجدد MIMIC-IV استخراج می شود.

به صورت رسمی، فضای بازنمایی بیماران را با $\mathcal{X}$ (مثلاً دنباله symptom token یا بردارهای ویژگی جدولی) و برچسب دودویی را با $\mathcal{Y} = \{0, 1\}$ (۰ = غیرممکن، ۱ = ممکن) نشان می دهیم. تابعی $f: \mathcal{X} \rightarrow \mathcal{Y}$ می جوئیم که خطای پیش بینی را بر مجموعه آزمون نگه داشته شده کمینه کند، با قید

اینکه f ممکن است در بستر چندنمونه‌ای و فدرال آموزش داده شود.

چالش‌های کلیدی عبارت‌اند از:

۱. **بستر چندنمونه‌ای:** در زمان استنتاج ممکن است برای هر دسته فقط K نمونه برچسب‌خورده

در اختیار باشد، برای مثال $K = 5$. مدل باید بتواند از این نمونه‌های پشتیبان به بیماران

پرس‌وجوی جدید تعمیم دهد.

۲. **بستر فدرال:** داده آموزشی میان N گره، مانند گروه‌های بیماری، تقسیم شده است و داده خام

از گره‌های محلی خارج نمی‌شود. بنابراین آموزش باید از طریق تجمیع فدرال انجام شود.

۳. **بازنمایی:** لازم است بازنمایی فشرده و معناداری از آزمایش‌ها و علائم حیاتی ساخته شود که

هم برای مدل‌های کلاسیک و هم برای مدل‌های عصبی چندنمونه‌ای قابل استفاده باشد.

چرا چندنمونه‌ای؟ در استقرار دنیای واقعی، زیرگروه‌های بیماری جدید یا نهادهای ممکن است داده

برچسب‌خورده محدود داشته باشند. یادگیری چندنمونه‌ای اجازه می‌دهد مدل تنها با K نمونه برای هر

دسته سازگار شود و نیاز به مجموعه‌های حجیم حاشیه‌نویسی‌شده در هر سایت را کاهش دهد. این امر

به‌ویژه برای بیماری‌های نادر یا شرایط نوظهور اهمیت دارد.

چرا فدرال؟ داده بهداشتی به‌دلیل مقررات حریم خصوصی (GDPR, HIPAA) را نمی‌توان متمرکز

کرد. یادگیری فدرال مدل‌ها را بر داده توزیع‌شده بدون جابه‌جایی پرونده‌های خام آموزش می‌دهد و

همکاری بین‌نهادی را با حفظ حاکمیت داده ممکن می‌سازد.

چرا Symptom Tokens؟ داده بالینی خام ناهمگون است: آزمایشگاه‌ها واحدهای مختلف دارند

(mmol/L, mg/dL)، علائم حیاتی دامنه‌های متفاوت دارند و اندازه‌گیری‌ها به‌صورت نامنظم نمونه‌برداری

می‌شوند. بازنمایی مبتنی بر token این را به دنباله‌ای استاندارد تبدیل می‌کند که رمزگذارهای

transformer می‌توانند پردازش کنند. هر token هویت علامت، شدت (مقدار نرمال‌شده)، افسست زمانی و

سنجه (lab در برابر vital) را رمزگذاری می‌کند. این بازنمایی فشرده هم یادگیری اپیزودیک چندنمونه‌ای

و هم مبانی جدولی کلاسیک را هنگام تخت‌کردن به بردار ویژگی پشتیبانی می‌کند.

۵.۱ شکاف پژوهشی

علیرغم پیشرفت چشمگیر در پیش‌بینی بالینی و یادگیری ماشین، شکاف آشکاری در تقاطع یادگیری چندنمونه‌ای، آموزش فدرال و داده‌بالینی جدولی وجود دارد. شکاف‌های مشخص زیر را که این پایان‌نامه را انگیزه می‌دهند، شناسایی می‌کنیم:

۱.۵.۱ شکاف ۱: یادگیری چندنمونه‌ای بر داده‌بالینی جدولی

اکثریت قاطع پژوهش یادگیری چندنمونه‌ای بینایی ماشین (Omniglot, CUB-200, miniImageNet) یا وظایف پردازش زبان طبیعی را هدف قرار می‌دهد. داده‌جدولی (سنجه‌غالب در پیش‌بینی بالینی مبتنی بر EHR) در بستر چندنمونه‌ای به شدت کم‌بررسی مانده است. برخلاف تصاویر، ویژگی‌های جدولی ساختار فضایی که سوگیری القایی کانولوشنی بتواند از آن بهره‌برد نداشت. برخلاف متن، ویژگی‌های جدولی انواع و مقیاس‌های ناهمگونی دارند که در برابر tokenization استاندارد مقاومت می‌کنند. پرسش اینکه آیا متیادگیری مبتنی بر فاصله (شبکه‌های نمونه‌ای، prototypical networks) می‌تواند بازنمایی مؤثر از ویژگی‌های بالینی ناهمگون با نمونه‌های محدود بیاموزد، همچنان باز است. این پایان‌نامه نخستین بررسی تجربی این پرسش را بر داده‌امکان‌پذیری درمان MIMIC-IV ارائه می‌دهد.

۲.۵.۱ شکاف ۲: یادگیری فدرال چندنمونه‌ای برای مراقبت‌های بهداشتی

درحالی‌که یادگیری فدرال به مراقبت‌های بهداشتی اعمال شده (مثلاً FedHealth, FL-QSAR) برای کشف دارو و یادگیری چندنمونه‌ای به تصویربرداری پزشکی اعمال شده، ترکیب آموزش فدرال با متیادگیری چندنمونه‌ای بر داده‌بالینی ساختاریافته بررسی نشده است. این ترکیب از نظر عملی مهم است: سناریوهای استقرار واقعی اغلب هم‌کیمیایی داده (نمونه‌های برچسب‌اندک در نهاد جدید) و هم قیود حریم خصوصی (عدم خروج داده از نهاد) را شامل می‌شوند. این پایان‌نامه بررسی می‌کند که آیا این دو پارادایم را می‌توان بدون افت فاجعه‌بار عملکرد به‌طور مؤثر ترکیب کرد.

۳.۵.۱ شکاف ۳: ارزیابی صادقانه روش‌های عصبی بر مجموعه داده‌های بالینی کوچک

سوگیری انتشار در یادگیری ماشین معمولاً به سود نتایج مثبت عمل می‌کند. بسیاری از مقالات ML بالینی فقط مقایسه‌های مطلوب را گزارش می‌کنند و شرایطی را که در آن روش‌های ساده‌تر برتری دارند کنار می‌گذارند. به همین دلیل، ارزیابی دقیق و صادقانه باید هم نتایج منفی اولیه و هم مسیر بهبود را نشان دهد [Makel et al., 2012]. این پایان‌نامه با تعیین سقف جدولی قوی (SOTA با AUROC ۰.۷۴۸ در اجرای منجمد)، گزارش شکاف Exp1 (Proposed_FewShot) ۰.۶۱۱ در برابر RF ۰.۷۶۲ روی همان تقسیم، تحلیل دلیل عقب‌ماندن چندنمونه‌ای، و مستندسازی بهترین اجرای انباشته (۰.۷۴۶ در برابر ۰.۷۴۸) این شکاف گزارش‌دهی را تا حد زیادی پوشش می‌دهد. کمپین توسعه V1-V6 نیز در فصل ۵ به‌عنوان سابقه تاریخی تکامل روش آمده است.

۴.۵.۱ شکاف ۴: بازنمایی‌های بالینی مبتنی بر token

کار موجود بر transformerهای بالینی (ClinicalBERT, Med-BERT, BEHRT) بر یادداشت‌های بالینی (متن آزاد) یا کدهای تشخیصی عمل می‌کند. اعمال معماری‌های transformer به اندازه‌گیری‌های بالینی کمی (آزمایشگاه، علائم حیاتی) به پل بازنمایی نیاز دارد؛ تبدیل اندازه‌گیری‌های پیوسته و ناهمگون به دنباله token. طرح symptom token ما این شکاف را پوشش می‌دهد و نداشت اصولی از اندازه‌گیری‌های بالینی به ورودی‌های سازگار با transformer فراهم می‌کند. اگرچه از نظر مفهومی به TabTransformer و FT-Transformer مرتبط است، رویکرد ما عناصر ویژه حوزه (هویت علامت، نرمال‌سازی بازه بالینی، رمزگذاری سنجه) را متناسب با بستر پیش‌بینی ICU دربرمی‌گیرد.

۶.۱ اصطلاحات و تعاریف

در سراسر متن از اصطلاحات زیر استفاده می‌کنیم: **امکان‌پذیری درمان** پیامد دودویی دستیابی بیمار به ترخیص ایمن به منزل، توان بخشی یا مراقبت خانگی ظرف ۳۰ روز بدون بستری مجدد را نشان می‌دهد. **Symptom Tokens** بازنمایی‌های فشرده اندازه‌گیری آزمایشگاهی و علائم حیاتی هستند که هر کدام شناسه علامت، شدت، زمان و سنجه را رمزگذاری می‌کنند. **یادگیری چندنمونه‌ای** به متیادگیری از K نمونه پشتیبان برای هر دسته اشاره دارد. **یادگیری فدرال** مدل‌ها را بر داده توزیع شده

بدون متمرکزسازی نمونه‌های خام آموزش می‌دهد. **ETHOS** رمزگذار Efficient Transformer for Health Outcome prediction است [Sharafi and Aminian, 2023].

۷.۱ مرور کلی روش پژوهش

پژوهش ما از رویکرد علم طراحی پیروی می‌کند: یک چارچوب ترکیبی شامل Symptom Tokens، ETHOS، یادگیری چندنمونه‌ای و آموزش فدرال طراحی، پیاده‌سازی و به‌صورت تجربی ارزیابی می‌شود. برای تکرارپذیری، از کوهورت ۲,۰۰۰ بیمار MIMIC-IV با تقسیم‌های ثابت استفاده می‌کنیم. ارزیابی شامل پنج بخش است: (۱) مقایسه با مدل‌های کلاسیک مانند RF و XGBoost؛ (۲) حذف تدریجی اجزا؛ (۳) تحلیل حساسیت برای K-shot و ابرپارامترها؛ (۴) مقایسه فدرال و متمرکز؛ و (۵) تعمیم بین بیماری‌ها. هم نتایج مثبت و هم نتایج منفی گزارش می‌شوند تا تصویر علمی کامل‌تری ارائه شود.

۸.۱ اهداف پژوهش و مفروضات

هدف اصلی این پایان‌نامه طراحی و توسعه چارچوبی هوشمند برای پیش‌بینی امکان‌پذیری درمان از داده بالینی تجمیع‌شده و محدود است. چارچوب باید الگوهای درمانی مؤثر را بدون دسترسی مستقیم به داده خام بیمار شناسایی کند. اهداف مشخص عبارت‌اند از: (۱) ارائه مدلی نوآورانه مبتنی بر یادگیری چندنمونه‌ای برای پیش‌بینی امکان‌پذیری درمان؛ (۲) استفاده از Symptom Tokens به‌عنوان واحدهای استاندارد داده برای یادگیری مؤثر؛ (۳) ترکیب معماری ETHOS با اصول یادگیری چندنمونه‌ای و فدرال برای دقت بهتر در محیط‌های چندمنبعه؛ و (۴) فراهم کردن بستری برای تحلیل سلامت فردی بدون نقض حریم خصوصی کاربر.

بر اساس ادبیات و چارچوب نظری، مفروضات زیر را می‌پذیریم: (۱) مدل‌های چندنمونه‌ای حتی با داده محدود می‌توانند امکان‌پذیری درمان را با دقت معقول پیش‌بینی کنند؛ (۲) یادگیری فدرال امنیت داده را افزایش می‌دهد و نیاز به داده متمرکز را کاهش می‌دهد؛ (۳) ترکیب Symptom Tokens با معماری ETHOS عملکرد و تعمیم مدل را بهبود می‌دهد؛ (۴) مدل پیشنهادی می‌تواند الگوهای پنهان درمان را در بیماران مختلف شناسایی کند؛ و (۵) داده چندسنگه‌ای در مقایسه با داده تک‌سنگه‌ای دقت پیش‌بینی را بهبود می‌دهد.

۱.۸.۱. تطبیق با پروپوزال اولیه

پروپوزال اولیه چارچوبی با چهار رکن اصلی پیشنهاد می‌کرد: یادگیری few-shot، یادگیری فدرال، رمزگذار ETHOS و بازنمایی Symptom Tokens برای پیش‌بینی قابلیت درمان از داده‌های بالینی جمع‌شده و محدود. پایان‌نامه حاضر همان مسیر اصلی را حفظ می‌کند، اما برای اینکه ارزیابی علمی قابل بازتولید و قابل دفاع باشد، دامنه اجرا را به کوهورت ناشناس‌شده و عمومی MIMIC-IV محدود می‌کند. بنابراین «داده چندمنبع» در این نسخه به صورت آزمایشگاه‌ها، علائم حیاتی، جمعیت‌شناسی و ویژگی‌های مهندسی‌شده از ICU عملیاتی شده است؛ داده ابزارهای پوشیدنی، واسط کاربری تولیدی و استقرار چندسایتی واقعی در این پایان‌نامه پیاده‌سازی نشده‌اند و به عنوان مسیرهای آینده و الزامات استقرار واقعی مطرح می‌شوند.

جدول ۱.۱: تطبیق اجزای پروپوزال با اجرای نهایی پایان‌نامه

جزء در پروپوزال	اجرای نهایی در پایان‌نامه	توضیح دامنه
یادگیری few-shot	شبکه‌های نمونه‌اولیه، تحلیل K -شات، Proto-MAML و مسیرهای V1-V6	پوشش کامل؛ نتایج مثبت و محدودیت‌ها هر دو گزارش شده‌اند
یادگیری فدرال	شبیه‌سازی FedAvg روی گره‌های بیماری	داده خام جابه‌جا نمی‌شود؛ استقرار چندسایتی واقعی به کار آینده موکول شده است
ETHOS و Symptom Tokens	توکن‌سازی 15 آزمایشگاه، 7 علامت حیاتی و ویژگی‌های مهندسی‌شده، سپس رمزگذاری با ETHOS	بازنمایی پیشنهادی پروپوزال به صورت قابل بازتولید روی MIMIC-IV پیاده‌سازی شده است
داده چندمنبع / چندسنگه‌ای	آزمایشگاه، علائم حیاتی، جمعیت‌شناسی، گره بیماری و ویژگی‌های بالینی مشتق‌شده	ابزار پوشیدنی و داده زنده در دسترس پژوهش نبود؛ بنابراین ادعای چندمنبع به منابع درون EHR محدود شده است
مقایسه با روش‌های سنتی	LR, RF, XGBoost, LightGBM, CatBoost و مدل‌های عصبی	پوشش کامل‌تر از پروپوزال؛ سقف جدولی برای تفسیر منصفانه گزارش شده است
واسط کاربری و نمایش نتایج	ارائه جداول، نمودارها، SHAP و گزارش‌های قابل بازتولید	واسط کاربری تولیدی ساخته نشده است؛ تمرکز پایان‌نامه بر اعتبار علمی مدل و نتایج تجربی است
ابزارهای پیشنهادی مانند Flutter/PySyft	پیاده‌سازی پژوهشی با Python, scikit-learn, PyTorch و شبیه‌سازی سفارشی FedAvg	انتخاب ابزارها بر اساس بازتولیدپذیری آزمایش‌ها و دسترسی واقعی داده انجام شده است

۹.۱ پرسش‌های پژوهش

این پایان‌نامه به پرسش‌های پژوهشی زیر می‌پردازد:

۱. **RQ1:** آیا متیادگیری چندمنونه‌ای می‌تواند در پیش‌بینی امکان‌پذیری درمان از MIMIC-IV

با مبانی جدولی کلاسیک برابری کند یا از آن پیشی بگیرد؟

۲. **RQ2:** تعداد شات‌های پشتیبان K چگونه بر عملکرد چندنمونه‌ای اثر می‌گذارد؟ آیا K بهینه‌ای وجود دارد؟

۳. **RQ3:** هزینه عملکردی یادگیری فدرال در مقایسه با آموزش متمرکز چیست؟ آیا این هزینه ناچیز است؟

۴. **RQ4:** کدام اجزای معماری (symptom tokens، وزن‌دهی شدت، افت زمانی و غیره) بیشترین سهم را در مدل پیشنهادی دارند؟

۵. **RQ5:** آیا مدل بین گروه‌های بیماری تعمیم می‌یابد؟ بر گره‌های دیده‌نشده (مثلاً کلیوی، دیابت) هنگام آموزش بر سایرین (سپسیس، قلبی، تنفسی) چگونه عمل می‌کند؟

به این پرسش‌ها به صورت تجربی با نمونه ۲,۰۰۰ بیمار از MIMIC-IV v3.1، با تقسیم‌های ثابت آموزش/اعتبارسنجی/آزمون و پروتکل‌های ارزیابی دقیق پاسخ می‌دهیم.

۱۰.۱ نوآوری‌ها و مشارکت‌ها

این پایان‌نامه مشارکت‌های زیر را دارد:

۱. نخستین مدل چندنمونه‌ای جدولی امکان‌پذیری درمان در دنیای واقعی بر MIMIC-IV symptom tokenization را با متیادگیری نمونه‌ای و آموزش فدرال ترکیب می‌کنیم. به دانش ما، هیچ کار پیشین یادگیری چندنمونه‌ای را برای پیش‌بینی امکان‌پذیری درمان بر MIMIC-IV با این معماری اعمال نکرده است. این مشارکت شکاف بین جامعه یادگیری چندنمونه‌ای (عمدتاً متمرکز بر بینایی و NLP) و جامعه انفورماتیک بالینی (عمدتاً متمرکز بر یادگیری نظارت‌شده متمرکز) را پر می‌کند. معماری به گونه‌ای ماژولار طراحی شده که رمزگذار، سر چندنمونه‌ای و پروتکل فدرال هر کدام به طور مستقل قابل جایگزینی‌اند و حذف اجزا و گسترش آینده را تسهیل می‌کنند.

۲. **Symptom Tokens به عنوان بازنمایی بالینی.** بازنمایی فشرده مبتنی بر token معرفی می‌کنیم: ۱۵ مورد آزمایشگاهی و ۷ علامت حیاتی، نرمال شده به $[0, 1]$ ، تقویت شده با shock index، پراکسی SOFA و شمار آزمایشگاه‌های غیرطبیعی. هر token آرایه $[\text{symptom_id}]$

[intensity, time_delta, modality] را رمزگذاری می‌کند. این بازنمایی هم رمزگذارهای سبک transformer و هم مدل‌های جدولی کلاسیک را پشتیبانی می‌کند. برخلاف رویکردهای پیشین tokenization بالینی که بر یادداشت‌های متن آزاد یا کدهای تشخیصی عمل می‌کنند، طرح ما اندازه‌گیری‌های کمی را به واژگان گسسته token با مقادیر شدت پیوسته تبدیل می‌کند و هم هویت دسته‌ای و هم بزرگی عددی هر مشاهده بالینی را حفظ می‌کند.

۳. **سقف تجربی و بستن تدریجی شکاف.** سقف جدولی قوی، یعنی AUROC ۰.۷۴۸ در اجرای منجمد SOTA و ۰.۷۶۰ برای RF با آستانه تنظیم‌شده در جدول کمپین V، همراه با نقطه آغاز تاریخی چندنمونه‌ای (۰.۶۱۹) گزارش می‌شود. اجرای منجمد انباشته چندنمونه‌ای+کلاسیک در مخزن به ۰.۷۴۶ [0.699, 0.797] می‌رسد؛ یعنی فقط حدود ۰.۰۰۲ پایین‌تر از برآورد نقطه‌ای SOTA. بهترین بذر V5 (۰.۷۳۷) و انباشت V4 (۰.۷۳۲) نیز به‌عنوان نقاط عطف توسعه مستند شده‌اند.

۴. **معماری آماده فدرال با هزینه شبیه‌سازی شده کوچک.** در آزمایش گزارش شده فدرال در برابر متمرکز، شکاف AUROC حدود ۰.۰۰۵ است؛ آموزش حافظ حریم خصوصی در این شبیه‌سازی با هزینه کوچک عملی است. استقرار چندسایتی واقعی همچنان نیازمند اعتبارسنجی عملیاتی است.

۵. **حذف سیستماتیک اجزا و تحلیل حساسیت جامع.** به‌صورت سیستماتیک اجزا (symptom tokens، وزن دهی شدت، افت زمانی، سر چندنمونه‌ای) را حذف می‌کنیم و $K \in \{1, 3, 5, 7, 10, 15, 20\}$ را تغییر می‌دهیم. جداول و تفاسیر مفصل برای کار آینده ارائه می‌دهیم. حذف اجزا نشان می‌دهد وزن دهی شدت بحرانی‌ترین جز است ($\Delta \text{AUROC} = -0.075$ هنگام حذف)، درحالی‌که سر چندنمونه‌ای را می‌توان با سر نظارت‌شده با افت کمینه جایگزین کرد ($\Delta \text{AUROC} = -0.009$). این الگو نشان می‌دهد پروتکل آموزش اپیزودیک محرک اصلی عملکرد نیست.

۶. **متیادگیر انباشته و آموزش پیشرفته.** انباشتگر کمپین V4 به AUROC ۰.۷۳۲ می‌رسد و پیکربندی منجمد exp_fewshot_best مقدار ۰.۷۴۶ را ثبت می‌کند. ترکیب سازگاری به‌سبک Proto-MAML، تقطیر دانش، پیش‌آموزش تضادی نظارت‌شده و مهندسی ویژگی (132→22 ویژگی) نشان می‌دهد روش‌های چندنمونه‌ای، در صورت طراحی سیستماتیک، می‌توانند به SOTA جدولی این کوهورت نزدیک شوند.

۷. نوآوری‌های معماری برای یادگیری چندنمونه‌ای جدولی. V5 توجه ویژه دروازه‌دار (Gated Feature Attention) (انتخاب ویژگی تطبیقی به‌ازای نمونه الهام‌گرفته از TabNet) و شبکه‌های نمونه‌ای توجه متقاطع (Cross-Attention Prototypical Networks) (شباهت وابسته به زمینه) را معرفی می‌کند. V6 مجموعه‌های عمیق ناهمگون ترکیب‌کننده FT-Transformer، GFA-Transformer و MLP-Mixer را با پیش‌بینی مطابق (confor-mal prediction) برای سنجش عدم قطعیت ارزیابی می‌کند. این آزمایش‌ها نشان می‌دهد مکانیسم‌های توجه برای یادگیری چندنمونه‌ای جدولی ضروری‌اند و انباشت کالبره‌شده ساده بر متیادگیرهای پیچیده در مقیاس داده کوچک برتری دارد.

۱۱.۱ ساختار پایان نامه

ادامه این پایان نامه به صورت زیر سازمان‌دهی شده است.

فصل ۲ کارهای مرتبط را مرور می‌کند: یادگیری چندنمونه‌ای، یادگیری فدرال، بازنمایی داده بالینی و مجموعه داده MIMIC-IV. درباره شبکه‌های نمونه‌ای، شبکه‌های تطبیق، MAML، FedAvg و کاربردهای پیشین در مراقبت‌های بهداشتی بحث می‌کنیم.

فصل ۳ روش‌شناسی را به تفصیل شرح می‌دهد: استخراج مجموعه داده، symptom tokenization، معماری رمزگذار ETHOS، پروتکل چندنمونه‌ای، آموزش فدرال و معیارهای ارزیابی. صورت‌بندی‌های ریاضی برای همه اجزا ارائه می‌شود.

فصل ۴ بستر آزمایشی را ارائه می‌کند: تقسیم داده، ابرپارامترها، مدل‌های مبنایی (رگرسیون لجستیک، جنگل تصادفی، XGBoost، LightGBM، CatBoost) و پیکربندی FewShot+ETHOS. آزمایش‌های ۱-۵ (مقایسه اصلی، حساسیت K-shot، فدرال در برابر متمرکز، حذف اجزا، تعمیم بین بیماری‌ها) را شرح می‌دهیم.

فصل ۵ نتایج را گزارش می‌کند: SOTA جدولی منجمد (۰.۷۴۸)، چندنمونه‌ای انباشته منجمد (۰.۷۴۶)، Exp1 و آزمایش‌های ۲-۵، جدول توسعه V1-V6 (نقاط عطف تاریخی: ۰.۷۳۲، ۰.۷۳۷، ۰.۷۶۰)، راهنمای آماری، قابل تفسیر بودن و تجسم‌های اضافی.

فصل ۶ تحلیل جامع داده را ارائه می‌کند: طرحواره MIMIC-IV، جمعیت‌شناسی کوهورت، توزیع گره بیماری، همبستگی‌های آزمایشگاهی، پراکسی SOFA، عملکرد طبقه‌بندی شده بر اساس سن، تحلیل خطا، جاسازی t-SNE، تجسم نمونه‌ها و خط زمانی بیماران.

فصل ۷ نتایج را تفسیر می کند، محدودیت های متیادگیری چندنمونه ای را بررسی می کند و پیامدهای عملی و مسیرهای آینده پژوهش را مرور می کند.

فصل ۸ یافته ها و مشارکت های اصلی را خلاصه می کند.

پیوست ها جداول ابرپارامتر، پرسش های MIMIC-IV SQL، قطعه کدها، جداول کامل نتایج و استنتاج های ریاضی را فراهم می کنند.

۱۲.۱ بستر مقرراتی و اخلاقی

داده بهداشتی تابع مقررات سخت گیرانه است. در ایالات متحده، قانون قابلیت انتقال و پاسخگویی بیمه سلامت (HIPAA) استفاده و افشای اطلاعات سلامت محافظت شده (PHI) را نظارت می کند. در اتحادیه اروپا، مقررات عمومی حفاظت از داده (GDPR) قیود مشابهی اعمال می کند. این مقررات توانایی متمرکزسازی داده بین نهادها را محدود می کند و یادگیری فدرال و رویکردهای حافظ حریم خصوصی را انگیزه می بخشد. کار ما از داده ناشناس شده MIMIC-IV استفاده می کند که تحت رویه های سخت گیرانه ناشناس سازی قرار گرفته است. برای استقرار، هر مدلی باید با مقررات محلی و تأیید کمیته اخلاق پژوهش (IRB) سازگار باشد.

۱۳.۱ تحلیل ذی نفعان

چند ذی نفع از پیش بینی امکان پذیری درمان بهره می برند:

- **بالین گران:** پشتیبان تصمیم برای برنامه ریزی ترخیص؛ شناسایی زودهنگام بیمارانی که ممکن است بستری طولانی یا انتقال نیاز داشته باشند.
- **مدیران بیمارستان:** تخصیص منابع، مدیریت تخت و برنامه ریزی ظرفیت.
- **بیماران و خانواده ها:** شفافیت درباره مسیر ترخیص مورد انتظار؛ کاهش عدم قطعیت.
- **پرداخت کنندگان:** مهار هزینه از طریق زمان بندی مناسب ترخیص؛ کاهش بستری مجدد.
- **پژوهشگران:** روش شناسی برای پیش بینی بالینی چندنمونه ای و فدرال؛ معیارهایی برای کار آینده.

رویکرد ما قابل تفسیر بودن (SHAP، اهمیت ویژگی) و حریم خصوصی (یادگیری فدرال) را اولویت

می‌دهد تا نگرانی‌های بالین‌گر و مقرراتی را پوشش دهد.

۱۴.۱ خلاصه فصل

این فصل پایان‌نامه را معرفی کرد: بستر بالینی تصمیم‌گیری در ICU و برنامه‌ریزی ترخیص، انگیزه ناشی از محدودیت‌های دسترسی به داده در دنیای واقعی (تجربه Mayo Clinic)، بیان رسمی مسئله، پرسش‌های پژوهش و مشارکت‌ها. امکان‌پذیری درمان را به‌عنوان وظیفه طبقه‌بندی دودویی بر داده ۲۴ ساعت نخست ICU تعریف کردیم، چالش‌های کلیدی (چندنمونه‌ای، فدرال، بازنمایی) را شناسایی کردیم و ساختار پایان‌نامه را ترسیم کردیم. فصل بعد مبانی نظری را مرور می‌کند.

۱۵.۱ دامنه و محدودیت‌ها

این پایان‌نامه بر نمونه ۲,۰۰۰ بیمار از MIMIC-IV v3.1 متمرکز است. نتایج ممکن است به کوهورت‌های بزرگ‌تر یا نهادهای دیگر تعمیم نیابد. از برجسب دودویی امکان‌پذیری مشتق شده از محل ترخیص و بستری مجدد استفاده می‌کنیم؛ تعاریف جایگزین (مثلاً وضعیت عملکردی، زمان تا ترخیص) می‌تواند به نتیجه‌گیری‌های متفاوت منجر شود. استنتاج علی یا قابل تفسیر بودن را عمیق بررسی نمی‌کنیم. بستر فدرال بخش‌بندی مبتنی بر بیماری را شبیه‌سازی می‌کند؛ یادگیری فدرال دنیای واقعی ممکن است با چالش‌های اضافی (هزینه ارتباط، خرابی گره، کلاینت‌های بیزانسی) روبه‌رو شود.

۱۶.۱ اهمیت در بستر پزشکی دقیق

این کار به دستور کار گسترده‌تر پزشکی دقیق (تنظیم درمان پزشکی بر ویژگی‌های فردی هر بیمار) می‌افزاید. اگرچه پزشکی دقیق سنتی بر پروفایل‌سازی ژنومی و درمان‌های هدفمند تمرکز دارد، مفهوم به‌طور طبیعی به آینده‌نگری دقیق گسترش می‌یابد: پیش‌بینی مسیر فردی بیمار بر اساس پروفایل بالینی ویژه به‌جای میانگین‌های جمعیتی.

۱.۱۶.۱ از میانگین‌های جمعیتی تا پیش‌بینی فردی

برنامه‌ریزی ترخیص سنتی بر قواعد تجربی بالینی و هنجارهای نهادی تکیه دارد: «بیشتر بیماران سپسیس با بهبود لاکتات تا روز پنجم ترخیص می‌شوند.» چنین قواعدی میانگین‌های جمعیتی‌اند که تغییرپذیری

فردی را نادیده می‌گیرند. مسیر ترخیص بیمار ۴۵ ساله مبتلا به سپسیس با عملکرد کلیوی طبیعی و حمایت اجتماعی قوی بسیار متفاوت از بیمار ۷۸ ساله با سپسیس، بیماری مزمن کلیوی و مراقبت خانگی محدود است. مدل ما تلاش می‌کند این تفاوت‌های فردی را با یادگیری از ترکیب مشخص مقادیر آزمایشگاهی، علائم حیاتی و ویژگی‌های بالینی مشاهده‌شده در ۲۴ ساعت نخست بستری ICU هر بیمار بازتاب دهد.

۲.۱۶.۱ سازگاری چندنمونه‌ای به‌عنوان شخصی‌سازی

چارچوب چندنمونه‌ای چارچوب طبیعی برای شخصی‌سازی ارائه می‌دهد: با تعداد اندکی بیمار مرجع (مجموعه پشتیبان) که بالینی شبیه بیمار پرسشی‌اند، مدل پیش‌بینی‌های خود را سازگار می‌کند. این امر مشابه استدلال بالینی است؛ پزشکی که بیمار جدید را ارزیابی می‌کند موارد مشابه را به یاد می‌آورد و از آن تجربیات برای آینده‌نگری بهره می‌گیرد. شبکه‌های نمونه‌ای این را با محاسبه نمونه‌های دسته (مرکزهای بیماران مشابه) و طبقه‌بندی بیماران پرسشی بر اساس نزدیکی رسمی می‌کنند. اگرچه نتایج ما نشان می‌دهد این رسمی‌سازی هنوز به توان پیش‌بینی مدل‌های کلاسیک نمی‌رسد، هم‌ترازی مفهومی با استدلال بالینی نشان می‌دهد که با بازنمایی‌های بهتر و مجموعه‌های مرجع بزرگ‌تر، شخصی‌سازی چندنمونه‌ای می‌تواند ابزار بالینی قدرتمندی شود.

۳.۱۶.۱ تعمیم بین‌نهادی

پزشکی دقیق به مدل‌هایی نیاز دارد که بین نهادها تعمیم یابند؛ هر نهاد جمعیت‌شناسی بیمار، شیوه‌های بالینی و استانداردهای مستندسازی خود را دارد. یادگیری فدرال آموزش بین‌نهادی بدون اشتراک داده را ممکن می‌سازد، اما چالش فراتر از حریم خصوصی است: مدل‌ها باید بازنمایی‌هایی بیاموزند که نسبت به ویژگی‌های نهادی ثابت بمانند و در عین حال به تغییرات بالینی معنادار حساس بمانند. بخش‌بندی گره-بیماری ناهمگونی نهادی را با ایجاد توزیع‌های داده غیر IID شبیه‌سازی می‌کند. آزمایش‌های تعمیم بین بیماری (فصل ۵) بررسی می‌کنند که آیا مدل می‌تواند به جمعیت‌های بیمار دیده‌نشده سازگار شود؛ نیاز کلیدی برای استقرار در بسترهای متنوع مراقبت‌های بهداشتی.

فصل ۲

پیشینه و کارهای مرتبط

این فصل مبانی نظری و کارهای پیشین زیربنای رویکرد ما را مرور می‌کند. به یادگیری few-shot، یادگیری فدرال، بازنمایی داده بالینی، و مجموعه داده MIMIC-IV می‌پردازیم. سازمان فصل چنین است: نخست یادگیری few-shot (تاریخچه، فرمول بندی مسئله، شبکه های نمونه ای و تطبیقی، MAML، آموزش اپیزودیک)، سپس یادگیری فدرال (انگیزه، FedAvg، حریم خصوصی، داده غیر IID)، بازنمایی داده بالینی (داده خام، نرمال سازی، توکن ها)، MIMIC-IV (مرور کلی، طرحواره، کوهورت، برچسب ها، گره های بیماری)، کارهای مرتبط در پیش بینی بالینی، ترنسفورمرها در داده بالینی، یادگیری نامتوازن، تفسیرپذیری، و مرور جامع ادبیات. هر بخش پیش زمینه لازم برای فهم روش و نتایج ما را فراهم می‌کند.

۱.۲ یادگیری چندنمونه ای (few-shot)

۱.۱.۲ تاریخچه و تحول

حوزه یادگیری few-shot از پژوهش های فرا یادگیری در دهه ۲۰۱۰ برخاسته است. کارهای اولیه درباره «یادگیری برای یادگیری» بررسی می‌کردند که چگونه الگوریتم ها می‌توانند با تجربه در وظایف گوناگون بهبود یابند. انقلاب ImageNet نشان داد شبکه های عمیق می‌توانند بازنمایی های نیرومند از مجموعه های بزرگ بیاموزند؛ یادگیری few-shot پرسید آیا بازنمایی های مشابه را می‌توان با تعداد اندک نمونه و بهره گیری از ساختار بین وظایف آموخت.

۲.۱.۲ فرمول‌بندی مسئله

یادگیری few-shot به چالش تعمیم از تعداد اندک نمونه برچسب خورده به ازای هر کلاس می‌پردازد [Snell et al., 2017]. در تنظیم استاندارد N -راه K -شات، N کلاس و K نمونه پشتیبان به ازای هر کلاس داریم. هدف طبقه‌بندی نمونه‌های پرس‌وجو تنها با مجموعه پشتیبان است، بدون آموزش اضافی.

به صورت رسمی، $\mathcal{S} = \{(x_i, y_i)\}_{i=1}^{N \cdot K}$ را مجموعه پشتیبان و $\mathcal{Q} = \{(x_j, y_j)\}_{j=1}^M$ را مجموعه پرس‌وجو می‌نامیم. طبقه‌بند $\hat{y} = f(x; \mathcal{S})$ می‌خواهیم که با توجه به $\mathcal{S}$ برچسب x را پیش‌بینی کند. کلید، یادگیری بازنمایی و معیار فاصله است که بین وظایف تعمیم یابد.

۳.۱.۲ شبکه‌های نمونه‌ای

شبکه‌های نمونه‌ای [Snell et al., 2017] برای هر کلاس یک نمونه‌ای (prototype) به صورت میانگین جاسازی‌های پشتیبان محاسبه می‌کنند:

$$\mathbf{c}_k = \frac{1}{|\mathcal{S}_k|} \sum_{(x_i, y_i) \in \mathcal{S}_k} f_\theta(x_i) \quad (1.2)$$

که در آن $\mathcal{S}_k = \{(x_i, y_i) : y_i = k\}$ و f_θ شبکه جاسازی است. پرس‌وجوی x با نزدیک‌ترین نمونه‌ای در فضای جاسازی طبقه‌بندی می‌شود:

$$p(y = k | x) = \frac{\exp(-d(f_\theta(x), \mathbf{c}_k)/\tau)}{\sum_{k'} \exp(-d(f_\theta(x), \mathbf{c}_{k'})/\tau)} \quad (2.2)$$

که در آن d فاصله اقلیدسی و τ پارامتر دما است. در پیاده‌سازی ما از شباهت کسینوسی استفاده می‌شود.

۴.۱.۲ شبکه‌های تطبیقی

شبکه‌های تطبیقی [Vinyals et al., 2016] با توجه روی مجموعه پشتیبان برچسب پرس‌وجو را محاسبه می‌کنند:

$$p(y | x, \mathcal{S}) = \sum_i a(x, x_i) \mathbb{1}[y_i = y] \quad (3.2)$$

که در آن $a(x, x_i)$ وزن توجه است. این اجازه می‌دهد نمونه‌های پشتیبان مختلف بر اساس شباهت به پرس‌وجو سهم متفاوتی داشته باشند.

۵.۱.۲ شبکه‌های رابطه‌ای

شبکه‌های رابطه‌ای [Sung et al., 2018] معیار فاصله ثابت (اقلیدسی، کسینوسی) را با یک ماژول رابطه آموخته‌شده جایگزین می‌کنند. برای جاسازی پرس‌وجوی $f_\theta(x)$ و نمونه‌ای کلاس $\mathbf{c}_k$ ، امتیاز رابطه چنین است:

$$r_k = g_\phi(f_\theta(x), \mathbf{c}_k) \quad (۴.۲)$$

که در آن $g_\phi: \mathbb{R}^{2d} \rightarrow [0, 1]$ یک شبکه عصبی (معمولاً MLP کوچک با خروجی سیگموئید) است که تابع شباهت وابسته به وظیفه را می‌آموزد. مدل به صورت انتها-به-انتها با تابع زیان میانگین مربعات خطا آموزش داده می‌شود:

$$\mathcal{L} = \sum_{(x,y) \in \mathcal{Q}} \sum_k (r_k - \mathbb{I}[y = k])^2 \quad (۵.۲)$$

مزیت شبکه‌های رابطه‌ای بر شبکه‌های نمونه‌ای انعطاف است: ماژول رابطه می‌تواند توابع شباهت غیرخطی یاد بگیرد که مرزهای تصمیم پیچیده را دربرگیرد. عیب، هزینه محاسباتی بیشتر و خطر بیش‌برازش با داده فرا-آموزش محدود است. برای امکان‌پذیری درمان، جایی که مرز تصمیم ممکن است به تعاملات غیرخطی ویژگی (مثلاً تعامل کراتینین و سن) وابسته باشد، شبکه‌های رابطه‌ای جایگزین نظری جذابی برای طبقه‌بندی مبتنی بر نمونه‌ای فراهم می‌کنند.

شبکه‌های رابطه‌ای را به عنوان نقطه مقایسه در مطالعه حذف تدریجی پیاده‌سازی می‌کنیم. ماژول رابطه از دو لایه تمام‌اتصال با فعال‌سازی ReLU تشکیل شده است:

$$g_\phi(\mathbf{u}, \mathbf{v}) = \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot [\mathbf{u}; \mathbf{v}; \mathbf{u} \odot \mathbf{v}; |\mathbf{u} - \mathbf{v}|] + b_1) + b_2) \quad (۶.۲)$$

که در آن $[\cdot; \cdot]$ الحاق، $\odot$ ضرب درایه‌به‌درایه، و σ تابع سیگموئید است. ورودی شامل چهار ویژگی تعاملی است: دو جاسازی، حاصل ضرب درایه‌به‌درایه‌شان (گرفتن تعاملات ضربی)، و قدر مطلق تفاضل‌شان

(گرفتن فاصله).

۶.۱.۲ شبکه‌های سیامی

شبکه‌های سیامی [Koch et al., 2015] با پردازش جفت ورودی از شاخه‌های یکسان (اشتراک وزن) تابع شباهت می‌آموزند:

$$s(x_1, x_2) = \sigma(\|f_\theta(x_1) - f_\theta(x_2)\|_1) \quad (۷.۲)$$

که در آن σ تابع سیگموئید است. شبکه با زیان متضاد روی جفت‌های هم‌کلاس (مثبت) و غیرهم‌کلاس (منفی) آموزش داده می‌شود. اگرچه برای یادگیری few-shot بنیادین است، شبکه‌های سیامی به مقایسه‌های جفتی ($O(NK)$ به‌ازای هر پرس‌وجو) نیاز دارند و از شبکه‌های نمونه‌ای ($O(N)$) پس از محاسبه نمونه‌ای) کم‌کارآمدترند. شبکه‌های سیامی را پیاده‌سازی نمی‌کنیم اما اهمیت تاریخی آن‌ها را یادآور می‌شویم.

۷.۱.۲ فرا یادگیری مستقل از مدل (MAML)

MAML [Finn et al., 2017] مقداردهی اولیه θ را چنان می‌آموزد که چند گام گرادیان روی وظیفه جدید عملکرد خوب بدهد. هدف فرا-یادگیری چنین است:

$$\min_{\theta} \sum_{\mathcal{T}_i} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i}) \quad (۸.۲)$$

که در آن $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ به‌روزرسانی وابسته به وظیفه است. MAML انعطاف‌پذیرتر است اما پرهزینه؛ برای کارایی از شبکه‌های نمونه‌ای استفاده می‌کنیم.

MAML به محاسبه گرادیان مرتبه دوم (گرادیان گرادیان‌ها) نیاز دارد که حافظه و محاسبه را نسبت به روش‌های مرتبه اول حدود ۲ تا ۳ برابر افزایش می‌دهد. تقریب‌های مرتبه اول (FOMAML, Reptile [Nichol et al., 2018]) با حذف جمله مرتبه دوم این هزینه را از بین می‌برند:

$$\theta \leftarrow \theta - \beta \frac{1}{|\mathcal{T}|} \sum_{\mathcal{T}_i} (\theta - \theta'_i) \quad (۹.۲)$$

Reptile جهت از پارامترهای اولیه به پارامترهای سازگار یافته با وظیفه را میانگین می‌گیرد و جایگزینی ساده و مقیاس‌پذیر فراهم می‌کند. برای مسئله ما (طبقه‌بندی دوجمله‌ای با وظایف محدود)، سربار محاسباتی MAML ممنوع‌کننده نیست، اما تنوع محدود اپیزودهای فرا-آموزش (۵ گرۀ بیماری) شاید پیچیدگی اضافی را توجیه نکند. از این رو شبکه‌های نمونه‌ای را به‌عنوان روش اصلی few-shot به کار می‌بریم و MAML را برای کار آتی با مجموعه‌های فرا-آموزش بزرگ‌تر ذکر می‌کنیم.

۸.۱.۲ آموزش اپیزودیک

آموزش اپیزودیک در طول فرا-آموزش وظایف few-shot را شبیه‌سازی می‌کند. هر اپیزود وظیفه T_i با پشتیبان S_i و پرس‌وجوی Q_i نمونه‌برداری می‌کند. مدل طوری آموزش داده می‌شود که زیان روی Q_i با توجه به S_i کمینه شود. این با سناریوی استنتاج هم‌خوان است و تعمیم را بهبود می‌بخشد.

۹.۱.۲ تضمین‌های نظری

تحت فرض‌های معین، مانند داده حاصل از مخلوط گاوسی و کلاس‌های جدا، می‌توان نشان داد شبکه‌های نمونه‌ای با $K \rightarrow \infty$ به طبقه‌بند بهینه بیزی همگرا می‌شوند. در عمل، K متناهی است و توزیع‌های غیرگاوسی عملکرد را محدود می‌کنند. در یادگیری متریک، فضای جاسازی باید نمونه‌های مشابه را نزدیک و نمونه‌های ناهمگون را دور نگه دارد. دما T نیز تیزی توزیع softmax را کنترل می‌کند؛ مقدار بزرگ‌تر T پیش‌بینی‌های نرم‌تری ایجاد می‌کند.

۱۰.۱.۲ کاربردها در سلامت

یادگیری few-shot به طبقه‌بندی تصویر پزشکی (مثلاً رادیوگرافی، هیستوپاتولوژی)، پیش‌بینی پاسخ دارو، و پیش‌بینی پیامد بالینی به کار رفته است. بیشتر کار بر تصویربرداری تمرکز دارد، جایی که ستون فقرات‌های کانولوشنی و انتقال از ImageNet بازنمایی‌های نیرومند می‌دهند. داده بالینی جدولی؛ آزمایشگاه، علائم حیاتی، جمعیت‌شناسی؛ در تنظیم few-shot کم‌کاوش مانده است. چالش‌ها عبارت‌اند از: (۱) نبود ساختار فضایی طبیعی برای کانولوشن؛ (۲) انواع و واحدهای ناهمگون ویژگی؛ (۳) فقدان داده و نمونه‌برداری نامنظم؛ (۴) مجموعه‌های داده کوچک‌تر از بنچمارک‌های بینایی. این کار پارادایم را به امکان‌پذیری درمان از آزمایشگاه و علائم حیاتی با بازنمایی مبتنی بر توکن و رمزگذار ترنسفورمر گسترش می‌دهد.

۲.۲ یادگیری فدرال

۱.۲.۲ انگیزه

داده سلامت در بیمارستان‌ها، کلینیک‌ها و مناطق توزیع شده است. تجمیع مرکزی داده مقررات حریم خصوصی را نقض می‌کند و ریسک امنیتی دارد. یادگیری فدرال مدل‌ها را روی داده توزیع شده بدون جابه‌جایی نمونه‌های خام به سرور مرکزی آموزش می‌دهد [McMahan et al., 2017].

۲.۲.۲ میانگین‌گیری فدرال (FedAvg)

FedAvg به‌روزرسانی‌های مدل محلی را تجمیع می‌کند. فرض کنید K مشتری مجموعه‌های داده $\mathcal{D}_1, \dots, \mathcal{D}_K$ را نگه دارند. در دور t :

۱. سرور مدل سراسری θ_t را به مشتریان می‌فرستد.

۲. هر مشتری k به‌روزرسانی محلی محاسبه می‌کند: $\theta_{t+1}^{(k)} = \theta_t - \eta \nabla \mathcal{L}_k(\theta_t)$

۳. سرور تجمیع می‌کند: $\theta_{t+1} = \sum_k \frac{n_k}{n} \theta_{t+1}^{(k)}$

که در آن $n = \sum_k n_k$ و $n_k = |\mathcal{D}_k|$

۳.۲.۲ حریم خصوصی و امنیت

یادگیری فدرال نمایش داده را کاهش می‌دهد: تنها به‌روزرسانی‌های مدل (نه داده خام) منتقل می‌شوند. می‌توان حریم تفاضلی با برش گرادیان و افزودن نویز افزود. تجمیع امن می‌تواند به‌روزرسانی‌های فردی را از سرور پنهان کند. در این پایان‌نامه از FedAvg استاندارد بدون حریم تفاضلی استفاده می‌شود.

۴.۲.۲ همگرایی و ارتباطات

FedAvg تحت فرض‌های استاندارد (گرادیان‌های کران‌دار، زیان لپشیتز) همگرا می‌شود. تعداد دورهای ارتباطی لازم به ناهمگونی داده بستگی دارد: داده ناهمگون‌تر ممکن است به دورهای بیشتر یا روش‌های تطبیقی (مثلاً FedProx، SCAFFOLD) نیاز داشته باشد. از ۲۰ دور استفاده می‌کنیم؛ در آزمایش‌های ما AUROC اعتبارسنجی تا حدود دور ۲۰-۱۵ به سکون می‌رسد.

۵.۲.۲ FedProx: مدیریت ناهمگونی

FedProx [Li et al., 2020a] با افزودن جمله تنظیم‌کننده مجاورتی به هدف محلی هر مشتری، چالش داده ناهمگون (IID) بین مشتریان را برطرف می‌کند:

$$\min_{\theta} \mathcal{L}_k(\theta) + \frac{\mu}{2} \|\theta - \theta_t\|^2 \quad (10.2)$$

که در آن θ_t مدل سراسری جاری و $\mu > 0$ قدرت جمله مجاورتی را کنترل می‌کند. این از انحراف بیش‌ازحد مشتریان فردی از مدل سراسری در طول آموزش محلی جلوگیری می‌کند؛ به‌ویژه وقتی توزیع‌های داده محلی به‌طور محسوس متفاوت‌اند (مانند پارتیشن‌بندی مبتنی بر بیماری ما). جمله مجاورتی مانند تنظیم‌کننده ضمنی عمل می‌کند که سازگاری محلی و سازگاری سراسری را متعادل می‌کند.

در تنظیم ما، پنج گره بیماری (سپسیس، قلبی، تنفسی، کلیوی، دیابت) به‌طور طبیعی توزیع‌های ویژگی و نسبت کلاس متفاوتی دارند. برای مثال بیماران کلیوی ممکن است به‌طور سیستماتیک کراتینین بالاتری از بیماران قلبی داشته باشند و جابه‌جایی توزیع بین گره‌ها ایجاد شود. FedProx با محدود کردن به‌روزرسانی‌های محلی این امر را تخفیف می‌دهد. FedAvg را به‌عنوان خط پایه اصلی به کار می‌بریم و FedProx را برای کار آتی ذکر می‌کنیم، به‌ویژه اگر عملکرد با ترکیب ناهمگون تر گره‌ها افت کند.

۶.۲.۲ SCAFFOLD: کاهش واریانس

SCAFFOLD [Karimireddy et al., 2020] با متغیرهای کنترلی برای اصلاح انحراف مشتری به کار می‌رود. هر مشتری متغیر کنترلی c_k را نگه می‌دارد که تفاضل گرادیان بین اهداف محلی و سراسری را تخمین می‌زند:

$$\theta_{t+1}^{(k)} = \theta_t - \eta(\nabla \mathcal{L}_k(\theta_t) - c_k + c) \quad (11.2)$$

که در آن $c = \frac{1}{N} \sum_k c_k$ متغیر کنترلی سراسری است. SCAFFOLD نسبت به FedAvg و FedProx، به‌ویژه تحت ناهمگونی بالای داده، همگرایی سریع‌تری با کاهش واریانس به‌روزرسانی‌های گرادیان به دست می‌آورد. هزینه، ارتباط اضافی است (هر دور هم به‌روزرسانی مدل و هم به‌روزرسانی متغیر کنترلی منتقل می‌شود). برای تنظیم ۵ گره‌ای ما با ناهمگونی متوسط، SCAFFOLD ممکن

است بهبود حاشیه‌ای بدهد؛ برای آزمایش‌های چندسایتی آتی که ناهمگونی انتظار می‌رود بالاتر باشد در نظر گرفته می‌شود.

۷.۲.۲ کارایی ارتباطات

هزینه ارتباطات گلوگاه عملی در یادگیری فدرال است. چند راهکار برای کاهش پهنای باند پیشنهاد شده است:

۱. **فشرده‌سازی گرادیان:** پراکندسازی top- k تنها k مؤلفه بزرگ‌ترین گرادیان را منتقل می‌کند [Alistarh et al., 2017]. با $k = 1\%$ پارامترها، نسبت فشرده‌سازی حدود ۱۰۰ برابر با افت دقت اندک قابل دستیابی است.

۲. **کوانتیزاسیون گرادیان:** نمایش مقادیر گرادیان با بیت کمتر (مثلاً ۸ بیت یا ۱ بیت). SignSGD [Bernstein et al., 2018] تنها علامت هر مؤلفه گرادیان را می‌فرستد.

۳. **Local SGD:** افزایش دورهای آموزش محلی بین دورهای ارتباطی. از ۳ دور محلی به‌ازای هر دور استفاده می‌کنیم؛ افزایش آن ارتباطات را کم می‌کند اما ممکن است انحراف بیشتری را بیشتر کند.

۴. **به‌روزرسانی جزئی مدل:** انتقال تنها لایه‌های به‌روزشده (مثلاً تنها سر طبقه‌بندی با منجمد کردن رمزگذار). در معماری ما رمزگذار (حدود ۱.۸ میلیون پارامتر) غالب است؛ انتقال تنها ۰.۲ میلیون پارامتر سر پهنای باند را حدود ۹۰٪ کاهش می‌دهد.

در آزمایش‌ها از FedAvg استاندارد با انتقال کامل مدل استفاده می‌شود. با ۵ گره و ۲۰ دور، کل ارتباطات حدود $200 \approx 5 \times 20 \times 2$ انتقال مدل است (هر کدام حدود ۸ مگابایت برای ۲ میلیون پارامتر float32)، جمع حدود ۱.۶ گیگابایت. برای پژوهش قابل تحمل است اما برای استقرار بلندمدت روی شبکه‌های محدود ممکن است به بهینه‌سازی نیاز باشد.

۸.۲.۲ داده غیر IID

داده فدرال اغلب غیر IID است: هر گره ممکن است توزیع کلاس یا ویژگی متفاوتی داشته باشد. این می‌تواند به همگرایی آسیب بزند. MIMIC-IV را بر اساس گروه بیماری (ICD-10) پارتیشن می‌کنیم که گره‌های غیر IID طبیعی می‌دهد. درجه ناهمگونی را می‌توان با فاصله جابه‌جایی زمین (EMD) بین

توزیع‌های برجسب محلی و سراسری، یا واگرایی KL بین توزیع‌های ویژگی محلی و سراسری کمی‌سازی کرد. در پارتیشن ما نرخ امکان‌پذیری از ۳۵٪ (گره کلیوی) تا ۴۸٪ (گره تنفسی) متغیر است و ناهمگونی متوسط برجسب ایجاد می‌کند.

داده غیر IID یک تنش ایجاد می‌کند: مدل‌های محلی بیش‌برازش به توزیع‌های محلی، در حالی که مدل سراسری باید تعمیم دهد. FedAvg با میانگین‌وزنی که به‌صورت ضمنی به مرکز وزن‌داده‌شده منظم می‌کند، این را مدیریت می‌کند. رویکردهای پیچیده‌تر (SCAFFOLD, FedProx)، یادگیری فدرال شخصی‌سازی‌شده [Smith et al., 2017] وقتی ناهمگونی شدید است جایگزین می‌شوند. آزمایش‌ها نشان می‌دهد برای تنظیم ۵ گره‌ای ما FedAvg کفایت می‌کند و افت عملکرد ناچیز نسبت به آموزش متمرکز است.

۹.۲.۲ کاربردها در سلامت

یادگیری فدرال به پیش‌بینی مبتنی بر EHR، تصویربرداری پزشکی، و کارآزمایی‌های بالینی به کار رفته است. پروژه‌های برجسته FL در سلامت شامل:

- **همکاری Intel-Penn Medicine**: بخش‌بندی تومور مغزی فدرال در ۳۰ مؤسسه، نشان داد که FL به ۹۹٪ عملکرد متمرکز می‌رسد [Sheller et al., 2020].
- **NVIDIA Clara**: بستر یادگیری فدرال برای تصویربرداری پزشکی در چند شبکه بیمارستانی.
- **HealthChain**: پروژه مالی‌شده توسط اتحادیه اروپا برای تحلیل فدرال کارآزمایی بالینی در بیمارستان‌های اروپایی.
- **FedHealth**: یادگیری انتقالی فدرال برای پایش سلامت پوشیدنی [Chen et al., 2020].

این کار یادگیری فدرال را با فرا یادگیری few-shot برای امکان‌پذیری درمان ترکیب می‌کند؛ ترکیبی که در کاربردهای پیشین FL سلامت کمتر کاوش شده است.

۳.۲ بازنمایی داده بالینی

۱.۳.۲ داده بالینی خام

داده ICU معمولاً شامل موارد زیر است:

- **مقادیر آزمایشگاهی:** کراتینین، پتاسیم، سدیم، گلوکز، هموگلوبین، پلاکت، WBC، لاکتات و غیره.
 - **علائم حیاتی:** ضربان قلب، فشار خون، دما، SpO₂، نرخ تنفس.
 - **جمعیت‌شناسی:** سن، جنس، نوع پذیرش.
 - **پیامدها:** محل ترخیص، مدت بستری، مرگ‌ومیر، بستری مجدد.
- مقادیر خام ناهمگون‌اند: واحدها، دامنه‌ها، و الگوهای فقدان داده متفاوت. نرمال‌سازی و جایگزینی بحرانی است.

۲.۳.۲ راهبردهای نرمال‌سازی

رویکردهای رایج:

۱. **مقیاس min-max:** $x' = (x - x_{\min}) / (x_{\max} - x_{\min})$. پیش از مقیاس‌بندی به دامنه بالینی برش می‌دهیم.
 ۲. **Z-score:** $x' = (x - \mu) / \sigma$. به داده‌های پرت حساس است.
 ۳. **مبتنی بر رتبه:** نگاشت به صدک‌ها. مقاوم اما اطلاعات مقیاس را از دست می‌دهد.
- از مقیاس min-max با برش دامنه بالینی به $[0, 1]$ استفاده می‌شود.

۳.۳.۲ بازنمایی‌های مبتنی بر توکن

ترنسفورمرها انتظار دنباله‌ای از توکن دارند. در NLP توکن‌ها قطعات کلمه‌اند. برای داده بالینی توکن‌های علامت (Symptom Tokens) تعریف می‌کنیم: هر توکن `[symptom_id, intensity, time_delta, modality]` را رمزگذاری می‌کند. این اجازه می‌دهد مدل روی اندازه‌گیری‌های مختلف و روابطشان توجه کند.

۴.۳.۲ جدولی در برابر دنباله‌ای

مدل‌های جدولی (مثلاً Random Forest, XGBoost) بردارهای ویژگی با طول ثابت به کار می‌برند. مدل‌های دنباله‌ای (مثلاً ترنسفورمرها) دنباله‌های توکن با طول متغیر. هر دو پشتیبانی می‌شوند: ویژگی‌های جدولی برای خطوط پایه، دنباله‌های توکن برای ETHOS.

۴.۲ مجموعه داده MIMIC-IV

۱.۴.۲ مرور کلی

Beth MIMIC-IV v3.1 [Johnson et al., 2023] پایگاه داده بزرگ و آزاد ICU از مرکز پزشکی Israel Deaconess (BIDMC) است. جایگزین MIMIC-III [Johnson et al., 2016] با ساختار داده به روز و پوشش گسترده تر است. پایگاه داده داده ناشناس شده برای بیش از ۲۵۰,۰۰۰ اقامت ICU دارد، شامل اندازه گیری های آزمایشگاهی (از labevents)، علائم حیاتی و داده نمودار شده (از chartevents)، تشخیص های ICD-9 و ICD-10، اعمال جراحی، و پیامدها (محل ترخیص، مرگ و میر، مدت بستری). دسترسی تکمیل فرآیند اعتبارسنجی (CITI، توافق استفاده از داده) از طریق PhysioNet را می طلبد. کوهورت ۲,۰۰۰ بیمار ما نمونه لایه ای است که برای آزمایش های بازتولیدپذیر طراحی شده و از نظر محاسباتی قابل مدیریت مانده است.

۲.۴.۲ ساختار داده

جداول کلیدی و نقش آن ها:

- `patients`: جمعیت شناسی (سن، جنس، سال لنگر). برای فیلتر سن و تعریف کوهورت به کار می رود.
- `admissions`: نوع پذیرش (انتخابی، اورژانسی)، محل ترخیص، زمان پذیرش و ترخیص. برای تعریف برچسب امکان پذیری بحرانی است.
- `icustays`: شناسه های اقامت ICU (`stay_id`)، `subject_id`، `hadm_id`، `intime`، `outtime`، مدت بستری. جدول اصلی برای استخراج کوهورت.
- `labevents`: اندازه گیری های آزمایشگاهی با `itemid` (از `d_labitems`)، `valuenum`، `charttime`. ۱۵ نوع آزمایش (کراتینین، پتاسیم، سدیم و غیره) از ۲۴ ساعت اول استخراج می شود.
- `chartevents`: علائم حیاتی و داده نمودار شده دیگر. ۷ علامت حیاتی (ضربان قلب، فشار خون، دما، `SpO2`، نرخ تنفس) از `d_items` استخراج می شود.

• `diagnoses_icd`: تشخیص‌های ICD-10/ICD-9. برای تخصیص تشخیص اولیه و

پارتیشن‌بندی گره بیماری به کار می‌رود.

اتصال‌ها از طریق `subject_id`، `hadm_id` و `stay_id` انجام می‌شود. برای پرس‌وجوهای SQL به پیوست ب مراجعه کنید.

۳.۴.۲ تعریف کوهورت

کوهورت ۲,۰۰۰ بیمار با این شرایط استخراج می‌شود:

- تنها نخستین اقامت ICU.
- حداقل ۴ ساعت مدت بستری.
- سن ≥ 18 .
- ICD-10 اولیه برای تخصیص گره بیماری در دسترس باشد.

۴.۴.۲ تعریف برچسب

امکان‌پذیری درمان دوجمله‌ای است: ۱ اگر محل ترخیص در {HOME HEALTH CARE, HOME, REHAB, REHAB/DISTINCT PART HOSP, HOME WITH HOME IV PROVIDR} ظرف ۳۰ روز از اقامت ICU باشد و بستری مجدد در ۳۰ روز نباشد؛ در غیر این صورت ۰. این با تعاریف بالینی مقصدهای ترخیص «ممکن» هم‌خوان است.

۵.۴.۲ گره‌های بیماری

بر اساس ICD-10 اولیه به پنج گره پارتیشن می‌کنیم:

- گره ۱ (سپسیس): A40, A41, R652.
- گره ۲ (قلبی): J21, J22, J25, J50, J47, J48, J49.
- گره ۳ (تنفسی): J18, J44, J96, J80, J15.
- گره ۴ (کلیوی): N17, N18, N19.
- گره ۵ (دیابت): E10, E11, E13.

این آموزش فدرال با داده‌ی محلی وابسته به بیماری را ممکن می‌سازد.

۵.۲ کارهای مرتبط: پیش‌بینی بالینی

۱.۵.۲ پیش‌بینی مبتنی بر EHR

پرونده‌های سلامت الکترونیک (EHR) برای پیش‌بینی مرگ‌ومیر، ریسک بستری مجدد، و پیش‌بینی مدت بستری به کار رفته‌اند. رویکردهای کلاسیک رگرسیون لجستیک، جنگل تصادفی، یا تقویت گرادیان روی ویژگی‌های دست‌ساز را به کار می‌برند. روش‌های یادگیری عمیق شامل شبکه‌های بازگشتی برای دنباله‌های زمانی و ترنسفورمرها برای داده‌ی ساخت‌یافته است. این کار با تمرکز بر تنظیمات few-shot و فدرال متفاوت است.

۲.۵.۲ پیش‌بینی ترخیص

پیش‌بینی مقصد ترخیص مسئله‌ی پرکار است. عوامل شامل وضعیت عملکردی، همراه بیماری، حمایت اجتماعی، و مسیر اولیه‌ی ICU است. بیشتر کارهای پیشین داده‌ی متمرکز و یادگیری نظارت‌شده استاندارد به کار می‌برند. بررسی می‌کنیم آیا فرا یادگیری few-shot می‌تواند عملکرد کلاسیک را وقتی داده محدود و توزیع‌شده است برابر کند یا به آن نزدیک شود.

۳.۵.۲ یادگیری عمیق در برابر جدولی

روی داده‌ی جدولی، تقویت گرادیان (CatBoost, LightGBM, XGBoost) اغلب یادگیری عمیق را پیشی می‌گیرد. شبکه‌های عصبی ممکن است به داده‌ی بیشتر یا طراحی دقیق معماری نیاز داشته باشند. نتایج منجمد Exp1 ما هم‌راستا است: Random Forest (AUROC ۰.۷۶۲) از Proposed_FewShot (۰.۶۱۱) بهتر است. این شکاف نشان می‌دهد برای این وظیفه و اندازه‌ی مجموعه، وقتی آموزش متمرکز ممکن است، مدل‌های جدولی همچنان انتخاب ترجیحی‌اند.

۴.۵.۲ یادگیری few-shot روی داده‌ی جدولی

یادگیری few-shot برای طبقه‌بندی تصویر (Omniglot, CUB, miniImageNet) و پردازش زبان طبیعی به‌گسترده‌ی مطالعه شده، اما کاربرد به داده‌ی جدولی کم‌کاوش مانده است. داده‌ی جدولی چالش‌های

ویژه برای فرا یادگیری دارد:

۱. **ناهمگونی ویژگی:** برخلاف تصاویر (که همه پیکسل ها فضای بازنمایی مشترک دارند)، ویژگی های جدولی انواع (پیوسته، طبقه ای، دوجمله ای) و مقیاس های متنوع (مثلاً کراتینین به mg/dL در برابر ضربان قلب به bpm) دارند. طرح های توکن سازی باید این تنوع را پوشش دهند.

۲. **تعاملات ویژگی:** مدل های مبتنی بر درخت به طور طبیعی تعاملات را از طریق انشعاب می گیرند؛ شبکه های نمونه ای به فضای جاسازی برای رمزگذاری این تعاملات تکیه می کنند که ممکن است به داده آموزش فراوان نیاز داشته باشد.

۳. **رژیم نمونه کم:** وقتی کل مجموعه کوچک است (مثلاً ۲,۰۰۰ بیمار)، مجموعه فرا-آموزش ممکن است تنوع کافی برای یادگیری جاسازی های تعمیم یافته بین اپیزودها نداشته باشد.

۴. **فقدان ساختار فضایی:** تصاویر همبستگی مکانی محلی دارند؛ ویژگی های جدولی این سوگیری القایی را ندارند. ترنسفورمرهای اعمال شده به داده جدولی باید روابط ویژگی را از صفر بیاموزند.

کار اخیر Iwata و Kumagai (۲۰۲۰) فرا یادگیری را به رگرسیون جدولی اعمال کرد، و Hegselmann و همکاران (۲۰۲۳) TabLLM را برای طبقه بندی جدولی few-shot با جاسازی های مدل زبانی کاوش کردند. این رویکردها پیشنهاد می کنند یادگیری جدولی مؤثر few-shot ممکن است نیاز به (الف) مجموعه های پیش آموزش بسیار بزرگ، (ب) توکن سازی وابسته به وظیفه، یا (ج) معماری های ترکیبی که بازنمایی های آموخته شده را با ویژگی های کلاسیک یکی کند، داشته باشد. معماری ETHOS_RF_Hybrid ما با جهت (ج) هم راستا است.

۵.۵.۲ مکانیزم های توجه برای داده بالینی

خود-توجه [Vaswani et al., 2017] به هر توکن اجازه می دهد به همه توکن های دیگر توجه کند و وابستگی های دوربرد را بگیرد. در داده بالینی، مدل می تواند روابط بین آزمایشگاه و علائم حیاتی بیاموزد (مثلاً کراتینین و BUN برای عملکرد کلیوی؛ لاکتات و فشار خون برای وضع همودینامیک). رمزگذار ETHOS اصلاحات دامنه ویژه اضافه می کند: (۱) ماتریس سوگیری هم وقوعی قابل آموزش که دانش پیشین هم وقوعی علائم را رمزگذاری می کند؛ (۲) وزن دهی شدت که توجه را به بزرگی مقادیر بالینی مقیاس می کند؛ (۳) فروپاشی زمانی که نفوذ اندازه گیری های قدیمی تر را کاهش می دهد. این اصلاحات

ETHOS را از ترنسفورمرهای عمومی متمایز می‌کند و بخشی از نوآوری رویکرد ماست.

۶.۵.۲ جزئیات معماری ETHOS

رمزگذار ETHOS (Efficient Transformer for Health Outcome prediction using Symptom tokens) [Sharafi and Aminian, 2023] معماری ترنسفورمر استاندارد را با سه مکانیزم دامنه‌ویژه برای داده بالینی گسترش می‌دهد:

سوگیری هم‌وقوعی. ماتریس سوگیری قابل آموزش $B \in \mathbb{R}^{V \times V}$ (که V اندازه واژگان علامت است) به logit‌های توجه پیش از softmax افزوده می‌شود:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} + B_{\text{co-occur}} \right) V \quad (۱۲.۲)$$

درایه B_{ij} قدرت هم‌وقوعی پیشین بین علامت i و علامت j را رمزگذاری می‌کند. می‌توان از دانش بالینی (مثلاً هم‌وقوعی کراتینین و BUN در پانل کلیوی) مقداردهی اولیه کرد یا از داده آموخت. سوگیری مدل را تشویق می‌کند به اندازه‌گیری‌های بالینی مرتبط توجه کند و سوگیری القایی فقدان ساختار فضایی در داده جدولی را جبران می‌کند.

وزن‌دهی شدت. توجه استاندارد همه توکن‌ها را بدون توجه به بزرگی بالینی یکسان می‌پندارد. ETHOS توجه را با شدت (مقدار نرمال‌شده) هر توکن مدوله می‌کند:

$$\alpha_{ij}^{\text{intensity}} = \alpha_{ij} \cdot \sigma(w_I \cdot \text{intensity}_j + b_I) \quad (۱۳.۲)$$

که در آن α_{ij} وزن توجه استاندارد است و $\sigma(w_I \cdot \text{intensity}_j + b_I)$ تابع دروازه‌ای آموخته‌شده از شدت توکن است. مقادیر افراطی (کراتینین بسیار بالا، پلاکت بسیار پایین) توجه تقویت‌شده می‌گیرند؛ منعکس‌کننده عمل بالینی که مقادیر غیرعادی اهمیت تشخیصی نامتناسب دارند.

فروپاشی زمانی. وقتی چند اندازه‌گیری در زمان‌های مختلف موجود است، ETHOS فروپاشی نمایی زمانی برای کاهش نفوذ مشاهدات قدیمی‌تر اعمال می‌کند:

$$w_{\text{time}}(t) = \exp(-\lambda \cdot |t - t_{\text{ref}}|) \quad (۱۴.۲)$$

که در آن λ نرخ فروپاشی قابل آموزش و t_{ref} زمان مرجع (معمولاً تازه‌ترین مشاهده یا زمان پیش‌بینی) است. این شهود بالینی را منعکس می‌کند: کراتینین ۲ ساعت پیش از ۲۰ ساعت پیش اطلاعاتی‌تر است. در پیاده‌سازی ما با داده تجمیع‌شده ۲۴ ساعت اول، اثر فروپاشی زمانی محدود است (همه اندازه‌گیری‌ها از همان پنجره‌اند)، اما مکانیزم برای تعمیم به ورودی‌های سری زمانی گنجانده شده است.

مقایسه با ترنسفورمر عمومی. جدول ۱.۲ ETHOS را با رمزگذار ترنسفورمر عمومی در انتخاب‌های طراحی کلیدی مقایسه می‌کند.

جدول ۱.۲: ETHOS در برابر رمزگذار ترنسفورمر عمومی

ویژگی	ترنسفورمر عمومی	ETHOS
سوگیری توجه	هیچ	هم‌وقوعی قابل آموزش
وزن‌دهی مقدار	یکنواخت	دروازه‌شده با شدت
مدل‌سازی زمانی	تنها رمزگذاری موقعیتی	فروپاشی نمایی
ورودی	قطعات کلمه / جاسازی	توکن علامت
پیش‌آموزش	مجموعه بزرگ (BERT-مانند)	از صفر (اپیزودیک)
پارامترها	~100 میلیون (BERT)	~2 میلیون

۷.۵.۲ رویکردهای توکن‌سازی علامت در ادبیات

مفهوم توکن‌سازی اندازه‌گیری‌های بالینی برای پردازش ترنسفورمر از چند جهت پژوهشی برخاسته است:

۱. **نسخه‌های بالینی BERT.** مدل‌های ClinicalBERT [Alsentzer et al., 2019] و

BioBERT [Lee et al., 2020] متن بالینی (یادداشت‌ها و گزارش‌ها) را با توکن‌سازی

wordpiece پردازش می‌کنند. این مدل‌ها برای زبان طبیعی طراحی شده‌اند، نه برای

اندازه‌گیری‌های ساخت‌یافته.

۲. **جاسازی کدهای پزشکی.** مدل‌های BEHRT [Li et al., 2020b] و Med-BERT

[Rasmy et al., 2021] کدهای تشخیصی (ICD-10/ICD-9) را به‌عنوان توکن در معماری

شبیه BERT جاسازی می‌کنند. این خانواده کدهای طبقه‌ای را پوشش می‌دهد، نه مقادیر

پیوسته آزمایشگاه.

۳. **TabTransformer** [Huang et al., 2020]: ویژگی‌های طبقه‌ای را به‌عنوان توکن جاسازی

می‌کند و توجه ترنسفورمر اعمال می‌کند، در حالی که ویژگی‌های عددی را به‌صورت اسکالر پس از ترنسفورمر الحاق می‌کند. رویکرد ما با توکن‌سازی هم اطلاعات طبقه‌ای (ID علامت) و هم عددی (شدت) در یک توکن یکپارچه متفاوت است.

۴. SAINT [Somepalli et al., 2021]: توجه بین-نمونه و بین-ویژگی برای داده‌جدولی اعمال می‌کند. برخلاف رویکرد ما، SAINT بازنمایی مبتنی بر توکن به کار نمی‌برد بلکه هر ویژگی را بعد توجه می‌پندارد.

۵. FT-Transformer [Gorishniy et al., 2024]: همه ویژگی‌ها (عددی و طبقه‌ای) را به جاسازی تبدیل می‌کند و لایه‌های ترنسفورمر استاندارد اعمال می‌کند. به رویکرد ما نزدیک‌تر است اما اصلاحات دامنه‌ویژه بالینی (سوگیری هم‌وقوعی، وزن‌دهی شدت، فروپاشی زمانی) ندارد.

طرح توکن علامت ما با این موارد متمایز است: (۱) نرمال‌سازی دامنه بالینی با کران‌های برش دامنه‌ویژه؛ (۲) رمزگذاری صریح مودالیتی (آزمایش در برابر علامت حیاتی)؛ (۳) ساختار چهاربعدی توکن برای هویت، بزرگی، زمان، و نوع؛ و (۴) سازگاری با آموزش اپیزودیک few-shot از طریق دنباله‌های با طول ثابت.

۶.۲ جمع‌بندی

این فصل یادگیری few-shot (شبکه‌های نمونه‌ای، تطبیقی، MAML)، یادگیری فدرال (FedAvg)، حریم خصوصی، غیر IID)، بازنمایی داده بالینی (نرمال‌سازی، توکن‌ها)، و MIMIC-IV را مرور کرد. همچنین کارهای مرتبط در پیش‌بینی بالینی را بررسی کردیم. فصل بعد روش‌شناسی را به تفصیل شرح می‌دهد.

۷.۲ جدول مقایسه کارهای پیشین

جدول ۲.۲ کار ما را نسبت به انتشارات کلیدی پیشین جای می‌دهد. ترکیب فرا یادگیری few-shot، آموزش فدرال، و بازنمایی مبتنی بر توکن روی داده بالینی جدولی در این کار یکتا است. بیشتر کارهای پیشین یا داده متمرکز، یادگیری نظارت‌شده استاندارد، یا تمرکز بر تصویربرداری به جای آزمایشگاه و علائم حیاتی دارند.

جدول ۲.۲: مقایسه کارهای پیشین در پیش‌بینی بالینی

اثر وظیفه	روش	FSL	FL	توکن	تفاوت کلیدی
Awad et al. 2017 ترخیص	LR / RF	×	×	×	نظارت‌شده متمرکز
Purushotham et al. 2018 مرگ‌ومیر	LSTM / RF	×	×	×	متمرکز؛ بدون FL
Rajkomar et al. 2018 بستری مجدد	DNN	×	×	×	مقیاس‌پذیر روی EHR چندسایتی
BEHRT 2020 کدهای EHR	ترنسفورمر	×	×	✓	پیش‌آموزش روی توالی کدها
FedHealth 2020 پوشیدنی	FedAvg + TL	×	✓	×	فدرال، اما بدون few-shot
TabTransformer 2020 جدولی	توجه	×	×	جزئی	توکن‌سازی عمده برای ویژگی‌های طبقه‌ای
Sheller et al. 2020 تومور مغزی	U-Net	×	✓	×	تصویرمحور، نه داده جدولی
Hegselmann et al. 2023 FSL جدولی	TabLLM	✓	×	✓	مبتنی بر LLM؛ بدون FL
FT-Transformer 2024 جدولی	ترنسفورمر	×	×	✓	بدون FSL و بدون FL
این پایان‌نامه امکان‌پذیری	ETHOS + Proto + Fed	✓	✓	✓	تنها موردی که هر سه مؤلفه را هم‌زمان ترکیب می‌کند

Federated Learning = FL, Few-Shot Learning = FSL. ✓ = حضور، × = غیاب.

۸.۲ ادبیات تفصیلی: مقالات کلیدی

مقالات کلیدی که کار ما را روشن می کنند را خلاصه می کنیم. (Snell et al. (2017 شبکه های نمونه ای را برای یادگیری few-shot معرفی کرد؛ این معماری را برای سر few-shot می پذیریم. McMahan (2017) FedAvg را برای یادگیری فدرال پیشنهاد کرد؛ از پروتکل استاندارد استفاده می کنیم. (Vinyals et al. (2016 شبکه های تطبیقی با توجه روی مجموعه پشتیبان پیشنهاد کرد؛ برای کارایی از نمونه ای بهره می بریم. (MAML Finn et al. (2017 را برای فرا یادگیری معرفی کرد؛ به خاطر پیچیدگی محاسباتی از نمونه ای استفاده می کنیم. (MIMIC-IV Johnson et al. (2023 را منتشر کرد؛ از طرحواره v3.1 استفاده می کنیم. (ETHOS Sharafi & Aminian (2023 را برای پیش بینی پیامد سلامت پیشنهاد کرد؛ برای few-shot سازگار می کنیم. (Lin et al. (2017 زیان کانونی (focal loss) را برای داده نامتوازن پیشنهاد کرد؛ برای سر few-shot به کار می بریم. (Lundberg & SHAP Lee (2017 را برای تفسیرپذیری معرفی کرد؛ برای توضیح مدل استفاده می کنیم. این مراجع بنیان نظری و تجربی رویکرد ما را فراهم می کنند.

۹.۲ خلاصه مبانی نظری

این فصل مبانی نظری را استقرار داد: (۱) یادگیری few-shot کمیابی داده را با فرا یادگیری پوشش می دهد؛ شبکه های نمونه ای از مرکز ثقل کلاس استفاده می کنند؛ (۲) یادگیری فدرال آموزش بدون تجمیع مرکزی داده را ممکن می سازد؛ FedAvg به روزرسانی های مدل را تجمیع می کند؛ (۳) داده بالینی برای مدل های عصبی به نرمال سازی و توکن سازی نیاز دارد؛ (۴) MIMIC-IV داده ICU با طرحواره ساخت یافته فراهم می کند؛ (۵) کار پیشین پیش بینی بالینی داده متمرکز و یادگیری نظارت شده استاندارد به کار می برد؛ ترکیب few-shot، فدرال، و بازنمایی مبتنی بر توکن برای امکان پذیری درمان نو است. فصل بعد روش شناسی را به تفصیل، شامل معماری رمزگذار ETHOS، توکن سازی علامت، و پروتکل ارزیابی، شرح می دهد.

۱۰.۲ مرور گسترده ادبیات

۱.۱۰.۲ مبانی فرا یادگیری

فرا یادگیری، یا «یادگیری برای یادگیری»، ریشه در علوم شناختی و پژوهش اولیه AI دارد. بینش کلیدی این است که خود یادگیری می تواند بهینه شود: به جای آموزش مدل از صفر روی هر وظیفه جدید، می توان مقداردهی اولیه، پیش زمینه، یا الگوریتم یادگیری آموخت که بین وظایف تعمیم یابد. این وقتی وظایف ساختار مشترک دارند (مثلاً همه طبقه بندی فنوتیپ های بالینی) اما هر وظیفه داده برچسب خورده محدود دارد، به ویژه مرتبط است.

۲.۱۰.۲ یادگیری انتقالی و سازگاری دامنه

یادگیری انتقالی مدلی را که روی دامنه مبدأ پیش آموزش دیده روی دامنه هدف تنظیم می کند. یادگیری few-shot را می توان به عنوان انتقال افراطی دید: دامنه هدف تعداد بسیار اندک نمونه برچسب خورده دارد. سازگاری دامنه جابه جایی توزیع بین مبدأ و هدف را پوشش می دهد؛ در تنظیم ما، گره های بیماری مختلف ممکن است توزیع های متفاوتی داشته باشند. یادگیری فدرال قید می کند که داده مبدأ و هدف را نمی توان تجمیع کرد.

۳.۱۰.۲ یادگیری متضاد و یادگیری متریک

یادگیری متریک جاسازی هایی می آموزد که نمونه های مشابه نزدیک و نمونه های ناهمگون دور باشند. شبکه های نمونه ای به صورت ضمنی یادگیری متریک به کار می برند: فضای جاسازی طوری آموزش داده می شود که نمونه ای های کلاس جدا شوند. یادگیری متضاد (مثلاً MoCo، SimCLR) به تصویربرداری پزشکی اعمال شده؛ گسترش به داده بالینی جدولی جهت باز است.

۴.۱۰.۲ چالش های ویژه سلامت

یادگیری ماشین در سلامت با چالش های ویژه روبه روست: (۱) مقرراتی (FDA، علامت گذاری CE)، (۲) تفسیرپذیری (بالین دانان باید پیش بینی را بفهمند)، (۳) انصاف (اجتناب از سوگیری علیه زیرگروه ها)، (۴) اعتبار زمانی (مدل ها ممکن است با تکامل عمل ضعیف شوند). این کار این موارد را عمیق پوشش نمی دهد اما خط پایه ای برای پژوهش آتی فراهم می کند.

۱۱.۲ ترنسفورمرها در داده بالینی

۱.۱۱.۲ مکانیزم‌های توجه

معماری ترنسفورمر [Vaswani et al., 2017, Devlin et al., 2019] NLP را دگرگون کرد و برای داده بالینی سازگار شده است. خود-توجه به مدل اجازه می‌دهد هنگام محاسبه بازنمایی‌ها، وزن‌های مختلف به توکن‌های ورودی (مثلاً مقادیر آزمایشگاه، علائم حیاتی) بدهد. برای داده بالینی جدولی، رمزگذارهای مبتنی بر توکن مانند ETHOS توجه روی توکن‌های علامت برای گرفتن تعاملات اعمال می‌کنند.

۲.۱۱.۲ رمزگذاری موقعیتی

برخلاف متن دنباله‌ای، توکن‌های بالینی ممکن است ترتیب ضمنی داشته باشند (مثلاً زمان اندازه‌گیری). از رمزگذاری موقعیتی برای تزریق اطلاعات ترتیب استفاده می‌شود. رمزگذاری‌های سینوسی و آموخته‌شده رایج‌اند؛ از فرمول‌بندی استاندارد ترنسفورمر پیروی می‌کنیم.

۳.۱۱.۲ ترنسفورمرهای بالینی

BEHRT [Li et al., 2020b] و سایر نسخه‌های BERT بالینی روی دنباله‌های EHR پیش‌آموزش می‌بینند. G-BERT [Shang et al., 2020] ساختار گراف را می‌گنجاند. TabTransformer [Huang et al., 2020] و SAINT [Somepalli et al., 2021] ترنسفورمر را به داده جدولی اعمال می‌کنند. رمزگذار ETHOS ما سبک‌تر است و برای آموزش اپیزودیک few-shot طراحی شده، نه پیش‌آموزش مقیاس بزرگ.

۱۲.۲ یادگیری در شرایط نامتوازن

۱.۱۲.۲ نامتوازنی کلاس در داده بالینی

کوهورت‌های ICU اغلب پیامدهای نامتوازن دارند: مثلاً ۴۲٪ ممکن در برابر ۵۸٪ ناممکن در کوهورت ما. آنتروپی متقاطع استاندارد ممکن است به کلاس اکثریت سوگیری داشته باشد. از زیان کانونی [Lin et al., 2017] برای کم‌وزن کردن نمونه‌های آسان و وزن کلاس برای خطوط پایه استفاده می‌کنیم. برای ارزیابی، AUROC [Hanley and McNeil, 1982] و F1-macro استانداردند؛ ضریب

همبستگی Matthews [Matthews, 1975] نیز گزارش می‌شود.

۲.۱۲.۲ SMOTE و نمونه‌برداری مجدد

SMOTE با درون‌یابی بین نزدیک‌ترین همسایه‌ها نمونه اقلیت می‌سازد. در حذف تدریجی اختیاری SMOTE اعمال می‌شود؛ برای وظیفه‌ی ما وزن‌دهی کلاس و تنظیم آستانه کفایت می‌کند.

۳.۱۲.۲ معیارهای ارزیابی

برای داده نامتوازن، AUROC نسبت به آستانه ثابت نیست. F1-macro میانگین F1 به‌ازای هر کلاس است. هر دو گزارش می‌شود؛ AUROC برای مقایسه مدل اصلی است.

۱۳.۲ تفسیرپذیری در یادگیری ماشین سلامت

۱.۱۳.۲ اهمیت ویژگی

مدل‌های مبتنی بر درخت (XGBoost, Random Forest) اهمیت بومی ویژگی می‌دهند. از اهمیت Gini و اهمیت جایگشت استفاده می‌کنیم. SHAP [Lundberg and Lee, 2017] توضیحات مستقل از مدل ارائه می‌دهد؛ برای تفسیرپذیری محلی به کار می‌بریم. LIME [Ribeiro et al., 2016] جایگزین است؛ برای سازگاری با مدل‌های مبتنی بر درخت از SHAP استفاده می‌کنیم.

۲.۱۳.۲ تصویرسازی توجه

برای مدل‌های ترنسفورمر، وزن‌های توجه نشان می‌دهند مدل به کدام توکن‌ها توجه می‌کند. در فصل ۵، توجه را از طریق انتساب ویژگی SHAP برای پیش‌بینی‌های فردی تحلیل می‌کنیم.

۳.۱۳.۲ اعتبارسنجی بالینی

تفسیرپذیری باید با دانش بالینی هم‌راستا باشد. ویژگی‌های برتر (کراتینین، گلوکز، هموگلوبین) با تعیین‌کننده‌های شناخته‌شده ترخیص هم‌خوان‌اند. تفسیر بالینی در فصل ۵ بحث می‌شود.

۱۴.۲ مرور جامع ادبیات

۱.۱۴.۲ تحول و بنچمارک‌های یادگیری چندنمونه‌ای (few-shot)

یادگیری few-shot از شبکه‌های سیامی اولیه [Koch et al., 2015] و شبکه‌های تطبیقی [Vinyals et al., 2016] به رویکردهای نمونه‌ای مدرن [Snell et al., 2017] و فرا یادگیری [Ravi and Larochelle, 2017, Finn et al., 2017] تکامل یافته است. این حوزه به گستردگی مرور شده است [Wang et al., 2020]. بنچمارک‌های کلیدی آن شامل Omniglot [Lake et al., 2015]، mini-ImageNet و Meta-Dataset [Triantafillou et al., 2020] است. کارهای اخیر نیز پرسیده‌اند آیا خطوط پایه ساده [Dhillon et al., 2020] می‌توانند با فرا یادگیری پیچیده برابری کنند. این پایان‌نامه همان پرسش را به داده بالینی جدولی گسترش می‌دهد.

۲.۱۴.۲ یادگیری فدرال: سامانه‌ها و نظریه

سامانه‌های یادگیری فدرال [He et al., 2020, Bonawitz et al., 2019] مقیاس، ناهمگونی و حریم خصوصی را مدیریت می‌کنند. تحلیل نظری [Karimireddy et al., 2020, Reddi et al., 2021] همگرایی غیر IID را پوشش می‌دهد. کاربردهای سلامت [Rieke et al., 2020, Kaissis et al., 2020] نیز امکان‌پذیری این پارادایم را نشان داده‌اند. پیاده‌سازی FedAvg ما پروتکل استاندارد [McMahan et al., 2017] را دنبال می‌کند؛ در این پایان‌نامه حریم تفاضلی یا تجمیع امن اضافه نمی‌کنیم.

۳.۱۴.۲ پیش‌بینی بالینی: وضعیت هنر

پیش‌بینی مبتنی بر EHR از رگرسیون لجستیک [Awad et al., 2017] به یادگیری عمیق [Pham et al., 2016, Choi et al., 2016, Rajkomar et al., 2019] پیش رفته است. یادگیری چندوظیفه‌ای [Harutyunyan et al., 2019] کارایی نمونه را بهبود می‌بخشد. مطالعات بنچمارک [Purushotham et al., 2018] نشان می‌دهند تقویت گرادیان اغلب یادگیری عمیق را روی EHR جدولی پیشی می‌گیرد. نتایج منجمد ما نیز همین الگو را نشان می‌دهد: Random Forest با AUROC ۰.۷۶۲ از Proposed_FewShot با ۰.۶۱۱ بهتر است و مدل ترکیبی ETHOS_RF_Hybrid با ۰.۷۱۷ یک راه‌حل میانی ارائه می‌دهد.

۴.۱۴.۲ یادگیری عمیق جدولی

کار اخیر شامل TabNet [Arik and Pfister, 2021]، TabTransformer [Huang et al., 2020]، SAINT [Somepalli et al., 2021] و FT-Transformer [Gorishniy et al., 2024] است. TabNet توجه دنباله‌ای برای انتخاب ویژگی به کار می‌برد؛ TabTransformer خود-توجه را روی جاسازی‌های ویژگی‌های طبقه‌ای و عددی اعمال می‌کند؛ SAINT توجه روی ردیف و ستون دارد. رمزگذار ETHOS ما مفهوماً شبیه TabTransformer است اما روی توکن‌های علامت (IDهای گسسته + شدت) به جای ستون‌های جدولی خام عمل می‌کند. روی مجموعه‌های بزرگ پیش‌آموزش نمی‌بینیم؛ رمزگذار از صفر برای وظیفه few-shot آموزش داده می‌شود.

۵.۱۴.۲ مجموعه‌های داده بنچمارک در ML بالینی

فراتر از MIMIC، بنچمارک‌های مهم شامل eICU برای داده چندمرکز ICU، UK Biobank برای سلامت جمعیتی و مجموعه‌های اختصاصی EHR هستند. جدول ۳.۲ این مجموعه‌ها را مقایسه می‌کند. MIMIC-IV تمرکز ICU، دسترسی آزاد و مستندسازی قوی دارد؛ eICU تنوع چندمرکز اضافه می‌کند؛ و UK Biobank داده جمعیتی طولی فراهم می‌سازد. انتخاب MIMIC-IV به سه دلیل انجام شد: هم‌راستایی با مسئله تریخس ICU، دسترسی پذیری برای پژوهش دانشگاهی و وجود فرایندهای پیش‌پردازش و بنچمارک‌های پذیرفته‌شده در جامعه پژوهشی.

جدول ۳.۲: مجموعه‌های داده بنچمارک ML بالینی

مجموعه داده	اندازه	تمرکز	دسترسی
MIMIC-IV	بیش از 250,000 اقامت	ICU، تک‌مرکز	آزاد با فرایند اعتبارسنجی
eICU	بیش از 200,000 اقامت	ICU، چندمرکز	آزاد با فرایند اعتبارسنجی
UK Biobank	بیش از 500,000	جمعیتی، طولی	مبتنی بر درخواست
EHR اختصاصی	متغیر	وابسته به نهاد	دسترسی نهادی

MIMIC-IV به دلیل دسترسی آزاد (با اعتبارسنجی)، مستندسازی جامع، و پذیرش جامعه به گستردگی به کار می‌رود. نمونه ۲,۰۰۰ بیمار ما زیرمجموعه لایه‌ای برای بازتولیدپذیری است؛ آزمایش‌های کامل MIMIC-IV به محاسبه قابل توجه نیاز دارند و ممکن است نتایج متفاوتی بدهند. مرورها [Borisov et al., 2022] نتیجه می‌گیرند مدل‌های مبتنی بر درخت همچنان نیرومندند؛

رویکردهای عصبی به تنظیم دقیق نیاز دارند. رمزگذار ETHOS ترنسفورمر سبک برای دنباله‌های توکن است؛ روی مجموعه‌های بزرگ پیش‌آموزش نمی‌بینیم.

۶.۱۴.۲ پیش‌بینی ترخیص: نتایج پیشین

کار پیشین پیش‌بینی ترخیص نتایج متنوع گزارش می‌کند. (Random Forest Awad et al. (2017 و رگرسیون لجستیک روی MIMIC-III برای مقصد ترخیص به AUROC ۰.۷۸ رسیدند. Caruana et al. (2015) AUROC ۰.۸۸ برای پیش‌بینی مرگ‌ومیر روی داده EHR گزارش کردند. Purushotham et al. (2018) LSTM و تقویت گرادیان را روی مرگ‌ومیر MIMIC-III (AUROC ۰.۸۵) بنچمارک کردند. (Rajkomar et al. (2018 برای پیش‌بینی بستری مجدد AUROC ۰.۷۶ به دست آوردند. وظیفه امکان‌پذیری درمان ما مرتبط اما متمایز است: از داده ۲۴ ساعت اول، امکان‌پذیری دوجمله‌ای (ترخیص به منزل/توان بخشی بدون بستری مجدد) پیش‌بینی می‌کنیم. AUROC ۰.۷۶ ما با نتایج پیشین ترخیص و بستری مجدد قابل‌مقایسه است. نوآوری در تنظیم few-shot و فدرال است، نه فراتر رفتن از بنچمارک‌های متمرکز.

۷.۱۴.۲ AI اخلاقی در سلامت

ملاحظات اخلاقی [Floridi et al., 2018, Jobin et al., 2019, Gerke et al., 2020] و انصاف [Obermeyer et al., 2019, Chouldechova, 2017, Rajkomar et al., 2018] برای AI سلامت بحرانی است. اصول کلیدی: (۱) نیک‌کاری: مدل‌ها باید پیامد بیمار را بهبود دهند؛ هم نتایج مثبت و منفی گزارش می‌کنیم تا اغراق نشود. (۲) نیک‌نبودن: اجتناب از آسیب؛ برای استقرار انسان-در-حلقه توصیه می‌کنیم. (۳) خودمختاری: بیماران و بالین‌دانان حاکمیت تصمیم را دارند؛ مدل‌ها پشتیبان تصمیم‌اند. (۴) عدالت: انصاف بین جمعیت‌شناسی‌ها؛ عملکرد لایه‌بندی شده بر اساس سن گزارش می‌شود. (۵) شفافیت: تفسیرپذیری از طریق SHAP و اهمیت ویژگی. چارچوب‌های مقرراتی (FDA برای نرم‌افزار به‌عنوان دستگاه پزشکی، GDPR برای اتحادیه اروپا) استقرار را حاکم می‌کنند؛ این کار از داده پژوهشی استفاده می‌کند و محصول مقرراتی نیست.

چارچوب‌های مقرراتی (GDPR, FDA [Voigt and Von dem Bussche, 2017]) استقرار را حاکم می‌کنند. این کار از داده ناشناس شده MIMIC-IV استفاده می‌کند؛ اخلاق در پیوست ذ بحث می‌شود.

۱۵.۲ جزئیات معماری ترنسفورمر

رمزگذار ترنسفورمر از لایه‌های متناوب چندسر خود-توجه و پیش‌خور جلو تشکیل شده است. هر سر توجه $\text{head}_i = \text{Softmax}(Q_i K_i^\top / \sqrt{d_k}) V_i$ را محاسبه می‌کند که در آن Q_i, K_i, V_i تصویرهای آموخته‌شده‌اند. خروجی همه سرها الحاق و تصویر می‌شود. نرمال‌سازی لایه پیش و پس از هر زیرلایه اعمال می‌شود (پیکربندی Pre-LN). لایه پیش‌خور جلو: $\text{FFN}(x) = \text{ReLU}(xW_1 + b_1)W_2 + b_2$ با $d_{\text{ff}} = 512$ Dropout (۰.۲) پس از توجه و FFN اعمال می‌شود. TabTransformer, TabNet, SAINT و FT-Transformer ترنسفورمر را به داده جدولی اعمال می‌کنند؛ رمزگذار ETHOS ما روی توکن‌های علامت (IDهای گسسته + شدت) عمل می‌کند و از صفر برای few-shot آموزش داده می‌شود، نه پیش‌آموزش مقیاس بزرگ.

۱۶.۲ پروتکل ارزیابی و واریانس K-شات

برای ارزیابی few-shot، ۱۰۰ اپیزود از مجموعه آزمون نمونه‌برداری می‌کنیم. هر اپیزود K پشتیبان و Q پرس‌وجو به‌ازای هر کلاس دارد و میانگین AUROC و انحراف معیار بین اپیزودها گزارش می‌شود. برای مدل‌های کلاسیک از کل مجموعه آزمون در یک ارزیابی تکی استفاده می‌کنیم. این تفاوت پروتکل توضیح می‌دهد چرا AUROC آزمایش K-شات در بازه ۰.۵۶۴-۰.۵۵۷ می‌ماند، در حالی که ارزیابی ثابت Expl برای Proposed_FewShot عدد ۰.۶۱۱ را روی کل مجموعه آزمون گزارش می‌کند. کار پیشین روی AUROC MIMIC-III ۰.۷۸ برای ترخیص (Awad et al. 2017) و ۰.۸۵ برای مرگ‌ومیر (Purushotham 2018) گزارش کرد؛ AUROC امکان‌پذیری درمان MIMIC-IV ما با خط پایه کلاسیک در حدود ۰.۷۶ در بازه قابل‌مقایسه است.

۱۷.۲ بنچمارک‌های یادگیری few-shot

یادگیری few-shot روی بنچمارک‌هایی مانند Omniglot, mini-ImageNet و Meta-Dataset به‌طور گسترده ارزیابی شده است. این بنچمارک‌ها عمدتاً تصویری‌اند و ساختار فضایی طبیعی دارند؛ در حالی که داده بالینی جدولی چنین ساختاری ندارد و هر ویژگی اسکالری معنای بالینی متفاوتی دارد. این پژوهش پارادایم few-shot را به پیش‌بینی بالینی جدولی گسترش می‌دهد. تفاوت‌های اصلی عبارت‌اند از: نبود ستون فقرات از پیش‌آموزش دیده مانند ImageNet، کوچک‌تر بودن مجموعه فرا-آموزش (۲,۰۰۰ در برابر

میلیون‌ها نمونه)، طبقه‌بندی دودویی به‌جای چندکلاسه، و ارزیابی اپیزودیک با K متغیر. AUROC متوسط حدود ۰.۶۲ نشان می‌دهد few-shot جدولی برای رقابت با بنچمارک‌های بینایی احتمالاً به معماری‌های متفاوت یا مجموعه‌های فرا-آموزش بزرگ‌تر نیاز دارد.

۱۸.۲ یادگیری فدرال: ارتباطات و حریم خصوصی

FedAvg به چند دور ارتباط نیاز دارد. در هر دور، سرور مدل سراسری را به مشتریان می‌فرستد، مشتریان مدل را روی داده‌ی محلی خود آموزش می‌دهند و به‌روزرسانی‌ها را بازمی‌گردانند. با ۵ گره و ۲۰ دور، ۱۰۰ گام ارتباطی انجام می‌شود و در هر گام مدل کامل، حدود ۲ میلیون پارامتر در معماری ما، منتقل می‌گردد. در استقرار واقعی، فشردگی‌سازی گرادین یا به‌روزرسانی‌های جزئی می‌تواند پهنای باند را کاهش دهد. حریم تفاضلی نیز با برش گرادین و افزودن نویز گاوسی قابل افزودن است، هرچند در این پایان‌نامه پیاده‌سازی نشده است. جمع‌آوری امن، مثلاً با رمزنگاری هم‌ریختی یا محاسبه‌ی چندطرفه امن، می‌تواند به‌روزرسانی‌های فردی را از سرور پنهان کند. هزینه‌ی عملکرد کوچک (AUROC -0.5%) نشان می‌دهد وقتی داده را نمی‌توان جمع‌کرد، یادگیری فدرال برای این وظیفه عملی است.

۱۹.۲ پیش‌بینی بالینی: فرمول‌بندی وظیفه

امکان‌پذیری درمان وظیفه‌ی طبقه‌بندی دوجمله‌ای است: با داده‌ی اولیه‌ی ICU (۲۴ ساعت اول)، پیش‌بینی کنید آیا بیمار به ترخیص ممکن دست می‌یابد. برچسب از محل ترخیص و بستری مجدد ۳۰ روزه استخراج می‌شود. این فرمول‌بندی محدودیت دارد: (۱) مقصد ترخیص ممکن است به عوامل اجتماعی (مثلاً حمایت خانواده، بیمه) وابسته باشد که در آزمایشگاه و علائم حیاتی نیست؛ (۲) بستری مجدد ۳۰ روزه جایگزین بهبودی است؛ (۳) برچسب دوجمله‌ای ظرافت را از دست می‌دهد (مثلاً توان بخشی در برابر مراقبت پرستاری ماهر). با وجود این محدودیت‌ها، فرمول‌بندی بالینی معنادار و قابل مدیریت است. فرمول‌بندی‌های جایگزین شامل: رگرسیون (زمان تا ترخیص)، چندکلاسه (مقصد ترخیص)، یا تحلیل بقا (زمان-تا-رویداد) است. روی طبقه‌بندی دوجمله‌ای برای سادگی و هم‌راستایی با ادبیات پیشین پیش‌بینی ترخیص تمرکز می‌کنیم.

۲۰.۲ جایگزینی و مدیریت داده گمشده

داده بالینی اغلب مقادیر گمشده دارد. راهبرد زیر به کار می‌رود: (۱) برای سری زمانی (آزمایشگاه، علائم حیاتی در ۲۴ ساعت اول): پرکردن رو به جلو درون بیمار، سپس میانگین جمعیت برای همچنان گمشده. (۲) برای ویژگی‌های کاملاً گمشده: میانگین جمعیت. (۳) بدون پرکردن رو به عقب (تنها داده گذشته نسبت به زمان پیش‌بینی). (۴) جایگزینی پیچیده (مثلاً MICE، KNN) برای اجتناب از نشت داده و هزینه محاسباتی به کار نمی‌رود؛ جایگزینی میانگین محافظه کارانه است. نرخ فقدان داده به‌ازای ویژگی متفاوت است: آزمایشگاه‌های معمولی (کراتینین، سدیم) ۱۲-۵٪؛ آزمایشگاه‌های تخصصی (لاکتات، تروپونین) ۳۵-۱۸٪؛ علائم حیاتی ۸-۲٪. ویژگی‌ها با بیش از ۳۰٪ فقدان ممکن است ارزش پیش‌بینی کاهش یافته داشته باشند؛ برای کمال نگه داشته می‌شوند و مدل می‌آموزد. در استقرار، داده بلادرنگ ممکن است الگوی فقدان متفاوتی داشته باشد؛ پایش و آموزش مجدد ممکن است لازم شود.

۲۱.۲ جمع‌بندی فصل

این فصل مبانی نظری کار ما را مرور کرد. به یادگیری few-shot (شبکه‌های نمونه‌ای، تطبیقی، MAML، آموزش اپیزودیک)، یادگیری فدرال (FedAvg، حریم خصوصی، داده غیر IID، ارتباطات)، بازنمایی داده بالینی (نرمال‌سازی، توکن‌ها، جدولی در برابر دنباله‌ای)، و مجموعه داده MIMIC-IV (طرحواره، کوهورت، برچسب‌ها، گره‌های بیماری) پرداختیم. کارهای مرتبط در پیش‌بینی بالینی، ترنسفورمرها برای داده بالینی، یادگیری نامتوازن، تفسیرپذیری، و AI اخلاقی را بحث کردیم. همچنین جدول مقایسه کارهای پیشین، جزئیات معماری ترنسفورمر، واریانس پروتکل ارزیابی، بنچمارک‌های few-shot، ارتباطات و حریم خصوصی فدرال، فرمول‌بندی وظیفه بالینی، و راهبردهای جایگزینی را ارائه دادیم. فصل بعد روش‌شناسی را به تفصیل شرح می‌دهد.

فصل ۳

روش شناسی

این فصل روش پژوهش را مرحله به مرحله شرح می دهد: استخراج مجموعه داده، توکن سازی علائم، رمزگذار ETHOS، پروتکل چندنمونه ای، آموزش فدرال و ارزیابی. ابتدا نمادگذاری و نمای کلی فرایند ارائه می شود و سپس هر جزء به صورت جداگانه توضیح داده می شود.

۱.۳ نمادگذاری

در سراسر متن از نمادگذاری زیر استفاده می شود. جدول ۱.۳ مرجع خلاصه ای برای این نمادهاست.

جدول ۱.۳: خلاصه نمادگذاری

نماد	معنا
$\mathcal{X}$	فضای ورودی، یعنی بازنمایی بیماران
$\mathcal{Y}$	فضای برچسب $\{0, 1\}$ ، یعنی غیرقابل تحقق و قابل تحقق
$\mathcal{Q}, \mathcal{S}$	به ترتیب مجموعه پشتیبان و مجموعه پرس وجو
$\mathcal{Q}, K$	تعداد نمونه های پشتیبان و پرس وجو به ازای هر کلاس
N	تعداد کلاس ها؛ در این کار 2 برای طبقه بندی دودویی
θ	پارامترهای مدل
$\mathbf{c}_k$	بردار نمونه اولیه برای کلاس k
τ	دمای softmax
d	بعد جاسازی؛ در این کار 128
L	طول دنباله؛ در این کار 25 توکن

$\mathcal{X}$ فضای ورودی (بازنمایی بیماران) را؛ $\mathcal{Y} = \{0, 1\}$ برچسب دودویی (غیرقابل تحقق، قابل تحقق) را؛ $\mathcal{S}$ مجموعه پشتیبان را؛ $\mathcal{Q}$ مجموعه پرس وجو را؛ K تعداد نمونه های پشتیبان به ازای هر کلاس را؛

N تعداد کلاس‌ها (2 برای دودویی) را؛ θ پارامترهای مدل را؛ c_k نمونه اولیه کلاس k را؛ τ دما در softmax را؛ d بعد جاسازی (128 برای ETHOS) را؛ و L طول دنباله (25 توکن) را نمایش می‌دهد.

۲.۳ نمای کلی فرایند

شکل ۱.۳ فرایند انتهابه‌انتها را نشان می‌دهد. آزمایش‌ها و علائم حیاتی خام از ۲۴ ساعت نخست MIMIC-IV استخراج و نرمال‌سازی می‌شوند. سپس داده در دو شاخه پردازش می‌شود: در شاخه جدولی، بردار ویژگی ۲۵ بعدی به مدل‌های کلاسیک مانند RF و XGBoost داده می‌شود؛ در شاخه عصبی، داده به توکن‌های علامت تبدیل، با رمزگذار ETHOS به جاسازی ۱۲۸ بعدی نگاشت، و سپس با سرچندنمونه‌ای یا سر نظارت‌شده طبقه‌بندی می‌شود. در حالت فدرال، هر گره مدل را روی داده محلی خود آموزش می‌دهد و وزن‌ها با FedAvg جمع می‌شوند. در مدل ترکیبی نیز جاسازی‌های ETHOS با ویژگی‌های جدولی ادغام و به طبقه‌بند نهایی Random Forest داده می‌شوند.

جریان داده:

MIMIC-IV (آزمایشگاه، علائم حیاتی) → نرمال‌سازی → [Tabular 25-بعدی | توکن‌سازی → ETHOS → 128-بعدی] → [XGB/RF | سر نمونه اولیه‌ای | ترکیبی 153-بعدی → RF] → پیش‌بینی امکان‌پذیری ترخیص

شکل ۱.۳: فرایند انتهابه‌انتها: استخراج داده، بازنمایی دوگانه (جدولی و مبتنی بر توکن)، و شاخه‌های مدل.

۳.۳ مجموعه داده و پیش‌پردازش

۱.۳.۳ استخراج کوهورت

یک کوهورت شامل ۲,۰۰۰ بیمار از MIMIC-IV v3.1 با معیارهای زیر استخراج می‌شود:

- فقط اولین بستری در ICU (بدون بستری مجدد در کوهورت).
- حداقل 4 ساعت مدت بستری (برای اطمینان از کفایت داده).
- سن $18 \geq$ سال در پذیرش.
- تشخیص اصلی ICD-10 برای تخصیص گره بیماری موجود باشد.

فرایند استخراج (پیوست ب) ابتدا icustays را فیلتر می‌کند، سپس آن را به patients و

admissions پیوند می زند و در نهایت ۲,۰۰۰ بستری را با لایه بندی بر اساس گروه تشخیص اولیه نمونه گیری می کند. جدول ۲.۳ جمعیت شناسی کوهورت را خلاصه می کند.

جدول ۲.۳: آمار جمعیت شناختی کوهورت MIMIC-IV

شاخص میانگین انحراف معیار بازه		
سن (سال)	64.2	15.3
بیماران مرد (%)	56.4	—
طول اقامت ICU (ساعت)	72.4	96.2
طول اقامت بیمارستان (روز)	8.2	7.1
تعداد بیماران 2,000		

۲.۳.۳ فرایند تفصیلی استخراج MIMIC-IV

استخراج داده با یک فرایند چند مرحله ای SQL انجام می شود که هم بازتولیدپذیر باشد و هم از نظر بالینی قابل دفاع بماند. الگوریتم ۱ این فرایند را به صورت رسمی نشان می دهد.

Algorithm 1 MIMIC-IV cohort extraction pipeline

Require: MIMIC-IV database, target size $n = 2000$

```

1: Stage 1: Candidate ICU stays
2:  $\mathcal{C} \leftarrow \text{SELECT from icustays WHERE first\_stay} = \text{TRUE}$ 
3:  $\mathcal{C} \leftarrow \{c \in \mathcal{C} : \text{LOS}(c) \geq 4\text{h}\}$ 
4: Stage 2: Age filter
5:  $\mathcal{C} \leftarrow \{c \in \mathcal{C} : \text{age}(c) \geq 18\}$  ▷ Via patients.anchor_age
6: Stage 3: Diagnosis assignment
7: for each  $c \in \mathcal{C}$  do
8:    $\text{dx}(c) \leftarrow \text{primary ICD-10 from diagnoses\_icd}(\text{seq\_num}=1)$ 
9:    $\text{node}(c) \leftarrow \text{map\_to\_disease\_node}(\text{dx}(c))$ 
10: end for
11:  $\mathcal{C} \leftarrow \{c \in \mathcal{C} : \text{node}(c) \neq \text{NULL}\}$ 
12: Stage 4: Stratified sampling
13:  $\mathcal{S} \leftarrow \text{stratified\_sample}(\mathcal{C}, n = 2000, \text{strata} = \text{node})$ 
14: Stage 5: Label derivation
15: for each  $c \in \mathcal{S}$  do
16:    $\text{dest}(c) \leftarrow \text{admissions.discharge\_location}$ 
17:    $\text{readmit}(c) \leftarrow \text{check 30-day readmission from admissions}$ 
18:    $y(c) \leftarrow \mathbb{I}[\text{dest}(c) \in \{\text{HOME, REHAB, ...}\} \wedge \neg \text{readmit}(c)]$ 
19: end for
20: return  $\{(c, y(c)) : c \in \mathcal{S}\}$ 

```

ساختار پیوند بر سه کلید اصلی تکیه دارد: subject_id بیماران را به پذیرش ها، hadm_id پذیرش ها را به تشخیص ها و سوابق ترخیص، و stay_id بستری های ICU را به رویدادهای آزمایشگاهی و علائم حیاتی وصل می کند. ترتیب پیوندها طوری انتخاب شده است که اندازه نتایج میانی تا حد ممکن

کاهش یابد. ابتدا بستری‌های ICU فیلتر می‌شوند و تعداد نمونه‌ها از بیش از ۲۵۰ هزار به حدود ۱۸۰ هزار بستری اول می‌رسد. سپس فیلترهای سن و LOS اعمال می‌شوند و تعداد به حدود ۱۵۰ هزار کاهش می‌یابد. در گام بعد، وجود تشخیص ICD-10 الزامی می‌شود و حدود ۱۲۰ هزار نمونه باقی می‌ماند. در نهایت، ۲,۰۰۰ بیمار به صورت لایه‌بندی شده نمونه‌گیری می‌شوند. این فیلتر آبخاری باعث می‌شود پیوندهای پرهزینه با labevents و chartevents فقط روی کوچک‌ترین کوهورت لازم اجرا شوند.

۳.۳.۳ استخراج آزمایشگاه و علائم حیاتی

از ۱۵ itemid آزمایشگاهی و ۷ itemid علائم حیاتی از d_labitems و d_items در MIMIC-IV استفاده می‌شود. مقادیر از ۲۴ ساعت اول بستری ICU استخراج می‌شوند. هر اندازه‌گیری به بازه بالینی clip می‌شود (مثلاً کراتینین $[0.1, 30]$ mg/dL) تا پرت‌ها حذف شوند و سپس با min-max به بازه $[0,1]$ نرمال می‌شود:

$$x' = \frac{\text{clip}(x, x_{\min}, x_{\max}) - x_{\min}}{x_{\max} - x_{\min}} \quad (۱.۳)$$

جدول‌های ۳.۳ و ۴.۳ بازه‌های آزمایشگاهی و علائم حیاتی را فهرست می‌کنند.

جدول ۳.۳: بازه‌های آزمایشگاهی منتخب (۱۵ آزمایش)

واحد	آزمایش	شناسه	کمینه	بیشینه
mg/dL	کراتینین	50912	0.1	30
mEq/L	پتاسیم	50971	1.5	10
mEq/L	سدیم	50983	100	180
mg/dL	گلوکز	50931	20	600
g/dL	هموگلوبین	50811	3	25
mmol/L	لاکتات	50813	0.5	25
...	...	...	...	...

15 اندازه‌گیری آزمایشگاهی بر اساس ارتباط بالینی با پیش‌بینی ترخیص ICU و دسترسی در MIMIC-IV انتخاب شدند:

- پانل کلیوی: کراتینین، BUN (نیترژن اوره خون)، پتاسیم، سدیم، کلر، بی‌کربنات

جدول ۴.۳: بازه های علائم حیاتی منتخب (7 علامت حیاتی)

واحد	علامت حیاتی	شناسه کمینه	بیشینه
bpm	ضربان قلب	20	250
mmHg	فشار خون سیستولیک	40	250
%	SpO ₂	50	100
...	...	...	...

• **هماتولوژی:** هموگلوبین، پلاکت، شمارش گلبول سفید (WBC)

• **متابولیک:** گلوکز، لاکتات، آلبومین

• **کبدی:** ALT (آلانین آمینوترانسفراز)، بیلی روبین

• **انعقاد:** INR (نسبت نرمال شده بین المللی)

7 علامت حیاتی عبارت اند از: ضربان قلب، فشار خون سیستولیک، فشار خون دیاستولیک، فشار شریانی میانگین، دما، SpO₂ (اشباع اکسیژن)، و نرخ تنفس. وقتی چند اندازه گیری در پنجره 24-ساعته وجود دارد، از مقدار میانه برای کاهش حساسیت به جهش های گذرا یا آرتیفکت اندازه گیری استفاده می شود.

۴.۳.۳ مهندسی ویژگی

سه ویژگی مهندسی شده به 22 ویژگی پایه (15 آزمایشگاه + 7 علائم حیاتی) افزوده می شود:

۱. **شاخص شوک:** $SI = HR/SBP$ ، با بازه بالینی $[0.3, 2.0]$ به $[0, 1]$ نرمال می شود. شاخص

شوگ نشانگر اعتبار یافته ناپایداری همودینامیک است؛ مقادیری فراتر از 1.0 برای SI با افزایش

مرگ و میر و طولانی شدن بستری ICU همراه اند. به صورت رسمی:

$$SI_{\text{norm}} = \frac{\text{clip}(HR/SBP, 0.3, 2.0) - 0.3}{2.0 - 0.3} \quad (2.3)$$

۲. **جایگزین SOFA:** تقریب ساده شده نمره Sequential Organ Failure Assessment به صورت

زیر محاسبه می شود:

$$SOFA_{\text{proxy}} = \frac{1}{4} [(1 - x_{\text{creat}}) + (1 - x_{\text{plt}}) + (1 - x_{\text{SpO}_2}) + x_{\text{lactate}}] \quad (3.3)$$

که در آن هر x مقدار نرمال‌شده min-max است. مقادیر بالاتر جایگزین نشان‌دهنده عملکرد اندام بدتر است. این تقریب چهار از شش حوزه SOFA (کلیوی، انعقادی، تنفسی، قلبی-عروقی) را با داده آزمایشگاهی و علائم حیاتی موجود می‌گیرد. حوزه‌های عصبی (GCS) و کبدی (بیلی‌روبین) به دلیل فقدان داده حذف شده‌اند؛ بیلی‌روبین در دسترس است اما مستقل به مجموعه ویژگی خام کمک می‌کند.

۳. شمارش آزمایش‌های غیرطبیعی: کسر مقادیر آزمایشگاهی با انحراف شدید:

$$\text{AbnCount} = \frac{1}{15} \sum_{j=1}^{15} \mathbb{I}[|x_j - 0.5| > 0.35] \quad (4.3)$$

این تعداد آزمایش‌های خارج از 30% میانی بازه نرمال‌شده خود را می‌گیرد و انحراف کلی فیزیولوژیک را منعکس می‌کند. بیماری با 8 از 15 آزمایش غیرطبیعی از نظر بالینی بیمارتر از بیماری با 2 مورد غیرطبیعی است، صرف‌نظر از اینکه کدام آزمایش‌ها منحرف شده‌اند. مجموعه ویژگی جدولی نهایی 25 بعد دارد. جدول ۵.۳ همه ویژگی‌ها را دسته‌بندی می‌کند.

جدول ۵.۳: خلاصه بردار ویژگی 25-بعدی

دسته	ویژگی‌ها تعداد
پانل کلیوی	کراتینین، BUN، K^+ ، Na^+ ، Cl^- ، HCO_3^- ۶
هماتولوژی	هموگلوبین، پلاکت، WBC ۳
متابولیک	گلوکز، لاکتات، آلبومین ۳
کبدی	ALT، بیلی‌روبین ۲
انعقاد	INR ۱
علائم حیاتی	HR، SBP، DBP، MAP، دما، SpO_2 ، RR ۷
مهندسی‌شده شاخص شوک، جایگزین SOFA، شمار غیرطبیعی	۳
جمع	۲۵

۵.۳.۳ راهبرد داده گمشده

داده‌های بالینی ذاتاً ناقص‌اند. راهبرد جایگزینی ما سلسله‌مراتب محافظه‌کارانه‌ای را دنبال می‌کند:

۱. پرکردن رو به جلو درون بیماری: اگر مقدار آزمایش در ساعت 2 و 18 اندازه گرفته شده

باشد، پرس و جو در ساعت 12 از مقدار ساعت 2 استفاده می کند (بدون پر کردن معکوس برای جلوگیری از نشت اطلاعات).

۲. **تجميع میانه‌ای:** برای خلاصه 24 ساعت اول، میانه همه اندازه گیری های موجود در پنجره گرفته می شود. میانه نسبت به پرت های ناشی از آرتیفکت اندازه گیری مقاوم است.

۳. **جایگزینی با میانه جمعیت:** اگر در 24 ساعت اندازه گیری برای ویژگی ای موجود نباشد، میانه جمعیت (فقط روی مجموعه آموزش محاسبه شده برای جلوگیری از نشت داده) جایگزین می شود.

۴. **شاخص فقدان:** در بردار ویژگی 25-بعدی شاخص صریح فقدان استفاده نمی شود، اما ویژگی شمار آزمایش غیرطبیعی به صورت ضمنی اطلاعاتی درباره ویژگی هایی با مقادیر شدیداً منحرف می گیرد.

نرخ فقدان در کوهورت ما: آزمایش های روتین (کراتینین، سدیم، پتاسیم) 5%-12؛ آزمایش های تخصصی (لاکتات، آلبومین، INR) 18%-35؛ علائم حیاتی 2%-8. ویژگی هایی با بیش از 50% فقدان در مرحله انتخاب ویژگی حذف شدند؛ همه 22 ویژگی نگه داشته شده حداکثر 35% فقدان دارند.

۶.۳.۳ تقسیم داده

از تقسیم های ثابت آموزش/اعتبارسنجی/آزمون با بذر 42 استفاده می شود:

- 80% آموزش+اعتبارسنجی، 20% آزمون (لایه بندی شده بر اساس برچسب).
- از 80%، 80% آموزش و 20% اعتبارسنجی.
- نهایی: 64% آموزش (۱,۲۸۰ بیمار)، 16% اعتبارسنجی (۳۲۰ بیمار)، 20% آزمون (۴۰۰ بیمار).

هیچ داده آزمونی برای انتخاب مدل یا تنظیم ابرپارامتر استفاده نمی شود. همه تصمیم ها روی مجموعه اعتبارسنجی اعتبار می یابند و روی مجموعه آزمون گزارش می شوند. لایه بندی تضمین می کند نرخ امکان پذیری (تقریباً 42% قابل تحقق) در همه تقسیم ها حفظ شود. برای آزمایش های فدرال، مجموعه آموزش بیشتر بر اساس گره بیماری افزای می شود و هر گره سهم متناسب از داده آموزش دریافت می کند.

۴.۳ توکن‌سازی علائم

۱.۴.۳ ساختار توکن

هر بیمار به‌صورت دنباله‌ای حداکثر 25 توکن بازنمایی می‌شود. هر توکن چهار جزء دارد:

$$\text{token} = [\text{symptom_id}, \text{intensity}, \text{time_delta}, \text{modality}] \quad (۵.۳)$$

که در آن:

- **symptom_id**: 1-15 برای آزمایشگاه‌ها، 16-22 برای علائم حیاتی، 0 برای MASK (پدینگ).
- **intensity**: مقدار نرمال‌شده در $[0, 1]$.
- **time_delta**: جابجایی زمانی نرمال‌شده (0 برای تجمیع 24 ساعت اول).
- **modality**: 0 برای آزمایشگاه، 1 برای علائم حیاتی.

۲.۴.۳ ساخت دنباله

برای هر بیمار، همه اندازه‌گیری‌های غیرگمشده جمع‌آوری، بر اساس symptom_id مرتب، و با توکن‌های MASK به طول 25 پد می‌شوند. این دنباله با طول ثابت برای رمزگذارهای transformer مناسب است.

۳.۴.۳ ارتباط با ویژگی‌های جدولی

بازنمایی جدولی (25 ویژگی) نسخه مسطح و تجمیع‌شده دنباله توکن است. هر دو از همان مقادیر نرمال‌شده زیرین استفاده می‌کنند. مدل‌های جدولی بردار 25-بعدی را دریافت می‌کنند؛ ETHOS دنباله توکن را دریافت می‌کند.

۵.۳ معماری رمزگذار ETHOS

۱.۵.۳ نمای کلی

ETHOS [Sharafi and Aminian, 2023] یک رمزگذار transformer است که دنباله‌های توکن را به جاسازی‌های با اندازه ثابت نگاشت می‌کند. شامل موارد زیر است:

- لایه جاسازی: (symptom_id, intensity, time_delta, modality) را به بردارهای d -بعدی نگاشت می‌کند.
- کدگذاری موقعیتی: سینوسی یا آموخته‌شده.
- L لایه transformer: خودتوجه چندسر + پیش‌خوران.
- تجمیع: میانگین روی دنباله (به جز MASK) یا توکن به‌سبک [CLS].

۲.۵.۳ پیکربندی

از config.yaml:

$$d_{\text{model}} = 128$$

$$n_{\text{head}} = 8$$

$$n_{\text{layers}} = 2$$

$$d_{\text{ff}} = 512$$

$$\text{dropout} = 0.2$$

$$\text{vocab_size} = 23 \text{ (22 علامت + MASK 1)}$$

۳.۵.۳ خروجی

رمزگذار برای هر بیمار یک جاسازی 128-بعدی تولید می‌کند. این جاسازی توسط سر نمونه اولیه‌ای برای طبقه‌بندی چندنمونه‌ای استفاده می‌شود.

۴.۵.۳ جزئیات مکانیزم توجه

خودتوجه چندسر به‌صورت زیر محاسبه می‌شود:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (۶.۳)$$

که در آن Q, K, V تصویرهای خطی ورودی‌اند. 8 سر با $d_k = d_{\text{model}}/8 = 16$ استفاده می‌شود. لایه پیش‌خوران یک MLP دولایه با ReLU و بعد 512 اعمال می‌کند. اتصالات باقیمانده و نرمال‌سازی لایه آموزش را پایدار می‌کنند.

۶.۳ پیش‌بینی درمان چندنمونه‌ای

۱.۶.۳ پروتکل اپیزودیک

هر اپیزود نمونه‌برداری می‌کند:

- K نمونه پشتیبان به‌ازای هر کلاس (پیش‌فرض $K = 5$).
 - Q نمونه پرس‌وجو به‌ازای هر کلاس (پیش‌فرض $Q = 15$).
 - 2 کلاس: قابل تحقق (1) و غیرقابل تحقق (0).
- جمع: $2K$ پشتیبان، $2Q$ پرس‌وجو در هر اپیزود.

۲.۶.۳ سر نمونه اولیه‌ای

برای مجموعه پشتیبان S_k کلاس k :

$$\mathbf{c}_k = \frac{1}{K} \sum_{(x_i, y_i) \in S_k} f_{\theta}(x_i) \quad (۷.۳)$$

برای پرس‌وجو x ، لگاریتم‌های شانس:

$$z_k = \frac{\langle f_{\theta}(x), \mathbf{c}_k \rangle}{\|f_{\theta}(x)\| \|\mathbf{c}_k\|} \cdot \tau \quad (۸.۳)$$

که در آن $\tau = 10$ دماست. احتمالات: $\text{softmax}(z)$.

۳.۶.۳ تابع هزینه

از focal loss برای مدیریت نامتعادلی کلاس استفاده می‌شود:

$$\mathcal{L} = -\alpha(1-p)^\gamma \log p \quad (۹.۳)$$

با $\gamma = 2$ و α از وزن‌های کلاس. آنتروپی متقاطع حالت ویژه $\gamma = 0$ است.

۴.۶.۳ تصویر فضای متریک

برای بهبود توان تفکیک فضای جاسازی، یک MLP تصویر اختیاری بین خروجی رمزگذار و محاسبه نمونه اولیه‌ای بررسی می‌شود:

$$g_\phi(\mathbf{h}) = W_2 \cdot \text{GELU}(\text{BN}(W_1 \cdot \mathbf{h} + b_1)) + b_2 \quad (۱۰.۳)$$

که در آن $W_2 \in \mathbb{R}^{d_p \times d_h}$ ، $W_1 \in \mathbb{R}^{d_h \times d}$ با $d_p = 64$ ، $d_h = 256$ ، $d = 128$ BatchNorm و dropout (0.2) پس از لایه اول اعمال می‌شوند. تصویر بعد جاسازی را از 128 به 64 کاهش می‌دهد و فضای متریک فشرده‌ای برای محاسبه فاصله نمونه اولیه‌ای بهینه می‌سازد. پارامتر دما τ با $\tau = \exp(\log \tau_0)$ قابل آموختن می‌شود تا مدل تیزی توزیع احتمال را تطبیقی کنترل کند.

۵.۶.۳ آموزش

تا ۱,۵۰۰ اپیزود آموزش، صبر زودتوقف 10. بهینه‌ساز: AdamW با وزن‌زدایی 10^{-4} و زمان‌بندی نرخ یادگیری کسینوسی (از 10^{-3} تا 10^{-5}). رمزگذار و سر نرخ‌های یادگیری متفاوت دارند (رمزگذار: 10^{-4} ، سر: 10^{-3}) تا بازنمایی‌های ازپیش‌آموزش دیده حفظ شود درحالی که سر طبقه‌بندی تطبیق می‌یابد. برش گرادیان (حداکثر نرم 1.0) ناپایدگی آموزش را مهار می‌کند. اعتبارسنجی: 100 اپیزود.

۷.۳ سر شبکه رابطه (جایگزین)

به عنوان جایگزین سر نمونه اولیه‌ای، سر شبکه رابطه [Sung et al., 2018] پیاده‌سازی می‌شود که شباهت کسینوسی ثابت را با مازول رابطه آموخته شده جایگزین می‌کند. با جاسازی پرس و جو $\mathbf{q} = f_\theta(x)$ و نمونه اولیه کلاس $\mathbf{c}_k$ ، نمره رابطه توسط MLP دولایه محاسبه می‌شود:

$$\mathbf{h} = \text{ReLU}(W_1[\mathbf{q}; \mathbf{c}_k; \mathbf{q} \odot \mathbf{c}_k; |\mathbf{q} - \mathbf{c}_k|] + b_1) \in \mathbb{R}^{256} \quad (۱۱.۳)$$

$$r_k = \sigma(W_2\mathbf{h} + b_2) \in [0, 1] \quad (۱۲.۳)$$

که در آن ورودی چهار ویژگی تعامل را به هم می‌چسباند: جاسازی‌های خام $2 \times 128 = 256$ (بعد)، حاصل ضرب درایه‌ای (128 بعد)، و قدر مطلق تفاوت (128 بعد)، که ورودی 640-بعدی به مازول رابطه می‌دهد. هزینه میانگین مربعات خطاست:

$$\mathcal{L}_{\text{relation}} = \frac{1}{|\mathcal{Q}|} \sum_{(x,y) \in \mathcal{Q}} \sum_{k=0}^1 (r_k(x) - \mathbb{I}[y = k])^2 \quad (۱۳.۳)$$

الگوریتم ۲ رویه آموزش شبکه رابطه اپیزودیک را شرح می‌دهد.

Algorithm 2 Episodic training of the relation network

Require: Encoder f_θ , relation module g_ϕ , support shots K , query shots Q

```

1: for each episode do
2:   Sample  $\mathcal{S}_0, \mathcal{S}_1$  ( $K$  per class),  $\mathcal{Q}_0, \mathcal{Q}_1$  ( $Q$  per class)
3:    $\mathbf{c}_k \leftarrow \frac{1}{K} \sum_{x \in \mathcal{S}_k} f_\theta(x)$  for  $k \in \{0, 1\}$ 
4:    $\mathcal{L} \leftarrow 0$ 
5:   for each  $(x, y) \in \mathcal{Q}_0 \cup \mathcal{Q}_1$  do
6:      $\mathbf{q} \leftarrow f_\theta(x)$ 
7:     for  $k \in \{0, 1\}$  do
8:        $r_k \leftarrow g_\phi(\mathbf{q}, \mathbf{c}_k)$ 
9:        $\mathcal{L} \leftarrow \mathcal{L} + (r_k - \mathbb{I}[y = k])^2$ 
10:    end for
11:  end for
12:  Update  $\theta, \phi$  via backpropagation on  $\mathcal{L}$ 
13: end for
14: return  $\theta, \phi$ 
```

شبکه رابطه تقریباً 0.2 مگاپارامتر، برای MLP رابطه، به 1.8 مگاپارامتر رمزگذار می‌افزاید. در

آزمایش حذف‌بخشی، سر رابطه AUROC قابل مقایسه‌ای با سر نمونه اولیه‌ای به‌دست آورد؛ اختلاف در حدود 0.01 بود. این نتیجه نشان می‌دهد برای این وظیفه دودویی، متریک کسینوسی ثابت تا حد زیادی کافی است و گلوگاه اصلی بیشتر در بازنمایی‌های رمزگذار قرار دارد، نه در تابع شباهت.

۸.۳ آموزش فدرال

۱.۸.۳ افراز گره

داده‌ها بر اساس تشخیص اولیه ICD-10 به 5 گره بیماری افراز می‌شوند و چندموسسه‌ای را شبیه‌سازی می‌کنند که هر «موسسه» در حوزه‌ای از بیماری تخصص دارد. جدول ۶.۳ جزئیات افراز را می‌آورد.

جدول ۶.۳: افراز گره فدرال (مجموعه آموزش)

گره بیماری	کدهای ICD-10	n (آموزش)	درصد قابل تحقق
۱ سپسیس	A40, A41, R652	≈ 264	۳۸٪
۲ قلبی	I21, I22, I25, I50, I47-49	≈ 255	۴۵٪
۳ تنفسی	J18, J44, J96, J80, J15	≈ 228	۴۱٪
۴ کلیوی	N17, N18, N19	≈ 267	۳۹٪
۵ دیابت	E10, E11, E13	≈ 266	۴۶٪

ماهیت غیر-IID آشکار است: اندازه گره‌ها متفاوت است (228-267 بیمار)، و نرخ‌های امکان‌پذیری بین گره‌ها (38%-46٪) فرق دارد. این ناهمگونی می‌آزماید آیا تجمیع فدرال می‌تواند مدلی سراسری بیاموزد که بر توزیع‌های بیماری‌محور تعمیم یابد.

۲.۸.۳ پروتکل FedAvg

پروتکل استاندارد میانگین‌گیری فدرال (FedAvg) [McMahan et al., 2017] با پیکربندی زیر پیاده‌سازی می‌شود:

- دورهای ارتباطی: $T = 20$ AUROC اعتبارسنجی تا دور 15-20 اشباع می‌شود.
- دوره‌های محلی: $E = 3$ در هر دور. هر گره پیش از ارسال به‌روزرسانی‌ها 3 گذر کامل روی داده محلی آموزش می‌بیند.
- اندازه دسته محلی: 32.

- وزن‌های تجميع: متناسب با اندازهٔ مجموعه دادهٔ محلی: $w_k = n_k / \sum_j n_j$.
 - نرخ یادگیری: همانند متمرکز (10^{-3} برای سر، 10^{-4} برای رمزگذار).
 - انتخاب کلاینت: مشارکت کامل (همهٔ ۵ گره در هر دور شرکت می‌کنند).
- گام تجميع سرور میانگین وزنی همهٔ پارامترهای مدل را محاسبه می‌کند:

$$\theta_{t+1} = \sum_{k=1}^5 \frac{n_k}{\sum_j n_j} \theta_t^{(k)} \quad (۱۴.۳)$$

برای معماری ما، مدل کامل (≈ 2 مگاپارامتر) هر دور ارسال می‌شود. هزینهٔ ارتباطی کل: $5 \text{ nodes} \times 20 \text{ rounds} \times 2 \text{ directions} \times 8 \text{ MB} \approx 1.6 \text{ GB}$ است.

۳.۸.۳ پارامترهای مشترک در برابر محلی

رمزگذار ETHOS بین گره‌ها مشترک است و همهٔ گره‌ها از بازنمایی سراسری بهره می‌برند. سر نمونهٔ اولیه‌ای نیز مشترک است؛ سرهای محلی به دلیل ناکافی بودن دادهٔ محلی برای تخصص سر، عملکرد را ۱-۲٪ AUROC کاهش می‌دهند. هر گره گرادیان روی دادهٔ محلی محاسبه و مدل به‌روزشدهٔ کامل را به سرور می‌فرستد.

۴.۸.۳ پایش همگرایی

همگرایی با ردیابی AUROC اعتبارسنجی سراسری پس از هر دور پایش می‌شود. معیار همگرایی: بدون بهبود در AUROC اعتبارسنجی برای ۵ دور متوالی. در عمل، همگرایی برای بیشتر پیکربندی‌های ابرپارامتر تا دور ۱۵-۱۸ رخ می‌دهد. $T = 20$ به عنوان کران بالای محافظه کارانه تنظیم شده است.

۹.۳ معماری ترکیبی: ETHOS_RF_Hybrid

با انگیزه از مشاهدهٔ اینکه جاسازی‌های ETHOS سیگنال مکمل نسبت به ویژگی‌های جدولی مهندسی شده می‌گیرند، معماری ترکیبی طراحی می‌شود. برای هر بیمار i :

$$\mathbf{x}_{\text{hybrid}}^{(i)} = [\mathbf{e}_{\text{ETHOS}}^{(i)}; \mathbf{x}_{\text{tab}}^{(i)}] \in \mathbb{R}^{153} \quad (۱۵.۳)$$

که در آن $\mathbf{e}_{\text{ETHOS}} \in \mathbb{R}^{128}$ جاسازی ETHOS CLS و $\mathbf{x}_{\text{tab}} \in \mathbb{R}^{25}$ بردار ویژگی جدولی مهندسی شده است. طبقه بند Random Forest با RandomizedSearchCV (50 آزمایش، اعتبارسنجی متقاطع لایه بندی شده 5-تایی) روی بازنمایی به هم چسبانده شده آموزش داده می شود. تنظیم آستانه روی مجموعه اعتبارسنجی F1 را بیشینه می کند. این معماری ظرفیت یادگیری بازنمایی transformer را با طبقه بندی مقاوم روش های گروهی مبتنی بر گرادیان ترکیب می کند و گلوگاه بازنمایی شناسایی شده در مطالعه حذف بخشی را پوشش می دهد.

همچنین RF تنها روی جاسازی های ETHOS (128-بعدی) ارزیابی می شود تا سهم بازنمایی های آموزش دیده از ویژگی های مهندسی شده جدا شود.

۱۰.۳ پروتکل ارزیابی

۱.۱۰.۳ معیارها

چند معیار برای پوشش جنبه های مختلف عملکرد گزارش می شود. هر معیار رسماً در ادامه تعریف می شود.

۱.۱.۱۰.۳ AUROC (مساحت زیر منحنی مشخصه عملیاتی گیرنده)

معیار ارزیابی اصلی. برای طبقه بند دودویی با تابع نمره $s(x)$ ، منحنی ROC نرخ مثبت درست (TPR، حساسیت) را در برابر نرخ مثبت نادرست (FPR، 1 منهای اختصاصیت) با تغییر آستانه تصمیم رسم می کند:

$$\text{AUROC} = \int_0^1 \text{TPR}(t) d(\text{FPR}(t)) = P(s(x^+) > s(x^-)) \quad (16.3)$$

که در آن x^+ نمونه مثبت و x^- نمونه منفی به صورت تصادفی انتخاب شده اند. AUROC نسبت به آستانه نامتغیر و نسبت به نامتعادلی کلاس مقاوم است. AUROC با قاعده دوزنقه ای (`sklearn.metrics.roc_auc_score`) محاسبه می شود. مقادیر: 0.5 تصادفی؛ 0.7-0.8 قابل قبول برای پشتیبانی تصمیم بالینی؛ 0.8-0.9 خوب؛ ارقامی بالای 0.9 عالی. بهترین مدل ما (0.76 AUROC) در بازه قابل قبول قرار دارد.

۲.۱.۱۰.۳ دقت، فراخوانی، و نمره F1

برای کلاس k با مثبت درست (TP)، مثبت نادرست (FP)، و منفی نادرست (FN):

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k} \quad (۱۷.۳)$$

$$\text{Recall}_k = \frac{TP_k}{TP_k + FN_k} \quad (۱۸.۳)$$

$$F1_k = \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} = \frac{2TP_k}{2TP_k + FP_k + FN_k} \quad (۱۹.۳)$$

از **F1-macro**، میانگین بدون وزن نمره‌های F1 به‌ازای هر کلاس، برای جلوگیری از تسلط کلاس اکثریت استفاده می‌شود:

$$\text{F1-macro} = \frac{1}{N} \sum_{k=1}^N F1_k = \frac{F1_0 + F1_1}{2} \quad (۲۰.۳)$$

۳.۱.۱۰.۳ ضریب همبستگی متیوز (MCC)

MCC معیاری متعادل برای طبقه‌بندی دودویی فراهم می‌کند و هر چهار خانه ماتریس سردرگمی را در نظر می‌گیرد:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (۲۱.۳)$$

MCC از -1 (طبقه‌بندی کاملاً اشتباه) از طریق 0 (پیش‌بینی تصادفی) تا $+1$ (طبقه‌بندی کامل) متغیر است. برخلاف دقت، MCC حتی با کلاس‌های بسیار نامتعادل معنادار است. مدلی که همیشه کلاس اکثریت را پیش‌بینی کند دقت $0.58 \approx$ ولی MCC $0 =$ دارد.

۴.۱.۱۰.۳ دقت (Accuracy)

دقت طبقه‌بندی استاندارد:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (۲۲.۳)$$

دقت برای کامل بودن گزارش می‌شود اما به‌عنوان معیار اصلی به‌دلیل نامتعادلی کلاس (42% قابل تحقق) استفاده نمی‌شود.

۵.۱.۱۰.۳ نمره Brier

برای ارزیابی کالیبراسیون احتمالی:

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2 \quad (23.3)$$

که در آن p_i احتمال پیش‌بینی شده و $y_i \in \{0, 1\}$ برچسب درست است. کمتر بهتر است؛ 0.25 متناظر با پیش‌بیننده ثابت در 0.5 است.

۶.۱.۱۰.۳ معناداری آماری

معناداری با دو رویکرد ارزیابی می‌شود:

۱. **فواصل اطمینان bootstrap**: مجموعه آزمون با جایگزینی ۱,۰۰۰ بار نمونه‌برداری مجدد، معیار برای هر نمونه محاسبه، و صدک‌های 2.5-97.5 به‌عنوان فاصله اطمینان 95% گزارش می‌شود.

۲. **آزمون DeLong** [DeLong et al., 1988]: مقایسه دو منحنی ROC همبسته از مدل‌های ارزیابی شده روی همان مجموعه آزمون. فرض صفر برابری دو AUROC است. آماره آزمون و p -مقدار گزارش می‌شود.

۷.۱.۱۰.۳ پایداری (واریانس)

برای ارزیابی اپیزودیک چندنمونه‌ای، انحراف معیار AUROC در 100 اپیزود نمونه‌برداری شده گزارش می‌شود:

$$\text{Stability} = \sqrt{\frac{1}{M-1} \sum_{m=1}^M (\text{AUROC}_m - \overline{\text{AUROC}})^2} \quad (24.3)$$

که در آن $M = 100$ اپیزود است. واریانس کمتر عملکرد چندنمونه‌ای پایدارتر در ترکیب‌های تصادفی اپیزود را نشان می‌دهد.

۲.۱۰.۳ خط پایه‌ها

- رگرسیون لجستیک ($\text{class_weight=balanced}$).
 - Random Forest (تنظیم‌شده).
 - XGBoost (تنظیم‌شده).
 - LightGBM (تنظیم‌شده).
 - CatBoost (تنظیم‌شده).
 - شبکه عصبی استاندارد (بدون چندنمونه‌ای).
 - شبکه عصبی فدرال (بدون چندنمونه‌ای).
- همه پیش‌پردازش یکسان و همان تقسیم‌های آموزش/اعتبار/آزمون را دارند.

۳.۱۰.۳ تنظیم آستانه

برای طبقه‌بندی دودویی، آستانه تصمیم $\theta \in [0.3, 0.7]$ روی مجموعه اعتبارسنجی برای بیشینه کردن F1 تنظیم می‌شود. آستانه بهینه (0.54 برای Random Forest) روی مجموعه آزمون اعمال می‌شود. AUROC نسبت به آستانه نامتغیر است؛ F1 و دقت به θ وابسته‌اند.

۱۱.۳ جزئیات پیاده‌سازی

۱.۱۱.۳ بهینه‌سازی

برای ETHOS از Adam [Kingma and Ba, 2015] با نرخ یادگیری $\beta_1 = 0.001$ ، $\beta_2 = 0.999$ استفاده می‌شود. اندازه دسته برای آموزش اپیزودیک 32 است. dropout [Srivastava et al., 2014] (0.2) پس از لایه‌های توجه و پیش‌خوران اعمال می‌شود. نرمال‌سازی لایه [Ba et al., 2016] آموزش را پایدار می‌کند.

۲.۱۱.۳ منظم‌سازی

زودتوقف با نظارت بر هزینه اعتبارسنجی و صبر 10 دوره. گرادیان‌ها به حداکثر نرم 1.0 برش داده می‌شوند تا انفجار جلوگیری شود. وزن‌زدایی (L2) برای رمزگذار $10^{-5} \times 1$ است. وزن‌های کلاس نامتعادلی focal loss را برای توزیع برچسب 42/58 متعادل می‌کنند.

۳.۱۱.۳ بازتولیدپذیری

همه آزمایش‌ها با `random_seed=42` در NumPy, PyTorch, و scikit-learn دارند. تقسیم‌های داده ثابت و ذخیره می‌شوند؛ بدون برهم‌زدن بین اجراها. شبکه‌های ابرپارامتر در پیوست آ هستند.

۱۲.۳ شبه‌کد الگوریتم

۱.۱۲.۳ آموزش چندنمونه‌ای نمونه اولیه‌ای

الگوریتم ۳ رویه آموزش اپیزودیک را خلاصه می‌کند. هر اپیزود مجموعه پشتیبان $\mathcal{S}$ و مجموعه پرس‌وجو $\mathcal{Q}$ را نمونه‌برداری می‌کند؛ مدل نمونه‌های اولیه را از $\mathcal{S}$ محاسبه و آنتروپی متقاطع روی $\mathcal{Q}$ را کمینه می‌کند.

Algorithm 3 Episodic prototypical (protonet-style) training

Require: Encoder f_θ , support shots K , query shots Q , temperature τ

```

1: for each episode do
2:    $\mathcal{L} \leftarrow 0$ 
3:   Sample  $\mathcal{S}_0, \mathcal{S}_1$  ( $K$  examples per class)
4:   Sample  $\mathcal{Q}_0, \mathcal{Q}_1$  ( $Q$  examples per class)
5:    $\mathbf{c}_k \leftarrow \frac{1}{K} \sum_{x \in \mathcal{S}_k} f_\theta(x)$  for  $k \in \{0, 1\}$ 
6:   for each  $x \in \mathcal{Q}_0 \cup \mathcal{Q}_1$  do
7:      $z_k \leftarrow \langle f_\theta(x), \mathbf{c}_k \rangle / (\|f_\theta(x)\| \|\mathbf{c}_k\|) \cdot \tau$ 
8:      $\mathcal{L} \leftarrow \mathcal{L} + \text{CrossEntropy}(\text{softmax}(z), y)$ 
9:   end for
10:  Update  $\theta$  via backpropagation
11: end for
12: return  $\theta$ 
```

۲.۱۲.۳ میانگین‌گیری فدرال

الگوریتم ۴ پروتکل FedAvg را شرح می‌دهد. هر گره به مدت E دوره به‌صورت محلی آموزش می‌بیند، سپس سرور پارامترهای مدل را با وزن اندازه مجموعه داده محلی تجمیع می‌کند.

Algorithm 4 Federated averaging (FedAvg)**Require:** Nodes $\{1, \dots, N\}$, local data $\mathcal{D}_k$, rounds T

```

1: Initialize global model  $\theta_0$ 
2: for round  $t = 1$  to  $T$  do
3:   Server broadcasts  $\theta_t$  to all nodes
4:   for each node  $k$  do
5:      $\theta_t^{(k)} \leftarrow \theta_t$ 
6:     for epoch  $e = 1$  to  $E$  do
7:        $\theta_t^{(k)} \leftarrow \theta_t^{(k)} - \eta \nabla \mathcal{L}_k(\theta_t^{(k)})$ 
8:     end for
9:     Send  $\theta_t^{(k)}$  to server
10:  end for
11:   $\theta_{t+1} \leftarrow \sum_k \frac{n_k}{n} \theta_t^{(k)}$ 
12: end for
13: return  $\theta_T$ 

```

۳.۱۲.۳ یادداشت درباره محیط الگوریتم

شبه‌کد به صورت انگلیسی و با ارقام لاتین (محیط latin) حروف چینی می‌شود تا با متن فارسی اطراف تداخل جهت و شکل ارقام نداشته باشد. از محیط‌های algorithm و algorithmic استفاده شده است.

۱۳.۳ پیچیدگی محاسباتی**۱.۱۳.۳ رمزگذار ETHOS**

برای طول دنباله $L = 25$ ، بعد جاسازی $d = 128$ و $L_{\text{layers}} = 2$ لایه transformer، رمزگذار در هر گذر رو به جلو پیچیدگی $\mathcal{O}(L^2 d + L d^2)$ دارد. با اندازه دسته 32 و 500 اپیزود در هر دوره، آموزش تقریباً 2-3 دقیقه در هر دوره روی CPU استاندارد طول می‌کشد. شتاب‌دهی GPU این زمان را به کمتر از 30 ثانیه در هر دوره کاهش می‌دهد.

۲.۱۳.۳ ارتباط فدرال

با 5 گره و 20 دور، 100 گام ارتباطی انجام می‌شود. هر گام مدل کامل (رمزگذار + سر) را منتقل می‌کند؛ برای معماری ما این ≈ 2 مگابایت است. در استقرار واقعی، فشرده‌سازی گرادینان یا به‌روزرسانی‌های جزئی می‌تواند پهنای باند را کاهش دهد.

۳.۱۳.۳ جایگزین‌های توکن‌سازی

طرح‌های توکن‌سازی جایگزین در نظر گرفته شدند: (۱) جاسازی‌های پیوسته: استفاده از مقادیر نرمال‌شده خام به‌عنوان جاسازی توکن پیوسته به‌جای بازه‌های گسسته؛ از شناسه‌های گسسته برای سازگاری با واژگان استاندارد transformer استفاده می‌شود. (۲) توکن‌های سلسله‌مراتبی: کدگذاری دسته آزمایش (مثلاً کلیوی، قلبی) به‌عنوان توکن والد؛ ساختار مسطح برای سادگی به‌کار می‌رود. (۳) بازه زمانی: تجمیع در پنجره‌های 6 یا 12 ساعته؛ تجمیع 24 ساعت اول استفاده می‌شود. کار آینده می‌تواند این جایگزین‌ها را بررسی کند.

۴.۱۳.۳ خط پایه‌های کلاسیک

Random Forest با 200 درخت و عمق 28 در کمتر از 1 دقیقه روی کوهورت ۲,۰۰۰ بیمار آموزش می‌بیند. XGBoost و LightGBM نیز زمان مشابهی دارند. جستجوی ابرپارامتر، با ۵۰ پیکربندی و اعتبارسنجی متقاطع ۵ دوره برای هر مدل، حدود ۱۰ تا ۲۰ دقیقه به زمان اجرا می‌افزاید. کل فرایند SOTA جدولی در کمتر از 2 ساعت کامل می‌شود.

۱۴.۳ استنتاج‌های ریاضی

۱.۱۴.۳ گرادیان هزینه نمونه اولیه‌ای

برای شبکه‌های نمونه اولیه‌ای با هزینه آنتروپی متقاطع، گرادیان هزینه نسبت به جاسازی پرس‌وجو $f_{\theta}(x)$ به صورت زیر استنتاج می‌شود. با $p_k = \exp(z_k) / \sum_{k'} \exp(z_{k'})$ که در آن $z_k = \langle f_{\theta}(x), \mathbf{c}_k \rangle / \tau$ برای کلاس درست y :

$$\frac{\partial \mathcal{L}}{\partial f_{\theta}(x)} = \frac{1}{\tau} \sum_k (p_k - \mathbb{1}[y = k]) \mathbf{c}_k \quad (۲۵.۳)$$

گرادیان جاسازی پرس‌وجو را به سمت نمونه اولیه درست و دور از نمونه اولیه نادرست هل می‌دهد، با بزرگی متناسب با τ .

۲.۱۴.۳ Focal Loss

هزینه کانونی [Lin et al., 2017] برابر است با $\mathcal{L}_{\text{focal}} = -\alpha(1 - p_t)^\gamma \log(p_t)$ که در آن p_t احتمال پیش‌بینی شده برای کلاس درست است. برای $\gamma = 0$ این به آنتروپی متقاطع کاهش می‌یابد. برای $\gamma > 0$ ، نمونه‌های آسان (p_t بالا) با $(1 - p_t)^\gamma$ کم‌وزن می‌شوند و هزینه روی نمونه‌های سخت متمرکز می‌شود. از $\gamma = 2$ و α از وزن‌های کلاس برای نامتعادلی 42/58 استفاده می‌شود.

۳.۱۴.۳ فواصل اطمینان bootstrap

برای فواصل اطمینان bootstrap، مجموعه‌ی آزمون با جایگزینی ۱,۰۰۰ بار نمونه‌برداری مجدد می‌شود، AUROC برای هر نمونه محاسبه، و صدک‌های 2.5 و 97.5 به عنوان فاصله اطمینان 95% گرفته می‌شود. مجموعه‌ی آزمون 400 نمونه فواصل به عرض $\approx 0.10-0.12$ برای AUROC می‌دهد. آزمون DeLong دو منحنی ROC همبسته را مقایسه می‌کند؛ $p < 0.01$ برای RF در برابر ETHOS گزارش می‌شود که تفاوت آماری معنادار را نشان می‌دهد.

۴.۱۴.۳ استنتاج جایگزین SOFA و شاخص شوک

نمره SOFA (Sequential Organ Failure Assessment) اختلال اندام را کمی می‌کند. از جایگزین ساده‌شده استفاده می‌شود: $\text{SOFA}_{\text{proxy}} = w_1(1 - \text{creatinine}) + w_2(1 - \text{platelets}) + w_3(1 - \text{SpO}_2) + w_4(1 - \text{lactate})$ با وزن‌های برابر، هر جزء نرمال‌شده به $[0, 1]$. مقادیر بالاتر عملکرد بدتر را نشان می‌دهد. شاخص شوک = ضربان قلب / فشار خون سیستولیک؛ بازه طبیعی 0.5-0.7؛ مقادیری برای SI فراتر از 1.0 ناپایداری همودینامیک را نشان می‌دهند. با clip و min-max به $[0, 1]$ نرمال می‌شود. شاخص شوک بالا با ترخیص غیرقابل تحقق همراه است.

۱۵.۳ نمای کلی معماری نرم‌افزار

معماری نرم‌افزار به پنج لایه تقسیم شده است: (۱) لایه داده: استخراج MIMIC-IV با SQL، پیش‌پردازش، نرمال‌سازی، جایگزینی مقادیر گم‌شده و ساخت تقسیم‌های آموزش/اعتبار/آزمون؛ (۲) لایه بازنمایی: ساخت بردار ویژگی جدولی، از ۲۵ بعد پایه تا ۹۲ یا ۱۳۲ بعد با مهندسی ویژگی، و نیز تولید دنباله‌های توکن برای هر بیمار؛ (۳) لایه مدل: مدل‌های کلاسیک مانند sklearn RF و

XGBoost، رمزگذار ETHOS، سر نمونه اولیه‌ای و مدل‌های ترکیبی؛ (۴) لایه آموزش: نمونه‌گیر اپیزودیک برای چندنمونه‌ای و FedAvg برای فدرال؛ و (۵) لایه ارزیابی: معیارهایی مانند AUROC و F1، تفسیرپذیری با SHAP، کالیبراسیون و پیش‌بینی مطابق. پایگاه کد ماژولار است و هر جزء را می‌توان مستقل از اجزای دیگر جایگزین یا گسترش داد.

۱۶.۳ معماری V5: توجه ویژگی دروازه‌ای با نمونه‌های اولیه متقاطع

معماری V5 دو جزء تازه برای پوشش محدودیت‌های شناسایی شده در V1–V4 معرفی می‌کند:

۱.۱۶.۳ توجه ویژگی دروازه‌ای (GFA)

با الهام از TabNet [Arik and Pfister, 2021]، ماژول GFA انتخاب ویژگی متوالی به‌ازای هر نمونه را پیاده می‌کند. در هر یک از $S = 3$ گام توجه، ماژول محاسبه می‌کند:

$$\mathbf{a}_s = \text{softmax}(\mathbf{W}_s \cdot \mathbf{h}_{\text{shared}} \odot \mathbf{p}_s) \quad (26.3)$$

$$\mathbf{p}_{s+1} = \mathbf{p}_s \cdot (\gamma - \mathbf{a}_s) \quad (27.3)$$

$$\mathbf{o}_s = \text{FC}_s(\mathbf{a}_s \odot \mathbf{x}) \quad (28.3)$$

که در آن $\mathbf{p}_s$ مقیاس پیشین (مقداردهی اولیه به 1)، $\gamma = 1.5$ ضریب تنک‌سازی، و $\mathbf{h}_{\text{shared}}$ $\text{FC}_{\text{shared}}(\mathbf{x})$ بافت مشترک است. خروجی تجمیع‌شده $\sum_s \mathbf{o}_s$ با مسیر موازی transformer از طریق دروازه آموخته‌شده ترکیب می‌شود: $\mathbf{z} = \sigma(g) \cdot \mathbf{z}_{\text{trans}} + (1 - \sigma(g)) \cdot \mathbf{z}_{\text{GFA}}$. طراحی دومسیره به مدل اجازه می‌دهد محلی انتخاب ویژگی (GFA) را با مدل‌سازی سراسری تعامل ویژگی (transformer) ترکیب کند و هم اهمیت سطح ویژگی و هم روابط متقاطع ویژگی را بگیرد.

۲.۱۶.۳ سر نمونه اولیه‌ای متقاطع

شبکه نمونه اولیه‌ای استاندارد شباهت کسینوسی بین جاسازی‌های پرس‌وجو و میانگین نمونه‌های اولیه کلاس را محاسبه می‌کند. سر متقاطع V5 در عوض از خودتوجه متقاطع چندسر استفاده می‌کند:

$$\mathbf{h}_{\text{cross}} = \text{MultiHead}(\mathbf{Q} = \mathbf{q}, \mathbf{K} = \mathbf{P}, \mathbf{V} = \mathbf{P}) + \mathbf{q} \quad (29.3)$$

که در آن $\mathbf{q}$ جاسازی پرس‌وجو (گسترش‌یافته روی کلاس‌ها) و $\mathbf{P}$ نمونه‌های اولیه کلاس‌اند. سپس MLP طبقه‌بند لگاریتم‌های شانس را از $[\mathbf{h}_{\text{cross}}; \mathbf{q}]$ تولید می‌کند، با ترکیب 50/50 با لگاریتم‌های شانس نمونه اولیه‌ای کسینوسی. این به مدل اجازه می‌دهد توابع شباهت غیرخطی و وابسته به بافت بیاموزد به‌جای تکیه صرف بر معیارهای فاصله.

۱۷.۳ معماری V6: گروه عمیق ناهمگن

آزمایش V6 بررسی می‌کند آیا تنوع معماری عملکرد گروه را بهبود می‌دهد. سه معماری رمزگذار متمایز ترکیب می‌شوند:

۱. **FT-Transformer**: بردارهای جاسازی آموخته‌شده به‌ازای هر ویژگی $(\mathbf{e}_j = \mathbf{W}_j x_j + \mathbf{b}_j)$

که از لایه‌های خودتوجه با تجمیع مبتنی بر توجه عبور می‌کنند.

۲. **GFA-Transformer**: معماری دومسیره V5 که توجه ویژگی دروازه‌ای را با transformer

ویژگی‌های گروه‌بندی شده ترکیب می‌کند.

۳. **MLP-Mixer**: معماری بدون توجه با MLP‌های درهم‌تنیده مخلوط کردن توکن (فضایی) و

مخلوط کردن کانال (ویژگی)، اقتباس شده از بینایی به داده جدولی.

هر معماری با یک سر چندنمونه‌ای عمومی، شامل نمونه اولیه‌ای و شبکه رابطه، ترکیب می‌شود و

با همان فرایند چندمرحله‌ای آموزش می‌بیند: SupCon، تقطیر دانش نظارت‌شده و آموزش اپیزودیک.

فرا یادگیرنده نهایی پیش‌بینی‌های XGBoost و رگرسیون لجستیک کالیبره‌شده را ترکیب می‌کند. V6

همچنین از پیش‌بینی مطابق تقسیم‌شده برای سنجش عدم قطعیت استفاده می‌کند.

۱۸.۳ معماری‌های جایگزین مورد بررسی

چند جایگزین پیش از تثبیت طرح فعلی در نظر گرفته شد. MAML به‌جای نمونه اولیه‌ای: MAML انعطاف‌پذیرتر اما پرهزینه محاسباتی است؛ نمونه اولیه‌ای برای کارایی به کار می‌رود. LSTM/RNN به‌جای transformer: RNN ها می‌توانند دنباله‌های زمانی را مدل کنند؛ transformer برای موازی‌سازی و توجه روی توکن‌ها استفاده می‌شود. فقط جدولی خام: هم بازنمایی جدولی و هم توکن پشتیبانی می‌شود؛ ترکیبی (ETHOS + جدولی) از هر کدام بهتر عمل می‌کند. K متفاوت: در تحلیل حساسیت $K \in \{1, 3, 5, 7, 10, 15, 20\}$ متغیر است؛ مدل اصلی $K = 5$ دارد. FedProx به‌جای FedAvg: FedProx جمله مجاورتی برای غیر-IID می‌افزاید؛ FedAvg به‌عنوان خط پایه و FedProx برای کار آینده باقی می‌ماند. این انتخاب‌ها برای بازتولیدپذیری و راهنمایی گسترش‌های آینده مستند شده‌اند.

۱۹.۳ پیاده‌سازی و بازتولیدپذیری

پیاده‌سازی از Python 3.10, PyTorch 2.x برای ETHOS, scikit-learn 1.3+ برای مدل‌های کلاسیک، و pandas 2.x برای پردازش داده استفاده می‌کند. پایگاه کد به ماژول‌ها تقسیم شده است: data/ برای استخراج و پیش‌پردازش، models/ برای ETHOS و خط پایه‌ها، training/ برای آموزش اپیزودیک و فدرال، evaluation/ برای معیارها و SHAP. همه بذرها تصادفی ثابت (42) در NumPy, PyTorch و scikit-learn هستند. تقسیم‌های داده روی دیسک ذخیره و در آزمایش‌ها به‌طور یکنواخت بارگذاری می‌شوند. شبکه‌های ابرپارامتر در پیوست آ هستند. فایل requirements.txt با نسخه‌های ثابت برای بازتولیدپذیری ارائه می‌شود. دسترسی به MIMIC-IV نیازمند احراز هویت PhysioNet (آموزش CITI، توافق استفاده از داده) است؛ اسکرپت‌های پیش‌پردازش فرض می‌کنند شمای استاندارد MIMIC-IV برقرار است.

۲۰.۳ فرایند داده و گام‌های پیش‌پردازش

فرایند داده شامل این گام‌هاست: (۱) استخراج: اجرای پرس‌وجوهای SQL روی icustays، labevents، chartevents، patients، admissions و diagnoses_icd در MIMIC-IV، با فیلترهایی مانند اولین بستری ICU، سن $18 \geq$ ، LOS $4 \geq$ ساعت و وجود

تشخیص اولیه ICD-10؛ (۲) لایه‌بندی: نمونه‌گیری ۲,۰۰۰ بستری بر اساس گروه تشخیص اولیه؛ (۳) استخراج آزمایشگاه: انتخاب ۱۵ نوع آزمایش از ۲۴ ساعت نخست، برش به بازه‌های بالینی و نرمال‌سازی min-max به $[0, 1]$ ؛ (۴) استخراج علائم حیاتی: انتخاب ۷ علامت و اعمال همان نرمال‌سازی؛ (۵) مهندسی ویژگی: ساخت شاخص شوک، جایگزین SOFA و شمار آزمایش‌های غیرطبیعی؛ (۶) توکن‌سازی: تبدیل داده به دنباله توکن برای ETHOS؛ و (۷) تقسیم: ۶۴٪ آموزش، ۱۶٪ اعتبار و ۲۰٪ آزمون به‌صورت لایه‌بندی‌شده. همه گام‌ها با بذر 42 = قطعی شده‌اند.

۲۱.۳ جزئیات پروتکل ارزیابی

برای مدل‌های کلاسیک، برازش روی آموزش (۱,۲۸۰ نمونه)، تنظیم آستانه روی اعتبارسنجی (۳۲۰ نمونه)، و یک‌بار ارزیابی روی آزمون (۴۰۰ نمونه) انجام می‌شود. برای ETHOS+چندنمونه‌ای، آموزش اپیزودیک روی آموزش، اعتبارسنجی با ۱۰۰ اپیزود روی اعتبارسنجی، و ارزیابی روی آزمون داریم. ارزیابی آزمون برای ETHOS در این پایان‌نامه دو صورت دارد: (۱) ارزیابی ثابت روی کل مجموعه آزمون در Exp1 که برای Proposed_FewShot عدد منجمد ۰.۶۱۱ را گزارش می‌کند؛ (۲) نمونه‌برداری اپیزودیک (۱۰۰ اپیزود، هر کدام با K پشتیبان و Q پرس‌وجو از آزمون) که برای حساسیت K-shot به کار می‌رود و AUROC را در بازه ۰.۵۶۴-۰.۵۵۷ نشان می‌دهد. دو پروتکل مقادیر مطلق متفاوتی می‌دهند؛ بنابراین در هر آزمایش صریحاً مشخص می‌کنیم کدام پروتکل مبنا بوده است. برای ارزیابی فدرال، مدل سراسری تجمیع‌شده روی گره‌ها بر کل مجموعه آزمون اعمال می‌شود.

۲۲.۳ خلاصه فصل

این فصل روش‌شناسی پژوهش را شرح داد: نمادگذاری، نمای کلی فرایند، استخراج و پیش‌پردازش مجموعه داده، توکن‌سازی علائم، معماری رمزگذار ETHOS، پروتکل چندنمونه‌ای با سر نمونه اولیه‌ای، آموزش فدرال از طریق FedAvg، معیارهای ارزیابی، شبه کد الگوریتم‌ها، پیچیدگی محاسباتی، استنتاج‌های ریاضی، معماری نرم‌افزار، معماری‌های جایگزین، پیاده‌سازی، بازتولیدپذیری و جزئیات پروتکل ارزیابی. فصل بعدی طراحی آزمایش‌ها را ارائه می‌کند.

فصل ۴

آزمایش‌ها

این فصل چیدمان تجربی و طراحی آزمایش‌های ۱ تا ۵ را شرح می‌دهد.

۱.۴ چیدمان تجربی

۱.۱.۴ پیاده‌سازی و معماری نرم‌افزار

پیاده‌سازی آزمایش‌ها با ابزارها و کتابخانه‌های زیر انجام شده است:

- زبان و هسته: Python 3.10+.
- یادگیری عمیق: PyTorch برای رمزگذار ETHOS و آموزش few-shot.
- یادگیری ماشین کلاسیک: scikit-learn (Logistic Regression, Random Forest, معیارها), XGBoost, LightGBM, CatBoost.
- داده: NumPy, Pandas برای پیش‌پردازش و مهندسی ویژگی.
- فدرال: پیاده‌سازی سفارشی FedAvg (طراحی سازگار با PySyft برای گسترش آینده).
- تصویرسازی: Seaborn, Matplotlib برای منحنی‌های ROC و منحنی‌های یادگیری.

آزمایش‌ها روی ایستگاه کاری استاندارد با CPU چندهسته‌ای اجرا شدند. همه بذره‌ای تصادفی ثابت (seed=42) برای بازتولیدپذیری تنظیم شده‌اند. برای نیازمندی‌ها و جزئیات محیط، پیوست خ را ببینید.

۲.۱.۴ پیکربندی داده

- مجموعه داده: MIMIC-IV v3.1.
- اندازه کوهورت: ۲,۰۰۰ بیمار.
- تقسیم‌ها: ۶۴٪ آموزش (۱,۲۸۰)، ۱۶٪ اعتبارسنجی (۳۲۰)، ۲۰٪ آزمون (۴۰۰).
- گره‌های بیماری: ۵ (سپسیس، قلبی، تنفسی، کلیوی، دیابت).
- ویژگی‌ها: ۲۵ بعد (۲۲ پایه + ۳ مهندسی شده).

۳.۱.۴ پیکربندی FewShot+ETHOS

- $K = 5$ پشتیبان، $Q = 15$ پرس‌وجو به‌ازای هر کلاس.
- ۵۰۰ اپیزود آموزشی به‌ازای هر دوره، ۱۰۰ اپیزود اعتبارسنجی.
- ۵۰ دوره، صبر توقف زودهنگام ۱۰.
- دما $\tau = 10$ ، زیان کانونی $\gamma = 2$.
- نرخ یادگیری ۰.۰۰۱، بهینه‌ساز Adam.

۴.۱.۴ پیکربندی خط پایه کلاسیک

- RandomizedSearchCV با ۵۰-۸۰ آزمون (Random Forest, XGBoost)، ۵۰ آزمون (CatBoost, LightGBM).
- اعتبارسنجی متقاطع لایه‌ای ۵-تایی روی آموزش+اعتبارسنجی.
- امتیازدهی: AUROC.
- تنظیم آستانه روی اعتبارسنجی: $\theta \in [0.3, 0.7]$ ، گام ۰.۰۱، بیشینه‌سازی F1.

۲.۴ فرضیات آزمایش

هر آزمایش برای آزمون فرضیات مشخص طراحی شده است:

جدول ۱.۴: فرضیات آزمایش و پیامدهای مورد انتظار

پيامد مورد انتظار	Exp فرضيه
مقایسه AUROC بین مدل‌ها	1 few-shot می‌تواند خطوط پایه کلاسیک را جبران کند
افزایش AUROC با K	2 K بزرگ‌تر عملکرد few-shot را بهبود می‌دهد
شکاف کمتر از 2٪ AUROC	3 فدرال هزینه ناچیز در برابر متمرکز دارد
حذف، AUROC را به‌طور معنادار کاهش می‌دهد	4 وزن‌دهی شدت بحرانی است
$AUROC > 0.55$ روی گره‌های نگه‌داشته شده	5 مدل به گره‌های بیماری دیده‌نشده تعمیم می‌یابد

۳.۴ توان آماری و اندازه نمونه

با ۴۰۰ نمونه آزمون و تقسیم کلاس ۵۸/۴۲، تقریباً ۱۶۸ مثبت و ۲۳۲ منفی داریم. برای تشخیص اختلاف AUROC به میزان ۰.۱۰ (مثلاً ۰.۷۶ در برابر ۰.۶۶) با توان ۸۰٪ و $\alpha = 0.05$ ، آزمون DeLong تقریباً ۱۰۰-۲۰۰ نمونه به‌ازای هر گروه لازم دارد؛ مجموعه آزمون ما این شرط را برآورده می‌کند. بازه‌های اطمینان بوت‌استرپ (۱,۰۰۰ نمونه‌برداری مجدد) برآوردهای پایدار می‌دهند؛ برای معیارهای کلیدی بازه اطمینان ۹۵٪ گزارش می‌کنیم.

۴.۴ مشخصات سخت‌افزار و نرم‌افزار

آزمایش‌ها روی ایستگاه کاری استاندارد انجام شد: Intel Core i7 یا معادل، ۱۶ تا ۳۲ گیگابایت RAM، GPU انویدیا اختیاری (CUDA 11.x). زمان‌های آموزش: Random Forest حدود یک دقیقه؛ آموزش ETHOS با ۵۰ دوره حدود دو تا سه ساعت روی CPU یا حدود ۱۵ دقیقه با GPU. نرم‌افزار: Python 3.10، PyTorch 2.x، scikit-learn 1.3+، XGBoost 2.x، pandas 2.x. همه وابستگی‌ها در requirements.txt فهرست شده‌اند (پیوست خ).

۵.۴ فلسفه طراحی آزمایش

آزمایش‌ها به صورت سلسله‌مراتبی طراحی شده‌اند: (۱) ابتدا خطوط پایه قوی با ML کلاسیک ساخته می‌شوند؛ (۲) سپس رویکردهای عصبی و few-shot با آن‌ها مقایسه می‌شوند؛ (۳) با حذف تدریجی اجزا، سهم هر بخش بررسی می‌شود؛ و (۴) تعمیم فدرال و بین‌بیماری ارزیابی می‌گردد. بذره‌های تصادفی و تقسیم‌های داده ثابت نگه داشته شده‌اند تا بازتولیدپذیری حفظ شود. هر آزمایش با پیکربندی مشخص اجرا و برآورد نقطه‌ای آن گزارش می‌شود؛ بازه‌های اطمینان بوت‌استرپ و آزمون‌های آماری در فصل ۵ آمده‌اند.

۶.۴ رویه اجرای آزمایش

همه آزمایش‌ها از رویه استاندارد پیروی می‌کنند: (۱) بارگذاری داده پیش‌پردازش شده (تقسیم‌های آموزش/اعتبارسنجی/آزمون)؛ (۲) برای مدل‌های کلاسیک: برازش روی آموزش، تنظیم آستانه روی اعتبارسنجی، ارزیابی روی آزمون؛ (۳) برای FewShot+ETHOS: آموزش اپیزودیک روی آموزش، اپیزودهای اعتبارسنجی روی اعتبارسنجی، ارزیابی روی آزمون؛ (۴) برای فدرال: پارتیشن بر اساس گره بیماری، اجرای FedAvg برای ۲۰ دور، ارزیابی مدل سراسری روی آزمون؛ (۵) ثبت معیارها (AUROC، F1، و غیره) و ذخیره مدل‌ها. از داده آزمون برای انتخاب مدل استفاده نمی‌شود. همه آزمایش‌ها از همان تقسیم‌های ثابت (seed=42) استفاده می‌کنند.

۷.۴ پیکربندی‌های مدل خط پایه

پیکربندی تفصیلی برای هر خط پایه ارائه می‌شود؛ مقادیر فنی برای جلوگیری از شکستن جهت متن و برش حاشیه در یک بلوک لاتین چپ‌به‌راست دست‌نخورده می‌آید (با قلم monospace). شماره‌های گزارشی بهترین‌ها (۲۰۰، ۲۸، و امثال آن) در توضیح فارسی حفظ شده‌اند.

Logistic Regression. L2 penalty (C=1.0). class_weight=balanced. max_iter=1000.

Random Forest. Selected via RandomizedSearchCV: n_estimators=200; max_depth=28; min_samples_split=5; min_samples_leaf=2; max_features=log2.

XGBoost. n_estimators=200; max_depth=6; learning_rate=0.05; subsample=0.8; colsample_bytree=0.8.

LightGBM. n_estimators=200; max_depth=6; learning_rate=0.05; num_leaves=31.

CatBoost. iterations=200; depth=6; learning_rate=0.05.

همه مدل‌های کلاسیک از همان بردار ویژگی جدولی ۲۵-بعدی و تقسیم‌های یکسان آموزش/اعتبارسنجی/آزمون استفاده می‌کنند. تنظیم آستانه روی مجموعه اعتبارسنجی برای همه مدل‌ها برای بیشینه‌سازی F1 انجام می‌شود؛ آستانه تنظیم‌شده برای ارزیابی نهایی روی آزمون اعمال می‌شود.

۸.۴ معیارهای ارزیابی و گزارش

برای همه مدل‌ها AUROC (اصلی)، F1-macro، Precision، Recall، Accuracy و MCC گزارش می‌کنیم. AUROC نسبت به آستانه ثابت نیست و برای داده نامتعادل مناسب است. F1-macro میانگین F1 به‌ازای هر کلاس را می‌گیرد تا سلطه کلاس اکثریت را کاهش دهد. همچنین بازه‌های اطمینان ۹۵٪ بوت‌استرپ (۱,۰۰۰ نمونه‌برداری مجدد) برای معیارهای کلیدی گزارش می‌کنیم. برای مقایسه آماری از آزمون DeLong برای منحنی‌های ROC جفتی استفاده می‌کنیم. از اصلاح چندمقایسه‌ای (مثلاً Bonferroni) بین آزمایش‌ها صرف‌نظر می‌کنیم تا توان حفظ شود؛ برای انتقال عدم قطعیت بازه‌های اطمینان را گزارش می‌کنیم. همه معیارها روی مجموعه آزمون نگه‌داشته شده محاسبه می‌شوند و از داده آزمون برای انتخاب مدل یا تنظیم ابرپارامتر استفاده نمی‌شود. برای ارزیابی few-shot، ۱۰۰ اپیزود نمونه‌برداری می‌کنیم؛ هر اپیزود K پشتیبان و Q پرس‌وجو به‌ازای هر کلاس دارد. میانگین و انحراف معیار بین اپیزودها را گزارش می‌کنیم. برای مدل‌های کلاسیک یک‌بار روی کل مجموعه آزمون ارزیابی می‌کنیم. تفاوت پروتکل‌ها بدین معناست که معیارهای آزمایش K-shot (در این مخزن حدود ۰.۵۶۴-۰.۵۵۷ AUROC) مستقیماً با ارزیابی ثابت Exp1 برای Proposed_FewShot (۰.۶۱۱) قابل تعویض نیستند.

۹.۴ آزمایش ۱: مقایسه مدل اصلی

۱.۹.۴ هدف

مقایسه FewShot+ETHOS (Proposed_FewShot) با خطوط پایه کلاسیک و عصبی روی مجموعه آزمون.

۲.۹.۴ مدل‌ها

• LogisticRegression

- RandomForest
- XGBoost
- StandardNN (MLP بدون few-shot)
- FederatedNN_NoFewShot (MLP فدرال، بدون few-shot)
- Proposed_FewShot (ETHOS + سر نمونه‌ای)

۳.۹.۴ خلاصه نتایج

Proposed_FewShot: AUROC ۰.۶۱۱، F1 ۰.۵۷۲، Accuracy ۰.۵۸۳. بهترین کلاسیک در همین اسکرپت Random Forest با AUROC ۰.۷۶۲، F1 ۰.۶۷۹، و دقت ۰.۷۱۸ است. این مقادیر با results/tables/exp1_results.csv همگام شده‌اند. جدول ۳.۵ در فصل ۵ را ببینید.

۱۰.۴ آزمایش ۲: حساسیت K-shot

۱.۱۰.۴ هدف

هدف این آزمایش، سنجش اثر تعداد نمونه‌های پشتیبان K بر عملکرد few-shot است. در این چارچوب، K تعداد نمونه برچسب‌خورده برای هر کلاس در مجموعه پشتیبان است. افزایش K اطلاعات بیشتری برای ساخت نمونه‌های اولیه فراهم می‌کند، اما هم‌زمان مسئله را از حالت کم‌نمونه دورتر می‌سازد. بنابراین K را تغییر می‌دهیم تا این بده‌بستان بهتر روشن شود.

۲.۱۰.۴ جزئیات طراحی

برای هر مقدار K از میان ۱، ۳، ۵، ۱۰ و ۱۵، اپیزودها با K پشتیبان و $Q=15$ پرس‌وجو به‌ازای هر کلاس نمونه‌برداری می‌شوند. هر پیکربندی روی ۱۰۰ اپیزود آزمون ارزیابی می‌شود و میانگین AUROC و انحراف معیار گزارش می‌گردد. مدل اصلی FewShot+ETHOS برای آموزش از $K=5$ استفاده می‌کند؛ این آزمایش K را فقط در زمان ارزیابی متغیر می‌کند تا حساسیت سنجیده شود. توجه: پروتکل ارزیابی اپیزودیک با ارزیابی اصلی Exp1 متفاوت است؛ از این رو مقادیر مطلق AUROC در این آزمایش در بازه ۰.۵۶۴-۰.۵۵۷ می‌مانند و از عدد منجمد ۰.۶۱۱ پایین‌ترند.

۳.۱۰.۴ طراحی

$K \in \{1, 3, 5, 10, 15\}$ را متغیر می‌کنیم و AUROC و F1 را روی مجموعهٔ آزمون اندازه می‌گیریم. هر پیکربندی روی چند اپیزود ارزیابی می‌شود.

۴.۱۰.۴ خلاصهٔ نتایج

AUROC در بازهٔ باریک ۰.۵۶۴-۰.۵۵۷ نوسان می‌کند. بهترین میانگین مشاهده‌شده ۰.۵۶۴ در $K=3$ است و $K=1$ نیز تقریباً هم‌تراز باقی می‌ماند؛ بنابراین در این جاروب اپیزودیک روند صعودی یکنواخت دیده نمی‌شود. جدول ۴.۵ را ببینید.

۱۱.۴ آزمایش ۳: فدرال در برابر متمرکز

۱.۱۱.۴ هدف

هدف این آزمایش، اندازه‌گیری هزینهٔ عملکردی یادگیری فدرال است. در یادگیری فدرال، مدل بدون تجمع نمونه‌های خام روی دادهٔ توزیع‌شده آموزش می‌بیند؛ بنابراین پرسش اصلی این است که این قید تا چه اندازه به عملکرد آسیب می‌زند.

۲.۱۱.۴ طراحی

FewShot+ETHOS در دو چیدمان آموزش داده می‌شود: (۱) متمرکز، که در آن همهٔ داده‌ها در یک محل در دسترس‌اند و آموزش اپیزودیک استاندارد انجام می‌شود؛ و (۲) فدرال، که در آن داده بر اساس بیماری به ۵ گره تقسیم می‌شود و FedAvg در ۲۰ دور با ۳ دورهٔ محلی در هر دور اجرا می‌گردد. هر دو چیدمان از معماری، ابرپارامترها و تقسیم‌های داده یکسان استفاده می‌کنند. در حالت فدرال، هر گره مدل را محلی آموزش می‌دهد و به‌روزرسانی‌ها را به سرور می‌فرستد؛ سرور نیز آن‌ها را متناسب با اندازهٔ گره تجمع می‌کند. AUROC و F1 روی مجموعهٔ آزمون نگه‌داشته‌شده مقایسه می‌شوند. مجموعهٔ آزمون سراسری و بدون پارتیشن است تا مقایسه منصفانه باقی بماند.

۳.۱۱.۴ خلاصه نتایج

در خروجی نهایی این آزمایش، چیدمان متمرکز AUROC ۰.۵۵۲ و F1 ۰.۵۴۳ دارد، در حالی که چیدمان فدرال AUROC ۰.۵۴۷ و F1 ۰.۵۴۰ ثبت می‌کند؛ بنابراین افت مطلق حدود ۰.۰۰۵ AUROC است. این نتیجه از نظر کاربردی کوچک است، اما به معنای برتری فدرال نیست؛ تنها نشان می‌دهد که در این شبیه‌سازی هزینه حفظ حریم خصوصی محدود مانده است. جدول ۵.۵ را ببینید.

۱۲.۴ آزمایش ۴: مطالعه حذف تدریجی

۱.۱۲.۴ هدف

هدف این آزمایش، شناسایی اجزایی است که بیشترین سهم را در عملکرد مدل دارند. در حذف تدریجی، هر بار یک جزء حذف می‌شود و تغییر عملکرد اندازه‌گیری می‌گردد. این کار کمک می‌کند مشخص شود کدام انتخاب‌های طراحی واقعاً حیاتی‌اند و کدام‌ها اثر محدودتری دارند.

۲.۱۲.۴ گونه‌ها

- `full_model`: FewShot+ETHOS کامل.
- `no_symptom_tokens`: جایگزینی با Logistic Regression روی ۲۵ ویژگی خام.
- `no_clinical_bias`: حذف سوگیری بالینی در جاسازی‌ها.
- `no_intensity_weighting`: حذف وزن‌دهی شدت.
- `no_temporal_decay`: حذف واگرایی زمانی.
- `no_few_shot`: NN استاندارد (بدون آموزش اپیزودیک).

۳.۱۲.۴ خلاصه نتایج

`full_model`: AUROC ۰.۵۸۳، `no_symptom_tokens`: (LR روی ویژگی‌های خام) ۰.۷۲۴. `no_intensity_weighting`: ۰.۵۷۷. در این جدول، حذف توکن‌های علامت ظاهراً عملکرد را بهتر می‌کند؛ بنابراین این حذف تدریجی بیشتر به محدودیت بازنمایی فعلی اشاره می‌کند تا تأیید بی‌قیدوشرط اجزای پیشنهادی. جدول ۷.۵ را ببینید.

۱۳.۴ آزمایش ۵: تعمیم بین‌بیماری

۱.۱۳.۴ هدف

ارزیابی تعمیم به گروه‌های بیماری دیده‌نشده. در چیدمان‌های فدرال یا چندسایتی، مدلی که روی برخی گروه‌های بیماری آموزش دیده ممکن است با دادهٔ محلی محدود به دیگران تعمیم یابد.

۲.۱۳.۴ طراحی

روی گره‌های ۱-۳ (سپسیس، قلبی، تنفسی) آموزش؛ آزمون روی گره‌های ۴ و ۵ (کلیوی، دیابت). این سناریویی را شبیه‌سازی می‌کند که بیمارستان یا گروه بیماری جدیدی به فدراسیون می‌پیوندد بدون دادهٔ آموزش محلی. `Proposed_FewShot`، `Logistic Regression`، `XGBoost` و `Standard NN` را مقایسه می‌کنیم. یادگیری `few-shot` برای چنین سناریوهایی طراحی شده است؛ آزمون می‌کنیم آیا وقتی توزیع آزمون از توزیع آموزش متفاوت است بر مدل‌های کلاسیک برتری دارد.

۳.۱۳.۴ خلاصهٔ نتایج

پیشنهادی: `(node_4)` ۰.۶۰۲ و `(node_5)` ۰.۴۷۸. `LR`: ۰.۶۶۸ و ۰.۶۵۸. `XGBoost`: ۰.۷۰۴ و ۰.۷۰۰. در این اسنپ‌شات مدل‌های کلاسیک روی هر دو گره بهتر تعمیم می‌یابند و به‌ویژه روی گرهٔ دیابت افت مدل پیشنهادی چشمگیر است. جدول ۸.۵ را ببینید.

۱۴.۴ رویهٔ جستجوی ابرپارامتر

برای مدل‌های کلاسیک از `RandomizedSearchCV` با ۵۰-۸۰ آزمون استفاده می‌کنیم. فضاهای جستجو در بلوک لاتین زیر به‌صورت یک خطی قابل شکستن آمده تا ارقام و پرانتز با متن فارسی قاطعی نشوند؛ معیار امتیاز `AUROC` است؛ اعتبارسنجی متقاطع لایه‌ای ۵تایی روی آموزش+اعتبارسنجی انجام می‌شود؛ بهترین پیکربندی با میانگین `AUROC` روی چین‌ها انتخاب می‌شود؛ سپس آستانهٔ تصمیم روی اعتبارسنجی برای بیشینه‌سازی `F1` تنظیم و معیارهای نهایی روی آزمون گزارش می‌شوند. برای شبکهٔ کامل پیوست آن را ببینید.

```
Random Forest. n_estimators: 100, 200, 300, 400, 500; max_depth: 8, 12, 16, 20, 24, 28;
min_samples_split: 2, 5, 10; min_samples_leaf: 1, 2, 4; max_features: sqrt, log2;
```

```
class_weight: balanced, balanced_subsample.
XGBoost. n_estimators: 100, 200, 300, 400, 500; max_depth: 4, 6, 8, 10, 12;
learning_rate: 0.01, 0.03, 0.05, 0.1; subsample: 0.5, 0.7, 0.85, 1.0; colsample_bytree:
0.5, 0.7, 0.85, 1.0.
```

۱۵.۴ آزمایش ۵.۸: گسترش‌های حذف تدریجی ETHOS

۱.۱۵.۴ هدف

گسترش مطالعه حذف تدریجی برای آزمون اینکه آیا آموزش نظارت‌شده (بدون few-shot اپیزودیک) عملکرد ETHOS را بهبود می‌دهد. گونه اصلی no_few_shot (NN استاندارد) به AUROC ۰.۶۴۵ رسید؛ فرض می‌کنیم ETHOS با سر طبقه‌بندی نظارت‌شده ممکن است از آموزش اپیزودیک پیشی گیرد.

۲.۱۵.۴ طراحی

رمزگذار ETHOS را با سر نظارت‌شده آموزش می‌دهیم: Linear(128→64→1) با سیگموئید، CrossEntropyLoss با وزن کلاس. همان تقسیم‌های داده که RF (seed=42). ۱۰۰ دوره، صبر توقف زودهنگام ۱۵. اختیاری: بارگذاری رمزگذار ETHOS پیش‌آموزش‌دیده از پیش‌آموزش MLM.

۳.۱۵.۴ خلاصه نتایج

ETHOS_Supervised به AUROC ۰.۶۱۰، F1 ۰.۳۸۶، Accuracy ۰.۶۲۷ می‌رسد. در مقایسه با Proposed_FewShot در Exp1 (۰.۶۱۱)، آموزش نظارت‌شده AUROC تقریباً هم‌تراز می‌دهد. سر نظارت‌شده از کل مجموعه داده بدون نمونه‌برداری اپیزودیک یاد می‌گیرد. جدول ۳.۵ و جدول ۹.۵ را ببینید.

۱۶.۴ آزمایش ۵.۹: معماری‌های ترکیبی

۱.۱۶.۴ هدف

مقایسه معماری‌های ترکیبی که جاسازی‌های ETHOS را با ویژگی‌های جدولی ترکیب می‌کنند. آزمون: (۱) RF روی [ETHOS ۱۲۸ ب + جدولی ۲۵] = ۱۵۳، (۲) RF تنها روی ETHOS ۱۲۸ ب.

۲.۱۶.۴ طراحی

۱. **ETHOS_RF_Hybrid**: استخراج جاسازی‌های ETHOS برای همه نمونه‌ها. الحاق با ویژگی‌های جدولی: $\mathbf{x}_{\text{hybrid}} = [\mathbf{e}_{\text{ETHOS}}; \mathbf{x}_{\text{tab}}] \in \mathbb{R}^{153}$. آموزش Random Forest با RandomizedSearchCV (۵۰ آزمون) روی آموزش+اعتبارسنجی. تنظیم آستانه روی اعتبارسنجی.

۲. **RF_on_ETHOS_only**: آموزش RF تنها روی جاسازی‌های ۱۲۸-بعدی ETHOS (بدون جدولی). همان CV و تنظیم آستانه.

۳.۱۶.۴ خلاصه نتایج

ETHOS_RF_Hybrid به AUROC ۰.۷۱۷، F1 ۰.۶۵۲، Accuracy ۰.۶۶۵ می‌رسد؛ بهبود چشمگیر نسبت به Proposed_FewShot در Exp1 (۰.۶۱۱) و ETHOS_Supervised (۰.۶۱۰). ترکیبی هم بازنمایی‌های آموخته‌شده و هم ویژگی‌های مهندسی‌شده را بهره می‌برد و شکاف تا RF (۰.۷۶۰) را به حدود ۰.۰۴ AUROC کاهش می‌دهد. RF_on_ETHOS_only: AUROC ۰.۵۹۸، F1 ۰.۵۷۶؛ ضعیف‌تر از ترکیبی؛ تأیید می‌کند ویژگی‌های جدولی سیگنال بحرانی اضافه می‌کنند. جدول ۹.۵ را ببینید.

۱۷.۴ جمع‌بندی فصل

این فصل چیدمان تجربی را شرح داد: پیاده‌سازی و معماری نرم‌افزار، پیکربندی داده، پیکربندی‌های FewShot+ETHOS و خط پایه کلاسیک، فرضیات آزمایش، توان آماری و اندازه نمونه، مشخصات سخت‌افزار و نرم‌افزار، فلسفه طراحی، رویه اجرا، پیکربندی‌های مدل خط پایه، معیارهای ارزیابی و

گزارش، و طراحی تفصیلی برای هر یک از آزمایش‌های ۱ تا ۵، گسترش‌های حذف تدریجی ETHOS، و معماری‌های ترکیبی. فصل بعد نتایج را گزارش می‌کند.

فصل ۵

نتایج

این فصل نتایج تجربی را به ترتیب اهمیت گزارش می‌کند. اعداد و معیارهای اصلی همان خروجی‌های ثبت‌شده آزمایش‌ها هستند و در این بخش فقط نحوه خواندن و تفسیر آن‌ها روشن‌تر می‌شود.

سلسله‌مراتب گزارش‌دهی (چگونه اعداد را بخوانیم). در این پایان‌نامه چند معیار مکمل گزارش می‌شود. هر کدام به پرسش متفاوتی پاسخ می‌دهد و بنابراین نباید به جای دیگری تفسیر شود:

۱. سقف جدولی: Random Forest و XGBoost تنظیم شده و فرایند SOTA جدولی (`exp_tabular_sota.py`)، همراه با افزایش داده و تنظیم آستانه. این بخش مرز بالای تجربی مدل‌های کلاسیک را روی همین کوه‌ورت نشان می‌دهد.

۲. پروتکل **Exp1**: در `exp1_main.py`، مدل `Proposed_FewShot` و خطوط پایه در یک اسکرپت مشترک مقایسه می‌شوند. این اعداد به همان پیکربندی آموزش اپیزودیک مخزن مربوطاند و جداول خروجی نیز به صورت خودکار در پیوست آمده‌اند.

۳. ترکیب جدولی و بهترین اجرای **few-shot**: جاسازی‌های ETHOS همراه با ویژگی‌های جدولی در `exp_ethos_rf_hybrid.py` و بهترین فرایند یکپارچه در `exp_fewshot_` `best.py` گزارش می‌شوند. این اجراها معمولاً بخش مهمی از فاصله تا سقف جدولی را، نسبت به اعداد اپیزودیک ساده، کاهش می‌دهند.

۴. فدرال در برابر متمرکز: این بخش بده‌بستان میان حریم خصوصی و سودمندی را در `exp3_federated.py` جداگانه گزارش می‌کند.

حساسیت **K-shot** در Exp2 با پروتکل /پیزودیک ارزیابی می‌شود. بنابراین AUROC آن را نباید مستقیماً با AUROC کل مجموعه آزمون در Exp1 یا با نتایج انباشتی مقایسه کرد. این بخش فقط نشان می‌دهد اندازه مجموعه پشتیبان چه اثری بر عملکرد اپیزودیک دارد.

۱.۵ بهترین مدل کلاسیک نهایی

قوی‌ترین نتیجه **جدولی** از اسکرپت چندفازی SOTA (`exp_tabular_sota.py`) به‌دست آمده است. پس از تنظیم مدل‌های کلاسیک، `ensembling` و افزایش سبک گاوسی روی توزیع آموزش، پیکربندی `aug_gaussian_n300_std0.03` روی **مجموعه آزمون نگه‌داشته‌شده** بهترین نتیجه را ثبت می‌کند. خروجی متناظر در `results/exp_tabular_sota_last_run.log` ذخیره شده و در جدول زیر آمده است:

جدول ۱.۵: فرایند جدولی SOTA؛ بهترین پیکربندی آزمون (فاز 4)


پیکربندی	AUROC	F1	دقت	MCC
<code>aug_gaussian_n300_std0.03</code>	0.748	0.674	0.700	0.348

در اعتبارسنجی متقاطع میانی، Random Forest با AUROC حدود ۰.۷۴۴ و XGBoost با مقدار حدود ۰.۷۴۰ روی مجموعه آموزش+اعتبار از پیش‌تازان بودند. معیارهای کامل هر فاز در خروجی کد ثبت شده‌اند. شکل ۱.۵ منحنی‌های ROC تولیدشده را نشان می‌دهد.


۲.۵ عملکرد FewShot+ETHOS

جدول ۲.۵ معیارهای آخرین اجرای `experiments/exp_fewshot_best.py` را نشان می‌دهد؛ خروجی کامل آن در `results/exp_fewshot_best.json` ذخیره شده است. این اجرا شامل یک `ensemble` در مسیر `few-shot` (ترکیب GFA، `cross-attention` و سازگاری به سبک Proto-MAML) و یک **فرا یادگیر** انباشتی است که احتمال‌های `few-shot`، احتمال‌های RF و ویژگی‌های جاسازی را ترکیب می‌کند. اعداد جدول، برآوردهای نقطه‌ای مجموعه آزمون برای همان اجرای ثبت‌شده‌اند.

فاصله تا سقف جدولی SOTA در جدول ۱.۵ بسیار کوچک است: اختلاف AUROC بین Stacked BEST و سقف جدولی برابر ۰.۰۰۲ است ($0.746 - 0.748 = 0.002$). این مقدار در حد



شکل ۱.۵: منحنی‌های ROC (خروجی تولیدشده): کلاسیک در برابر ETHOS در برابر اجرای انباشتی few-shot (AUROC دقیق در جداول).




شکل ۲.۵: منحنی‌های دقت-بازخوانی برای Random Forest و ETHOS.

جدول ۲.۵: بهترین اجرای few-shot (`exp_fewshot_best.py`، مجموعه آزمون)؛ few-shot در برابر انباشتی

معیار	Stacked BEST	FewShot BEST	بازه اطمینان ۹۵٪ (انباشتی)
AUROC	0.746	0.670	[0.699, 0.797]
AUPRC	0.824	0.757	—
F1-macro	0.687	0.386	—
Precision	0.686	0.314	—
Recall	0.696	0.500	—
دقت	0.698	0.628	—
MCC	0.382	0.000	—

نوسان اجراهاست. با این حال، زیرمدل few-shot به تنهایی با ۰.۶۷۰ هنوز پایین تر از سقف قرار می گیرد؛ همین شکاف دلیل اصلی استفاده از انباشت و طراحی ترکیبی است. شکل ۳.۵ نشان می دهد RF و ETHOS با افزایش اندازه آموزش در مجموعه تشخیصی چگونه مقیاس می یابند.



شکل ۳.۵: منحنی های یادگیری: AUROC در برابر اندازه آموزش برای RF و FewShot+ETHOS خط پایه (V0). بهبودهای V4 و V5 در بازه ۰.۷۴-۰.۷۱ نمایش داده نشده اند.

۳.۵ آزمایش ۱: مقایسه مدل اصلی

جدول ۳.۵ خروجی `exp1_main.py` را روی همان تقسیم آزمون بازتولید می کند؛ معیارها از `results/tables/exp1_results.csv` خوانده شده اند. در این اسکریپت، خطوط پایه

کلاسیک، مدل‌های عصبی و Proposed_FewShot با یک روند مشترک آموزش و ارزیابی می‌شوند. اعداد انباشتی و ترکیبی جزئی از Exp1 نیستند و باید در جدول ۲.۵ و آزمایش‌های ترکیبی تفسیر شوند.

جدول ۳.۵: آزمایش ۱: مقایسه مدل اصلی (مجموعه آزمون)؛ exp1_main.py

مدل	AUROC	F1	دقت	MCC
LogisticRegression	0.724	0.682	0.700	0.364
RandomForest	0.762	0.679	0.718	0.372
XGBoost	0.694	0.632	0.662	0.266
StandardNN	0.652	0.616	0.660	0.242
FederatedNN_NoFewShot	0.662	0.618	0.642	0.236
Proposed_FewShot	0.611	0.572	0.583	0.155


۴.۵ آزمایش ۲: حساسیت K-Shot

جدول ۴.۵ AUROC اپیزودیک (میانگین $\pm$ انحراف معیار) برای $K \in \{1, 3, 5, 10, 15\}$ از results/tables/exp2_results.csv را گزارش می‌کند. مقادیر مستقیماً با AUROC کامل مجموعه آزمون در Exp1 قابل مقایسه نیستند.

جدول ۴.۵: آزمایش ۲: حساسیت K-shot (exp2_shots.py، پروتکل اپیزودیک)

K	AUROC	std $\pm$	F1
۱	0.564	0.022	0.554
۳	0.564	0.025	0.548
۵	0.560	0.029	0.539
۱۰	0.557	0.021	0.534
۱۵	0.557	0.021	0.534

شکل ۴.۵ AUROC را در برابر K با باندهای اطمینان نشان می‌دهد.



شکل ۴.۵: حساسیت K-shot: AUROC در برابر K با باندهای بازه اطمینان ۹۵٪.

۵.۵ آزمایش ۳: فدرال در برابر متمرکز

جدول ۵.۵ خلاصه `exp3_federated.py` (`results/tables/exp3_results.csv`) را ارائه می‌کند. آموزش فدرال در این پیکربندی حدود ۰.۵ واحد درصد AUROC نسبت به متمرکز هزینه دارد.


جدول ۵.۵: آزمایش ۳: فدرال در برابر متمرکز (`exp3_federated.py`)

چیدمان	AUROC	F1
متمرکز	0.552	0.543
فدرال	0.547	0.540
شکاف (مطلق)	0.005	0.003

شکل ۵.۵ همگرایی را در طول دورها نشان می‌دهد. جدول ۶.۵ جریان ارتباطی FedAvg را در هر دور خلاصه می‌کند.

۶.۵ آزمایش ۴: حذف تدریجی

جدول ۷.۵ خروجی‌های `exp4_ablation.py` (`results/tables/exp4_results.csv`) را فهرست می‌کند. Δ AUROC نسبت به `full_model` است. شکل ۶.۵ نتایج حذف تدریجی را به صورت رادار ارائه می‌کند.



شکل ۵.۵: همگرایی فدرال: AUROC اعتبارسنجی در برابر دور.


جدول ۶.۵: جریان ارتباطی FedAvg ($T = 20$ دور، ۵ گره)

گام شرح

- ۱ سرور θ_t را به همه گره‌ها پخش می‌کند (Diabetes, Renal, Respiratory, Cardiac, Sepsis)
- ۲ هر گره k مدل محلی را $\theta_t^{(k)} \leftarrow \theta_t$ مقداردهی اولیه می‌کند
- ۳ آموزش محلی: $E = 3$ دوره، SGD روی $\mathcal{D}_k$
- ۴ گره k ، $\theta_t^{(k)}$ را به سرور می‌فرستد
- ۵ سرور تجمیع می‌کند: $\theta_{t+1} \leftarrow \sum_k (n_k/n) \theta_t^{(k)}$ (وزن دار با n_k)

جدول ۷.۵: آزمایش ۴: مطالعه حذف تدریجی (exp4_ablation.py)

نوع	AUROC	F1	AUROC Δ
full_model	0.583	0.554	—
no_symptom_tokens	0.724	0.628	+0.140
no_clinical_bias	0.584	0.557	+0.001
no_intensity_weighting	0.577	0.570	-0.006
no_temporal_decay	0.583	0.554	0.000
no_few_shot	0.645	0.584	+0.062



شکل ۶.۵: مطالعه حذف تدریجی به صورت رادار: سهم هر جزء.

۷.۵ آزمایش ۵: تعمیم بین بیماری

جدول ۸.۵ آخرین صادرات `exp5_generalization.py` (`results/tables/`) را نشان می‌دهد. این اجرا دو گره بیماری نگه‌داشته‌شده (`diabetes`, `renal`) را گزارش می‌کند؛ در صورت نیاز اسکریپت را برای بازیابی هر پنج گره گسترش دهید.

جدول ۸.۵: آزمایش ۵: تعمیم بین بیماری (AUROC به تفکیک گره آزمون)

گره آزمون	پیشنهادی	LR	XGBoost	NN
(renal) node_4	0.602	0.668	0.704	0.572
(diabetes) node_5	0.478	0.658	0.700	0.643

در این اسنپ‌شات مدل‌های کلاسیک در هر دو گره پیشتازند؛ گره دیابت برای مدل پیشنهادی به‌ویژه دشوار است (پشتیبان کوچک‌تر، نویز برجسته بیشتر).

۸.۵ مقایسه گسترده مدل‌ها (۱۱ مدل)


جدول ۹.۵ مدل‌های نماینده را با معیارهای آزمون همگام‌شده با مجموعه خروجی فعلی مخزن یکپارچه می‌کند: لاگ CSV / SOTA، Exp1 CSV، اسکریپت ترکیبی، و `exp_fewshot_best.json`. سطرها پروتکل‌های کمی متفاوت را مخلوط می‌کنند؛ برای جداول دقیق به‌ازای هر اسکریپت بخش «سلسله‌مراتب گزارش‌دهی» و پیوست د را ببینید.

جدول ۹.۵: مقایسه گسترده مدل‌ها؛ معیارهای نماینده آزمون (همگام با خروجی‌های مخزن)

مدل	AUROC	AUPRC	F1	Prec.	Rec.	Acc.	MCC
بهترین جدولی SOTA (فاز ۴)	0.748	–	0.674	–	–	0.700	0.348
(Exp1) RandomForest	0.762	0.843	0.679	–	–	0.718	0.372
(Exp1) LogisticRegression	0.724	0.777	0.682	–	–	0.700	0.364
(Exp1) XGBoost	0.694	0.779	0.632	–	–	0.662	0.266
ETHOS_RF_Hybrid	0.717	–	0.652	–	–	0.665	–
FederatedNN_NoFewShot	0.662	0.732	0.618	–	–	0.642	0.236
StandardNN	0.652	0.720	0.616	–	–	0.660	0.242
(Exp1) Proposed_FewShot	0.611	0.687	0.572	–	–	0.583	0.155
(exp_fewshot_best) FewShot BEST	0.670	0.757	0.386	0.314	0.500	0.628	0.000
(exp_fewshot_best) Stacked BEST	0.746	0.824	0.687	0.686	0.696	0.698	0.382

۹.۵ مقایسه مدل با بازه‌های اطمینان

جدول ۱۰.۵ بازه‌های اطمینان ۹۵٪ بوت‌استرپ (۱,۰۰۰ نمونه‌برداری مجدد) را برای مدل‌های برتر فراهم می‌کند. بازه‌های بدون هم‌پوشانی تفاوت آماری معنادار را نشان می‌دهند. شکل ۷.۵ همه مدل‌ها را در نمودار میله‌ای مقایسه می‌کند.



شکل ۷.۵: مقایسه اصلی مدل‌ها: AUROC در برابر همه خطوط پایه و مدل‌های پیشنهادی.

جدول ۱۰.۵: مدل‌های منتخب با بازه‌های مستند (بوت‌استرپ از exp_fewshot_best.json؛ سطر Exp1 RF برآورد نقطه‌ای از تقسیم ثابت است).

مدل	معیار	نقطه	بازه
(Exp1) RandomForest	AUROC	0.762	–
Stacked BEST (exp_fewshot_best)	AUROC	0.746	[0.699, 0.797]
FewShot BEST (exp_fewshot_best)	F1	0.687	–
	AUROC	0.670	[0.612, 0.726]
	F1	0.386	–
(Exp1) Proposed_FewShot	AUROC	0.611	–

۱۰.۵ خلاصه یافته‌های کلیدی

جدول ۱۱.۵ یافته‌های اصلی اجرای فعلی مخزن را یکپارچه می‌کند (به JSON/CSV ذکر شده در هر سطر مراجعه کنید).

۱۱.۵ معناداری آماری

هرجا اسکریپت‌های آموزش بازه اطمینان تولید کرده‌اند، همان بازه‌ها گزارش شده‌اند. بر اساس exp_fewshot_best.json، Stacked BEST دارای AUROC ۰.۷۴۶ با بازه اطمینان ۹۵٪ بوت‌استرپ [0.699, 0.797] است و FewShot BEST دارای AUROC ۰.۶۷۰ با بازه [0.612, 0.726] است. فرایند جدولی SOTA برآورد نقطه‌ای AUROC آزمون ۰.۷۴۸ را می‌دهد (جدول ۱.۵). مقایسه جفتی رسمی میان این خروجی‌ها به پروتکل نگه‌داشت اختصاصی و بردارهای پیش‌بینی هم‌تراز نیاز دارد. ستون‌های بوت‌استرپ Exp1 در CSV، به دلیل تکرار مقدار اسکالر، برای استنتاج آماری قابل اتکا نیستند؛ بنابراین برای Exp1 از برآوردهای نقطه‌ای تقسیم ثابت در جدول ۳.۵ استفاده می‌شود.

۱۲.۵ تفسیرپذیری

شکل ۸.۵ اهمیت ویژگی در Random Forest را نشان می‌دهد. کراتینین، گلوکز و هموگلوبین بالاترین رتبه را دارند و این الگو با شهود بالینی هم‌خوان است. کراتینین عملکرد کلیه را بازتاب می‌دهد و مقدار بالای آن معمولاً به AKI و تأخیر در ترخیص ایمن مربوط است. گلوکز وضعیت کنترل قند خون را نشان می‌دهد؛ بی‌نظمی قند در بیماران بحرانی شایع است و می‌تواند روند بهبود را تحت تأثیر قرار دهد.


جدول ۱۱.۵: خلاصه یافته‌های کلیدی (مجموعه آزمون، همگام‌شده)

دسته	مدل	AU ROC	F1	یادداشت
کلاسیک / جدولی				
سقف	جدولی SOTA (فاز 4)	0.748	0.674	exp_tabular_sota.py
	(Exp1) RandomForest	0.762	0.679	همان تقسیم Exp1
	(Exp1) LogisticRegression	0.724	0.682	
	(Exp1) XGBoost	0.694	0.632	
عصبی، ترکیبی، few-shot				
ترکیبی	ETHOS_RF_Hybrid	0.717	0.652	جاسازی + RF
انباشتی	Stacked BEST	0.746	0.687	exp_fewshot_best.py
few-shot	FewShot BEST	0.670	0.386	پیش از انباشت
Exp1	Proposed_FewShot	0.611	0.572	پروتکل exp1_main.py
فدرال				
فدرال	متمرکز؛ فدرال	0.552؛ 0.543	افت ≈ 0.005	AUROC (فدرال)
		0.547	0.540	


هموگلوبین نیز نشانگر کم‌خونی یا خونریزی است و مقادیر پایین آن ممکن است نیاز به انتقال خون یا پایش طولانی‌تر ایجاد کند. نمره SOFA و shock index نیز سهم دارند و با نقش اختلال اندام و پایداری همودینامیک در امکان‌پذیری درمان سازگارند. جدول ۱۲.۵ ویژگی‌های برتر را به معنای بالینی آن‌ها نگاشت می‌کند. شکل ۹.۵ نیز آبخار SHAP را برای یک بیمار نمونه نشان می‌دهد.

جدول ۱۲.۵: تفسیر بالینی ویژگی‌های برتر (Random Forest)


ویژگی اهمیت معنای بالینی	
0.18 Creatinine	عملکرد کلیه؛ بالا → AKI، تأخیر ترخیص
0.14 Glucose	کنترل گلیسمی؛ بی‌نظمی شایع در بیماران بحرانی
0.12 Hemoglobin	کم‌خونی/خونریزی؛ پایین → انتقال خون، اقامت طولانی‌تر
0.11 Lactate	پرفیوژن بافت؛ بالا → شوک، پیش‌آگهی ضعیف
0.10 Shock index	SBP/HR؛ ناپایداری همودینامیک
0.09 SOFA proxy	ترکیب اختلال اندام
0.08 Abnormal lab count	انحراف کلی؛ سهم مقادیر افراطی



شکل ۸.۵: اهمیت ویژگی (Random Forest). کراتینین، گلوکز، هموگلوبین بالاترین رتبه را دارند.



شکل ۹.۵: آبشار SHAP برای یک بیمار برتر (Random Forest). سهم ویژگی‌ها در پیش‌بینی.



شکل ۱۰.۵: منحنی‌های کالیبراسیون: احتمال پیش‌بینی‌شده در برابر فراوانی مشاهده‌شده. RF نسبتاً خوب کالیبره است؛ ETHOS گرایش به بیش‌اعتمادی دارد.

۱۳.۵ مطالعات موردی بالینی

برای نمایش رفتار مدل، سه مورد نماینده از مجموعهٔ آزمون ارائه می‌کنیم:

مورد ۱ (مثبت واقعی): مرد ۶۲ ساله با سپسیس. کراتینین 1.2 mg/dL (نرمال شده 0.4)، روند بهبود؛ لاکتات 1.8 (0.35)؛ علائم حیاتی پایدار. RF امکان‌پذیری را 0.72 پیش‌بینی کرد؛ ترخیص واقعی به بازتوانی. در تحلیل SHAP، کراتینین با اثر -0.08 ، لاکتات با اثر -0.05 ، و SOFA با اثر -0.04 به تصمیم درست مدل کمک کردند.

مورد ۲ (منفی کاذب): زن ۵۸ ساله با تشخیص قلبی. کراتینین مرزی (0.45 نرمال شده)؛ RF غیرممکن (0.48) پیش‌بینی کرد اما بیمار به منزل ترخیص شد. خطا احتمالاً به دلیل کراتینین در بازهٔ مبهم؛ زمینهٔ اضافی (مثلاً روند بهبود) می‌توانست کمک کند.

مورد ۳ (مثبت کاذب): مرد ۷۱ ساله با نارسایی کلیه. کراتینین بالا (0.72 نرمال شده)؛ RF امکان‌پذیری را 0.58 پیش‌بینی کرد اما بیمار نیاز به اقامت طولانی داشت. مدل ممکن است تعامل سن-کراتینین را کم‌وزن کرده باشد.

این موارد برجسته می‌کنند که مقادیر آزمایشگاهی مرزی و زیرگروه‌های نادر همچنان چالش‌زا هستند. در استقرار باید پیش‌بینی‌های با اطمینان پایین برای بازبینی بالینی علامت‌گذاری شوند.

۱۴.۵ تحلیل توزیع اطمینان

توزیع احتمالات پیش‌بینی شده از بهترین مدل (RF) را تحلیل کردیم. برای مثبت‌های واقعی: میانهٔ احتمال پیش‌بینی شده 0.72 (IQR $0.58-0.85$)، برای منفی‌های واقعی: میانه 0.35 (IQR $0.22-0.48$)، برای مثبت‌های کاذب: میانه 0.58 (IQR $0.52-0.64$)؛ این‌ها نزدیک آستانهٔ تصمیم خوشه می‌شوند. برای منفی‌های کاذب: میانه 0.48 (IQR $0.42-0.54$)، هم‌پوشانی در بازهٔ $0.45-0.55$. تأیید می‌کند که موارد مرزی دشوارترین‌اند. آستانهٔ اطمینان (مثلاً فقط اقدام برای پیش‌بینی‌های با احتمال کمتر از 0.3 یا بیش از 0.7) می‌تواند دقت را به‌قیمت پوشش بهبود دهد.

۱۵.۵ معیارهای تفصیلی به تفکیک بیماری

جدول ۱۳.۵ AUROC، F1، Precision، و Recall را برای بهترین مدل (Random Forest) و Proposed_FewShot به‌ازای هر گرهٔ بیماری گزارش می‌کند. مدل RF به‌طور پیوسته از ETHOS

در همه گره‌ها بهتر است؛ بیشترین شکاف برای دیابت (node_5) است که ETHOS تنها AUROC ۰.۵۳ دارد. این نشان می‌دهد عوامل ویژه بیماری ممکن است تعمیم few-shot را متفاوت از مدل‌های کلاسیک تحت تأثیر قرار دهد.

جدول ۱۳.۵: معیارها به تفکیک بیماری (RF در برابر Proposed_FewShot)

گره	Proposed_FewShot				RF			
	Rec.	Prec.	F1	AUROC	Rec.	Prec.	F1	AUROC
سپسیس	0.58	0.54	0.56	0.61	0.70	0.66	0.68	0.74
قلبی	0.60	0.56	0.58	0.62	0.68	0.64	0.66	0.72
تنفسی	0.57	0.53	0.55	0.60	0.66	0.62	0.64	0.70
کلیوی	0.58	0.54	0.56	0.60	0.67	0.63	0.65	0.70
دیابت	0.52	0.48	0.50	0.53	0.62	0.58	0.60	0.64

۱۶.۵ کالیبراسیون و تحلیل حساسیت

خطای کالیبراسیون مورد انتظار (ECE) و بیشینه خطای کالیبراسیون (MCE) را برای RF و ETHOS محاسبه کردیم. RF: ECE ۰.۰۴، MCE ۰.۰۸؛ ETHOS: ECE ۰.۰۹، MCE ۰.۱۵. بیش‌اعتمادتر است؛ بازکالیبراسیون (مثلاً Platt scaling) می‌تواند قابلیت اطمینان احتمالات را بهبود دهد. تاب‌آوری نسبت به تقسیم‌های تصادفی مختلف (بذرهای ۴۲، ۱۲۳، ۴۵۶) نیز ارزیابی شد: RF AUROC 0.76 ± 0.01 ؛ ETHOS AUROC 0.62 ± 0.02 . نتایج در تقسیم‌ها پایدارند. اهمیت ویژگی (Gini) در اعتبارسنجی متقاطع ۵ لایه نشان می‌دهد ویژگی‌های برتر (کراتینین، گلوکز، هموگلوبین) پایدارند (همبستگی رتبه بزرگتر از ۰.۹ بین دوره‌های اعتبارسنجی).

۱۷.۵ تحلیل خطا به‌ازای ویژگی

تحلیل کردیم کدام ویژگی‌ها با طبقه‌بندی اشتباه بیشتر همراه‌اند. برای مثبت‌های کاذب (امکان‌پذیری پیش‌بینی‌شده، غیرممکن واقعی): کراتینین و لاکتات اغلب در بازه پایین-نرمال‌اند و مدل را به کم‌برآوردن ریسک سوق می‌دهند. برای منفی‌های کاذب (غیرممکن پیش‌بینی‌شده، امکان‌پذیر واقعی): سن و نمره SOFA گاهی بالا هستند با وجود ترخیص مطلوب؛ مدل ممکن است بیش‌محافظه‌کار باشد. این الگو

نشان می‌دهد افزودن اطلاعات روند (بهبود در برابر وخامت) و یادداشتهای بالینی می‌تواند خطاها را کاهش دهد. بازنمایی فعلی از تجمیع ۲۴ ساعت اول استفاده می‌کند و پویایی زمانی را نمی‌گیرد.

۱۸.۵ تحلیل ROC و دقت-بازخوانی

منحنی ROC نرخ مثبت واقعی (حساسیت) را در برابر نرخ مثبت کاذب ($1 - \text{اختصاصیت}$) در آستانه‌های مختلف نشان می‌دهد. AUROC برابر ۰.۷۶ یعنی در حدود ۷۶٪ موارد، مدل به یک بیمار واقعاً امکان‌پذیر امتیاز بالاتری از یک بیمار واقعاً ناممکن می‌دهد. در داده نامتعادل، منحنی دقت-بازخوانی نیز اهمیت دارد. در آستانه پیش‌فرض ۰.۵۴، مدل RF دقت ۰.۶۷ و بازخوانی ۰.۶۹ دارد. برای استقرار، آستانه باید بر اساس هزینه مثبت کاذب، مانند ترخیص زودهنگام، و منفی کاذب، مانند تأخیر در ترخیص، تنظیم شود. آستانه پایین‌تر بازخوانی را افزایش می‌دهد اما هشدارهای کاذب بیشتری تولید می‌کند؛ بنابراین نقطه قابل قبول باید با مشارکت ذی‌نفعان بالینی و بر اساس اولویت‌های هر مؤسسه تعیین شود.

۱۹.۵ منحنی‌های یادگیری و کارایی داده

مجموعه آموزش به ۲۵٪، ۵۰٪، ۷۵٪ و ۱۰۰٪ زیرنمونه‌برداری شد و AUROC آزمون اندازه‌گیری گردید. برای Random Forest مقادیر به ترتیب ۰.۶۸، ۰.۷۲، ۰.۷۵ و ۰.۷۶ بود. برای FewShot+ETHOS نیز مقادیر ۰.۵۵، ۰.۵۸، ۰.۶۰ و ۰.۶۲ به دست آمد. هر دو مدل از افزایش داده سود می‌برند، اما شیب بهبود RF بیشتر است؛ یعنی در این وظیفه، مدل کلاسیک از داده موجود کارا تر استفاده می‌کند. با تنها ۲۵٪ داده آموزش، یعنی ۳۲۰ نمونه، RF هنوز به AUROC برابر ۰.۶۸ می‌رسد که برای تنظیمات کم‌داده قابل قبول است. در مقابل، ETHOS برای رسیدن به عملکرد مشابه به داده بیشتری نیاز دارد. این نتیجه استفاده از مدل‌های کلاسیک را در سناریوهایی که داده کافی وجود دارد تقویت می‌کند و نقش few-shot را بیشتر برای سناریوهای فدرال یا واقعاً کم‌داده برجسته می‌سازد.

۲۰.۵ نتایج حساسیت ابرپارامتر

ابروپارامترهای کلیدی را تغییر دادیم و تغییر AUROC را اندازه گرفتیم. برای ETHOS: بعد جاسازی (۶۴، ۱۲۸، ۲۵۶)؛ بهترین ۱۲۸؛ تعداد لایه‌ها (۱، ۲، ۳)؛ بهترین ۲؛ dropout (۰.۱، ۰.۲، ۰.۳)؛ بهترین ۰.۲. AUROC در این بازه‌ها حدود ۰.۰۲ نوسان داشت. برای Random Forest: max_depth (۱۰،

۲۰، ۲۸، None؛ بهترین ۲۸؛ $n_estimators$ (۱۰۰، ۲۰۰، ۳۰۰)؛ بهترین ۲۰۰. AUROC از عمق ۱۰ به بالا و با دست کم ۲۰۰ برآوردگر، در حد ۰.۰۱ پایدار بود. مدل به تغییرات متوسط ابرپارامتر تاب‌آور است؛ بهترین پیکربندی را برای بازتولیدپذیری گزارش می‌دهیم.

۲۱.۵ تاب‌آوری تقسیم جایگزین

تاب‌آوری نسبت به تقسیم‌های تصادفی مختلف با بذره‌های ۴۲، ۱۲۳، و ۴۵۶ ارزیابی شد. برای هر بذر، تقسیم‌های آموزش/اعتبار/آزمون را دوباره تولید کردیم (طبقه‌بندی‌شده، همان نسبت ۲۰/۱۶/۶۴) و همه مدل‌ها را دوباره آموزش دادیم. نتایج: 0.76 ± 0.01 AUROC RF؛ 0.62 ± 0.02 ETHOS؛ 0.72 ± 0.01 ETHOS_RF_Hybrid. رتبه‌بندی مدل‌ها در تقسیم‌ها پایدار است. بذر ۴۲ را به‌عنوان نتیجه اصلی برای بازتولیدپذیری گزارش می‌دهیم؛ واریانس کوچک نشان می‌دهد نتیجه‌گیری‌ها به یک تقسیم خاص حساس نیستند.

۲۲.۵ تحلیل معماری مدل تقویت‌شده

به صورت سیستماتیک تقویت‌های معماری برای بهبود عملکرد FewShot+ETHOS بررسی شد. جدول ۱۴.۵ تأثیر هر تقویت در چارچوب نمونه‌اولیه اصلی را خلاصه می‌کند.

جدول ۱۴.۵: تحلیل اولیه تقویت معماری برای FewShot+ETHOS (روایت تاریخی توسعه، فقط نمونه‌اولیه)

تقویت	AUROC	F1	AUROC Δ	یادداشت
خط پایه تاریخی	0.619	0.580	—	ارزیابی اپیزودیک، 500 اپیزود
weight decay + AdamW +	0.613	0.576	-0.006	منظم‌سازی
Cosine annealing LR +	0.612	0.578	-0.007	زمان‌بندی LR
+ ارزیابی چنداپیزودی (20)	0.611	0.573	-0.008	میانگین روی 20 اپیزود
+ ارزیابی پشتیبان آموزش کامل	0.611	0.573	-0.008	پروتکل نظارت‌شده
+ ProjectionMLP (128→64)	0.612	0.578	-0.007	فضای متریک
+ Focal + وزن کلاس	0.611	0.576	-0.008	نامتعادلی
+ 1,200 اپیزود	0.610	0.570	-0.009	آموزش بیشتر
بهترین ترکیب تاریخی	0.619	0.580	0.000	چیدمان اصلی

نتایج اولیه نشان داد مدل FewShot+ETHOS به تغییر تک‌جزء تاب‌آور است اما در چارچوب فقط

نمونه‌اولیه مقاوم به بهبود مانده است. این انگیزه‌ای برای دور دوم تقویت‌های بنیادی‌تر بود.

۲۳.۵ راهبردهای آموزش بهبودیافته

یادداشت خواننده (اسنپ‌شات ارسال). زیربخش‌های زیر مسیر توسعه گسترده V1-V6 را توسعه توصیف می‌کنند (روش‌شناسی و بنچمارک‌های میانی آن کمپین). اعدادی که برای این پایان‌نامه منجمد شده‌اند جداول همگام شده با مخزن در ابتدای فصل ۵ است (AUROC آزمون جدولی SOTA ۰.۷۴۸؛ انباشتی `exp_fewshot_best` [0.699, 0.797]؛ `Proposed_FewShot Exp1` ۰.۷۴۶؛ و غیره) و پیوست د. جایی که روایت به ۰.۷۳۲، ۰.۷۳۷، ۰.۷۶۰ استناد می‌کند، مگر همان مقدار در آن جداول اولیه ظاهر شود، آن را خروجی تاریخی کمپین V بدانید.

بر اساس تحلیل محدودیت‌های مدل نمونه‌اولیه، سه راهبرد بهبود مکمل توسعه دادیم. جدول ۱۵.۵ نتایج را خلاصه می‌کند.

۱.۲۳.۵ راهبرد ۱: سر نمونه‌اولیه-رابطه ترکیبی با پیش‌تنظیم نظارت‌شده

شبکه نمونه‌اولیه شباهت را از راه فاصله کسینوسی تا مرکزهای کلاس محاسبه می‌کند که ضمناً مرزهای محدب کلاس در فضای جاسازی فرض می‌کند. برای شل کردن این فرض، سر شبکه رابطه (MLP) کوچک که تابع شباهت غیرخطی بین جاسازی‌های پرس‌وجو و نمونه‌های اولیه کلاس یاد می‌گیرد) معرفی شد. معماری نهایی از ترکیب درگاهی هر دو لگاریتم فاصله کسینوسی نمونه‌اولیه و لگاریتم‌های رابطه آموزش‌دیده استفاده می‌کند:

$$\text{logits} = \sigma(g) \cdot \text{logits}_{\text{proto}} + (1 - \sigma(g)) \cdot \text{logits}_{\text{relation}} \quad (۱.۵)$$

که در آن g پارامتر درگاه قابل‌یادگیری و σ تابع سیگموئید است.

همچنین پیش‌تنظیم نظارت‌شده رمزگذار افزودیم: پیش از آموزش اپیزودیک، رمزگذار ETHOS ابتدا با زبان آنتروپی متقاطع نظارت‌شده روی کل مجموعه آموزش (با هموارسازی برچسب ۰.۰۵) آموزش می‌بیند. این به رمزگذار بازنمایی‌های اولیه بهتری برای فاز اپیزودیک بعدی می‌دهد. جزئیات آموزش در دو مرحله اجرا شد: ابتدا ۴۰ دوره پیش‌تنظیم نظارت‌شده با AdamW، نرخ

یادگیری 5×10^{-4} و وزن زدایی 10^{-4} . سپس ۱,۵۰۰ اپیزود آموزش اپیزودیک با افزایش داده اجرا شد (نویز گاوسی $\sigma = 0.03$ ، ماسک ۵٪ ویژگی). ارزیابی از ensemble ۸۰ اپیزود با مجموعه‌های پشتیبان متفاوت به همراه یک ارزیابی پشتیبان کامل استفاده می‌کند.

۲.۲۳.۵ راهبرد ۲: ترکیبی بهبودیافته (XGBoost + ETHOS)

Random Forest در معماری ترکیبی را با XGBoost جایگزین کردیم، با RandomizedSearchCV ۵۰ آزمون و اعتبارسنجی متقاطع ۵ لایه طبقه‌ای. ترکیب، جاسازی‌های ۱۲۸ بعدی ETHOS (از رمزگذار پیش تنظیم شده نظارت شده) را با ویژگی‌های جدولی اصلی ۲۵ بعدی می‌چسباند و ورودی ۱۵۳ بعدی می‌سازد. تقویت گرادیان XGBoost اطلاعات مکمل بین بازنمایی‌های آموزش دیده و ویژگی‌های خام را بهتر بهره می‌برد. تنظیم آستانه روی اعتبارسنجی F1 را بیشینه می‌کند.

۳.۲۳.۵ راهبرد ۳: طبقه‌بند نظارت شده ETHOS

به عنوان مرز بالای توان رمزگذار ETHOS، سر طبقه‌بند ۳ لایه مستقیماً روی جاسازی‌های رمزگذار (2→64→128→128) با وزن دهی کلاس، هموارسازی برچسب، و توقف زودهنگام بر اساس AUROC اعتبارسنجی آموزش دادیم. این پارادایم آموزش اپیزودیک را به طور کامل دور می‌زند.

۴.۲۳.۵ راهبرد ۴: FewShot V2؛ آموزش چندفازی با SupCon

با اتکا به بینش‌های راهبردهای ۱-۳، نسخه جامع V2 با پنج نوآوری کلیدی ساخته شد:

۱. **مهندسی ویژگی:** گسترش ویژگی‌های اصلی ۲۲ بعدی با نسبت‌های جفتی، حاصل ضرب‌های تعاملی، و جملات مربع، فضای ویژگی را به ۵۵ بعد می‌رساند. این به رمزگذار سیگنال غنی‌تری برای یادگیری می‌دهد.

۲. **پیش آموزش SupCon:** به جای آنتروپی متقاطع استاندارد، ابتدا رمزگذار را با زیان مقابله‌ای که صریحاً جاسازی‌های هم کلاس را نزدیک و غیرهم کلاس را دور می‌کند آموزش می‌دهیم. این فضای جاسازی خوشه شده می‌سازد؛ دقیقاً هندسی که شبکه‌های نمونه اولیه نیاز دارند.

۳. **آموزش چندفازی:** آموزش در سه فاز انجام می‌شود: (الف) پیش آموزش SupCon (۲۵ دوره) → (ب) تنظیم دقیق نظارت شده با زیان کانونی و وزن دهی کلاس (۲۰ دوره با توقف زودهنگام

مبتنی بر اعتبارسنجی) $\rightarrow$ (ج) فرا آموزش اپیزودیک (۱,۵۰۰ اپیزود) با افزایش نویز گاوسی و برنامه‌ریزی درسی K .

۴. **پالایش نمونه‌اولیه تراپردی:** در استنتاج، پالایش soft k-means (۱۰ تکرار) با آمار مجموعه پرس‌وجوی بدون برچسب برای تنظیم نمونه‌های اولیه اعمال می‌کنیم و عملاً به توزیع آزمون سازگار می‌شویم.

۵. **ensemble چندبذری:** دو مدل با بذرها متفاوت آموزش دیده با پروتکل‌های ارزیابی پشتیبان کامل و اپیزود نمونه‌برداری شده ترکیب می‌شوند تا پیش‌بینی تاب‌آور شود.

معماری رمزگذار از تجمیع مبتنی بر توجه (به‌جای توکن CLS) با جاسازی‌های موقعیتی استفاده می‌کند و سر few-shot لگاریتم‌های نمونه‌اولیه کسینوسی و شبکه رابطه را از راه درگاه آموزش دیده ترکیب می‌کند.

۵.۲۳.۵ راهبرد ۵: FewShot V3؛ تقطیر دانش از Random Forest

ایده اصلی در V3 این است که معلم Random Forest با AUROC برابر ۰.۷۶۰ دانشی دارد که می‌تواند از راه تقطیر دانش (KD) به رمزگذار few-shot منتقل شود. به‌جای یادگیری صرفاً از برچسب‌های سخت، رمزگذار خروجی‌های نرم RF را نیز می‌آموزد و مرزهای تصمیم RF را به فضای جاسازی فشرده منتقل می‌کند. V3 نسبت به V2 سه نوآوری افزود:

۱. **تقطیر دانش:** در هر دو فاز SupCon و نظارت‌شده، رمزگذار با زیان ترکیبی آموزش می‌بیند:

$$\mathcal{L} = \mathcal{L}_{\text{task}} + \alpha \cdot \mathcal{L}_{\text{KD}} \quad \text{که} \quad \mathcal{L}_{\text{KD}} = T^2 \cdot \text{KL}(\sigma(\mathbf{z}_s/T) \parallel \sigma(\mathbf{z}_t/T)) \quad \text{واگرایی KL}$$

بین پیش‌بینی‌های نرم شاگرد و معلم در دمای T است. از $T = 3-4$ و $\alpha = 0.4-0.5$ استفاده می‌کنیم.

۲. **مهندسی ویژگی غنی‌تر:** فضای ویژگی از ۲۲ به ۹۲ بعد با نسبت‌های جفتی، حاصل ضرب‌ها، جملات مربع، تبدیل‌های لگاریتمی، و آمار خلاصه به‌ازای نمونه (میانگین، انحراف معیار، میانه، شمار مقادیر بالا/پایین) گسترش یافت.

۳. **افزایش داده در زمان آزمون (TTA):** در ارزیابی، ۵ نسخه افزایش یافته از هر نمونه آزمون (نویز گاوسی $\sigma = 0.015$) ساخته و پیش‌بینی‌ها روی ورودی‌های افزایش یافته و اصلی میانگین می‌شوند تا واریانس کاهش یابد.

ensemble سه‌بذری (بذرهای ۴۲، ۴۹، ۵۵) AUROC پایدار به‌ازای بذر ۰.۷۰۱-۰.۷۰۶ دارد و ensemble به ۰.۷۱۲ می‌رسد. عملکرد بهترین مدل تکی به‌ازای بذر از قبل با V2 ensemble (۰.۶۸۹) رقابتی است و نشان می‌دهد تقطیر دانش به‌تنهایی حدود ۰.۰۱۵ بهبود AUROC می‌دهد.

۶.۲۳.۵ راهبرد ۶: FewShot V4 ؛ Proto-MAML، ترنسفورمر ویژگی

گروه‌بندی‌شده، و فرا یادگیر انباشتی

V4 سه تکنیک نوآورانه برای امکان استقرار بالینی معرفی می‌کند:

۱. **Proto-MAML (سازگاری زمان آزمون):** در زمان ارزیابی، مدل آموزش دیده را کلون

می‌کنیم و ۸ گام گرادیان روی مجموعه پشتیبان پیش از پیش‌بینی روی پرس‌وجو انجام می‌دهیم. این پارامترهای مدل (به‌ویژه دما، بایاس کلاس، و شبکه رابطه) را به هر وظیفه ارزیابی خاص سازگار می‌کند. Proto-MAML رویکرد استاندارد در یادگیری few-shot است و امکان تنظیم دقیق به هر کوهورت بیمار را فراهم می‌کند. حلقه درونی از SGD با نرخ یادگیری ۰.۰۱ برای پارامترهای سر و 10^{-4} برای رمزگذار با برش گرادیان ۱.۰ استفاده می‌کند.

۲. **ترنسفورمر ویژگی گروه‌بندی‌شده:** به‌جای قالب توکن علامت ETHOS اصلی (که توکن‌های

۴ بعدی خاص می‌طلبد)، از یک رمزگذار ترنسفورمر تمیز استفاده می‌کنیم که ۹۲ ویژگی مهندسی‌شده را در توکن‌های اندازه ۴ گروه‌بندی می‌کند، جاسازی‌های موقعیتی آموزش دیده اعمال می‌کند، و از ۲ لایه خودتوجه با تجمیع مبتنی بر توجه عبور می‌دهد. این معماری به قالب ورودی بی‌طرف است و از مکانیزم‌های ضرب شدت و بایاس هم‌وقوعی که رمزگذار ETHOS اصلی را به ساختار توکن خاص محدود می‌کند، اجتناب می‌کند.

۳. **فرا یادگیر انباشتی:** یک رگرسیون لجستیک کالیبره شده (با کالیبراسیون ایزوتونیک،

اعتبارسنجی متقاطع ۳ لایه) پنج سیگنال ورودی را ترکیب می‌کند: (الف) احتمالات ensemble few-shot، (ب) احتمالات RF، (ج) حاصل ضرب آن‌ها (سیگنال توافق)، (د) قدرمطلق تفاوت (سیگنال اختلاف)، و (ه) ۱۰ مؤلفه اول PCA از جاسازی‌های میانگین رمزگذار. این فرا یادگیر بهینه قوت‌های مکمل few-shot و کلاسیک را می‌آمیزد: مدل few-shot هندسه فضای جاسازی را می‌گیرد و به ساختار وظیفه سازگار می‌شود، در حالی که RF در افراز مستقیم ویژگی عالی است.

پروتکل ارزیابی استنتاج پشتیبان کامل استاندارد (وزن $2 \times$)، سازگاری پشتیبان کامل Proto-MAML (وزن $3 \times$)، پالایش نمونه‌اولیه ترابردی (وزن $2 \times$)، ۳ عبور TTA، و ۲۰ اپیزود نمونه‌برداری شده (۳ تا با سازگاری MAML) را ترکیب می‌کند. AUROC به‌ازای بذر از ۰.۶۹۶ تا ۰.۷۱۳ متغیر است. مدل انباشتی به AUROC ۰.۷۳۲ [0.684, 0.783] می‌رسد؛ تقریباً هم‌تراز با خط پایه RF (۰.۷۳۵) با شکاف تنها ۰.۰۰۳ تا RF بدون تنظیم و ۰.۰۲۸ تا RF با تنظیم آستانه. این نخستین پیکربندی است که خانواده معماری few-shot به تساوی آماری با سقف کلاسیک نزدیک می‌شود.

۷.۲۳.۵ راهبرد ۷: FewShot V5؛ توجه درگاهی به ویژگی، نمونه‌های

cross-attention، و تقطیر عمیق

بر پایه V4، نسخه V5 نوآوری معماری در پردازش ویژگی و محاسبه نمونه‌های اولیه را بررسی می‌کند:

۱. توجه درگاهی به ویژگی (GFA): با الهام از TabNet [Arik and Pfister, 2021]، V5

مکانیزم انتخاب ویژگی تطبیقی به‌ازای نمونه معرفی می‌کند. به‌جای یکسان‌رفتار با همه ویژگی‌ها، درگاه توجه چندگانه یاد می‌گیرد کدام ویژگی‌ها برای هر بیمار مرتبط‌ترند. در هر یک از $S = 3$ گام توجه، ماسک نرم ویژگی $\mathbf{a}_s = \text{softmax}(\mathbf{W}_s \mathbf{h} \odot \mathbf{p}_s)$ محاسبه می‌شود که $\mathbf{p}_s$ پیش‌مقیاس با $\mathbf{a}_{s-1} - \gamma$ کاهش یافته است و ویژگی‌های متفاوت در هر گام تشویق می‌شوند. بازنمایی‌های ویژگی ماسک‌شده در گام‌ها تجمیع و از راه درگاه آموزش‌دیده با مسیر ترنسفورمر می‌آمیزند.

۲. سر نمونه‌اولیه cross-attention: به‌جای مقایسه پرس‌وجوها با میانگین نمونه‌های اولیه از

طریق شباهت کسینوسی (شبکه نمونه‌اولیه استاندارد)، V5 از لایه cross-attention چندسر استفاده می‌کند که هر نمونه پرس‌وجو به‌طور هم‌زمان به همه نمونه‌های اولیه توجه می‌کند. این اجازه می‌دهد مدل توابع شباهت غیرخطی، وابسته به زمینه بین پرس‌وجوها و بازنمایی‌های کلاس یاد بگیرد و ساختار روابط غنی‌تر از معیارهای فاصله ساده بگیرد.

۳. منظم‌سازی سازگاری: در آموزش، پایداری پیش‌بینی تحت اختلال‌های کوچک ورودی ($\sigma =$

0.02) با جریمه KL اجبار می‌شود: $\mathcal{L}_{\text{consist}} = \text{KL}(p_{\theta}(\mathbf{x}) \| p_{\theta}(\mathbf{x} + \epsilon))$. این به‌عنوان

پیش‌زمینه همواری روی مرز تصمیم عمل می‌کند.

۴. مهندسی ویژگی گسترده‌شده: فضای ویژگی از ۹۲ به ۱۳۲ بعد با تعاملات بالینی سه‌جانبه

(ترکیب کراتینین، لاکتات، و BUN)، شاخص‌های چارک، و نسبت‌های ویژه حوزه (BUN/کراتینین، ALT/AST، shock index) گسترش یافت.

۵. **ensemble پنج‌بذری**: افزایش از ۳ به ۵ بذر واریانس ensemble را کاهش و تاب‌آوری را بهبود می‌دهد.

نتایج: V5 few-shot ensemble به AUROC ۰.۷۲۲ [0.669, 0.772] با AUROC به‌ازای بذر از ۰.۷۰۳ تا ۰.۷۳۷ می‌رسد؛ بالاترین AUROC تکی few-shot مشاهده‌شده در همه آزمایش‌ها. فرا یادگیر انباشتی V5 به AUROC ۰.۷۳۰ [0.680, 0.778]، F1 ۰.۶۶۱، و MCC ۰.۳۳۳ می‌رسد. ماژول GFA الگوهای توجه ویژگی معنادار بالینی یاد می‌گیرد: کراتینین، لاکتات، و هموگلوبین وزن‌های توجه بالا و پایدار دریافت می‌کنند، سازگار با رتبه‌بندی اهمیت ویژگی Random Forest.

۸.۲۳.۵ راهبرد ۸: FewShot V6 ؛ ensemble عمیق ناهمگن با انباشت

XGBoost

V6 می‌آزماید آیا تنوع معماری در ensemble می‌تواند با ترکیب رمزگذارهای ساختاراً متفاوت عملکرد را بیشتر بهبود دهد:

۱. **ensemble معماری ناهمگن**: به جای آموزش همان معماری با بذرهای متفاوت، V6 سه معماری بنیاداً متفاوت آموزش می‌دهد: (الف) **FT-Transformer**؛ جاسازی‌های آموزش‌دیده به‌ازای ویژگی با تجمیع توجه، (ب) **GFA-Transformer**؛ رمزگذار دومسیره که توجه درگاهی به ویژگی را با ترنسفورمر ویژگی گروه‌بندی‌شده می‌آمیزد، و (ج) **MLP-Mixer**؛ معماری بدون توجه با MLP‌های مخلوط‌کننده توکن و کانال. هر معماری با ۲ بذر آموزش داده می‌شود (۶ مدل).

۲. **انباشت XGBoost**: فرا یادگیر از رگرسیون لجستیک به درخت‌های تقویت‌شده گرادیان (XGBoost) ارتقا می‌یابد که روابط غیرخطی بین پیش‌بینی‌های مدل پایه را می‌گیرد. احتمالات ensemble به‌ازای هر معماری به‌عنوان ویژگی‌های انباشت جداگانه در کنار پیش‌بینی‌های RF و مؤلفه‌های PCA جاسازی قرار می‌گیرند.

۳. **پیش‌بینی مطابق (Conformal prediction)**: پیش‌بینی مطابق تقسیم‌شده مجموعه‌های پیش‌بینی معتبر با تضمین پوشش ($1 - \alpha = 0.90$) فراهم می‌کند. آستانه کالیبراسیون

مطابق $\hat{q} = 0.304$ میانگین اندازهٔ مجموعهٔ پیش‌بینی ۱.۴۰ می‌دهد، یعنی ۴۰٪ بیماران هر دو کلاس را در مجموعهٔ پیش‌بینی دریافت می‌کنند (موارد نامطمئن)، در حالی که ۶۰٪ پیش‌بینی تک‌کلاسه با پوشش حاشیه‌ای ۹۰٪ دارند.

نتایج: ensemble ناهمگن V6 به AUROC $0.725 \pm [0.676, 0.773]$ می‌رسد. نتایج به‌ازای معماری تغییر معنادار نشان می‌دهد: FT-Transformer (۰.۷۰۷)، GFA-Transformer (۰.۶۹۲)، و MLP-Mixer (۰.۶۴۲). عملکرد ضعیف‌تر MLP-Mixer، یعنی AUROC ۰.۰۶۵ پایین‌تر از FT-Transformer، نشان می‌دهد مکانیزم‌های خودتوجه برای یادگیری تعامل بین‌ویژگی در دادهٔ جدولی بالینی ضروری‌اند؛ مخلوط کردن توکن به‌تنهایی کافی نیست. مدل انباشتی V6 XGBoost (AUROC ۰.۶۸۹) از فرا یادگیر لجستیک V4 (۰.۷۳۲) به‌دلیل بیش‌برازش فرا یادگیر تقویت‌شدهٔ گرادیان روی مجموعهٔ اعتبارسنجی کوچک ($n = 320$) عقب می‌ماند.

بینش کلیدی: تنوع معماری به‌طور خودکار عملکرد ensemble را بهبود نمی‌دهد؛ ضعیف‌ترین معماری (MLP-Mixer) ensemble را بیش از آن‌که ناهمگنی کمک کند تخریب می‌کند. رویکرد V4، V5 یعنی ensemble چندبذری هم‌معماری با انباشت لجستیک کالیبره‌شده برای این مقیاس داده بهینه می‌ماند.

جدول ۱۵.۵: راهبردهای آموزش بهبودیافته در کمپین تاریخی V0–V6؛ همهٔ مدل‌ها روی همان مجموعهٔ آزمون

مدل	AU ROC	AU PRC	F1	Prec.	Rec.	Acc.	MCC	راهبرد
اصلی (تاریخی)	0.619	0.68	0.580	0.56	0.60	0.620	0.180	Proposed_FewShot (نمونه‌اولیه)
1	0.626	0.72	0.602	0.60	0.60	0.622	0.205	SupervisedPreFT + RelationNet
2	0.625	0.70	0.615	0.63	0.61	0.658	0.239	طبقه‌بند نظارت‌شده ETHOS
3	0.734	0.80	0.652	0.65	0.66	0.663	0.314	ترکیبی XGBoost + ETHOS
4	0.689	0.757	0.654	0.654	0.655	0.675	0.309	FewShot V2 (SupCon+تراپردی)
5	0.712	0.790	0.648	0.652	0.662	0.655	0.314	FewShot V3 (TTA+SupCon+KD)
6	0.711	0.790	0.652	0.652	0.662	0.670	0.304	FewShot V4 (Proto-MAML)
6	0.732	0.810	0.693	0.693	0.693	0.708	0.388	انباشتی V4 (Emb+RF+FS)
7	0.722	0.797	0.651	0.649	0.655	0.668	0.304	FewShot V5 (CrossAttn+GFA)
7	0.730	0.810	0.661	0.661	0.672	0.670	0.333	انباشتی V5 (Emb+RF+FS)
8	0.725	0.791	0.655	0.658	0.668	0.663	0.326	FewShot V6 (ensemble ناهمگن)
مرجع	0.760	0.81	0.682	0.67	0.69	0.703	0.364	RF_threshold_tuned

۹.۲۳.۵ تحلیل بهبودها

بهبودهای تدریجی چند یافتهٔ کلیدی را نشان می‌دهند:

۱. پیش‌آموزش SupCon دگرگون‌کننده است: بزرگ‌ترین سهم در بهبود V2 پیش‌آموزش

مقابله‌ای نظارت‌شده (راهبرد ۴) است. با بهینه‌سازی صریح برای ساختار جاسازی خوشه‌شده، SupCon دقیقاً هندسهٔ بازنمایی را می‌سازد که شبکه‌های نمونه‌اولیه نیاز دارند. این در تضاد با پیش‌آموزش آنتروپی متقاطع استاندارد (راهبرد ۱) است که تنها بازنمایی‌های کمی بهتر تولید می‌کند.

۲. **مهندسی ویژگی ظرفیت رمزگذار را تقویت می‌کند:** گسترش فضای ویژگی از ۲۲ به ۵۵ بعد از طریق جملات تعاملی، نسبت‌ها، و ویژگی‌های چندجمله‌ای سیگنال غنی‌تری به رمزگذار می‌دهد. ترنسفورمر ETHOS سپس می‌تواند به تعاملات بین‌ویژگی که در ویژگی‌های خام ضمنی‌اند توجه کند.

۳. **استنتاج تراپردی تقویت معنادار می‌دهد:** استفاده از آمار مجموعهٔ پرس‌وجو برای پالایش نمونه‌های اولیه در زمان آزمون (soft k-means, ۱۰ تکرار) مدل را به توزیع محلی آزمون سازگار می‌کند و AUROC را حدود ۰.۰۳-۰.۰۲ نسبت به ارزیابی غیرتراپردی بهبود می‌دهد.

۴. **آموزش چندفازی ضروری است:** آموزش سه‌فازی (SupCon → نظارت‌شده → اپیزودیک) از هر فاز تکی بهتر عمل می‌کند. هر فاز بر قبلی بنا می‌شود: SupCon ساختار اولیه می‌سازد، آموزش نظارت‌شده مرزهای تصمیم را صیقل می‌دهد، و آموزش اپیزودیک مدل را با پروتکل ارزیابی few-shot سازگار می‌کند.

۵. **تقطیر دانش تأثیرگذارترین نوآوری تکی است:** V3 با تقطیر دانش RF به AUROC برابر ۰.۷۱۲ می‌رسد و نسبت به V2 با مقدار ۰.۶۸۹، بهبود ۰.۰۲۳ دارد. KD مرزهای تصمیم RF را به‌خوبی به فضای جاسازی رمزگذار منتقل می‌کند.

۶. **فاصله تا مدل‌های کلاسیک به‌شدت کم می‌شود:** مدل V3 few-shot (AUROC ۰.۷۱۲) فاصله تا بهترین مدل کلاسیک (RF ۰.۷۶۰) را به تنها ۰.۰۴۸ AUROC کاهش می‌دهد (معادل کاهش ۶۶٪ از فاصلهٔ اولیه ۰.۱۴۱). بازه‌های اطمینان به‌طور قابل‌توجهی هم‌پوشانی دارند.

۷. **انباشت در کمپین V فاصله را کاهش می‌دهد:** فرا‌یادگیر انباشتی V4 با AUROC برابر ۰.۷۳۲ بخش زیادی از فاصله تا سطر RF در جدول ۱۵.۵ را می‌بندد. برای ادعاهای اصلی نسخهٔ ارسال، باید به اجرای انباشتی منجمد ۰.۷۴۶ در برابر ۰.۷۴۸ استناد شود و در صورت نیاز، آزمون‌های جفتی دوباره محاسبه شوند.

۸. **Proto-MAML سازگاری زمان آزمون را ممکن می‌کند:** با وجود آن که Proto-MAML

(گام‌های گرادیان زمان آزمون روی پشتیبان) برآورد نقطه‌ای را نسبت به V3 به‌طور محسوس بهبود نمی‌دهد (۰.۷۱۱ در برابر ۰.۷۱۲)، قابلیت حیاتی برای استقرار بالینی فراهم می‌کند: مدل می‌تواند در زمان استنتاج بدون آموزش مجدد به توزیع بیماران مؤسسه‌ویژه سازگار شود. این به‌ویژه در تنظیمات فدرال ارزشمند است که هر بیمارستان جمعیت‌شناسی متفاوتی دارد.

۹. توجه درگاهی به ویژگی بالاترین AUROC تکی few-shot را ایجاد می‌کند: V5 با GFA و نمونه‌های cross-attention بهترین مدل few-shot تکی را با بذر ۵۵ و AUROC برابر ۰.۷۳۷ تولید می‌کند. با این حال، میانگین ensemble پنج‌بذری (۰.۷۲۲) پایین‌تر از انباشتی V4 (۰.۷۳۲) است و نشان می‌دهد GFA به مقداردهی اولیه حساس‌تر است.

۱۰. تنوع معماری در این مقیاس داده کمک نمی‌کند: ensemble ناهمگن V6 (۰.۷۲۵) از ensemble‌های هم‌معماری V4، V5 عقب می‌ماند. معماری MLP-Mixer (AUROC ۰.۶۴۲) فاقد مکانیزم خودتوجه حیاتی برای تعامل بین‌ویژگی است و ensemble را پایین می‌کشد. این یافته با ادبیات اخیر یادگیری عمیق جدولی هم‌راستا است که معماری‌های مبتنی بر توجه را بر MLP در داده ساخت یافته برتر می‌داند.

۱۱. انباشت لجستیک کالیبره شده از انباشت XGBoost بهتر است: روی مجموعه اعتبارسنجی کوچک ($n = 320$)، فرا یادگیر تقویت شده گرادیان در V6 (AUROC ۰.۶۸۹) بیش‌برازش می‌کند، در حالی که رگرسیون لجستیک با کالیبراسیون ایزوتونیک در V4 (AUROC ۰.۷۳۲) خوب تعمیم می‌یابد. این نتیجه نشان می‌دهد برای فرا یادگیرهای آموزش دیده روی مجموعه‌های اعتبارسنجی کوچک، مدل‌های خطی منظم‌شده بر روش‌های ensemble غیرخطی ترجیح دارند.

با وجود این بهبودها، تفاوت‌های باقی‌مانده عملکرد را می‌توان به موارد زیر نسبت داد:

۱. **سربار بازنمایی:** بازنمایی توکن علامت از طریق ترنسفورمر پیچیدگی افزوده دارد، در حالی که مدل‌های درخت‌بنیاد مستقیماً فضای ویژگی را افراز می‌کنند. برای داده جدولی متوسط، این سربار تا حدی سود بازنمایی‌های آموزش‌دیده را خنثی می‌کند.

۲. **واریانس ارزیابی اپیزودیک:** حتی با میانگین‌گیری ensemble و پالایش تراپردی، پروتکل ارزیابی اپیزودیک واریانسی معرفی می‌کند که مدل‌های نظارت‌شده از آن اجتناب می‌کنند.

۳. **مقیاس داده:** با ۱,۲۸۰ نمونه آموزش، رمزگذار داده محدودی برای یادگیری بازنمایی‌های

قابل تعمیم دارد. SupCon با بهره‌وری بیشتر از برجسب‌های موجود این را تخفیف می‌دهد اما نمی‌تواند کاملاً جبران کند.

جمع‌بندی (هم‌تراز با جداول اولیه): اجرای انباشتی یکپارچه `exp_fewshot_best` به AUROC ۰.۷۴۶ می‌رسد، یعنی حدود ۰.۰۰۲ پایین‌تر از برآورد نقطه‌ای جدولی SOTA (۰.۷۴۸). روایت V1–V6 و جدول ۱۵.۵ همچنان به‌عنوان نقشه‌راه روش‌شناختی ارزشمند است؛ اما ادعاهای چکیده و خلاصه اجرایی باید ابتدا به جداول اولیه استناد کنند.

۲۴.۵ جمع‌بندی فصل

این فصل نتایج را در چهار سطح گزارش کرد: (۱) سقف جدولی SOTA (AUROC ۰.۷۴۸ آزمون)؛ (۲) ترکیبی و `few-shot` + انباشت `exp_fewshot_best` (۰.۷۴۶ انباشتی، ۰.۶۷۰ فقط `few-shot`)؛ (۳) مقایسه اسکرپت `Exp1` (Proposed_FewShot) ۰.۶۱۱ در برابر RF ۰.۷۶۲ روی همان تقسیم؛ و (۴) فدرال در برابر متمرکز، با شکاف حدود ۰.۰۰۵ AUROC، به‌همراه تحلیل‌های K -شات، حذف تدریجی، و بین‌گره‌ای. همچنین کمپین آموزش گسترده V1–V6 (جدول ۱۵.۵) را برای بازتولیدپذیری و گسترش‌های آینده مستند کردیم. تفسیرپذیری، اشکال کالیبراسیون، و مطالعات موردی خوانش گرایش به استقرار را پشتیبانی می‌کنند مشروط به محدودیت‌های فصل ۷.


فصل ۶

تحلیل داده و یافته‌های اکتشافی

این فصل تصویری منسجم از کوهورت MIMIC-IV ارائه می‌کند: توزیع داده‌ها، همبستگی ویژگی‌ها، کیفیت داده و چند تصویرسازی اکتشافی که مبنای تصمیم‌های مدل‌سازی در فصل‌های بعد هستند.

۱.۶ طرحواره و گردش داده MIMIC-IV

شکل ۱.۶ رابطه جدول‌های MIMIC-IV و روند پیش‌پردازش را به صورت خلاصه نشان می‌دهد.



شکل ۱.۶: طرح استخراج MIMIC-IV: جدول‌های منبع، کلیدهای اتصال، و پیش‌پردازش به بازنمایی‌های جدولی و توکنی (نمودار برداری؛ تک‌رنگ برای چاپ).

جدول ۱.۶ روند استخراج و پیش‌پردازش داده MIMIC-IV را خلاصه می‌کند. ابتدا patients،

admissions و icustays بر اساس subject_id و hadm_id به هم متصل می‌شوند؛ سپس labevents و chartevents از طریق stay_id به اقامت‌های ICU پیوند می‌خورند. در مرحله پیش‌پردازش، ۱۵ آزمایش و ۷ علامت حیاتی انتخاب و به بازه [۱،۰] نرمال می‌شوند. سپس ویژگی‌های مهندسی‌شده ساخته می‌شود و برای هر بیمار یا بردار جدولی ۲۵ بعدی، یا دنباله توکن مناسب رمزگذار ETHOS با جاسازی ۱۲۸ بعدی تولید می‌گردد. برای شبیه‌سازی فدرال، کوهورت بر اساس تشخیص اصلی ICD-10 لایه‌بندی می‌شود.

جدول ۱.۶: گردش استخراج و پردازش داده MIMIC-IV

مرحله	ورودی	خروجی
استخراج	admissions, patients, icustays	اقامت‌های ICU با جمعیت‌شناسی
	labevents, chartevents (stay_id)	آزمایشگاه و علائم حیاتی به‌ازای هر اقامت
انتخاب	15 آزمایش + 7 علامت حیاتی	ItemID ها از d_items, d_labitems
نرمال‌سازی	مقادیر خام	[1,0] min-max
مهندسی	مقادیر نرمال‌شده	پراکسی SOFA، شاخص شوک، شمار غیرطبیعی
بازنمایی	ویژگی‌های مهندسی‌شده	جدولی 25-بعدی دنباله توکن
رمزگذاری	دنباله توکن	ETHOS → جاسازی 128-بعدی
خروجی: 2,000 بیمار؛ هر کدام 25 ویژگی به‌اضافه برچسب		

۲.۶ جمعیت‌شناسی کوهورت

جدول ۲.۶ آمار جمعیت‌شناختی کوهورت را نشان می‌دهد. در نمونه ۲,۰۰۰ بیمار، نرخ امکان‌پذیری درمان حدود ۴۲٪ است و ۵۸٪ نمونه‌ها در گروه ناممکن قرار می‌گیرند؛ این عدم تعادل نسبی نشان می‌دهد پیش‌بینی ترخیص ICU مسئله‌ای ساده و کاملاً جداپذیر نیست. توزیع سن نیز به سمت سنین بالاتر کشیده شده و بیشتر بیماران در بازه ۶۰ تا ۸۰ سال قرار دارند.

جدول ۲.۶: جمعیت‌شناسی گسترده کوهورت

مقدار	معیار
2,000	کل بیماران
840 (42%)	ممکن (برچسب=1)
1,160 (58%)	ناممکن (برچسب=0)
64.2	میانگین سن (سال)
67	میانه سن (سال)
90-18	دامنه سن
44%	زن
56%	مرد
72.4	میانگین طول اقامت ICU (ساعت)
48	میانه طول اقامت ICU (ساعت)

۳.۶ توزیع گره بیماری

جدول ۴.۶ توزیع بیماران را در پنج گره بیماری نشان می‌دهد. برای شفافیت و بازتولیدپذیری، جدول ۳.۶ نیز چند کد نمونه از ICD-10 را برای هر گره فهرست می‌کند.

جدول ۳.۶: نمونه‌هایی از کدهای ICD-10 به تفکیک گره بیماری

گره	کد شرح
1	A40، A41 استرپتوکوکی/سپسیس
1	R652 سپسیس شدید
2	I21، I22 انفارکتوس حاد میوکارد
2	I50 نارسایی قلبی
3	J18، J44 پنومونی، COPD
3	J96 نارسایی تنفسی
4	N17، N18، N19 نارسایی حاد/مزمن کلیه
5	E10، E11، E13 دیابت قندی


گره‌های سپسیس و قلبی از نظر تعداد نمونه بزرگ‌ترند، در حالی که گره‌های کلیوی و دیابت نمونه‌های کمتری دارند. همین تفاوت اندازه، استفاده از رویکردهای few-shot و فدرال را برای گروه‌های کم‌داده توجیه می‌کند.

جدول ۴.۶: توزیع بیماران به تفکیک گره بیماری

بیماران درصد ممکن	گره تشخیصی
38 412	1 سپسیس (R652, A41, A40)
45 398	2 قلبی (I21, I22, I25, I50, و غیره)
41 356	3 تنفسی (J18, J44, J96, و غیره)
39 418	4 کلیوی (N17, N18, N19)
46 416	5 دیابت (E10, E11, E13)

۴.۶ همبستگی آزمایشگاه و علائم حیاتی


کراتینین با BUN همبستگی بالایی دارد ($r > 0.7$) و هر دو شاخصی از عملکرد کلیه‌اند. هموگلوبین و پلاکت‌ها نیز بخشی از الگوی خون‌شناختی بیمار را منعکس می‌کنند، و در بیماران بحرانی گلوکز و لاکتات می‌توانند هم‌زمان افزایش یابند. این همبستگی‌ها برای مهندسی ویژگی مهم‌اند، زیرا نشان می‌دهند کدام ویژگی‌ها اطلاعات مکمل دارند و کدام‌ها ممکن است تا حدی افزونه باشند.



شکل ۲.۶: ماتریس همبستگی پیرسون برای آزمایشگاه‌ها و علائم حیاتی (ساختار گویای کوهورت آموزش).

۵.۶ پراکسی SOFA و شدت بالینی

پراکسی SOFA از کراتینین، پلاکت‌ها، SpO_2 ، و لاکتات محاسبه می‌شود. SOFA بالاتر (اختلال اندام بدتر) با امکان‌پذیری پایین‌تر همبسته است، همان‌طور که بالینی انتظار دارد. میانگین پراکسی SOFA برای بیماران ممکن ۰.۳۵ در برابر ۰.۵۲ برای ناممکن است ($p < 0.001$ ، رتبه‌جمع ویلکسون).




شکل ۳.۶: پراکسی SOFA در برابر کراتینین (نرمال‌شده) به تفکیک برچسب امکان‌پذیری؛ SOFA و کراتینین بالاتر با ترکیبی ناممکن همراه‌اند.

۶.۶ عملکرد لایه‌بندی شده بر اساس سن

بیماران ۶۵ سال و بالاتر نرخ امکان‌پذیری پایین‌تری دارند (۳۷٪)؛ این نرخ برای گروه ۱۸ تا ۴۵ سال ۵۱٪ و برای گروه ۴۵ تا ۶۵ سال ۴۴٪ است. AUROC مدل در گروه ۶۵ سال و بالاتر نیز اندکی پایین‌تر از کل کوهورت است (۰.۷۲ در برابر ۰.۷۶). این تفاوت نشان می‌دهد که در صورت استقرار بالینی، ارزیابی انصاف و پایش عملکرد در زیرگروه‌های سنی ضروری است.


۷.۶ تحلیل خطا: کراتینین

کراتینین از ویژگی‌های برتر است. طبقه‌بندی‌های اشتباه در بازه‌های مرزی (کراتینین نرمال شده ۰.۳-۰.۵) خوشه‌بندی می‌شوند، جایی که عملکرد کلیه نه کاملاً طبیعی است و نه شدیداً مختل. در



شکل ۴.۶: AUROC آزمون لایه‌بندی‌شده بر سن: Random Forest، انباشت V4، و خط پایه FewShot+ETHOS.


این بازه‌ها نرخ خطا حدود ۴۰٪ در برابر ۲۰٪ در بازه‌های شدید است.



شکل ۵.۶: نرخ خطای طبقه‌بندی به تفکیک بازه کراتینین (RF در برابر ETHOS) با شمار بیماران.

۸.۶ تصویرسازی جاسازی (t-SNE)

نمای t-SNE از جاسازی‌های ETHOS نشان می‌دهد بیماران ممکن و ناممکن تا حدی از هم جدا می‌شوند، اما هم‌پوشانی میان دو کلاس همچنان قابل توجه است. این الگو با عملکرد متوسط مدل few-shot سازگار است. امتیاز سیلوئت برای پارتیشن دوکلاسه برابر ۰.۱۲ است؛ یعنی ساختار خوشه‌ای ضعیف اما کاملاً تصادفی نیست.




شکل ۶.۶: t-SNE جاسازی‌های ETHOS (بیماران آزمون): هم‌پوشانی جزئی کلاس‌های ممکن در برابر ناممکن.

۹.۶ تحلیل نمونه


در شبکه‌های نمونه‌ای، برای هر کلاس یک نمونه اولیه ساخته می‌شود که برابر میانگین جاسازی‌های مجموعه پشتیبان است. فاصله اقلیدسی میان دو نمونه اولیه در فضای جاسازی ۱۲۸ بعدی برابر ۳.۴۲ است. این فاصله نشان می‌دهد سر few-shot تا حدی توان تفکیک دارد، اما جداسازی کلاس‌ها قوی نیست. بیماران پرس‌وجو بر اساس نزدیک‌ترین نمونه اولیه طبقه‌بندی می‌شوند.

۱۰.۶ نمونه خط زمانی بیمار

الگوهای زمانی، مانند کاهش کراتینین یا پایداری علائم حیاتی، برای برآورد امکان‌پذیری ترخیص اطلاعات مهمی فراهم می‌کنند. برای نمونه، بیماری که کراتینین او در ۲۴ ساعت از ۲.۱ به ۱.۴ mg/dL کاهش یافته و هم‌زمان ضربان قلب او در بازه ۷۵ تا ۸۵ bpm و فشار خون سیستولیک او در بازه ۱۲۰ تا ۱۳۰ mmHg پایدار مانده است، احتمال امکان‌پذیری بالاتری دارد (۰.۷۸). توکن‌سازی در این پژوهش چنین مسیرهای زمانی را به بازنمایی با طول ثابت تبدیل می‌کند.



شکل ۷.۶: شمایک مجموعه‌های پشتیبان، نمونه‌های کلاس، و طبقه‌بندی پرس‌وجو در فضای جاسازی (پیش‌نمایش دوبعدی).



شکل ۸.۶: نمونه مسیر ۲۴ ساعت اول ICU: ضربان قلب، فشار خون، و کراتینین (گویای).

۱۱.۶ تعادل کلاس

SMOTE را برای مدیریت عدم تعادل ۵۸/۴۲ بررسی کردیم. در این وظیفه، وزن دهی کلاس در تابع زیان و تنظیم آستانه روی مجموعه اعتبارسنجی کافی بود و SMOTE بهبود پایداری ایجاد نکرد. به نظر می‌رسد شدت عدم تعادل در این کوهورت متوسط است و برای بخش قابل توجهی از نمونه‌ها، مرز تصمیم با روش‌های ساده‌تر نیز قابل یادگیری است.

۱۲.۶ فقدان داده و کیفیت داده

در داده بالینی، مقادیر گم شده پدیده‌ای رایج است؛ زیرا آزمایش‌ها با نظم یکسان برای همه بیماران درخواست نمی‌شوند و نیازهای بالینی هر بیمار متفاوت است. در این کوهورت، مقادیر آزمایشگاهی مانند لاکتات و تروپونین بیشتر از علائم حیاتی معمول مانند ضربان قلب و فشار خون گم می‌شوند. برای توکن‌سازی، در سری‌های زمانی از forward-fill و برای ویژگی‌هایی که کاملاً گم شده‌اند از میانه جمعیت استفاده می‌شود. جدول ۵.۶ نرخ فقدان را به تفکیک دسته ویژگی خلاصه می‌کند. ویژگی‌هایی با فقدان بیش از ۳۰٪، مانند لاکتات در برخی بیماران غیرسپتیک، در استقرار واقعی به پایش و رسیدگی دقیق‌تری نیاز دارند.

جدول ۵.۶: نرخ فقدان به تفکیک دسته ویژگی (24 ساعت اول)

دسته ویژگی	درصد گم شده	جایگزینی
آزمایشگاه‌های معمول (کراتینین، گلوکز)	12±5	میانه
آزمایشگاه‌های تخصصی (لاکتات، تروپونین)	35±18	میانه
علائم حیاتی (SpO2, BP, HR)	8±2	Forward-fill
مهندسی شده (SOFA, شاخص شوک)	0	مشتق

۱۳.۶ ارزیابی کیفیت داده

کیفیت داده را با چند معیار سنجیدیم: (۱) **کامل بودن**: سهم مقادیر غیرگم شده به ازای هر ویژگی؛ آزمایشگاه‌های معمول (کراتینین، سدیم) بیش از ۹۰٪ کامل هستند؛ آزمایشگاه‌های تخصصی (لاکتات، تروپونین) ۶۵-۸۰٪. (۲) **باورپذیری**: مقادیر در بازه‌های بالینی (مثلاً کراتینین ۰.۱-۳۰ mg/dL)؛ پرت‌ها را برش می‌دهیم. (۳) **سازگاری**: بدون تناقض (مثلاً ترخیص پیش از پذیرش)؛ زمان‌بندی‌ها

را اعتبارسنجی کردیم. (۴) نمایندگی: کوهورت با توزیع سن و جنس MIMIC-IV همخوان است؛ نمونه‌برداری لایه‌ای ما تعادل بین گره‌های بیماری را تضمین می‌کند. این بررسی‌ها اعتبار نتایج تجربی را پشتیبانی می‌کنند.

۱۴.۶ الگوهای زمانی

روندهای زمانی در ۲۴ ساعت نخست بستری بررسی شد. بیمارانی که آزمایش‌های آنان مسیر بهبود را نشان می‌دهد، برای مثال کاهش کراتینین یا پایداری گلوکز، معمولاً نرخ امکان‌پذیری بالاتری دارند. پراکسی SOFA محاسبه‌شده از اوج مقادیر ۲۴ ساعت نخست نیز با امکان‌پذیری همبسته است (بخش ۵.۶). در این پژوهش، اطلاعات زمانی به دنباله توکنی با طول ثابت تبدیل می‌شود؛ در کار آینده می‌توان مدل‌سازی زمانی صریح، مانند LSTM روی پنجره‌های ساعتی، را برای ثبت مستقیم‌تر روندها بررسی کرد.

۱۵.۶ توزیع مقادیر آزمایشگاه و علائم حیاتی

توزیع مقادیر کلیدی آزمایشگاه و علائم حیاتی در سراسر کوهورت بررسی شد. میانه کراتینین ۱.۱ mg/dL است (IQR: ۰.۸ تا ۱.۸) و ۱۲٪ بیماران مقداری بالاتر از ۲.۰ دارند که با اختلال عملکرد کلیه سازگار است. میانه گلوکز ۱۴۰ mg/dL است (IQR: ۱۱۰ تا ۱۸۰) و نوسان قند در بیماران بحرانی بالا دیده می‌شود. میانه هموگلوبین ۹.۲ g/dL است (IQR: ۷.۸ تا ۱۰.۵) و ۲۸٪ بیماران مقدار کمتر از ۸.۰ دارند. میانه لاکتات نیز ۱.۶ mmol/L است (IQR: ۱.۰ تا ۲.۵) و لاکتات بالاتر از ۲.۰ در ۳۵٪ بیماران با امکان‌پذیری پایین‌تر همراه است. این توزیع‌ها مبنای مهندسی ویژگی و تفسیر بالینی پیش‌بینی‌های مدل هستند. پراکسی SOFA که از کراتینین، پلاکت‌ها، SpO_2 و لاکتات محاسبه می‌شود، میانه ۰.۴۲ دارد (IQR: ۰.۲۸ تا ۰.۵۸)؛ مقادیر بالاتر نشان‌دهنده اختلال اندام بیشتر و نرخ امکان‌پذیری پایین‌تر است.

۱۶.۶ نوع پذیرش و مقصد ترخیص

امکان‌پذیری درمان بر اساس نوع پذیرش و مقصد ترخیص نیز تحلیل شد. پذیرش‌های اورژانسی نسبت به پذیرش‌های انتخابی نرخ امکان‌پذیری پایین‌تری دارند (۳۸٪ در برابر ۴۸٪)، که با شدت بالینی بیشتر

سازگار است. در کل کوهورت، ۲۲٪ بیماران به منزل، ۱۸٪ به توان بخشی، ۱۵٪ به مراقبت تخصصی پرستاری و ۲۵٪ به مراقبت حاد دیگر ترخیص شده‌اند؛ مرگ بیمارستانی نیز ۸٪ است. در تعریف برجسب این پژوهش، ترخیص به منزل، مراقبت خانگی و توان بخشی در گروه ممکن قرار می‌گیرند و سایر مقاصد در گروه ناممکن. این تعریف دودویی بخشی از ظرافت بالینی را از دست می‌دهد، اما مسئله را برای مدل سازی اولیه قابل مدیریت می‌کند.

۱۷.۶ ساختار همبستگی و افزونگی ویژگی

ساختار همبستگی، روابط بالینی مورد انتظار را نیز تأیید می‌کند. کراتینین و BUN همبستگی قوی دارند ($r > 0.7$) و هر دو عملکرد کلیه را بازتاب می‌دهند. هموگلوبین و هماتوکریت نیز همبستگی بسیار بالایی دارند ($r > 0.9$)، بنابراین از دید مدل می‌توانند اطلاعات افزونه ایجاد کنند. سدیم و کلر نیز با یکدیگر همبسته‌اند ($r > 0.6$) و به تعادل الکترولیتی مربوط می‌شوند. این الگوها در انتخاب ویژگی اهمیت دارند؛ زیرا حذف ویژگی‌های بسیار افزونه می‌تواند مدل را ساده‌تر کند، بدون آنکه توان پیش‌بینی به‌طور محسوس کاهش یابد.

۱۸.۶ جمع‌بندی فصل

این فصل کوهورت MIMIC-IV را از چند زاویه بررسی کرد: طرحواره پایگاه داده و روند استخراج، جمعیت‌شناسی، توزیع گره‌های بیماری، همبستگی آزمایش‌ها و علائم حیاتی، پراکسی SOFA، عملکرد به تفکیک سن، تحلیل خطا، جاسازی‌ها، تعادل کلاس، الگوهای فقدان، کیفیت داده، روندهای زمانی و ساختار همبستگی. مهم‌ترین یافته‌ها چنین‌اند: (۱) کوهورت میان گره‌های بیماری نسبتاً متعادل است؛ (۲) همبستگی‌های آزمایشگاهی با روابط بالینی شناخته‌شده هم‌خوانی دارد؛ (۳) پراکسی SOFA با امکان‌پذیری درمان رابطه دارد؛ (۴) خطاهای طبقه‌بندی بیشتر در مقادیر مرزی آزمایشگاهی رخ می‌دهند؛ و (۵) جاسازی‌های ETHOS جداسازی جزئی اما نه کامل میان دو کلاس نشان می‌دهند. این نتایج مبنای انتخاب معماری، مهندسی ویژگی و تفسیر نتایج تجربی در فصل‌های بعد هستند.

فصل ۷

بحث و گفتگو

۱.۷ تفسیر عملکرد

۱.۱.۷ از نتیجه منفی تا نزدیکی به تساوی

یافته کلیدی این پایان نامه این است که خط پایه ساده few-shot می تواند به طور محسوس از مدل های جدولی قوی روی همان وظیفه عقب بماند. این موضوع صریح گزارش شده است، زیرا نتایج منفی نیز مرزهای روش را روشن می کنند و از تکرار مسیرهای ناموفق جلوگیری می نمایند. بر اساس معیارهای منجمد ارسال، مدل جدولی SOTA به AUROC آزمون ۰.۷۴۸ می رسد، در حالی که اجرای انباشتی یکپارچه exp_fewshot_best مقدار ۰.۷۴۶ [0.699, 0.797] را ثبت می کند؛ یعنی تنها حدود ۰.۰۰۲ پایین تر از برآورد نقطه ای SOTA. بهترین زیرمدل few-shot به تنهایی ۰.۶۷۰ است. مقایسه Exp1 روی تقسیم ثابت نیز شکاف کنترل شده را نشان می دهد: Proposed_FewShot با ۰.۶۱۱ در برابر RF با ۰.۷۶۲. فصل ۵ علاوه بر این، کمپین V1-V6 را به عنوان مسیر تاریخی توسعه مستند می کند.

۲.۱.۷ سقف تجربی و بستن تدریجی فاصله

نتایج ما سقف جدولی روشنی برای این کوهورت نشان می دهد: AUROC بسته به پروتکل در بازه ۰.۷۶۰-۰.۷۴۸ قرار دارد. پیکربندی تاریخی آغازین در کمپین توسعه با few-shot ساده نزدیک ۰.۶۱۹ شروع می شود؛ اما این عدد با Exp1 ثابت (۰.۶۱۱) یکسان نیست و نباید جایگزین آن شود. راهبردهای

بعدی در همان مسیر توسعه، با انباشت، GFA و آموزش چندمرحله‌ای فاصله را کاهش می‌دهند. نتیجه انباشتی few-shot که مرجع ارسال است، ۰.۷۴۶ از exp_fewshot_best است.

۲.۷ محدودیت‌های فرا یادگیری few-shot

۱.۲.۷ ناسازگاری اپیزودیک

امکان‌پذیری درمان ممکن است با فرا یادگیری اپیزودیک هم‌راستا نباشد. وظیفه ممکن است به آمار سراسری (مثلاً توزیع آزمایشگاهی جمعیت، عوامل ریسک سطح کوهورت) نیاز داشته باشد نه نمونه‌های اولیه محلی مجموعه پشتیبان. شبکه‌های نمونه‌اولیه فرض می‌کنند هویت کلاس را میانگین چند جاسازی پشتیبان می‌گیرد؛ برای امکان‌پذیری درمان، مرز تصمیم ممکن است به تعاملات غیرخطی پیچیده وابسته باشد که با مرکزهای نمونه‌اولیه خوب تقریب زده نمی‌شوند.

برای تصویرسازی، دو بیمار را در نظر بگیرید: بیمار A کراتینین بالا (۰.۸ نرمال شده) و لاکتات نرمال (۰.۲) دارد؛ بیمار B کراتینین نرمال (۰.۲) و لاکتات بالا (۰.۷) دارد. هر دو ممکن است غیرممکن باشند اما به دلایل متفاوت. نمونه‌اولیه کلاس «غیرممکن» این پروفایل‌های متفاوت را میانگین می‌گیرد و مرکزی با کراتینین متوسط (۰.۵) و لاکتات متوسط (۰.۴۵) می‌سازد؛ پروفایلی که هیچ‌کدام از بیماران را خوب نمایندگی نمی‌کند. این مشکل «میانگین‌گیری نمونه‌اولیه» بنیادین برای شبکه‌های نمونه‌اولیه است و وقتی کلاس‌ها توزیع چندوجهی یا ناهمگن دارند تشدید می‌شود. مدل‌های درخت‌بنیاد این وضعیت را طبیعی‌تر از راه افرازهای ویژگی‌محور که زیرجمعیت‌های مختلف را در یک کلاس جدا می‌کنند، مدیریت می‌کنند.

۲.۲.۷ ناسازگاری سوگیری القایی

داده جدولی و تصویر ساختار بنیاداً متفاوتی دارند و سوگیری‌های القایی که few-shot را در تصویر موفق می‌کند ممکن است به جدول منتقل نشود:

۱. همسایگی فضایی در تصاویر در برابر استقلال ویژگی در جدول. شبکه‌های کانولوشنی از همسایگی فضایی؛ پیکسل‌های نزدیک همبسته؛ برای یادگیری سلسله‌مراتبی بهره می‌برند. ویژگی‌های جدولی این ساختار را ندارند؛ کراتینین و ضربان قلب در هیچ معنای فضایی «مجاور» نیستند. مکانیزم خودتوجه ترنسفورمر می‌تواند تعاملات ویژگی دلخواه یاد بگیرد اما باید از صفر

بدون سوگیری فضایی این کار را کند.

۲. **شکاف یادگیری انتقالی.** در بینش، روش‌های few-shot از ستون فقرات‌های

ازپیش‌آموزش‌دیده (ImageNet) سود می‌برند. ستون فقرات مشابهی برای داده‌جدولی بالینی وجود ندارد. رمزگذار ETHOS ما از صفر روی ۱,۲۸۰ بیمار آموزش‌دیده که کیفیت بازنمایی‌های آموخته‌شده را محدود می‌کند.

۳. **مهندسی ویژگی به‌عنوان دانش ضمنی قبلی.** مدل‌های کلاسیک روی ویژگی‌های دست‌ساز

مانند shock index و پراکسی SOFA کار می‌کنند؛ ویژگی‌هایی که دهه‌ها دانش بالینی را در خود دارند. رمزگذار ETHOS باید این روابط را از داده‌محدود دوباره کشف کند. شکاف میان ETHOS تاریخی (۰.۶۱۹) و LR روی ویژگی‌های خام (۰.۷۲۴) نشان می‌دهد فرایند کدگذاری، دست‌کم در پیکربندی‌های اولیه، ممکن است بیش از آنکه از تعاملات آموخته‌شده سود ببرد بخشی از اطلاعات را از دست بدهد.

۴. **تنوع وظیفه در فرا آموزش.** بنچمارک‌های few-shot (miniImageNet) از صدها کلاس

نمونه می‌گیرند و اپیزودهای متنوع می‌سازند. طبقه‌بندی ۲ راه با ۵ گره بیماری تنوع وظیفه‌محدودی دارد که ممکن است به فرا-بیش‌برازش منجر شود؛ مدل توزیع اپیزود خاص را حل می‌کند نه ترکیب‌های جدید بیمار را تعمیم می‌دهد.

۳.۲.۷ مقیاس داده

۲,۰۰۰ بیمار ممکن است برای فرا یادگیری جهت یادگیری بازنمایی‌های تاب‌آور کافی نباشد. روش‌های few-shot اغلب به مجموعه‌های فرا آموزش بزرگ برای شبیه‌سازی وظایف متنوع نیاز دارند. با تنها ۲,۰۰۰ بیمار و ۵ گره بیماری، تنوع اپیزودها محدود است. پیش‌آموزش بزرگ‌تر روی MIMIC-IV یا EHR خارجی می‌تواند عملکرد را بهبود دهد.

رابطه بین اندازه مجموعه فرا آموزش و AUROC مورد انتظار را بر اساس تحلیل حساسیت K -شات و مقایسه با مدل‌های کلاسیک برآورد می‌کنیم. مدل‌های کلاسیک (RF) با ≥ 800 بیمار آموزش AUROC پایدار (± 0.01) دارند، در حالی که FewShot+ETHOS واریانس بالاتر و عملکرد مطلق پایین‌تر نشان می‌دهد. با برون‌یابی از منحنی یادگیری، تخمین می‌زنیم ETHOS ممکن است برای رسیدن به عملکرد RF روی این وظیفه به ۵۰,۰۰۰-۱۰,۰۰۰ بیمار نیاز داشته باشد، با فرض آن که گلوگاه بازنمایی برطرف شود. این برآورد گمانه‌ای است و رفتار مقیاس واقعی به پیچیدگی بازنمایی‌های

آموخته‌شده و تنوع جمعیت بیماران وابسته است.

۴.۲.۷ بازنمایی

توکن‌های علامت ممکن است نسبت به ویژگی‌های جدولی خام اطلاعات را از دست بدهند. مدل‌های کلاسیک بردار کامل ۲۵ بعدی را مستقیماً دریافت می‌کنند؛ ETHOS باید از دنباله‌های توکن اطلاعات مرتبط استخراج کند. سوگیری القایی ترنسفورمر ممکن است با ساختار وظایف پیش‌بینی بالینی هم‌تراز نباشد.

۳.۷ تحلیل تفصیلی: چرا خط پایه اولیه few-shot ضعیف‌تر بود

شکاف اولیه ۰.۱۴ AUROC بین RF (۰.۷۶۰) و FewShot+ETHOS (۰.۶۱۹) نیازمند تحلیل دقیق است. درک این عوامل راهبرد بهبود ما را شکل داد. پنج عامل زیر، با تکیه بر شواهد حذف تدریجی:

۱.۳.۷ عامل ۱: گلوگاه فشرده‌سازی بازنمایی

رمزگذار ETHOS ورودی ۲۵ بعدی را به جاسازی ۱۲۸ بعدی فشرده می‌کند، سپس سر نمونه اولیه آن را به فاصله اسکالر کاهش می‌دهد. با وجود آن که بعد جاسازی (۱۲۸) از بعد ورودی (۲۵) بیشتر است، تبدیل بی‌زیان نیست. نتیجه حذف تدریجی: LR روی ۲۵ ویژگی خام AUROC ۰.۷۲۴ دارد، بالاتر از ETHOS روی جاسازی ۱۲۸ بعدی (۰.۶۱۹)؛ نشان می‌دهد رمزگذار ETHOS صرفاً اطلاعات را حفظ نمی‌کند بلکه فعالانه تبدیل می‌کند و این تبدیل ممکن است ویژگی‌های حیاتی برای مرز طبقه‌بندی را حذف کند.

برای کمی‌سازی، اطلاع متقابل بین ورودی ۲۵ بعدی و جاسازی ۱۲۸ بعدی ETHOS را با برآوردگر چگالی هسته محاسبه می‌کنیم. اطلاع متقابل برآوردشده $I(X; E) \approx 3.2$ nats است در مقایسه با حداکثر نظری $4.8 \approx \text{nats}$ (با فرض ویژگی‌های گاوسی). شکاف ($1.6 \approx \text{nats}$) زیان اطلاعات در فرایند کدگذاری را نشان می‌دهد، به‌ویژه در لایه‌های غیرخطی ترنسفورمر که تعاملات ویژگی سیگنال لازم برای طبقه‌بندی دودویی را مبهم می‌کنند.

۲.۳.۷ عامل ۲: هندسه نمونه اولیه در فضاهای کم بعد

شبکه های نمونه اولیه با نزدیک ترین نمونه اولیه در فضای جاسازی طبقه بندی می کنند. برای کارایی خوب، فضای جاسازی باید: (۱) فشردگی درون کلاسی: نمونه های هم کلاس محکم دور نمونه اولیه خوشه شوند؛ و (۲) جداسازی بین کلاسی: نمونه های اولیه کلاس های مختلف دور از هم باشند. تجسم های t-SNE ما (فصل ۵) جداسازی متوسط اما ناقص با هم پوشانی قابل توجه در ناحیه تصمیم نشان می دهند. به صورت رسمی، نرخ خطای طبقه بندی نمونه اولیه توسط

$$P(\text{error}) \leq \exp\left(-\frac{d(\mathbf{c}_0, \mathbf{c}_1)^2}{8\sigma^2}\right) \quad (۱.۷)$$

کران داده می شود که در آن $d(\mathbf{c}_0, \mathbf{c}_1)$ فاصله بین نمونه های اولیه و σ^2 واریانس درون کلاسی است. برای مدل ما، فاصله کسینوسی مشاهده شده بین نمونه های اولیه $0.15 \approx$ و واریانس درون کلاسی $0.12 \approx$ است که نسبت سیگنال به نویز (SNR) $1.25 \approx$ می دهد؛ ناکافی برای نرخ خطای پایین RF. برعکس در فضای ویژگی اصلی کار می کند که افرازه های هم محور مرزهای تیزتری می سازند.

۳.۳.۷ عامل ۳: واریانس نمونه برداری اپیزودیک

هر اپیزود آموزش K پشتیبان و Q پرس و جو به ازای هر کلاس نمونه می گیرد. با $K = 5$ ، نمونه اولیه از ۵ بیمار محاسبه می شود؛ برآورد پرنویز از مرکز کلاس. واریانس برآورد نمونه اولیه

$$\text{Var}(\mathbf{c}_k) = \frac{\sigma_k^2}{K} \quad (۲.۷)$$

است که σ_k^2 واریانس درون کلاسی است. با $K = 5$ ، واریانس نمونه اولیه $\sigma_k^2/5$ است؛ ۵ برابر بیش از میانگین جمعیت. این نویز به مرز طبقه بندی منتقل می شود و نرخ خطا را افزایش می دهد. در عمل، جاروب K-shot ما فقط تغییرات کوچکی نشان می دهد: AUROC اپیزودیک در بازه $0.564 - 0.557$ می ماند و بهترین مقدار در $K=3$ دیده می شود. بنابراین انتظار نظری کاهش واریانس با K بزرگ تر در این وظیفه وجود دارد، اما اثر تجربی آن در مقیاس کنونی ضعیف است.

۴.۳.۷ عامل ۴: مدل سازی تعامل ویژگی

Random Forest تعاملات ویژگی را طبیعی از راه افراز درخت می گیرد: افراز روی کراتینین و سپس سن، تعامل «کراتینین و سن» را می گیرد. RF عمق ۲۸ با ۲۰۰ درخت می تواند تعاملات تا مرتبه ۲۸ را مدل کند. ترنسفورمر ETHOS تعاملات را از راه خودتوجه چندسر می گیرد، اما با تنها ۲ لایه و ۸ سر، ظرفیت برای تعاملات پیچیده ممکن است ناکافی باشد؛ به ویژه با داده آموزش محدود.

تقویت گرادیان، مانند XGBoost و LightGBM، AUROC نزدیک به RF (0.73–0.75) به دست می آورد. این نتیجه تأیید می کند که مدل سازی تعاملات با درخت ها برای این وظیفه مؤثر است. مدل ترکیبی با AUROC برابر ۰.۷۱۷ نشان می دهد ETHOS برخی تعاملات مکمل را می گیرد که در ویژگی های مهندسی شده ۲۵ بعدی کاملاً دیده نمی شوند؛ با این حال، این سیگنال به تنهایی برای بستن شکاف کافی نیست.

۵.۳.۷ عامل ۵: منظره بهینه سازی

آموزش اپیزودیک یک فرا-هدف (زیان روی اپیزودها) را بهینه می کند، نه آنتروپی متقاطع استاندارد روی مجموعه آموزش. فرا-هدف پرنویزتر است (هر اپیزود برآورد تصادفی از فرا-زیان است) و ممکن است منظره بهینه سازی متفاوتی داشته باشد. با داده فرا آموزش محدود (۱,۲۸۰ بیمار ÷ ۵ به ازای هر کلاس در هر اپیزود ≈ ۱۲۸ اپیزود ممکن پیش از تکرار)، مدل ممکن است منظره زیان را به اندازه کافی کاوش نکند. مدل های کلاسیک یک هدف واحد واضح روی کل آموزش بهینه می کنند و راه حل های پایدارتر می دهند.

۴.۷ معامله ها و پیامدهای عملی

۱.۴.۷ چه وقت از FewShot+ETHOS استفاده کنیم

در تنظیمات فدرال و کم داده که حریم خصوصی حیاتی است و مدل های کلاسیک نمی توانند به صورت متمرکز آموزش ببینند (مثلاً همکاری بین مؤسسه با حاکمیت داده سخت)، رویکرد ما خط پایه عملی ارائه می کند. هزینه فدرال ناچیز است (۰.۵٪ AUROC)، بنابراین حریم خصوصی را بدون افت محسوس عملکرد می توان حفظ کرد.

۲.۴.۷ چه وقت از مدل‌های کلاسیک استفاده کنیم

برای بیشینه دقت روی این وظیفه، Random Forest یا XGBoost تنظیم شده ترجیح داده می‌شود. توصیه می‌کنیم پژوهشگران هر دو را گزارش کنند: مدل‌های کلاسیک به عنوان مرز بالا، FewShot+ETHOS به عنوان خط پایه فدرال few-shot. انتخاب به بستر استقرار (متمرکز در برابر فدرال، دسترسی به داده) بستگی دارد. جدول ۱.۷ راهنمای تصمیم ارائه می‌کند.

جدول ۱.۷: راهنمای انتخاب مدل

سناریو	مدل توصیه شده	استدلال
بیشینه دقت، متمرکز	جدولی SOTA یا RF_threshold_tuned	AUROC در حدود 0.748-0.760 (فصل ۵)
بهترین ترکیب few-shot کلاسیک	انباشتی exp_fewshot_best	AUROC 0.746 [0.699, 0.797]
بهترین عصبی تکی (کمپین V)	CrossAttn+GFA V5	بهترین بذر 0.737؛ میانگین ensemble 0.722 (تاریخی)
فدرال، حریم بحرانی	چیدمان فدرال (فصل ۵)	شکاف حدود AUROC 0.005 نسبت به متمرکز
گره جدید کم داده	Proto-MAML FewShot	سازگاری زمان آزمون با پشتیبان کم
استقرار تولید	+ Stacked BEST SHAP + کالبراسیون	نمونه پژوهشی؛ اعتبارسنجی محلی

۳.۴.۷ از ترکیبی به انباشت: مسیر تا تساوی

مدل ETHOS_RF_Hybrid با AUROC ۰.۷۱۷ در کمپین V نشان داد ترکیب جاسازی‌های ETHOS با ویژگی‌های جدولی می‌تواند فاصله تا خطوط پایه کلاسیک را کم کند. انباشت V4 با ۰.۷۳۲ و بهترین بذر V5 با ۰.۷۳۷ نیز نقش هم‌آمیزی و معماری را بیشتر بررسی کردند. اجرای انباشتی منجمد ارسال، یعنی exp_fewshot_best با AUROC ۰.۷۴۶، روایت few-shot+کلاسیک را با برآورد نقطه‌ای SOTA جدولی (۰.۷۴۸) هم‌تراز می‌کند.

۵.۷ تحلیل علی (اکتشافی)

برای نمایش اعتبارسنجی بالینی بالقوه، تحلیل‌های علی اکتشافی پیوند پیش‌بینی‌های امکان‌پذیری به پیامدهای واقعی را بررسی کردند. این تحلیل‌ها نمایشی‌اند؛ اعتبارسنجی کامل به داده آینده‌نگر نیاز دارد.

۱.۵.۷ تطبیق امتیاز گرایش

تطبیق امتیاز گرایش برای برآورد اثر پیش‌بینی امکان‌پذیری روی پیامدهای پایین‌دست به کار رفت. بیماران با پیش‌بینی امکان‌پذیر ($RF > 0.54$) با بیماران پیش‌بینی‌شده غیرممکن روی سن، جنس، تشخیص اولیه، و SOFA پایه تطبیق داده شدند. کوهورت تطبیق‌یافته نشان داد $AUROC = 0.76$. کاهش بستری مجدد ۳۰ روزه را پیش‌بینی می‌کند: بیماران درست پیش‌بینی‌شده امکان‌پذیر نرخ بستری مجدد ۱۲٪ پایین‌تری نسبت به اشتباه پیش‌بینی‌شده غیرممکن داشتند ($p < 0.05$). این نتیجه نشان می‌دهد مدل احتمالاً سیگنال بالینی معناداری فراتر از همبستگی ساده دریافت می‌کند.

۲.۵.۷ تحلیل متغیر ابزاری

با استفاده از تغییرات سطح بیمارستان در شیوه ترخیص به عنوان ابزار، دو مرحله‌ای کمترین مربعات برای برآورد اثر علی امکان‌پذیری روی طول اقامت ICU انجام شد. نتایج نشان می‌دهد پیش‌بینی‌های امکان‌پذیری با کاهش LOS هنگام معتبر بودن ابزار ($F_{\text{first-stage}} > 10$) همبسته‌اند، فرضیه آن‌که ارزیابی زودهنگام امکان‌پذیری می‌تواند روزهای غیرضروری ICU را کاهش دهد را پشتیبانی می‌کند.

۶.۷ یادگیری چندوظیفه (اکتشافی)

رمزگذار مشترک ETHOS را به پیش‌بینی چندوظیفه گسترش دادیم: امکان‌پذیری، مرگ‌ومیر ۳۰ روزه، و طول اقامت ICU (LOS). یک رمزگذار با سرهای وظیفه‌ویژه از راه بازنمایی‌های مشترک $AUROC$ امکان‌پذیری را بهبود می‌دهد. جدول ۲.۷ عملکرد تک‌وظیفه در برابر چندوظیفه را مقایسه می‌کند. این نتایج اکتشافی‌اند؛ آزمایش‌های چندوظیفه کامل به اجراهای اختصاصی نیاز دارند.

یادگیری چندوظیفه سودهای اندک در همه وظایف می‌دهد: $AUROC$ امکان‌پذیری $+0.012$ ، $AUROC$ مرگ‌ومیر $+0.01$ ، $MAE_{LOS} -0.2$ روز. رمزگذار مشترک بازنمایی‌های بالینی قابل‌تعمیم یاد می‌گیرد که در وظایف پیش‌بینی مرتبط منتقل می‌شوند.

جدول ۲.۷: عملکرد تک‌وظیفه در برابر چندوظیفه (اکتشافی؛ مبتنی بر پیکربندی تاریخی ETHOS)

چیدمان	AUROC امکان‌پذیری	AUROC مرگ‌ومیر	MAE LOS
تک‌وظیفه (فقط امکان‌پذیری؛ تاریخی)	۶۱۹.۰	—	—
تک‌وظیفه (فقط مرگ‌ومیر)	—	۷۱.۰	—
تک‌وظیفه (فقط LOS)	—	—	۲.۴ روز
چندوظیفه	۶۳۱.۰	—	—
(هر سه سر)	—	۷۲.۰	—
	—	—	۰.۴ روز
سود نسبت به تک‌وظیفه	+0.012	+0.01	-0.2

۷.۷ تحلیل حساسیت

با پیروی از چارچوب تحلیل نظری پیشنهاد، تحلیل‌های حساسیت برای تاب‌آوری یافته‌ها انجام شد.

۱.۷.۷ حساسیت ابرپارامتر

اب‌پارامترهای کلیدی را تغییر دادیم و تغییر AUROC را اندازه گرفتیم. برای ETHOS: بعد جاسازی (۶۴، ۱۲۸، ۲۵۶)، تعداد سرها (۲، ۴، ۸)، و dropout (۰.۱، ۰.۲، ۰.۳). AUROC در حدود ۰.۰۲ بالا یا پایین می‌شد و ترکیب ۱۲۸ بعد و ۴ سر، بهترین توازن را نشان داد. برای Random Forest: max_depth (5–25) و n_estimators (100–500) بررسی شد. AUROC از عمق ۱۰ به بالا و با دست‌کم ۲۰۰ برآوردگر، در بازه حدود ۰.۰۱ پایدار ماند.

۲.۷.۷ حساسیت شات پشتیبان K

با تغییر مقدار K در میان ۱، ۳، ۵، ۱۰ و ۱۵ در آزمایش حساسیت K-shot، AUROC در بازه ۰.۵۶۴–۰.۵۵۷ باقی ماند. بهترین میانگین در K=3 با ۰.۵۶۴ دیده شد و K=1 تقریباً همان عملکرد را نشان داد. روند صعودی یکنواختی مشاهده نمی‌شود. مدل منجمد Proposed_FewShot در Expl روی ارزیابی ثابت عدد ۰.۶۱۱ دارد؛ بنابراین اختلاف عمده بیشتر از تفاوت پروتکل ارزیابی ناشی می‌شود تا صرفاً شمار شات پشتیبان.

۳.۷.۷ اثر ترکیب ماژول‌ها

سهم هر ماژول را از راه حذف تدریجی leave-one-out (جدول ۷.۵) تحلیل کردیم. حذف وزن‌دهی شدت AUROC را به ۰.۵۷۷ کاهش داد، در حالی که حذف واگرایی زمانی عملاً تغییری ایجاد نکرد و روی ۰.۵۸۳ باقی ماند. به‌ویژه **no_symptom_tokens** یعنی Logistic Regression روی ۲۵ بعد خام، به AUROC ۰.۷۲۴ رسید؛ بالاتر از مدل کامل FewShot+ETHOS با ۰.۵۸۳. این نتیجه نشان می‌دهد بازنمایی مبتنی بر توکن، در مقایسه با ویژگی‌های جدولی خام، ممکن است برای این وظیفه بخشی از اطلاعات را از دست بدهد و رمزگذار ETHOS باید این زیان را جبران کند. همچنین حذف سر few-shot و جایگزینی آن با سر نظارت‌شده استاندارد به AUROC ۰.۶۴۵ می‌رسد که از مدل کامل بهتر است؛ بنابراین چیدمان اپیزودیک در این مقیاس الزاماً سودمند نیست.

۸.۷ تحلیل ROI (نمایشی)

بازگشت سرمایه (ROI) استقرار مدل پیش‌بینی امکان‌پذیری در بستر بالینی برآورد شد. آنچه می‌آید محاسبه تقریبی است؛ ROI واقعی به هزینه و گردش کار وابسته به سایت بستگی دارد. فرض‌ها: بهبود ۱٪ AUROC (مثلاً ۰.۷۶ در برابر ۰.۷۵) ترخیص‌های نامناسب را حدود ۲٪ کاهش می‌دهد، یعنی حدود ۰.۵ بستری مجدد کمتر به‌ازای ۱۰۰ بیمار. با ۱۵,۰۰۰ دلار به‌ازای هر بستری مجدد اجتناب‌شده و ۵,۰۰۰ پذیرش ICU در سال، پس‌انداز سالانه حدود ۳۷۵,۰۰۰ دلار است. هزینه پیاده‌سازی (یکپارچه‌سازی، آموزش، پایش) حدود ۵۰,۰۰۰ دلار در سال برآورد می‌شود. $ROI \approx 6.5 \times$ در سال اول. تحلیل حساسیت برای سود $AUROC > 0.5\%$ و هزینه بستری مجدد ۲۰,۰۰۰-۱۰,۰۰۰ دلار تاب‌آوری نشان می‌دهد.

۹.۷ گسترش سری زمانی (اکتشافی)

توکن‌سازی ۲۵ توکنی علامت را با خط پایه سری زمانی خام مقایسه کردیم: RNN-LSTM روی علائم حیاتی خام نمونه‌برداری‌شده هر ۴ ساعت در ۲۴ ساعت اول. LSTM وضوح زمانی کامل دارد؛ معادل ۶ مقطع زمانی برای هر یک از هفت علامت حیاتی ثبت‌شده. این مقایسه اکتشافی است؛ آزمایش‌های کامل LSTM به تنظیم ابرپارامتر اختصاصی نیاز دارند.

فشرده‌سازی توکن حدود ۲٪ AUROC از دست می‌دهد اما تفسیرپذیری می‌گیرد.

LSTM به AUROC ۰.۷۸ برای امکان‌پذیری در برابر ۰.۷۶ برای RF مبتنی بر توکن رسید. شکاف ۲٪ زیان اطلاعات از سطل‌بندی و تجمیع را منعکس می‌کند. با این حال بازنمایی توکن ارائه می‌کند: (۱) اهمیت ویژگی قابل‌تفسیر (SHAP)، (۲) سازگاری با یادگیری اپیزودیک few-shot، و (۳) هزینه محاسباتی پایین‌تر. در استقرارهایی که تفسیرپذیری و حریم فدرال مهم است، رویکرد مبتنی بر توکن با وجود معامله کوچک AUROC توجیه می‌شود.

۱۰.۷ تحلیل خطا

جایی که بهترین مدل (Random Forest) خطا می‌کند را تحلیل کردیم. طبقه‌بندی اشتباه شایع‌تر میان بیماران با کراتینین مرزی (۰.۳-۰.۵ نرمال‌شده) و در گره‌های بیماری با نمونه آموزش کمتر (کلیه، دیابت) است. کالیبراسیون (شکل ۱۰.۵) نشان می‌دهد احتمالات پیش‌بینی‌شده برای RF نسبتاً خوب کالیبره‌اند؛ ETHOS گرایش به بیش‌اعتمادی دارد. برای استقرار، نمودارهای قابلیت اطمینان و باز کالیبراسیون (مثلاً Platt scaling) در صورت نیاز توصیه می‌شود.

۱۱.۷ ملاحظات استقرار

برای استقرار تولید توصیه می‌کنیم: (۱) یکپارچه‌سازی: REST API یا HL7 FHIR برای EHR؛ (۲) تأخیر: استنتاج $RF < 10\text{ ms}$ ؛ $ETHOS < 50\text{ ms}$ روی CPU؛ (۳) پایش: ردیابی AUROC، کالیبراسیون، و معیارهای انصاف در زمان؛ (۴) پشتیبان: بازبینی انسانی برای پیش‌بینی‌های کم‌اطمینان (با احتمال کمتر از ۰.۳ یا بیش از ۰.۷)؛ (۵) نسخه‌گذاری: ثبت نسخه مدل و توزیع داده برای هر پیش‌بینی. مشخصات API در پیوست ز آمده است.

۱۲.۷ مشخصات API

برای استقرار و بازتولیدپذیری، مشخصات API (پیوست ز) ارائه شده است. REST API نقاط پایانی برای: (۱) پیش‌بینی امکان‌پذیری (/predict POST)، (۲) فراداده مدل (/model GET)، و (۳) توضیح SHAP (/explain POST) دارد. برای مشخصات کامل OpenAPI به پیوست ز مراجعه کنید.

۱۳.۷ تحلیل تفصیلی خطا به تفکیک زیر گروه

نرخ خطا را به تفکیک گروه سنی (۴۵-۱۸، ۶۵-۴۶، ۶۶+)، جنس و نوع پذیرش (انتخابی در برابر اورژانسی) تحلیل کردیم. برای بهترین مدل (RF)، نرخ خطا در گروه ۶۶+ بالاتر است (۲۴٪ در برابر ۱۸٪ برای ۴۵-۱۸)، که با پیچیدگی بالینی بیشتر در سالمندان سازگار است. نرخ خطا به تفکیک جنس مشابه است (۲۰٪ در برابر ۲۱٪). پذیرش‌های اورژانسی نیز نرخ خطای بالاتری دارند (۲۳٪ در برابر ۱۷٪ انتخابی)، که نشان می‌دهد شدت بیماری و ناپایداری مسیر بالینی می‌تواند پیش‌بینی را دشوارتر کند. این تحلیل‌های زیرگروهی برای ارزیابی انصاف مهم‌اند و در استقرار باید عملکرد مدل در گروه‌های جمعیت‌شناختی پایش شود.

۱۴.۷ مقایسه با کار پیشین

۱.۱۴.۷ ادبیات پیش‌بینی ترخیص

کار پیشین روی پیش‌بینی مقصد ترخیص [Caruana et al., 2015, Awad et al., 2017] معمولاً از داده متمرکز و ML کلاسیک استفاده می‌کند. AUROC ۰.۷۶ ما با نتایج گزارش شده برای وظایف مشابه قابل قیاس است. جدول ۳.۷ مقایسه تفصیلی ارائه می‌کند.

نتیجه SOTA/RF در این پژوهش، بسته به پروتکل، در بازه ۰.۷۶۰-۰.۷۴۸ قرار می‌گیرد و با مقادیر گزارش شده برای وظایف مرتبط با ترخیص در داده MIMIC هم‌خوان است. نوآوری این کار در ادعای عبور از همه بنچمارک‌های پیشین نیست؛ بلکه در نشان دادن ظرفیت و محدودیت رویکردهای few-shot و فدرال برای یک مسئله جدولی بالینی واقعی است.

۲.۱۴.۷ یادگیری چندنمونه‌ای (few-shot) در بهداشت

یادگیری few-shot در تصویربرداری پزشکی، مانند طبقه‌بندی X-ray با $AUROC > 0.85$ و پوست‌شناسی با دقت بیش از 80% [Prabhu et al., 2019]، کاربردهای موفقی داشته است؛ اما در پیامدهای جدولی بالینی هنوز کمتر بررسی شده است. نقطه مشترک بسیاری از موفقیت‌های تصویری، وجود ستون فقرات‌های کانولوشنی ازپیش‌آموزش دیده است که پیش از سر few-shot، ویژگی‌های غنی استخراج می‌کنند. نتیجه منفی اولیه در این پژوهش، یعنی ETHOS تاریخی با ۰.۶۱۹ در برابر RF حدود ۰.۷۶۰، نشان می‌دهد یادگیری few-shot جدولی احتمالاً یا به بازنمایی‌های ازپیش‌آموزش دیده

جدول ۳.۷: مقایسه با نتایج پیشین ترخیص/پیامد

مطالعه وظیفه	مجموعه داده	AUROC	روش کلیدی
Awad 2017 مقصد ترخیص	MIMIC-III	0.78	RF، متمرکز
Purushotham 2018 مرگ و میر	MIMIC-III	0.85	LSTM، متمرکز
Rajkomar 2018 بستری مجدد	چندسایتی	0.76	DNN، متمرکز
Caruana 2015 مرگ و میر	EHR	0.88	Ensembles
Harutyunyan 2019 چندوظیفه	MIMIC-III	0.86	LSTM چندوظیفه
ما (SOTA, RF) امکان پذیری	MIMIC-IV	0.748	RF؛ اسکریپت منجمد SOTA
ما (V5 بهترین) امکان پذیری	MIMIC-IV	0.737	CrossAttn+GFA (کمپین V)
ما (انباشت V4) امکان پذیری	MIMIC-IV	0.732	RF+FS (کمپین V)
ما (Stacked) امکان پذیری (BEST)	MIMIC-IV	0.746	exp_fewshot_best
ما (V6) امکان پذیری	MIMIC-IV	0.725	ensemble ناهمگن (کمپین V)
ما (خط پایه امکان پذیری منجمد)	MIMIC-IV	0.611	(Exp1) Proposed_FewShot

قوی تر نیاز دارد یا به معماری‌هایی که مخصوص داده‌های جدولی ناهمگن طراحی شده باشند. جهت‌های امیدبخش اخیر شامل:

۱. پیش‌آموزش EHR مقیاس بزرگ: پیش‌آموزش روی میلیون‌ها پرونده پیش از تنظیم دقیق few-shot، مشابه پیش‌آموزش ImageNet برای بینش.
۲. پل‌های مدل زبانی: استفاده از LLM برای تولید توصیف متنی ویژگی‌های بیمار، سپس اعمال روش‌های few-shot مبتنی بر متن (TabLLM [Hegselmann et al., 2023]).
۳. نمونه‌های اولیه وابسته به وظیفه: یادگیری توابع محاسبه نمونه اولیه ویژه وظیفه به جای میانگین ساده [Ye et al., 2020].

۳.۱۴.۷ بهداشت فدرال

یادگیری فدرال در سلامت [Duan et al., 2022, Rieke et al., 2020] در چند بستر پژوهشی و عملی امکان‌پذیر نشان داده شده است. هزینه کوچک فدرال در این پژوهش (AUROC -0.5%) با گزارش‌های پیشین سازگار است، به‌ویژه زمانی که ناهمگنی داده متوسط باشد. برای نمونه، همکاری Intel-Penn Medicine [Sheller et al., 2020] گزارش کرد که بخش‌بندی فدرال تومور مغز در ۳۰ مؤسسه به

۹۹٪ عملکرد آموزش متمرکز رسیده است؛ نتیجه‌ای که امکان‌پذیری عملی FL در سلامت را تقویت می‌کند.

تفاوت‌های کلیدی بین چیدمان فدرال شبیه‌سازی‌شده ما و FL دنیای واقعی:

۱. **قابلیت اطمینان ارتباط:** شبیه‌سازی ما ارتباط همزمان قابل‌اعتماد فرض می‌کند. FL واقعی باید خرابی شبکه، timeout، و به‌روزرسانی‌های ناهمزمان را مدیریت کند.
۲. **ناهمگنی گره:** گره‌های ما بر اساس بیماری از هم جدا شده‌اند؛ اما در محیط واقعی، مؤسسات از نظر سخت‌افزار، نسخه نرم‌افزار و روند پردازش داده نیز با هم تفاوت دارند.
۳. **شرکت‌کنندگان خصمانه:** گره‌های مخرب یا بیزانسی می‌توانند مدل سراسری را فاسد کنند. روش‌های تجمیع تاب‌آور (مثلاً میانگین هرس‌شده، Krum [Blanchard et al., 2017]) این را پوشش می‌دهند اما در خط پایه ما پیاده نشده‌اند.
۴. **عقب‌ماندگان:** گره‌ها با سخت‌افزار کند یا داده محلی بزرگ ممکن است دورها را به تعویق اندازند. روش‌های FL ناهمزمان (FedAsync) می‌توانند این را تخفیف دهند.

۱۵.۷ ملاحظات نظری

۱.۱۵.۷ چرا شبکه‌های نمونه‌اولیه ممکن است ضعیف‌تر عمل کنند

شبکه‌های نمونه‌اولیه فرض می‌کنند هویت کلاس را میانگین جاسازی‌های پشتیبان می‌گیرد. برای امکان‌پذیری درمان، مرز تصمیم ممکن است به تعاملات غیرخطی (مثلاً ترکیب کراتینین و سن، یا ترکیب SOFA و تشخیص) وابسته باشد که با مرکزهای نمونه‌اولیه خوب تقریب زده نمی‌شوند. یادگیری متریک ممکن است به توابع فاصله ویژه وظیفه نیاز داشته باشد.

۲.۱۵.۷ کارایی داده

با ۲,۰۰۰ بیمار و ۵ گره بیماری، حدود ۴۰۰ بیمار به‌ازای هر گره داریم. فرا یادگیری few-shot اغلب از هزاران وظیفه برای نمونه‌برداری اپیزود متنوع سود می‌برد. مقیاس‌دهی به کل کوهورت MIMIC-IV (۲۵۰ هزار + اقامت) یا داده چندسایتی می‌تواند عملکرد ETHOS را بهبود دهد.

۳.۱۵.۷ تهدیدهای اعتبار

چند تهدید اعتبار باید در نظر گرفته شود. از نظر اعتبار درونی، کوهورت از یک مؤسسه (BIDMC) آمده و ممکن است ویژگی‌های همان مرکز را بازتاب دهد. از نظر اعتبار بیرونی، نمونه ۲,۰۰۰ بیمار نسبتاً محدود است و استفاده از کل MIMIC-IV یا داده‌چندسایتی می‌تواند به نتیجه‌گیری متفاوتی منجر شود. از نظر اعتبار سازه، امکان‌پذیری درمان با مقصد ترخیص و بستری مجدد تعریف شده است؛ تعاریف جایگزین مانند وضعیت عملکردی یا زمان تا ترخیص ممکن است نتایج را تغییر دهند. از نظر اعتبار نتیجه‌گیری نیز با وجود استفاده از بازه‌های اطمینان بوت‌استرپ و آزمون DeLong، تعدد مقایسه‌ها می‌تواند احتمال خطای نوع I را افزایش دهد. برای کاهش این خطر، بازه‌های اطمینان گزارش شده و از گزارش گزینشی پرهیز شده است.

۴.۱۵.۷ گلوگاه بازنمایی: تحلیل عمیق‌تر

توکن‌سازی علامت، فضای جدولی ۲۵ بعدی را به دنباله‌ای از توکن‌های گسسته تبدیل می‌کند. در این تبدیل، بخشی از اطلاعات ممکن است هنگام سطل‌بندی و تجمیع از دست برود. اینکه LR روی ویژگی‌های خام با AUROC برابر ۰.۷۲۴ از ETHOS کامل با ۰.۵۸۳ بهتر عمل می‌کند، این نگرانی را تقویت می‌کند. این گلوگاه از سه منظر بررسی می‌شود:

منظر اطلاع‌نظری. فرایند توکن‌سازی مقادیر پیوسته $x \in [0, 1]$ را به شناسه علامت گسسته (۲۲-۱) و مقدار شدت پیوسته نگاشت می‌کند. با وجود حفظ مقدار نرمال‌شده توسط شدت، گسسته‌سازی هویت علامت واژگان ثابتی معرفی می‌کند که ممکن است تمایزهای ریز را نگیرد. برای مثال، مقادیر کراتینین ۰.۳۱ و ۰.۶۹ همان شناسه علامت را دارند اما پیامدهای بالینی متفاوت (نرمال در برابر بالا). مدل باید این تمایزها را تنها از بعد شدت یاد بگیرد، در حالی که مدل‌های کلاسیک مستقیماً روی مقدار پیوسته کار می‌کنند.

منظر معماری. مکانیزم خودتوجه ترنسفورمر پیچیدگی محاسباتی $O(L^2d)$ دارد که در اینجا $L = 25$ طول دنباله است. وقتی دنباله فقط ۲۵ توکن دارد، پنجره زمینه برای توجه محدود است و ممکن است نسبت به معماری‌های ساده‌تر، مانند MLP دولایه روی بردار ۲۵ بعدی صاف‌شده، مزیت روشنی ایجاد نکند. نتایج حذف تدریجی نیز همین نکته را تأیید می‌کند: جایگزینی ترنسفورمر با یک رمزگذار MLP ساده AUROC را تنها حدود ۰.۰۲ از ETHOS کامل دور می‌کند. بنابراین، برای این طول دنباله

و این وظیفه، خودتوجه به تنهایی عامل اصلی عملکرد نیست.

راهبردهای تخفیف. بازنمایی‌های جایگزین که می‌توانند گلوگاه را پوشش دهند:

۱. **جاسازی‌های توکن پیوسته:** جایگزینی شناسه‌های علامت گسسته با جاسازی‌های پیوسته آموزش دیده به ازای هر اندازه‌گیری، تا مدل بازنمایی‌های ویژه وظیفه یاد بگیرد.
۲. **ساختار مبتنی بر گراف:** نمایش روابط آزمایشگاه-علائم حیاتی به عنوان گراف (مثلاً یال کراتینین-BUN برای عملکرد کلیه) و استفاده از شبکه‌های عصبی گرافی برای کدگذاری. این ساختار حوزه بالینی را به عنوان سوگیری القایی معرفی می‌کند.
۳. **تجميع زمانی چندمقیاس:** به جای تجميع تکی ۲۴ ساعته، ویژگی‌ها در پنجره‌های ۴، ۸، ۱۲، و ۲۴ ساعت محاسبه شوند تا بازنمایی زمانی غنی‌تر روندها را بگیرد.
۴. **توکن‌سازی ترکیبی:** ترکیب ویژگی‌های جدولی خام با بازنمایی‌های توکن تا مدل به هر دو قالب دسترسی داشته باشد. ETHOS_RF_Hybrid این راهبرد را تا حدی پیاده می‌کند و به AUROC برابر ۰.۷۱۷ می‌رسد.

۱۶.۷ مقایسه بین حوزه‌ای: یادگیری few-shot در انواع داده

برای روشن‌تر شدن جایگاه نتایج، عملکرد یادگیری few-shot در چند نوع داده با هم مقایسه می‌شود. این مقایسه نشان می‌دهد چرا few-shot جدولی بالینی از نظر بازنمایی و تعمیم با چالش‌های خاصی روبه‌روست.

۱.۱۶.۷ حوزه بینش

روی miniImageNet (۵ راه، ۵ شات)، شبکه‌های نمونه اولیه حدود ۶۸٪ دقت با ستون فقرات CNN ۴ لایه و حدود ۷۴٪ با ستون فقرات ResNet-12 به دست می‌آورند [Snell et al., 2017]. عملکرد قوی ناشی از: (۱) ستون فقرات‌های از پیش آموزش دیده قوی با ویژگی‌های غنی و قابل انتقال؛ (۲) ساختار فضایی در تصاویر که شبکه‌های کانولوشنی به کارآمد بهره می‌برند؛ (۳) مجموعه‌های فرا آموزش بزرگ (۶۴ کلاس، ~۳۸,۰۰۰ تصویر) که نمونه‌برداری اپیزود متنوع را ممکن می‌کند.

۲.۱۶.۷ حوزه NLP

در طبقه‌بندی متن few-shot (ARSC, FewRel)، شبکه‌های نمونه‌اولیه ۸۵-۷۰٪ دقت بسته به وظیفه و ستون فقرات به دست می‌آورند [Han et al., 2018]. مدل‌های زبانی ازپیش‌آموزش دیده (BERT) به عنوان ستون فقرات سود چشمگیری می‌دهند، با Proto+BERT تنظیم شده با دقت بالاتر از 85% روی FewRel. موفقیت ناشی از: (۱) بازنمایی‌های ازپیش‌آموزش دیده قوی از متن عظیم؛ (۲) شباهت معنایی که با طبقه‌بندی مبتنی بر فاصله هم‌راستا است.

۳.۱۶.۷ حوزه کشف دارو

در یادگیری few-shot مولکولی، به‌ویژه در بنچمارک FS-Mol، شبکه‌های نمونه‌اولیه برای پیش‌بینی خاصیت‌ها معمولاً AUROC حدود ۰.۶۰ تا ۰.۷۰ به دست می‌آورند [Stanley et al., 2021]. این بازه با خط پایه منجمد Proposed_FewShot در این پژوهش (۰.۶۱۱) قابل مقایسه است. چنین شباهتی نشان می‌دهد پیش‌بینی خاصیت مولکولی و امکان‌پذیری بالینی هر دو با ورودی‌های ناهمگن، مرزهای تصمیم غیرخطی و محدودیت داده پیش‌آموزش روبه‌رو هستند.

۴.۱۶.۷ حوزه جدولی

کار اخیر روی یادگیری few-shot جدولی [Hegselmann et al., 2023] با جاسازی‌های مدل زبانی (TabLLM) نتایج متغیر گزارش می‌کند: رقابتی با خطوط پایه در برخی مجموعه‌ها اما ضعیف‌تر در دیگران. یافته کلی آن است که few-shot جدولی همچنان چالش باز است، سازگار با نتایج ما.

۵.۱۶.۷ ترکیب

جدول ۴.۷ مقایسه بین حوزه‌ای را خلاصه می‌کند.

الگوی کلی روشن است: عملکرد few-shot زمانی بهتر می‌شود که بازنمایی‌های ازپیش‌آموزش دیده قوی وجود داشته باشد و ساختار داده با سوگیری‌های القایی مدل هم‌راستا باشد. داده جدولی بالینی معمولاً هر دو مزیت را کمتر دارد و همین موضوع بخشی از شکاف عملکرد را توضیح می‌دهد. بنابراین برای کاهش این شکاف، یا باید پیش‌آموزش مقیاس بزرگ روی داده جدولی بالینی انجام شود، مشابه نقشی که ImageNet در بینایی ماشین داشته است، یا باید رویکردهای فرا یادگیری تازه‌ای طراحی شوند که به‌طور خاص با ویژگی‌های جدولی ناهمگن سازگار باشند.

جدول ۴.۷: عملکرد یادگیری few-shot در حوزه‌های مختلف

حوزه	بنچمارک	Proto-Net بهترین	ازپیش آموزش؟
بینش	miniImageNet 5w5s	68% acc 80%+	بله (ImageNet)
NLP	5w5s FewRel	72% acc 85%+	بله (BERT)
مولکولی	FS-Mol	0.65 0.72	جزئی
		AUROC	
		0.746 انباشت	
		SOTA 0.748	
		V5 0.737	
جدولی (ما)	MIMIC-IV 2w5s	0.611 AUROC	جزئی

۱۷.۷ پیامدهای بالینی و تحلیل استقرار

۱.۱۷.۷ تأثیر بر گردش کار بالینی

مدل پیش‌بینی امکان‌پذیری درمان می‌تواند در چند نقطه تصمیم در گردش کار ICU یکپارچه شود:

۱. **ارزیابی ۲۴ ساعته:** پس از ۲۴ ساعت اول پذیرش ICU، مدل امتیاز امکان‌پذیری بر اساس آزمایش‌ها و علائم حیاتی موجود تولید می‌کند. بیماران با امتیاز بالا (بیش از ۰.۷) برای برنامه‌ریزی زودهنگام ترخیص علامت‌گذاری می‌شوند.
۲. **ارزیابی مجدد روزانه:** با دسترسی داده جدید، مدل پیش‌بینی را به‌روز می‌کند. روند امتیاز امکان‌پذیری (صعودی در برابر نزولی) اطلاعات اضافی درباره مسیر بیمار می‌دهد.
۳. **گردش‌های چندرشته‌ای:** امتیاز امکان‌پذیری همراه داده بالینی دیگر در گردش‌های صبح ارائه می‌شود و تصمیم‌های مشترک برنامه‌ریزی ترخیص را پشتیبانی می‌کند.
۴. **مدیریت تخت:** پیش‌بینی‌های تجمیعی امکان‌پذیری می‌توانند در برنامه‌ریزی ظرفیت ICU و برآورد دسترسی به تخت به کار روند.

۲.۱۷.۷ اعتماد و پذیرش بالینی

برای پذیرش بالینی، چند عامل باید پوشش داده شوند:

۱. **تفسیرپذیری:** بالینیان باید بفهمند چرا مدل امتیاز خاصی پیش‌بینی می‌کند. توضیحات

SHAP (نشان دادن کراتینین بالا و پلاکت پایین پیش‌بینی «غیرممکن» را هدایت می‌کنند) با استدلال بالینی هم‌راستا است و اعتماد می‌سازد. تحلیل اهمیت ویژگی ما تأیید می‌کند ویژگی‌های پیش‌بینی‌کننده برتر (کراتینین، گلوکز، هموگلوبین) با تعیین‌کننده‌های شناخته‌شده ترخیص هم‌خوان‌اند.

۲. **کالیبراسیون:** مدلی که می‌گوید «۷۰٪ احتمال ترخیص امکان‌پذیر» باید تقریباً در ۷۰٪ مواقع درست باشد. تحلیل کالیبراسیون ما نشان می‌دهد RF نسبتاً خوب کالیبره است (Brier ۰.۲۱)، در حالی که ETHOS گرایش به بیش‌اعتمادی دارد. باز کالیبراسیون (Platt scaling) یا رگرسیون ایزوتونیک) پیش از استقرار لازم است.

۳. **خستگی هشدار:** اگر مدل برای هر بیمار هشدار تولید کند، بالینیان آن‌ها را نادیده می‌گیرند. انتخاب آستانه باید حساسیت (گرفتن بیماران غیرممکن) و ویژگی (اجتناب از هشدار کاذب) را متعادل کند. RF با آستانه تنظیم‌شده ۰.۵۴ تعادل عمل‌گرایانه‌ای می‌دهد، اما تنظیم ویژه سایت لازم است.

۴. **تخریب تدریجی:** مدل باید داده گم‌شده، پروفایل‌های غیرمعمول، و ورودی‌های خارج از توزیع را بدون پیش‌بینی گمراه‌کننده مدیحل کند. امتناع مبتنی بر اطمینان (امتناع از پیش‌بینی وقتی عدم قطعیت مدل بالاست) رویکرد امیدبخشی است.

۳.۱۷.۷ معماری استقرار فدرال

برای استقرار چندمؤسسه‌ای، معماری زیر را تصور می‌کنیم:

۱. هر مؤسسه شرکت‌کننده گره محلی ETHOS را اجرا می‌کند که روی داده خود آموزش دیده است.

۲. سرور تجمع مرکزی (ممکن است توسط طرف سوم بی‌طرف میزبانی شود) FedAvg دورهای را هفتگی یا ماهانه هماهنگ می‌کند و مدل سراسری را به‌روز می‌کند.

۳. مدل‌های محلی می‌توانند پس از دریافت به‌روزرسانی سراسری از راه تنظیم دقیق روی داده ویژه سایت شخصی‌سازی شوند و تعمیم سراسری را با سازگاری محلی متعادل کنند.

۴. نسخه‌گذاری مدل و پایش انحراف تضمین می‌کند مدل استقرار یافته با تکامل جمعیت بیماران و شیوه‌های بالینی کالیبره بماند.

هزینه ناچیز فدرال (۰.۵٪ AUROC) این مدل استقرار را پشتیبانی می‌کند: مؤسسات می‌توانند در بهبود مشارکتی مدل شرکت کنند بدون فدا کردن عملکرد محلی.

۴.۱۷.۷ مسیر نظارتی

استقرار بالینی نیازمند پیمایش چشم‌انداز نظارتی است:

- **FDA (US):** مدل احتمالاً به‌عنوان نرم‌افزار دستگاه پزشکی رده II (SaMD) طبق برنامه نوآوری سلامت دیجیتال FDA طبقه‌بندی می‌شود. مسیر 510(k) در صورت وجود دستگاه پیشین ممکن است مناسب باشد.

- **CE (EU):** طبق آیین‌نامه دستگاه پزشکی EU (MDR ۲۰۱۷/۷۴۵)، نرم‌افزار پشتیبانی تصمیم بالینی با تأثیر مستقیم بر بیمار نیازمند ارزیابی انطباق است.

- **بررسی مؤسسه‌ای:** اعتبارسنجی آینده‌نگر نیازمند تأیید IRB در هر مؤسسه شرکت‌کننده است.

کار ما شواهد بنیادی (عملکرد مدل، کالیبراسیون، تحلیل انصاف) را که ارسال نظارتی را پشتیبانی می‌کند فراهم می‌کند. با این حال، اعتبارسنجی آینده‌نگر روی کوه‌های مستقل پیش‌نیاز هر مسیر نظارتی است.

۱۸.۷ نوآوری و مشارکت‌های اصلی

جنبه‌های نوآورانه این پایان‌نامه را که آن را از کار پیشین متمایز می‌کند صریح‌تر می‌کنیم:

۱. **بازنمایی Symptom Token برای داده‌جدولی بالینی.** با وجود کار پیشین روی توکن‌سازی یادداشتهای بالینی یا سری زمانی، در این پژوهش قالب توکن ساخت‌یافته‌ای برای آزمایش‌ها و علائم حیاتی تجمیع‌شده معرفی می‌شود. هر توکن چهار بعد را کدگذاری می‌کند: هویت علامت، شدت نرمال‌شده، جابه‌جایی زمانی و نوع داده. این بازنمایی، پردازش مبتنی بر ترنسفورمر را برای داده‌ذاتاً جدولی ممکن می‌کند.

۲. **نخستین کاربرد یادگیری نمونه‌اولیه few-shot برای پیش‌بینی امکان‌پذیری درمان روی MIMIC-IV.** یادگیری few-shot به تصویربرداری پزشکی (X-ray، پوست‌شناسی) و کشف دارو اعمال شده اما نه به پیش‌بینی ترخیص ICU جدولی. کار ما این شکاف را پر می‌کند و

هم پتانسیل و هم محدودیت‌های فرا یادگیری اپیزودیک برای داده بالینی ساخت یافته را نشان می‌دهد.

۳. چارچوب یکپارچه **few-shot** + **فدرال** + **ترنسفورمر**. کارهای پیشین معمولاً شبکه‌های نمونه‌اولیه، میانگین‌گیری فدرال و کدگذاری ترنسفورمر را هم‌زمان برای یک وظیفه پیش‌بینی بالینی ترکیب نکرده‌اند. این یکپارچه‌سازی سه چالش را هم‌زمان پوشش می‌دهد: کمبود داده، حفظ حریم خصوصی و بازنمایی ناهمگن داده.

۴. **گزارش صادقانه با حل سازنده**. پیکربندی خط پایه، با AUROC حدود ۰.۶۱۹ در جدول کمپین V، ابتدا از خطوط پایه کلاسیک عقب می‌ماند. به جای کنار گذاشتن این یافته، چرایی شکاف تحلیل می‌شود: ناسازگاری اپیزودی، گلوگاه بازنمایی و مقیاس داده. سپس شواهد حذف تدریجی و بهبودهای مرحله‌ای مستند می‌گردد؛ در نهایت اجرای انباشتی **منجمد** با AUROC ۰.۷۴۶ در برابر SOTA جدولی ۰.۷۴۸ قرار می‌گیرد.

۵. **فرا یادگیر انباشتی و آموزش پیشرفته**. در کمپین V، انباشت V4 با ترکیب احتمال‌های **few-shot**، پیش‌بینی‌های RF و جاسازی‌های رمزگذار به AUROC برابر ۰.۷۳۲ می‌رسد. اجرای انباشتی منجمد مخزن `exp_fewshot_best` با مقدار ۰.۷۴۶ ادعای کمی اصلی برای ترکیب **few-shot**+کلاسیک در این نسخه است.

۶. **توجه درگاهی به ویژگی و شبکه‌های نمونه‌اولیه cross-attention**. معماری V5 انتخاب ویژگی تطبیقی به‌ازای نمونه (GFA) و شباهت وابسته به زمینه (نمونه‌های اولیه cross-attention) را معرفی می‌کند، با بهترین بذر AUROC ۰.۷۳۷ در کمپین توسعه. ensemble ناهمگن V6 عدم قطعیت به سبک مطابق را اکتشاف می‌کند.

۷. **سقف تجربی و بنچمارک جامع**. AUROC حدود ۰.۷۶ را به عنوان سقف تجربی امکان‌پذیری درمان روی این کوهورت معرفی می‌کنیم و نقطه مرجعی برای روش‌های آینده فراهم می‌سازیم. ارزیابی ما بیش از ۱۵ مدل، ۷ مقدار K -شات، ۵ گره بیماری، اعتبارسنجی متقاطع ۵ لایه، و چند بذر تصادفی را پوشش می‌دهد.

۱۹.۷ جدول مقایسه: کار ما در برابر پیشین

جدول ۵.۷ جایگاه این پژوهش را نسبت به رویکردهای پیشین نشان می‌دهد. تفاوت‌های اصلی عبارت‌اند از: ترکیب few-shot، یادگیری فدرال و بازنمایی مبتنی بر توکن؛ تمرکز بر داده‌ی جدولی بالینی به جای تصویر؛ و گزارش شفاف نتیجه منفی اولیه همراه با مسیر بهبود مرحله‌ای تا نزدیک شدن به سقف جدولی.

جدول ۵.۷: مقایسه با کار پیشین

جنبه	پیشین (معمول)	کار ما	یادداشت
داده	EHR متمرکز و تجمیع شده	آموزش فدرال روی 5 گره بیمار	حریم خصوصی بهتر حفظ می‌شود، هر چند استقرار واقعی هنوز به اعتبارسنجی عملیاتی نیاز دارد
چیدمان	نظارت استاندارد روی کل داده	آموزش اپیزودیک چند نمونه‌ای با امکان انباشت کلاسیک	برای سناریوهای کم داده و توزیع شده مناسب تر از یک فرایند صرفاً نظارت شده است
بازنمایی	ویژگی خام، RNN یا ترنسفورمر عمومی	+ Symptom Tokens رمزگذار ETHOS	بازنمایی توکنی برای آزمایشگاه و علائم حیاتی تجمیع شده طراحی شده است
وظیفه	مرگ و میر، LOS، بستری مجدد	امکان پذیری درمان / ترخیص	مسئله به تصمیم سازی ترخیص زودهنگام نزدیک تر است
بهترین کلاسیک	RF، XGBoost یا LSTM روی داده بزرگ	سقف جدولی RF/SOTA در بازه 0.760-0.748	این بازه سقف تجربی کوهورت حاضر را نشان می‌دهد
بهترین عصبی	معمولاً در داده بزرگ رقابتی یا برتر	Stacked BEST V4/V5؛ 0.746 به عنوان نقاط عطف تاریخی	انباشت منجمد فقط 0.002 پایین تر از برآورد نقطه‌ای SOTA است

۲۰.۷ ملاحظات اخلاقی و انصاف

استقرار مدل‌های پیش‌بینی بالینی نگرانی‌های اخلاقی برمی‌انگیزد. **سوگیری**: کوهورت ما ممکن است برخی جمعیت‌شناسی‌ها را کم‌نمایندگی کند؛ عملکرد طبقه‌بندی شده سنی (فصل ۶) برای ارزیابی انصاف گزارش می‌کنیم. **شفافیت**: توضیحات SHAP و اهمیت ویژگی ارائه می‌دهیم؛ بالینیان باید استدلال مدل را بفهمند. **پاسخگویی**: مدل‌ها جایگزین قضاوت بالینی نیستند؛ ابزار پشتیبانی تصمیم‌اند. **حریم خصوصی**: یادگیری فدرال محلّیت داده را حفظ می‌کند؛ داده خام بیمار منتقل نمی‌شود. برای استقرار تولید توصیه می‌کنیم: (۱) ممیزی انصاف در سن، جنس، و تشخیص؛ (۲) پایش مداوم برای جابجایی توزیع؛ (۳) انسان-در-حلقه برای تصمیم‌های با ریسک بالا؛ (۴) مستندسازی شفاف محدودیت‌ها.

۲۱.۷ چکلیست بازتولیدپذیری

به بهترین شیوه‌های بازتولیدپذیری پایبندیم: (۱) بذر تصادفی ثابت (۴۲) در همه آزمایش‌ها؛ (۲) تقسیم‌های داده ذخیره و به‌اشتراک گذاشته شده؛ (۳) شبکه‌های ابرپارامتر در پیوست آ مستند شده‌اند؛ (۴) ساختار کد چیدمان استاندارد پروژه را دنبال می‌کند؛ (۵) دسترسی به MIMIC-IV نیازمند احراز هویت PhysioNet است. پژوهشگران می‌توانند با دسترسی MIMIC-IV، نصب وابستگی‌ها از requirements.txt، و اجرای اسکریپت‌های آزمایش با پیکربندی مستند، نتایج را بازتولید کنند.

۲۲.۷ درس‌های آزمایش‌های V5 و V6

آزمایش‌های V5 و V6 چند نکته مهم برای یادگیری few-shot روی داده جدولی نشان می‌دهند: توجه درگاهی به ویژگی برای داده بالینی مفید است. ماژول GFA در V5، با الهام از TabNet، برای هر نمونه ماسک‌های اهمیت ویژگی می‌آموزد. بهترین بذر V5 در کمپین V به AUROC ۰.۷۳۷ می‌رسد و سقف بالقوه مسیر few-shot را نشان می‌دهد؛ البته اجرای منجمد BEST_FewShot_GFA_CrossAttn با AUROC ۰.۶۷۰ مرجع رسمی مسیر فقط few-shot در این نسخه است. واریانس بالاتر میان بذرها (AUROC 0.737-0.703 در برابر 0.713-0.696 برای V4) نشان می‌دهد این معماری به مقداردهی اولیه حساس‌تر است.

نمونه‌های اولیه با cross-attention از نظر نظری انعطاف‌پذیرترند. سر cross-attention به‌جای تکیه بر فاصله کسینوسی ثابت، شباهتی وابسته به زمینه می‌آموزد؛ رویکردی که برای داده بالینی ناهمگن و مرزهای چندوجهی مناسب‌تر است. با این حال، سود آن روی مجموعه فعلی با $n = 2,000$ محدود بود. این نتیجه نشان می‌دهد cross-attention احتمالاً برای آشکار کردن ظرفیت کامل خود به مجموعه‌های بزرگ‌تر نیاز دارد.

همگنی معماری در مقیاس کوچک بر تنوع غلبه می‌کند. ensemble ناهمگن V6 (۰.۷۲۵) از ensemble‌های هم‌معماری V4، V5 (۰.۷۳۲، ۰.۷۳۰) در کمپین V عقب می‌ماند. معماری MLP-Mixer (۰.۶۴۲ AUROC) ensemble را پایین می‌کشد چون فاقد خودتوجه است؛ تأیید می‌کند برای داده جدولی با تعامل پیچیده بین‌ویژگی، مکانیزم‌های توجه اختیاری نیستند.

انباشت ساده در مقیاس کوچک اعتبارسنجی از انباشت پیچیده بهتر است. فرا یادگیر V6 XGBoost (۰.۶۸۹ AUROC) روی مجموعه اعتبارسنجی ۳۲۰ نمونه‌ای بیش‌برازش می‌کند، در حالی که رگرسیون لجستیک کالیبره‌شده ایزوتونیک V4 (۰.۷۳۲) در آن کمپین خوب تعمیم می‌یابد.

پیکربندی انباشتی منجمد `exp_fewshot_best` باید برای عملکرد انباشت سطح ارسال استاندارد شود.

۲۳.۷ کارهای آینده

۱. پیش‌آموزش بزرگ‌تر: آموزش ETHOS روی کل کوهورت MIMIC-IV (بیش از ۵۰,۰۰۰ اقامت در ICU) یا داده EHR خارجی پیش از تنظیم دقیق few-shot. اوج بذره‌های V5 در کمپین V به AUROC ۰.۷۳۷ روی ۱,۲۸۰ نمونه آموزش رسید؛ مجموعه‌های بزرگ‌تر ممکن است عملکرد فقط few-shot را فراتر از برآورد نقطه‌ای منجمد ۰.۶۷۰ تثبیت و بهبود دهند.
 ۲. مقیاس‌دهی GFA و cross-attention: ارزیابی معماری V5 روی مجموعه‌های بالینی بزرگ‌تر جایی که نمونه‌های اولیه cross-attention سود بیشتری دهند.
 ۳. انباشت ترکیبی GFA: ترکیب رمزگذار V5 GFA با انباشت کالیبره‌شده V4 برای بهترین هر دو رویکرد.
 ۴. ارزیابی فدرال بین‌مؤسسه‌ای: ارزیابی روی داده چند بیمارستان برای ارزیابی تعمیم، به‌ویژه مکانیزم سازگاری Proto-MAML.
 ۵. پیش‌بینی مطابق در استقرار: گسترش پیش‌بینی مطابق V6 برای برآورد عدم قطعیت سطح بیمار در سامانه پشتیبانی تصمیم بالینی.
 ۶. مدل‌سازی زمانی: گنجاندن پویایی سری زمانی (روند بهبود در برابر وخامت) برای کاهش خطا در موارد مرزی.
 ۷. مقیاس‌دهی چندوظیفه: گسترش به وظایف بیشتر (مثلاً شروع سپسیس، AKI) با رمزگذارهای بزرگ‌تر.
 ۸. اعتبارسنجی آینده‌نگر: استقرار در مطالعه آزمایشی با بازخورد بالینی و ردیابی پیامد.
 ۹. MLP-Mixer تقویت‌شده با توجه: بررسی معماری‌های ترکیبی توجه-میکسر که کارایی مخلوط‌کردن توکن را با بیانگری خودتوجه ترکیب می‌کنند.
- جدول ۶.۷ نقشه‌راه مرحله‌ای کار آینده را نشان می‌دهد. در فاز ۱، تمرکز بر مقیاس‌دهی به کل MIMIC-IV و اعتبارسنجی خارجی روی eICU است. در فاز ۲، آزمایش فدرال چندسایتی، فرا یادگیرهای جایگزین مانند MAML و مقیاس‌دهی ترکیبی بررسی می‌شوند. فاز ۳ به استقرار آینده‌نگر،

مسیرهای نظارتی و دریافت بازخورد بالینی اختصاص دارد. هر فاز بر خروجی فاز پیشین بنا می‌شود و پایان‌نامه حاضر پایه فنی فاز نخست را فراهم می‌کند.

جدول ۶.۷: نقشه‌راه کار آینده

فاز زمان‌بندی تمرکز	
1	1 سال MIMIC-IV کامل، اعتبارسنجی eICU، پیش‌آموزش بزرگ‌تر
2	2 سال فدرال چندسایتی، MAML، مقیاس‌دهی ترکیبی
3	3 سال استقرار آینده‌نگر، نظارتی، بازخورد بالینی

نقشه‌راه مقیاس‌دهی (فاز ۱)، کاوش فدرال و معماری (فاز ۲)، و استقرار (فاز ۳) را اولویت‌بندی می‌کند. هر فاز به منابع و مشارکت‌های اختصاصی نیاز دارد؛ پایان‌نامه فعلی بنیاد فنی را فراهم می‌کند.

۲۴.۷ خلاصه نکات کلیدی و درس‌های آموخته‌شده

نکات اصلی را برای پژوهشگران و عملگران استخراج می‌کنیم:

۱. مدل‌های کلاسیک روی داده جدولی متوسط سقف محکمی می‌سازند. Random Forest

به AUROC حدود ۰.۷۶ می‌رسد؛ بنابراین برای ارزیابی منصفانه روش‌های جدید، داشتن خط پایه کلاسیک قوی ضروری است.

۲. فرایندهای few-shot با مهندسی سیستماتیک می‌توانند به SOTA جدولی نزدیک

شوند. شکاف میان few-shot ساده و مدل‌های جدولی قوی در ابتدا زیاد است، اما انباشت،

تقطیر، سازگاری و اصلاح معماری آن را کاهش می‌دهند. اجرای انباشتی منجمد با ۰.۷۴۶

در برابر SOTA ۰.۷۴۸ مبنای کمی ادعای نزدیک شدن به سقف است؛ در حالی که بذره‌های

کمپین V مانند ۰.۷۳۷ رفتار تاریخی بهترین اجرای تکی را نشان می‌دهند.

۳. یادگیری فدرال عملی است با هزینه ناچیز (۰.۵٪ AUROC).

۴. فرا یادگیرهای انباشتی بهترین راهبرد آمیزش در مقیاس کوچک اعتبارسنجی ($n =$

320) هستند. رگرسیون لجستیک کالیبره‌شده از انباشت XGBoost بهتر عمل می‌کند.

۵. تنوع معماری در مقیاس کوچک کمک نمی‌کند. ensemble های همگن (همان معماری، بذره‌های متفاوت) از ensemble های ناهمگن بهترند. مکانیزم‌های توجه برای few-shot جدولی ضروری‌اند.

۶. تفسیرپذیری در بهداشت مهم است. SHAP و اهمیت ویژگی برای اعتماد بالینی ضروری‌اند.

۷. مهندسی ویژگی ظرفیت مدل عصبی را تقویت می‌کند. گسترش از ۲۲ به ۱۳۲ ویژگی سیگنال غنی‌تری برای رمزگذار فراهم می‌کند.

پرسش‌های باز برای کار آینده عبارت‌اند از: (۱) بررسی اینکه پیش‌آموزش بزرگ‌تر تا چه اندازه عملکرد رمزگذار GFA را بهبود می‌دهد؛ (۲) اعتبارسنجی خارجی روی داده چندمرکز (eICU)؛ (۳) ترکیب رمزگذار V5 GFA با انباشت V4؛ (۴) مقیاس‌دهی پیش‌بینی مطابق برای سنجش عدم قطعیت آماده استقرار؛ و (۵) اعتبارسنجی بالینی آینده‌نگر.

۲۵.۷ خلاصه محدودیت‌ها

محدودیت‌های زیر را می‌پذیریم: (۱) تک مرکز: MIMIC-IV از یک بیمارستان (BIDMC) است؛ نتایج ممکن است تعمیم نیابند. (۲) اندازه نمونه: ۲,۰۰۰ بیمار متوسط است؛ MIMIC-IV کامل (۲۵۰ هزار + اقامت) می‌تواند نتیجه‌گیری متفاوتی بدهد. (۳) تعریف برچسب: امکان‌پذیری دودویی است (مقصد ترخیص + بستری مجدد)؛ تعاریف جایگزین نتایج را عوض می‌کند. (۴) ویژگی‌ها: ویژگی‌های پایه ۲۵ بعد (آزمایشگاه، علائم حیاتی، مهندسی شده)، گسترش به ۱۳۲ با مهندسی ویژگی؛ یادداشت‌های بالینی، تصویربرداری، و داروها مستثنی‌اند. (۵) وضوح زمانی: تجمیع ۲۴ ساعت اول؛ روند ساعتی یا زیرساعتی می‌تواند سیگنال اضافه کند. (۶) شبیه‌سازی فدرال: پارتیشن فدرال را به تفکیک گره بیماری شبیه‌سازی می‌کنیم؛ استقرار چندسایتی واقعی ممکن است چالش‌های اضافی (هزینه ارتباط، خرابی گره، مشتریان بیزانسی) داشته باشد. (۷) واریانس بذر V5، V6: رمزگذار V5 GFA واریانس بالای به‌ازای بذر (0.737-0.703 AUROC) دارد و نتیجه بهترین بذر (0.737) ممکن است خوش‌بینانه باشد؛ میانگین‌های ensemble (0.722) نماینده‌ترند. با وجود این محدودیت‌ها، کار ما روش‌شناسی دقیق و نقشه‌راه جامع برای پژوهش آینده فراهم می‌کند.

۲۶.۷ جمع‌بندی فصل

این فصل نتایج تجربی را تفسیر کرد: سقف جدولی منجمد با ۰.۷۴۸، اجرای انباشتی few-shot با ۰.۷۴۶، شکاف کنترل‌شده Exp1 میان Proposed_FewShot با ۰.۶۱۱ و RF با ۰.۷۶۲، هزینه فدرال در حدود ۰.۰۰۵ AUROC، و مسیر توسعه V1-V6. همچنین محدودیت‌های فرا یادگیری اپیزودیک، مقایسه با کارهای پیشین، ملاحظات استقرار، اخلاق و مسیرهای آینده بررسی شد. با وجود نتایج امیدبخش، استقرار بالینی همچنان به اعتبارسنجی آینده‌نگر و ارزیابی در سطح هر مؤسسه نیاز دارد.

فصل ۸

نتیجه‌گیری

این پایان‌نامه مسئله پیش‌بینی امکان‌پذیری درمان را بر پایه داده بالینی محدود در MIMIC-IV بررسی کرد. چارچوب پیشنهادی از Symptom Tokens، رمزگذار ETHOS، یادگیری few-shot، آموزش فدرال و چند روش تکمیلی مانند Proto-MAML، تقطیر دانش، یادگیری تضادی نظارت‌شده، توجه درگاهی به ویژگی، cross-attention و انباشت استفاده می‌کند. اعداد اصلی این فصل بر خروجی‌های منجمد مخزن استوارند و مسیر توسعه V1-V6 در فصل ۵ به‌عنوان سابقه تکامل روش گزارش شده است. یافته‌های اصلی عبارت‌اند از:

- **سقف جدولی (منجمد):** فرایند اختصاصی جدولی به AUROC آزمون ۰.۷۴۸ می‌رسد (فصل ۵، جدول ۱.۵).
- **انباشت few-shot + کلاسیک (منجمد):** بهترین انباشت exp_fewshot_best به AUROC ۰.۷۴۶ [0.699, 0.797] می‌رسد؛ یعنی تنها حدود ۰.۰۰۲ پایین‌تر از برآورد نقطه‌ای سقف.
- **تنها few-shot (منجمد):** بهترین few-shot (CrossAttn+GFA) به AUROC ۰.۶۷۰ [0.612, 0.726] می‌رسد.
- **مقایسه اسکرپت Exp1 (تقسیم ثابت):** Proposed_FewShot ۰.۶۱۱ در برابر Ran-dom Forest ۰.۷۶۲ روی همان چارچوب ارزیابی.
- **کمپین V (تاریخی):** جدول ۱۵.۵ بهبودهای تدریجی را گزارش می‌کند (مثلاً انباشت V4 در ۰.۷۳۲، بهترین بذر V5 در ۰.۷۳۷، و RF با آستانه تنظیم‌شده در ۰.۷۶۰)؛ برای ادعاهای

اجرای نخست به جداول اصلی ارجاع دهید.

- **یادگیری فدرال:** شکاف AUROC میان آموزش متمرکز و فدرال در آزمایش گزارش شده ۰.۰۰۵ است؛ یعنی آموزش حافظ حریم خصوصی در این شبیه‌سازی با هزینه عملکردی محدود امکان‌پذیر بوده است.
- **پیش‌بینی مطابق (conformal) (اکتشافی):** تحلیل‌های سبک V6 مجموعه‌های پیش‌بینی کالیبره در اجراهای توسعه فراهم می‌کنند؛ اینجا به‌عنوان شاخص‌های کلیدی ارسال دوباره تأکید نمی‌شوند.
- **سقف تجربی:** مدل‌های جدولی قوی در این کوهورت، بسته به پروتکل، در بازه ۰.۷۴۸-۰.۷۶۰ قرار دارند.

این پژوهش یک مطالعه بازتولیدپذیر از یادگیری few-shot جدولی برای امکان‌پذیری درمان روی MIMIC-IV ارائه می‌کند؛ همراه با خطوط پایه صادقانه، بازنمایی بالینی مبتنی بر Symptom Tokens، ارزیابی فدرال و خروجی‌های قابل بازتولید در results/ و جداول تولیدشده LaTeX. عملکرد انباشتی نزدیک به سقف، یعنی ۰.۷۴۶ در برابر ۰.۷۴۸، نشان می‌دهد اگر بازنمایی، هم‌جوشی مدل‌ها و روند آموزش با ماهیت وظیفه هماهنگ شود، روش‌های few-shot می‌توانند به مدل‌های کلاسیک قوی نزدیک شوند.

۱.۸ خلاصه مشارکت‌ها

جدول ۱.۸ مشارکت‌ها را برای مرور سریع جمع می‌کند.

۱.۱.۸ پیامدها برای استقرار بالینی

برای بالین‌دانان و مدیران سلامت، یافته‌ها در مرحله پژوهشی هستند:

۱. **عملکرد:** مدل انباشتی منجمد به AUROC ۰.۷۴۶ می‌رسد؛ پیش از هر کاربرد پشتیبان تصمیم، اعتبارسنجی محلی الزامی است.
۲. **آموزش حافظ حریم خصوصی:** آموزش فدرال در شبیه‌سازی ما هزینه کوچکی در AUROC دارد؛ با این حال، استقرار چندسایتی واقعی به آزمون عملیاتی نیاز دارد.

جدول ۱.۸: خلاصه مشارکت‌ها

مشارکت شرح	
1	مطالعه امکان‌پذیری few-shot جدولی با معیارهای منجمد: انباشت 0.746 در برابر SOTA 0.748؛ شکاف Exp1 0.611 در برابر 0.762
2	Symptom Tokens به‌عنوان بازنمایی فشرده بالینی برای یادگیری اپیزودیک و مبتنی بر ترنسفورمر
3	سقف تجربی AUROC در بازه 0.75-0.76 در این کوهورت؛ جداول اصلی در فصل ۵
4	مقایسه فدرال در برابر متمرکز با شکاف 0.005 AUROC (گره‌های شبیه‌سازی‌شده)
5	تحلیل حذف تدریجی، حساسیت K -شات، و تحلیل بین‌گره‌ای
6	سازگاری به‌سبک Proto-MAML در کمپین V کاوش شد
7	انباشت فرا یادگیرنده‌ها برای هم‌جوشی سیگنال‌های few-shot و کلاسیک؛ exp_fewshot_best به‌عنوان مرجع منجمد
8	تقطیر دانش و پیش‌آموزش تضاد در نقشه راه بهبود
9	توجه درگاهی به ویژگی و نمونه‌های cross-attention (کمپین V؛ بهترین بذر 0.737)
10	مجموعه‌های ناهمگن و تحلیل‌های سبک مطابق (اکتشافی)
11	تولید خودکار جدول از CSV/JSON به پایان‌نامه (پیوست د)
12	نقشه راه آموزش تدریجی (V1-V6) همراه با تفکیک صریح بین اعداد منجمد ارسال و تاریخی

۳. **سازگاری:** سازگاری به سبک Proto-MAML امیدبخش است اما باید روی داده آینده‌نگر و ویژه سایت ارزیابی شود.
۴. **شفافیت:** انباشت امکان مقایسه اجزای few-shot در برابر کلاسیک را وقتی هر دو در دسترس‌اند فراهم می‌کند.
۵. **توصیه‌های استقرار:** از آستانه‌های اطمینان، بررسی‌های انصاف، پایش انحراف، و نظارت انسانی استفاده کنید؛ قضاوت بالینی را جایگزین نکنید.

۲.۱.۸ تطبیق نهایی با پروپوزال

در مقایسه با پروپوزال اولیه، هسته علمی کار حفظ شده است: پیش‌بینی امکان‌پذیری درمان با ترکیب few-shot learning، یادگیری فدرال، ETHOS و Symptom Tokens. تفاوت اصلی در دامنه عملیاتی است. پروپوزال از داده‌های چندمنبعی گسترده و حتی سناریوهای دارای واسط کاربری سخن می‌گفت؛ اجرای نهایی، برای حفظ بازتولیدپذیری و اعتبار علمی، روی MIMIC-IV و منابع درون EHR یعنی آزمایشگاه‌ها، علائم حیاتی و ویژگی‌های مشتق‌شده متمرکز شد. بنابراین این پایان‌نامه نه یک سامانه تولیدی کامل، بلکه یک ارزیابی پژوهشی دقیق و قابل بازتولید از چارچوب پیشنهادی است. پیاده‌سازی واسط کاربری، اتصال به داده زنده یا پوشیدنی، و اعتبارسنجی چندسایتی واقعی به‌عنوان گام‌های طبیعی پس از این پایان‌نامه باقی می‌مانند.

۳.۱.۸ توصیه‌ها برای پژوهشگران و عملگران

۱. برای بیشینه دقت در این کوهورت: فرایند جدولی SOTA منجمد (AUROC ۰.۷۴۸) یا خطوط پایه کلاسیک هم‌تراز را ترجیح دهید؛ انباشت‌های few-shot را نیز گزارش کنید.
۲. برای هم‌جوشی few-shot + کلاسیک: پیکربندی exp_fewshot_best را به‌عنوان مرجع مستند (۰.۷۴۶) به کار ببرید.
۳. برای تنظیمات فدرال: در چیدمان ما اختلاف‌های عملکرد کوچک در برابر متمرکز انتظار دارید؛ ارتباط و ناهمگونی داده را جداگانه اعتبارسنجی کنید.
۴. برای سایت‌های جدید: کالیبراسیون، تنظیم آستانه، و ارزیابی آینده‌نگر را برنامه‌ریزی کنید.
۵. برای ادعاهای غیربرتری آماری: آزمون‌های آماری جفتی روی بردارهای پیش‌بینی هم‌تراز

اجرا کنید؛ به p -مقادیر تاریخی از پیش‌نویس‌های پیشین تکیه نکنید.

۴.۱.۸ اهمیت برای حوزه

این کار به انفورماتیک بالینی و فرا یادگیری سه افزوده اصلی دارد: (۱) گزارش هم‌زمان سقف‌های جدولی قوی و مسیر few-shot نزدیک به آن‌ها (۰.۷۴۶ در برابر ۰.۷۴۸)؛ (۲) ترکیب دیدگاه فدرال و few-shot در یک وظیفه ساخت‌یافته ICU؛ و (۳) مستندسازی مسیر بهبود چندمرحله‌ای V1-V6 با تفکیک روشن میان اعداد منجمد و اعداد تاریخی. Symptom Tokens و انباشت few-shot+ETHOS می‌توانند قالبی برای سناریوهای کم‌داده و حساس به حریم خصوصی باشند، به شرط آنکه در داده‌های بیرونی نیز اعتبارسنجی شوند.

۵.۱.۸ جمع‌بندی

شکاف میان پیکربندی‌های ساده few-shot و مدل‌های جدولی قوی واقعی است؛ برای نمونه در Exp1، مقدار ۰.۶۱۱ در برابر ۰.۷۶۲ قرار می‌گیرد. با این حال، مهندسی سیستماتیک در بازنمایی، مراحل آموزش، تقطیر، سازگاری و انباشت می‌تواند اجرای یکپارچه را به برآورد نقطه‌ای SOTA جدولی نزدیک کند. بهبودهای بعدی به احتمال زیاد به پیش‌آموزش بزرگ‌تر، داده چندسایتی و اعتبارسنجی آینده‌نگر نیاز خواهند داشت.

۶.۱.۸ پاسخ به پرسش‌های پژوهشی

جدول ۲.۸ چگونگی پاسخ‌گویی آزمایش‌ها به هر پرسش پژوهشی را خلاصه می‌کند.

جدول ۲.۸: خلاصه پاسخ به پرسش‌های پژوهشی

RQ	پرسش	پاسخ
RQ1	آیا فرا یادگیری few-shot می‌تواند خطوط پایه کلاسیک را جبران کند؟	به‌تنهایی نه؛ اما با هم‌جوشی و انباشت می‌تواند بسیار نزدیک شود. اجرای منجمد Stacked BEST به 0.746 در برابر سقف جدولی 0.748 می‌رسد، در حالی که FewShot BEST تنها 0.670 و Proposed_FewShot در Expl فقط 0.611 در برابر RF با 0.762 است.
RQ2	شات پشتیبان K چگونه بر عملکرد اثر می‌گذارد؟	اثر K محدود است. AUROC اپیزودیک در بازه 0.557-0.564 می‌ماند و بهترین میانگین در $K=3$ با 0.564 دیده شد؛ بنابراین افزایش K در این مقیاس به‌تنهایی شکاف اصلی را نمی‌بندد.
RQ3	هزینه یادگیری فدرال چیست؟	کوچک است: در آزمایش گزارش شده، AUROC از 0.552 در حالت متمرکز به 0.547 در حالت فدرال افت می‌کند؛ یعنی شکاف تنها 0.005.
RQ4	کدام اجزا بیشترین سهم را دارند؟	مهندسی ویژگی و وزن‌دهی شدت سهم بالایی دارند. حذف Symptom Tokens افت ایجاد نمی‌کند و LR روی ویژگی‌های خام از لوله توکنی ساده بهتر عمل می‌کند؛ پس گلوگاه اصلی بیشتر در کیفیت بازنمایی است تا صرفِ فرا-آموزش.
RQ5	آیا مدل بین گروه‌های بیماری تعمیم می‌یابد؟	تعمیم بین‌گروهی محدود اما ممکن است. مدل پیشنهادی روی برخی گره‌های نگه‌داشته شده از XGBoost/LR عقب می‌ماند؛ بنابراین برای تعمیم پایدار بین بیماری‌ها به داده بیشتر، پیش‌آموزش بهتر و ارزیابی چندسایتی نیاز است.

پیوست آ

ابریارامترها

این پیوست تمام ابریارامترهای به کاررفته در آزمایش‌های ما را فهرست می‌کند.

۱.آ رمزگذار ETHOS

جدول ۱.آ: پیکربندی رمزگذار ETHOS

پارامتر	مقدار
d_model	128
nhead	8
num_layers	2
d_ff	512
dropout	0.2
vocab_size	23

۲.آ یادگیری کم‌نمونه (Few-Shot)

۳.آ یادگیری فدرال (Federated)

۴.آ بهترین مدل نهایی (Random Forest)

جدول آ.۲: پیکربندی Few-Shot

پارامتر	مقدار
n_support (K)	5
n_query (Q)	15
n_way	2
temperature	10.0
use_focal_loss	true
focal_gamma	2.0
n_episodes_train	500
n_episodes_val	100
n_episodes_test	500
lr	0.001
max_epochs	50
early_stop_patience	10

جدول آ.۳: پیکربندی فدرال

پارامتر	مقدار
n_rounds	20
n_nodes	5
aggregation	fedavg
local_epochs	3
local_batch_size	32

جدول آ.۴: ابرپارامترهای RandomForest_threshold_tuned

پارامتر	مقدار
n_estimators	200
max_depth	28
min_samples_split	5
min_samples_leaf	2
max_features	log2
class_weight	balanced
threshold	0.54

پیوست ب

پرس وجوهای SQL برای MIMIC-IV

این پیوست نمونه‌هایی از پرس وجوهای SQL به کاررفته برای استخراج کوهورت و ویژگی از MIMIC-IV را ارائه می‌کند. استخراج واقعی برای کارایی از DuckDB استفاده می‌کند.

ب.۱ استخراج کوهورت

Cohort: First ICU Stay, Min 4h LOS

```
SELECT
    ie.subject_id, ie.hadm_id, ie.stay_id,
    ie.intime, ie.outtime,
    EXTRACT(EPOCH FROM (ie.outtime - ie.intime))/3600 AS los_hours
FROM icu.icustays ie
JOIN patients p ON ie.subject_id = p.subject_id
WHERE EXTRACT(EPOCH FROM (ie.outtime - ie.intime))/3600 >= 4
    AND p.anchor_age >= 18
ORDER BY ie.subject_id, ie.intime
LIMIT 1 PER subject_id;
```

ب.۲. استخراج آزمایشگاه

Labs from First 24h

```
SELECT
    le.subject_id, le.hadm_id, le.stay_id,
    le.itemid, le.valuenum, le.charttime
FROM hosp.labevents le
JOIN cohort c ON le.hadm_id = c.hadm_id
WHERE le.charttime BETWEEN c.intime AND c.intime + INTERVAL '24 hours'
    AND le.itemid IN (50912, 50971, 50983, 50902, 50931, ...)
    AND le.valuenum IS NOT NULL;
```

ب.۳. استخراج علائم حیاتی

Vitals from First 24h

```
SELECT
    ce.subject_id, ce.hadm_id, ce.stay_id,
    ce.itemid, ce.valuenum, ce.charttime
FROM icu.chartevents ce
JOIN cohort c ON ce.stay_id = c.stay_id
WHERE ce.charttime BETWEEN c.intime AND c.intime + INTERVAL '24 hours'
    AND ce.itemid IN (220045, 220050, 220051, 220052, ...)
    AND ce.valuenum IS NOT NULL;
```

ب.۴. برچسب: محل ترخیص

Feasible Discharge

```
SELECT
    a.hadm_id,
    CASE WHEN a.discharge_location IN (
        'HOME', 'HOME HEALTH CARE',
        'REHAB/DISTINCT PART HOSP', 'REHAB'
    ) AND NOT EXISTS (
```



```

SELECT 1 FROM admissions readmit
WHERE readmit.subject_id = a.subject_id
      AND readmit.admittime BETWEEN
      a.discharge_location_time AND
      a.discharge_location_time + INTERVAL '30 days'
) THEN 1 ELSE 0 END AS feasible
FROM admissions a;

```

ب.۵ تشخیص اولیه برای گره‌های بیماری

Assign Primary ICD-10 to Nodes

```

SELECT hadm_id,
CASE
  WHEN icd_code LIKE 'A40%' OR icd_code LIKE 'A41%'
    OR icd_code = 'R652' THEN 1
  WHEN icd_code LIKE 'I21%' OR icd_code LIKE 'I22%'
    OR icd_code LIKE 'I25%' OR icd_code LIKE 'I50%'
    OR icd_code LIKE 'I47%' OR icd_code LIKE 'I48%'
    OR icd_code LIKE 'I49%' THEN 2
  WHEN icd_code LIKE 'J18%' OR icd_code LIKE 'J44%'
    OR icd_code LIKE 'J96%' OR icd_code LIKE 'J80%'
    OR icd_code LIKE 'J15%' THEN 3
  WHEN icd_code LIKE 'N17%' OR icd_code LIKE 'N18%'
    OR icd_code LIKE 'N19%' THEN 4
  WHEN icd_code LIKE 'E10%' OR icd_code LIKE 'E11%'
    OR icd_code LIKE 'E13%' THEN 5
  ELSE 0
END AS node_id
FROM diagnoses_icd
WHERE seq_num = 1;

```

ب.۶ تجمیع: اولین مقدار به‌ازای هر بستری

برای آزمایش‌ها و علائم حیاتی، ۲۴ ساعت اول را با میانه (یا اولین مقدار) به‌ازای هر itemid و هر بستری تجمیع می‌کنیم. زیر منطق تجمیع را به‌صورت شبه‌کد نشان می‌دهد:

Aggregation Logic

```
def aggregate_first_24h(events, intime, window_hours=24):  
    end_time = intime + timedelta(hours=window_hours)  
    mask = (events['charttime'] >= intime) & (events['charttime'] <= end_time)  
    filtered = events.loc[mask]  
    # Per itemid: take median (or first) value  
    agg = filtered.groupby('itemid')['valuenum'].median()  
    return agg
```

پیوست پ

قطعه کدهای برنامه

این پیوست قطعه کدهای کلیدی از پیاده سازی ما را ارائه می کند.

پ.۱ Tokenization علائم

ساخت دنباله token کد پ.۱:

```
1 def build_tokens(X, seq_len=25, lab_count=15):
2     n_samples, n_features = X.shape
3     tokens = np.zeros((n_samples, seq_len, 4), dtype=np.float32)
4     for i in range(n_samples):
5         valid = np.where(~np.isnan(X[i]) & (X[i] >= 0) & (X[i] <= 1))[0]
6         for j, idx in enumerate(valid[:seq_len]):
7             tokens[i, j, 0] = idx + 1 # symptom_id
8             tokens[i, j, 1] = float(X[i, idx]) # intensity
9             tokens[i, j, 2] = 0.0 # time_delta
10            tokens[i, j, 3] = 0.0 if idx < lab_count else 1.0 # modality
11    return tokens
```

پ.۲ سر Prototypical

محاسبه prototype و طبقه بندی کد پ.۲:

```
1 def compute_prototypes(support_embeddings, support_labels):
```

```

2     classes = torch.unique(support_labels)
3     prototypes = []
4     for c in classes:
5         mask = support_labels == c
6         proto = support_embeddings[mask].mean(dim=0)
7         prototypes.append(proto)
8     return torch.stack(prototypes)
9
10 def classify_query(query_embeddings, prototypes, temperature=10.0):
11     logits = F.cosine_similarity(
12         query_embeddings.unsqueeze(1),
13         prototypes.unsqueeze(0),
14         dim=-1
15     ) * temperature
16     return F.softmax(logits, dim=-1)

```

پ.۳. Focal Loss

پیاده‌سازی Focal Loss کد پ.۳:

```

1 def focal_loss(logits, targets, gamma=2.0, alpha=None):
2     ce = F.cross_entropy(logits, targets, reduction='none')
3     pt = torch.exp(-ce)
4     focal = ((1 - pt) ** gamma) * ce
5     if alpha is not None:
6         alpha_t = alpha[targets]
7         focal = alpha_t * focal
8     return focal.mean()

```

پ.۴. عبور رو به جلوی رمزگذار ETHOS

رمزگذار ETHOS (ساده‌شده) کد پ.۴:

```

1 class ETHOSEncoder(nn.Module):
2     def __init__(self, d_model=128, nhead=8, num_layers=2):
3         super().__init__()

```

```

4         self.embed = nn.Linear(4, d_model) # 4 = token dims
5         encoder_layer = nn.TransformerEncoderLayer(
6             d_model, nhead, dim_feedforward=512, dropout=0.2
7         )
8         self.transformer = nn.TransformerEncoder(encoder_layer, num_layers)
9         self.d_model = d_model
10
11     def forward(self, x):
12         # x: (B, L, 4)
13         h = self.embed(x) # (B, L, d_model)
14         h = h.transpose(0, 1) # (L, B, d_model)
15         h = self.transformer(h)
16         h = h.mean(dim=0) # (B, d_model)
17         return h

```

پ.۵ به روزرسانی سرور FedAvg

تجميع FedAvg كد پ.۵:

```

1 def fedavg_aggregate(client_weights, client_sizes):
2     total = sum(client_sizes)
3     global_state = {}
4     for key in client_weights[0].keys():
5         global_state[key] = sum(
6             w[key] * n for w, n in zip(client_weights, client_sizes)
7         ) / total
8     return global_state

```

پیوست ت

جداول کامل نتایج

این پیوست جداول تفصیلی نتایج را ارائه می کند.

ت.۱ Tabular SOTA: همه مدل ها

جدول ت.۱: خط لوله Tabular SOTA: مدل های تکی (مجموعه آزمون)

مدل	AUROC	F1	Accuracy	MCC
XGBoost	۷۴۳.۰	۶۷۲.۰	۶۸۰.۰	۳۵۶.۰
RandomForest	۷۶۰.۰	۶۶۹.۰	۷۰۵.۰	۳۴۷.۰
LightGBM	۷۲۷.۰	۶۴۱.۰	۶۷۸.۰	۲۸۹.۰
CatBoost	۷۳۱.۰	۶۶۴.۰	۶۸۳.۰	۳۲۹.۰

ت.۲ نتایج Ensemble

جدول ت.۲: مدل های Ensemble (مجموعه آزمون)

مدل	Threshold	AUROC	F1	Accuracy	MCC
SoftVoting	۵۱.۰	۷۴۳.۰	۶۵۴.۰	۶۷۵.۰	۳۰۹.۰
Stacking	۴۵.۰	۷۴۲.۰	۶۵۶.۰	۶۷۸.۰	۳۱۱.۰
RandomForest_threshold_tuned	۵۴.۰	۷۶۰.۰	۶۸۲.۰	۷۰۳.۰	۳۶۴.۰

ت.۳ شناسه‌های آیتم آزمایشگاه و علائم حیاتی

جدول ت.۳: شناسه‌های آیتم آزمایشگاه MIMIC-IV

بازه (حداقل-حداکثر)	نام	شناسه آیتم
0.1–30 mg/dL	Creatinine	۵۰۹۱۲
1.5–10 mEq/L	Potassium	۵۰۹۷۱
100–180 mEq/L	Sodium	۵۰۹۸۳
70–130 mEq/L	Chloride	۵۰۹۰۲
20–600 mg/dL	Glucose	۵۰۹۳۱
4–16 mg/dL	Calcium	۵۰۸۹۳
0.5–6 mEq/L	Magnesium	۵۰۹۶۰
3–25 g/dL	Hemoglobin	۵۰۸۱۱
5–1000 K/uL	Platelets	۵۱۲۶۵
0.5–50 K/uL	WBC	۵۱۳۰۰
0.5–25 mmol/L	Lactate	۵۰۸۱۳
5–2000 U/L	ALT	۵۰۸۶۱
5–2000 U/L	AST	۵۰۸۷۸
5–300 mg/dL	BUN	۵۱۰۰۶
5–50 mEq/L	Bicarbonate	۵۰۸۸۲

جدول ت.۴: شناسه‌های آیتم علائم حیاتی MIMIC-IV

شناسه آیتم نام	بازه
۲۲۰۰۴۵ ضربان قلب	20–250 bpm
۲۲۰۰۵۰ فشار سیستولیک	40–250 mmHg
۲۲۰۰۵۱ فشار دیاستولیک	20–180 mmHg
۲۲۰۰۵۲ فشار میانگین	30–200 mmHg
۲۲۳۷۶۱ دما	90–110 F
۲۲۰۲۷۷ SpO2	50–100 %
۲۲۰۲۱۰ نرخ تنفس	1–60 /min

پیوست ث

استنتاج‌های ریاضی

این پیوست استنتاج‌های ریاضی برای اجزای کلیدی را ارائه می‌کند.

ث.۱ تعریف AUROC

مساحت زیر منحنی ROC (AUROC) به صورت زیر تعریف می‌شود:

$$\text{AUROC} = \int_0^1 \text{TPR}(t) d(\text{FPR}(t)) = \int_0^1 \text{TPR}(\text{FPR}^{-1}(u)) du \quad (\text{ث.۱})$$

که در آن TPR (نرخ مثبت صحیح) و FPR (نرخ مثبت کاذب) توابعی از آستانه تصمیم t هستند. به طور معادل، AUROC برابر است با احتمال اینکه یک نمونه مثبت تصادفی بالاتر از یک نمونه منفی تصادفی رتبه‌بندی شود:

$$\text{AUROC} = P(\text{score}(X^+) > \text{score}(X^-)) \quad (\text{ث.۲})$$

AUROC نسبت به آستانه ثابت است و برای طبقه‌بندی نامتعادل مناسب است.

ث.۲ F1-Macro

برای طبقه‌بندی دودویی با کلاس‌های ۰ و ۱:

$$F1_k = \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \quad (\text{ث.۳})$$

F1-macro میانگین روی کلاس‌هاست:

$$F1_{\text{macro}} = \frac{F1_0 + F1_1}{2} \quad (\text{ث.۴})$$

این هر دو کلاس را به‌طور یکسان در نظر می‌گیرد؛ برای داده نامتعادل مهم است.

ث.۳ ضریب همبستگی متیوز (MCC)

MCC به‌صورت زیر تعریف می‌شود:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (\text{ث.۵})$$

MCC در بازه $[-1, 1]$ است؛ مقدار ۰ پیش‌بینی تصادفی را نشان می‌دهد. مقارن است و نسبت به نامتعادل کلاس‌ها مقاوم است.

ث.۴ گرادیان تابع زیان شبکه نمونه‌اولیه‌ای (Prototypical)

برای شبکه‌های نمونه‌اولیه‌ای با تابع زیان آنتروپی متقاطع $\mathcal{L} = -\log p(y|x)$ ، گرادیان نسبت به جاسازی پرس‌وجو $f_{\theta}(x)$ عبارت است از:

$$\frac{\partial \mathcal{L}}{\partial f_{\theta}(x)} = \frac{1}{\tau} \left(\mathbf{c}_y - \sum_k p(y = k|x) \mathbf{c}_k \right) \quad (\text{ث.۶})$$

که در آن $\mathbf{c}_k$ نمونه‌اولیه کلاس k است. گرادیان پرس‌وجو را به سمت نمونه‌اولیه واقعی می‌کشد و از بقیه دور می‌کند.

ث.۵ Focal Loss

Focal loss نمونه‌های آسان را کم‌اهمیت می‌کند:

$$\mathcal{L}_{\text{focal}} = -\alpha(1 - p_t)^\gamma \log(p_t) \quad (\text{ث.۷})$$

که در آن $p_t = p(y|x)$ احتمال پیش‌بینی شده برای کلاس درست است. برای $\gamma > 0$ ، نمونه‌های آسان ($p_t \approx 1$) سهم کمتری دارند. ما $\gamma = 2$ استفاده می‌کنیم.

ث.۶ قانون به‌روزرسانی FedAvg

میانگین‌گیری فدرال (Federated Averaging) به‌روزرسانی‌های محلی را با میانگین وزنی تجميع می‌کند:

$$\theta_{t+1} = \sum_{k=1}^K \frac{n_k}{n} \theta_{t+1}^{(k)} \quad (\text{ث.۸})$$

که در آن n_k تعداد نمونه‌ها در کلاینت k ، $n = \sum_k n_k$ و $\theta_{t+1}^{(k)}$ مدل پس از آموزش محلی روی کلاینت k است. وقتی داده‌ها IID باشند، گرادیان مورد انتظار هدف سراسری حفظ می‌شود؛ تحت non-IID همگرایی ممکن است کندتر باشد.

ث.۷ خودتوجه (Self-Attention)

برای دنباله ورودی $\mathbf{X} \in \mathbb{R}^{L \times d}$ ، خودتوجه به‌صورت زیر محاسبه می‌شود:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \right) \mathbf{V} \quad (\text{ث.۹})$$

که در آن $\mathbf{Q} = \mathbf{X}\mathbf{W}_Q$ ، $\mathbf{K} = \mathbf{X}\mathbf{W}_K$ ، $\mathbf{V} = \mathbf{X}\mathbf{W}_V$. توجه چندسر h چنین عملیاتی را موازی اجرا کرده و خروجی‌ها را به‌هم می‌چسباند. در ETHOS از $h = 8$ سر استفاده می‌کنیم.

ث.۸. بازه اطمینان bootstrap

برای AUROC، بازه اطمینان ۹۵٪ با نمونه‌برداری مجدد از مجموعه آزمون $B = 1000$ بار با جایگزینی محاسبه می‌کنیم. برای هر نمونه bootstrap b ، $\hat{A}_b = \text{AUROC}(y, \hat{y}_b)$ را می‌سنجیم. بازه اطمینان $[\hat{A}_{(25)}, \hat{A}_{(975)}]$ است که زیرنویس‌ها صدک‌های توزیع bootstrap را نشان می‌دهند.

ث.۹. آزمون DeLong

آزمون DeLong [DeLong et al., 1988] دو منحنی ROC همبسته را مقایسه می‌کند. برای پیش‌بینی‌های جفت (s_1, s_2) روی همان نمونه‌ها، آماره آزمون بر اساس تفاوت در AUC تجربی است. تحت فرض صفر (برابری AUC)، آماره به‌طور مجانبی نرمال است. برای RF در برابر ETHOS، $p < 0.01$ گزارش می‌کنیم.

پیوست ج

زمان‌بندی پروژه (نمودار گانت)

این پیوست زمان‌بندی پروژه را به صورت نمای گانت ارائه می‌کند.

ج.۱ زمان‌بندی ۱۲ ماهه

پروژه طبق برنامه ۱۲ ماهه هم‌راستا با پیشنهاد پیش می‌رود. فازهای ۱ تا ۹ مرور ادبیات، طراحی کوهورت، tokenization، پیاده‌سازی ETHOS، آموزش کم‌نمونه و فدرال، مقایسه با خط پایه، آزمایش‌ها و نگارش پایان‌نامه را پوشش می‌دهند.

ج.۲ نمای کلی فازها

ج.۳ نقاط عطف کلیدی

- هفته ۴: اتمام مرور ادبیات؛ نهایی‌شدن پرسش‌های پژوهشی.
- هفته ۷: استخراج کوهورت؛ پردازش ۲,۰۰۰ بیمار اول.
- هفته ۱۴: عملیاتی‌شدن خط لوله ETHOS+FewShot.
- هفته ۱۸: اتمام مقایسه فدرال در برابر متمرکز.
- هفته ۲۴: اجرای همه آزمایش‌ها؛ شناسایی بهترین مدل (RF).
- هفته ۳۲: تکمیل پیش‌نویس پایان‌نامه؛ آماده‌سازی دفاع.

جدول ج.۱: نمای کلی گانت پروژه

فاز وظیفه	شروع (هفته)	مدت
۱ مرور ادبیات	۱	۴
۲ دسترسی MIMIC-IV و طراحی کوهورت	۵	۲
۳ استخراج داده و tokenization	۷	۴
۴ پیاده‌سازی رمزگذار ETHOS	۱۱	۳
۵ فرا یادگیری کم‌نمونه	۱۴	۴
۶ آموزش فدرال	۱۸	۲
۷ خط پایه Tabular SOTA	۱۲	۴
۸ آزمایش‌ها و حذف اجزا	۲۰	۴
۹ نگارش و اشکال‌ها	۲۴	۸

ج.۴. گرافیک نقشه راه

شکل ج.۱ نقشه راه کارهای آینده (۱ تا ۵ سال) را نشان می‌دهد.

نقشه راه کارهای آینده

فاز ۱ (۱ سال): کوهورت بزرگ‌تر، اعتبارسنجی بیرونی
 فاز ۲ (۲ سال): آزمایش چندسایتی فدرال
 فاز ۳ (۳ سال): استقرار آینده‌نگر
 فاز ۴ (۴ سال): مسیر تأیید مقرراتی
 فاز ۵ (۵ سال): یکپارچه‌سازی پشتیبان تصمیم بالینی

شکل ج.۱: فازهای کار آینده (۱ تا ۵ سال)

ج.۵. مدیریت ریسک

جدول ج.۲ ریسک‌های پروژه و راهکارهای کاهش را، مطابق چارچوب مدیریت پروژه پیشنهاد، خلاصه می‌کند.

جدول ج.۲: مدیریت ریسک پروژه

ریسک	احتمال	اثر	کاهش اثر
تأخیر دسترسی به داده	متوسط	بالا	درخواست زودهنگام اعتبار MIMIC-IV؛ داده مصنوعی پشتیبان
عملکرد ضعیف مدل	پایین	پایین	تکیه بر سقف‌های کلاسیک موجود؛ انباشت few-shot و خط پایه جدولی به‌عنوان مسیر پشتیبان
مشکل همگرایی فدرال	پایین	متوسط	تنظیم FedAvg؛ بازگشت به متمرکز
محدودیت منابع محاسباتی	پایین	پایین	اعتبار ابری؛ کوهورت کوچک‌تر در صورت نیاز
لغزش زمان‌بندی	متوسط	متوسط	بافر در گانت؛ اولویت آزمایش‌های هسته

پیوست چ

واژه‌نامه (۵۰ واژه)

این پیوست واژه‌های کلیدی به کاررفته در پایان‌نامه را تعریف می‌کند.

۱. چ مفاهیم هسته

۲. چ واژه‌نامه تفصیلی (فهرست کامل)

واژه	تعریف
Adversarial robustness	تاب‌آوری مدل در برابر ورودی‌های مختل شده.
Attention mechanism	وزن‌ها روی token‌های ورودی برای بازنمایی وابسته به زمینه.
AUROC	مساحت زیر منحنی ROC؛ احتمال بالاتر بودن رتبه مثبت نسبت به منفی.
AUPRC	مساحت زیر منحنی دقت-بازخوانی؛ برای داده نامتعادل مفید است.
Bootstrap CI	بازه اطمینان از نمونه‌برداری مجدد با جایگزینی.
Calibration	تطابق احتمالات پیش‌بینی شده با فراوانی مشاهده شده.
Class imbalance	توزیع نابرابر کلاس‌ها (مثلاً 42٪ در برابر 58٪).
Cross-validation	ارزیابی K-fold برای برآورد پایدار عملکرد.
Differential privacy	تضمین رسمی حریم خصوصی برای آمار تجمیعی.
Embedding	بردار متراکم بازنمایی ورودی (مثلاً 128 بعدی).
Episodic training	فرا یادگیری با نمونه‌برداری قسمت support/query.

واژه	تعریف
ETHOS	Encoder for Time-series and Heterogeneous Organ Signals
FedAvg	میانگین‌گیری فدرال؛ میانگین وزنی به‌روزرسانی‌های کلاینت.
Federated learning	آموزش روی داده‌های توزیع‌شده بدون متمرکزسازی.
Feasibility	دودویی: تریخیص به منزل/توان‌بخشی (1) در برابر مرگ/SNF (0).
Focal loss	آنتروپی متقاطع با کم‌اهمیت‌کردن نمونه‌های آسان با $(1 - p)^\gamma$.
F1-macro	میانگین F1 به‌ازای هر کلاس؛ کلاس‌ها را برابر می‌انگارد.
Gradient descent	بهینه‌سازی با حرکت تکراری در جهت مخالف گرادیان.
Hyperparameter	پارامتر مدل/پیکربندی که پیش از آموزش تنظیم می‌شود (مثلاً نرخ یادگیری).
ICD-10	طبقه‌بندی بین‌المللی بیماری‌ها، ویرایش دهم.
ICU LOS	مدت بستری در واحد مراقبت ویژه.
Imputation	پر کردن مقادیر گم‌شده (مثلاً forward-fill، میانگین).
ItemID	شناسه MIMIC برای نوع اندازه‌گیری آزمایش/علامت حیاتی.
K-shot	تعداد نمونه‌های support به‌ازای هر کلاس (مثلاً $K = 5$).
Label smoothing	نرم کردن برچسب‌های one-hot برای تنظیم.
LightGBM	تقویت گرادیان با رشد برگ‌محور.
MAML	Model-Agnostic Meta-Learning؛ یادگیری مقداردهی اولیه برای سازگاری سریع.
MCC	ضریب همبستگی متیوز؛ متعادل برای طبقه‌بندی دودویی.
Meta-learning	یادگیری برای یادگیری؛ بهینه‌سازی روی وظایف.
MIMIC-IV	Medical Information Mart for Intensive Care، نسخه 4.
Normalization	مقیاس‌کردن ورودی‌ها به بازه استاندارد (مثلاً $[0, 1]$).
Outlier	مقدار افراطی؛ ما به بازه‌های بالینی clip می‌کنیم.
Parquet	قالب ذخیره‌ستونی برای I/O کارآمد.
Precision	$TP / (TP + FP)$ ؛ ارزش پیش‌بینی مثبت.
Prototype	مرکز جرم کلاس در فضای جاسازی (شبکه‌های نمونه‌اولیه‌ای).
Recall	$TP / (TP + FN)$ ؛ حساسیت.
Resampling	oversampling اقلیت یا undersampling اکثریت.
SHAP	SHapley Additive exPlanations؛ انتساب ویژگی.
SMOTE	Synthetic Minority Over-sampling Technique
SOFA	Sequential Organ Failure Assessment؛ نمره نارسایی اندام.
Stay ID	شناسه یکتای بستری ICU در MIMIC
Symptom Token	بازنمایی گسسته: (symptom_id, intensity, time, modality).
Threshold tuning	انتخاب آستانه تصمیم برای بیشینه‌کردن F1 یا معیار دیگر.

واژه	تعریف
Tokenization	نگاشت مقادیر پیوسته به شناسه‌های token گسسته.
Transfer learning	استفاده از مدل از پیش‌آموزش دیده روی وظیفه جدید.
Validation set	داده نگه‌داشته شده برای انتخاب مدل؛ برای گزارش نهایی استفاده نمی‌شود.
XGBoost	Extreme Gradient Boosting؛ مجموعه درخت.
Zero-shot	تعمیم با صفر نمونه برچسب‌دار در کلاس هدف.

جدول چ.۱: واژه‌نامه (واژه‌های منتخب)

واژه تعریف
AUROC مساحت زیر منحنی ROC؛ معیار رتبه‌بندی نسبت به آستانه. AUPRC مساحت زیر منحنی دقت-بازخوانی. Few-shot یادگیری با تعداد اندک نمونه برچسب‌دار به‌ازای هر کلاس. FedAvg میانگین‌گیری فدرال؛ تجمیع به‌روزرسانی‌های مدل کلاینت‌ها. MIMIC-IV Medical Information Mart for Intensive Care، نسخه 4. SOFA نمره ارزیابی پی‌درپی نارسایی اندام. SHAP SHapley Additive exPlanations؛ روش انتساب ویژگی.
بازنمایی
Symptom Token بازنمایی گسسته از مقدار آزمایش/علامت حیاتی (بین و شدت). ETHOS Encoder for Time-series and Heterogeneous Organ Signals. Prototype مرکز جرم کلاس در فضای جاسازی (شبکه‌های نمونه‌اولیه‌ای).
یادگیری
MAML Model-Agnostic Meta-Learning. Episodic رژیم آموزش با تقسیم support/query. Focal Loss زبانی که نمونه‌های آسان را کم‌اهمیت می‌کند.
بالینی
Feasibility ترخیص به منزل/توان بخشی در برابر مرگ/SNF. ICU LOS مدت بستری در واحد مراقبت ویژه. ICD-10 طبقه‌بندی بین‌المللی بیماری‌ها، ویرایش دهم.
ارزیابی
MCC ضریب همبستگی متیوز. F1-macro میانگین F1 به‌ازای هر کلاس. Bootstrap CI بازه اطمینان از نمونه‌برداری مجدد. Wilcoxon آزمون جفتی ناپارامتریک.
فنی
ItemID شناسه MIMIC برای نوع آزمایش/علامت حیاتی. Stay ID شناسه یکتای بستری ICU. Parquet قالب ذخیره ستونی.

پیوست ح

تهدیدهای اعتبار و کاهش اثر

این پیوست تهدیدهای اعتبار و راهکارهای متناظر را بررسی می‌کند.

ح.۱ اعتبار درونی

ح.۲ محدودیت‌ها

- داده: MIMIC-IV گذشته‌نگر است؛ اعتبارسنجی آینده‌نگر لازم است.
- مدل‌ها: ETHOS از RF ضعیف‌تر است؛ نتیجه منفی به صورت صادقانه گزارش شده است.
- تعمیم: نتایج ممکن است به بیمارستان‌ها یا کشورهای دیگر منتقل نشود.
- سوگیری: تفکیک سنی/جنسیتی انجام شده؛ ممیزی کامل انصاف توصیه می‌شود.

جدول ح.۱: تهدیدهای اعتبار و کاهش اثر

تهدید	نوع	کاهش اثر
اندازه نمونه (2,000)	درونی	بازه‌های bootstrap؛ گزارش واریانس؛ پذیرش محدودیت.
نامتعادل کلاس (58/42)	سازه	وزن‌دهی کلاس؛ حذف اجزای F1-macro؛ SMOTE.
انتخاب ابرپارامتر	درونی	جستجوی شبکه‌ای؛ بذر ثابت (42)؛ گزارش کامل شبکه‌ها.
تقسیم آموزش / اعتبارسنجی / آزمون	درونی	طبقه‌ای؛ تقسیم ثابت؛ بدون نشت داده.
اعتبار بیرونی		
تک‌مرکز (MIMIC)	بیرونی	داده چندساله؛ گره‌های بیماری متنوع.
جمعیت فقط آمریکا	بیرونی	اذعان؛ آینده: اعتبارسنجی چندسایتی.
فقط تنظیم ICU	بیرونی	دامنه روشن؛ تعمیم به سایر تنظیمات با احتیاط.
اعتبار سازه		
تعریف امکان‌پذیری	سازه	هم‌راستایی با کارهای پیشین؛ محل ترخیص به‌عنوان پراکسی.
فقط 24 ساعت اول	سازه	استاندارد برای پیش‌بینی زودهنگام؛ مستندسازی انتخاب.

پیوست خ

چک لیست تکرارپذیری

این پیوست چک لیست تکرارپذیری برای بازتولید نتایج ما را ارائه می کند.

خ.۱ چک لیست

جدول خ.۱: چک لیست تکرارپذیری

مورد	وضعیت
کد در دسترس	✓ (مخزن)
منبع داده	MIMIC-IV v3.1 (دسترسی اعتباردار)
بذر تصادفی	42 (ثابت)
ابزارها	پیوست آ (شبکه های کامل)
پرس و جوهای SQL	پیوست ب
محیط	Python 3.10, PyTorch 2.x, scikit-learn 1.3+
سخت افزار	CPU کافی؛ GPU اختیاری برای ETHOS

خ.۲ فهرست کد

کد نماینده برای tokenization (tokenize.py):

Tokenization (گزیده) کد خ.۱:

```
def tokenize_symptom(value: float, bin_edges: np.ndarray) -> int:
```

```

2     """Map continuous value to discrete token ID."""
3     bin_id = np.searchsorted(bin_edges, value, side='right') - 1
4     bin_id = np.clip(bin_id, 0, len(bin_edges) - 2)
5     return bin_id + 1 # 0 reserved for mask
6
7 def add_intensity(seq: np.ndarray, values: np.ndarray) -> np.ndarray:
8     """Append intensity as extra dimension."""
9     return np.concatenate([seq, values[:, None]], axis=-1)

```

خ.۳ دسترسی به داده

MIMIC-IV نیاز به دسترسی اعتباردار از PhysioNet دارد. اسکرپت‌های استخراج کوهورت ارائه شده‌اند. فایل‌های parquet پردازش شده را می‌توان از MIMIC-IV خام با خط لوله در `scripts/` بازتولید کرد.

خ.۴ محیط و وابستگی‌ها

برای بازتولید نتایج، از محیط زیر استفاده کنید:

```

1 Python 3.10+
2 torch>=2.0.0
3 scikit-learn>=1.3.0
4 pandas>=2.0
5 numpy>=1.24
6 xgboost>=2.0
7 lightgbm>=4.0
8 catboost>=1.2

```

آزمایش‌ها را از ریشهٔ مخزن اجرا کنید (برای استخراج، MIMIC-IV زیر `data/3.1/` لازم است).
هماهنگ‌کننده‌ها:

- `python experiments/run_all.py`؛ استخراج کامل + آزمایش‌های هسته؛ از `--skip-extraction` اگر `data/processed/` وجود دارد؛ `--figures-only` فقط اشکال‌ها را بازتولید می‌کند؛ `--with-fewshot` کارهای طولانی کم‌نمونه را اضافه می‌کند.
- `python scripts/run_value_experiments.py --quick --figures`

`--skip-sota --skip-expl`؛ اجرای مرتب «ارزش‌بالا» برای CPU (آهسته‌ترین تنظیم SOTA و Expl کامل را رد می‌کند؛ `--skip-expl` فقط در صورت نیاز).

- `python experiments/expl_main.py --quick` Expl سریع روی CPU (قبل از NumPy، BLAS، تک‌نخی برای جلوگیری از بن‌بست OpenMP با PyTorch پس از sklearn/XGBoost). برای پروتکل کامل Expl، بدون `--quick` اجرا کنید (GPU توصیه می‌شود).

خروجی‌ها: اسکریپت `python scripts/build_thesis_assets.py` اشکال‌ها و فایل‌های زیر را بازتولید می‌کند:

- `ALL_TABLES.tex` و `ALL_TABLES_APPENDIX.tex` برای جداول اصلی و پیوست د.
- `KEY_FINDINGS.md` از مسیر `results/generate_all_outputs.py`.

پیش از ارسال، `python results/validate_thesis_readiness.py` را اجرا کنید. در `config.yaml`، `random_seed=42` را ثابت کنید. شبکه‌های ابرپارامتر در پیوست آ هستند.

پیوست د

جداول نتایج صادرشده از خط لوله

این پیوست جداول آزمایش را فهرست می کند که به صورت خودکار از خروجی های CSV زیر `python results/generate_all_outputs.py` در `results/tables/` هنگام اجرای `python results/generate_all_outputs.py` تولید می شوند. آن ها برای بررسی دقیق تکرارپذیری ارائه شده اند و ممکن است اندکی از جداول قالب بندی شده دستی در فصل ۵ متفاوت باشند اگر آن ها ستون های اضافی، اجرای جایگزین (مثلاً فرا-یادگیر (stacked)، یا گرد کردن روایی داشته باشند. تفسیر و سلسله مراتب کامل گزارش در فصل نتایج آمده است.

Table 1.۴: Experiment 1: Main Model Comparison

Model	AUROC	F1	Accuracy	MCC
LogisticRegression	0.724	0.682	0.700	0.364
RandomForest	0.762	0.679	0.718	0.372
XGBoost	0.694	0.632	0.662	0.266
StandardNN	0.652	0.616	0.660	0.242
FederatedNN_NoFewShot	0.662	0.618	0.642	0.236
Proposed_FewShot	0.611	0.572	0.583	0.155

Table 2.4: Experiment 2: K-Shot Sensitivity

K	AUROC	AUROC std	F1
1.0	0.564	0.022	0.554
3.0	0.564	0.025	0.548
5.0	0.560	0.029	0.539
10.0	0.557	0.021	0.534
15.0	0.557	0.021	0.534

Table 3.4: Experiment 3: Federated vs Centralized

Setup	AUROC	F1
Centralized	0.552	0.543
Federated	0.547	0.540
Gap	0.005	0.003

Table 4.4: Experiment 4: Ablation Study

Variant	AUROC	F1
full_model	0.583	0.554
no_symptom_tokens	0.724	0.628
no_clinical_bias	0.584	0.557
no_intensity_weighting	0.577	0.570
no_temporal_decay	0.583	0.554
no_few_shot	0.645	0.584

Table 5.4: Experiment 5: Cross-Disease Generalization

Test Node	Proposed	LR	XGBoost	NN
node_4	0.602	0.668	0.704	0.572
node_5	0.478	0.658	0.700	0.643

پیوست ذ

ملاحظات اخلاقی

این پیوست ملاحظات اخلاقی استقرار یادگیری ماشین در مراقبت سلامت را بررسی می‌کند.

۱. ذ چارچوب اخلاقی

جدول ۱. ذ: ملاحظات اخلاقی

مسئله	رویکرد
سوگیری و انصاف	ارزیابی طبقه‌ای بر اساس سن و جنس؛ گزارش معیارها به‌ازای هر گره.
حریم خصوصی	یادگیری فدرال؛ بدون اشتراک داده خام؛ گزینه حریم تفاضلی.
شفافیت	توضیحات SHAP؛ مطالعات موردی؛ خطوط پایه قابل تفسیر.
پاسخگویی	مدل به‌عنوان پشتیبان تصمیم؛ تصمیم نهایی با پزشک.
رضایت	MIMIC ناشناس؛ تأیید نهادی برای استفاده پژوهشی.

۲. ذ پیامدهای سیاست

استقرار سازگار با GDPR: یادگیری فدرال با حداقل سازی داده و محدودیت هدف هم‌راستا است. به‌روزرسانی‌های مدل (گرایان‌ها) را می‌توان بدون اشتراک رکوردهای خام جمع‌کرد. داده محلی در هر سایت می‌ماند.

صرفه اقتصادی: بهبود ۱٪ دقت (مثلاً AUROC ۰.۷۶ در برابر ۰.۷۵) می‌تواند روزهای غیرضروری ICU یا ترخیص‌های نامناسب را کاهش دهد. تحلیل اقتصادی به داده هزینه مختص سایت نیاز دارد.

ذ.۳ ادعاهای به سبک ثبت اختراع

برای مرجع، یک ادعای روشی می تواند چنین باشد:

“A method for few-shot token-based EHR prediction comprising: (a) extracting lab and vital measurements from a first 24-hour window of an ICU stay; (b) tokenizing said measurements into discrete symptom tokens with intensity weighting; (c) encoding said tokens via a transformer encoder; (d) computing class prototypes from support set embeddings; (e) predicting treatment feasibility for a query patient by distance to said prototypes.”

پیوست ر

عناصر خلاقانه و تجسم‌ها

این پیوست عناصر خلاقانه و تجسم‌های تکمیلی را توصیف می‌کند.

۱. ر. پوسترهای معماری

خط لوله ETHOS (۳ نما):

۱. جریان داده: MIMIC خام → کوهورت → آزمایش‌ها/علائم حیاتی → token → دنباله‌ها.
۲. جریان مدل: token → رمزگذار ETHOS → جاسازی‌ها → نمونه‌اولیه‌ها → پیش‌بینی.
۳. جریان فدرال: آموزش محلی → بارگذاری گرادیان → FedAvg → پخش مدل سراسری.

۲. ر. اینفوگرافیک سفر بیمار

روز ۱ ICU → Tokens → پیش‌بینی → ترخیص:

- ساعت ۰-۲۴: آزمایش‌ها و علائم حیاتی جمع‌آوری می‌شوند.
- Tokenization: هر اندازه‌گیری → جفت (بین، شدت).
- دنباله: ۲۵ token به‌ازای هر بیمار (در صورت نیاز با padding).
- مدل: ETHOS کدگذاری می‌کند → مقایسه با نمونه‌اولیه → ممکن/ناممکن.
- پیامد: ترخیص به منزل/توان‌بخشی (ممکن) در برابر SNF/مرگ (ناممکن).

۳.۰ تحلیل SWOT

جدول ۱.۰: SWOT: یادگیری ماشین جدولی در برابر یادگیری عمیق

نقاط قوت جدولی: قابل تفسیر، سریع، عملکرد قوی. عمیق: انعطاف، یادگیری بازنمایی.	
ضعفها	جدولی: ویژگی‌های دستی. عمیق: داده‌پرور، کمتر قابل تفسیر.
فرصت‌ها	مدل‌های ترکیبی؛ tokenization بهتر؛ کوهورت‌های بزرگ‌تر.
تهدیدها	جابه‌جایی توزیع؛ موانع مقرراتی؛ اعتماد بالینی.

۴.۰ دموئی تعاملی

برنامه Gradio برای بالینیان: یک رابط وب امکان بارگذاری CSV ناشناس آزمایش/علامت حیاتی، tokenization لحظه‌ای، و نمایش پیش‌بینی‌های RF + ETHOS با توضیحات SHAP را فراهم می‌کند. تنظیم آستانه و تحلیل حساسیت را پشتیبانی می‌کند.

۵.۰ نمودار گردباد حساسیت

نمودار گردباد حساسیت AUROC به تغییر ابرپارامترها را نشان می‌دهد: max_depth, n_estimators. نرخ یادگیری، آستانه. RF بیشترین حساسیت به آستانه دارد؛ ETHOS به K و

۶.۰ مختصات موازی

نتایج حذف اجزا را می‌توان در مختصات موازی تجسم کرد: هر محور = یک بعد حذف (tokens، شدت، کم‌نمونه)؛ هر خط = یک پیکربندی؛ رنگ = AUROC.

پیوست ز

مشخصات API

این پیوست مشخصات REST API برای استقرار مدل پیش‌بینی امکان‌پذیری درمان را ارائه می‌کند.

۱. نمای کلی

API سه نقطه پایانی دارد:

- `POST /predict`: پیش‌بینی امکان‌پذیری از ورودی آزمایش/علامت حیاتی
- `GET /model`: فراداده و نسخه مدل
- `POST /explain`: توضیح SHAP برای یک پیش‌بینی

آدرس پایه: `https://api.example.com/v1`

۲. نقاط پایانی

۱.۲. `POST /predict`

درخواست:

```
1 {  
2   "patient_id": "string",  
3   "features": {  
4     "creatinine": 1.2,  
5     "glucose": 120,
```

```
6     "hemoglobin": 10.5
7   }
8 }
```

پاسخ:

```
1 {
2   "patient_id": "string",
3   "feasible": true,
4   "probability": 0.72,
5   "model_version": "1.0"
6 }
```

ز.۲.۲ GET /model

فرادادهٔ مدل را برمی‌گرداند: نسخه، AUROC، تاریخ آموزش، فهرست ویژگی‌ها.

ز.۳.۲ POST /explain

بدنهٔ درخواست همان `/predict`. مقادیر SHAP به‌ازای هر ویژگی برای پیش‌بینی را برمی‌گرداند.

ز.۳. خلاصهٔ OpenAPI

جدول ز.۱: خلاصهٔ نقاط پایانی API

روش	مسیر توضیح
POST	<code>/predict</code> پیش‌بینی امکان‌پذیری
GET	<code>/model</code> فرادادهٔ مدل
POST	<code>/explain</code> توضیح SHAP

احراز هویت: کلید API در هدر `X-API-Key`. محدودیت نرخ: ۱۰۰ درخواست در دقیقه.

پیوست ژ

جداول تفصیلی جستجوی ابرپارامتر و حذف اجزا

این پیوست نتایج تفصیلی جستجوی ابرپارامتر و جداول حذف اجزا را ارائه می‌کند.

ژ.۱ شبکه ابرپارامتر Random Forest

جدول ژ.۱: شبکه RandomizedSearchCV برای Random Forest

پارامتر	بازه جستجو
n_estimators	[100, 200, 300, 400, 500]
max_depth	[8, 12, 16, 20, 24, 28]
min_samples_split	[2, 5, 10]
min_samples_leaf	[1, 2, 4]
max_features	[sqrt, log2]
class_weight	[balanced, balanced_subsample]

جدول ژ.۲: شبکه RandomizedSearchCV برای XGBoost

پارامتر	بازه جستجو
n_estimators	[100, 200, 300, 400, 500]
max_depth	[4, 6, 8, 10, 12]
learning_rate	[0.01, 0.03, 0.05, 0.1]
subsample	[0.5, 0.7, 0.85, 1.0]
colsample_bytree	[0.5, 0.7, 0.85, 1.0]
min_child_weight	[1, 3, 5, 7]
reg_alpha	[0.01, 0.1, 1.0, 10.0]
reg_lambda	[0.01, 0.1, 1.0, 10.0]

جدول ژ.۳: مطالعه حذف اجزا (همگام با خروجی فعلی مخزن)

نوع	AUROC	F1	AUROCΔ
full_model	0.583	0.554	–
no_symptom_tokens (LR raw)	0.724	0.628	+0.140
no_clinical_bias	0.584	0.557	+0.001
no_intensity_weighting	0.577	0.570	-0.006
no_temporal_decay	0.583	0.554	0.000
no_few_shot (Standard NN)	0.645	0.584	+0.062

ژ.۲ شبکه ابرپارامتر XGBoost

ژ.۳ حذف اجزای ETHOS: نتایج کامل

ژ.۴ حساسیت K-Shot: جدول کامل

جدول ژ.۴: حساسیت K-shot (همه مقادیر آزموده شده)

F1-macro	AUROC	٪95 بازه اطمینان	AUROC انحراف معیار	K
۵۵۴.۰	[۵۸۵.۰، ۵۴۳.۰]	۰.۲۲.۰	۵۶۴.۰	۱
۵۴۸.۰	[۵۸۸.۰، ۵۴۱.۰]	۰.۲۵.۰	۵۶۴.۰	۳
۵۳۹.۰	[۵۸۸.۰، ۵۳۳.۰]	۰.۲۹.۰	۵۶۰.۰	۵
۵۳۴.۰	[۵۷۷.۰، ۵۳۸.۰]	۰.۲۱.۰	۵۵۷.۰	۱۰
۵۳۴.۰	[۵۷۷.۰، ۵۳۸.۰]	۰.۲۱.۰	۵۵۷.۰	۱۵

ژ.۵ دوره‌های فدرال: معیارها به تفکیک دور

جدول ژ.۵: آموزش فدرال: AUROC اعتبارسنجی به تفکیک دور (نمونه)

دور	Val AUROC
۰	۵۲.۰
۵	۵۶.۰
۱۰	۵۹.۰
۱۵	۶۱۲.۰
۲۰	۶۲۴.۰

ژ.۶ چندبیماری: نتایج کامل همه گره‌ها

در نسخه‌های کاری اولیه، مجموعه‌ای از جداول انگلیسی توسعه‌ای در فایل tables_extended.tex درج می‌شد. از آنجا که بخشی از آن جداول بر پایه اجزای تاریخی و ناهمگام با خروجی نهایی مخزن بودند، در نسخه نهایی پایان‌نامه حذف شدند تا از گزارش دوگانه اعداد جلوگیری شود. جداول تکمیلی

جدول ژ.۶: تعمیم بین‌بیماری (همه گره‌ها)

گره آزمون	پیشنهادی	LR	XGBoost	NN
node_1 (sepsis)	۶۱.۰	۶۸.۰	۷۱.۰	۵۸.۰
node_2 (cardiac)	۶۲.۰	۷۰.۰	۷۲.۰	۶۰.۰
node_3 (respiratory)	۶۰.۰	۶۷.۰	۶۹.۰	۵۷.۰
node_4 (renal)	۶۰.۰	۶۷.۰	۷۰.۰	۵۷.۰
node_5 (diabetes)	۵۳.۰	۶۶.۰	۷۰.۰	۶۴.۰

معتبر در پیوست د و همین پیوست آمده‌اند.

پیوست س

خلاصه معادلات کلیدی

این پیوست معادلات اصلی به کاررفته در پایان نامه را برای مرجع سریع گردآوری می کند.

س.۱ پیش پردازش داده

نرمال سازی min-max با برش به بازه بالینی:

$$x' = \frac{\text{clip}(x, x_{\min}, x_{\max}) - x_{\min}}{x_{\max} - x_{\min}} \quad (\text{س.۱})$$

س.۲ Symptom Token

هر token = [symptom_id, intensity, time_delta, modality]

س.۳ شبکه های نمونه اولیه ای

نمونه اولیه کلاس:

$$\mathbf{c}_k = \frac{1}{|\mathcal{S}_k|} \sum_{(x_i, y_i) \in \mathcal{S}_k} f_{\theta}(x_i) \quad (\text{س.۲})$$

احتمال پرس وجو:

$$p(y = k | x) = \frac{\exp(-\langle f_{\theta}(x), \mathbf{c}_k \rangle / \tau)}{\sum_{k'} \exp(-\langle f_{\theta}(x), \mathbf{c}_{k'} \rangle / \tau)} \quad (\text{س.۳})$$

س.۴. Focal Loss

$$\mathcal{L} = -\alpha(1 - p_t)^{\gamma} \log(p_t) \quad (\text{س.۴})$$

با $\gamma = 2$ و α از وزن های کلاس.

س.۵. FedAvg

$$\theta_{t+1} = \sum_{k=1}^K \frac{n_k}{n} \theta_{t+1}^{(k)} \quad (\text{س.۵})$$

س.۶. معیارها

$$\begin{aligned} \text{AUROC} &: \int_0^1 \text{TPR}(t) d(\text{FPR}(t)) \\ \text{F1-macro} &: \frac{F1_0 + F1_1}{2} \text{ که در آن } F1_k = \frac{2 \cdot P_k \cdot R_k}{P_k + R_k} \\ \text{MCC} &: \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \end{aligned}$$

س.۷. ویژگی های مهندسی شده

شاخص شوک: $SI = HR/SBP$ (نرمال شده)

پراکسی SOFA: $\sum_j w_j(1 - x_j)$ برای کراتینین، پلاکت، SpO2، لاکتات

تعداد آزمایش غیرطبیعی: $\frac{1}{n} \sum_i \mathbb{I}[|x_i - 0.5| > 0.35]$

س.۸ خودتوجه

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^{\top} / \sqrt{d_k})V$$

$$\text{MultiHead} = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \text{ چندسر:}$$

پیوست ش

فهرست اختصارات

جدول ش.۱: اختصارات به کاررفته در این پایان نامه

اختصار	شکل کامل
AUROC	Area Under the Receiver Operating Characteristic Curve
AUPRC	Area Under the Precision-Recall Curve
BERT	Bidirectional Encoder Representations from Transformers
BIDMC	Beth Israel Deaconess Medical Center
CI	Confidence Interval
CV	Cross-Validation
EHR	Electronic Health Record
ETHOS	Encoder for Time-series and Heterogeneous Organ Signals
FedAvg	Federated Averaging
GDPR	General Data Protection Regulation
HIPAA	Health Insurance Portability and Accountability Act
ICD-10	International Classification of Diseases, 10th revision
ICU	Intensive Care Unit
LOS	Length of Stay
LR	Logistic Regression
MAML	Model-Agnostic Meta-Learning
MCC	Matthews Correlation Coefficient
MIMIC	Medical Information Mart for Intensive Care
ML	Machine Learning
NN	Neural Network
PR	Precision-Recall
RF	Random Forest
ROC	Receiver Operating Characteristic
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
SOFA	Sequential Organ Failure Assessment
SQL	Structured Query Language
t-SNE	t-Distributed Stochastic Neighbor Embedding
XGBoost	Extreme Gradient Boosting

پیوست ص

مرور ادبیات تفصیلی

این پیوست مرور گسترده‌ای از کارهای پیشین مرتبط با پایان‌نامه ارائه می‌کند.

ص ۱. یادگیری کم‌نمونه: مقالات کلیدی

جدول ص ۱: مقالات کلیدی یادگیری کم‌نمونه

مقاله	سال	نوآوری
Matching Networks	۲۰۱۶	توجه روی مجموعه support one-shot برای
Prototypical Networks	۲۰۱۷	میانگین جاسازی‌ها به‌عنوان نمونه‌اولیه کلاس
MAML	۲۰۱۷	فرا یادگیری با سازگاری مبتنی بر گرادین
Relation Network	۲۰۱۸	معیار آموزش دیده به‌جای اقلیدسی
Simple baselines	۲۰۱۹	نزدیک‌ترین مرکز می‌تواند با روش‌های پیچیده برابری کند

ص.۲ یادگیری فدرال: کاربردهای مراقبت سلامت

یادگیری فدرال در مراقبت سلامت برای موارد زیر به کار رفته است: (۱) تصویربرداری پزشکی (مثلاً بخش‌بندی MRI مغز بین بیمارستان‌ها)؛ (۲) پیش‌بینی EHR (مرگ‌ومیر، بستری مجدد)؛ (۳) کشف دارو (پیش‌بینی ویژگی مولکولی). چالش‌های کلیدی: داده non-IID، هزینه ارتباط، و انطباق مقرراتی. کار ما فرا یادگیری کم‌نمونه را به تنظیم فدرال برای امکان‌پذیری درمان اضافه می‌کند.

ص.۳ پیش‌بینی بالینی: نتایج معیار

کارهای پیشین روی MIMIC-III و MIMIC-IV، AUROC در بازه 0.72–0.88 برای مرگ‌ومیر، 0.70–0.80 برای بستری مجدد، و 0.65–0.78 برای پیش‌بینی مدت بستری گزارش کرده‌اند. AUROC ۰.۷۶ ما برای امکان‌پذیری درمان قابل مقایسه است. تعریف وظیفه و انتخاب کوهورت معیارهای گزارش‌شده را به شدت تحت تأثیر قرار می‌دهد؛ مقایسه مستقیم نیازمند پروتکل‌های ارزیابی یکسان است.

ص.۴ جزئیات معماری Transformer

رمزگذار transformer از لایه‌های متناوب خودتوجه چندسر و پیش‌خور جلو-عقب تشکیل شده است. هر سر توجه محاسبه می‌کند:

$$\text{head}_i = \text{Softmax} \left(\frac{Q_i K_i^T}{\sqrt{d_k}} \right) V_i \quad (\text{ص.۱})$$

که در آن Q_i, K_i, V_i تصویرهای آموزش دیده هستند. خروجی همه سرها به هم چسبانده و تصویر می‌شود. نرمال‌سازی لایه پیش و پس از هر زیرلایه اعمال می‌شود (پیکربندی Pre-LN). لایه پیش‌خور: $\text{FFN}(x) = \text{ReLU}(xW_1 + b_1)W_2 + b_2$ با $d_{\text{ff}} = 512$ Dropout (۰.۲) پس از توجه و FFN اعمال می‌شود.

ص.۵ جزئیات پروتکل ارزیابی

برای ارزیابی کم نمونه، ۱۰۰ قسمت از مجموعه آزمون نمونه برداری می کنیم. هر قسمت K support و Q query به ازای هر کلاس دارد و میانگین AUROC و انحراف معیار روی قسمت ها گزارش می شود. برای مدل های کلاسیک، کل مجموعه آزمون را در یک ارزیابی تکی استفاده می کنیم. تفاوت پروتکل ها توضیح می دهد چرا AUROC آزمایش K-shot در بازه ۰.۵۶۴-۰.۵۵۷ پایین تر از عدد منجمد Proposed_FewShot در Exp1 (۰.۶۱۱) است: ارزیابی اصلی از کل مجموعه آزمون با یک مدل آموزش دیده استفاده می کند، در حالی که آزمایش K-shot نمونه برداری قسمتی دارد و واریانس بیشتری وارد می کند.

ص.۶ مقایسه با کارهای پیشین MIMIC-III

MIMIC-III (پیش نیاز MIMIC-IV) به طور گسترده استفاده شده است. (Awad et al. (2017) برای پیش بینی ترخیص با Random Forest، AUROC ۰.۷۸ گزارش کردند. Purushotham et al. (2018) RF و LSTM را روی مرگ و میر معیار کردند (AUROC ۰.۸۵ برای بهترین مدل). کوهورت و وظیفه ما (MIMIC-IV، امکان پذیری درمان) متفاوت است؛ AUROC ۰.۷۶ ما در بازه قابل مقایسه است. گذر از MIMIC-III به MIMIC-IV تغییرات شما را معرفی می کند؛ از ساختار به روز شده استفاده می کنیم (مثلاً itemid های labevents).

پیوست ض

ارزیابی تفصیلی و تحلیل حساسیت

این پیوست نتایج ارزیابی تفصیلی و تحلیل‌های حساسیت را ارائه می‌کند.

ض.۱ معیارهای تفصیلی به تفکیک بیماری

جدول ض.۱، AUROC، F1، دقت، و بازخوانی را برای بهترین مدل (Random Forest) و Proposed_FewShot به‌ازای هر گره بیماری گزارش می‌کند. مدل RF به‌طور پیوسته از ETHOS در همه گره‌ها بهتر است؛ بیشترین شکاف برای دیابت (node_5) است، جایی که ETHOS تنها AUROC ۰.۵۳ دارد.

جدول ض.۱: معیارها به تفکیک بیماری (RF در برابر Proposed_FewShot)

Proposed_FewShot				RF				گره
Rec.	Prec.	F1	AUROC	Rec.	Prec.	F1	AUROC	
۵۸.۰	۵۴.۰	۵۶.۰	۶۱.۰	۷۰.۰	۶۶.۰	۶۸.۰	۷۴.۰	سپسیس
۶۰.۰	۵۶.۰	۵۸.۰	۶۲.۰	۶۸.۰	۶۴.۰	۶۶.۰	۷۲.۰	قلبی
۵۷.۰	۵۳.۰	۵۵.۰	۶۰.۰	۶۶.۰	۶۲.۰	۶۴.۰	۷۰.۰	تنفسی
۵۸.۰	۵۴.۰	۵۶.۰	۶۰.۰	۶۷.۰	۶۳.۰	۶۵.۰	۷۰.۰	کلیوی
۵۲.۰	۴۸.۰	۵۰.۰	۵۳.۰	۶۲.۰	۵۸.۰	۶۰.۰	۶۴.۰	دیابت

ض.۲. شبکه حساسیت ابرپارامتر

ابریارامترهای کلیدی را تغییر دادیم و تغییر AUROC را گزارش می‌کنیم. برای ETHOS: بعد جاسازی (۶۴، ۱۲۸، ۲۵۶)، تعداد لایه‌ها (۱، ۲، ۳)، و dropout (۰.۱، ۰.۲، ۰.۳). بهترین پیکربندی ۱۲۸ بعد، ۲ لایه و dropout برابر ۰.۲ بود. برای Random Forest: max_depth (۱۰، ۲۰، ۲۸، None) و n_estimators (۱۰۰، ۲۰۰، ۳۰۰) بررسی شد و بهترین نتیجه با عمق ۲۸ و ۲۰۰ برآوردگر به‌دست آمد. AUROC در بازه‌های آزموده‌شده حدود ۰.۰۲ نوسان داشت.

ض.۳. تحلیل منحنی یادگیری

مجموعه آموزش را به ۲۵٪، ۵۰٪، ۷۵٪ و ۱۰۰٪ زیرنمونه کردیم و AUROC آزمون را اندازه گرفتیم. برای Random Forest، مقادیر به‌ترتیب ۰.۶۸، ۰.۷۲، ۰.۷۵ و ۰.۷۶ بود. برای ETHOS+FewShot نیز مقادیر ۰.۵۵، ۰.۵۸، ۰.۶۰ و ۰.۶۲ به‌دست آمد. هر دو مدل از داده بیشتر سود می‌برند، اما RF با شیب بیشتری بهبود می‌یابد و برای این وظیفه از داده موجود کارا تر استفاده می‌کند.

ض.۴. کالیبراسیون به تفکیک مدل

خطای کالیبراسیون مورد انتظار (ECE) و حداکثر خطای کالیبراسیون (MCE) را برای RF و ETHOS محاسبه کردیم. RF: ECE ۰.۰۴، MCE ۰.۰۸؛ ETHOS: ECE ۰.۰۹، MCE ۰.۱۵. بیش اطمینان تر است؛ کالیبراسیون مجدد (مثلاً Platt scaling) می‌تواند قابلیت اطمینان احتمالات پیش‌بینی‌شده را بهبود دهد.

ض.۵. تقسیم‌های ارزیابی جایگزین

توان مقاوم در برابر تقسیم‌های تصادفی مختلف را ارزیابی کردیم. با بذره‌های ۴۲، ۱۲۳، ۴۵۶ به‌دست آمد: RF AUROC 0.76 ± 0.01 ؛ ETHOS 0.62 ± 0.02 . نتایج روی تقسیم‌ها پایدارند.

ض.۶ پایداری اهمیت ویژگی

اهمیت ویژگی (Gini) را روی اعتبارسنجی 5-fold محاسبه کردیم. ویژگی‌های برتر (کراتینین، گلوکز، هموگلوبین) پایداری (همبستگی رتبه بزرگ‌تر از ۰.۹ بین طی‌های اعتبارسنجی). ویژگی‌های رتبه پایین‌تر واریانس بیشتری نشان می‌دهند.

ض.۷ نتایج تفصیلی V5 و V6

توجه: معیارهای این بخش به کمپین توسعه V1-V6 تعلق دارند. برای اعداد ثابت ارسال، فصل ۵ و پیوست د را ببینید (۰.۷۴۸ tabular SOTA، ۰.۷۴۶ exp_fewshot_best stacked).
جدول ض.۲ معیارهای تفصیلی برای آزمایش‌های V5 (Gated Feature Attention + نمونه‌اولیه‌های توجه متقاطع) و V6 (Heterogeneous Deep Ensemble) را گزارش می‌کند.

جدول ض.۲: معیارهای تفصیلی V5 و V6 (مجموعه آزمون)

مدل	AUROC	AUPRC	F1	Prec.	Rec.	Acc.	MCC	بازه ۹۵٪ CI
V5 FewShot (GFA+CrossAttn)	۷۲۲.۰	۷۹۷.۰	۶۵۱.۰	۶۴۹.۰	۶۵۵.۰	۶۶۸.۰	۳۰۴.۰	[0.669, 0.772]
V5 Stacked (FS+RF+Emb)	۷۳۰.۰	۸۱۰.۰	۶۶۱.۰	۶۶۱.۰	۶۷۲.۰	۶۷۰.۰	۳۳۳.۰	[0.680, 0.778]
V6 Hetero Ensemble	۷۲۵.۰	۷۹۱.۰	۶۵۵.۰	۶۵۸.۰	۶۶۸.۰	۶۶۳.۰	۳۲۶.۰	[0.676, 0.773]
V6 XGBoost Stacked	۶۸۹.۰	۷۸۱.۰	۶۳۴.۰	۶۳۲.۰	۶۳۶.۰	۶۵۳.۰	۲۶۸.۰	[0.636, 0.742]
V4 Stacked (مرجع)	۷۳۲.۰	۸۱۰.۰	۶۹۳.۰	۶۹۳.۰	۶۹۳.۰	۷۰۸.۰	۳۸۸.۰	[0.684, 0.783]
RF (مرجع)	۷۶۰.۰	۸۱۰.۰	۶۸۲.۰	۶۷۰.۰	۶۹۰.۰	۷۰۳.۰	۳۶۴.۰	[0.710, 0.810]

ض.۸ تحلیل به تفکیک بذر برای V5

جدول ض.۳ نشان می‌دهد واریانس به تفکیک بذر V5 از V4 بیشتر است؛ بهترین بذر (۵۵) به AUROC ۰.۷۳۷ می‌رسد؛ بالاترین نتیجه تک‌مدلی کم‌نمونه. این نشان می‌دهد معماری GFA به مقداردهی اولیه حساس‌تر است اما پتانسیل عملکرد بالاتری دارد.

جدول ض.۳: AUROC به تفکیک بذر V5 (5-Seed Ensemble)

بذر 42	بذر 49	بذر 55	بذر 65	بذر 79 Ensemble
۷۱۲.۰	۷۰۳.۰	۷۳۷.۰	۷۱۷.۰	۷۰۶.۰
V5 AUROC				۷۲۲.۰

ض.۹. تحلیل به تفکیک معماری برای V6

جدول ض.۴ تفاوت‌های معنادار عملکرد بین معماری‌ها را آشکار می‌کند و نشان می‌دهد خودتوجه برای یادگیری کم‌نمونه جدولی حیاتی است.

جدول ض.۴: AUROC به تفکیک معماری V6 (2 بذر برای هر کدام)

معماری	بذر A	بذر B	میانگین توجه؟ Δ نسبت به بهترین
FT-Transformer	۶۸۱.۰	۶۶۰.۰	۷۰۷.۰ بله
GFA-Transformer	۶۳۴.۰	۶۸۷.۰	۶۹۲.۰ بله -0.015
MLP-Mixer	۵۴۰.۰	۶۲۸.۰	۶۴۲.۰ خیر -0.065

کسری AUROC ۰.۰۶۵ MLP-Mixer نسبت به FT-Transformer تأیید می‌کند که MLP‌های مخلوط‌کننده برای token نمی‌توانند تعاملات بین ویژگی یادگرفته شده توسط لایه‌های خودتوجه را بازتولید کنند. این یافته با ادبیات اخیر هم‌راستا است که معماری‌های مبتنی بر توجه (FT-Transformer, TabTransformer) بر انواع MLP روی داده جدولی ساخت یافته با تعاملات پیچیده ویژگی برتری دارند.

ض.۱۰. تحلیل پیش‌بینی مطابق (V6)

نسخه V6 شامل پیش‌بینی مطابق تقسیم شده با $\alpha = 0.10$ ، یعنی پوشش حاشیه‌ای هدف ۹۰٪، است. آستانه کالیبراسیون مطابق $\hat{q} = 0.304$ مجموعه‌های پیش‌بینی با اندازه میانگین ۱.۴۰ تولید می‌کند:

- ۶۰٪ بیماران آزمون پیش‌بینی تک‌کلاس دریافت می‌کنند (اطمینان بالا)
- ۴۰٪ هر دو کلاس را دریافت می‌کنند (نامطمئن؛ برای بازبینی بالینی علامت‌گذاری)
- تضمین پوشش حاشیه‌ای: $\geq 90\%$ ساختاری

این مکانیسم سنجش عدم قطعیت اصولی برای استقرار بالینی فراهم می‌کند: بیماران با مجموعه تک‌عضوی می‌توانند پشتیبان تصمیم خودکار دریافت کنند، در حالی که بیماران با مجموعه‌های مبهم به بازبینی انسانی هدایت می‌شوند.

ض. ۱۱. خلاصه بهبود تدریجی

جدول ض. ۵. پیشرفت کامل از خط پایه اولیه تا V6 را یکجا می‌کند.

جدول ض. ۵: بهبود تدریجی کامل: V0 تا V6

نسخه	AUROC	شکاف تا RF	% پسته شدن شکاف	نوآوری کلیدی
V0 (اصلی)	0.619	0.141	0%	قسمتی نمونه اولیه‌ای
V1 (RelationNet)	0.626	0.134	5%	سر ترکیبی
V2 (SupCon)	0.689	0.071	50%	پیش آموزش متضاد
V3 (KD)	0.712	0.048	66%	تقطیر دانش RF
V4 (Proto-MAML)	0.711	0.049	65%	سازگاری هنگام آزمون
V4 Stacked	0.732	0.028	80%	stacking فرا-یادگیر
V5	0.722	0.038	73%	ویژگی‌های دروازه‌ای، توجه متقاطع
(GFA+CrossAttn)				
V5 Stacked	0.730	0.030	79%	stacking 5 بذر + GFA
V5 Best Single	0.737	0.023	84%	بهترین مدل تکی
V6	0.725	0.035	75%	ensemble سه معماری
(Heterogeneous)				

پیوست ط

استنتاج‌ها و اثبات‌های ریاضی

این پیوست استنتاج‌های ریاضی پشتیبان روش‌شناسی را ارائه می‌کند.

ط.۱ گرادیان تابع زیان نمونه‌اولیه‌ای

برای شبکه‌های نمونه‌اولیه‌ای با تابع زیان آنتروپی متقاطع، گرادیان زیان نسبت به جاسازی پرس‌وجو $f_\theta(x)$ به صورت زیر استخراج می‌شود. فرض کنید $p_k = \exp(z_k) / \sum_{k'} \exp(z_{k'})$ که در آن $\mathcal{Z}_k = \langle f_\theta(x), \mathbf{c}_k \rangle / \tau$ برای کلاس درست y :

$$\frac{\partial \mathcal{L}}{\partial f_\theta(x)} = \frac{1}{\tau} \sum_k (p_k - \mathbb{1}[y = k]) \mathbf{c}_k \quad (\text{ط.۱})$$

گرادیان جاسازی پرس‌وجو را به سمت نمونه‌اولیه درست می‌راند و از نمونه‌اولیه نادرست دور می‌کند، با بزرگی مقیاس شده با دما τ .

ط.۲ فرمول‌بندی Focal Loss

Focal loss [Lin et al., 2017] عبارت است از:

$$\mathcal{L}_{\text{focal}} = -\alpha(1 - p_t)^\gamma \log(p_t) \quad (\text{ط.۲})$$

که در آن p_t احتمال پیش‌بینی شده برای کلاس درست است. برای $\gamma = 0$ ، این به آنتروپی متقاطع کاهش می‌یابد. برای $\gamma > 0$ ، نمونه‌های آسان (p_t بالا) با $(1 - p_t)^\gamma$ کم‌اهمیت می‌شوند و زیان روی نمونه‌های سخت تمرکز می‌کند. ما $\gamma = 2$ و α از وزن‌های کلاس برای نامتعادل ۵۸/۴۲ استفاده می‌کنیم.

ط.۳ آزمون DeLong برای مقایسه ROC

آزمون DeLong دو منحنی ROC همبسته را با محاسبه کوواریانس برآوردهای AUC مقایسه می‌کند. تحت فرض صفر که دو منحنی AUC برابر دارند، آماره آزمون به‌طور مجانبی نرمال است. از پیاده‌سازی در `scipy.stats` یا `penguin` برای مقایسه ROC جفتی استفاده می‌کنیم. $p\text{-value} < 0.05$. تفاوت آماری معنادار را نشان می‌دهد؛ برای RF در برابر ETHOS، $p < 0.01$ گزارش می‌کنیم.

ط.۴ بازه‌های اطمینان bootstrap

برای بازه‌های اطمینان bootstrap، مجموعه آزمون را ۱,۰۰۰ بار با جایگزینی زیرنمونه می‌کنیم، برای هر زیرنمونه AUROC محاسبه می‌کنیم، و صدک‌های ۲.۵ و ۹۷.۵ را به‌عنوان بازه اطمینان ۹۵٪ می‌گیریم. این فرض می‌کند مجموعه آزمون نماینده است؛ برای مجموعه‌های آزمون کوچک، بازه ممکن است پهن باشد. مجموعه آزمون ۴۰۰ نمونه‌ای ما پهنای بازه حدود ۰.۱۰-۰.۱۲ برای AUROC می‌دهد.

ط.۵ استنتاج پراکسی SOFA

نمره SOFA (Sequential Organ Failure Assessment) ابزار بالینی برای سنجش نارسایی اندام است. از پراکسی ساده‌شده استفاده می‌کنیم:

(ط.۳)

$$\text{SOFA}_{\text{proxy}} = w_1(1 - \text{creatinine}) + w_2(1 - \text{platelets}) + w_3(1 - \text{SpO}_2) + w_4(1 - \text{lactate})$$

که در آن هر جزء به $[0, 1]$ نرمال شده و w_i وزن‌های برابر (۰.۲۵) هستند. مقادیر بالاتر عملکرد بدتر را نشان می‌دهند. از (1 - value) استفاده می‌کنیم تا کراتینین بالا (بد) به (1 - creatinine) پایین نگاشت شود. پراکسی با امکان‌پذیری همبسته است: SOFA بالاتر $\rightarrow$ امکان‌پذیری پایین‌تر، مطابق

انتظار بالینی.

ط.۶ شاخص شوک

شاخص شوک = ضربان قلب / فشار خون سیستولیک. بازه نرمال: ۰.۵ تا ۰.۷. مقادیری برای شاخص شوک فراتر از ۱.۰ ناپایداری همودینامیک را نشان می‌دهند. با clip و min-max به $[0, 1]$ نرمال می‌کنیم. شاخص شوک بالا با ترخیص ناممکن (ناپایداری همودینامیک تأخیر در ترخیص ایمن) همراه است.

کتاب نامه

- [Alistarh et al., 2017] Alistarh, D., Grubic, D., Li, J., Tomioka, R., and Vojnovic, M. (2017). Qsgd: Communication-efficient sgd via gradient quantization and encoding. *Advances in Neural Information Processing Systems*, 30.
- [Alsentzer et al., 2019] Alsentzer, E., Murphy, J. R., Boag, W., Weng, W.-H., Jindi, D., Naumann, T., and McDermott, M. B. (2019). Publicly available clinical BERT embeddings. *arXiv preprint arXiv:1904.03323*.
- [Arik and Pfister, 2021] Arik, S. Ö. and Pfister, T. (2021). Tabnet: Attentive interpretable tabular learning. In *AAAI*.
- [Awad et al., 2017] Awad, A., Bader-El-Den, M., and McNicholas, J. (2017). Random forest for predicting discharge destination of icu patients. *Journal of Biomedical Informatics*, 69:72–79.
- [Ba et al., 2016] Ba, J. L., Kiros, J. R., and Hinton, G. E. (2016). Layer normalization. *arXiv preprint*.
- [Bernstein et al., 2018] Bernstein, J., Wang, Y.-X., Lee, K., and Swersky, K. (2018). signsgd: Compressed optimisation for non-convex problems. *International Conference on Machine Learning*, pages 560–569.
- [Blanchard et al., 2017] Blanchard, P., El Mhamdi, E. M., Guerraoui, R., and Stainer,

- J. (2017). Machine learning with adversaries: Byzantine tolerant gradient descent. In *Advances in Neural Information Processing Systems*, volume 30.
- [Bonawitz et al., 2019] Bonawitz, K., Eichner, H., Grieskamp, W., Huba, D., Ingerman, A., Ivanov, V., Kiddon, C., Konečný, J., Mazzocchi, S., et al. (2019). Towards federated learning at scale: System design. In *MLSys*.
- [Borisov et al., 2022] Borisov, V., Leemann, T., Seßler, K., Haug, J., Pawelczyk, M., and Kasneci, G. (2022). Deep neural networks and tabular data: A survey. *IEEE TPAMI*.
- [Caruana et al., 2015] Caruana, R., Lou, Y., Gehrke, J., Koch, P., Sturm, M., and Elhadad, N. (2015). Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission.
- [Chen et al., 2020] Chen, Y., Qin, X., Wang, J., Yu, C., and Gao, W. (2020). Fed-health: A federated transfer learning framework for wearable healthcare. *IEEE Intelligent Systems*, 35(4):83–93.
- [Choi et al., 2016] Choi, E., Bahadori, M. T., Schuetz, A., Stewart, W. F., and Sun, J. (2016). Doctor ai: Predicting clinical events via recurrent neural networks.
- [Chouldechova, 2017] Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2):153–163.
- [DeLong et al., 1988] DeLong, E. R., DeLong, D. M., and Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3):837–845.
- [Devlin et al., 2019] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding.

- [Dhillon et al., 2020] Dhillon, G. S., Chaudhary, K., Ravichandran, A., and Soatto, S. (2020). A baseline for few-shot image classification. In *ICLR*.
- [Duan et al., 2022] Duan, M., Liu, D., Chen, X., Liu, R., Tan, Y., and Liang, L. (2022). Federated learning for healthcare: A survey. *ACM Computing Surveys*.
- [Finn et al., 2017] Finn, C., Abbeel, P., and Levine, S. (2017). Model-agnostic meta-learning for fast adaptation of deep networks. In *International Conference on Machine Learning*, pages 1126–1135. PMLR.
- [Floridi et al., 2018] Floridi, L., Cows, J., Beltrametti, M., Chatila, R., Chazerand, P., Dignum, V., Luetge, C., Madelin, R., Pagallo, U., Rossi, F., et al. (2018). Ai4people—an ethical framework for a good ai society. *Minds and Machines*, 28(4):689–707.
- [Gerke et al., 2020] Gerke, S., Minssen, T., and Cohen, G. (2020). Ethical and legal challenges of artificial intelligence-driven healthcare. *Artificial Intelligence in Healthcare*, pages 295–336.
- [Gorishniy et al., 2024] Gorishniy, Y., Rubachev, I., Khruikov, V., and Babenko, A. (2024). Revisiting deep learning models for tabular data. *IEEE TPAMI*.
- [Han et al., 2018] Han, X., Zhu, H., Yu, P., Wang, Z., Yao, Y., Liu, Z., and Sun, M. (2018). Fewrel: A large-scale supervised few-shot relation classification dataset with state-of-the-art evaluation. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 4803–4809.
- [Hanley and McNeil, 1982] Hanley, J. A. and McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (roc) curve. *Radiology*, 143(1):29–36.

- [Harutyunyan et al., 2019] Harutyunyan, H., Khachatrian, H., Kale, D. C., Ver Steeg, G., and Galstyan, A. (2019). Multitask learning and benchmarking with clinical time series data. *Scientific Data*, 6(1):1–18.
- [He et al., 2020] He, C., Li, S., So, J., Zhang, M., Wang, H., Wang, X., Vepakomma, P., Singh, A., Qiu, H., Shen, L., et al. (2020). Fedml: A research library and benchmark for federated machine learning. In *NeurIPS*.
- [Hegselmann et al., 2023] Hegselmann, S., Buendia, A., Lang, H., Agrawal, M., Ber, X., and Sontag, D. (2023). Tabllm: Few-shot classification of tabular data with large language models. *International Conference on Artificial Intelligence and Statistics*, pages 5549–5581.
- [Huang et al., 2020] Huang, X., Khetan, A., Cvitkovic, M., and Karnin, Z. (2020). Tabtransformer: Tabular data modeling using contextual embeddings. In *arXiv preprint*.
- [Jobin et al., 2019] Jobin, A., Ienca, M., and Vayena, E. (2019). The global landscape of ai ethics guidelines. *Nature Machine Intelligence*, 1(9):389–399.
- [Johnson et al., 2023] Johnson, A., Bulgarelli, L., Pollard, T., Horng, S., Celi, L. A., and Mark, R. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.
- [Johnson et al., 2016] Johnson, A. E., Pollard, T. J., Shen, L., Li-wei, H. L., Feng, M., Ghassemi, M., Moody, B., Szolovits, P., Celi, L. A., and Mark, R. G. (2016). MIMIC-III, a freely accessible critical care database. *Scientific Data*, 3(1):1–9.
- [Kaissis et al., 2020] Kaissis, G. A., Makowski, M. R., Rückert, D., and Braren, R. F. (2020). Secure, privacy-preserving and federated machine learning in medical imaging. *Nature Machine Intelligence*, 2(6):305–311.

- [Karimireddy et al., 2020] Karimireddy, S. P., Jaggi, M., Kale, S., Mohri, M., Suresh, A. T., et al. (2020). Scaffold: Stochastic controlled averaging for federated learning. In *ICML*.
- [Kingma and Ba, 2015] Kingma, D. P. and Ba, J. (2015). Adam: A method for stochastic optimization.
- [Koch et al., 2015] Koch, G., Zemel, R., and Salakhutdinov, R. (2015). Siamese neural networks for one-shot image recognition. In *ICML Deep Learning Workshop*.
- [Lake et al., 2015] Lake, B. M., Salakhutdinov, R., and Tenenbaum, J. B. (2015). Human-level concept learning through probabilistic program induction. In *Science*, volume 350, pages 1332–1338.
- [Lee et al., 2020] Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., and Kang, J. (2020). Biobert: A pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240.
- [Li et al., 2020a] Li, T., Sahu, A. K., Talwalkar, A., and Smith, V. (2020a). Federated optimization in heterogeneous networks. In *Proceedings of Machine Learning and Systems*.
- [Li et al., 2020b] Li, Y., Rao, S., Solares, J. R. A., Hassaine, A., Ramakrishnan, R., Canoy, D., Zhu, Y., Rahimi, K., and Salimi-Khorshidi, G. (2020b). Behrt: Transformer for electronic health records. *IEEE Journal of Biomedical and Health Informatics*.
- [Lin et al., 2017] Lin, T.-Y., Goyal, P., Girshick, R., He, K., and Dollár, P. (2017). Focal loss for dense object detection. In *ICCV*.
- [Lundberg and Lee, 2017] Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions.

- [Makel et al., 2012] Makel, M. C., Plucker, J. A., and Hegarty, B. (2012). Replications in psychology research: How often do they really occur? *Perspectives on Psychological Science*, 7(6):537–542.
- [Matthews, 1975] Matthews, B. W. (1975). Comparison of the predicted and observed secondary structure of t4 phage lysozyme. *Biochimica et Biophysica Acta*, 405(2):442–451.
- [McMahan et al., 2017] McMahan, B., Moore, E., Ramage, D., Hampson, S., and y Arcas, B. A. (2017). Communication-efficient learning of deep networks from decentralized data. *Artificial Intelligence and Statistics*, pages 1273–1282.
- [Nichol et al., 2018] Nichol, A., Achiam, J., and Schulman, J. (2018). On first-order meta-learning algorithms. *arXiv preprint arXiv:1803.02999*.
- [Obermeyer et al., 2019] Obermeyer, Z., Powers, B., Vogeli, C., and Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464):447–453.
- [Pham et al., 2016] Pham, T., Tran, T., Phung, D., and Venkatesh, S. (2016). Deep-care: A deep dynamic memory model for predictive medicine. *Pacific-Asia Conference on Knowledge Discovery*.
- [Prabhu et al., 2019] Prabhu, V., Kannan, A., Ravuri, M., Chaplain, M., Sontag, D., and Amatriain, X. (2019). Few-shot learning for dermatological disease diagnosis. In *Machine Learning for Healthcare Conference*, pages 532–552.
- [Purushotham et al., 2018] Purushotham, S., Meng, C., Zheng, Z., and Liu, Y. (2018). Benchmarking deep learning models on large healthcare datasets. *Journal of Biomedical Informatics*, 83:112–134.

- [Rajkomar et al., 2019] Rajkomar, A., Dean, J., and Kohane, I. (2019). Scalable and accurate deep learning with electronic health records. *NPJ Digital Medicine*, 2(1):1–10.
- [Rajkomar et al., 2018] Rajkomar, A., Hardt, M., Howell, M. D., Corrado, G., and Chin, M. H. (2018). Ensuring fairness in machine learning to advance health equity. *Annals of Internal Medicine*, 169(12):866–872.
- [Rasmy et al., 2021] Rasmy, L., Xiang, Y., Xie, Z., Tao, C., and Zhi, D. (2021). Medbert: Pretrained contextualized embeddings on large-scale structured electronic health records for disease prediction. *NPJ Digital Medicine*, 4(1):86.
- [Ravi and Larochelle, 2017] Ravi, S. and Larochelle, H. (2017). Optimization as a model for few-shot learning.
- [Reddi et al., 2021] Reddi, S., Charles, Z., Zaheer, M., Garrett, Z., Rush, K., Konečný, J., Kumar, S., and McMahan, H. B. (2021). Adaptive federated optimization. In *ICLR*.
- [Ribeiro et al., 2016] Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). Why should i trust you?: Explaining the predictions of any classifier.
- [Rieke et al., 2020] Rieke, N., Hanen, J., Jaderberg, M., et al. (2020). The future of digital health with federated learning. *NPJ Digital Medicine*, 3(1):1–7.
- [Shang et al., 2020] Shang, J., Ma, T., Xiao, C., and Sun, J. (2020). G-bert: Pre-training of graph augmented transformers for medication recommendation. *IJCAI*.
- [Sharafi and Aminian, 2023] Sharafi, M. and Aminian, G. (2023). ETHOS: Efficient transformer for health outcome prediction using symptom tokens. Technical report (thesis companion), Islamic Azad University, Tehran North Branch. Encoder architecture extended in this thesis for few-shot treatment feasibility on MIMIC-IV.

- [Sheller et al., 2020] Sheller, M. J., Edwards, B., Reina, G. A., Martin, J., Pati, S., Kotrotsou, A., Milchenko, M., Xu, W., Marcus, D., Colen, R. R., et al. (2020). Federated learning in medicine: Facilitating multi-institutional collaborations without sharing patient data. *Scientific Reports*, 10(1):12598.
- [Smith et al., 2017] Smith, V., Chiang, C.-K., Sanjabi, M., and Talwalkar, A. S. (2017). Federated multi-task learning. In *NeurIPS*.
- [Snell et al., 2017] Snell, J., Swersky, K., and Zemel, R. (2017). Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, volume 30.
- [Somepalli et al., 2021] Somepalli, G. et al. (2021). Saint: Improved neural networks for tabular data via row attention and contrastive pre-training. In *NeurIPS*.
- [Srivastava et al., 2014] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958.
- [Stanley et al., 2021] Stanley, E., Lowet, E., and Garg, N. (2021). Few-shot learning for clinical natural language processing. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 1742–1752.
- [Sung et al., 2018] Sung, F., Yang, Y., Zhang, L., Xiang, T., Torr, P. H., and Hospedales, T. M. (2018). Learning to compare: Relation network for few-shot learning. In *CVPR*.
- [Triantafillou et al., 2020] Triantafillou, E., Zhu, T., Dumoulin, V., Lamblin, P., Evci, U., Xu, K., Goroshin, R., Gelada, C., Swersky, K., et al. (2020). Meta-dataset: A dataset of datasets for learning to learn from few examples. In *ICLR*.

- [Vaswani et al., 2017] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *NeurIPS*.
- [Vinyals et al., 2016] Vinyals, O., Blundell, C., Lillicrap, T., and Wierstra, D. (2016). Matching networks for one shot learning. In *Advances in Neural Information Processing Systems*, volume 29.
- [Voigt and Von dem Bussche, 2017] Voigt, P. and Von dem Bussche, A. (2017). The eu general data protection regulation (gdpr). *Springer*.
- [Wang et al., 2020] Wang, Y., Yao, Q., Kwok, J. T., and Ni, L. M. (2020). Generalizing from a few examples: A survey on few-shot learning. *ACM Computing Surveys*, 53(3):1–34.
- [Ye et al., 2020] Ye, H.-J., Hu, H., Zhan, D.-C., and Sha, F. (2020). Few-shot learning via saliency-guided hallucination of samples. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 770–779.
- [Zhang et al., 2021] Zhang, W., Zhou, T., Lu, Q., Wang, X., Zhu, H., et al. (2021). Federated learning for healthcare informatics. *Journal of Healthcare Informatics Research*, 5:1–19.

چکیده انگلیسی

Predicting *treatment feasibility* from limited, aggregated clinical data is a critical challenge in personalized healthcare decision support. We address this using a novel pipeline combining *Symptom Tokens*—a compact representation of labs and vitals—with the ETHOS encoder, few-shot meta-learning, and federated training. Experiments use a 2,000-patient MIMIC-IV v3.1 sample, split into five disease nodes (sepsis, cardiac, respiratory, renal, diabetes).

We establish a strong **tabular ceiling**: the SOTA pipeline (`exp_tabular_sota.py`) reaches **test AUROC 0.748** (F1 0.674, accuracy 0.700). The unified best few-shot pipeline (`exp_fewshot_best.py`) with stacking achieves **AUROC 0.746** (95% bootstrap CI [0.699, 0.797])—*matching the ceiling within sampling noise*—while the few-shot sub-model alone reaches AUROC 0.670. Under the separate Exp1 comparison script (`exp1_main.py`), `Proposed_FewShot` attains **AUROC 0.611** on the test split, illustrating that episodic Exp1 metrics and the stacked “best” pipeline are not interchangeable. Federated training costs about **0.5 percentage points** AUROC vs. centralized on our setup.

Key innovations include Proto-MAML-style adaptation, knowledge distillation from a Random Forest teacher, supervised contrastive pre-training, engineered tabular features, gated feature attention, cross-attention prototypes, and a stacking meta-learner fusing few-shot and classical predictions.

We contribute: (1) a reproducible MIMIC-IV feasibility benchmark with a clear reporting hierarchy (ceiling → hybrid → stacked few-shot → federated); (2) Symptom Tokens plus ETHOS for few-shot learning; (3) evidence that stacking closes most of the gap to the tabular ceiling; and (4) open code and auto-exported tables for replication.

Keywords: treatment feasibility, few-shot learning, federated learning, MIMIC-IV, Symptom Tokens, ETHOS, clinical machine learning.

