



دانشگاه آزاد اسلامی

واحد تهران شمال

دانشکده برق و کامپیوتر، گروه مهندسی کامپیوتر

پایان نامه کارشناسی ارشد

رشته: مهندسی کامپیوتر

گرایش: نرم افزار

عنوان:

فیوژنات درمانی:

پیش بینی هوشمند قابلیت درمان
با توکن های علائم از داده های تجمیع شده

استاد راهنما: جناب آقای دکتر علی محمدزاده

محمد شرفی

نگارش:

اسفند ۱۴۰۴

تعمدنامه‌ی اصالت رساله یا پایان نامه

اینجانب محمد شرفی، دانش‌آموخته‌ی مقطع کارشناسی ارشد ناپیوسته در رشته‌ی مهندسی کامپیوتر،
گرایش نرم‌افزار، که در تاریخ از پایان‌نامه‌ی خود تحت عنوان

فیوضات درمانی:

پیش‌بینی هوشمند قابلیت درمان با توکن‌های علائم از داده‌های تجمیع‌شده

با کسب نمره‌ی و درجه‌ی دفاع نموده‌ام، بدین‌وسیله متعهد می‌شوم:

- این پایان‌نامه حاصل تحقیق و پژوهش انجام‌شده توسط اینجانب بوده و در مواردی که از دستاوردهای علمی و پژوهشی دیگران، اعم از پایان‌نامه، کتاب، مقاله، گزارش، نرم‌افزار یا مجموعه‌داده، استفاده کرده‌ام، مطابق ضوابط و رویه‌ی موجود، نام منبع مورد استفاده و سایر مشخصات آن را در فهرست مربوطه ذکر و درج کرده‌ام.
- این پایان‌نامه پیش‌تر برای دریافت هیچ مدرک تحصیلی، در همین سطح یا سطوح پایین‌تر و بالاتر، در سایر دانشگاه‌ها و مؤسسات آموزش عالی ارائه نشده است.
- چنانچه پس از فراغت از تحصیل قصد استفاده یا هرگونه بهره‌برداری، اعم از چاپ کتاب، انتشار مقاله، ثبت اختراع، توسعه‌ی نرم‌افزار یا کاربرد اجرایی از این پایان‌نامه را داشته باشم، مجوزهای لازم را از حوزه‌ی معاونت پژوهشی واحد دانشگاهی اخذ خواهم کرد.
- چنانچه در هر مقطع زمانی خلاف موارد فوق ثابت شود، عواقب ناشی از آن را می‌پذیرم و واحد دانشگاهی مجاز است مطابق ضوابط و مقررات با اینجانب رفتار نماید. در صورت ابطال مدرک تحصیلی نیز هیچ‌گونه ادعایی نخواهم داشت.

محمد شرفی

نام و نام خانوادگی:

.....

امضا:

.....

تاریخ:

تقديم

به خانواده‌ام که همواره پشتیبان من بودند.

سپاسگزاری

خاستگاه این پژوهش به تجربه کاری من در بستر Mayo Clinic بازمی گردد؛ جایی که از نزدیک با دو واقعیت همزمان روبه‌رو شدم: نیاز روزافزون به پیش‌بینی هوشمند در سلامت، و دشواری جدی دسترسی به داده بالینی حساس. در آن تجربه، آنچه در دسترس بود عمدتاً شناسه‌ها و کدها بود، نه پرونده‌های بالینی خام. همین محدودیت برای من روشن کرد که اگر قرار است مدل‌های پیش‌بینی در پزشکی کاربرد واقعی پیدا کنند، باید بتوانند بدون تجمیع مستقیم داده و با احترام به حریم خصوصی بیمار آموزش ببینند. این پایان‌نامه از همان دغدغه شکل گرفت و سه مسیر یادگیری کم‌نمونه، یادگیری فدرال و بازنمایی فشرده مبتنی بر توکن‌های علائم را دنبال کرد. از استاد راهنما، دکتر علی محمدزاده، برای راهنمایی‌های ارزشمندشان و از همه کسانی که در این مسیر همراه من بودند، صمیمانه سپاسگزارم.

فهرست مطالب

ک	چکیده
ل	مقدمه
۱	۱ کلیات تحقیق
۱	۱.۱ بستر بالینی
۱	۱.۱.۱ محیط بخش مراقبت ویژه و تصمیم‌گیری
۱	۲.۱.۱ گردش کار بالینی و نقاط تصمیم
۲	۳.۱.۱ برنامه‌ریزی ترخیص و امکان‌پذیری درمان
۲	۲.۱ تحول دیجیتال در سلامت
۳	۱.۲.۱ از سیلوهای داده تا هوش تجمیعی
۳	۲.۲.۱ وعده و خطر هوش مصنوعی بالینی
۴	۳.۲.۱ امکان‌پذیری درمان در عصر مراقبت مبتنی بر ارزش
۴	۳.۱ انگیزه
۵	۴.۱ بیان مسئله
۶	۵.۱ شکاف پژوهشی
۶	۱.۵.۱ شکاف ۱: یادگیری کم‌نمونه بر داده‌ی بالینی جدولی
۷	۲.۵.۱ شکاف ۲: یادگیری فدرال کم‌نمونه برای مراقبت‌های بهداشتی
۷	۳.۵.۱ شکاف ۳: ارزیابی صادقانه‌ی روش‌های عصبی بر مجموعه‌داده‌های بالینی کوچک
۷	۴.۵.۱ شکاف ۴: بازنمایی‌های بالینی مبتنی بر توکن‌های علائم
۸	۶.۱ اصطلاحات و تعاریف
۸	۷.۱ مرور کلی روش پژوهش

۸	اهداف پژوهش و مفروضات	۸.۱
۹	۱.۸.۱ تطبیق با پروپوزال اولیه	۹.۱
۹	پرسش‌های پژوهش	۹.۱
۱۱	نوآوری‌ها و مشارکت‌ها	۱۰.۱
۱۳	ساختار پایان‌نامه	۱۱.۱
۱۴	بستر مقرراتی و اخلاقی	۱۲.۱
۱۴	تحلیل ذی‌نفعان	۱۳.۱
۱۴	خلاصه‌ی فصل	۱۴.۱
۱۵	دامنه و محدودیت‌ها	۱۵.۱
۱۵	اهمیت در بستر پزشکی دقیق	۱۶.۱
۱۵	۱.۱۶.۱ از میانگین‌های جمعیتی تا پیش‌بینی فردی	۱۵.۱
۱۵	۲.۱۶.۱ سازگاری کم‌نمونه به‌عنوان شخصی‌سازی	۱۵.۱
۱۶	۳.۱۶.۱ تعمیم بین‌نهادی	۱۶.۱

۲ پیشینه و کارهای مرتبط ۱۷

۱۷	یادگیری کم‌نمونه	۱.۲
۱۷	۱.۱.۲ تاریخچه و تحول	۱.۲
۱۸	۲.۱.۲ فرمول‌بندی مسئله	۲.۲
۱۸	۳.۱.۲ شبکه‌های نمونه‌ای	۳.۲
۱۸	۴.۱.۲ شبکه‌های تطبیقی	۴.۲
۱۹	۵.۱.۲ شبکه‌های رابطه‌ای	۵.۲
۲۰	۶.۱.۲ شبکه‌های سیامی	۶.۲
۲۰	۷.۱.۲ فرا یادگیری مستقل از مدل (MAML)	۷.۲
۲۱	۸.۱.۲ آموزش اپیزودیک	۸.۲
۲۱	۹.۱.۲ تضمین‌های نظری	۹.۲
۲۱	۱۰.۱.۲ کاربردها در سلامت	۱۰.۲
۲۲	۲.۲ یادگیری فدرال	۲.۲
۲۲	۱.۲.۲ انگیزه	۱.۲.۲

۲۲	 میانگین گیری فدرال (FedAvg)	۲.۲.۲
۲۲	 حریم خصوصی و امنیت	۳.۲.۲
۲۲	 همگرایی و ارتباطات	۴.۲.۲
۲۳	 FedProx: مدیریت ناهمگونی	۵.۲.۲
۲۳	 SCAFFOLD: کاهش واریانس	۶.۲.۲
۲۴	 کارایی ارتباطات	۷.۲.۲
۲۴	 داده غیر IID	۸.۲.۲
۲۵	 کاربردها در سلامت	۹.۲.۲
۲۵	 بازنمایی داده بالینی	۳.۲
۲۵	 داده بالینی خام	۱.۳.۲
۲۶	 راهبردهای نرمال سازی	۲.۳.۲
۲۶	 بازنمایی های مبتنی بر توکن	۳.۳.۲
۲۶	 جدولی در برابر دنباله ای	۴.۳.۲
۲۶	 مجموعه داده MIMIC-IV	۴.۲
۲۶	 مرور کلی	۱.۴.۲
۲۷	 ساختار داده	۲.۴.۲
۲۷	 تعریف کوهورت	۳.۴.۲
۲۸	 تعریف برچسب	۴.۴.۲
۲۸	 گره های بیماری	۵.۴.۲
۲۸	 کارهای مرتبط: پیش بینی بالینی	۵.۲
۲۸	 پیش بینی مبتنی بر EHR	۱.۵.۲
۲۸	 پیش بینی ترخیص	۲.۵.۲
۲۹	 یادگیری عمیق در برابر جدولی	۳.۵.۲
۲۹	 یادگیری کم نمونه روی داده جدولی	۴.۵.۲
۳۰	 مکانیزم های توجه برای داده بالینی	۵.۵.۲
۳۰	 جزئیات معماری ETHOS	۶.۵.۲
۳۲	 رویکردهای توکن سازی علامت در ادبیات	۷.۵.۲
۳۲	 جمع بندی	۶.۲

۷.۲	جدول مقایسه کارهای پیشین	۳۳
۸.۲	ادبیات تفصیلی: مقالات کلیدی	۳۳
۹.۲	خلاصه مبانی نظری	۳۴
۱۰.۲	مرور گسترده ادبیات	۳۴
۱.۱۰.۲	مبانی فرا یادگیری	۳۴
۲.۱۰.۲	یادگیری انتقالی و سازگاری دامنه	۳۴
۳.۱۰.۲	یادگیری متضاد و یادگیری متریک	۳۵
۴.۱۰.۲	چالش‌های ویژه سلامت	۳۵
۱۱.۲	ترنسفورمرها در داده بالینی	۳۵
۱.۱۱.۲	مکانیزم‌های توجه	۳۵
۲.۱۱.۲	رمزگذاری موقعیتی	۳۵
۳.۱۱.۲	ترنسفورمرهای بالینی	۳۶
۱۲.۲	یادگیری در شرایط نامتوازن	۳۶
۱.۱۲.۲	نامتوانی کلاس در داده بالینی	۳۶
۲.۱۲.۲	SMOTE و نمونه‌برداری مجدد	۳۶
۳.۱۲.۲	معیارهای ارزیابی	۳۶
۱۳.۲	تفسیرپذیری در یادگیری ماشین سلامت	۳۶
۱.۱۳.۲	اهمیت ویژگی	۳۶
۲.۱۳.۲	تصویرسازی توجه	۳۷
۳.۱۳.۲	اعتبارسنجی بالینی	۳۷
۱۴.۲	مرور جامع ادبیات	۳۷
۱.۱۴.۲	تحول و بنچمارک‌های یادگیری کم‌نمونه	۳۷
۲.۱۴.۲	یادگیری فدرال: سامانه‌ها و نظریه	۳۷
۳.۱۴.۲	پیش‌بینی بالینی: وضعیت هنر	۳۸
۴.۱۴.۲	یادگیری عمیق جدولی	۳۸
۵.۱۴.۲	مجموعه‌های داده بنچمارک در ML بالینی	۳۸
۶.۱۴.۲	پیش‌بینی ترخیص: نتایج پیشین	۳۹
۷.۱۴.۲	AI اخلاقی در سلامت	۳۹

۴۰	جزئیات معماری ترنسفورمر	۱۵.۲
۴۰	پروتکل ارزیابی و واریانس K-شات	۱۶.۲
۴۰	بنچمارک‌های یادگیری کم‌نمونه	۱۷.۲
۴۱	یادگیری فدرال: ارتباطات و حریم خصوصی	۱۸.۲
۴۱	پیش‌بینی بالینی: فرمول‌بندی وظیفه	۱۹.۲
۴۱	جایگزینی و مدیریت داده گمشده	۲۰.۲
۴۲	جمع‌بندی فصل	۲۱.۲

۳ روش‌شناسی ۴۳

۴۳	نمادگذاری	۱.۳
۴۴	نمای کلی فرایند	۲.۳
۴۴	مجموعه داده و پیش‌پردازش	۳.۳
۴۴	استخراج کوهورت	۱.۳.۳
۴۵	فرایند تفصیلی استخراج MIMIC-IV	۲.۳.۳
۴۶	استخراج آزمایشگاه و علائم حیاتی	۳.۳.۳
۴۷	مهندسی ویژگی	۴.۳.۳
۴۸	راهبرد داده‌ی گمشده	۵.۳.۳
۴۹	تقسیم داده	۶.۳.۳
۴۹	توکن‌سازی علائم	۴.۳
۴۹	ساختار توکن	۱.۴.۳
۵۰	ساخت دنباله	۲.۴.۳
۵۰	ارتباط با ویژگی‌های جدولی	۳.۴.۳
۵۰	معماری رمزگذار ETHOS	۵.۳
۵۰	نمای کلی	۱.۵.۳
۵۱	پیکربندی	۲.۵.۳
۵۱	خروجی	۳.۵.۳
۵۱	جزئیات مکانیزم توجه	۴.۵.۳
۵۱	پیش‌بینی درمان کم‌نمونه	۶.۳

۵۱	پروتکل اپیزودیک	۱.۶.۳
۵۲	سر نمونه‌ی اولیه‌ی	۲.۶.۳
۵۲	تابع هزینه	۳.۶.۳
۵۳	تصویر فضای متریک	۴.۶.۳
۵۳	آموزش	۵.۶.۳
۵۳	سر شبکه‌ی رابطه (جایگزین)	۷.۳
۵۴	آموزش فدرال	۸.۳
۵۴	افراز گره	۱.۸.۳
۵۵	پروتکل FedAvg	۲.۸.۳
۵۶	پارامترهای مشترک در برابر محلی	۳.۸.۳
۵۶	پایش همگرایی	۴.۸.۳
۵۶	معماری ترکیبی ETHOS و جنگل تصادفی	۹.۳
۵۷	پروتکل ارزیابی	۱۰.۳
۵۷	معیارها	۱.۱۰.۳
۵۷	AUROC (مساحت زیر منحنی مشخصه‌ی عملیاتی گیرنده)	۱.۱۱.۰.۳
۵۷	دقت، فراخوانی، و امتیاز F1	۲.۱۱.۰.۳
۵۸	ضریب همبستگی متیوز (MCC)	۳.۱۱.۰.۳
۵۸	دقت (Accuracy)	۴.۱۱.۰.۳
۵۸	نمره‌ی Brier	۵.۱۱.۰.۳
۵۹	معناداری و محدودیت مقایسه‌ی آماری	۶.۱۱.۰.۳
۵۹	پایداری (واریانس)	۷.۱۱.۰.۳
۵۹	خط پایه‌ها	۲.۱۰.۳
۶۰	تنظیم آستانه	۳.۱۰.۳
۶۰	جزئیات پیاده‌سازی	۱۱.۳
۶۰	بهینه‌سازی	۱.۱۱.۳
۶۰	منظم‌سازی	۲.۱۱.۳
۶۰	بازتولیدپذیری	۳.۱۱.۳
۶۱	شبه‌کد الگوریتم	۱۲.۳

۶۱	آموزش کم‌نمونه نمونه‌ی اولیه‌ی	۱.۱۲.۳
۶۱	میانگین‌گیری فدرال	۲.۱۲.۳
۶۲	یادداشت درباره‌ی محیط الگوریتم	۳.۱۲.۳
۶۲	پیچیدگی محاسباتی	۱۳.۳
۶۲	رمزگذار ETHOS	۱.۱۳.۳
۶۲	ارتباط فدرال	۲.۱۳.۳
۶۲	جایگزین‌های توکن‌سازی	۳.۱۳.۳
۶۲	خط پایه‌های کلاسیک	۴.۱۳.۳
۶۳	استنتاج‌های ریاضی	۱۴.۳
۶۳	گرادیان هزینه‌ی نمونه‌ی اولیه‌ی	۱.۱۴.۳
۶۳	زیان کانونی	۲.۱۴.۳
۶۳	فواصل اطمینان bootstrap	۳.۱۴.۳
۶۴	استنتاج جایگزین SOFA و شاخص شوک	۴.۱۴.۳
۶۴	نمای کلی معماری نرم‌افزار	۱۵.۳
۶۴	معماری V5: توجه ویژگی دروازه‌ای با نمونه‌های اولیه‌ی متقاطع	۱۶.۳
۶۵	توجه ویژگی دروازه‌ای (GFA)	۱.۱۶.۳
۶۵	سر نمونه‌ی اولیه‌ی متقاطع	۲.۱۶.۳
۶۶	معماری V6: گروه عمیق ناهمگن	۱۷.۳
۶۶	معماری‌های جایگزین مورد بررسی	۱۸.۳
۶۷	پیاده‌سازی و بازتولیدپذیری	۱۹.۳
۶۷	فرایند داده و گام‌های پیش‌پردازش	۲۰.۳
۶۷	جزئیات پروتکل ارزیابی	۲۱.۳
۶۸	خلاصه‌ی فصل	۲۲.۳

۴ آزمایش‌ها ۶۹

۶۹	چیدمان تجربی	۱.۴
۶۹	پیاده‌سازی و معماری نرم‌افزار	۱.۱.۴
۷۰	پیکربندی داده	۲.۱.۴

۷۰	پیکربندی ETHOS و یادگیری کم‌نمونه	۳.۱.۴
۷۰	پیکربندی خط پایه کلاسیک	۴.۱.۴
۷۰	فرضیات آزمایش	۲.۴
۷۱	توان آماری و اندازه نمونه	۳.۴
۷۱	مشخصات سخت‌افزار و نرم‌افزار	۴.۴
۷۱	فلسفه طراحی آزمایش	۵.۴
۷۲	رویه اجرای آزمایش	۶.۴
۷۲	پیکربندی‌های مدل خط پایه	۷.۴
۷۳	معیارهای ارزیابی و گزارش	۸.۴
۷۳	آزمایش ۱: مقایسه مدل اصلی	۹.۴
۷۳	هدف ۱.۹.۴	۱.۹.۴
۷۳	مدل‌ها ۲.۹.۴	۲.۹.۴
۷۴	خلاصه نتایج ۳.۹.۴	۳.۹.۴
۷۴	آزمایش ۲: حساسیت K-شات	۱۰.۴
۷۴	هدف ۱.۱۰.۴	۱.۱۰.۴
۷۴	جزئیات طراحی ۲.۱۰.۴	۲.۱۰.۴
۷۴	طراحی ۳.۱۰.۴	۳.۱۰.۴
۷۵	خلاصه نتایج ۴.۱۰.۴	۴.۱۰.۴
۷۵	آزمایش ۳: فدرال در برابر متمرکز	۱۱.۴
۷۵	هدف ۱.۱۱.۴	۱.۱۱.۴
۷۵	طراحی ۲.۱۱.۴	۲.۱۱.۴
۷۵	خلاصه نتایج ۳.۱۱.۴	۳.۱۱.۴
۷۶	آزمایش ۴: مطالعه حذف تدریجی	۱۲.۴
۷۶	هدف ۱.۱۲.۴	۱.۱۲.۴
۷۶	گونه‌ها ۲.۱۲.۴	۲.۱۲.۴
۷۶	خلاصه نتایج ۳.۱۲.۴	۳.۱۲.۴
۷۶	آزمایش ۵: تعمیم بین‌بیماری	۱۳.۴
۷۶	هدف ۱.۱۳.۴	۱.۱۳.۴

۷۷	طراحی	۲.۱۳.۴
۷۷	خلاصه نتایج	۳.۱۳.۴
۷۷	رویه جستجوی ابرپارامتر	۱۴.۴
۷۸	آزمایش ۵.۸: گسترش‌های حذف تدریجی ETHOS	۱۵.۴
۷۸	هدف	۱.۱۵.۴
۷۸	طراحی	۲.۱۵.۴
۷۸	خلاصه نتایج	۳.۱۵.۴
۷۸	آزمایش ۵.۹: معماری‌های ترکیبی	۱۶.۴
۷۸	هدف	۱.۱۶.۴
۷۸	طراحی	۲.۱۶.۴
۷۹	خلاصه نتایج	۳.۱۶.۴
۷۹	جمع‌بندی فصل	۱۷.۴

۵ نتایج

۸۰	
۸۱	بهترین مدل کلاسیک نهایی
۸۲	عملکرد ETHOS و یادگیری کم‌نمونه
۸۳	آزمایش ۱: مقایسه مدل اصلی
۸۳	آزمایش ۲: حساسیت K-شات
۸۴	آزمایش ۳: فدرال در برابر متمرکز
۸۶	آزمایش ۴: حذف تدریجی
۸۷	آزمایش ۵: تعمیم بین‌بیماری
۸۷	مقایسه گسترده مدل‌ها (۱۱ مدل)
۸۸	مقایسه مدل با بازه‌های اطمینان
۸۸	خلاصه یافته‌های کلیدی
۸۹	معناداری آماری
۸۹	تفسیرپذیری
۹۰	مطالعات موردی بالینی
۹۲	تحلیل توزیع اطمینان

۹۲	معیارهای تفصیلی به تفکیک بیماری	۱۵.۵
۹۲	کالیبراسیون و تحلیل حساسیت	۱۶.۵
۹۳	تحلیل خطا به ازای ویژگی	۱۷.۵
۹۳	تحلیل ROC و دقت-بازخوانی	۱۸.۵
۹۴	منحنی‌های یادگیری و کارایی داده	۱۹.۵
۹۴	نتایج حساسیت ابرپارامتر	۲۰.۵
۹۴	تاب‌آوری تقسیم جایگزین	۲۱.۵
۹۵	تحلیل معماری مدل تقویت‌شده	۲۲.۵
۹۵	راهنماهای آموزش بهبودیافته	۲۳.۵
۹۶	راهنما ۱: سر نمونه اولیه-رابطه ترکیبی با پیش‌تنظیم نظارت‌شده	۱.۲۳.۵
۹۶	راهنما ۲: ترکیبی بهبودیافته (XGBoost + ETHOS)	۲.۲۳.۵
۹۷	راهنما ۳: طبقه‌بند نظارت‌شده ETHOS	۳.۲۳.۵
۹۷	راهنما ۴: مدل کم‌نمونه V2 با SupCon و آموزش چندفازی	۴.۲۳.۵
۹۸	راهنما ۵: مدل کم‌نمونه V3 با تقطیر دانش از جنگل تصادفی	۵.۲۳.۵
۹۸	راهنما ۶: مدل کم‌نمونه V4 با Proto-MAML و فرا یادگیر انباشتی	۶.۲۳.۵
۹۹	راهنما ۷: مدل کم‌نمونه V5 با توجه دروازه‌ای و توجه متقاطع	۷.۲۳.۵
۱۰۰	راهنما ۸: مدل کم‌نمونه V6 با تجميع عمیق و انباشت XGBoost	۸.۲۳.۵
۱۰۱	تحلیل بهبودها	۹.۲۳.۵
۱۰۵	جمع‌بندی فصل	۲۴.۵

۶ تحلیل داده و یافته‌های اکتشافی ۱۰۶

۱۰۶	طرحواره و گردش داده MIMIC-IV	۱۶
۱۰۷	جمعیت‌شناسی کوهورت	۲۶
۱۰۷	توزیع گره بیماری	۳۶
۱۰۹	همبستگی آزمایشگاه و علائم حیاتی	۴۶
۱۰۹	پراکسی SOFA و شدت بالینی	۵۶
۱۱۰	عملکرد لایه‌بندی‌شده بر اساس سن	۶۶
۱۱۰	تحلیل خطا: کراتینین	۷۶

۱۱۰	تصویرسازی فضای نهفته (t-SNE)	۸۶
۱۱۲	تحلیل نمونه	۹۶
۱۱۲	نمونه خط زمانی بیمار	۱۰۶
۱۱۴	تعادل کلاس	۱۱۶
۱۱۴	فقدان داده و کیفیت داده	۱۲۶
۱۱۴	ارزیابی کیفیت داده	۱۳۶
۱۱۵	الگوهای زمانی	۱۴۶
۱۱۵	توزیع مقادیر آزمایشگاه و علائم حیاتی	۱۵۶
۱۱۵	نوع پذیرش و مقصد ترخیص	۱۶۶
۱۱۶	ساختار همبستگی و افزونگی ویژگی	۱۷۶
۱۱۶	جمع‌بندی فصل	۱۸۶

۷ بحث و گفتگو ۱۱۷

۱۱۷	تفسیر عملکرد	۱۰۷
۱۱۷	از نتیجه منفی تا نزدیکی به تساوی	۱۰۱.۷
۱۱۸	سقف تجربی و بستن تدریجی فاصله	۲۰۱.۷
۱۱۸	محدودیت‌های فرا یادگیری کم‌نمونه	۲۰۷
۱۱۸	ناسازگاری اپیزودیک	۱۰۲.۷
۱۱۸	ناسازگاری سوگیری القایی	۲۰۲.۷
۱۱۹	مقیاس داده	۳۰۲.۷
۱۲۰	بازنمایی	۴۰۲.۷
۱۲۰	تحلیل تفصیلی: چرا خط پایه اولیه کم‌نمونه ضعیف‌تر بود	۳۰۷
۱۲۰	عامل ۱: گلوگاه فشرده‌سازی بازنمایی	۱۰۳.۷
۱۲۰	عامل ۲: هندسه نمونه اولیه در فضاها کم‌بعد	۲۰۳.۷
۱۲۱	عامل ۳: واریانس نمونه برداری اپیزودیک	۳۰۳.۷
۱۲۱	عامل ۴: مدل سازی تعامل ویژگی	۴۰۳.۷
۱۲۲	عامل ۵: منظره بهینه سازی	۵۰۳.۷
۱۲۲	معامله ها و پیامدهای عملی	۴۰۷

۱۲۲	چه وقت از ETHOS و یادگیری کم‌نمونه استفاده کنیم	۱.۴.۷
۱۲۲	چه وقت از مدل‌های کلاسیک استفاده کنیم	۲.۴.۷
۱۲۳	از ترکیبی به انباشت: مسیر تا تساوی	۳.۴.۷
۱۲۳	اعتبارسنجی بالینی و تحلیل علی: چارچوب پیشنهادی	۵.۷
۱۲۳	مسیر پیشنهادی برای اعتبارسنجی آینده	۱.۵.۷
۱۲۴	مرزبندی ادعا	۲.۵.۷
۱۲۴	یادگیری چندوظیفه‌ای: مسیر توسعه	۶.۷
۱۲۴	تحلیل حساسیت	۷.۷
۱۲۴	حساسیت ابرپارامتر	۱.۷.۷
۱۲۵	حساسیت شات پشتیبان K	۲.۷.۷
۱۲۵	اثر ترکیب ماژول‌ها	۳.۷.۷
۱۲۵	اثر اقتصادی و بازگشت سرمایه‌ی توضیحی (ROI)	۸.۷
۱۲۶	گسترش سری زمانی: مسیر پیشنهادی	۹.۷
۱۲۶	تحلیل خطا	۱۰.۷
۱۲۶	ملاحظات استقرار	۱۱.۷
۱۲۷	مشخصات رابط برنامه‌نویسی کاربردی (API)	۱۲.۷
۱۲۷	تحلیل تفصیلی خطا به تفکیک زیرگروه	۱۳.۷
۱۲۷	مقایسه با کار پیشین	۱۴.۷
۱۲۷	ادبیات پیش‌بینی ترخیص	۱.۱۴.۷
۱۲۷	یادگیری کم‌نمونه در سلامت	۲.۱۴.۷
۱۲۸	بهداشت فدرال	۳.۱۴.۷
۱۲۹	ملاحظات نظری	۱۵.۷
۱۲۹	چرا شبکه‌های نمونه‌اولیه ممکن است ضعیف‌تر عمل کنند	۱.۱۵.۷
۱۲۹	کارایی داده	۲.۱۵.۷
۱۳۰	تهدیدهای اعتبار	۳.۱۵.۷
۱۳۰	گلوگاه بازنمایی: تحلیل عمیق‌تر	۴.۱۵.۷
۱۳۱	مقایسه بین حوزه‌ای: یادگیری کم‌نمونه در انواع داده	۱۶.۷
۱۳۱	حوزه بیش	۱.۱۶.۷

۱۳۱	 حوزه NLP	۲.۱۶.۷
۱۳۲	 حوزه کشف دارو	۳.۱۶.۷
۱۳۲	 حوزه جدولی	۴.۱۶.۷
۱۳۲	 ترکیب	۵.۱۶.۷
۱۳۳	 پیامدهای بالینی و تحلیل استقرار	۱۷.۷
۱۳۳	 تأثیر بر گردش کار بالینی	۱.۱۷.۷
۱۳۳	 اعتماد و پذیرش بالینی	۲.۱۷.۷
۱۳۴	 معماری استقرار فدرال	۳.۱۷.۷
۱۳۴	 مسیر نظارتی	۴.۱۷.۷
۱۳۵	 نوآوری و مشارکت‌های اصلی	۱۸.۷
۱۳۶	 جدول مقایسه: کار ما در برابر پیشین	۱۹.۷
۱۳۶	 ملاحظات اخلاقی و انصاف	۲۰.۷
۱۳۷	 چک‌لیست بازتولیدپذیری	۲۱.۷
۱۳۷	 درس‌های آزمایش‌های V5 و V6	۲۲.۷
۱۳۸	 کارهای آینده	۲۳.۷
۱۳۹	 خلاصه نکات کلیدی و درس‌های آموخته‌شده	۲۴.۷
۱۴۰	 خلاصه محدودیت‌ها	۲۵.۷
۱۴۱	 جمع‌بندی فصل	۲۶.۷

۸ نتیجه‌گیری

۱۴۲		
۱۴۳	 خلاصه مشارکت‌ها	۱.۸
۱۴۳	 پیامدها برای استقرار بالینی	۱.۱.۸
۱۴۵	 تطبیق نهایی با پروپوزال	۲.۱.۸
۱۴۵	 توصیه‌ها برای پژوهشگران و عملگران	۳.۱.۸
۱۴۶	 اهمیت برای حوزه	۴.۱.۸
۱۴۶	 جمع‌بندی	۵.۱.۸
۱۴۶	 پاسخ به پرسش‌های پژوهشی	۶.۱.۸

آ ابرپارامترها ۱۴۷

- ۱.آ رمزگذار ETHOS ۱۴۷
- ۲.آ یادگیری کم نمونه ۱۴۷
- ۳.آ یادگیری فدرال ۱۴۷
- ۴.آ بهترین مدل نهایی (جنگل تصادفی) ۱۴۷

ب پرس وجوهای SQL برای MIMIC-IV ۱۴۹

- ۱.ب استخراج کوهورت ۱۴۹
- ۲.ب استخراج آزمایشگاه ۱۵۰
- ۳.ب استخراج علائم حیاتی ۱۵۰
- ۴.ب برچسب: محل ترخیص ۱۵۰
- ۵.ب تشخیص اولیه برای گره های بیماری ۱۵۱
- ۶.ب تجمیع: اولین مقدار به ازای هر بستری ۱۵۱

پ قطعه کدهای برنامه ۱۵۳

- ۱.پ توکن سازی علائم ۱۵۳
- ۲.پ سر Prototypical ۱۵۳
- ۳.پ زیان کانونی ۱۵۴
- ۴.پ عبور رو به جلوی رمزگذار ETHOS ۱۵۴
- ۵.پ به روز رسانی سرور FedAvg ۱۵۵

ت جداول کامل نتایج ۱۵۶

- ۱.ت سقف مدل های جدولی: همه ی مدل ها ۱۵۶
- ۲.ت نتایج مدل های تجمیعی ۱۵۶
- ۳.ت شناسه های آیتم آزمایشگاه و علائم حیاتی ۱۵۷

ث استنتاج های ریاضی ۱۵۹

- ۱.ث تعریف AUROC ۱۵۹
- ۲.ث امتیاز F1 کلان ۱۶۰

۳.ث	ضریب همبستگی متیوز (MCC)	۱۶۰
۴.ث	گرادیان تابع زیان شبکه‌ی نمونه‌اولیه‌ای (Prototypical)	۱۶۰
۵.ث	زیان کانونی	۱۶۱
۶.ث	قانون به‌روزرسانی FedAvg	۱۶۱
۷.ث	خودتوجهی	۱۶۱
۸.ث	بازهی اطمینان bootstrap	۱۶۲
۹.ث	آزمون DeLong	۱۶۲

ج زمان‌بندی پروژه (نمودار گانت) ۱۶۳

۱.ج	زمان‌بندی ۱۲ ماهه	۱۶۳
۲.ج	نمای کلی فازها	۱۶۳
۳.ج	نقاط عطف کلیدی	۱۶۳
۴.ج	گرافیک نقشه‌ی راه	۱۶۴
۵.ج	مدیریت ریسک	۱۶۴

چ واژه‌نامه (۵۰ واژه) ۱۶۶

۱.چ	مفاهیم هسته	۱۶۶
۲.چ	واژه‌نامه‌ی تفصیلی (فهرست کامل)	۱۶۶

ح تهدیدهای اعتبار و کاهش اثر ۱۷۰

۱.ح	اعتبار درونی	۱۷۰
۲.ح	محدودیت‌ها	۱۷۰

خ چک‌لیست تکرارپذیری ۱۷۲

۱.خ	چک‌لیست	۱۷۲
۲.خ	فهرست کد	۱۷۲
۳.خ	دسترسی به داده	۱۷۳
۴.خ	محیط و وابستگی‌ها	۱۷۳

د جداول نتایج صادرشده از خط لوله ۱۷۵

۱۷۷	ملاحظات اخلاقی	ذ
۱۷۷	۱.۰ چارچوب اخلاقی	
۱۷۷	۲.۰ پیامدهای سیاست	
۱۷۸	۳.۰ ادعاهای به سبک ثبت اختراع	
۱۷۹	عناصر خلاقانه و تجسمها	ر
۱۷۹	۱.۰ پوستره‌های معماری	
۱۷۹	۲.۰ اینفوگرافیک سفر بیمار	
۱۸۰	۳.۰ تحلیل SWOT	
۱۸۰	۴.۰ دمو‌ی تعاملی	
۱۸۰	۵.۰ نمودار گردباد حساسیت	
۱۸۰	۶.۰ مختصات موازی	
۱۸۱	مشخصات رابط برنامه‌نویسی کاربردی (API)	ز
۱۸۱	۱.۰ نمای کلی	
۱۸۱	۲.۰ نقاط پایانی	
۱۸۱	۱.۲.۰ POST /predict	
۱۸۲	۲.۲.۰ GET /model	
۱۸۲	۳.۲.۰ POST /explain	
۱۸۲	۳.۰ خلاصه‌ی مشخصات OpenAPI	
۱۸۳	جداول تفصیلی جستجوی ابرپارامتر و حذف اجزا	ژ
۱۸۳	۱.۰ شبکه‌ی ابرپارامتر Random Forest	
۱۸۵	۲.۰ شبکه‌ی ابرپارامتر XGBoost	
۱۸۵	۳.۰ حذف اجزای ETHOS: نتایج کامل	
۱۸۵	۴.۰ حساسیت K-شات: جدول کامل	
۱۸۵	۵.۰ دوره‌های فدرال: معیارها به تفکیک دور	
۱۸۵	۶.۰ چندبیماری: نتایج کامل همه‌ی گره‌ها	

س خلاصه‌ی معادلات کلیدی ۱۸۷

۱۸۷	س.۱ پیش‌پردازش داده
۱۸۷	س.۲ توکن علائم
۱۸۷	س.۳ شبکه‌های نمونه‌اولیه‌ای
۱۸۸	س.۴ زیان کانونی
۱۸۸	س.۵ FedAvg
۱۸۸	س.۶ معیارها
۱۸۸	س.۷ ویژگی‌های مهندسی‌شده
۱۸۹	س.۸ خودتوجه

ش فهرست اختصارات ۱۹۰

ص مرور ادبیات تفصیلی ۱۹۲

۱۹۲	ص.۱ یادگیری کم‌نمونه: مقالات کلیدی
۱۹۲	ص.۲ یادگیری فدرال: کاربردهای مراقبت سلامت
۱۹۳	ص.۳ پیش‌بینی بالینی: نتایج معیار
۱۹۳	ص.۴ جزئیات معماری Transformer
۱۹۳	ص.۵ جزئیات پروتکل ارزیابی
۱۹۴	ص.۶ مقایسه با کارهای پیشین MIMIC-III

ض ارزیابی تفصیلی و تحلیل حساسیت ۱۹۵

۱۹۵	ض.۱ معیارهای تفصیلی به‌تفکیک بیماری
۱۹۶	ض.۲ شبکه‌ی حساسیت ابرپارامتر
۱۹۶	ض.۳ تحلیل منحنی یادگیری
۱۹۶	ض.۴ کالیبراسیون به‌تفکیک مدل
۱۹۶	ض.۵ تقسیم‌های ارزیابی جایگزین
۱۹۶	ض.۶ پایداری اهمیت ویژگی
۱۹۷	ض.۷ نتایج تفصیلی V5 و V6
۱۹۷	ض.۸ تحلیل به‌تفکیک بذر برای V5

۱۹۸	ض.۹ تحلیل به تفکیک معماری برای V6
۱۹۸	ض.۱۰ تحلیل پیش‌بینی مطابق (V6)
۱۹۹	ض.۱۱ خلاصه‌ی بهبود تدریجی

ط استنتاج‌ها و اثبات‌های ریاضی ۲۰۰

۲۰۰	ط.۱ گرادیان تابع زیان نمونه‌اولیه‌ای
۲۰۰	ط.۲ فرمول‌بندی زیان کانونی
۲۰۱	ط.۳ آزمون DeLong برای مقایسه‌ی ROC
۲۰۱	ط.۴ بازه‌های اطمینان bootstrap
۲۰۱	ط.۵ استنتاج پراکسی SOFA
۲۰۲	ط.۶ شاخص شوک

چکیده انگلیسی ۲۱۳

فهرست جداول

۱۰	۱.۱ تطبیق اجزای پروپوزال با اجرای نهایی پایان‌نامه
۳۱	۱.۲ ETHOS در برابر رمزگذار ترنسفورمر عمومی
۳۳	۲.۲ مقایسه کارهای پیشین در پیش‌بینی بالینی
۳۹	۳.۲ مجموعه‌های داده بنچمارک ML بالینی
۴۳	۱.۳ خلاصه نمادگذاری
۴۵	۲.۳ آمار جمعیت‌شناختی کوهورت MIMIC-IV
۴۶	۳.۳ بازه‌های آزمایشگاهی منتخب (۱۵ آزمایش)
۴۶	۴.۳ بازه‌های علائم حیاتی منتخب (۷ علامت حیاتی)
۴۸	۵.۳ خلاصه‌ی بردار ویژگی 25-بعدی
۵۵	۶.۳ افراز گره‌ی فدرال (مجموعه‌ی آموزش)

۱.۴	۷۱	فرضیات آزمایش و پیامدهای مورد انتظار
۱.۵	۸۱	فرایند جدولی SOTA؛ بهترین پیکربندی آزمون (فاز ۴)
۲.۵	۸۲	بهترین اجرای کم‌نمونه و انباشتی در مجموعه آزمون
۳.۵	۸۴	آزمایش ۱: مقایسه مدل اصلی در مجموعه آزمون
۴.۵	۸۴	آزمایش ۲: حساسیت K-شات در پروتکل اپیزودیک
۵.۵	۸۴	آزمایش ۳: آموزش فدرال در برابر آموزش متمرکز
۶.۵	۸۵	جریان ارتباطی FedAvg ($T = 20$ دور، ۵ گره)
۷.۵	۸۶	آزمایش ۴: مطالعه حذف تدریجی اجزای مدل
۸.۵	۸۷	آزمایش ۵: تعمیم بین‌بیماری (AUROC به تفکیک گره آزمون)
۹.۵	۸۷	مقایسه گسترده مدل‌ها؛ معیارهای نماینده آزمون (همگام با خروجی‌های مخزن)
۱۰.۵	۸۸	مدل‌های منتخب با بازه‌های مستند؛ سطر RF در Exp1 برآورد نقطه‌ای از تقسیم ثابت است
۱۱.۵	۸۹	خلاصه یافته‌های کلیدی (مجموعه آزمون، همگام‌شده)
۱۲.۵	۹۰	تفسیر بالینی ویژگی‌های برتر (جنگل تصادفی)
۱۳.۵	۹۳	معیارها به تفکیک بیماری (RF در برابر مدل پیشنهادی کم‌نمونه)
۱۴.۵	۹۵	تحلیل اولیه تقویت معماری برای ETHOS و یادگیری کم‌نمونه (روایت تاریخی توسعه، فقط نمونه اولیه)
۱۵.۵	۱۰۲	راهنمای آموزش بهبودیافته در کمپین تاریخی V0-V6؛ همه‌ی مدل‌ها روی همان مجموعه آزمون
۱۶	۱۰۷	گردش استخراج و پردازش داده MIMIC-IV
۲۶	۱۰۸	جمعیت‌شناسی گسترده کوهورت
۳۶	۱۰۸	نمونه‌هایی از کدهای ICD-10 به تفکیک گره بیماری
۴۶	۱۰۸	توزیع بیماران به تفکیک گره بیماری
۵۶	۱۱۴	نرخ فقدان به تفکیک دسته ویژگی (۲۴ ساعت اول)
۱.۷	۱۲۳	راهنمای انتخاب مدل
۲.۷	۱۲۸	مقایسه با نتایج پیشین ترخیص/پیامد
۳.۷	۱۳۲	عملکرد یادگیری کم‌نمونه در حوزه‌های مختلف
۴.۷	۱۳۷	مقایسه با کار پیشین
۵.۷	۱۳۹	نقشه‌راه کار آینده

۱۴۴	خلاصه مشارکت‌ها	۱.۸
۱۴۶	خلاصه پاسخ به پرسش‌های پژوهشی	۲.۸
۱۴۷	پیکربندی رمزگذار ETHOS	۱.آ
۱۴۸	پیکربندی Few-Shot	۲.آ
۱۴۸	پیکربندی فدرال	۳.آ
۱۴۸	ابزارهای Random Forest با تنظیم آستانه	۴.آ
۱۵۶	سقف مدل‌های جدولی: مدل‌های تکی در مجموعه‌ی آزمون	۱.ت
۱۵۶	مدل‌های تجمیعی در مجموعه‌ی آزمون	۲.ت
۱۵۷	شناسه‌های آیتم آزمایشگاه MIMIC-IV	۳.ت
۱۵۸	شناسه‌های آیتم علائم حیاتی MIMIC-IV	۴.ت
۱۶۴	نمای کلی گانت پروژه	۱.ج
۱۶۵	مدیریت ریسک پروژه	۲.ج
۱۶۹	واژه‌نامه (واژه‌های منتخب)	۱.چ
۱۷۰	تهدیدهای اعتبار و کاهش اثر	۱.ح
۱۷۲	چک‌لیست تکرارپذیری	۱.خ
۱۷۵	آزمایش ۱: مقایسه مدل‌های اصلی (خروجی خودکار مخزن)	۱.د
۱۷۵	آزمایش ۲: حساسیت K-shot (خروجی خودکار مخزن)	۲.د
۱۷۶	آزمایش ۳: فدرال در برابر متمرکز (خروجی خودکار مخزن)	۳.د
۱۷۶	آزمایش ۴: مطالعه حذف تدریجی (خروجی خودکار مخزن)	۴.د
۱۷۶	آزمایش ۵: تعمیم بین‌بیماری (خروجی خودکار مخزن)	۵.د
۱۷۷	ملاحظات اخلاقی	۱.ذ
۱۸۰	SWOT: یادگیری ماشین جدولی در برابر یادگیری عمیق	۱.ر
۱۸۲	خلاصه‌ی نقاط پایانی رابط برنامه‌نویسی کاربردی	۱.ز

۱۸۳	شبکه‌ی RandomizedSearchCV برای Random Forest	۱.۸۳
۱۸۴	شبکه‌ی RandomizedSearchCV برای XGBoost	۲.۸۴
۱۸۴	مطالعه حذف اجزا (همگام با خروجی فعلی مخزن)	۳.۸۴
۱۸۵	حساسیت K-شات (همه‌ی مقادیر آزموده شده)	۴.۱۸۵
۱۸۵	آموزش فدرال: AUROC اعتبارسنجی به تفکیک دور (نمونه)	۵.۱۸۵
۱۸۶	تعمیم بین بیماری (همه‌ی گره‌ها)	۶.۱۸۶
۱۹۱	اختصارات به کاررفته در این پایان نامه	۱.۹۱
۱۹۲	مقالات کلیدی یادگیری کم نمونه	۱.۹۲
۱۹۵	معیارها به تفکیک بیماری (RF در برابر مدل پیشنهادی کم نمونه)	۱.۹۵
۱۹۷	معیارهای تفصیلی V5 و V6 در مجموعه آزمون	۲.۱۹۷
۱۹۸	AUROC به تفکیک بذر V5 در تجمیع پنج بذری	۳.۱۹۸
۱۹۸	AUROC به تفکیک معماری V6 (۲ بذر برای هر کدام)	۴.۱۹۸
۱۹۹	بهبود تدریجی کامل: V0 تا V6	۵.۱۹۹

فهرست تصاویر

۴۴	فرایند انتها به انتها: استخراج داده، بازنمایی دوگانه (جدولی و مبتنی بر توکن)، و شاخه‌های مدل	۱.۴۴
۸۱	منحنی‌های ROC: مدل‌های کلاسیک، ETHOS، و اجرای انباشتی کم نمونه (AUROC دقیق در جداول)	۱.۸۱
۸۲	منحنی‌های دقت-بازخوانی در مجموعه آزمون برای Random Forest و ETHOS	۲.۸۲
	منحنی‌های یادگیری: AUROC در برابر اندازه آموزش برای RF و خط پایه ETHOS با یادگیری کم نمونه	۳.۵
۸۳	(V0). بهبودهای V4 و V5 در بازه ۰.۷۴-۰.۷۱ نمایش داده نشده‌اند	۳.۸۳
۸۵	حساسیت K-شات: AUROC در برابر K با باندهای بازه اطمینان ۹۵ درصد	۴.۸۵
۸۵	همگرایی فدرال: AUROC اعتبارسنجی در برابر دور	۵.۸۵
۸۶	مطالعه حذف تدریجی به صورت رادار: سهم هر جزء	۶.۸۶

۷.۵	مقایسه اصلی مدل‌ها: AUROC در برابر همهی خطوط پایه و مدل‌های پیشنهادی.	۸۸
۸.۵	اهمیت ویژگی (جنگل تصادفی). کراتینین، گلوکز، هموگلوبین بالاترین رتبه را دارند.	۹۰
۹.۵	آبشار SHAP برای یک بیمار برتر (جنگل تصادفی). سهم ویژگی‌ها در پیش‌بینی.	۹۱
۱۰.۵	منحنی‌های کالیبراسیون: احتمال پیش‌بینی‌شده در برابر فراوانی مشاهده‌شده. RF نسبتاً خوب کالیبره است؛	
۹۱	ETHOS گرایش به بیش‌اعتمادی دارد.	
۱۶	طرح استخراج MIMIC-IV: جدول‌های منبع، کلیدهای اتصال، و پیش‌پردازش به بازنمایی‌های جدولی و	
۱۰۶	توکنی (نمودار برداری؛ تک‌رنگ برای چاپ).	
۲۶	ماتریس همبستگی پیرسون برای آزمایشگاه‌ها و علائم حیاتی (ساختار گویای کوهورت آموزش).	۱۰۹
۳۶	پراکسی SOFA در برابر کراتینین (نرمال‌شده) به تفکیک برچسب امکان‌پذیری؛ SOFA و کراتینین بالاتر با	
۱۱۰	ترخیص ناممکن همراه‌اند.	
۴۶	AUROC آزمون لایه‌بندی‌شده بر سن: Random Forest، انباشت V4، و خط پایه ETHOS با یادگیری	
۱۱۱	کم‌نمونه.	
۵۶	نرخ خطای طبقه‌بندی به تفکیک بازه کراتینین (RF در برابر ETHOS) با شمار بیماران.	۱۱۱
۶۶	t-SNE بردارهای نهفته ETHOS (بیماران آزمون): هم‌پوشانی جزئی کلاس‌های ممکن در برابر ناممکن.	۱۱۲
۷۶	شماتیک مجموعه‌های پشتیبان، نمونه‌های کلاس، و طبقه‌بندی پرس‌وجو در فضای نهفته (پیش‌نمایش دوبعدی).	۱۱۳
۸۶	نمونه مسیر ۲۴ ساعت اول ICU: ضربان قلب، فشار خون، و کراتینین (گویای).	۱۱۳
۱.ج	فازهای کار آینده (۱ تا ۵ سال)	۱۶۴

چکیده

پیش‌بینی امکان‌پذیری درمان بر پایه داده بالینی محدود و حساس، یکی از مسائل مهم در پشتیبانی تصمیم فردمحور است. در این پژوهش، امکان‌پذیری درمان به صورت عملیاتی به معنای پیش‌بینی یک پیامد بالینی قابل اندازه‌گیری بر اساس سیگنال‌های اولیه بیمار در ICU تعریف می‌شود. این مفهوم به معنای توصیه مستقیم درمان، نسخه‌نویسی خودکار یا جایگزینی تصمیم پزشک نیست. در این پایان‌نامه، چارچوبی ترکیبی بررسی می‌شود که از چند جزء اصلی تشکیل شده است: توکن‌های علائم (Symptom Tokens) برای بازنمایی فشرده آزمایش‌ها و علائم حیاتی، رمزگذار ETHOS، یادگیری کم‌نمونه و آموزش فدرال. آزمایش‌ها روی نمونه ۲,۰۰۰ بیمار از MIMIC-IV v3.1 و پنج گره بیماری شامل سپسیس، بیماری‌های قلبی، تنفسی، کلیوی و دیابت انجام شده است.

برای تعیین مرجع عملکرد، ابتدا یک مدل جدولی قوی گزارش می‌شود. فرایند SOTA جدولی در مجموعه آزمون به **AUROC برابر ۰.۷۴۸**، **F1 برابر ۰.۶۷۴** و دقت ۰.۷۰۰ می‌رسد. بهترین اجرای ترکیبی یادگیری کم‌نمونه با انباشت **AUROC برابر ۰.۷۴۶** با بازه اطمینان بوت‌استرپ ۹۵٪ [۰.۶۹۹, ۰.۷۹۷] دارد؛ بنابراین از نظر توصیفی به سقف جدولی بسیار نزدیک است. در مقابل، زیرمدل کم‌نمونه به تنهایی AUROC برابر ۰.۶۷۰ به دست می‌آورد. در آزمایش جداگانه Exp1 نیز مدل پیشنهادی کم‌نمونه به **۰.۶۱۱** و Random Forest به **۰.۷۶۲** می‌رسند؛ از این رو نتایج اپیزودیک، نتایج Exp1 و نتایج انباشتی نباید به جای یکدیگر تفسیر شوند. شکاف آموزش فدرال نسبت به آموزش متمرکز نیز حدود **۰.۰۰۵** واحد AUROC است.

اجزای اصلی روش شامل سازگاری به سبک Proto-MAML، تقطیر دانش از معلم Random Forest، پیش‌آموزش Contrastive نظارت‌شده، ویژگی‌های جدولی مهندسی‌شده، توجه درگاهی به ویژگی، نمونه‌های Cross-Attention و یک فرا یادگیر انباشتی است که پیش‌بینی‌های کم‌نمونه و مدل‌های کلاسیک را با هم ترکیب می‌کند.

مشارکت‌های این پایان‌نامه عبارت‌اند از: (۱) ارائه بنچمارکی بازتولیدپذیر برای امکان‌پذیری درمان بر MIMIC-IV با سلسله‌مراتب شفاف گزارش نتایج؛ (۲) استفاده از Symptom Tokens همراه با ETHOS برای یادگیری کم‌نمونه؛ (۳) نشان دادن اینکه مدل کم‌نمونه خام جایگزین مستقیم مدل‌های جدولی قوی نیست، اما

انباشت می‌تواند فاصله تا سقف جدولی را به‌طور چشمگیر کاهش دهد؛ و (۴) فراهم کردن کد و جداول خروجی برای بازتولید نتایج. محدودیت‌های اصلی شامل تک‌مرکزی بودن MIMIC-IV، اندازه نمونه ۲,۰۰۰ بیمار، برچسب جانشین برای پیامد بالینی و نبود اعتبارسنجی خارجی است.

کلیدواژه‌ها: امکان‌پذیری درمان؛ یادگیری کم‌نمونه؛ یادگیری فدرال؛ MIMIC-IV؛ Symptom Tokens؛ ETHOS؛ یادگیری ماشین بالینی.

مقدمه

رشد سریع سامانه‌های هوشمند در سلامت، امکان تحلیل حجم بزرگی از داده‌های بالینی را فراهم کرده است؛ اما در عمل، داده‌ی سلامت همواره کامل، آزاد و قابل تجمیع نیست. پرونده‌های الکترونیک سلامت، داده‌های آزمایشگاهی و علائم حیاتی بیماران در مراکز مختلف با قالب‌های ناهمگون ثبت می‌شوند و به دلیل ملاحظات حریم خصوصی، دسترسی مستقیم به آن‌ها محدود است. بنابراین مسئله‌ی اصلی این پژوهش از یک نیاز عملی شکل می‌گیرد: چگونه می‌توان از داده‌ی محدود و حساس، مدلی ساخت که برای پشتیبانی تصمیم بالینی قابل استفاده و در عین حال از نظر حریم خصوصی قابل دفاع باشد؟

این پایان‌نامه بر پیش‌بینی امکان‌پذیری درمان/ترخیص در بیماران بستری در بخش مراقبت‌های ویژه تمرکز دارد. ایده‌ی محوری آن ترکیب چند رویکرد است: مدل‌های جدولی کلاسیک برای تعیین سقف عملکرد، بازنمایی توکنی علائم برای استانداردسازی داده‌های ناهمگون، یادگیری کم‌نمونه برای سناریوهای کم‌داده، و یادگیری فدرال برای شبیه‌سازی وضعیتی که داده‌ی خام میان مراکز جابه‌جا نمی‌شود. نتایج نشان می‌دهد که یادگیری کم‌نمونه خام به‌تنهایی برای داده‌ی جدولی بالینی کافی نیست، اما وقتی با بازنمایی مناسب و مدل‌های کلاسیک در یک خط لوله‌ی ترکیبی ادغام می‌شود، می‌تواند به سقف عملکرد جدولی نزدیک شود.

ساختار پایان‌نامه به‌گونه‌ای تنظیم شده است که ابتدا مسئله، انگیزه و پرسش‌های پژوهش روشن شود؛ سپس پیشینه‌ی علمی، روش‌شناسی، طراحی آزمایش‌ها و نتایج تجربی ارائه گردد. در ادامه، تحلیل داده، بحث درباره‌ی محدودیت‌ها و نتیجه‌گیری نهایی آورده می‌شود. پیوست‌ها نیز جزئیات فنی، جداول کامل، قطعه‌کدها و مستندات تکمیلی را برای بازتولید نتایج فراهم می‌کنند.

فصل ۱

کلیات تحقیق

۱.۱ بستر بالینی

۱.۱.۱ محیط بخش مراقبت ویژه و تصمیم‌گیری

بخش مراقبت‌های ویژه (ICU) محیطی پرخطر و زمان‌حساس است؛ جایی که تصمیم‌های بالینی باید با اتکا به داده‌های ناقص اما پیوسته به‌روز گرفته شوند. بیماران این بخش معمولاً وضعیت ناپایدارتری دارند و تحت پایش مداوم علائم حیاتی، آزمایش‌های مکرر و مراقبت تیم‌های چندرشته‌ای قرار می‌گیرند. تصمیم‌هایی که در ۲۴ تا ۴۸ ساعت نخست بستری گرفته می‌شود، اغلب مسیر کل بستری را تعیین می‌کند؛ از تحرک‌دهی زودهنگام و جداسازی از ونتیلاسیون مکانیکی تا برنامه‌ریزی ترخیص، همگی به برآورد دقیق پایداری بالینی و ظرفیت بهبود بیمار وابسته‌اند.

۲.۱.۱ گردش کار بالینی و نقاط تصمیم

گردش کار معمول ICU را می‌توان در چهار گام خلاصه کرد: (۱) پذیرش و ارزیابی اولیه؛ (۲) تثبیت وضعیت در ۲۴ تا ۴۸ ساعت نخست؛ (۳) پایش و درمان مداوم؛ و (۴) برنامه‌ریزی ترخیص. ارزیابی امکان‌پذیری درمان معمولاً در مرحله تثبیت انجام می‌شود، زمانی که نخستین روندهای آزمایشگاهی و علائم حیاتی در دسترس قرار گرفته‌اند. بالین‌گران در این مرحله چند جریان داده را کنار هم می‌گذارند: پانل‌های آزمایشگاهی مانند کراتینین، لاکتات و گلوکز؛ علائم حیاتی مانند ضربان قلب، فشار خون و SpO_2 ؛ و یادداشت‌های بالینی. مدلی که بتواند این داده‌ها را به‌صورت منسجم ترکیب کند، می‌تواند بیمارانی را که شانس ترخیص ایمن زودهنگام دارند زودتر شناسایی کند و

برنامه‌ریزی ترخیص را دقیق‌تر سازد.

۳.۱.۱ برنامه‌ریزی ترخیص و امکان‌پذیری درمان

برنامه‌ریزی ترخیص از آغاز بستری در ICU آغاز می‌شود. بالین‌گران باید به‌طور مداوم ارزیابی کنند که آیا بیمار می‌تواند به‌صورت ایمن به منزل، توان‌بخشی یا مرکز دیگری ترخیص شود. این ارزیابی (امکان‌پذیری درمان)، روندهای آزمایشگاهی (مثلاً بهبود کراتینین در نارسایی کلیوی)، پایداری علائم حیاتی (مثلاً جداسازی از وازوپرسورها)، وضعیت عملکردی و عوامل اجتماعی تعیین‌کننده‌ی سلامت را یکپارچه می‌کند. ترخیص زودهنگام خطر بستری مجدد را افزایش می‌دهد؛ تأخیر در ترخیص ظرفیت ICU را تحت فشار قرار می‌دهد و هزینه‌ها را بالا می‌برد.

در این پژوهش، قابلیت/ امکان‌پذیری درمان به‌صورت عملیاتی به معنای پیش‌بینی یک پیامد بالینی قابل‌اندازه‌گیری بر اساس سیگنال‌های اولیه بیمار در ICU تعریف می‌شود. این مفهوم به معنای توصیه مستقیم درمان، نسخه‌نویسی خودکار یا جایگزینی تصمیم پزشک نیست. بنابراین خروجی مدل، در بهترین حالت، یک نشانه‌ی کمی برای پشتیبانی تصمیم و اولویت‌بندی بررسی بالینی است، نه دستور درمان. مراقبت‌های بهداشتی مدرن به‌طور فزاینده‌ای به داده‌های تجمیع‌شده (پایگاه‌های داده‌ی بیمارستانی، پرونده‌های ICU، دستگاه‌های پوشیدنی و گزارش علائم از منابع متعدد) برای پشتیبانی از پیش‌بینی سلامت فردی تکیه دارد. امکان‌پذیری درمان، که در این پایان‌نامه به‌صورت ارزیابی دودویی دستیابی به ترخیص ایمن در بازه‌ی زمانی معقول و نبود بستری مجدد عملیاتی شده است، نقطه‌ی تصمیم‌گیری است. مدل‌های یادگیری ماشین که امکان‌پذیری را از داده‌های اولیه‌ی ICU پیش‌بینی کنند می‌توانند به بالین‌گران در برنامه‌ریزی ترخیص کمک کنند، به شرط آنکه دقیق، قابل‌تفسیر، محدودیت‌مند و در شرایط واقعی اعتبارسنجی شده باشند.

۲.۱ تحول دیجیتال در سلامت

نظام سلامت در سال‌های اخیر دگرگونی دیجیتال گسترده‌ای را تجربه کرده است. گسترش پرونده‌ی الکترونیک سلامت (EHR)، ابزارهای پوشیدنی پایش سلامت، پزشکی از راه دور و استانداردهای تبادل داده مانند HL7 FHIR باعث شده حجم و تنوع داده‌های بالینی به‌طور چشمگیری افزایش یابد. پیش‌بینی‌ها نشان می‌دهند بازار جهانی سلامت دیجیتال تا سال ۲۰۲۸ از ۵۰۰ میلیارد دلار فراتر خواهد رفت؛ رشدی که نشان‌دهنده اهمیت روزافزون سامانه‌های پشتیبان تصمیم مبتنی بر داده است. این تحول، هم فرصت‌های تازه‌ای برای یادگیری ماشین ایجاد می‌کند و هم چالش‌های جدی درباره کیفیت، حریم خصوصی و قابلیت تعمیم داده‌ها پیش می‌کشد.

۱.۲.۱ از سیلوهای داده تا هوش تجمیعی

از نظر تاریخی، داده‌های بالینی در سیلوهای نهادی قرار داشت؛ هر بیمارستان سامانه‌ی EHR خود را با طرحواره‌های اختصاصی، قراردادهای کدگذاری و کنترل‌های دسترسی نگه می‌داشت. ظهور تبادلات اطلاعات سلامت (HIE) و شبکه‌های داده‌ی فدرال شروع به شکستن این موانع کرده است و پژوهش چندنهادی را بدون متمرکزسازی کامل داده ممکن می‌سازد. ابتکارهایی مانند PCORnet, OHDSI (Observational Health Data Sciences and Informatics) و برنامه‌ی UK NHS Digital پتانسیل هوش بالینی تجمیعی را نشان می‌دهند. با این حال، این شبکه‌ها با چالش‌های پایدار روبه‌رو هستند: قالب‌های ناهمگون داده، کیفیت متغیر داده، امتناع نهادی از اشتراک پرونده‌های حساس و محدودیت‌های مقرراتی که در حوزه‌های قضایی مختلف متفاوت است.

این پایان نامه در همین بستر تعریف می‌شود. ایده‌ی اصلی آن است که یادگیری فدرال با سازگاری کم نمونه ترکیب شود تا مدل بتواند از داده‌های بالینی توزیع شده بیاموزد، بدون آنکه داده‌های خام در یک مرکز تجمع شوند. بازنمایی توکن‌های علائم نیز نقش یک لایه‌ی میانی استاندارد را دارد؛ یعنی داده‌های ناهمگون را به قالبی تبدیل می‌کند که برای مدل قابل استفاده باشد و در عین حال وابستگی مستقیم به قالب خام هر نهاد را کاهش دهد.

۲.۲.۱ وعده و خطر هوش مصنوعی بالینی

هوش مصنوعی در مراقبت‌های بهداشتی در حوزه‌های مشخص نتایج چشمگیر به دست آورده است: رادیولوژی (مثلاً غربالگری رتینوپاتی دیابتی)، پاتولوژی (مثلاً تشخیص تومور) و پردازش زبان طبیعی (مثلاً خلاصه‌سازی یادداشت بالینی). با این حال، انتقال پژوهش AI به عمل بالینی کند مانده است. موانع کلیدی عبارت‌اند از: (۱) شکاف‌های اعتبارسنجی؛ مدل‌های آموزش دیده بر داده‌ی گذشته‌نگر ممکن است به استقرار آینده‌نگر تعمیم نیابند؛ (۲) عدم قطعیت مقرراتی؛ چارچوب در حال تکامل FDA برای نرم‌افزار به عنوان دستگاه پزشکی (SaMD) ابهام ایجاد می‌کند؛ (۳) اعتماد بالین‌گر؛ مدل‌های مبهم با مقاومت پزشکانی روبه‌رو می‌شوند که مسئولیت پیامدهای بیمار را بر عهده دارند؛ و (۴) دسترسی به داده؛ مقررات حریم خصوصی داده‌ی موجود برای توسعه‌ی مدل را محدود می‌کند. این پایان نامه به‌طور مستقیم به دو مانع مهم می‌پردازد: محدودیت دسترسی به داده از طریق یادگیری فدرال، و شکاف اعتبارسنجی از طریق طراحی آزمایش و گزارش دقیق. نتیجه‌ی منفی اولیه، یعنی عملکرد ضعیف‌تر مدل کم‌نمونه نسبت به مدل‌های کلاسیک، پنهان نشده است؛ بلکه به عنوان نقطه‌ی شروع تحلیل مطرح می‌شود. سپس با چند دور بهبود مهندسی و مدل‌سازی، فاصله با سقف جدولی کاهش می‌یابد. این رویکرد با روح ارزیابی مسئولانه AI در سلامت سازگار است، زیرا اعتماد بالینی زمانی شکل می‌گیرد که هم موفقیت‌ها و هم محدودیت‌ها شفاف گزارش شوند.

۳.۲.۱ امکان‌پذیری درمان در عصر مراقبت مبتنی بر ارزش

گذار از مدل کارمزد به‌ازای خدمت به مدل‌های مراقبت مبتنی بر ارزش، برنامه‌ریزی ترخیص را به اولویت مالی و بالینی تبدیل کرده است. در برنامه‌های پرداخت تجمیعی (مثلاً CMS Bundled Payments for Care Improvement)، بیمارستان‌ها مسئولیت مالی بستری مجدد در ۳۰ روز را بر عهده دارند. پیش‌بینی دقیق امکان‌پذیری درمان (اینکه آیا بیمار می‌تواند در بازه‌ی زمانی بالینی مناسب به ترخیص ایمن دست یابد) مستقیماً بر تخصیص منابع، مدیریت تخت و بازپرداخت اثر می‌گذارد. شناسایی زود هنگام بیمارانی که احتمال ترخیص ممکن را دارند، هماهنگی مراقبت پیشگیرانه را ممکن می‌سازد: ترتیب خدمات بهداشت خانگی، زمان‌بندی ارزیابی‌های توان‌بخشی و ارتباط با خانواده‌ها درباره‌ی جدول زمانی مورد انتظار.

بستر ICU به‌ویژه سرنوشت‌ساز است؛ هزینه‌ی هر روز بستری در ICU حدود ۳ تا ۵ برابر هزینه‌ی روز بستری در بخش عمومی است و ظرفیت ICU در اوج موج‌ها محدودیت الزام‌آور است (همان‌طور که در همه‌گیری COVID-19 نشان داده شد). ابزار پشتیبان تصمیم که زمان‌بندی ترخیص را حتی یک روز بهبود دهد می‌تواند صرفه‌جویی هزینه‌ی قابل توجه و جریان بهتر بیمار را به همراه داشته باشد.

۳.۱ انگیزه

انگیزه اصلی این کار از یک تجربه عملی شکل گرفت. هنگام کار با پلتفرم Mayo Clinic روشن شد که دسترسی به داده سلامت، حتی برای هدف‌های پژوهشی، بسیار محدود است: در بسیاری موارد تنها شناسه‌ها و کدها در دسترس‌اند و پرونده‌های بالینی زیربنایی قابل استفاده نیستند. این تجربه پرسش اصلی پایان‌نامه را برجسته کرد: اگر داده را نتوان متمرکز یا آزادانه مبادله کرد، چگونه می‌توان سامانه‌های پیش‌بین قابل اعتماد ساخت؟ پاسخ این پایان‌نامه بررسی ترکیب یادگیری فدرال، سازگاری کم‌نمونه و بازنمایی‌های فشرده مانند Symptom Tokens است.

بخش مراقبت ویژه (ICU) یکی از غنی‌ترین محیط‌های داده‌ای و در عین حال بحرانی‌ترین محیط‌های تصمیم در مراقبت‌های مدرن است. بالین‌گران باید به‌طور مداوم پایداری بیمار، پیامدها و مقصد مناسب ترخیص را بر اساس مشاهدات اولیه‌ی محدود ارزیابی کنند. امکان‌پذیری درمان (پرسش دودویی اینکه آیا بیمار می‌تواند به‌صورت ایمن به منزل، توان‌بخشی یا سایر بسترهای غیرحاد ترخیص شود) به مقادیر آزمایشگاهی، علائم حیاتی و مسیرهای بالینی مشاهده‌شده در ساعات نخست بستری ICU وابسته است.

علیرغم پیشرفت‌ها در EHR و یادگیری ماشین، چند چالش بنیادین پابرجاست. نخست، کمیابی داده: بسیاری از زیرگروه‌های بیماری نمونه‌های برجسب‌خورده‌ی اندک دارند و یادگیری نظارت‌شده‌ی استاندارد را دشوار می‌کند.

دوم، حریم خصوصی: داده‌ی بهداشتی به دلیل محدودیت‌های مقرراتی (مثلاً HIPAA، GDPR) را نمی‌توان بین نهادهای متمرکز کرد. سوم، بازنمایی: داده‌ی بالینی خام ناهمگون است (آزمایشگاه، علائم حیاتی، جمعیت‌شناسی) و برای مدل‌های پایین دست پیش‌پردازش دقیق می‌طلبد. چهارم، تعمیم: مدل‌های آموزش دیده بر یک گروه بیماری ممکن است به گروه‌های دیگر منتقل نشوند.

یادگیری کم نمونه [Vinyals et al., 2016, Snell et al., 2017] این امکان را فراهم می‌کند که مدل با تعداد کمی نمونه پشتیبان برای هر دسته، بیماران جدید را طبقه‌بندی کند. از سوی دیگر، یادگیری فدرال [McMahan et al., 2017] آموزش بر داده توزیع شده را بدون انتقال نمونه‌های خام ممکن می‌سازد. ترکیب این دو رویکرد می‌تواند مدلی ایجاد کند که از داده محدود بیاموزد، حریم خصوصی را حفظ کند و بین گروه‌های بیماری تعمیم یابد. این پایان‌نامه بررسی می‌کند که آیا چنین ترکیبی برای پیش‌بینی امکان‌پذیری درمان روی MIMIC-IV [Johnson et al., 2023] عملی و قابل دفاع است یا خیر.

۴.۱ بیان مسئله

پیش‌بینی امکان‌پذیری درمان را به عنوان وظیفه‌ی طبقه‌بندی دودویی صورت‌بندی می‌کنیم. با مشاهدات بالینی بیمار از ۲۴ ساعت نخست بستری در ICU، پیش‌بینی می‌کنیم که آیا بیمار به ترخیص ممکن دست خواهد یافت؛ تعریف شده به عنوان ترخیص به منزل، مراقبت خانگی یا توان بخشی ظرف ۳۰ روز از پذیرش ICU، بدون بستری مجدد ظرف ۳۰ روز. برچسب از سوابق ترخیص و بستری مجدد MIMIC-IV استخراج می‌شود.

به صورت رسمی، فضای بازنمایی بیماران را با $\mathcal{X}$ (مثلاً دنباله‌ی توکن‌های علائم یا بردارهای ویژگی جدولی) و برچسب دودویی را با $\mathcal{Y} = \{0, 1\}$ (۰ = غیرممکن، ۱ = ممکن) نشان می‌دهیم. تابعی $f: \mathcal{X} \rightarrow \mathcal{Y}$ می‌جوییم که خطای پیش‌بینی را بر مجموعه‌ی آزمون نگه‌داشته شده کمینه کند، با قید اینکه f ممکن است در بستر کم‌نمونه و فدرال آموزش داده شود.

چالش‌های کلیدی عبارت‌اند از:

۱. **بستر کم‌نمونه:** در زمان استنتاج ممکن است برای هر دسته فقط K نمونه برچسب‌خورده در اختیار باشد، برای مثال $K = 5$. مدل باید بتواند از این نمونه‌های پشتیبان به بیماران پرس‌وجوی جدید تعمیم دهد.

۲. **بستر فدرال:** داده آموزشی میان N گره، مانند گروه‌های بیماری، تقسیم شده است و داده خام از گره‌های محلی خارج نمی‌شود. بنابراین آموزش باید از طریق تجمیع فدرال انجام شود.

۳. **بازنمایی:** لازم است بازنمایی فشرده و معناداری از آزمایش‌ها و علائم حیاتی ساخته شود که هم برای مدل‌های کلاسیک و هم برای مدل‌های عصبی کم‌نمونه قابل استفاده باشد.

چرا کم‌نمونه؟ در استقرار دنیای واقعی، زیرگروه‌های بیماری جدید یا نهادهای ممکن است داده‌ی برچسب‌خورده‌ی محدود داشته باشند. یادگیری کم‌نمونه اجازه می‌دهد مدل تنها با K نمونه برای هر دسته سازگار شود و نیاز به مجموعه‌های حجیم حاشیه‌نویسی‌شده در هر سایت را کاهش دهد. این امر به‌ویژه برای بیماری‌های نادر یا شرایط نوظهور اهمیت دارد.

چرا فدرال؟ داده‌ی بهداشتی به دلیل مقررات حریم خصوصی (GDPR، HIPAA) را نمی‌توان متمرکز کرد. یادگیری فدرال مدل‌ها را بر داده‌ی توزیع‌شده بدون جابه‌جایی پرونده‌های خام آموزش می‌دهد و همکاری بین‌نهادی را با حفظ حاکمیت داده ممکن می‌سازد.

چرا Symptom Tokens؟ داده‌ی بالینی خام ناهمگون است: آزمایشگاه‌ها واحدهای مختلف دارند (mg/L، mmol/L، dL)، علائم حیاتی دامنه‌های متفاوت دارند و اندازه‌گیری‌ها به صورت نامنظم نمونه‌برداری می‌شوند. بازنمایی مبتنی بر توکن‌های علائم این را به دنباله‌ای استاندارد تبدیل می‌کند که رمزگذارهای transformer می‌توانند پردازش کنند. هر توکن هویت علامت، شدت (مقدار نرمال شده)، افسست زمانی و سنج (lab) در برابر (vital) را رمزگذاری می‌کند. این بازنمایی فشرده هم یادگیری اپیزودیک کم‌نمونه و هم مبانی جدولی کلاسیک را هنگام تخت‌کردن به بردار ویژگی پشتیبانی می‌کند.

۵.۱ شکاف پژوهشی

علیرغم پیشرفت چشمگیر در پیش‌بینی بالینی و یادگیری ماشین، شکاف آشکاری در تقاطع یادگیری کم‌نمونه، آموزش فدرال و داده‌ی بالینی جدولی وجود دارد. شکاف‌های مشخص زیر را که این پایان‌نامه را انگیزه می‌دهند، شناسایی می‌کنیم:

۱.۵.۱ شکاف ۱: یادگیری کم‌نمونه بر داده‌ی بالینی جدولی

اکثریت قاطع پژوهش یادگیری کم‌نمونه بینایی ماشین (Omniglot، CUB-200، miniImageNet) یا وظایف پردازش زبان طبیعی را هدف قرار می‌دهد. داده‌ی جدولی (سنجی غالب در پیش‌بینی بالینی مبتنی بر EHR) در بستر کم‌نمونه به شدت کم‌بررسی مانده است. برخلاف تصاویر، ویژگی‌های جدولی ساختار فضایی که سوگیری

القایی کانولوشنی بتواند از آن بهره برد ندارند. برخلاف متن، ویژگی‌های جدولی انواع و مقیاس‌های ناهمگونی دارند که در برابر توکن‌سازی استاندارد مقاومت می‌کنند. پرسش اینکه آیا متایادگیری مبتنی بر فاصله (شبکه‌های نمونه‌ای، prototypical networks) می‌تواند بازنمایی مؤثر از ویژگی‌های بالینی ناهمگون با نمونه‌های محدود بیاموزد، همچنان باز است. در چارچوب مرور ادبیات این پژوهش، این پایان‌نامه این پرسش را بر داده امکان‌پذیری درمان MIMIC-IV به صورت تجربی و با خطوط پایه جدولی قوی بررسی می‌کند.

۲.۵.۱ شکاف ۲: یادگیری فدرال کم‌نمونه برای مراقبت‌های بهداشتی

درحالی که یادگیری فدرال به مراقبت‌های بهداشتی اعمال شده (مثلاً FedHealth، FL-QSAR برای کشف دارو) و یادگیری کم‌نمونه به تصویربرداری پزشکی اعمال شده، ترکیب آموزش فدرال با متایادگیری کم‌نمونه بر داده‌ی بالینی ساختاریافته بررسی نشده است. این ترکیب از نظر عملی مهم است: سناریوهای استقرار واقعی اغلب هم کمیابی داده (نمونه‌های برچسب‌اندک در نهاد جدید) و هم قیود حریم خصوصی (عدم خروج داده از نهاد) را شامل می‌شوند. این پایان‌نامه بررسی می‌کند که آیا این دو پارادایم را می‌توان بدون افت فاجعه بار عملکرد به طور مؤثر ترکیب کرد.

۳.۵.۱ شکاف ۳: ارزیابی صادقانه‌ی روش‌های عصبی بر مجموعه داده‌های

بالینی کوچک

سوگیری انتشار در یادگیری ماشین معمولاً به سود نتایج مثبت عمل می‌کند. بسیاری از مقالات ML بالینی فقط مقایسه‌های مطلوب را گزارش می‌کنند و شرایطی را که در آن روش‌های ساده‌تر برتری دارند کنار می‌گذارند. به همین دلیل، ارزیابی دقیق و صادقانه باید هم نتایج منفی اولیه و هم مسیر بهبود را نشان دهد [Makel et al., 2012]. این پایان‌نامه با تعیین سقف جدولی قوی (SOTA با AUROC ۰.۷۴۸ در اجرای منجمد)، گزارش شکاف Exp1 (مدل پیشنهادی کم‌نمونه با ۰.۶۱۱ در برابر RF با ۰.۷۶۲ روی همان تقسیم)، تحلیل دلیل عقب‌ماندن کم‌نمونه، و مستندسازی بهترین اجرای انباشته (۰.۷۴۶ در برابر ۰.۷۴۸) این شکاف گزارش‌دهی را تا حد زیادی پوشش می‌دهد. کمپین توسعه V1-V6 نیز در فصل ۵ به عنوان سابقه تاریخی تکامل روش آمده است.

۴.۵.۱ شکاف ۴: بازنمایی‌های بالینی مبتنی بر توکن‌های علائم

کار موجود بر transformerهای بالینی (ClinicalBERT، Med-BERT، BEHRT) بر یادداشت‌های بالینی (متن آزاد) یا کدهای تشخیصی عمل می‌کند. اعمال معماری‌های transformer به اندازه‌گیری‌های بالینی کمی

(آزمایشگاه، علائم حیاتی) به پل بازنمایی نیاز دارد؛ یعنی تبدیل اندازه‌گیری‌های پیوسته و ناهمگون به دنباله‌ی توکن. طرح توکن‌های علائم در این پژوهش این شکاف را پوشش می‌دهد و نگاشت اصولی از اندازه‌گیری‌های بالینی به ورودی‌های سازگار با transformer فراهم می‌کند. اگرچه از نظر مفهومی به TabTransformer و FT-Transformer مرتبط است، رویکرد ما عناصر ویژه‌ی حوزه (هویت علامت، نرمال‌سازی بازه‌ی بالینی، رمزگذاری سنجه) را متناسب با بستر پیش‌بینی ICU دربرمی‌گیرد.

۶.۱ اصطلاحات و تعاریف

در سراسر متن از اصطلاحات زیر استفاده می‌کنیم: **امکان‌پذیری درمان** پیامد دودویی دستیابی بیمار به ترخیص ایمن به منزل، توان بخشی یا مراقبت خانگی ظرف ۳۰ روز بدون بستری مجدد را نشان می‌دهد. **Symp-tom Tokens** بازنمایی‌های فشرده‌ی اندازه‌گیری آزمایشگاهی و علائم حیاتی هستند که هرکدام شناسه‌ی علامت، شدت، زمان و سنجه را رمزگذاری می‌کنند. **یادگیری کم‌نمونه** به متیادگیری از K نمونه‌ی پشتیبان برای هر دسته اشاره دارد. **یادگیری فدرال** مدل‌ها را بر داده‌ی توزیع‌شده بدون متمرکزسازی نمونه‌های خام آموزش می‌دهد. **ETHOS** رمزگذار Efficient Transformer for Health Outcome prediction است [Sharafi and Aminian, 2023].

۷.۱ مرور کلی روش پژوهش

پژوهش ما از رویکرد علم طراحی پیروی می‌کند: یک چارچوب ترکیبی شامل ETHOS, Symptom Tokens, یادگیری کم‌نمونه و آموزش فدرال طراحی، پیاده‌سازی و به‌صورت تجربی ارزیابی می‌شود. برای تکرارپذیری، از کوهورت ۲,۰۰۰ بیمار MIMIC-IV با تقسیم‌های ثابت استفاده می‌کنیم. ارزیابی شامل پنج بخش است: (۱) مقایسه با مدل‌های کلاسیک مانند RF و XGBoost؛ (۲) حذف تدریجی اجزاء؛ (۳) تحلیل حساسیت برای K-shot و ابرپارامترها؛ (۴) مقایسه فدرال و متمرکز؛ و (۵) تعمیم بین بیماری‌ها. هم نتایج مثبت و هم نتایج منفی گزارش می‌شوند تا تصویر علمی کامل‌تری ارائه شود.

۸.۱ اهداف پژوهش و مفروضات

هدف اصلی این پایان‌نامه طراحی و ارزیابی چارچوبی پژوهشی برای پیش‌بینی امکان‌پذیری درمان از داده‌ی بالینی تجمیع‌شده و محدود است. چارچوب باید الگوهای مرتبط با پیامد ترخیص/درمان را بدون اتکا به جابه‌جایی مستقیم

داده‌ی خام بیمار بررسی کند. اهداف مشخص عبارت‌اند از: (۱) ارائه و ارزیابی مدلی مبتنی بر یادگیری کم‌نمونه برای پیش‌بینی امکان‌پذیری درمان؛ (۲) استفاده از Symptom Tokens به‌عنوان واحدهای استاندارد داده برای یادگیری مؤثر؛ (۳) ترکیب معماری ETHOS با اصول یادگیری کم‌نمونه و فدرال برای سنجش سودمندی آن در محیط‌های چندمنبعه؛ و (۴) فراهم‌کردن بستری پژوهشی برای تحلیل سلامت فردی با کاهش نیاز به تمرکز داده‌ی خام.

بر اساس ادبیات و چارچوب نظری، مفروضات آزمون‌پذیر زیر مطرح می‌شوند: (۱) مدل‌های کم‌نمونه ممکن است در شرایط داده‌ی محدود به پیش‌بینی امکان‌پذیری درمان کمک کنند، اما باید با خطوط پایه‌ی جدولی قوی مقایسه شوند؛ (۲) یادگیری فدرال می‌تواند نیاز به انتقال داده‌ی خام را کاهش دهد، هرچند به‌تنهایی تضمین کامل حریم خصوصی نیست؛ (۳) ترکیب Symptom Tokens با معماری ETHOS ممکن است بازنمایی مفیدی فراهم کند؛ (۴) الگوهای پنهان پیامد درمان/ترخیص باید با تحلیل خطا و اهمیت ویژگی تفسیر شوند؛ و (۵) داده‌ی چندسنگه‌ای در مقایسه با داده‌ی تک‌سنگه‌ای می‌تواند اطلاعات بیشتری برای پیش‌بینی فراهم کند. نتایج فصل ۵ نشان می‌دهد برخی از این مفروضات تنها در حالت ترکیبی و انباشتی پشتیبانی می‌شوند، نه در مدل کم‌نمونه‌ی خام.

۱.۸.۱ تطبیق با پروپوزال اولیه

پروپوزال اولیه چارچوبی با چهار رکن اصلی پیشنهاد می‌کرد: یادگیری کم‌نمونه، یادگیری فدرال، رمزگذار ETHOS و بازنمایی Symptom Tokens برای پیش‌بینی قابلیت درمان از داده‌های بالینی تجمیع‌شده و محدود. پایان‌نامه حاضر همان مسیر اصلی را حفظ می‌کند، اما برای اینکه ارزیابی علمی قابل بازتولید و قابل دفاع باشد، دامنه‌ی اجرا را به کوهورت ناشناس‌شده و عمومی MIMIC-IV محدود می‌کند. به‌دلیل نبود دسترسی به داده‌ی واقعی چندمرکزی، جریان پوشیدنی و داده‌ی زنده در چارچوب زمانی این پژوهش کارشناسی ارشد، «داده‌ی چندمنبع» در این نسخه به‌صورت آزمایشگاه‌ها، علائم حیاتی، جمعیت‌شناسی و ویژگی‌های مهندسی‌شده از ICU عملیاتی شده است. بنابراین داده‌ی ابزارهای پوشیدنی، واسط کاربری تولیدی و استقرار چندسایتی واقعی در این پایان‌نامه پیاده‌سازی نشده‌اند و به‌عنوان مسیرهای آینده و الزامات استقرار واقعی مطرح می‌شوند.

۹.۱ پرسش‌های پژوهش

این پایان‌نامه به پرسش‌های پژوهشی زیر می‌پردازد:

۱. RQ1: آیا متایادگیری کم‌نمونه می‌تواند در پیش‌بینی امکان‌پذیری درمان از MIMIC-IV با مبانی

جدول ۱.۱: تطبیق اجزای پروپوزال با اجرای نهایی پایان نامه

جزء در پروپوزال	اجرای نهایی در پایان نامه	سطح پوشش	توضیح دامنه	نکته دفاعی
یادگیری کم نمونه	شبکه های نمونه اولیه، تحلیل K -شات، Proto-MAML و مسیرهای V1-V6	کامل	نتایج مثبت و محدودیت ها هر دو گزارش شده اند	ادعا نمی شود مدل خام از RF بهتر است
یادگیری فدرال	شبیه سازی FedAvg روی گره های بیماری	جزئی	داده ی خام در شبیه سازی جابه جا نمی شود؛ استقرار واقعی انجام نشده است	هزینه فدرال در این تنظیم حدود 0.005 AUROC است
ETHOS و Symptom Tokens	توکن سازی 15 آزمایشگاه، 7 علامت حیاتی و ویژگی های مهندسی شده، سپس رمزگذاری با ETHOS	کامل	بازنمایی پیشنهادی روی MIMIC-IV بازتولیدپذیر شده است	نقش آن بیشتر در مسیر ترکیبی/انباشتی دفاع پذیر است
داده ی تجمیع شده/چندسجه ای	آزمایشگاه، علائم حیاتی، جمعیت شناسی، گره بیماری و ویژگی های بالینی مشتق شده	جزئی	ابزار پوشیدنی و داده ی زنده در دسترس نبود؛ ادعای چندمنبع به ارشد است منابع درون EHR محدود است	این یک تصمیم دامنه بندی برای پژوهش کارشناسی
پیش بینی قابلیت درمان	پیامد جانشین ترخیص/بستری مجدد از MIMIC-IV	کامل با محدودیت	برچسب، جانشین عملیاتی است نه حقیقت کامل بالینی	مدل پشتیبان تصمیم است، نه نسخه نویس خودکار
مقایسه با روش های سنتی	LR، RF، XGBoost، CatBoost، LightGBM و مدل های عصبی	کامل	سقف جدولی برای تفسیر منصفانه گزارش شده است	مدل های کلاسیک روی داده ی جدولی بسیار قوی اند
واسط کاربری و نمایش نتایج	جداول، نمودارها، SHAP و گزارش های قابل بازتولید	آینده	واسط کاربری تولیدی ساخته نشده است	تمرکز پایان نامه اعتبار علمی مدل و نتایج تجربی است
ابزارهای پیشنهادی مانند Flutter/PySyft	پیاده سازی پژوهشی با PyTorch، Python، scikit-learn و سفارشی FedAvg	جایگزین موجه	انتخاب ابزارها بر اساس بازتولیدپذیری و دسترسی واقعی داده انجام شده است	ابزار عوض شده، پرسش پژوهش حفظ شده است

جدولی کلاسیک برابری کند یا از آن پیشی بگیرد؟

۲. **RQ2:** تعداد شات‌های پشتیبان K چگونه بر عملکرد کم‌نمونه اثر می‌گذارد؟ آیا K بهینه‌ای وجود دارد؟

۳. **RQ3:** هزینه عملکردی یادگیری فدرال در مقایسه با آموزش متمرکز چیست؟ آیا این هزینه ناچیز است؟

۴. **RQ4:** کدام اجزای معماری (توکن‌های علائم، وزن‌دهی شدت، افت زمانی و غیره) بیشترین سهم را در مدل پیشنهادی دارند؟

۵. **RQ5:** آیا مدل بین گروه‌های بیماری تعمیم می‌یابد؟ بر گره‌های دیده‌نشده (مثلاً کلیوی، دیابت) هنگام آموزش بر سایرین (سپسیس، قلبی، تنفسی) چگونه عمل می‌کند؟

به این پرسش‌ها به‌صورت تجربی با نمونه‌ی ۲,۰۰۰ بیمار از MIMIC-IV v3.1، با تقسیم‌های ثابت آموزش/اعتبارسنجی/آزمون و پروتکل‌های ارزیابی دقیق پاسخ می‌دهیم.

۱۰.۱ نوآوری‌ها و مشارکت‌ها

این پایان‌نامه مشارکت‌های زیر را دارد:

۱. **بررسی یکپارچه یادگیری کم‌نمونه، توکن‌سازی علائم و فدرال برای امکان‌پذیری**

درمان. در چارچوب مرور ادبیات این پژوهش، ترکیب توکن‌سازی علائم، متیادگیری نمونه‌ای و آموزش فدرال برای پیش‌بینی امکان‌پذیری درمان بر MIMIC-IV کمتر به‌صورت یکپارچه بررسی شده است. این مشارکت شکاف بین جامعه‌ی یادگیری کم‌نمونه (عمدتاً متمرکز بر بینایی و NLP) و جامعه‌ی انفورماتیک بالینی (عمدتاً متمرکز بر یادگیری نظارت‌شده‌ی متمرکز) را به‌صورت پژوهشی بررسی می‌کند. معماری به‌گونه‌ای ماژولار طراحی شده که رمزگذار، سر کم‌نمونه و پروتکل فدرال هرکدام به‌طور مستقل قابل جایگزینی‌اند و حذف اجزا و گسترش آینده را تسهیل می‌کنند.

۲. **Symptom Tokens به عنوان بازنمایی بالینی.** بازنمایی فشرده‌ی مبتنی بر توکن معرفی

می‌کنیم: ۱۵ مورد آزمایشگاهی و ۷ علامت حیاتی، نرمال‌شده به $[0, 1]$ ، تقویت‌شده با shock index، پراکسی SOFA و شمار آزمایشگاه‌های غیرطبیعی. هر توکن آرایه‌ی $[\text{symptom_id}, \text{intensity}, \text{time_delta}, \text{modality}]$ را رمزگذاری می‌کند. این بازنمایی هم رمزگذارهای سبک transformer و هم مدل‌های جدولی کلاسیک را پشتیبانی می‌کند. برخلاف رویکردهای پیشین توکن‌سازی بالینی

که بر یادداشت‌های متن آزاد یا کدهای تشخیصی عمل می‌کنند، طرح ما اندازه‌گیری‌های کمی را به واژگان گسسته‌ی توکن با مقادیر شدت پیوسته تبدیل می‌کند و هم هویت دسته‌ای و هم بزرگی عددی هر مشاهده‌ی بالینی را حفظ می‌کند.

۳. **سقف تجربی و بستن تدریجی شکاف.** سقف جدولی قوی، یعنی AUROC 0.748 در اجرای منجمد SOTA و 0.760 برای RF با آستانه تنظیم‌شده در جدول کمپین V، همراه با نقطه آغاز تاریخی کم‌نمونه (0.619) گزارش می‌شود. اجرای منجمد انباشته کم‌نمونه + کلاسیک در مخزن به 0.746 [$0.699, 0.797$] می‌رسد؛ یعنی فقط حدود 0.002 پایین‌تر از برآورد نقطه‌ای SOTA. بهترین بذر V5 (0.737) و انباشت V4 (0.732) نیز به عنوان نقاط عطف توسعه مستند شده‌اند.

۴. **معماری آماده‌ی فدرال با هزینه‌ی شبیه‌سازی‌شده‌ی کوچک.** در آزمایش گزارش‌شده‌ی فدرال در برابر متمرکز، شکاف AUROC حدود 0.005 است؛ آموزش حافظ حریم خصوصی در این شبیه‌سازی با هزینه‌ی کوچک عملی است. استقرار چندسایتی واقعی همچنان نیازمند اعتبارسنجی عملیاتی است.

۵. **حذف سیستماتیک اجزا و تحلیل حساسیت جامع.** به صورت سیستماتیک اجزا (توکن‌های علائم، وزن‌دهی شدت، افت زمانی، سر کم‌نمونه) را حذف می‌کنیم و $K \in \{1, 3, 5, 7, 10, 15, 20\}$ را تغییر می‌دهیم. جداول و تفاسیر مفصل برای کار آینده ارائه می‌دهیم. حذف اجزا نشان می‌دهد وزن‌دهی شدت بحرانی‌ترین جز است ($\Delta \text{AUROC} = -0.075$ هنگام حذف)، درحالی‌که سر کم‌نمونه را می‌توان با سر نظارت‌شده با افت کمینه جایگزین کرد ($\Delta \text{AUROC} = -0.009$). این الگو نشان می‌دهد پروتکل آموزش اپیزودیک محرک اصلی عملکرد نیست.

۶. **متایادگیر انباشته و آموزش پیشرفته.** انباشتگر کمپین V4 به AUROC 0.732 می‌رسد و پیکربندی منجمد exp_fewshot_best مقدار 0.746 را ثبت می‌کند. ترکیب سازگاری به سبک Proto-MAML، تقطیر دانش، پیش‌آموزش تضادی نظارت‌شده و مهندسی ویژگی ($132 \rightarrow 22$ ویژگی) نشان می‌دهد روش‌های کم‌نمونه، در صورت طراحی سیستماتیک، می‌توانند به SOTA جدولی این کوهورت نزدیک شوند.

۷. **نوآوری‌های معماری برای یادگیری کم‌نمونه جدولی.** V5 توجه ویژگی دروازه‌دار (Gated Feature Attention) (انتخاب ویژگی تطبیقی به‌ازای نمونه الهام گرفته از TabNet) و شبکه‌های نمونه‌ای توجه متقاطع (Cross-Attention Prototypical Networks) (شباهت وابسته به زمینه) را معرفی می‌کند. V6 مجموعه‌های عمیق ناهمگون ترکیب‌کننده‌ی FT-Transformer، GFA-Transformer و MLP-Mixer را با پیش‌بینی مطابق (conformal prediction) برای سنجش

عدم قطعیت ارزیابی می کند. این آزمایش ها نشان می دهد مکانیسم های توجه برای یادگیری کم نمونه جدولی ضروری اند و انباشت کالیبره شده ی ساده بر متیادگیرهای پیچیده در مقیاس داده ی کوچک برتری دارد.

۱۱.۱ ساختار پایان نامه

ادامه ی این پایان نامه به صورت زیر سازمان دهی شده است.

فصل ۲ کارهای مرتبط را مرور می کند: یادگیری کم نمونه، یادگیری فدرال، بازنمایی داده ی بالینی و مجموعه داده ی MIMIC-IV. درباره ی شبکه های نمونه ای، شبکه های تطبیق، MAML، FedAvg و کاربردهای پیشین در مراقبت های بهداشتی بحث می کنیم.

فصل ۳ روش شناسی را به تفصیل شرح می دهد: استخراج مجموعه داده، توکن سازی علائم، معماری رمزگذار ETHOS، پروتکل کم نمونه، آموزش فدرال و معیارهای ارزیابی. صورت بندی های ریاضی برای همه ی اجزا ارائه می شود.

فصل ۴ بستر آزمایشی را ارائه می کند: تقسیم داده، ابرپارامترها، مدل های مبنایی (رگرسیون لجستیک، جنگل تصادفی، XGBoost، LightGBM، CatBoost) و پیکربندی ETHOS همراه با یادگیری کم نمونه. آزمایش های ۵-۱ (مقایسه ی اصلی، حساسیت K-شات، فدرال در برابر متمرکز، حذف اجزا، تعمیم بین بیماری ها) را شرح می دهیم.

فصل ۵ نتایج را گزارش می کند: SOTA جدولی منجمد (۰.۷۴۸)، کم نمونه انباشته ی منجمد (۰.۷۴۶)، Exp1 و آزمایش های ۵-۲، جدول توسعه ی V1-V6 (نقاط عطف تاریخی: ۰.۷۳۲، ۰.۷۳۷، ۰.۷۶۰)، راهنمای آماری، قابل تفسیر بودن و تجسم های اضافی.

فصل ۶ تحلیل جامع داده را ارائه می کند: طرحواره ی MIMIC-IV، جمعیت شناسی کوهورت، توزیع گره ی بیماری، همبستگی های آزمایشگاهی، پراکسی SOFA، عملکرد طبقه بندی شده بر اساس سن، تحلیل خطا، نهفته سازی t-SNE، تجسم نمونه ها و خط زمانی بیماران.

فصل ۷ نتایج را تفسیر می کند، محدودیت های متیادگیری کم نمونه را بررسی می کند و پیامدهای عملی و مسیرهای آینده پژوهش را مرور می کند.

فصل ۸ یافته ها و مشارکت های اصلی را خلاصه می کند.

پیوست ها جداول ابرپارامتر، پرسش های MIMIC-IV SQL، قطعه کدها، جداول کامل نتایج و استنتاج های ریاضی را فراهم می کنند.

۱۲.۱ بستر مقرراتی و اخلاقی

داده‌ی بهداشتی تابع مقررات سخت‌گیرانه است. در ایالات متحده، قانون قابلیت انتقال و پاسخگویی بیمه‌ی سلامت (HIPAA) استفاده و افشای اطلاعات سلامت محافظت‌شده (PHI) را نظارت می‌کند. در اتحادیه‌ی اروپا، مقررات عمومی حفاظت از داده (GDPR) قیود مشابهی اعمال می‌کند. این مقررات توانایی متمرکزسازی داده بین نهادها را محدود می‌کند و یادگیری فدرال و رویکردهای حافظ حریم خصوصی را انگیزه می‌بخشد. کار ما از داده‌ی ناشناس‌شده‌ی MIMIC-IV استفاده می‌کند که تحت رویه‌های سخت‌گیرانه‌ی ناشناس‌سازی قرار گرفته است. برای استقرار، هر مدلی باید با مقررات محلی و تأیید کمیته‌ی اخلاق پژوهش (IRB) سازگار باشد.

۱۳.۱ تحلیل ذی‌نفعان

چند ذی‌نفع از پیش‌بینی امکان‌پذیری درمان بهره می‌برند:

- **بالین‌گران:** پشتیبان تصمیم برای برنامه‌ریزی ترخیص؛ شناسایی زود هنگام بیمارانی که ممکن است بستری طولانی یا انتقال نیاز داشته باشند.
- **مدیران بیمارستان:** تخصیص منابع، مدیریت تخت و برنامه‌ریزی ظرفیت.
- **بیماران و خانواده‌ها:** شفافیت درباره‌ی مسیر ترخیص مورد انتظار؛ کاهش عدم قطعیت.
- **پرداخت‌کنندگان:** مهار هزینه از طریق زمان‌بندی مناسب ترخیص؛ کاهش بستری مجدد.
- **پژوهشگران:** روش‌شناسی برای پیش‌بینی بالینی کم‌نمونه و فدرال؛ معیارهایی برای کار آینده.

رویکرد ما قابل تفسیر بودن (SHAP، اهمیت ویژگی) و حریم خصوصی (یادگیری فدرال) را اولویت می‌دهد تا نگرانی‌های بالین‌گر و مقرراتی را پوشش دهد.

۱۴.۱ خلاصه‌ی فصل

این فصل پایان‌نامه را معرفی کرد: بستر بالینی تصمیم‌گیری در ICU و برنامه‌ریزی ترخیص، انگیزه ناشی از محدودیت‌های دسترسی به داده در دنیای واقعی (تجربه‌ی Mayo Clinic)، بیان رسمی مسئله، پرسش‌های پژوهش و مشارکت‌ها. امکان‌پذیری درمان را به‌عنوان وظیفه‌ی طبقه‌بندی دودویی بر داده‌ی ۲۴ ساعت نخست ICU تعریف کردیم، چالش‌های کلیدی (کم‌نمونه، فدرال، بازنمایی) را شناسایی کردیم و ساختار پایان‌نامه را ترسیم کردیم. فصل بعد مبانی نظری را مرور می‌کند.

۱۵.۱ دامنه و محدودیت‌ها

این پایان‌نامه بر نمونه‌ی ۲,۰۰۰ بیمار از MIMIC-IV v3.1 متمرکز است. نتایج ممکن است به کوهورت‌های بزرگ‌تر یا نهادهای دیگر تعمیم نیابد. از برچسب دودویی امکان‌پذیری مشتق‌شده از محل ترخیص و بستری مجدد استفاده می‌کنیم؛ تعاریف جایگزین (مثلاً وضعیت عملکردی، زمان تا ترخیص) می‌تواند به نتیجه‌گیری‌های متفاوت منجر شود. استنتاج علی یا قابل‌تفسیر بودن را عمیق بررسی نمی‌کنیم. بستر فدرال بخش‌بندی مبتنی بر بیماری را شبیه‌سازی می‌کند؛ یادگیری فدرال دنیای واقعی ممکن است با چالش‌های اضافی (هزینه‌ی ارتباط، خرابی گره، کلاینت‌های بیزانسی) روبه‌رو شود.

۱۶.۱ اهمیت در بستر پزشکی دقیق

این کار به دستور کار گسترده‌تر پزشکی دقیق (تنظیم درمان پزشکی بر ویژگی‌های فردی هر بیمار) می‌افزاید. اگرچه پزشکی دقیق سنتی بر پروفایل‌سازی ژنومی و درمان‌های هدفمند تمرکز دارد، مفهوم به‌طور طبیعی به آینده‌نگری دقیق گسترش می‌یابد: پیش‌بینی مسیر فردی بیمار بر اساس پروفایل بالینی ویژه به‌جای میانگین‌های جمعیتی.

۱.۱۶.۱ از میانگین‌های جمعیتی تا پیش‌بینی فردی

برنامه‌ریزی ترخیص سنتی بر قواعد تجربی بالینی و هنجارهای نهادی تکیه دارد: «بیشتر بیماران سپسیس با بهبود لاکتات تا روز پنجم ترخیص می‌شوند.» چنین قواعدی میانگین‌های جمعیتی‌اند که تغییرپذیری فردی را نادیده می‌گیرند. مسیر ترخیص بیمار ۴۵ ساله مبتلا به سپسیس با عملکرد کلیوی طبیعی و حمایت اجتماعی قوی بسیار متفاوت از بیمار ۷۸ ساله با سپسیس، بیماری مزمن کلیوی و مراقبت خانگی محدود است. مدل ما تلاش می‌کند این تفاوت‌های فردی را با یادگیری از ترکیب مشخص مقادیر آزمایشگاهی، علائم حیاتی و ویژگی‌های بالینی مشاهده‌شده در ۲۴ ساعت نخست بستری ICU هر بیمار بازتاب دهد.

۲.۱۶.۱ سازگاری کم‌نمونه به‌عنوان شخصی‌سازی

چارچوب کم‌نمونه چارچوب طبیعی برای شخصی‌سازی ارائه می‌دهد: با تعداد اندکی بیمار مرجع (مجموعه‌ی پشتیبان) که بالینی شبیه بیمار پرسشی‌اند، مدل پیش‌بینی‌های خود را سازگار می‌کند. این امر مشابه استدلال بالینی است؛ پزشکی که بیمار جدید را ارزیابی می‌کند موارد مشابه را به یاد می‌آورد و از آن تجربیات برای آینده‌نگری بهره می‌گیرد. شبکه‌های نمونه‌ای این را با محاسبه‌ی نمونه‌های دسته (مرکزهای بیماران مشابه) و طبقه‌بندی بیماران پرسشی

بر اساس نزدیکی رسمی می‌کنند. اگرچه نتایج ما نشان می‌دهد این رسمی‌سازی هنوز به توان پیش‌بینی مدل‌های کلاسیک نمی‌رسد، هم‌ترازی مفهومی با استدلال بالینی نشان می‌دهد که با بازنمایی‌های بهتر و مجموعه‌های مرجع بزرگ‌تر، شخصی‌سازی کم‌نمونه می‌تواند ابزار بالینی قدرتمندی شود.

۳.۱۶.۱ تعمیم بین‌نهادی

پزشکی دقیق به مدل‌هایی نیاز دارد که بین نهادها تعمیم یابند؛ هر نهاد جمعیت‌شناسی بیمار، شیوه‌های بالینی و استانداردهای مستندسازی خود را دارد. یادگیری فدرال آموزش بین‌نهادی بدون اشتراک داده را ممکن می‌سازد، اما چالش فراتر از حریم خصوصی است: مدل‌ها باید بازنمایی‌هایی بیاموزند که نسبت به ویژگی‌های نهادی ثابت بمانند و در عین حال به تغییرات بالینی معنادار حساس بمانند. بخش‌بندی گره-بیماری ناهمگونی نهادی را با ایجاد توزیع‌های داده‌ی غیر IID شبیه‌سازی می‌کند. آزمایش‌های تعمیم بین‌بیماری (فصل ۵) بررسی می‌کنند که آیا مدل می‌تواند به جمعیت‌های بیمار دیده‌نشده سازگار شود؛ نیاز کلیدی برای استقرار در بسترهای متنوع مراقبت‌های بهداشتی.

فصل ۲

پیشینه و کارهای مرتبط

این فصل مبانی نظری و کارهای پیشین زیربنای رویکرد ما را مرور می‌کند. به یادگیری کم‌نمونه، یادگیری فدرال، بازنمایی داده بالینی، و مجموعه داده MIMIC-IV می‌پردازیم. سازمان فصل چنین است: نخست یادگیری کم‌نمونه (تاریخچه، فرمول بندی مسئله، شبکه‌های نمونه‌ای و تطبیقی، MAML، آموزش اپیزودیک)، سپس یادگیری فدرال (انگیزه، FedAvg، حریم خصوصی، داده غیر IID)، بازنمایی داده بالینی (داده خام، نرمال سازی، توکن‌ها)، MIMIC-IV (مرور کلی، طرحواره، کوهورت، برچسب‌ها، گره‌های بیماری)، کارهای مرتبط در پیش‌بینی بالینی، ترنسفورمرها در داده بالینی، یادگیری نامتوازن، تفسیرپذیری، و مرور جامع ادبیات. هر بخش پیش‌زمینه لازم برای فهم روش و نتایج ما را فراهم می‌کند.

۱.۲ یادگیری کم‌نمونه

۱.۱.۲ تاریخچه و تحول

حوزه یادگیری کم‌نمونه از پژوهش‌های فرا یادگیری در دهه ۲۰۱۰ برخاسته است. کارهای اولیه درباره «یادگیری برای یادگیری» بررسی می‌کردند که چگونه الگوریتم‌ها می‌توانند با تجربه در وظایف گوناگون بهبود یابند. انقلاب ImageNet نشان داد شبکه‌های عمیق می‌توانند بازنمایی‌های نیرومند از مجموعه‌های بزرگ بیاموزند؛ یادگیری کم‌نمونه پرسید آیا بازنمایی‌های مشابه را می‌توان با تعداد اندک نمونه و بهره‌گیری از ساختار بین وظایف آموخت.

۲.۱.۲ فرمول‌بندی مسئله

یادگیری کم‌نمونه به چالش تعمیم از تعداد اندک نمونه برچسب‌خورده به‌ازای هر کلاس می‌پردازد [Snell et al., 2017]. در تنظیم استاندارد N -راه K -شات، N کلاس و K نمونه پشتیبان به‌ازای هر کلاس داریم. هدف طبقه‌بندی نمونه‌های پرس‌وجو تنها با مجموعه پشتیبان است، بدون آموزش اضافی. به‌صورت رسمی، $\mathcal{S} = \{(x_i, y_i)\}_{i=1}^{N \cdot K}$ را مجموعه پشتیبان و $\mathcal{Q} = \{(x_j, y_j)\}_{j=1}^M$ را مجموعه پرس‌وجو می‌نامیم. طبقه‌بند $\hat{y} = f(x; \mathcal{S})$ می‌خواهیم که با توجه به $\mathcal{S}$ برچسب x را پیش‌بینی کند. کلید، یادگیری بازنمایی و معیار فاصله است که بین وظایف تعمیم یابد.

۳.۱.۲ شبکه‌های نمونه‌ای

شبکه‌های نمونه‌ای [Snell et al., 2017] برای هر کلاس یک نمونه‌ای (prototype) به‌صورت میانگین بردارهای نهفته پشتیبان محاسبه می‌کنند:

$$\mathbf{c}_k = \frac{1}{|\mathcal{S}_k|} \sum_{(x_i, y_i) \in \mathcal{S}_k} f_\theta(x_i) \quad (۱.۲)$$

که در آن $\mathcal{S}_k = \{(x_i, y_i) : y_i = k\}$ و f_θ شبکه نهفته‌سازی است. پرس‌وجوی x با نزدیک‌ترین نمونه‌ای در فضای نهفته طبقه‌بندی می‌شود:

$$p(y = k | x) = \frac{\exp(-d(f_\theta(x), \mathbf{c}_k)/\tau)}{\sum_{k'} \exp(-d(f_\theta(x), \mathbf{c}_{k'})/\tau)} \quad (۲.۲)$$

که در آن d فاصله اقلیدسی و τ پارامتر دما است. در پیاده‌سازی ما از شباهت کسینوسی استفاده می‌شود.

۴.۱.۲ شبکه‌های تطبیقی

شبکه‌های تطبیقی [Vinyals et al., 2016] با توجه روی مجموعه پشتیبان برچسب پرس‌وجو را محاسبه می‌کنند:

$$p(y | x, \mathcal{S}) = \sum_i a(x, x_i) \mathbb{1}[y_i = y] \quad (۳.۲)$$

که در آن $a(x, x_i)$ وزن توجه است. این اجازه می‌دهد نمونه‌های پشتیبان مختلف بر اساس شباهت به پرس‌وجو سهم متفاوتی داشته باشند.

۵.۱.۲ شبکه‌های رابطه‌ای

شبکه‌های رابطه‌ای [Sung et al., 2018] معیار فاصله ثابت (اقلیدسی، کسینوسی) را با یک ماژول رابطه آموخته‌شده جایگزین می‌کنند. برای بردار نهفته پرس‌وجوی $f_\theta(x)$ و نمونه‌ای کلاس $\mathbf{c}_k$ ، امتیاز رابطه چنین است:

$$r_k = g_\phi(f_\theta(x), \mathbf{c}_k) \quad (۴.۲)$$

که در آن $g_\phi: \mathbb{R}^{2d} \rightarrow [0, 1]$ یک شبکه عصبی (معمولاً MLP کوچک با خروجی سیگموئید) است که تابع شباهت وابسته به وظیفه را می‌آموزد. مدل به صورت انتها-به-انتها با تابع زیان میانگین مربعات خطا آموزش داده می‌شود:

$$\mathcal{L} = \sum_{(x,y) \in \mathcal{Q}} \sum_k (r_k - \mathbb{1}[y = k])^2 \quad (۵.۲)$$

مزیت شبکه‌های رابطه‌ای بر شبکه‌های نمونه‌ای انعطاف است: ماژول رابطه می‌تواند توابع شباهت غیرخطی یاد بگیرد که مرزهای تصمیم پیچیده را دربرگیرد. عیب، هزینه محاسباتی بیشتر و خطر بیش‌برازش با داده فرا-آموزش محدود است. برای امکان‌پذیری درمان، جایی که مرز تصمیم ممکن است به تعاملات غیرخطی ویژگی (مثلاً تعامل کراتینین و سن) وابسته باشد، شبکه‌های رابطه‌ای جایگزین نظری جذابی برای طبقه‌بندی مبتنی بر نمونه‌ای فراهم می‌کنند.

شبکه‌های رابطه‌ای را به عنوان نقطه مقایسه در مطالعه حذف تدریجی پیاده‌سازی می‌کنیم. ماژول رابطه از دو لایه تمام‌اتصال با فعال‌سازی ReLU تشکیل شده است:

$$g_\phi(\mathbf{u}, \mathbf{v}) = \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot [\mathbf{u}; \mathbf{v}; \mathbf{u} \odot \mathbf{v}; |\mathbf{u} - \mathbf{v}|] + b_1) + b_2) \quad (۶.۲)$$

که در آن $[\cdot; \cdot]$ الحاق، $\odot$ ضرب درایه‌به‌درایه، و σ تابع سیگموئید است. ورودی شامل چهار ویژگی تعاملی است: دو نهفته‌سازی، حاصل ضرب درایه‌به‌درایه‌شان (گرفتن تعاملات ضربی)، و قدر مطلق تفاضل‌شان (گرفتن فاصله).

۶.۱.۲ شبکه‌های سیامی

شبکه‌های سیامی [Koch et al., 2015] با پردازش جفت ورودی از شاخه‌های یکسان (اشتراک وزن) تابع شباهت می‌آموزند:

$$s(x_1, x_2) = \sigma(\|f_\theta(x_1) - f_\theta(x_2)\|_1) \quad (۷.۲)$$

که در آن σ تابع سیگموئید است. شبکه با زیان متضاد روی جفت‌های هم‌کلاس (مثبت) و غیرهم‌کلاس (منفی) آموزش داده می‌شود. اگرچه برای یادگیری کم‌نمونه بنیادین است، شبکه‌های سیامی به مقایسه‌های جفتی ($O(NK)$ به‌ازای هر پرس‌وجو) نیاز دارند و از شبکه‌های نمونه‌ای ($O(N)$ پس از محاسبه نمونه‌ای) کم‌کارآمدترند. شبکه‌های سیامی را پیاده‌سازی نمی‌کنیم اما اهمیت تاریخی آن‌ها را یادآور می‌شویم.

۷.۱.۲ فرا یادگیری مستقل از مدل (MAML)

MAML [Finn et al., 2017] مقداردهی اولیه θ را چنان می‌آموزد که چند گام گرادیان روی وظیفه جدید عملکرد خوب بدهد. هدف فرا-یادگیری چنین است:

$$\min_{\theta} \sum_{\mathcal{T}_i} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i}) \quad (۸.۲)$$

که در آن $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ به‌روزرسانی وابسته به وظیفه است. MAML انعطاف‌پذیرتر است اما پرهزینه؛ برای کارایی از شبکه‌های نمونه‌ای استفاده می‌کنیم.

MAML به محاسبه گرادیان مرتبه دوم (گرادیان گرادیان‌ها) نیاز دارد که حافظه و محاسبه را نسبت به روش‌های مرتبه اول حدود ۲ تا ۳ برابر افزایش می‌دهد. تقریب‌های مرتبه اول (FOMAML, Reptile [Nichol et al., 2018]) با حذف جمله مرتبه دوم این هزینه را از بین می‌برند:

$$\theta \leftarrow \theta - \beta \frac{1}{|\mathcal{T}|} \sum_{\mathcal{T}_i} (\theta - \theta'_i) \quad (۹.۲)$$

Reptile جهت از پارامترهای اولیه به پارامترهای سازگار یافته با وظیفه را میانگین می‌گیرد و جایگزینی ساده و مقیاس‌پذیر فراهم می‌کند. برای مسئله ما (طبقه‌بندی دوجمله‌ای با وظایف محدود)، سربار محاسباتی MAML ممنوع‌کننده نیست، اما تنوع محدود اپیزودهای فرا-آموزش (۵ گره بیماری) شاید پیچیدگی اضافی را توجیه نکند.

از این رو شبکه‌های نمونه‌ای را به عنوان روش اصلی کم‌نمونه به کار می‌بریم و MAML را برای کار آتی با مجموعه‌های فرا-آموزش بزرگ‌تر ذکر می‌کنیم.

۸.۱.۲ آموزش اپیزودیک

آموزش اپیزودیک در طول فرا-آموزش وظایف کم‌نمونه را شبیه‌سازی می‌کند. هر اپیزود وظیفه T_i با پشتیبان S_i و پرس‌وجوی Q_i نمونه‌برداری می‌کند. مدل طوری آموزش داده می‌شود که زیان روی Q_i با توجه به S_i کمینه شود. این با سناریوی استنتاج هم‌خوان است و تعمیم را بهبود می‌بخشد.

۹.۱.۲ تضمین‌های نظری

تحت فرض‌های معین، مانند داده‌ی حاصل از مخلوط گاوسی و کلاس‌های جدا، می‌توان نشان داد شبکه‌های نمونه‌ای با $K \rightarrow \infty$ به طبقه‌بند بهینه‌ی بیزی همگرا می‌شوند. در عمل، K متناهی است و توزیع‌های غیر گاوسی عملکرد را محدود می‌کنند. در یادگیری متریک، فضای نهفته باید نمونه‌های مشابه را نزدیک و نمونه‌های ناهمگون را دور نگه دارد. دما T نیز تیزی توزیع softmax را کنترل می‌کند؛ مقدار بزرگ‌تر T پیش‌بینی‌های نرم‌تری ایجاد می‌کند.

۱۰.۱.۲ کاربردها در سلامت

یادگیری کم‌نمونه به طبقه‌بندی تصویر پزشکی (مثلاً رادیوگرافی، هیستوپاتولوژی)، پیش‌بینی پاسخ دارو، و پیش‌بینی پیامد بالینی به کار رفته است. بیشتر کار بر تصویربرداری تمرکز دارد، جایی که ستون فقرات‌های کانولوشنی و انتقال از ImageNet بازنمایی‌های نیرومند می‌دهند. داده‌ی بالینی جدولی؛ آزمایشگاه، علائم حیاتی، جمعیت‌شناسی؛ در تنظیم کم‌نمونه کم‌کاوش مانده است. چالش‌ها عبارت‌اند از: (۱) نبود ساختار فضایی طبیعی برای کانولوشن؛ (۲) انواع و واحدهای ناهمگون ویژگی؛ (۳) فقدان داده و نمونه‌برداری نامنظم؛ (۴) مجموعه‌های داده کوچک‌تر از بنچمارک‌های بینایی. این کار پارادایم را به امکان‌پذیری درمان از آزمایشگاه و علائم حیاتی با بازنمایی مبتنی بر توکن و رمزگذار ترنسفورمر گسترش می‌دهد.

۲.۲ یادگیری فدرال

۱.۲.۲ انگیزه

داده سلامت در بیمارستان‌ها، کلینیک‌ها و مناطق توزیع شده است. تجمع مرکزی داده مقررات حریم خصوصی را نقض می‌کند و ریسک امنیتی دارد. یادگیری فدرال مدل‌ها را روی داده توزیع شده بدون جابه‌جایی نمونه‌های خام به سرور مرکزی آموزش می‌دهد [McMahan et al., 2017].

۲.۲.۲ میانگین‌گیری فدرال (FedAvg)

FedAvg به روزرسانی‌های مدل محلی را تجمع می‌کند. فرض کنید K مشتری مجموعه‌های داده $\mathcal{D}_1, \dots, \mathcal{D}_K$ را نگه دارند. در دور t :

۱. سرور مدل سراسری θ_t را به مشتریان می‌فرستد.

۲. هر مشتری k به‌روزرسانی محلی محاسبه می‌کند: $\theta_{t+1}^{(k)} = \theta_t - \eta \nabla \mathcal{L}_k(\theta_t)$.

۳. سرور تجمع می‌کند: $\theta_{t+1} = \sum_k \frac{n_k}{n} \theta_{t+1}^{(k)}$.

که در آن $n = \sum_k n_k$ و $n_k = |\mathcal{D}_k|$.

۳.۲.۲ حریم خصوصی و امنیت

یادگیری فدرال نمایش داده را کاهش می‌دهد: تنها به‌روزرسانی‌های مدل (نه داده خام) منتقل می‌شوند. می‌توان حریم تفاضلی با برش گرادیان و افزودن نویز افزود. تجمع امن می‌تواند به‌روزرسانی‌های فردی را از سرور پنهان کند. در این پایان‌نامه از FedAvg استاندارد بدون حریم تفاضلی استفاده می‌شود.

۴.۲.۲ همگرایی و ارتباطات

FedAvg تحت فرض‌های استاندارد (گرادیان‌های کران‌دار، زیان لیشیتز) همگرا می‌شود. تعداد دورهای ارتباطی لازم به ناهمگونی داده بستگی دارد: داده ناهمگون‌تر ممکن است به دورهای بیشتر یا روش‌های تطبیقی (مثلاً SCAFFOLD, FedProx) نیاز داشته باشد. از ۲۰ دور استفاده می‌کنیم؛ در آزمایش‌های ما AUROC اعتبارسنجی تا حدود دور ۲۰-۱۵ به سکون می‌رسد.

۵.۲.۲ FedProx: مدیریت ناهمگونی

FedProx [Li et al., 2020a] با افزودن جمله تنظیم‌کننده مجاورتی به هدف محلی هر مشتری، چالش داده ناهمگون (IID) بین مشتریان را برطرف می‌کند:

$$\min_{\theta} \mathcal{L}_k(\theta) + \frac{\mu}{2} \|\theta - \theta_t\|^2 \quad (۱۰.۲)$$

که در آن مدل سراسری جاری و $\mu > 0$ قدرت جمله مجاورتی را کنترل می‌کند. این از انحراف بیش‌ازحد مشتریان فردی از مدل سراسری در طول آموزش محلی جلوگیری می‌کند؛ به‌ویژه وقتی توزیع‌های داده محلی به‌طور محسوس متفاوت‌اند (مانند پارتیشن‌بندی مبتنی بر بیماری ما). جمله مجاورتی مانند تنظیم‌کننده ضمنی عمل می‌کند که سازگاری محلی و سازگاری سراسری را متعادل می‌کند.

در تنظیم ما، پنج گره بیماری (سپسیس، قلبی، تنفسی، کلیوی، دیابت) به‌طور طبیعی توزیع‌های ویژگی و نسبت کلاس متفاوتی دارند. برای مثال بیماران کلیوی ممکن است به‌طور سیستماتیک کراتینین بالاتری از بیماران قلبی داشته باشند و جابه‌جایی توزیع بین گره‌ها ایجاد شود. FedProx با محدودکردن به‌روزرسانی‌های محلی این امر را تخفیف می‌دهد. FedAvg را به‌عنوان خط پایه اصلی به کار می‌بریم و FedProx را برای کار آتی ذکر می‌کنیم، به‌ویژه اگر عملکرد با ترکیب ناهمگون تر گره‌ها افت کند.

۶.۲.۲ SCAFFOLD: کاهش واریانس

SCAFFOLD [Karimireddy et al., 2020] با متغیرهای کنترلی برای اصلاح انحراف مشتری به کار می‌رود. هر مشتری متغیر کنترلی c_k را نگه می‌دارد که تفاضل گرادیان بین اهداف محلی و سراسری را تخمین می‌زند:

$$\theta_{t+1}^{(k)} = \theta_t - \eta(\nabla \mathcal{L}_k(\theta_t) - c_k + c) \quad (۱۱.۲)$$

که در آن $c = \frac{1}{N} \sum_k c_k$ متغیر کنترلی سراسری است. SCAFFOLD نسبت به FedAvg و FedProx، به‌ویژه تحت ناهمگونی بالای داده، همگرایی سریع‌تری با کاهش واریانس به‌روزرسانی‌های گرادیان به دست می‌آورد. هزینه، ارتباط اضافی است (هر دور هم به‌روزرسانی مدل و هم به‌روزرسانی متغیر کنترلی منتقل می‌شود). برای تنظیم ۵ گره‌ای ما با ناهمگونی متوسط، SCAFFOLD ممکن است بهبود حاشیه‌ای بدهد؛ برای آزمایش‌های چندسایتی آتی که ناهمگونی انتظار می‌رود بالاتر باشد در نظر گرفته می‌شود.

۷.۲.۲ کارایی ارتباطات

هزینه ارتباطات گلوگاه عملی در یادگیری فدرال است. چند راهکار برای کاهش پهنای باند پیشنهاد شده است:

۱. **فشرده سازی گرادیان:** پراکندسازی $\text{top-}k$ تنها k مؤلفه بزرگ ترین گرادیان را منتقل

می کند [Alistarh et al., 2017]. با $k = 1\%$ پارامترها، نسبت فشرده سازی حدود ۱۰۰

برابر با افت دقت اندک قابل دستیابی است.

۲. **کوانتیزاسیون گرادیان:** نمایش مقادیر گرادیان با بیت کمتر (مثلاً ۸ بیت یا ۱ بیت).

SignSGD [Bernstein et al., 2018] تنها علامت هر مؤلفه گرادیان را می فرستد.

۳. **Local SGD:** افزایش دورهای آموزش محلی بین دورهای ارتباطی. از ۳ دور محلی به ازای هر دور

استفاده می کنیم؛ افزایش آن ارتباطات را کم می کند اما ممکن است انحراف بیشتری را بیشتر کند.

۴. **به روزرسانی جزئی مدل:** انتقال تنها لایه های به روز شده (مثلاً تنها سر طبقه بندی با منجمد کردن

رمزگذار). در معماری ما رمزگذار (حدود ۱.۸ میلیون پارامتر) غالب است؛ انتقال تنها ۰.۲ میلیون پارامتر

سر پهنای باند را حدود ۹۰٪ کاهش می دهد.

در آزمایش ها از FedAvg استاندارد با انتقال کامل مدل استفاده می شود. با ۵ گره و ۲۰ دور، کل ارتباطات

حدود $200 \approx 5 \times 20 \times 2$ انتقال مدل است (هر کدام حدود ۸ مگابایت برای ۲ میلیون پارامتر float32)،

جمع حدود ۱.۶ گیگابایت. برای پژوهش قابل تحمل است اما برای استقرار بلادرنگ روی شبکه های محدود ممکن

است به بهینه سازی نیاز باشد.

۸.۲.۲ داده غیر IID

داده فدرال اغلب غیر IID است: هر گره ممکن است توزیع کلاس یا ویژگی متفاوتی داشته باشد. این می تواند به

همگرایی آسیب بزند. MIMIC-IV را بر اساس گروه بیماری (ICD-10) پارتیشن می کنیم که گره های غیر IID

طبیعی می دهد. درجه ناهمگونی را می توان با فاصله جابه جایی زمین (EMD) بین توزیع های برچسب محلی و

سراسری، یا واگرایی KL بین توزیع های ویژگی محلی و سراسری کمی سازی کرد. در پارتیشن ما نرخ امکان پذیری

از ۳۵٪ (گره کلیوی) تا ۴۸٪ (گره تنفسی) متغیر است و ناهمگونی متوسط برچسب ایجاد می کند.

داده غیر IID یک تنش ایجاد می کند: مدل های محلی بیش برآزش به توزیع های محلی، در حالی

که مدل سراسری باید تعمیم دهد. FedAvg با میانگین وزنی که به صورت ضمنی به مرکز وزن داده شده

منظم می کند، این را مدیریت می کند. رویکردهای پیچیده تر (FedProx، SCAFFOLD، یادگیری فدرال

شخصی سازی شده [Smith et al., 2017]) وقتی ناهمگونی شدید است جایگزین می شوند. آزمایش ها نشان می دهد برای تنظیم ۵ گره ای ما FedAvg کفایت می کند و افت عملکرد ناچیز نسبت به آموزش متمرکز است.

۹.۲.۲ کاربردها در سلامت

یادگیری فدرال به پیش بینی مبتنی بر EHR، تصویربرداری پزشکی، و کارآزمایی های بالینی به کار رفته است. پروژه های برجسته FL در سلامت شامل:

- **همکاری Intel-Penn Medicine:** بخش بندی تومور مغزی فدرال در ۳۰ مؤسسه، نشان داد که FL به ۹۹٪ عملکرد متمرکز می رسد [Sheller et al., 2020].
 - **NVIDIA Clara:** بستر یادگیری فدرال برای تصویربرداری پزشکی در چند شبکه بیمارستانی.
 - **HealthChain:** پروژه مالی شده توسط اتحادیه اروپا برای تحلیل فدرال کارآزمایی بالینی در بیمارستان های اروپایی.
 - **FedHealth:** یادگیری انتقالی فدرال برای پایش سلامت پوشیدنی [Chen et al., 2020].
- این کار یادگیری فدرال را با فرا یادگیری کم نمونه برای امکان پذیری درمان ترکیب می کند؛ ترکیبی که در کاربردهای پیشین FL سلامت کمتر کاوش شده است.

۳.۲ بازنمایی داده بالینی

۱.۳.۲ داده بالینی خام

داده ICU معمولاً شامل موارد زیر است:

- **مقادیر آزمایشگاهی:** کراتینین، پتاسیم، سدیم، گلوکز، هموگلوبین، پلاکت، WBC، لاکتات و غیره.
- **علائم حیاتی:** ضربان قلب، فشار خون، دما، SpO₂، نرخ تنفس.
- **جمعیت شناسی:** سن، جنس، نوع پذیرش.
- **پیامدها:** محل ترخیص، مدت بستری، مرگ و میر، بستری مجدد.

مقادیر خام ناهمگون اند: واحدها، دامنه ها، و الگوهای فقدان داده متفاوت. نرمال سازی و جایگزینی بحرانی است.

۲.۳.۲ راهبردهای نرمال سازی

رویکردهای رایج:

۱. **مقیاس min-max**: $x' = (x - x_{\min}) / (x_{\max} - x_{\min})$. پیش از مقیاس بندی به دامنه

بالینی برش می دهیم.

۲. **Z-score**: $x' = (x - \mu) / \sigma$. به داده های پرت حساس است.

۳. **مبتنی بر رتبه**: نگاشت به صدک ها. مقاوم اما اطلاعات مقیاس را از دست می دهد.

از مقیاس min-max با برش دامنه بالینی به $[0, 1]$ استفاده می شود.

۳.۳.۲ بازنمایی های مبتنی بر توکن

ترنسفورمرها انتظار دنباله ای از توکن دارند. در NLP توکن ها قطعات کلمه اند. برای داده بالینی توکن های علائم (Symptom Tokens) تعریف می کنیم: هر توکن $[\text{symptom_id}, \text{intensity}, \text{time_delta}, \text{modality}]$ را رمزگذاری می کند. این اجازه می دهد مدل روی اندازه گیری های مختلف و روابطشان توجه کند.

۴.۳.۲ جدولی در برابر دنباله ای

مدل های جدولی (مثلاً Random Forest, XGBoost) بردارهای ویژگی با طول ثابت به کار می برند. مدل های دنباله ای (مثلاً ترنسفورمرها) دنباله های توکن با طول متغیر. هر دو پشتیبانی می شوند: ویژگی های جدولی برای خطوط پایه، دنباله های توکن برای ETHOS.

۴.۲ مجموعه داده MIMIC-IV

۱.۴.۲ مرور کلی

MIMIC-IV v3.1 [Johnson et al., 2023] پایگاه داده بزرگ و آزاد ICU از مرکز پزشکی Beth Is-Deaconess (BIDMC) است. جایگزین MIMIC-III [Johnson et al., 2016] با ساختار داده به روز و پوشش گسترده تر است. پایگاه داده ناشناس شده برای بیش از ۲۵۰,۰۰۰ اقامت ICU دارد، شامل اندازه گیری های آزمایشگاهی (از labevents)، علائم حیاتی و داده نمودار شده (از chartevents)، تشخیص های ICD-9 و ICD-10، اعمال جراحی، و پیامدها (محل ترخیص، مرگ و میر، مدت بستری). دسترسی تکمیل فرایند

اعتبارسنجی (CITI، توافق استفاده از داده) از طریق PhysioNet را می‌طلبید. کوهورت ۲,۰۰۰ بیمار ما نمونه لایه‌ای است که برای آزمایش‌های بازتولیدپذیر طراحی شده و از نظر محاسباتی قابل مدیریت مانده است.

۲.۴.۲ ساختار داده

جداول کلیدی و نقش آن‌ها:

- **patients**: جمعیت‌شناسی (سن، جنس، سال لنگر). برای فیلتر سن و تعریف کوهورت به کار می‌رود.
 - **admissions**: نوع پذیرش (انتخابی، اورژانسی)، محل ترخیص، زمان پذیرش و ترخیص. برای تعریف برجسب امکان‌پذیری بحرانی است.
 - **icustays**: شناسه‌های اقامت ICU (**stay_id**)، **subject_id**، **hadm_id**، **intime**، **outtime**، مدت بستری. جدول اصلی برای استخراج کوهورت.
 - **labevents**: اندازه‌گیری‌های آزمایشگاهی با **itemid** (از **d_labitems**)، **valuenum**، **charttime**. ۱۵ نوع آزمایش (کراتینین، پتاسیم، سدیم و غیره) از ۲۴ ساعت اول استخراج می‌شود.
 - **chartevents**: علائم حیاتی و داده نمودار شده‌ی دیگر. ۷ علامت حیاتی (ضربان قلب، فشار خون، دما، SpO2، نرخ تنفس) از **d_items** استخراج می‌شود.
 - **diagnoses_icd**: تشخیص‌های ICD-10/ICD-9. برای تخصیص تشخیص اولیه و پارتیشن‌بندی گره بیماری به کار می‌رود.
- اتصال‌ها از طریق **subject_id**، **hadm_id** و **stay_id** انجام می‌شود. برای پرس‌وجوهای SQL به پیوست ب مراجعه کنید.

۳.۴.۲ تعریف کوهورت

کوهورت ۲,۰۰۰ بیمار با این شرایط استخراج می‌شود:

- تنها نخستین اقامت ICU.
- حداقل ۴ ساعت مدت بستری.
- سن ≥ 18 .
- ICD-10 اولیه برای تخصیص گره بیماری در دسترس باشد.

۴.۴.۲ تعریف برجسب

امکان‌پذیری درمان دوجمله‌ای است: ۱ اگر محل ترخیص در {HOME HEALTH CARE, HOME REHAB, REHAB/DISTINCT PART HOSP, HOME WITH HOME IV PROVIDR } ظرف ۳۰ روز از اقامت ICU باشد و بستری مجدد در ۳۰ روز نباشد؛ در غیر این صورت ۰. این با تعاریف بالینی مقصدهای ترخیص «ممکن» هم‌خوان است.

۵.۴.۲ گره‌های بیماری

بر اساس ICD-10 اولیه به پنج گره پارتیشن می‌کنیم:

- گره ۱ (سپسیس): A40, A41, R652.
- گره ۲ (قلبی): I21, I22, I25, I50, I47, I48, I49.
- گره ۳ (تنفسی): J18, J44, J96, J80, J15.
- گره ۴ (کلیوی): N17, N18, N19.
- گره ۵ (دیابت): E10, E11, E13.

این آموزش فدرال با داده محلی وابسته به بیماری را ممکن می‌سازد.

۵.۲ کارهای مرتبط: پیش‌بینی بالینی

۱.۵.۲ پیش‌بینی مبتنی بر EHR

پرونده‌های سلامت الکترونیک (EHR) برای پیش‌بینی مرگ‌ومیر، ریسک بستری مجدد، و پیش‌بینی مدت بستری به کار رفته‌اند. رویکردهای کلاسیک رگرسیون لجستیک، جنگل تصادفی، یا تقویت گرادیان روی ویژگی‌های دست‌ساز را به کار می‌برند. روش‌های یادگیری عمیق شامل شبکه‌های بازگشتی برای دنباله‌های زمانی و ترنسفورمرها برای داده ساخت یافته است. این کار با تمرکز بر تنظیمات کم‌نمونه و فدرال متفاوت است.

۲.۵.۲ پیش‌بینی ترخیص

پیش‌بینی مقصد ترخیص مسئله پرکار است. عوامل شامل وضعیت عملکردی، همراه بیماری، حمایت اجتماعی، و مسیر اولیه ICU است. بیشتر کارهای پیشین داده متمرکز و یادگیری نظارت‌شده استاندارد به کار می‌برند. بررسی

می‌کنیم آیا فرا یادگیری کم‌نمونه می‌تواند عملکرد کلاسیک را وقتی داده محدود و توزیع شده است برابر کند یا به آن نزدیک شود.

۳.۵.۲ یادگیری عمیق در برابر جدولی

روی داده جدولی، تقویت گرادیان (CatBoost, LightGBM, XGBoost) اغلب یادگیری عمیق را پیشی می‌گیرد. شبکه‌های عصبی ممکن است به داده بیشتر یا طراحی دقیق معماری نیاز داشته باشند. نتایج منجمد Exp1 ما هم‌راستا است: Random Forest (AUROC ۰.۷۶۲) از Proposed_FewShot (۰.۶۱۱) بهتر است. این شکاف نشان می‌دهد برای این وظیفه و اندازه مجموعه، وقتی آموزش متمرکز ممکن است، مدل‌های جدولی همچنان انتخاب ترجیحی‌اند.

۴.۵.۲ یادگیری کم‌نمونه روی داده جدولی

یادگیری کم‌نمونه برای طبقه‌بندی تصویر (Omniglot, CUB, miniImageNet) و پردازش زبان طبیعی به گستردگی مطالعه شده، اما کاربرد به داده جدولی کم‌کاوش مانده است. داده جدولی چالش‌های ویژه برای فرا یادگیری دارد:

۱. **ناهمگونی ویژگی:** برخلاف تصاویر (که همه پیکسل‌ها فضای بازنمایی مشترک دارند)، ویژگی‌های جدولی انواع (پیوسته، طبقه‌ای، دوجمله‌ای) و مقیاس‌های متنوع (مثلاً کراتینین به mg/dL در برابر ضربان قلب به bpm) دارند. طرح‌های توکن‌سازی باید این تنوع را پوشش دهند.
۲. **تعاملات ویژگی:** مدل‌های مبتنی بر درخت به‌طور طبیعی تعاملات را از طریق انشعاب می‌گیرند؛ شبکه‌های نمونه‌ای به فضای نهفته برای رمزگذاری این تعاملات تکیه می‌کنند که ممکن است به داده آموزش فراوان نیاز داشته باشد.
۳. **رژیم نمونه کم:** وقتی کل مجموعه کوچک است (مثلاً ۲,۰۰۰ بیمار)، مجموعه فرا-آموزش ممکن است تنوع کافی برای یادگیری بردارهای نهفته تعمیم‌یافته بین اپیزودها نداشته باشد.
۴. **فقدان ساختار فضایی:** تصاویر همبستگی مکانی محلی دارند؛ ویژگی‌های جدولی این سوگیری القایی را ندارند. ترنسفورمرهای اعمال شده به داده جدولی باید روابط ویژگی را از صفر بیاموزند.

کار اخیر Kumagai و Iwata (۲۰۲۰) فرا یادگیری را به رگرسیون جدولی اعمال کرد، و Hegselmann و همکاران (۲۰۲۳) TabLLM را برای طبقه‌بندی جدولی کم‌نمونه با بردارهای نهفته مدل زبانی کاوش کردند. این

رویکردها پیشنهاد می‌کنند یادگیری جدولی مؤثر کم‌نمونه ممکن است نیاز به (الف) مجموعه‌های پیش‌آموزش بسیار بزرگ، (ب) توکن‌سازی وابسته به وظیفه، یا (ج) معماری‌های ترکیبی که بازنمایی‌های آموخته‌شده را با ویژگی‌های کلاسیک یکی کند، داشته باشد. معماری ETHOS_RF_Hybrid ما با جهت (ج) هم‌راستا است.

۵.۵.۲ مکانیزم‌های توجه برای داده بالینی

خود-توجه [Vaswani et al., 2017] به هر توکن اجازه می‌دهد به همه توکن‌های دیگر توجه کند و وابستگی‌های دوربرد را بگیرد. در داده بالینی، مدل می‌تواند روابط بین آزمایشگاه و علائم حیاتی بیاموزد (مثلاً کراتینین و BUN برای عملکرد کلیوی؛ لاکتات و فشار خون برای وضع همودینامیک). رمزگذار ETHOS اصلاحات دامنه‌ویژه اضافه می‌کند: (۱) ماتریس سوگیری هم‌وقوعی قابل آموزش که دانش پیشین هم‌وقوعی علائم را رمزگذاری می‌کند؛ (۲) وزن‌دهی شدت که توجه را به بزرگی مقادیر بالینی مقیاس می‌کند؛ (۳) فروپاشی زمانی که نفوذ اندازه‌گیری‌های قدیمی‌تر را کاهش می‌دهد. این اصلاحات ETHOS را از ترنسفورمرهای عمومی متمایز می‌کند و بخشی از نوآوری رویکرد ماست.

۶.۵.۲ جزئیات معماری ETHOS

رمزگذار ETHOS (Efficient Transformer for Health Outcome prediction using Symptom) (tokens) [Sharafi and Aminian, 2023] معماری ترنسفورمر استاندارد را با سه مکانیزم دامنه‌ویژه برای داده بالینی گسترش می‌دهد:

سوگیری هم‌وقوعی. ماتریس سوگیری قابل آموزش $B \in \mathbb{R}^{V \times V}$ (که V اندازه واژگان علامت است) به logit‌های توجه پیش از softmax افزوده می‌شود:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} + B_{\text{co-occur}} \right) V \quad (12.2)$$

درایه B_{ij} قدرت هم‌وقوعی پیشین بین علامت i و علامت j را رمزگذاری می‌کند. می‌توان از دانش بالینی (مثلاً هم‌وقوعی کراتینین و BUN در پانل کلیوی) مقداردهی اولیه کرد یا از داده آموخت. سوگیری مدل را تشویق می‌کند به اندازه‌گیری‌های بالینی مرتبط توجه کند و سوگیری القایی فقدان ساختار فضایی در داده جدولی را جبران می‌کند.

وزن‌دهی شدت. توجه استاندارد همه توکن‌ها را بدون توجه به بزرگی بالینی یکسان می‌پندارد. ETHOS توجه را با شدت (مقدار نرمال‌شده) هر توکن مدوله می‌کند:

$$\alpha_{ij}^{\text{intensity}} = \alpha_{ij} \cdot \sigma(w_I \cdot \text{intensity}_j + b_I) \quad (۱۳.۲)$$

که در آن α_{ij} وزن توجه استاندارد است و $\sigma(w_I \cdot \text{intensity}_j + b_I)$ تابع دروازه‌ای آموخته‌شده از شدت توکن است. مقادیر افراطی (کراتینین بسیار بالا، پلاکت بسیار پایین) توجه تقویت‌شده می‌گیرند؛ منعکس‌کننده عمل بالینی که مقادیر غیرعادی اهمیت تشخیصی نامتناسب دارند.

فروپاشی زمانی. وقتی چند اندازه‌گیری در زمان‌های مختلف موجود است، ETHOS فروپاشی نمایی زمانی برای کاهش نفوذ مشاهدات قدیمی‌تر اعمال می‌کند:

$$w_{\text{time}}(t) = \exp(-\lambda \cdot |t - t_{\text{ref}}|) \quad (۱۴.۲)$$

که در آن λ نرخ فروپاشی قابل آموزش و t_{ref} زمان مرجع (معمولاً تازه‌ترین مشاهده یا زمان پیش‌بینی) است. این شهود بالینی را منعکس می‌کند: کراتینین ۲ ساعت پیش از ۲۰ ساعت پیش اطلاعاتی‌تر است. در پیاده‌سازی ما با دادهٔ تجمیع‌شدهٔ ۲۴ ساعت اول، اثر فروپاشی زمانی محدود است (همه اندازه‌گیری‌ها از همان پنجره‌اند)، اما مکانیزم برای تعمیم به ورودی‌های سری زمانی گنجانده شده است.

مقایسه با ترنسفورمر عمومی. جدول ۱.۲ ETHOS را با رمزگذار ترنسفورمر عمومی در انتخاب‌های طراحی کلیدی مقایسه می‌کند.

جدول ۱.۲: ETHOS در برابر رمزگذار ترنسفورمر عمومی

ویژگی	ترنسفورمر عمومی	ETHOS
سوگیری توجه	هیچ	هم‌وقوعی قابل آموزش
وزن‌دهی مقدار	یکنواخت	دروازه‌شده با شدت
مدل‌سازی زمانی	تنها رمزگذاری موقعیتی	فروپاشی نمایی
ورودی	قطعات کلمه / نهفته‌سازی	توکن‌های علائم
پیش‌آموزش	مجموعه بزرگ (BERT-مانند)	از صفر (اپیزودیک)
پارامترها	~100 میلیون (BERT)	~2 میلیون

۷.۵.۲ رویکردهای توکن‌سازی علامت در ادبیات

مفهوم توکن‌سازی اندازه‌گیری‌های بالینی برای پردازش ترنسفورمر از چند جهت پژوهشی برخاسته است:

۱. **نسخه‌های بالینی BERT**. مدل‌های ClinicalBERT [Alsentzer et al., 2019] و BioBERT [Lee et al., 2020] متن بالینی (یادداشت‌ها و گزارش‌ها) را با توکن‌سازی wordpiece پردازش می‌کنند. این مدل‌ها برای زبان طبیعی طراحی شده‌اند، نه برای اندازه‌گیری‌های ساخت‌یافته.

۲. **نهفته‌سازی کدهای پزشکی**. مدل‌های BEHRT [Li et al., 2020b] و Med-BERT [Rasmy et al., 2021] کدهای تشخیصی (ICD-10/ICD-9) را به‌عنوان توکن در معماری شبیه BERT نهفته‌سازی می‌کنند. این خانواده کدهای طبقه‌ای را پوشش می‌دهد، نه مقادیر پیوسته‌ی آزمایشگاه.

۳. **TabTransformer** [Huang et al., 2020]: ویژگی‌های طبقه‌ای را به‌عنوان توکن نهفته‌سازی می‌کند و توجه ترنسفورمر اعمال می‌کند، در حالی که ویژگی‌های عددی را به‌صورت اسکالر پس از ترنسفورمر الحاق می‌کند. رویکرد ما با توکن‌سازی هم اطلاعات طبقه‌ای (ID علامت) و هم عددی (شدت) در یک توکن یکپارچه متفاوت است.

۴. **SAINT** [Somepalli et al., 2021]: توجه بین-نمونه و بین-ویژگی برای داده‌ی جدولی اعمال می‌کند. برخلاف رویکرد ما، SAINT بازنمایی مبتنی بر توکن به کار نمی‌برد بلکه هر ویژگی را بعد توجه می‌پندارد.

۵. **FT-Transformer** [Gorishniy et al., 2024]: همه ویژگی‌ها (عددی و طبقه‌ای) را به بردار نهفته تبدیل می‌کند و لایه‌های ترنسفورمر استاندارد اعمال می‌کند. به رویکرد ما نزدیک‌تر است اما اصلاحات دامنه‌ویژه بالینی (سوگیری هم‌وقوعی، وزن‌دهی شدت، فروپاشی زمانی) ندارد.

طرح توکن‌های علائم ما با این موارد متمایز است: (۱) نرمال‌سازی دامنه بالینی با کران‌های برش دامنه‌ویژه؛ (۲) رمزگذاری صریح مودالیتی (آزمایش در برابر علامت حیاتی)؛ (۳) ساختار چهاربعدی توکن برای هویت، بزرگی، زمان، و نوع؛ و (۴) سازگاری با آموزش اپیزودیک کم‌نمونه از طریق دنباله‌های با طول ثابت.

۶.۲ جمع‌بندی

این فصل یادگیری کم‌نمونه (شبکه‌های نمونه‌ای، تطبیقی، MAML)، یادگیری فدرال (FedAvg)، حریم خصوصی، غیر IID، بازنمایی داده بالینی (نرمال‌سازی، توکن‌ها)، و MIMIC-IV را مرور کرد. همچنین کارهای مرتبط در پیش‌بینی بالینی را بررسی کردیم. فصل بعد روش‌شناسی را به تفصیل شرح می‌دهد.

۷.۲ جدول مقایسه کارهای پیشین

جدول ۲.۲ کار ما را نسبت به انتشارات کلیدی پیشین جای می‌دهد. ترکیب فرا یادگیری کم‌نمونه، آموزش فدرال، و بازنمایی مبتنی بر توکن روی داده بالینی جدولی در این کار یکتا است. بیشتر کارهای پیشین یا داده متمرکز، یادگیری نظارت‌شده استاندارد، یا تمرکز بر تصویربرداری به‌جای آزمایشگاه و علائم حیاتی دارند.

جدول ۲.۲: مقایسه کارهای پیشین در پیش‌بینی بالینی

اثر وظیفه	روش	FSL	FL	توکن	تفاوت کلیدی
Awad et al. 2017 ترخیص	LR / RF	×	×	×	نظارت‌شده متمرکز
Purushotham et al. 2018 مرگ‌ومیر	LSTM / RF	×	×	×	متمرکز؛ بدون FL
Rajkomar et al. 2018 بستری مجدد	DNN	×	×	×	مقیاس‌پذیر روی EHR چندسایتی
BEHRT 2020 کدهای EHR	ترنسفورمر	×	×	✓	پیش‌آموزش روی توالی کدها
FedHealth 2020 پوشیدنی	FedAvg + TL	×	✓	×	فدرال، اما بدون کم‌نمونه
TabTransformer 2020 جدولی	توجه	×	×	×	توکن‌سازی عمدتاً برای ویژگی‌های طبقه‌ای
Sheller et al. 2020 تومور مغزی	U-Net	×	✓	×	تصویرمحور، نه داده‌ی جدولی
Hegselmann et al. 2023 جدولی FSL	TabLLM	✓	×	✓	مبتنی بر LLM؛ بدون FL
FT-Transformer 2024 جدولی	ترنسفورمر	×	×	✓	بدون FSL و بدون FL
این پایان‌نامه امکان‌پذیری	ETHOS + Proto + Fed	✓	✓	✓	تنها موردی که هر سه مؤلفه را هم‌زمان ترکیب می‌کند

Federated Learning = FL, Few-Shot Learning = FSL. ✓ = حضور، × = غیاب.

۸.۲ ادبیات تفصیلی: مقالات کلیدی

مقالات کلیدی که کار ما را روشن می کنند را خلاصه می کنیم. (Snell et al. (2017 شبکه های نمونه ای را برای یادگیری کم نمونه معرفی کرد؛ این معماری را برای سر کم نمونه می پذیریم. (McMahan et al. (2017 FedAvg را برای یادگیری فدرال پیشنهاد کرد؛ از پروتکل استاندارد استفاده می کنیم. (Vinyals et al. (2016 شبکه های تطبیقی با توجه روی مجموعه پشتیبان پیشنهاد کرد؛ برای کارایی از نمونه ای بهره می بریم. (Finn et al. (2017 MAML را برای فرا یادگیری معرفی کرد؛ به خاطر پیچیدگی محاسباتی از نمونه ای استفاده می کنیم. (MIMIC-IV Johnson et al. (2023 را منتشر کرد؛ از طرحواره v3.1 استفاده می کنیم. (Sharafi & ETHOS Aminian (2023 را برای پیش بینی پیامد سلامت پیشنهاد کرد؛ برای یادگیری کم نمونه سازگارش می کنیم. (Lin et al. (2017 زیان کانونی (focal loss) را برای داده نامتوازن پیشنهاد کرد؛ برای سر کم نمونه به کار می بریم. (SHAP Lundberg & Lee (2017 را برای تفسیرپذیری معرفی کرد؛ برای توضیح مدل استفاده می کنیم. این مراجع بنیان نظری و تجربی رویکرد ما را فراهم می کنند.

۹.۲ خلاصه مبانی نظری

این فصل مبانی نظری را استقرار داد: (۱) یادگیری کم نمونه کمیابی داده را با فرا یادگیری پوشش می دهد؛ شبکه های نمونه ای از مرکز ثقل کلاس استفاده می کنند؛ (۲) یادگیری فدرال آموزش بدون تجمیع مرکزی داده را ممکن می سازد؛ FedAvg به روزرسانی های مدل را تجمیع می کند؛ (۳) داده بالینی برای مدل های عصبی به نرمال سازی و توکن سازی نیاز دارد؛ (۴) MIMIC-IV داده ICU با طرحواره ساخت یافته فراهم می کند؛ (۵) کار پیشین پیش بینی بالینی داده متمرکز و یادگیری نظارت شده استاندارد به کار می برد؛ ترکیب کم نمونه، فدرال، و بازنمایی مبتنی بر توکن برای امکان پذیری درمان نو است. فصل بعد روش شناسی را به تفصیل، شامل معماری رمزگذار ETHOS، توکن سازی علائم، و پروتکل ارزیابی، شرح می دهد.

۱۰.۲ مرور گسترده ادبیات

۱.۱۰.۲ مبانی فرا یادگیری

فرا یادگیری، یا «یادگیری برای یادگیری»، ریشه در علوم شناختی و پژوهش اولیه AI دارد. بینش کلیدی این است که خود یادگیری می تواند بهینه شود: به جای آموزش مدل از صفر روی هر وظیفه جدید، می توان مقداردهی

اولیه، پیش‌زمینه، یا الگوریتم یادگیری آموخت که بین وظایف تعمیم یابد. این وقتی وظایف ساختار مشترک دارند (مثلاً همه طبقه‌بندی فنوتیپ‌های بالینی) اما هر وظیفه داده برچسب‌خورده محدود دارد، به‌ویژه مرتبط است.

۲.۱۰.۲ یادگیری انتقالی و سازگاری دامنه

یادگیری انتقالی مدلی را که روی دامنه مبدأ پیش‌آموزش دیده روی دامنه هدف تنظیم می‌کند. یادگیری کم‌نمونه را می‌توان به‌عنوان انتقال افراطی دید: دامنه هدف تعداد بسیار اندک نمونه برچسب‌خورده دارد. سازگاری دامنه جابه‌جایی توزیع بین مبدأ و هدف را پوشش می‌دهد؛ در تنظیم ما، گره‌های بیماری مختلف ممکن است توزیع‌های متفاوتی داشته باشند. یادگیری فدرال قید می‌کند که داده مبدأ و هدف را نمی‌توان تجمع کرد.

۳.۱۰.۲ یادگیری متضاد و یادگیری متریک

یادگیری متریک بردارهای نهفته‌ی می‌آموزد که نمونه‌های مشابه نزدیک و نمونه‌های ناهمگون دور باشند. شبکه‌های نمونه‌ای به‌صورت ضمنی یادگیری متریک به کار می‌برند: فضای نهفته طوری آموزش داده می‌شود که نمونه‌ای‌های کلاس جدا شوند. یادگیری متضاد (مثلاً SimCLR، MoCo) به تصویربرداری پزشکی اعمال شده؛ گسترش به داده بالینی جدولی جهتی باز است.

۴.۱۰.۲ چالش‌های ویژه سلامت

یادگیری ماشین در سلامت با چالش‌های ویژه روبه‌روست: (۱) مقرراتی (FDA، علامت‌گذاری CE)، (۲) تفسیرپذیری (بالین دانان باید پیش‌بینی را بفهمند)، (۳) انصاف (اجتناب از سوگیری علیه زیرگروه‌ها)، (۴) اعتبار زمانی (مدل‌ها ممکن است با تکامل عمل ضعیف شوند). این کار این موارد را عمیق پوشش نمی‌دهد اما خط پایه‌ای برای پژوهش آتی فراهم می‌کند.

۱۱.۲ ترنسفورمرها در داده بالینی

۱.۱۱.۲ مکانیزم‌های توجه

معماری ترنسفورمر [Devlin et al., 2019, Vaswani et al., 2017] NLP را دگرگون کرد و برای داده بالینی سازگار شده است. خود-توجه به مدل اجازه می‌دهد هنگام محاسبه بازنمایی‌ها، وزن‌های مختلف به توکن‌های ورودی (مثلاً مقادیر آزمایشگاه، علائم حیاتی) بدهد. برای داده بالینی جدولی، رمزگذارهای مبتنی بر توکن مانند

ETHOS توجه روی توکن‌های علائم را برای گرفتن تعاملات اعمال می‌کند.

۲.۱۱.۲ رمزگذاری موقعیتی

برخلاف متن دنباله‌ای، توکن‌های بالینی ممکن است ترتیب ضمنی داشته باشند (مثلاً زمان اندازه‌گیری). از رمزگذاری موقعیتی برای تزریق اطلاعات ترتیب استفاده می‌شود. رمزگذاری‌های سینوسی و آموخته‌شده رایج‌اند؛ از فرمول‌بندی استاندارد ترنسفورمر پیروی می‌کنیم.

۳.۱۱.۲ ترنسفورمرهای بالینی

BEHRT [Li et al., 2020b] و سایر نسخه‌های BERT بالینی روی دنباله‌های EHR پیش‌آموزش می‌بینند. [Shang et al., 2020] G-BERT ساختار گراف را می‌گنجاند. [Huang et al., 2020] TabTransformer و SAINT [Somepalli et al., 2021] ترنسفورمر را به داده‌جدولی اعمال می‌کنند. رمزگذار ETHOS ما سبک‌تر است و برای آموزش اپیزودیک کم‌نمونه طراحی شده، نه پیش‌آموزش مقیاس بزرگ.

۱۲.۲ یادگیری در شرایط نامتوازن

۱.۱۲.۲ نامتوازنی کلاس در داده بالینی

کوهورت‌های ICU اغلب پیامدهای نامتوازن دارند: مثلاً ۴۲٪ ممکن در برابر ۵۸٪ ناممکن در کوهورت ما. آنتروپی متقاطع استاندارد ممکن است به کلاس اکثریت سوگیری داشته باشد. از زیان کانونی [Lin et al., 2017] برای کم‌وزن کردن نمونه‌های آسان و وزن کلاس برای خطوط پایه استفاده می‌کنیم. برای ارزیابی، AUROC [Hanley and McNeil, 1982] و امتیاز F1 کلان استانداردند؛ ضریب همبستگی Matthews [Matthews, 1975] نیز گزارش می‌شود.

۲.۱۲.۲ SMOTE و نمونه‌برداری مجدد

SMOTE با درون‌یابی بین نزدیک‌ترین همسایه‌ها نمونه اقلیت می‌سازد. در حذف تدریجی اختیاری SMOTE اعمال می‌شود؛ برای وظیفه ما وزن‌دهی کلاس و تنظیم آستانه کفایت می‌کند.

۳.۱۲.۲ معیارهای ارزیابی

برای داده نامتوازن، AUROC نسبت به آستانه تصمیم مستقل است، در حالی که امتیاز F1 کلان به آستانه وابسته است و میانگین F1 را به ازای هر کلاس گزارش می کند. هر دو معیار گزارش می شوند؛ AUROC معیار اصلی مقایسه مدل هاست.

۱۳.۲ تفسیرپذیری در یادگیری ماشین سلامت

۱.۱۳.۲ اهمیت ویژگی

مدل های مبتنی بر درخت (XGBoost, Random Forest) اهمیت بومی ویژگی می دهند. از اهمیت Gini و اهمیت جایگشت استفاده می کنیم. SHAP [Lundberg and Lee, 2017] توضیحات مستقل از مدل ارائه می دهد؛ برای تفسیرپذیری محلی به کار می بریم. LIME [Ribeiro et al., 2016] جایگزین است؛ برای سازگاری با مدل های مبتنی بر درخت از SHAP استفاده می کنیم.

۲.۱۳.۲ تصویرسازی توجه

برای مدل های ترنسفورمر، وزن های توجه نشان می دهند مدل به کدام توکن ها توجه می کند. در فصل ۵، توجه را از طریق انتساب ویژگی SHAP برای پیش بینی های فردی تحلیل می کنیم.

۳.۱۳.۲ اعتبارسنجی بالینی

تفسیرپذیری باید با دانش بالینی هم راستا باشد. ویژگی های برتر (کراتینین، گلوکز، هموگلوبین) با تعیین کننده های شناخته شده ترخیص هم خوان اند. تفسیر بالینی در فصل ۵ بحث می شود.

۱۴.۲ مرور جامع ادبیات

۱.۱۴.۲ تحول و بنچمارک های یادگیری کم نمونه

یادگیری کم نمونه از شبکه های سیامی اولیه [Koch et al., 2015] و شبکه های تطبیقی [Vinyals et al., 2016] به رویکردهای نمونه ای مدرن [Snell et al., 2017] و فرا یادگیری [Finn et al., 2017] تکامل یافته است. این حوزه به گستردگی مرور شده است [Ravi and Larochelle, 2017].

[Wang et al., 2020]. بنچمارک های کلیدی آن شامل Omniglot [Lake et al., 2015]، mini-ImageNet و Meta-Dataset [Triantafillou et al., 2020] است. کارهای اخیر نیز پرسیده اند آیا خطوط پایه ساده [Dhillon et al., 2020] می توانند با فرا یادگیرهای پیچیده برابری کنند. این پایان نامه همان پرسش را به داده بالینی جدولی گسترش می دهد.

۲.۱۴.۲ یادگیری فدرال: سامانه ها و نظریه

سامانه های یادگیری فدرال [He et al., 2020, Bonawitz et al., 2019] مقیاس، ناهمگونی و حریم خصوصی را مدیریت می کنند. تحلیل نظری [Karimireddy et al., 2020, Reddi et al., 2021] همگرایی غیر IID را پوشش می دهد. کاربردهای سلامت [Rieke et al., 2020, Kaissis et al., 2020] نیز امکان پذیری این پارادایم را نشان داده اند. پیاده سازی FedAvg ما پروتکل استاندارد [McMahan et al., 2017] را دنبال می کند؛ در این پایان نامه حریم تفاضلی یا تجميع امن اضافه نمی کنیم.

۳.۱۴.۲ پیش بینی بالینی: وضعیت هنر

پیش بینی مبتنی بر EHR از رگرسیون لجستیک [Awad et al., 2017] به یادگیری عمیق [Pham et al., 2016, Choi et al., 2016, Rajkomar et al., 2019] پیش رفته است. یادگیری چندوظیفه ای [Harutyunyan et al., 2019] کارایی نمونه را بهبود می بخشد. مطالعات بنچمارک [Purushotham et al., 2018] نشان می دهند تقویت گرادیان اغلب یادگیری عمیق را روی EHR جدولی پیشی می گیرد. نتایج منجمد ما نیز همین الگو را نشان می دهد: Random Forest با AUROC ۰.۷۶۲ از مدل پیشنهادی کم نمونه با ۰.۶۱۱ بهتر است و معماری ترکیبی ETHOS و Random Forest با ۰.۷۱۷ یک راه حل میانی ارائه می دهد.

۴.۱۴.۲ یادگیری عمیق جدولی

کار اخیر شامل TabNet [Arik and Pfister, 2021]، TabTransformer [Huang et al., 2020]، SAINT [Somepalli et al., 2021] و FT-Transformer [Gorishniy et al., 2024] است. TabNet توجه دنباله ای برای انتخاب ویژگی به کار می برد؛ TabTransformer خود-توجه را روی بردارهای نهفته ویژگی های طبقه ای و عددی اعمال می کند؛ SAINT توجه روی ردیف و ستون دارد. رمزگذار ETHOS ما مفهوماً شبیه TabTransformer است اما روی توکن های علائم (IDهای گسسته + شدت) به جای ستون های

جدولی خام عمل می‌کند. روی مجموعه‌های بزرگ پیش‌آموزش نمی‌بینیم؛ رمزگذار از صفر برای وظیفه کم‌نمونه آموزش داده می‌شود.

۵.۱۴.۲ مجموعه‌های داده بنچمارک در ML بالینی

فراتر از MIMIC، بنچمارک‌های مهم شامل eICU برای داده چندمرکزه ICU، UK Biobank برای سلامت جمعیتی و مجموعه‌های اختصاصی EHR هستند. جدول ۳.۲ این مجموعه‌ها را مقایسه می‌کند. MIMIC-IV تمرکز ICU، دسترسی آزاد و مستندسازی قوی دارد؛ eICU تنوع چندمرکزه اضافه می‌کند؛ و UK Biobank داده جمعیتی طولی فراهم می‌سازد. انتخاب MIMIC-IV به سه دلیل انجام شد: هم‌راستایی با مسئله ترخیص ICU، دسترس‌پذیری برای پژوهش دانشگاهی و وجود فرایندهای پیش‌پردازش و بنچمارک‌های پذیرفته‌شده در جامعه‌ی پژوهشی.

جدول ۳.۲: مجموعه‌های داده بنچمارک ML بالینی

مجموعه داده اندازه	تمرکز	دسترسی
MIMIC-IV بیش از 250,000 اقامت	ICU، تک‌مرکز	آزاد با فرایند اعتبارسنجی
eICU بیش از 200,000 اقامت	ICU، چندمرکز	آزاد با فرایند اعتبارسنجی
UK Biobank بیش از 500,000 EHR اختصاصی متغیر	جمعیتی، طولی وابسته به نهاد	مبتنی بر درخواست دسترسی نهادی

MIMIC-IV به دلیل دسترسی آزاد (با اعتبارسنجی)، مستندسازی جامع، و پذیرش جامعه به گستردگی به کار می‌رود. نمونه ۲,۰۰۰ بیمار ما زیرمجموعه لایه‌ای برای بازتولیدپذیری است؛ آزمایش‌های کامل MIMIC-IV به محاسبه قابل توجه نیاز دارند و ممکن است نتایج متفاوتی بدهند. مرورها [Borisov et al., 2022] نتیجه می‌گیرند مدل‌های مبتنی بر درخت همچنان نیرومندان؛ رویکردهای عصبی به تنظیم دقیق نیاز دارند. رمزگذار ETHOS ترنسفورمر سبک برای دنباله‌های توکن است؛ روی مجموعه‌های بزرگ پیش‌آموزش نمی‌بینیم.

۶.۱۴.۲ پیش‌بینی ترخیص: نتایج پیشین

کار پیشین پیش‌بینی ترخیص نتایج متنوع گزارش می‌کند. (2017) Random Forest Awad et al. و رگرسیون لجستیک روی MIMIC-III برای مقصد ترخیص به ۰.۷۸ AUROC رسیدند. Caruana et al. (2015) AUROC ۰.۸۸ برای پیش‌بینی مرگ و میر روی داده EHR گزارش کردند. Purushotham et al. (2018) LSTM و تقویت گرادیان را روی مرگ و میر MIMIC-III (۰.۸۵ AUROC) بنچمارک کردند.

Rajkomar et al. (2018) برای پیش‌بینی بستری مجدد AUROC ۰.۷۶ به دست آوردند. وظیفه امکان‌پذیری درمان ما مرتبط اما متمایز است: از داده ۲۴ ساعت اول، امکان‌پذیری دوجمله‌ای (ترخیص به منزل/توان‌بخشی بدون بستری مجدد) پیش‌بینی می‌کنیم. AUROC ۰.۷۶ ما با نتایج پیشین ترخیص و بستری مجدد قابل‌مقایسه است. نوآوری در تنظیم کم‌نمونه و فدرال است، نه فراتر رفتن از بنچمارک‌های متمرکز.

۷.۱۴.۲ AI اخلاقی در سلامت

ملاحظات اخلاقی [Gerke et al., 2020, Jobin et al., 2019, Floridi et al., 2018] و انصاف [Rajkomar et al., 2018, Chouldechova, 2017, Obermeyer et al., 2019] برای AI سلامت بحرانی است. اصول کلیدی: (۱) **نیک‌کاری**: مدل‌ها باید پیامد بیمار را بهبود دهند؛ هم نتایج مثبت و منفی گزارش می‌کنیم تا اغراق نشود. (۲) **نیک‌نبودن**: اجتناب از آسیب؛ برای استقرار انسان-در-حلقه توصیه می‌کنیم. (۳) **خودمختاری**: بیماران و بالین‌دانان حاکمیت تصمیم را دارند؛ مدل‌ها پشتیبان تصمیم‌اند. (۴) **عدالت**: انصاف بین جمعیت‌شناسی‌ها؛ عملکرد لایه‌بندی شده بر اساس سن گزارش می‌شود. (۵) **شفافیت**: تفسیرپذیری از طریق SHAP و اهمیت ویژگی. چارچوب‌های مقرراتی (FDA برای نرم‌افزار به‌عنوان دستگاه پزشکی، GDPR برای اتحادیه اروپا) استقرار را حاکم می‌کنند؛ این کار از داده پژوهشی استفاده می‌کند و محصول مقرراتی نیست.

چارچوب‌های مقرراتی (GDPR, FDA [Voigt and Von dem Bussche, 2017]) استقرار را حاکم می‌کنند. این کار از داده ناشناس‌شده MIMIC-IV استفاده می‌کند؛ اخلاق در پیوست ذ بحث می‌شود.

۱۵.۲ جزئیات معماری ترنسفورمر

رمزگذار ترنسفورمر از لایه‌های متناوب چندسر خود-توجه و پیش‌خور جلو تشکیل شده است. هر سر توجه $\text{head}_i = \text{Softmax}(Q_i K_i^\top / \sqrt{d_k}) V_i$ را محاسبه می‌کند که در آن Q_i, K_i, V_i تصویرهای آموخته‌شده‌اند. خروجی همه سرها الحاق و تصویر می‌شود. نرمال‌سازی لایه پیش و پس از هر زیرلایه اعمال می‌شود (پیکربندی Pre-LN). لایه پیش‌خور جلو: $\text{FFN}(x) = \text{ReLU}(xW_1 + b_1)W_2 + b_2$ با $d_{\text{ff}} = 512$ و Dropout. (۰.۲) پس از توجه و FFN اعمال می‌شود. SAINT, TabTransformer, TabNet و FT-Transformer، رمزگذار ETHOS ما روی توکن‌های علائم (IDهای گسسته + شدت) عمل می‌کند و از صفر برای یادگیری کم‌نمونه آموزش داده می‌شود، نه پیش‌آموزش مقیاس بزرگ.

۱۶.۲ پروتکل ارزیابی و واریانس K-شات

برای ارزیابی کم‌نمونه، ۱۰۰ اپیزود از مجموعه آزمون نمونه‌برداری می‌کنیم. هر اپیزود K پشتیبان و Q پرس‌وجو به‌ازای هر کلاس دارد و میانگین AUROC و انحراف معیار بین اپیزودها گزارش می‌شود. برای مدل‌های کلاسیک از کل مجموعه آزمون در یک ارزیابی تکی استفاده می‌کنیم. این تفاوت پروتکل توضیح می‌دهد چرا AUROC آزمایش K-شات در بازه ۰.۵۶۴-۰.۵۵۷ می‌ماند، در حالی که ارزیابی ثابت Exp1 برای Proposed_FewShot عدد ۰.۶۱۱ را روی کل مجموعه آزمون گزارش می‌کند. کار پیشین روی AUROC MIMIC-III ۰.۷۸ برای تریخیس (Awad et al. 2017) و ۰.۸۵ برای مرگ‌ومیر (Purushotham 2018) گزارش کرد؛ AUROC امکان‌پذیری درمان MIMIC-IV ما با خط پایه‌ی کلاسیک در حدود ۰.۷۶ در بازه قابل‌مقایسه است.

۱۷.۲ بنچمارک‌های یادگیری کم‌نمونه

یادگیری کم‌نمونه روی بنچمارک‌هایی مانند mini-ImageNet, Omniglot و Meta-Dataset به‌طور گسترده ارزیابی شده است. این بنچمارک‌ها عمدتاً تصویری‌اند و ساختار فضایی طبیعی دارند؛ در حالی که داده بالینی جدولی چنین ساختاری ندارد و هر ویژگی اسکالری معنای بالینی متفاوتی دارد. این پژوهش پارادایم کم‌نمونه را به پیش‌بینی بالینی جدولی گسترش می‌دهد. تفاوت‌های اصلی عبارت‌اند از: نبود ستون فقرات ازپیش‌آموزش‌دیده مانند ImageNet، کوچک‌تر بودن مجموعه فرا-آموزش (۲,۰۰۰ در برابر میلیون‌ها نمونه)، طبقه‌بندی دودویی به‌جای چندکلاسه، و ارزیابی اپیزودیک با K متغیر. AUROC متوسط حدود ۰.۶۲ نشان می‌دهد کم‌نمونه جدولی برای رقابت با بنچمارک‌های بینایی احتمالاً به معماری‌های متفاوت یا مجموعه‌های فرا-آموزش بزرگ‌تر نیاز دارد.

۱۸.۲ یادگیری فدرال: ارتباطات و حریم خصوصی

FedAvg به چند دور ارتباط نیاز دارد. در هر دور، سرور مدل سراسری را به مشتریان می‌فرستد، مشتریان مدل را روی داده محلی خود آموزش می‌دهند و به‌روزرسانی‌ها را باز می‌گردانند. با ۵ گره و ۲۰ دور، ۱۰۰ گام ارتباطی انجام می‌شود و در هر گام مدل کامل، حدود ۲ میلیون پارامتر در معماری ما، منتقل می‌گردد. در استقرار واقعی، فشرده‌سازی گرادینان یا به‌روزرسانی‌های جزئی می‌تواند پهنای باند را کاهش دهد. حریم تفضلی نیز با برش گرادینان و افزودن نویز گاوسی قابل افزودن است، هرچند در این پایان‌نامه پیاده‌سازی نشده است. تجمع امن، مثلاً با رمزنگاری هم‌ریختی یا محاسبه چندطرفه امن، می‌تواند به‌روزرسانی‌های فردی را از سرور پنهان کند. شکاف عملکرد کوچک، حدود ۰.۰۰۵ واحد AUROC در آزمایش گزارش‌شده، نشان می‌دهد وقتی داده را نمی‌توان تجمع

کرد، یادگیری فدرال برای این وظیفه عملی است.

۱۹.۲ پیش‌بینی بالینی: فرمول‌بندی وظیفه

امکان‌پذیری درمان وظیفه طبقه‌بندی دوجمله‌ای است: با داده اولیه ICU (۲۴ ساعت اول)، پیش‌بینی کنید آیا بیمار به ترخیص ممکن دست می‌یابد. برچسب از محل ترخیص و بستری مجدد ۳۰ روزه استخراج می‌شود. این فرمول‌بندی محدودیت دارد: (۱) مقصد ترخیص ممکن است به عوامل اجتماعی (مثلاً حمایت خانواده، بیمه) وابسته باشد که در آزمایشگاه و علائم حیاتی نیست؛ (۲) بستری مجدد ۳۰ روزه جایگزین بهبودی است؛ (۳) برچسب دوجمله‌ای ظرافت را از دست می‌دهد (مثلاً توان بخشی در برابر مراقبت پرستاری ماهر). با وجود این محدودیت‌ها، فرمول‌بندی بالینی معنادار و قابل مدیریت است. فرمول‌بندی‌های جایگزین شامل: رگرسیون (زمان تا ترخیص)، چندکلاسه (مقصد ترخیص)، یا تحلیل بقا (زمان-تا-رویداد) است. روی طبقه‌بندی دوجمله‌ای برای سادگی و هم‌راستایی با ادبیات پیشین پیش‌بینی ترخیص تمرکز می‌کنیم.

۲۰.۲ جایگزینی و مدیریت داده گمشده

داده بالینی اغلب مقادیر گمشده دارد. راهبرد زیر به کار می‌رود: (۱) برای سری زمانی (آزمایشگاه، علائم حیاتی در ۲۴ ساعت اول): پرکردن رو به جلو درون بیمار، سپس میانگین جمعیت برای همچنان گمشده. (۲) برای ویژگی‌های کاملاً گمشده: میانگین جمعیت. (۳) بدون پرکردن رو به عقب (تنها داده گذشته نسبت به زمان پیش‌بینی). (۴) جایگزینی پیچیده (مثلاً MICE، KNN) برای اجتناب از نشت داده و هزینه محاسباتی به کار نمی‌رود؛ جایگزینی میانگین محافظه‌کارانه است. نرخ فقدان داده به‌ازای ویژگی متفاوت است: آزمایشگاه‌های معمولی (کراتینین، سدیم) ۱۲-۵٪؛ آزمایشگاه‌های تخصصی (لاکتات، تروپونین) ۳۵-۱۸٪؛ علائم حیاتی ۸-۲٪. ویژگی‌ها با بیش از ۳۰٪ فقدان ممکن است ارزش پیش‌بینی کاهش یافته داشته باشند؛ برای کمال نگه داشته می‌شوند و مدل می‌آموزد. در استقرار، داده بالادرنگ ممکن است الگوی فقدان متفاوتی داشته باشد؛ پایش و آموزش مجدد ممکن است لازم شود.

۲۱.۲ جمع‌بندی فصل

این فصل مبانی نظری کار ما را مرور کرد. به یادگیری کم‌نمونه (شبکه‌های نمونه‌ای، تطبیقی، MAML، آموزش ایزودیک)، یادگیری فدرال (FedAvg، حریم خصوصی، داده غیر IID، ارتباطات)، بازنمایی داده بالینی (نرمال‌سازی، توکن‌ها، جدولی در برابر دنباله‌ای)، و مجموعه داده MIMIC-IV (طرحواره، کوهورت، برچسب‌ها، گره‌های بیماری)

پرداختیم. کارهای مرتبط در پیش‌بینی بالینی، ترنسفورمرها برای داده‌بالینی، یادگیری نامتوازن، تفسیرپذیری، و AI اخلاقی را بحث کردیم. همچنین جدول مقایسه کارهای پیشین، جزئیات معماری ترنسفورمر، واریانس پروتکل ارزیابی، بنچمارک‌های کم‌نمونه، ارتباطات و حریم خصوصی فدرال، فرمول‌بندی وظیفه بالینی، و راهبردهای جایگزینی را ارائه دادیم. فصل بعد روش‌شناسی را به تفصیل شرح می‌دهد.

فصل ۳

روش شناسی

این فصل روش پژوهش را مرحله به مرحله شرح می دهد: استخراج مجموعه داده، توکن سازی علائم، رمزگذار ETHOS، پروتکل کم نمونه، آموزش فدرال و ارزیابی. ابتدا نمادگذاری و نمای کلی فرایند ارائه می شود و سپس هر جزء به صورت جداگانه توضیح داده می شود.

۱.۳ نمادگذاری

در سراسر متن از نمادگذاری زیر استفاده می شود. جدول ۱.۳ مرجع خلاصه ای برای این نمادهاست.

جدول ۱.۳: خلاصه نمادگذاری

نماد	معنا
$\mathcal{X}$	فضای ورودی، یعنی بازنمایی بیماران
$\mathcal{Y}$	فضای برچسب $\{0, 1\}$ ، یعنی غیرقابل تحقق و قابل تحقق
$\mathcal{Q}, \mathcal{S}$	به ترتیب مجموعه ی پشتیبان و مجموعه ی پرس و جو
$\mathcal{Q}, K$	تعداد نمونه های پشتیبان و پرس و جو به ازای هر کلاس
N	تعداد کلاس ها؛ در این کار 2 برای طبقه بندی دودویی
θ	پارامترهای مدل
$\mathbf{c}_k$	بردار نمونه ی اولیه برای کلاس k
τ	دما ی softmax
d	بعد نهفته؛ در این کار 128
L	طول دنباله؛ در این کار 25 توکن

$\mathcal{X}$ فضای ورودی (بازنمایی بیماران) را؛ $\mathcal{Y} = \{0, 1\}$ برچسب دودویی (غیرقابل تحقق، قابل تحقق) را؛ $\mathcal{S}$ مجموعه پشتیبان را؛ $\mathcal{Q}$ مجموعه پرس و جو را؛ K تعداد نمونه های پشتیبان به ازای هر کلاس را؛ N تعداد کلاس ها (2 برای دودویی) را؛ θ پارامترهای مدل را؛ $\mathbf{c}_k$ نمونه ی اولیه ی کلاس k را؛ τ دما در softmax را؛ d

بعد نهفته (128 برای ETHOS) را؛ و L طول دنباله (25 توکن) را نمایش می‌دهد.

۲.۳ نمای کلی فرایند

شکل ۱.۳ فرایند انتها به انتها را نشان می‌دهد. آزمایش‌ها و علائم حیاتی خام از ۲۴ ساعت نخست MIMIC-IV استخراج و نرمال‌سازی می‌شوند. سپس داده در دو شاخه پردازش می‌شود: در شاخه **جدولی**، بردار ویژگی ۲۵ بعدی به مدل‌های کلاسیک مانند RF و XGBoost داده می‌شود؛ در شاخه **عصبی**، داده به توکن‌های علائم تبدیل، با رمزگذار ETHOS به بردار نهفته ۱۲۸ بعدی نگاشت، و سپس با سر کم‌نمونه یا سر نظارت‌شده طبقه‌بندی می‌شود. در حالت فدرال، هر گره مدل را روی داده محلی خود آموزش می‌دهد و وزن‌ها با FedAvg تجمع می‌شوند. در مدل ترکیبی نیز بردارهای نهفته ETHOS با ویژگی‌های جدولی ادغام و به طبقه‌بند نهایی Random Forest داده می‌شوند.

جریان داده:

MIMIC-IV (آزمایشگاه، علائم حیاتی) → نرمال‌سازی → [Tabular 25-بعدی | توکن‌سازی] → ETHOS → [128-بعدی] → [XGB/RF | سر نمونه‌ی اولیه‌ای | ترکیبی 153-بعدی] → [RF] → پیش‌بینی امکان‌پذیری ترخیص

شکل ۱.۳: فرایند انتها به انتها؛ استخراج داده، بازنمایی دوگانه (جدولی و مبتنی بر توکن)، و شاخه‌های مدل.

۳.۳ مجموعه داده و پیش‌پردازش

۱.۳.۳ استخراج کوهورت

یک کوهورت شامل ۲,۰۰۰ بیمار از MIMIC-IV v3.1 با معیارهای زیر استخراج می‌شود:

- فقط اولین بستری در ICU (بدون بستری مجدد در کوهورت).
- حداقل 4 ساعت مدت بستری (برای اطمینان از کفایت داده).
- سن ≥ 18 سال در پذیرش.
- تشخیص اصلی ICD-10 برای تخصیص گره بیماری موجود باشد.

فرایند استخراج (پیوست ب) ابتدا icustays را فیلتر می‌کند، سپس آن را به patients و admissions پیوند می‌زند و در نهایت ۲,۰۰۰ بستری را با لایه‌بندی بر اساس گروه تشخیص اولیه نمونه‌گیری می‌کند. جدول ۲.۳

جمعیت‌شناسی کوهورت را خلاصه می‌کند.

جدول ۲.۳: آمار جمعیت‌شناختی کوهورت MIMIC-IV

شاخص میانگین انحراف معیار بازه		
۱۸-۹۰	15.3	سن (سال) 64.2
-	-	بیماران مرد (%) 56.4
۴-۷۲۰	96.2	طول اقامت ICU (ساعت) 72.4
۱-۴۵	7.1	طول اقامت بیمارستان (روز) 8.2
تعداد بیماران 2,000		

۲.۳.۳ فرایند تفصیلی استخراج MIMIC-IV

استخراج داده با یک فرایند چندمرحله‌ای SQL انجام می‌شود که هم بازتولیدپذیر باشد و هم از نظر بالینی قابل دفاع بماند. الگوریتم ۱ این فرایند را به صورت رسمی نشان می‌دهد.

Algorithm 1 فرایند استخراج کوهورت MIMIC-IV

Require: MIMIC-IV database, target size $n = 2000$

```

1: Stage 1: Candidate ICU stays
2:  $\mathcal{C} \leftarrow \text{SELECT from icustays WHERE first\_stay} = \text{TRUE}$ 
3:  $\mathcal{C} \leftarrow \{c \in \mathcal{C} : \text{LOS}(c) \geq 4\text{h}\}$ 
4: Stage 2: Age filter
5:  $\mathcal{C} \leftarrow \{c \in \mathcal{C} : \text{age}(c) \geq 18\}$  ▷ Via patients.anchor_age
6: Stage 3: Diagnosis assignment
7: for each  $c \in \mathcal{C}$  do
8:    $\text{dx}(c) \leftarrow \text{primary ICD-10 from diagnoses\_icd (seq\_num=1)}$ 
9:    $\text{node}(c) \leftarrow \text{map\_to\_disease\_node}(\text{dx}(c))$ 
10: end for
11:  $\mathcal{C} \leftarrow \{c \in \mathcal{C} : \text{node}(c) \neq \text{NULL}\}$ 
12: Stage 4: Stratified sampling
13:  $\mathcal{S} \leftarrow \text{stratified\_sample}(\mathcal{C}, n = 2000, \text{strata} = \text{node})$ 
14: Stage 5: Label derivation
15: for each  $c \in \mathcal{S}$  do
16:    $\text{dest}(c) \leftarrow \text{admissions.discharge\_location}$ 
17:    $\text{readmit}(c) \leftarrow \text{check 30-day readmission from admissions}$ 
18:    $y(c) \leftarrow \neg [\text{dest}(c) \in \{\text{HOME, REHAB, ...}\} \wedge \neg \text{readmit}(c)]$ 
19: end for
20: return  $\{(c, y(c)) : c \in \mathcal{S}\}$ 

```

ساختار پیوند بر سه کلید اصلی تکیه دارد: subject_id بیماران را به پذیرش‌ها، hadm_id پذیرش‌ها را به تشخیص‌ها و سوابق ترخیص، و stay_id بستری‌های ICU را به رویدادهای آزمایشگاهی و علائم حیاتی وصل می‌کند. ترتیب پیوندها طوری انتخاب شده است که اندازه نتایج میانی تا حد ممکن کاهش یابد. ابتدا بستری‌های ICU فیلتر می‌شوند و تعداد نمونه‌ها از بیش از ۲۵۰ هزار به حدود ۱۸۰ هزار بستری اول می‌رسد.

سپس فیلترهای سن و LOS اعمال می شوند و تعداد به حدود ۱۵۰ هزار کاهش می یابد. در گام بعد، وجود تشخیص ICD-10 الزامی می شود و حدود ۱۲۰ هزار نمونه باقی می ماند. در نهایت، ۲,۰۰۰ بیمار به صورت لایه بندی شده نمونه گیری می شوند. این فیلتر آبخاری باعث می شود پیوندهای پرهزینه با labevents و chartevents فقط روی کوچک ترین کوهورت لازم اجرا شوند.

۳.۳.۳ استخراج آزمایشگاه و علائم حیاتی

از ۱۵ itemid آزمایشگاهی و ۷ itemid علائم حیاتی از d_labitems و d_items در MIMIC-IV استفاده می شود. مقادیر از ۲۴ ساعت اول بستری ICU استخراج می شوند. هر اندازه گیری به بازه ی بالینی clip می شود (مثلاً کراتینین [0.1, 30] mg/dL) تا پرت ها حذف شوند و سپس با min-max به بازه [۰, ۱] نرمال می شود:

$$x' = \frac{\text{clip}(x, x_{\min}, x_{\max}) - x_{\min}}{x_{\max} - x_{\min}} \quad (۱.۳)$$

جدول های ۳.۳ و ۴.۳ بازه های آزمایشگاهی و علائم حیاتی را فهرست می کنند.

جدول ۳.۳: بازه های آزمایشگاهی منتخب (15 آزمایش)

واحد	آزمایش شناسه کمینه بیشینه			
mg/dL	30	0.1	۵۰۹۱۲	کراتینین
mEq/L	10	1.5	۵۰۹۷۱	پتاسیم
mEq/L	180	100	۵۰۹۸۳	سدیم
mg/dL	600	20	۵۰۹۳۱	گلوکز
g/dL	25	3	۵۰۸۱۱	هموگلوبین
mmol/L	25	0.5	۵۰۸۱۳	لاکتات
...	...	...	...	...

جدول ۴.۳: بازه های علائم حیاتی منتخب (7 علامت حیاتی)

واحد	علامت حیاتی شناسه کمینه بیشینه			
bpm	250	20	۲۲۰۰۴۵	ضربان قلب
mmHg	250	40	۲۲۰۰۵۰	فشار خون سیستولیک
%	100	50	۲۲۰۲۷۷	SpO ₂
...	...	...	...	...

15 اندازه‌گیری آزمایشگاهی بر اساس ارتباط بالینی با پیش‌بینی ترخیص ICU و دسترسی در MIMIC-IV انتخاب شدند:

- **پانل کلیوی:** کراتینین، BUN (نیترژن اوره خون)، پتاسیم، سدیم، کلر، بی‌کربنات
- **هماتولوژی:** هموگلوبین، پلاکت، شمارش گلبول سفید (WBC)
- **متابولیک:** گلوکز، لاکتات، آلومین
- **کبدی:** ALT (آلانین آمینوترانسفراز)، بیلی‌روبین
- **انعقاد:** INR (نسبت نرمال شده بین‌المللی)

7 علامت حیاتی عبارت‌اند از: ضربان قلب، فشار خون سیستولیک، فشار خون دیاستولیک، فشار شریانی میانگین، دما، SpO_2 (اشباع اکسیژن)، و نرخ تنفس. وقتی چند اندازه‌گیری در پنجره‌ی 24-ساعته وجود دارد، از مقدار میانه برای کاهش حساسیت به جهش‌های گذرا یا آرتیفکت اندازه‌گیری استفاده می‌شود.

۴.۳.۳ مهندسی ویژگی

سه ویژگی مهندسی‌شده به 22 ویژگی پایه (15 آزمایشگاه + 7 علائم حیاتی) افزوده می‌شود:

1. **شاخص شوک:** $SI = HR/SBP$ ، با بازه‌ی بالینی $[0.3, 2.0]$ به $[0, 1]$ نرمال می‌شود. شاخص شوک نشانگر اعتباریافته‌ی ناپایداری همودینامیک است؛ مقادیری فراتر از 1.0 برای SI با افزایش مرگ‌ومیر و طولانی‌شدن بستری ICU همراه‌اند. به‌صورت رسمی:

$$SI_{\text{norm}} = \frac{\text{clip}(HR/SBP, 0.3, 2.0) - 0.3}{2.0 - 0.3} \quad (2.3)$$

2. **جایگزین SOFA:** تقریب ساده‌شده‌ی نمره‌ی Sequential Organ Failure Assessment به‌صورت زیر محاسبه می‌شود:

$$SOFA_{\text{proxy}} = \frac{1}{4} [(1 - x_{\text{creat}}) + (1 - x_{\text{plt}}) + (1 - x_{\text{SpO}_2}) + x_{\text{lactate}}] \quad (3.3)$$

که در آن هر x مقدار نرمال‌شده‌ی min-max است. مقادیر بالاتر جایگزین نشان‌دهنده‌ی عملکرد اندام بدتر است. این تقریب چهار از شش حوزه‌ی SOFA (کلیوی، انعقادی، تنفسی، قلبی‌عروقی) را با داده‌ی آزمایشگاهی و علائم حیاتی موجود می‌گیرد. حوزه‌های عصبی (GCS) و کبدی (بیلی‌روبین) به‌دلیل فقدان

داده حذف شده‌اند؛ بیلی روبین در دسترس است اما مستقل به مجموعه‌ی ویژگی خام کمک می‌کند.

۳. شمارش آزمایش‌های غیرطبیعی: کسر مقادیر آزمایشگاهی با انحراف شدید:

$$\text{AbnCount} = \frac{1}{15} \sum_{j=1}^{15} \mathbb{I}[|x_j - 0.5| > 0.35] \quad (4.3)$$

این تعداد آزمایش‌های خارج از 30% میانی بازه‌ی نرمال شده‌ی خود را می‌گیرد و انحراف کلی فیزیولوژیک را منعکس می‌کند. بیماری با 8 از 15 آزمایش غیرطبیعی از نظر بالینی بیمارتر از بیماری با 2 مورد غیرطبیعی است، صرف نظر از اینکه کدام آزمایش‌ها منحرف شده‌اند.

مجموعه‌ی ویژگی جدولی نهایی 25 بعد دارد. جدول ۵.۳ همه‌ی ویژگی‌ها را دسته‌بندی می‌کند.

جدول ۵.۳: خلاصه‌ی بردار ویژگی 25-بعدی

دسته	ویژگی‌ها تعداد
پانل کلیوی	۶ HCO_3^- , Cl^- , Na^+ , K^+ , BUN, کراتینین
هماتولوژی	۳ WBC, پلاکت, هموگلوبین
متابولیک	۳ گلوکز, لاکتات, آلبومین
کبدی	۲ ALT, بیلی روبین
انعقاد	۱ INR
علائم حیاتی	۷ RR, SpO_2 , دما, MAP, DBP, SBP, HR
مهندسی شده شاخص شوک, جایگزین SOFA, شمار غیرطبیعی	۳
جمع	۲۵

۵.۳.۳ راهبرد داده‌ی گمشده

داده‌های بالینی ذاتاً ناقص‌اند. راهبرد جایگزینی ما سلسله‌مراتب محافظه‌کارانه‌ای را دنبال می‌کند:

۱. **پُرکردن رو به جلو درون بیماری:** اگر مقدار آزمایش در ساعت 2 و 18 اندازه گرفته شده باشد، پرس‌وجو در ساعت 12 از مقدار ساعت 2 استفاده می‌کند (بدون پرکردن معکوس برای جلوگیری از نشت اطلاعات).

۲. **تجميع میانه‌ای:** برای خلاصه‌ی 24 ساعت اول، میانه‌ی همه‌ی اندازه‌گیری‌های موجود در پنجره گرفته می‌شود. میانه نسبت به پرت‌های ناشی از آرتیفکت اندازه‌گیری مقاوم است.

۳. جایگزینی با میانه‌ی جمعیت: اگر در 24 ساعت اندازه‌گیری برای ویژگی‌ای موجود نباشد، میانه‌ی جمعیت (فقط روی مجموعه‌ی آموزش محاسبه‌شده برای جلوگیری از نشت داده) جایگزین می‌شود.

۴. شاخص فقدان: در بردار ویژگی 25-بعدی شاخص صریح فقدان استفاده نمی‌شود، اما ویژگی شمار آزمایش غیرطبیعی به‌صورت ضمنی اطلاعاتی درباره‌ی ویژگی‌هایی با مقادیر شدیداً منحرف می‌گیرد. نرخ فقدان در کوهورت ما: آزمایش‌های روتین (کراتینین، سدیم، پتاسیم) 5-12%؛ آزمایش‌های تخصصی (لاکتات، آلبومین، INR) 18-35%؛ علائم حیاتی 2-8%. ویژگی‌هایی با بیش از 50% فقدان در مرحله‌ی انتخاب ویژگی حذف شدند؛ همه‌ی 22 ویژگی نگه‌داشته‌شده حداکثر 35% فقدان دارند.

۶.۳.۳ تقسیم داده

از تقسیم‌های ثابت آموزش/اعتبارسنجی/آزمون با بذر 42 استفاده می‌شود:

- 80% آموزش+اعتبارسنجی، 20% آزمون (لایه‌بندی‌شده بر اساس برچسب).
 - از 80%، 80% آموزش و 20% اعتبارسنجی.
 - نهایی: 64% آموزش (۱,۲۸۰ بیمار)، 16% اعتبارسنجی (۳۲۰ بیمار)، 20% آزمون (۴۰۰ بیمار).
- هیچ داده‌ی آزمونی برای انتخاب مدل یا تنظیم ابرپارامتر استفاده نمی‌شود. همه‌ی تصمیم‌ها روی مجموعه‌ی اعتبارسنجی اعتبار می‌یابند و روی مجموعه‌ی آزمون گزارش می‌شوند. لایه‌بندی تضمین می‌کند نرخ امکان‌پذیری (تقریباً 42% قابل تحقق) در همه‌ی تقسیم‌ها حفظ شود. برای آزمایش‌های فدرال، مجموعه‌ی آموزش بیشتر بر اساس گره بیماری افزای می‌شود و هر گره سهم متناسب از داده‌ی آموزش دریافت می‌کند.

۴.۳ توکن‌سازی علائم

۱.۴.۳ ساختار توکن

هر بیمار به‌صورت دنباله‌ای حداکثر 25 توکن بازنمایی می‌شود. هر توکن چهار جزء دارد:

$$\text{توکن} = [\text{symptom_id}, \text{intensity}, \text{time_delta}, \text{modality}] \quad (۵.۳)$$

که در آن:

- **symptom_id**: 1-15 برای آزمایشگاه‌ها، 16-22 برای علائم حیاتی، 0 برای MASK (پدینگ).
- **intensity**: مقدار نرمال‌شده در $[0, 1]$.
- **time_delta**: جابجایی زمانی نرمال‌شده (0 برای تجمیع 24 ساعت اول).
- **modality**: 0 برای آزمایشگاه، 1 برای علائم حیاتی.

۲.۴.۳ ساخت دنباله

برای هر بیمار، همه‌ی اندازه‌گیری‌های غیرگمشده جمع‌آوری، بر اساس symptom_id مرتب، و با توکن‌های MASK به طول 25 پد می‌شوند. این دنباله‌ی با طول ثابت برای رمزگذارهای transformer مناسب است.

۳.۴.۳ ارتباط با ویژگی‌های جدولی

بازنمایی جدولی (25 ویژگی) نسخه‌ی مسطح و تجمیع‌شده‌ی دنباله‌ی توکن است. هر دو از همان مقادیر نرمال‌شده‌ی زیرین استفاده می‌کنند. مدل‌های جدولی بردار 25-بعدی را دریافت می‌کنند؛ ETHOS دنباله‌ی توکن را دریافت می‌کند.

۵.۳ معماری رمزگذار ETHOS

۱.۵.۳ نمای کلی

ETHOS [Sharafi and Aminian, 2023] یک رمزگذار transformer است که دنباله‌های توکن را به بردارهای نهفته با اندازه ثابت نگاشت می‌کند. شامل موارد زیر است:

- لایه نهفته‌سازی: (symptom_id, intensity, time_delta, modality) را به بردارهای d -بعدی نگاشت می‌کند.
- کدگذاری موقعیتی: سینوسی یا آموخته‌شده.
- L لایه‌ی transformer: خودتوجه چندسر + پیش‌خوران.
- تجمیع: میانگین روی دنباله (به جز MASK) یا توکن به‌سبک [CLS].

۲.۵.۳ پیکربندی

از config.yaml:

$$d_{\text{model}} = 128 \bullet$$

$$n_{\text{head}} = 8 \bullet$$

$$n_{\text{layers}} = 2 \bullet$$

$$d_{\text{ff}} = 512 \bullet$$

$$\text{Dropout} = 0.2 \bullet$$

$$\text{vocab_size} = 23 \bullet \text{ (MASK 1 + علامت 22)}$$

۳.۵.۳ خروجی

رمزگذار برای هر بیمار یک نهفته سازی 128-بعدی تولید می کند. این نهفته سازی توسط سر نمونه ای اولیه ای برای طبقه بندی کم نمونه استفاده می شود.

۴.۵.۳ جزئیات مکانیزم توجه

خودتوجه چندسری به صورت زیر محاسبه می شود:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (۴.۳)$$

که در آن Q, K, V تصویرهای خطی ورودی اند. 8 سر با $d_k = d_{\text{model}}/8 = 16$ استفاده می شود. لایه ی پیش خوران یک MLP دولایه با ReLU و بعد 512 اعمال می کند. اتصالات باقیمانده و نرمال سازی لایه آموزش را پایدار می کنند.

۶.۳ پیش بینی درمان کم نمونه

۱.۶.۳ پروتکل اپیزودیک

هر اپیزود نمونه برداری می کند:

- K نمونه پشتیبان به‌ازای هر کلاس (پیش‌فرض $K = 5$).
 - Q نمونه پرس‌وجو به‌ازای هر کلاس (پیش‌فرض $Q = 15$).
 - 2 کلاس: قابل تحقق (1) و غیرقابل تحقق (0).
- جمع: $2K$ پشتیبان، $2Q$ پرس‌وجو در هر اپیزود.

۲.۶.۳ سر نمونه‌ی اولیه‌ای

برای مجموعه پشتیبان S_k کلاس k :

$$\mathbf{c}_k = \frac{1}{K} \sum_{(x_i, y_i) \in S_k} f_\theta(x_i) \quad (۷.۳)$$

برای پرس‌وجو x ، لگاریتم‌های شانس:

$$z_k = \frac{\langle f_\theta(x), \mathbf{c}_k \rangle}{\|f_\theta(x)\| \|\mathbf{c}_k\|} \cdot \tau \quad (۸.۳)$$

که در آن $\tau = 10$ دماست. احتمالات: $\text{softmax}(z)$.

۳.۶.۳ تابع هزینه

از زیان کانونی برای مدیریت نامتعادلی کلاس استفاده می‌شود:

$$\mathcal{L} = -\alpha(1-p)^\gamma \log p \quad (۹.۳)$$

با $\gamma = 2$ و α از وزن‌های کلاس. آنتروپی متقاطع حالت ویژه‌ی $\gamma = 0$ است.

۴.۶.۳ تصویر فضای متریک

برای بهبود توان تفکیک فضای نهفته، یک MLP تصویر اختیاری بین خروجی رمزگذار و محاسبه‌ی نمونه‌ی اولیه‌ی بررسی می‌شود:

$$g_\phi(\mathbf{h}) = W_2 \cdot \text{GELU}(\text{BN}(W_1 \cdot \mathbf{h} + b_1)) + b_2 \quad (۱۰.۳)$$

که در آن $W_2 \in \mathbb{R}^{d_p \times d_h}$, $W_1 \in \mathbb{R}^{d_h \times d}$ ، با $d = 128$, $d_h = 256$, $d_p = 64$ و BatchNorm و Dropout (0.2) پس از لایه‌ی اول اعمال می‌شوند. تصویر بعد نهفته را از 128 به 64 کاهش می‌دهد و فضای متریک فشرده‌ای برای محاسبه‌ی فاصله‌ی نمونه‌ی اولیه‌ی بهینه می‌سازد. پارامتر τ با $\tau = \exp(\log \tau_0)$ قابل آموختن می‌شود تا مدل تیزی توزیع احتمال را تطبیقی کنترل کند.

۵.۶.۳ آموزش

تا ۱,۵۰۰ اپیزود آموزش، صبر زودتوقف 10. بهینه‌ساز: AdamW با وزن‌زدایی 10^{-4} و زمان‌بندی نرخ یادگیری کسینوسی (از 10^{-3} تا 10^{-5}). رمزگذار و سر نرخ‌های یادگیری متفاوت دارند (رمزگذار: 10^{-4} ، سر: 10^{-3}) تا بازنمایی‌های ازپیش‌آموزش‌دیده حفظ شود درحالی‌که سر طبقه‌بندی تطبیق می‌یابد. برش گرادیان (حداکثر نرم 1.0) ناپایدگی آموزش را مهار می‌کند. اعتبارسنجی: 100 اپیزود.

۷.۳ سر شبکه‌ی رابطه (جایگزین)

به‌عنوان جایگزین سر نمونه‌ی اولیه‌ای، سر شبکه‌ی رابطه [Sung et al., 2018] پیاده‌سازی می‌شود که شباهت کسینوسی ثابت را با مازول رابطه‌ی آموخته‌شده جایگزین می‌کند. با بردار نهفته پرس‌وجو $\mathbf{q} = f_\theta(x)$ و نمونه‌ی اولیه‌ی کلاس $\mathbf{c}_k$ ، نمره‌ی رابطه توسط MLP دولایه محاسبه می‌شود:

$$\mathbf{h} = \text{ReLU}(W_1[\mathbf{q}; \mathbf{c}_k; \mathbf{q} \odot \mathbf{c}_k; |\mathbf{q} - \mathbf{c}_k|] + b_1) \in \mathbb{R}^{256} \quad (۱۱.۳)$$

$$r_k = \sigma(W_2 \mathbf{h} + b_2) \in [0, 1] \quad (۱۲.۳)$$

که در آن ورودی چهار ویژگی تعامل را به هم می‌چسباند: بردارهای نهفته خام ($2 \times 128 = 256$ بعد)، حاصل ضرب درایه‌ای (128 بعد)، و قدر مطلق تفاوت (128 بعد)، که ورودی 640-بعدی به ماژول رابطه می‌دهد. هزینه میانگین مربعات خطاست:

$$\mathcal{L}_{\text{relation}} = \frac{1}{|\mathcal{Q}|} \sum_{(x,y) \in \mathcal{Q}} \sum_{k=0}^1 (r_k(x) - \mathbb{I}[y = k])^2 \quad (13.3)$$

الگوریتم ۲ رویه‌ی آموزش شبکه‌ی رابطه‌ی اپیزودیک را شرح می‌دهد.

Algorithm 2 آموزش اپیزودی شبکه‌ی رابطه

Require: Encoder f_θ , relation module g_ϕ , support shots K , query shots Q

```

1: for each episode do
2:   Sample  $\mathcal{S}_0, \mathcal{S}_1$  ( $K$  per class),  $\mathcal{Q}_0, \mathcal{Q}_1$  ( $Q$  per class)
3:    $\mathbf{c}_k \leftarrow \frac{1}{K} \sum_{x \in \mathcal{S}_k} f_\theta(x)$  for  $k \in \{0, 1\}$ 
4:    $\mathcal{L} \leftarrow 0$ 
5:   for each  $(x, y) \in \mathcal{Q}_0 \cup \mathcal{Q}_1$  do
6:      $\mathbf{q} \leftarrow f_\theta(x)$ 
7:     for  $k \in \{0, 1\}$  do
8:        $r_k \leftarrow g_\phi(\mathbf{q}, \mathbf{c}_k)$ 
9:        $\mathcal{L} \leftarrow \mathcal{L} + (r_k - \mathbb{I}[y = k])^2$ 
10:    end for
11:  end for
12:  Update  $\theta, \phi$  via backpropagation on  $\mathcal{L}$ 
13: end for
14: return  $\theta, \phi$ 

```

شبکه‌ی رابطه تقریباً 0.2 مگاپارامتر، برای MLP رابطه، به 1.8 مگاپارامتر رمزگذار می‌افزاید. در آزمایش حذف‌بخشی، سر رابطه AUROC قابل مقایسه‌ای با سر نمونه‌ی اولیه‌ای به‌دست آورد؛ اختلاف در حدود 0.01 بود. این نتیجه نشان می‌دهد برای این وظیفه‌ی دودویی، متریک کسینوسی ثابت تا حد زیادی کافی است و گلوگاه اصلی بیشتر در بازنمایی‌های رمزگذار قرار دارد، نه در تابع شباهت.

۸.۳ آموزش فدرال

۱.۸.۳ افراز گره

داده‌ها بر اساس تشخیص اولیه‌ی ICD-10 به 5 گره بیماری افراز می‌شوند و چندموسسه‌ای را شبیه‌سازی می‌کنند که هر «موسسه» در حوزه‌ای از بیماری تخصص دارد. جدول ۶.۳ جزئیات افراز را می‌آورد.

ماهیت غیر-IID آشکار است: اندازه‌ی گره‌ها متفاوت است (۲۶۷-۲۲۸ بیمار)، و نرخ‌های امکان‌پذیری بین گره‌ها (۳۸ تا ۴۶٪) فرق دارد. این ناهمگونی می‌آزمايد آیا تجميع فدرال می‌تواند مدلی سراسری بیاموزد که بر

جدول ۶.۳: افراز گره‌ی فدرال (مجموعه‌ی آموزش)

گره بیماری	کدهای ICD-10 n (آموزش) درصد قابل تحقق
۱ سپسیس	A40, A41, R652 ≈ 264 ۳۸%
۲ قلبی	I21, I22, I25, I50, I47-49 ≈ 255 ۴۵%
۳ تنفسی	J18, J44, J96, J80, J15 ≈ 228 ۴۱%
۴ کلیوی	N17, N18, N19 ≈ 267 ۳۹%
۵ دیابت	E10, E11, E13 ≈ 266 ۴۶%

توزیع‌های بیماری‌محور تعمیم یابد.

۲.۸.۳ پروتکل FedAvg

پروتکل استاندارد میانگین‌گیری فدرال (FedAvg) [McMahan et al., 2017] با پیکربندی زیر پیاده‌سازی می‌شود:

- دورهای ارتباطی: $T = 20$ AUROC اعتبارسنجی تا دور 15-20 اشباع می‌شود.
 - دوره‌های محلی: $E = 3$ در هر دور. هر گره پیش از ارسال به‌روزرسانی‌ها 3 گذر کامل روی داده‌ی محلی آموزش می‌بیند.
 - اندازه‌ی دسته‌ی محلی: 32.
 - وزن‌های تجمیع: متناسب با اندازه‌ی مجموعه‌داده‌ی محلی: $w_k = n_k / \sum_j n_j$.
 - نرخ یادگیری: همانند متمرکز (10^{-3} برای سر، 10^{-4} برای رمزگذار).
 - انتخاب کلاینت: مشارکت کامل (همه‌ی 5 گره در هر دور شرکت می‌کنند).
- گام تجمیع سرور میانگین وزنی همه‌ی پارامترهای مدل را محاسبه می‌کند:

$$\theta_{t+1} = \sum_{k=1}^5 \frac{n_k}{\sum_j n_j} \theta_t^{(k)} \quad (14.3)$$

برای معماری ما، مدل کامل (≈ 2 مگاپارامتر) هر دور ارسال می‌شود. هزینه‌ی ارتباطی کل: $5 \text{ nodes} \times 20 \text{ rounds} \times 2 \text{ directions} \times 8 \text{ MB} \approx 1.6 \text{ GB}$ است.

۳.۸.۳ پارامترهای مشترک در برابر محلی

رمزگذار ETHOS بین گره‌ها مشترک است و همه‌ی گره‌ها از بازنمایی سراسری بهره می‌برند. سر نمونه‌ی اولیه‌ای نیز مشترک است؛ سرهای محلی به دلیل ناکافی بودن داده‌ی محلی برای تخصص سر، عملکرد را 1-2% AUROC کاهش می‌دهند. هر گره گرادیان روی داده‌ی محلی محاسبه و مدل به‌روزشده‌ی کامل را به سرور می‌فرستد.

۴.۸.۳ پایش همگرایی

همگرایی با ردیابی AUROC اعتبارسنجی سراسری پس از هر دور پایش می‌شود. معیار همگرایی: بدون بهبود در AUROC اعتبارسنجی برای 5 دور متوالی. در عمل، همگرایی برای بیشتر پیکربندی‌های ابرپارامتر تا دور 15-18 رخ می‌دهد. $T = 20$ به عنوان کران بالای محافظه کارانه تنظیم شده است.

۹.۳ معماری ترکیبی ETHOS و جنگل تصادفی

با انگیزه از مشاهده‌ی اینکه بردارهای نهفته ETHOS سیگنال مکمل نسبت به ویژگی‌های جدولی مهندسی شده می‌گیرند، معماری ترکیبی طراحی می‌شود. برای هر بیمار i :

$$\mathbf{x}_{\text{hybrid}}^{(i)} = [\mathbf{e}_{\text{ETHOS}}^{(i)}; \mathbf{x}_{\text{tab}}^{(i)}] \in \mathbb{R}^{153} \quad (۱۵.۳)$$

که در آن $\mathbf{e}_{\text{ETHOS}} \in \mathbb{R}^{128}$ نهفته‌سازی ETHOS CLS و $\mathbf{x}_{\text{tab}} \in \mathbb{R}^{25}$ بردار ویژگی جدولی مهندسی شده است. طبقه‌بند Random Forest با RandomizedSearchCV (50 آزمایش، اعتبارسنجی متقاطع لایه‌بندی شده 5-تایی) روی بازنمایی به هم چسبانده شده آموزش داده می‌شود. تنظیم آستانه روی مجموعه‌ی اعتبارسنجی F1 را پیشنهاد می‌کند. این معماری ظرفیت یادگیری بازنمایی transformer را با طبقه‌بندی مقاوم روش‌های گروهی مبتنی بر گرادیان ترکیب می‌کند و گلوگاه بازنمایی شناسایی شده در مطالعه‌ی حذف بخشی را پوشش می‌دهد.

همچنین RF تنها روی بردارهای نهفته ETHOS (128-بعدی) ارزیابی می‌شود تا سهم بازنمایی‌های آموزش دیده از ویژگی‌های مهندسی شده جدا شود.

۱۰.۳ پروتکل ارزیابی

۱.۱۰.۳ معیارها

چند معیار برای پوشش جنبه‌های مختلف عملکرد گزارش می‌شود. هر معیار رسماً در ادامه تعریف می‌شود.

۱.۱.۱۰.۳ AUROC (مساحت زیر منحنی مشخصه‌ی عملیاتی گیرنده)

معیار ارزیابی اصلی. برای طبقه‌بند دودویی با تابع نمره $s(x)$ ، منحنی ROC نرخ مثبت درست (TPR، حساسیت) را در برابر نرخ مثبت نادرست (FPR، 1 منهای اختصاصیت) با تغییر آستانه‌ی تصمیم رسم می‌کند:

$$\text{AUROC} = \int_0^1 \text{TPR}(t) d(\text{FPR}(t)) = P(s(x^+) > s(x^-)) \quad (۱۶.۳)$$

که در آن x^+ نمونه‌ی مثبت و x^- نمونه‌ی منفی به صورت تصادفی انتخاب شده‌اند. AUROC نسبت به آستانه نامتغیر و نسبت به نامتعادلی کلاس مقاوم است. AUROC با قاعده‌ی ذوزنقه‌ای (sklearn.metrics.roc_auc_score) محاسبه می‌شود. مقادیر: 0.5 تصادفی؛ 0.7–0.8 قابل قبول برای پشتیبانی تصمیم بالینی؛ 0.8–0.9 خوب؛ ارقامی بالای 0.9 عالی. بهترین مدل ما (AUROC 0.76) در بازه‌ی قابل قبول قرار دارد.

۲.۱.۱۰.۳ دقت، فراخوانی، و امتیاز F1

برای کلاس k با مثبت درست (TP)، مثبت نادرست (FP)، و منفی نادرست (FN):

$$\text{Precision}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FP}_k} \quad (۱۷.۳)$$

$$\text{Recall}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FN}_k} \quad (۱۸.۳)$$

$$\text{F1}_k = \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} = \frac{2\text{TP}_k}{2\text{TP}_k + \text{FP}_k + \text{FN}_k} \quad (۱۹.۳)$$

از امتیاز F1 کلان، یعنی میانگین بدون وزن امتیازهای F1 به‌ازای هر کلاس، برای جلوگیری از تسلط

کلاس اکثریت استفاده می‌شود:

$$\text{Macro-F1} = \frac{1}{N} \sum_{k=1}^N \text{F1}_k = \frac{\text{F1}_0 + \text{F1}_1}{2} \quad (۲۰.۳)$$

۳.۱.۱۰.۳ ضریب همبستگی متیوز (MCC)

MCC معیاری متعادل برای طبقه‌بندی دودویی فراهم می‌کند و هر چهار خانه‌ی ماتریس سردرگمی را در نظر می‌گیرد:

$$\text{MCC} = \frac{\text{TP} \cdot \text{TN} - \text{FP} \cdot \text{FN}}{\sqrt{(\text{TP} + \text{FP})(\text{TP} + \text{FN})(\text{TN} + \text{FP})(\text{TN} + \text{FN})}} \quad (۲۱.۳)$$

MCC از -1 (طبقه‌بندی کاملاً اشتباه) از طریق 0 (پیش‌بینی تصادفی) تا $+1$ (طبقه‌بندی کامل) متغیر است. برخلاف دقت، MCC حتی با کلاس‌های بسیار نامتعادل معنادار است. مدلی که همیشه کلاس اکثریت را پیش‌بینی کند دقت $0.58 \approx$ ولی $\text{MCC} = 0$ دارد.

۴.۱.۱۰.۳ دقت (Accuracy)

دقت طبقه‌بندی استاندارد:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (۲۲.۳)$$

دقت برای کامل بودن گزارش می‌شود اما به‌عنوان معیار اصلی به‌دلیل نامتعادلی کلاس (42% قابل تحقق) استفاده نمی‌شود.

۵.۱.۱۰.۳ نمره‌ی Brier

برای ارزیابی کالیبراسیون احتمالی:

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2 \quad (۲۳.۳)$$

که در آن p_i احتمال پیش‌بینی شده و $y_i \in \{0, 1\}$ برچسب درست است. کمتر بهتر است؛ 0.25 متناظر با پیش‌بیننده‌ی ثابت در 0.5 است.

۶.۱.۱۰.۳ معناداری و محدودیت مقایسه آماری

معناداری با رویکردهای زیر و با احتیاط تفسیر می‌شود:

۱. **فواصل اطمینان bootstrap:** مجموعه‌ی آزمون با جایگزینی $1,000$ بار نمونه‌برداری مجدد، معیار

برای هر نمونه محاسبه، و صدک‌های $2.5-97.5$ به‌عنوان فاصله اطمینان 95% گزارش می‌شود.

۲. **آزمون DeLong [DeLong et al., 1988]:** فقط زمانی معتبر است که دو مدل روی همان نمونه‌های

آزمون و با بردارهای پیش‌بینی هم‌تراز ارزیابی شده باشند. فرض صفر برابری دو AUROC است.

از آنجا که همه مدل‌های این پایان‌نامه بردارهای پیش‌بینی هم‌تراز تحت یک پروتکل واحد تولید نمی‌کنند، مقایسه جفتی رسمی برای همه سطرهای نتایج قابل ادعا نیست. بنابراین در فصل نتایج، بازه‌های اطمینان در مواردی که واقعاً تولید شده‌اند گزارش می‌شود و مقایسه‌های بین پروتکلی به‌صورت توصیفی تفسیر می‌گردد.

۷.۱.۱۰.۳ پایداری (واریانس)

برای ارزیابی اپیزودیک کم‌نمونه، انحراف معیار AUROC در 100 اپیزود نمونه‌برداری شده گزارش می‌شود:

$$\text{Stability} = \sqrt{\frac{1}{M-1} \sum_{m=1}^M (\text{AUROC}_m - \overline{\text{AUROC}})^2} \quad (24.3)$$

که در آن $M = 100$ اپیزود است. واریانس کمتر عملکرد کم‌نمونه پایدارتر در ترکیب‌های تصادفی اپیزود را نشان می‌دهد.

۲.۱۰.۳ خط پایه‌ها

• رگرسیون لجستیک (class_weight=balanced).

• Random Forest (تنظیم شده).

• XGBoost (تنظیم شده).

• LightGBM (تنظیم شده).

- CatBoost (تنظیم شده).

- شبکه‌ی عصبی استاندارد (بدون کم‌نمونه).

- شبکه‌ی عصبی فدرال (بدون کم‌نمونه).

همه پیش‌پردازش یکسان و همان تقسیم‌های آموزش/اعتبار/آزمون را دارند.

۳.۱۰.۳ تنظیم آستانه

برای طبقه‌بندی دودویی، آستانه‌ی تصمیم $\theta \in [0.3, 0.7]$ روی مجموعه‌ی اعتبارسنجی برای بیشینه کردن F1 تنظیم می‌شود. آستانه‌ی بهینه (0.54 برای Random Forest) روی مجموعه‌ی آزمون اعمال می‌شود. AUROC نسبت به آستانه نامتغیر است؛ F1 و دقت به θ وابسته‌اند.

۱۱.۳ جزئیات پیاده‌سازی

۱.۱۱.۳ بهینه‌سازی

برای ETHOS از Adam [Kingma and Ba, 2015] با نرخ یادگیری $\beta_1 = 0.001$ ، $\beta_2 = 0.999$ استفاده می‌شود. اندازه‌ی دسته برای آموزش اپیزودیک 32 است. Dropout [Srivastava et al., 2014] (0.2) پس از لایه‌های توجه و پیش‌خوران اعمال می‌شود. نرمال‌سازی لایه [Ba et al., 2016] آموزش را پایدار می‌کند.

۲.۱۱.۳ منظم‌سازی

زودتوقف با نظارت بر هزینه‌ی اعتبارسنجی و صبر 10 دوره. گرادیان‌ها به حداکثر نرم 1.0 برش داده می‌شوند تا انفجار جلوگیری شود. وزن‌زدایی (L2) برای رمزگذار 1×10^{-5} است. وزن‌های کلاس نامتعادلی زیان کانونی را برای توزیع برچسب 42/58 متعادل می‌کنند.

۳.۱۱.۳ بازتولیدپذیری

همه‌ی آزمایش‌ها random_seed=42 در NumPy، PyTorch و scikit-learn دارند. تقسیم‌های داده ثابت و ذخیره می‌شوند؛ بدون برهم‌زدن بین اجراها. شبکه‌های ابرپارامتر در پیوست آ هستند.

۱۲.۳ شبه‌کد الگوریتم

۱.۱۲.۳ آموزش کم‌نمونه نمونه‌ی اولیه‌ای

الگوریتم ۳ رویه‌ی آموزش اپیزودیک را خلاصه می‌کند. هر اپیزود مجموعه پشتیبان $\mathcal{S}$ و مجموعه پرس‌وجو $\mathcal{Q}$ را نمونه‌برداری می‌کند؛ مدل نمونه‌های اولیه را از $\mathcal{S}$ محاسبه و آنتروپی متقاطع روی $\mathcal{Q}$ را کمینه می‌کند.

Algorithm 3 آموزش اپیزودی کم‌نمونه‌های

Require: Encoder f_θ , support shots K , query shots Q , temperature τ

```

1: for each episode do
2:    $\mathcal{L} \leftarrow 0$ 
3:   Sample  $\mathcal{S}_0, \mathcal{S}_1$  ( $K$  examples per class)
4:   Sample  $\mathcal{Q}_0, \mathcal{Q}_1$  ( $Q$  examples per class)
5:    $\mathbf{c}_k \leftarrow \frac{1}{K} \sum_{x \in \mathcal{S}_k} f_\theta(x)$  for  $k \in \{0, 1\}$ 
6:   for each  $x \in \mathcal{Q}_0 \cup \mathcal{Q}_1$  do
7:      $z_k \leftarrow \langle f_\theta(x), \mathbf{c}_k \rangle / (\|f_\theta(x)\| \|\mathbf{c}_k\|) \cdot \tau$ 
8:      $\mathcal{L} \leftarrow \mathcal{L} + \text{CrossEntropy}(\text{softmax}(z), y)$ 
9:   end for
10:  Update  $\theta$  via backpropagation
11: end for
12: return  $\theta$ 
```

۲.۱۲.۳ میانگین‌گیری فدرال

الگوریتم ۴ پروتکل FedAvg را شرح می‌دهد. هر گره به مدت E دوره به صورت محلی آموزش می‌بیند، سپس سرور پارامترهای مدل را با وزن اندازه‌ی مجموعه داده‌ی محلی تجمع می‌کند.

Algorithm 4 (FedAvg) میانگین‌گیری فدرال

Require: Nodes $\{1, \dots, N\}$, local data $\mathcal{D}_k$, rounds T

```

1: Initialize global model  $\theta_0$ 
2: for round  $t = 1$  to  $T$  do
3:   Server broadcasts  $\theta_t$  to all nodes
4:   for each node  $k$  do
5:      $\theta_t^{(k)} \leftarrow \theta_t$ 
6:     for epoch  $e = 1$  to  $E$  do
7:        $\theta_t^{(k)} \leftarrow \theta_t^{(k)} - \eta \nabla \mathcal{L}_k(\theta_t^{(k)})$ 
8:     end for
9:     Send  $\theta_t^{(k)}$  to server
10:  end for
11:   $\theta_{t+1} \leftarrow \sum_k \frac{n_k}{n} \theta_t^{(k)}$ 
12: end for
13: return  $\theta_T$ 
```

۳.۱۲.۳ یادداشت درباره‌ی محیط الگوریتم

شبه‌کد به صورت انگلیسی و با ارقام لاتین (محیط latin) حروف چینی می‌شود تا با متن فارسی اطراف تداخل جهت و شکل ارقام نداشته باشد. از محیط‌های algorithm و algorithmic استفاده شده است.

۱۳.۳ پیچیدگی محاسباتی

۱.۱۳.۳ رمزگذار ETHOS

برای طول دنباله $L = 25$ ، بعد نهفته $d = 128$ و $L_{\text{layers}} = 2$ لایه‌ی transformer، رمزگذار در هر گذر رو به جلو پیچیدگی $O(L^2d + Ld^2)$ دارد. با اندازه‌ی دسته 32 و 500 اپیزود در هر دوره، آموزش تقریباً 2-3 دقیقه در هر دوره روی CPU استاندارد طول می‌کشد. شتاب‌دهی GPU این زمان را به کمتر از 30 ثانیه در هر دوره کاهش می‌دهد.

۲.۱۳.۳ ارتباط فدرال

با 5 گره و 20 دور، 100 گام ارتباطی انجام می‌شود. هر گام مدل کامل (رمزگذار + سر) را منتقل می‌کند؛ برای معماری ما این ≈ 2 مگابایت است. در استقرار واقعی، فشردگی‌سازی گرادینان یا به‌روزرسانی‌های جزئی می‌تواند پهنای باند را کاهش دهد.

۳.۱۳.۳ جایگزین‌های توکن‌سازی

طرح‌های توکن‌سازی جایگزین در نظر گرفته شدند: (۱) **بردارهای نهفته پیوسته**: استفاده از مقادیر نرمال‌شده‌ی خام به عنوان نهفته‌سازی توکن پیوسته به جای بازه‌های گسسته؛ از شناسه‌های گسسته برای سازگاری با واژگان استاندارد transformer استفاده می‌شود. (۲) **توکن‌های سلسله‌مراتبی**: کدگذاری دسته آزمایش (مثلاً کلیوی، قلبی) به عنوان توکن والد؛ ساختار مسطح برای سادگی به کار می‌رود. (۳) **بازه‌ی زمانی**: تجمیع در پنجره‌های 6 یا 12 ساعته؛ تجمیع 24 ساعت اول استفاده می‌شود. کار آینده می‌تواند این جایگزین‌ها را بررسی کند.

۴.۱۳.۳ خط پایه‌های کلاسیک

Random Forest با 200 درخت و عمق 28 در کمتر از 1 دقیقه روی کوهورت ۲,۰۰۰ بیمار آموزش می‌بیند. XGBoost و LightGBM نیز زمان مشابهی دارند. جستجوی ابرپارامتر، با ۵۰ پیکربندی و اعتبارسنجی متقاطع

۵ دوره برای هر مدل، حدود ۱۰ تا ۲۰ دقیقه به زمان اجرا می‌افزاید. کل فرایند SOTA جدولی در کمتر از ۲ ساعت کامل می‌شود.

۱۴.۳ استنتاج‌های ریاضی

۱.۱۴.۳ گرادیان هزینه‌ی نمونه‌ی اولیه‌ای

برای شبکه‌های نمونه‌ی اولیه‌ای با هزینه‌ی آنتروپی متقاطع، گرادیان هزینه نسبت به بردار نهفته پرس‌وجو $f_\theta(x)$ به صورت زیر استنتاج می‌شود. با $p_k = \exp(z_k) / \sum_{k'} \exp(z_{k'})$ که در آن $z_k = \langle f_\theta(x), \mathbf{c}_k \rangle / \tau$ برای کلاس درست y :

$$\frac{\partial \mathcal{L}}{\partial f_\theta(x)} = \frac{1}{\tau} \sum_k (p_k - \mathbb{1}[y = k]) \mathbf{c}_k \quad (25.3)$$

گرادیان بردار نهفته پرس‌وجو را به سمت نمونه‌ی اولیه‌ی درست و دور از نمونه‌ی اولیه‌ی نادرست هل می‌دهد، با بزرگی متناسب با دما τ .

۲.۱۴.۳ زیان کانونی

هزینه‌ی کانونی [Lin et al., 2017] برابر است با $\mathcal{L}_{\text{focal}} = -\alpha(1 - p_t)^\gamma \log(p_t)$ که در آن p_t احتمال پیش‌بینی شده برای کلاس درست است. برای $\gamma = 0$ این به آنتروپی متقاطع کاهش می‌یابد. برای $\gamma > 0$ ، نمونه‌های آسان (p_t بالا) با $(1 - p_t)^\gamma$ کم‌وزن می‌شوند و هزینه روی نمونه‌های سخت متمرکز می‌شود. از $\gamma = 2$ و α از وزن‌های کلاس برای نامتعادلی 42/58 استفاده می‌شود.

۳.۱۴.۳ فواصل اطمینان bootstrap

برای فواصل اطمینان bootstrap، مجموعه‌ی آزمون با جایگزینی ۱,۰۰۰ بار نمونه‌برداری مجدد می‌شود، AUROC برای هر نمونه محاسبه، و صدک‌های ۲.۵ و ۹۷.۵ به عنوان فاصله اطمینان ۹۵٪ گرفته می‌شود. مجموعه‌ی آزمون ۴۰۰ نمونه فواصل به عرض تقریبی ۰.۱۰–۰.۱۲ برای AUROC می‌دهد. آزمون DeLong فقط برای مدل‌هایی قابل اتکاست که روی همان نمونه آزمون و با بردارهای احتمال هم‌تراز ارزیابی شده باشند. چون همه خروجی‌های این پایان‌نامه چنین شرطی را ندارند، تفسیر اصلی بر برآوردهای نقطه‌ای، بازه‌های اطمینان موجود

و سلسله مراتب پروتکل ها تکیه می کند؛ آزمون های جفتی کامل تر مانند McNemar، DeLong و بوت استرپ جفتی برای کار آینده توصیه می شوند.

۴.۱۴.۳ استنتاج جایگزین SOFA و شاخص شوک

نمره SOFA (Sequential Organ Failure Assessment) اختلال اندام را کمی می کند. از جایگزین ساده شده استفاده می شود: $SOFA_{proxy} = w_1(1 - \text{creatinine}) + w_2(1 - \text{platelets}) + w_3(1 - \text{SpO}_2) + w_4(1 - \text{lactate})$ با وزن های برابر، هر جزء نرمال شده به $[0, 1]$. مقادیر بالاتر عملکرد بدتر را نشان می دهد. شاخص شوک = ضربان قلب / فشار خون سیستولیک؛ بازه ی طبیعی 0.5-0.7؛ مقادیری برای SI فراتر از 1.0 ناپایداری همودینامیک را نشان می دهند. با clip و min-max به $[0, 1]$ نرمال می شود. شاخص شوک بالا با ترخیص غیر قابل تحقق همراه است.

۱۵.۳ نمای کلی معماری نرم افزار

معماری نرم افزار به پنج لایه تقسیم شده است: (۱) **لایه داده**: استخراج MIMIC-IV با SQL، پیش پردازش، نرمال سازی، جایگزینی مقادیر گم شده و ساخت تقسیم های آموزش/اعتبار/آزمون؛ (۲) **لایه بازنمایی**: ساخت بردار ویژگی جدولی، از ۲۵ بعد پایه تا ۹۲ یا ۱۳۲ بعد با مهندسی ویژگی، و نیز تولید دنباله های توکن برای هر بیمار؛ (۳) **لایه مدل**: مدل های کلاسیک مانند sklearn RF و XGBoost، رمزگذار ETHOS، سر نمونه ی اولیه ای و مدل های ترکیبی؛ (۴) **لایه آموزش**: نمونه گیر اپیزودیک برای کم نمونه و FedAvg برای فدرال؛ و (۵) **لایه ارزیابی**: معیارهایی مانند AUROC و F1، تفسیرپذیری با SHAP، کالیبراسیون و پیش بینی مطابق. پایگاه کد ماژولار است و هر جزء را می توان مستقل از اجزای دیگر جایگزین یا گسترش داد.

۱۶.۳ معماری V5: توجه ویژگی دروازه ای با نمونه های اولیه ی متقاطع

معماری V5 دو جزء تازه برای پوشش محدودیت های شناسایی شده در V1-V4 معرفی می کند:

۱.۱۶.۳ توجه ویژگی دروازه‌ای (GFA)

با الهام از TabNet [Arik and Pfister, 2021]، ماژول GFA انتخاب ویژگی متوالی به‌ازای هر نمونه را پیاده می‌کند. در هر یک از $S = 3$ گام توجه، ماژول محاسبه می‌کند:

$$\mathbf{a}_s = \text{softmax}(\mathbf{W}_s \cdot \mathbf{h}_{\text{shared}} \odot \mathbf{p}_s) \quad (۲۶.۳)$$

$$\mathbf{p}_{s+1} = \mathbf{p}_s \cdot (\gamma - \mathbf{a}_s) \quad (۲۷.۳)$$

$$\mathbf{o}_s = \text{FC}_s(\mathbf{a}_s \odot \mathbf{x}) \quad (۲۸.۳)$$

که در آن $\mathbf{p}_s$ مقیاس پیشین (مقداردهی اولیه به 1)، $\gamma = 1.5$ ضریب تنک‌سازی، و $\mathbf{h}_{\text{shared}} = \text{FC}_{\text{shared}}(\mathbf{x})$ بافت مشترک است. خروجی تجمیع شده $\sum_s \mathbf{o}_s$ با مسیر موازی transformer از طریق دروازه‌ای آموخته‌شده ترکیب می‌شود: $\mathbf{z} = \sigma(g) \cdot \mathbf{z}_{\text{trans}} + (1 - \sigma(g)) \cdot \mathbf{z}_{\text{GFA}}$.

طراحی دومسیره به مدل اجازه می‌دهد محلی انتخاب ویژگی (GFA) را با مدل‌سازی سراسری تعامل ویژگی (transformer) ترکیب کند و هم اهمیت سطح ویژگی و هم روابط متقاطع ویژگی را بگیرد.

۲.۱۶.۳ سر نمونه‌ی اولیه‌ای متقاطع

شبکه‌ی نمونه‌ی اولیه‌ای استاندارد شباهت کسینوسی بین بردارهای نهفته پرس‌وجو و میانگین نمونه‌های اولیه‌ی کلاس را محاسبه می‌کند. سر متقاطع V5 در عوض از خودتوجه متقاطع چندسر استفاده می‌کند:

$$\mathbf{h}_{\text{cross}} = \text{MultiHead}(\mathbf{Q} = \mathbf{q}, \mathbf{K} = \mathbf{P}, \mathbf{V} = \mathbf{P}) + \mathbf{q} \quad (۲۹.۳)$$

که در آن $\mathbf{q}$ بردار نهفته پرس‌وجو (گسترش‌یافته روی کلاس‌ها) و $\mathbf{P}$ نمونه‌های اولیه‌ی کلاس‌اند. سپس MLP طبقه‌بند لگاریتم‌های شانس را از $[\mathbf{h}_{\text{cross}}; \mathbf{q}]$ تولید می‌کند، با ترکیب 50/50 با لگاریتم‌های شانس نمونه‌ی اولیه‌ای کسینوسی. این به مدل اجازه می‌دهد توابع شباهت غیرخطی و وابسته به بافت پیامزد به‌جای تکیه صرف بر معیارهای فاصله.

۱۷.۳ معماری V6: گروه عمیق ناهمگن

آزمایش V6 بررسی می‌کند آیا تنوع معماری عملکرد گروه را بهبود می‌دهد. سه معماری رمزگذار متمایز ترکیب می‌شوند:

۱. **FT-Transformer**: بردارهای نهفته‌سازی آموخته‌شده به‌ازای هر ویژگی $(\mathbf{e}_j = \mathbf{W}_j x_j + \mathbf{b}_j)$

که از لایه‌های خودتوجه با تجمیع مبتنی بر توجه عبور می‌کنند.

۲. **GFA-Transformer**: معماری دومسیره‌ی V5 که توجه ویژگی دروازه‌ای را با transformer

ویژگی‌های گروه‌بندی‌شده ترکیب می‌کند.

۳. **MLP-Mixer**: معماری بدون توجه با MLP‌های درهم‌تنیده‌ی مخلوط کردن توکن (فضایی) و

مخلوط کردن کانال (ویژگی)، اقتباس‌شده از بینایی به داده‌ی جدولی.

هر معماری با یک سر کم‌نمونه عمومی، شامل نمونه‌ی اولیه‌ای و شبکه‌ی رابطه، ترکیب می‌شود و با همان فرایند چندمرحله‌ای آموزش می‌بیند: SupCon، تقطیر دانش نظارت‌شده و آموزش اپیزودیک. فرا یادگیرنده نهایی پیش‌بینی‌های XGBoost و رگرسیون لجستیک کالیبره‌شده را ترکیب می‌کند. V6 همچنین از پیش‌بینی مطابق تقسیم‌شده برای سنجش عدم قطعیت استفاده می‌کند.

۱۸.۳ معماری‌های جایگزین مورد بررسی

چند جایگزین پیش از تثبیت طرح فعلی در نظر گرفته شد. **MAML به‌جای نمونه‌ی اولیه‌ای**: MAML انعطاف‌پذیرتر اما پرهزینه‌ی محاسباتی است؛ نمونه‌ی اولیه‌ای برای کارایی به کار می‌رود. **LSTM/RNN به‌جای transformer**: RNN‌ها می‌توانند دنباله‌های زمانی را مدل کنند؛ transformer برای موازی‌سازی و توجه روی توکن‌ها استفاده می‌شود. **فقط جدولی خام**: هم بازنمایی جدولی و هم توکن پشتیبانی می‌شود؛ ترکیبی (ETHOS + جدولی) از هر کدام بهتر عمل می‌کند. **K متفاوت**: در تحلیل حساسیت $K \in \{1, 3, 5, 7, 10, 15, 20\}$ متغیر است؛ مدل اصلی $K = 5$ دارد. **FedProx به‌جای FedAvg**: FedProx جمله‌ی مجاورتی برای غیر-IID می‌افزاید؛ FedAvg به‌عنوان خط پایه و FedProx برای کار آینده باقی می‌ماند. این انتخاب‌ها برای بازتولیدپذیری و راهنمایی گسترش‌های آینده مستند شده‌اند.

۱۹.۳ پیاده‌سازی و بازتولیدپذیری

پیاده‌سازی از Python 3.10, PyTorch 2.x برای ETHOS, scikit-learn 1.3+ برای مدل‌های کلاسیک، و pandas 2.x برای پردازش داده استفاده می‌کند. پایگاه کد به ماژول‌ها تقسیم شده است: data/ برای استخراج و پیش‌پردازش، models/ برای ETHOS و خط پایه‌ها، training/ آموزش اپیزودیک و فدرال، evaluation/ برای معیارها و SHAP. همه‌ی بذرها تصادفی ثابت (42) در NumPy, PyTorch, و scikit-learn هستند. تقسیم‌های داده روی دیسک ذخیره و در آزمایش‌ها به‌طور یکنواخت بارگذاری می‌شوند. شبکه‌های ابرپارامتر در پیوست آ هستند. فایل requirements.txt با نسخه‌های ثابت برای بازتولیدپذیری ارائه می‌شود. دسترسی به MIMIC-IV نیازمند احراز هویت PhysioNet (آموزش CITI، توافق استفاده از داده) است؛ اسکرپت‌های پیش‌پردازش فرض می‌کنند شمای استاندارد MIMIC-IV برقرار است.

۲۰.۳ فرایند داده و گام‌های پیش‌پردازش

فرایند داده شامل این گام‌هاست: (۱) **استخراج**: اجرای پرس‌وجوهای SQL روی labevents, icustays با فیلترهایی مانند اولین admissions, patients, chartevents و diagnoses_icd در MIMIC-IV، با فیلترهایی مانند اولین بستری ICU، سن $18 \geq$ ، $4 \geq$ LOS ساعت و وجود تشخیص اولیه ICD-10؛ (۲) **لایه‌بندی**: نمونه‌گیری ۲,۰۰۰ بستری بر اساس گروه تشخیص اولیه؛ (۳) **استخراج آزمایشگاه**: انتخاب 15 نوع آزمایش از 24 ساعت نخست، برش به بازه‌های بالینی و نرمال‌سازی min-max به $[0, 1]$ ؛ (۴) **استخراج علائم حیاتی**: انتخاب 7 علامت و اعمال همان نرمال‌سازی؛ (۵) **مهندسی ویژگی**: ساخت شاخص شوک، جایگزین SOFA و شمار آزمایش‌های غیرطبیعی؛ (۶) **توکن‌سازی**: تبدیل داده به دنباله توکن برای ETHOS؛ و (۷) **تقسیم**: ۶۴٪ آموزش، ۱۶٪ اعتبار و ۲۰٪ آزمون به‌صورت لایه‌بندی‌شده. همه گام‌ها با بذر 42 = قطعی شده‌اند.

۲۱.۳ جزئیات پروتکل ارزیابی

برای مدل‌های کلاسیک، برازش روی آموزش (۱,۲۸۰ نمونه)، تنظیم آستانه روی اعتبارسنجی (۳۲۰ نمونه)، و یک‌بار ارزیابی روی آزمون (۴۰۰ نمونه) انجام می‌شود. برای ETHOS و یادگیری کم‌نمونه، آموزش اپیزودیک روی آموزش، اعتبارسنجی با 100 اپیزود روی اعتبارسنجی، و ارزیابی روی آزمون داریم. ارزیابی آزمون برای ETHOS در این پایان‌نامه دو صورت دارد: (۱) ارزیابی ثابت روی کل مجموعه آزمون در Exp1 که برای Proposed_FewShot عدد منجمد ۰.۶۱۱ را گزارش می‌کند؛ (۲) نمونه‌برداری اپیزودیک (100 اپیزود، هر

کدام با K پشتیبان و Q پرس‌وجو از آزمون) که برای حساسیت K -شات به کار می‌رود و AUROC را در بازهٔ ۰.۵۵۷-۰.۵۶۴ نشان می‌دهد. دو پروتکل مقادیر مطلق متفاوتی می‌دهند؛ بنابراین در هر آزمایش صریحاً مشخص می‌کنیم کدام پروتکل مبنا بوده است. برای ارزیابی فدرال، مدل سراسری تجمیع‌شده روی گره‌ها بر کل مجموعهٔ آزمون اعمال می‌شود.

۲۲.۳ خلاصه‌ی فصل

این فصل روش‌شناسی پژوهش را شرح داد: نمادگذاری، نمای کلی فرایند، استخراج و پیش‌پردازش مجموعه‌داده، توکن‌سازی علائم، معماری رمزگذار ETHOS، پروتکل کم‌نمونه با سر نمونه‌ی اولیه‌ای، آموزش فدرال از طریق FedAvg، معیارهای ارزیابی، شبه‌کد الگوریتم‌ها، پیچیدگی محاسباتی، استنتاج‌های ریاضی، معماری نرم‌افزار، معماری‌های جایگزین، پیاده‌سازی، بازتولیدپذیری و جزئیات پروتکل ارزیابی. فصل بعدی طراحی آزمایش‌ها را ارائه می‌کند.

فصل ۴

آزمایش‌ها

این فصل چیدمان تجربی و طراحی آزمایش‌های ۱ تا ۵ را شرح می‌دهد.

۱.۴ چیدمان تجربی

۱.۱.۴ پیاده‌سازی و معماری نرم‌افزار

پیاده‌سازی آزمایش‌ها با ابزارها و کتابخانه‌های زیر انجام شده است:

- زبان و هسته: Python 3.10+.
- یادگیری عمیق: PyTorch برای رمزگذار ETHOS و آموزش کم‌نمونه.
- یادگیری ماشین کلاسیک: scikit-learn (Logistic Regression, Random Forest, معیارها), XGBoost, LightGBM, CatBoost.
- داده: NumPy, Pandas برای پیش‌پردازش و مهندسی ویژگی.
- فدرال: پیاده‌سازی سفارشی FedAvg (طراحی سازگار با PySyft برای گسترش آینده).
- تصویرسازی: Seaborn, Matplotlib برای منحنی‌های ROC و منحنی‌های یادگیری.

آزمایش‌ها روی ایستگاه کاری استاندارد با CPU چندهسته‌ای اجرا شدند. همه‌ی بذره‌ای تصادفی ثابت (seed=42) برای بازتولیدپذیری تنظیم شده‌اند. برای نیازمندی‌ها و جزئیات محیط، پیوست خ را ببینید.

۲.۱.۴ پیکربندی داده

- مجموعه داده: MIMIC-IV v3.1.
- اندازه کوهورت: ۲,۰۰۰ بیمار.
- تقسیم‌ها: ۶۴٪ آموزش (۱,۲۸۰)، ۱۶٪ اعتبارسنجی (۳۲۰)، ۲۰٪ آزمون (۴۰۰).
- گره‌های بیماری: ۵ (سپسیس، قلبی، تنفسی، کلیوی، دیابت).
- ویژگی‌ها: ۲۵ بعد (۲۲ پایه + ۳ مهندسی شده).

۳.۱.۴ پیکربندی ETHOS و یادگیری کم‌نمونه

- $K = 5$ پشتیبان، $Q = 15$ پرس‌وجو به‌ازای هر کلاس.
- ۵۰۰ اپیزود آموزشی به‌ازای هر دوره، ۱۰۰ اپیزود اعتبارسنجی.
- ۵۰ دوره، صبر توقف زود هنگام ۱۰.
- دما $\tau = 10$ ، زیان کانونی $\gamma = 2$.
- نرخ یادگیری ۰.۰۰۱، بهینه‌ساز Adam.

۴.۱.۴ پیکربندی خط پایه کلاسیک

- RandomizedSearchCV با ۵۰-۸۰ آزمون (XGBoost, Random Forest)، ۵۰ آزمون (CatBoost, LightGBM).
- اعتبارسنجی متقاطع لایه‌ای ۵-تایی روی آموزش+اعتبارسنجی.
- امتیازدهی: AUROC.
- تنظیم آستانه روی اعتبارسنجی: $\theta \in [0.3, 0.7]$ ، گام ۰.۰۱، بیشینه‌سازی F1.

۲.۴ فرضیات آزمایش

هر آزمایش برای آزمون فرضیات مشخص طراحی شده است:

جدول ۱.۴: فرضیات آزمایش و پیامدهای مورد انتظار

Exp	فرضیه	پیامد مورد انتظار
1	کم‌نمونه می‌تواند خطوط پایه کلاسیک را جبران کند	مقایسه AUROC بین مدل‌ها
2	K بزرگ‌تر عملکرد کم‌نمونه را بهبود می‌دهد	افزایش AUROC با K
3	فدرال هزینه ناچیز در برابر متمرکز دارد	شکاف کمتر از 2٪ AUROC
4	وزن‌دهی شدت بحرانی است	حذف، AUROC را به‌طور محسوسی کاهش می‌دهد
5	مدل به گره‌های بیماری دیده‌نشده تعمیم می‌یابد	$AUROC > 0.55$ روی گره‌های نگه‌داشته‌شده

۳.۴ توان آماری و اندازه نمونه

با ۴۰۰ نمونه آزمون و تقسیم کلاس ۵۸/۴۲، تقریباً ۱۶۸ مثبت و ۲۳۲ منفی داریم. برای تشخیص اختلاف AUROC به میزان ۰.۱۰ (مثلاً ۰.۷۶ در برابر ۰.۶۶) با توان ۸۰٪ و $\alpha = 0.05$ ، آزمون DeLong تقریباً ۱۰۰-۲۰۰ نمونه به‌ازای هر گروه لازم دارد؛ مجموعه آزمون ما این شرط را برآورده می‌کند. بازه‌های اطمینان بوت‌استرپ (۱,۰۰۰ نمونه‌برداری مجدد) برآوردهای پایدار می‌دهند؛ برای معیارهای کلیدی بازه‌ی اطمینان ۹۵٪ گزارش می‌کنیم.

۴.۴ مشخصات سخت‌افزار و نرم‌افزار

آزمایش‌ها روی ایستگاه کاری استاندارد انجام شد: Intel Core i7 یا معادل، ۱۶ تا ۳۲ گیگابایت RAM، GPU. انویدیا اختیاری (CUDA 11.x). زمان‌های آموزش: Random Forest حدود یک دقیقه؛ آموزش ETHOS با ۵۰ دوره حدود دو تا سه ساعت روی CPU یا حدود ۱۵ دقیقه با GPU. نرم‌افزار: Python 3.10، PyTorch 2.x، scikit-learn 1.3+، XGBoost 2.x، pandas 2.x. همه‌ی وابستگی‌ها در requirements.txt فهرست شده‌اند (پیوست خ).

۵.۴ فلسفه طراحی آزمایش

آزمایش‌ها به‌صورت سلسله‌مراتبی طراحی شده‌اند: (۱) ابتدا خطوط پایه قوی با ML کلاسیک ساخته می‌شوند؛ (۲) سپس رویکردهای عصبی و کم‌نمونه با آن‌ها مقایسه می‌شوند؛ (۳) با حذف تدریجی اجزاء، سهم هر بخش بررسی می‌شود؛ و (۴) تعمیم فدرال و بین‌بیماری ارزیابی می‌گردد. بذره‌ای تصادفی و تقسیم‌های داده ثابت نگه‌داشته شده‌اند تا بازتولیدپذیری حفظ شود. هر آزمایش با پیکربندی مشخص اجرا و برآورد نقطه‌ای آن گزارش می‌شود؛

بازه‌های اطمینان بوت‌استرپ و آزمون‌های آماری در فصل ۵ آمده‌اند.

۶.۴ رویه اجرای آزمایش

همه‌ی آزمایش‌ها از رویه استاندارد پیروی می‌کنند: (۱) بارگذاری داده‌ی پیش‌پردازش‌شده (تقسیم‌های آموزش/اعتبارسنجی/آزمون)؛ (۲) برای مدل‌های کلاسیک: برازش روی آموزش، تنظیم آستانه روی اعتبارسنجی، ارزیابی روی آزمون؛ (۳) برای چارچوب ETHOS و یادگیری کم‌نمونه: آموزش اپیزودیک روی آموزش، اپیزودهای اعتبارسنجی روی اعتبارسنجی، ارزیابی روی آزمون؛ (۴) برای فدرال: پارتیشن بر اساس گره بیماری، اجرای FedAvg برای ۲۰ دور، ارزیابی مدل سراسری روی آزمون؛ (۵) ثبت معیارها (F1، AUROC، و غیره) و ذخیره مدل‌ها. از داده‌ی آزمون برای انتخاب مدل استفاده نمی‌شود. همه‌ی آزمایش‌ها از همان تقسیم‌های ثابت (seed=42) استفاده می‌کنند.

۷.۴ پیکربندی‌های مدل خط پایه

پیکربندی تفصیلی برای هر خط پایه ارائه می‌شود؛ مقادیر فنی برای جلوگیری از شکستن جهت متن و برش حاشیه در یک بلوک لاتین چپ‌به‌راست دست‌نخورده می‌آید (با قلم monospace). شماره‌های گزارشی بهترین‌ها (۲۰۰، ۲۸، و امثال آن) در توضیح فارسی حفظ شده‌اند.

Logistic Regression. L2 penalty (C=1.0). class_weight=balanced. max_iter=1000.

Random Forest. Selected via RandomizedSearchCV: n_estimators=200; max_depth=28;

min_samples_split=5; min_samples_leaf=2; max_features=log2.

XGBoost. n_estimators=200; max_depth=6; learning_rate=0.05; subsample=0.8;

colsample_bytree=0.8.

LightGBM. n_estimators=200; max_depth=6; learning_rate=0.05; num_leaves=31.

CatBoost. iterations=200; depth=6; learning_rate=0.05.

همه‌ی مدل‌های کلاسیک از همان بردار ویژگی جدولی ۲۵-بعدی و تقسیم‌های یکسان آموزش/اعتبارسنجی/

آزمون استفاده می‌کنند. تنظیم آستانه روی مجموعه اعتبارسنجی برای همه‌ی مدل‌ها برای بیشینه‌سازی F1 انجام می‌شود؛ آستانه تنظیم‌شده برای ارزیابی نهایی روی آزمون اعمال می‌شود.

۸.۴ معیارهای ارزیابی و گزارش

برای همه‌ی مدل‌ها AUROC (اصلی)، امتیاز F1 کلان، Precision، Recall، Accuracy و MCC گزارش می‌کنیم. AUROC نسبت به آستانه‌ی تصمیم مستقل است و برای داده‌ی نامتعادل مناسب‌تر از اتکا به یک آستانه‌ی ثابت است. امتیاز F1 کلان میانگین F1 به‌ازای هر کلاس را می‌گیرد تا سلطه‌ی کلاس اکثریت را کاهش دهد. همچنین بازه‌های اطمینان ۹۵ درصد بوت‌استرپ (۱,۰۰۰ نمونه‌برداری مجدد) برای معیارهای کلیدی گزارش می‌کنیم. آزمون‌های جفتی مانند DeLong فقط زمانی معتبرند که بردارهای پیش‌بینی هم‌تراز روی همان نمونه‌های آزمون موجود باشد؛ بنابراین مقایسه‌های بین پروتکلی در این پایان‌نامه عمدتاً توصیفی تفسیر می‌شوند. همه‌ی معیارها روی مجموعه‌ی آزمون نگه‌داشته‌شده محاسبه می‌شوند و از داده‌ی آزمون برای انتخاب مدل یا تنظیم ابرپارامتر استفاده نمی‌شود. برای ارزیابی کم‌نمونه، ۱۰۰ اپیزود نمونه‌برداری می‌کنیم؛ هر اپیزود K پشتیبان و Q پرس‌وجو به‌ازای هر کلاس دارد. میانگین و انحراف معیار بین اپیزودها را گزارش می‌کنیم. برای مدل‌های کلاسیک یک‌بار روی کل مجموعه‌ی آزمون ارزیابی می‌کنیم. تفاوت پروتکل‌ها بدین معناست که معیارهای آزمایش K-شات (در این مخزن حدود ۰.۵۶۴-۰.۵۵۷ AUROC) مستقیماً با ارزیابی ثابت Exp1 برای Proposed_FewShot (۰.۶۱۱) قابل تعویض نیستند.

۹.۴ آزمایش ۱: مقایسه‌ی مدل اصلی

۱.۹.۴ هدف

مقایسه‌ی چارچوب ETHOS و مدل پیشنهادی کم‌نمونه با خطوط پایه‌ی کلاسیک و عصبی روی مجموعه‌ی آزمون.

۲.۹.۴ مدل‌ها

- LogisticRegression
- RandomForest
- XGBoost
- StandardNN (MLP، بدون کم‌نمونه)
- FederatedNN_NoFewShot (MLP فدرال، بدون کم‌نمونه)
- مدل پیشنهادی کم‌نمونه (ETHOS + سر نمونه‌اولیه)

۳.۹.۴ خلاصه نتایج

مدل پیشنهادی کم‌نمونه به AUROC ۰.۶۱۱، F1 ۰.۵۷۲، و دقت ۰.۵۸۳ می‌رسد. بهترین مدل کلاسیک در همین پروتکل Random Forest است که AUROC ۰.۷۶۲، F1 ۰.۶۷۹، و دقت ۰.۷۱۸ دارد. این اعداد با جدول ۳.۵ در فصل ۵ همگام‌اند.

۱۰.۴ آزمایش ۲: حساسیت K-شات

۱.۱۰.۴ هدف

هدف این آزمایش، سنجش اثر تعداد نمونه‌های پشتیبان K بر عملکرد کم‌نمونه است. در این چارچوب، K تعداد نمونه برچسب‌خورده برای هر کلاس در مجموعه پشتیبان است. افزایش K اطلاعات بیشتری برای ساخت نمونه‌های اولیه فراهم می‌کند، اما هم‌زمان مسئله را از حالت کم‌نمونه دورتر می‌سازد. بنابراین K را تغییر می‌دهیم تا این بده‌بستان بهتر روشن شود.

۲.۱۰.۴ جزئیات طراحی

برای هر مقدار K از میان ۱، ۳، ۵، ۱۰ و ۱۵، اپیزودها با K پشتیبان و $Q=15$ پرس‌وجو به‌ازای هر کلاس نمونه‌برداری می‌شوند. هر پیکربندی روی ۱۰۰ اپیزود آزمون ارزیابی می‌شود و میانگین AUROC و انحراف معیار گزارش می‌گردد. مدل اصلی ETHOS و یادگیری کم‌نمونه برای آموزش از $K=5$ استفاده می‌کند؛ این آزمایش K را فقط در زمان ارزیابی متغیر می‌کند تا حساسیت سنجیده شود. توجه: پروتکل ارزیابی اپیزودیک با ارزیابی اصلی Exp1 متفاوت است؛ از این رو مقادیر مطلق AUROC در این آزمایش در بازه ۰.۵۶۴-۰.۵۵۷ می‌مانند و از عدد منجمد ۰.۶۱۱ پایین‌ترند.

۳.۱۰.۴ طراحی

$K \in \{1, 3, 5, 10, 15\}$ را متغیر می‌کنیم و AUROC و F1 را روی مجموعه آزمون اندازه می‌گیریم. هر پیکربندی روی چند اپیزود ارزیابی می‌شود.

۴.۱۰.۴ خلاصه نتایج

AUROC در بازه باریک $0.564-0.557$ نوسان می‌کند. بهترین میانگین مشاهده شده 0.564 در $K=3$ است و $K=1$ نیز تقریباً هم‌تراز باقی می‌ماند؛ بنابراین در این جاربوب اپیزودیک روند صعودی یکنواخت دیده نمی‌شود. جدول ۴.۵ را ببینید.

۱۱.۴ آزمایش ۳: فدرال در برابر متمرکز

۱.۱۱.۴ هدف

هدف این آزمایش، اندازه‌گیری هزینه عملکردی یادگیری فدرال است. در یادگیری فدرال، مدل بدون تجمیع نمونه‌های خام روی داده توزیع شده آموزش می‌بیند؛ بنابراین پرسش اصلی این است که این قید تا چه اندازه به عملکرد آسیب می‌زند.

۲.۱۱.۴ طراحی

چارچوب ETHOS و یادگیری کم‌نمونه در دو چیدمان آموزش داده می‌شود: (۱) متمرکز، که در آن همه داده‌ها در یک محل در دسترس‌اند و آموزش اپیزودیک استاندارد انجام می‌شود؛ و (۲) فدرال، که در آن داده بر اساس بیماری به ۵ گره تقسیم می‌شود و FedAvg در ۲۰ دور با ۳ دوره محلی در هر دور اجرا می‌گردد. هر دو چیدمان از معماری، ابرپارامترها و تقسیم‌های داده یکسان استفاده می‌کنند. در حالت فدرال، هر گره مدل را محلی آموزش می‌دهد و به‌روزرسانی‌ها را به سرور می‌فرستد؛ سرور نیز آن‌ها را متناسب با اندازه گره تجمیع می‌کند. AUROC و F1 روی مجموعه آزمون نگه‌داشته شده مقایسه می‌شوند. مجموعه آزمون سراسری و بدون پارتیشن است تا مقایسه منصفانه باقی بماند.

۳.۱۱.۴ خلاصه نتایج

در خروجی نهایی این آزمایش، چیدمان متمرکز AUROC 0.552 و F1 0.543 دارد، در حالی که چیدمان فدرال AUROC 0.547 و F1 0.540 ثبت می‌کند؛ بنابراین افت مطلق حدود 0.005 AUROC است. این نتیجه از نظر کاربردی کوچک است، اما به معنای برتری فدرال نیست؛ تنها نشان می‌دهد که در این شبیه‌سازی هزینه‌ی حفظ حریم خصوصی محدود مانده است. جدول ۵.۵ را ببینید.

۱۲.۴ آزمایش ۴: مطالعه حذف تدریجی

۱.۱۲.۴ هدف

هدف این آزمایش، شناسایی اجزایی است که بیشترین سهم را در عملکرد مدل دارند. در حذف تدریجی، هر بار یک جزء حذف می‌شود و تغییر عملکرد اندازه‌گیری می‌گردد. این کار کمک می‌کند مشخص شود کدام انتخاب‌های طراحی واقعاً حیاتی‌اند و کدام‌ها اثر محدودتری دارند.

۲.۱۲.۴ گونه‌ها

- `full_model`: چارچوب کامل ETHOS و یادگیری کم‌نمونه.
- `no_symptom_tokens`: جایگزینی با Logistic Regression روی ۲۵ ویژگی خام.
- `no_clinical_bias`: حذف سوگیری بالینی در بردارهای نهفته.
- `no_intensity_weighting`: حذف وزن‌دهی شدت.
- `no_temporal_decay`: حذف واگرایی زمانی.
- `no_few_shot`: NN استاندارد (بدون آموزش اپیزودیک).

۳.۱۲.۴ خلاصه نتایج

`full_model`: AUROC ۰.۵۸۳ `no_symptom_tokens`: ۰.۷۲۴ (LR روی ویژگی‌های خام).
`no_intensity_weighting`: ۰.۵۷۷. در این جدول، حذف توکن‌های علائم ظاهراً عملکرد را بهتر می‌کند؛ بنابراین این حذف تدریجی بیشتر به محدودیت بازنمایی فعلی اشاره می‌کند تا تأیید بی‌قیدوشرط اجزای پیشنهادی. جدول ۷.۵ را ببینید.

۱۳.۴ آزمایش ۵: تعمیم بین‌بیماری

۱.۱۳.۴ هدف

ارزیابی تعمیم به گروه‌های بیماری دیده‌نشده. در چیدمان‌های فدرال یا چندسایتی، مدلی که روی برخی گروه‌های بیماری آموزش دیده ممکن است با داده محلی محدود به دیگران تعمیم یابد.

۲.۱۳.۴ طراحی

روی گره‌های ۱-۳ (سپسیس، قلبی، تنفسی) آموزش؛ آزمون روی گره‌های ۴ و ۵ (کلیوی، دیابت). این سناریویی را شبیه‌سازی می‌کند که بیمارستان یا گروه بیماری جدیدی به فدراسیون می‌پیوندد بدون داده آموزش محلی. `Proposed_FewShot`، `Logistic Regression`، `XGBoost` و `Standard NN` را مقایسه می‌کنیم. یادگیری کم‌نمونه برای چنین سناریوهایی طراحی شده است؛ آزمون می‌کنیم آیا وقتی توزیع آزمون از توزیع آموزش متفاوت است بر مدل‌های کلاسیک برتری دارد.

۳.۱۳.۴ خلاصه نتایج

پیشنهادی: `(node_4)` ۰.۶۰۲ و `(node_5)` ۰.۴۷۸. `LR`: ۰.۶۶۸ و ۰.۶۵۸. `XGBoost`: ۰.۷۰۴ و ۰.۷۰۰. در این اسنپ‌شات مدل‌های کلاسیک روی هر دو گره بهتر تعمیم می‌یابند و به‌ویژه روی گرهی دیابت افت مدل پیشنهادی چشمگیر است. جدول ۸.۵ را ببینید.

۱۴.۴ رویه جستجوی ابرپارامتر

برای مدل‌های کلاسیک از `RandomizedSearchCV` با ۵۰-۸۰ آزمون استفاده می‌کنیم. فضاهای جستجو در بلوک لاتین زیر به‌صورت یک‌خطی قابل شکستن آمده تا ارقام و پرانتز با متن فارسی قاطی نشوند؛ معیار امتیاز `AUROC` است؛ اعتبارسنجی متقاطع لایه‌ای ۵ تایی روی آموزش+اعتبارسنجی انجام می‌شود؛ بهترین پیکربندی با میانگین `AUROC` روی چین‌ها انتخاب می‌شود؛ سپس آستانه تصمیم روی اعتبارسنجی برای بیشینه‌سازی `F1` تنظیم و معیارهای نهایی روی آزمون گزارش می‌شوند. برای شبکه‌ی کامل پیوست آن را ببینید.

```
Random Forest. n_estimators: 100, 200, 300, 400, 500; max_depth: 8, 12, 16, 20, 24, 28;
min_samples_split: 2, 5, 10; min_samples_leaf: 1, 2, 4; max_features: sqrt, log2;
class_weight: balanced, balanced_subsample.
XGBoost. n_estimators: 100, 200, 300, 400, 500; max_depth: 4, 6, 8, 10, 12;
learning_rate: 0.01, 0.03, 0.05, 0.1; subsample: 0.5, 0.7, 0.85, 1.0; colsample_bytree:
0.5, 0.7, 0.85, 1.0.
```


۱۵.۴ آزمایش ۵.۸: گسترش‌های حذف تدریجی ETHOS

۱.۱۵.۴ هدف

گسترش مطالعه حذف تدریجی برای آزمون اینکه آیا آموزش نظارت‌شده (بدون کم‌نمونه اپیزودیک) عملکرد ETHOS را بهبود می‌دهد. گونه اصلی no_few_shot (NN استاندارد) به AUROC ۰.۶۴۵ رسید؛ فرض می‌کنیم ETHOS با سر طبقه‌بندی نظارت‌شده ممکن است از آموزش اپیزودیک پیشی گیرد.

۲.۱۵.۴ طراحی

رمزگذار ETHOS را با سر نظارت‌شده آموزش می‌دهیم: Linear(128→64→1) با سیگموئید، CrossEntropyLoss با وزن کلاس. همان تقسیم‌های داده که RF (seed=42). ۱۰۰ دوره، صبر توقف زودهنگام ۱۵. اختیاری: بارگذاری رمزگذار ETHOS پیش‌آموزش‌دیده از پیش‌آموزش MLM.

۳.۱۵.۴ خلاصه نتایج

ETHOS_Supervised به AUROC ۰.۶۱۰، F1 ۰.۳۸۶، Accuracy ۰.۶۲۷ می‌رسد. در مقایسه با Proposed_FewShot در Exp1 (۰.۶۱۱)، آموزش نظارت‌شده AUROC تقریباً هم‌تراز می‌دهد. سر نظارت‌شده از کل مجموعه داده بدون نمونه‌برداری اپیزودیک یاد می‌گیرد. جدول ۳.۵ و جدول ۹.۵ را ببینید.

۱۶.۴ آزمایش ۵.۹: معماری‌های ترکیبی

۱.۱۶.۴ هدف

مقایسه معماری‌های ترکیبی که بردارهای نهفته ETHOS را با ویژگی‌های جدولی ترکیب می‌کنند. آزمون: (۱) RF روی [ETHOS ۱۲۸ ب + جدولی ۲۵ ب] = ۱۵۳، (۲) RF تنها روی ETHOS ۱۲۸ ب.

۲.۱۶.۴ طراحی

۱. معماری ترکیبی ETHOS و Random Forest: استخراج بردارهای نهفته ETHOS برای همه‌ی نمونه‌ها. الحاق با ویژگی‌های جدولی: $\mathbf{x}_{\text{hybrid}} = [\mathbf{e}_{\text{ETHOS}}; \mathbf{x}_{\text{tab}}] \in \mathbb{R}^{153}$ آموزش Random Forest با RandomizedSearchCV (۵۰ آزمون) روی آموزش + اعتبارسنجی. تنظیم

آستانه روی اعتبارسنجی.

۲. **Random Forest فقط روی نهفته‌سازی ETHOS:** آموزش Random Forest تنها روی

بردارهای نهفته ۱۲۸-بعدی ETHOS (بدون جدولی). همان CV و تنظیم آستانه.

۳.۱۶.۴ خلاصه نتایج

معماری ترکیبی ETHOS و Random Forest به 0.717 AUROC، 0.652 F1، 0.665 Accuracy می‌رسد؛ بهبود چشمگیر نسبت به Proposed_FewShot در Exp1 (0.611) و ETHOS_Supervised (0.610). ترکیبی هم بازنمایی‌های آموخته‌شده و هم ویژگی‌های مهندسی‌شده را بهره می‌برد و شکاف تا RF (0.760) را به حدود 0.04 AUROC کاهش می‌دهد. Random Forest فقط روی نهفته‌سازی ETHOS به AUROC 0.598 و 0.576 F1 می‌رسد؛ ضعیف‌تر از ترکیبی است و تأیید می‌کند ویژگی‌های جدولی سیگنال بحرانی اضافه می‌کنند. جدول ۹.۵ را ببینید.

۱۷.۴ جمع‌بندی فصل

این فصل چیدمان تجربی را شرح داد؛ پیاده‌سازی و معماری نرم‌افزار، پیکربندی داده، پیکربندی چارچوب ETHOS و یادگیری کم‌نمونه و خط پایه کلاسیک، فرضیات آزمایش، توان آماری و اندازه نمونه، مشخصات سخت‌افزار و نرم‌افزار، فلسفه طراحی، رویه اجرا، پیکربندی‌های مدل خط پایه، معیارهای ارزیابی و گزارش، و طراحی تفصیلی برای هر یک از آزمایش‌های ۱ تا ۵، گسترش‌های حذف تدریجی ETHOS، و معماری‌های ترکیبی. فصل بعد نتایج را گزارش می‌کند.

فصل ۵

نتایج

این فصل نتایج تجربی را به ترتیب اهمیت گزارش می کند. اعداد و معیارهای اصلی همان خروجی های ثبت شده آزمایش ها هستند و در این بخش فقط نحوه خواندن و تفسیر آنها روشن تر می شود.

سلسله مراتب گزارش دهی (چگونه اعداد را بخوانیم). در این پایان نامه چند معیار **مکمل** گزارش می شود. هر کدام به پرسش متفاوتی پاسخ می دهد و بنابراین نباید به جای دیگری تفسیر شود:

۱. **سقف جدولی:** Random Forest و XGBoost تنظیم شده و فرایند SOTA جدولی، همراه با افزایش

داده و تنظیم آستانه. این بخش مرز بالای تجربی مدل های کلاسیک را روی همین کوهورت نشان می دهد.

۲. **پروتکل Exp1:** در آزمایش اصلی Exp1، مدل پیشنهادی کم نمونه و خطوط پایه در یک روند مشترک

مقایسه می شوند. این اعداد به همان پیکربندی آموزش اپیزودیک مخزن مربوط اند و جداول خروجی نیز به صورت خودکار در پیوست د آمده اند.

۳. **ترکیب جدولی و بهترین اجرای کم نمونه:** بردارهای نهفته ETHOS همراه با ویژگی های جدولی

و بهترین فرایند یکپارچه ی کم نمونه/انباشتی گزارش می شوند. این اجراها معمولاً بخش مهمی از فاصله تا سقف جدولی را، نسبت به اعداد اپیزودیک ساده، کاهش می دهند.

۴. **فدرال در برابر متمرکز:** این بخش بدهستان میان حریم خصوصی و سودمندی را در اجرای فدرال

جداگانه گزارش می کند.

حساسیت K-شات در Exp2 با پروتکل اپیزودیک ارزیابی می شود. بنابراین AUROC آن را نباید مستقیماً

با AUROC کل مجموعه آزمون در Exp1 یا با نتایج انباشتی مقایسه کرد. این بخش فقط نشان می دهد اندازه

مجموعه پشتیبان چه اثری بر عملکرد اپیزودیک دارد.


۱.۵ بهترین مدل کلاسیک نهایی

قوی‌ترین نتیجه **جدولی** از فرایند چندفازی SOTA به دست آمده است. پس از تنظیم مدل‌های کلاسیک، هم‌رأی‌سازی مدل‌ها و افزایش سبک گاوسی روی توزیع آموزش، پیکربندی «افزایش گاوسی سبک همراه با تنظیم آستانه» روی **مجموعه آزمون نگه‌داشته‌شده** بهترین نتیجه را ثبت می‌کند. خلاصه این خروجی در جدول زیر آمده است:


جدول ۱.۵: فرایند جدولی SOTA؛ بهترین پیکربندی آزمون (فاز 4)

پیکربندی	AUROC	F1	دقت	MCC
افزایش گاوسی سبک + تنظیم آستانه	۰.۷۴۸	۰.۶۷۴	۰.۷۰۰	۰.۳۴۸

در اعتبارسنجی متقاطع میانی، Random Forest با AUROC حدود ۰.۷۴۴ و XGBoost با مقدار حدود ۰.۷۴۰ روی مجموعه آموزش+اعتبار از پیش‌تازان بودند. معیارهای کامل هر فاز در خروجی کد ثبت شده‌اند. شکل ۱.۵ منحنی‌های ROC تولیدشده را نشان می‌دهد.



شکل ۱.۵: منحنی‌های ROC: مدل‌های کلاسیک، ETHOS، و اجرای انباشتی کم‌نمونه (AUROC دقیق در جداول).



شکل ۲.۵: منحنی‌های دقت-بازخوانی در مجموعه آزمون برای Random Forest و ETHOS

۲.۵ عملکرد ETHOS و یادگیری کم‌نمونه


جدول ۲.۵ معیارهای بهترین اجرای یکپارچه کم‌نمونه/انباشتی را نشان می‌دهد. این اجرا شامل یک Ensemble در مسیر کم‌نمونه (ترکیب GFA، Cross-Attention و سازگاری به‌سبک Proto-MAML) و یک فرا یادگیر انباشتی است که احتمال‌های کم‌نمونه، احتمال‌های RF و ویژگی‌های نهفته‌سازی را ترکیب می‌کند. اعداد جدول، برآوردهای نقطه‌ای مجموعه آزمون برای همان اجرای ثبت‌شده‌اند.

جدول ۲.۵: بهترین اجرای کم‌نمونه و انباشتی در مجموعه آزمون

معیار زیرمدل کم‌نمونه مدل انباشته نهایی بازه اطمینان 95 درصد (انباشتی)			
AUROC	۰.۶۷۰	۰.۷۴۶	[۰.۶۹۹, ۰.۷۹۷]
AUPRC	۰.۷۵۷	۰.۸۲۴	-
F1 کلان	۰.۳۸۶	۰.۶۸۷	-
Precision	۰.۳۱۴	۰.۶۸۶	-
Recall	۰.۵۰۰	۰.۶۹۶	-
دقت	۰.۶۲۸	۰.۶۹۸	-
MCC	۰.۰۰۰	۰.۳۸۲	-

فاصله تا سقف جدولی SOTA در جدول ۱.۵ بسیار کوچک است: اختلاف AUROC بین Stacked

BEST و سقف جدولی برابر 0.002 است ($0.746 - 0.748 = 0.002$). این مقدار در حد نوسان اجراهاست. با این حال، زیرمدل کم‌نمونه به‌تنهایی با 0.670 هنوز پایین‌تر از سقف قرار می‌گیرد؛ همین شکاف دلیل اصلی استفاده از انباشت و طراحی ترکیبی است. همچنین باید توجه کرد که مقدار 0.762 برای Random Forest به پروتکل ثابت Exp1 تعلق دارد، در حالی که مقدار 0.748 به فرایند منجمد Tabular SOTA مربوط است؛ این دو عدد پروتکل‌های متفاوت را خلاصه می‌کنند و تناقض محسوب نمی‌شوند. شکل ۳.۵ نشان می‌دهد RF و ETHOS با افزایش اندازه آموزش در مجموعه تشخیصی چگونه مقیاس می‌یابند.



شکل ۳.۵: منحنی‌های یادگیری: AUROC در برابر اندازه آموزش برای RF و خط پایه ETHOS با یادگیری کم‌نمونه (V0). بهبودهای V4 و V5 در بازه $0.74-0.71$ نمایش داده نشده‌اند.

۳.۵ آزمایش ۱: مقایسه مدل اصلی

جدول ۳.۵ خروجی آزمایش اصلی Exp1 را روی همان تقسیم آزمون بازتولید می‌کند. در این آزمایش، خطوط پایه کلاسیک، مدل‌های عصبی و مدل پیشنهادی کم‌نمونه با یک روند مشترک آموزش و ارزیابی می‌شوند. اعداد انباشتی و ترکیبی جزئی از Exp1 نیستند و باید در جدول ۲.۵ و آزمایش‌های ترکیبی تفسیر شوند.

۴.۵ آزمایش ۲: حساسیت K-ثبات

جدول ۴.۵ AUROC ایزودیک (میانگین $\pm$ انحراف معیار) را برای $K \in \{1, 3, 5, 10, 15\}$ گزارش می‌کند. مقادیر مستقیماً با AUROC کامل مجموعه آزمون در Exp1 قابل مقایسه نیستند.

جدول ۳.۵: آزمایش 1: مقایسه مدل اصلی در مجموعه آزمون

مدل	AUROC	F1	دقت	MCC
Logistic Regression	۰.۷۲۴	۰.۶۸۲	۰.۷۰۰	۰.۳۶۴
Random Forest	۰.۷۶۲	۰.۶۷۹	۰.۷۱۸	۰.۳۷۲
XGBoost	۰.۶۹۴	۰.۶۳۲	۰.۶۶۲	۰.۲۶۶
Standard NN	۰.۶۵۲	۰.۶۱۶	۰.۶۶۰	۰.۲۴۲
Federated NN (بدون کم نمونه)	۰.۶۶۲	۰.۶۱۸	۰.۶۴۲	۰.۲۳۶
مدل پیشنهادی کم نمونه	۰.۶۱۱	۰.۵۷۲	۰.۵۸۳	۰.۱۵۵

جدول ۴.۵: آزمایش 2: حساسیت K-شات در پروتکل اپیزودیک

K	AUROC	انحراف معیار	F1
۱	۰.۵۶۴	۰.۰۲۲	۰.۵۵۴
۳	۰.۵۶۴	۰.۰۲۵	۰.۵۴۸
۵	۰.۵۶۰	۰.۰۲۹	۰.۵۳۹
۱۰	۰.۵۵۷	۰.۰۲۱	۰.۵۳۴
۱۵	۰.۵۵۷	۰.۰۲۱	۰.۵۳۴

شکل ۴.۵ AUROC را در برابر K با باندهای اطمینان نشان می دهد.


۵.۵. آزمایش ۳: فدرال در برابر متمرکز

جدول ۵.۵ خلاصه اجرای فدرال را ارائه می کند. آموزش فدرال در این پیکربندی حدود ۰.۰۰۰۵ واحد AUROC نسبت به متمرکز هزینه دارد.


جدول ۵.۵: آزمایش 3: آموزش فدرال در برابر آموزش متمرکز

چیدمان	AUROC	F1
متمرکز	۰.۵۵۲	۰.۵۴۳
فدرال	۰.۵۴۷	۰.۵۴۰
شکاف (مطلق)	۰.۰۰۵	۰.۰۰۳

شکل ۵.۵ همگرایی را در طول دورها نشان می دهد. جدول ۶.۵ جریان ارتباطی FedAvg را در هر دور خلاصه می کند.



شکل ۴.۵: حساسیت K-شات: AUROC در برابر K با باندهای بازه اطمینان ۹۵ درصد



شکل ۵.۵: همگرایی فدرال: AUROC اعتبارسنجی در برابر دور.

جدول ۶.۵: جریان ارتباطی FedAvg ($T = 20$ دور، 5 گره)

گام	شرح
۱	سرور θ_t را به تمامی گره‌ها پخش می‌کند (Diabetes, Renal, Respiratory, Cardiac, Sepsis)
۲	هر گره k مدل محلی را $\theta_t^{(k)} \leftarrow \theta_t$ مقداردهی اولیه می‌کند
۳	آموزش محلی: $E = 3$ دوره، SGD روی $\mathcal{D}_k$
۴	گره k ، $\theta_t^{(k)}$ را به سرور می‌فرستد
۵	سرور تجمیع می‌کند: $\theta_{t+1} \leftarrow \sum_k (n_k/n) \theta_t^{(k)}$ (وزن‌دار با n_k)


۶.۵ آزمایش ۴: حذف تدریجی

جدول ۷.۵ خروجی‌های مطالعه حذف تدریجی را فهرست می‌کند. Δ AUROC نسبت به مدل کامل محاسبه شده است.

جدول ۷.۵: آزمایش 4: مطالعه حذف تدریجی اجرای مدل

نوع	AUROC	F1	Δ AUROC
مدل کامل	۰.۵۸۳	۰.۵۵۴	-
بدون توکن‌های علائم	۰.۷۲۴	۰.۶۲۸	+۰.۱۴۰
بدون سوگیری بالینی	۰.۵۸۴	۰.۵۵۷	+۰.۰۰۱
بدون وزن‌دهی شدت	۰.۵۷۷	۰.۵۷۰	-۰.۰۰۶
بدون افت زمانی	۰.۵۸۳	۰.۵۵۴	۰.۰۰۰
بدون سر کم‌نمونه	۰.۶۴۵	۰.۵۸۴	+۰.۰۶۲

شکل ۶.۵ نتایج حذف تدریجی را به صورت رادار ارائه می‌کند.



شکل ۶.۵: مطالعه حذف تدریجی به صورت رادار: سهم هر جزء.

۷.۵ آزمایش ۵: تعمیم بین بیماری

جدول ۸.۵ آخرین خروجی تعمیم بین بیماری را نشان می دهد. این اجرا دو گرۀ بیماری نگه داشته شده (renal diabetes) را گزارش می کند؛ در نسخه های آینده می توان همین روند را برای بازایی هر پنج گرۀ گسترش داد.

جدول ۸.۵: آزمایش ۵: تعمیم بین بیماری (AUROC به تفکیک گرۀ آزمون)

گرۀ آزمون	پیشنهادی	LR	XGBoost	NN
گرۀ ۴ (کلیوی)	۰.۶۰۲	۰.۶۶۸	۰.۷۰۴	۰.۵۷۲
گرۀ ۵ (دیابت)	۰.۴۷۸	۰.۶۵۸	۰.۷۰۰	۰.۶۴۳

در این اسنپشات مدل های کلاسیک در هر دو گرۀ پیشنهادی؛ گرۀ دیابت برای مدل پیشنهادی به ویژه دشوار است (پشتیبان کوچک تر، نویز برجسته بیشتر).

۸.۵ مقایسه گسترده مدل ها (۱۱ مدل)


جدول ۹.۵ مدل های نماینده را با معیارهای آزمون همگام شده با مجموعه خروجی فعلی مخزن یکپارچه می کند. سطرها پروتکل های کمی متفاوت را مخلوط می کنند؛ برای جداول دقیق به ازای هر اجرای آزمایشی، بخش «سلسله مراتب گزارش دهی» و پیوست د را ببینید.

جدول ۹.۵: مقایسه گسترده مدل ها ؛ معیارهای نماینده آزمون (همگام با خروجی های مخزن)

مدل	AUROC	AUPRC	F1	Prec.	Rec.	Acc.	MCC
بهترین جدولی SOTA (فاز ۴)	۰.۷۴۸	-	۰.۶۷۴	-	-	۰.۷۰۰	۰.۳۴۸
(Exp1) Random Forest	۰.۷۶۲	۰.۸۴۳	۰.۶۷۹	-	-	۰.۷۱۸	۰.۳۷۲
(Exp1) Logistic Regression	۰.۷۲۴	۰.۷۷۷	۰.۶۸۲	-	-	۰.۷۰۰	۰.۳۶۴
(Exp1) XGBoost	۰.۶۹۴	۰.۷۷۹	۰.۶۳۲	-	-	۰.۶۶۲	۰.۲۶۶
ETHOS-RF Hybrid	۰.۷۱۷	-	۰.۶۵۲	-	-	۰.۶۶۵	-
Federated NN (بدون کم نمونه)	۰.۶۶۲	۰.۷۳۲	۰.۶۱۸	-	-	۰.۶۴۲	۰.۲۳۶
Standard NN	۰.۶۵۲	۰.۷۲۰	۰.۶۱۶	-	-	۰.۶۶۰	۰.۲۴۲
مدل پیشنهادی کم نمونه (Exp1)	۰.۶۱۱	۰.۶۸۷	۰.۵۷۲	-	-	۰.۵۸۳	۰.۱۵۵
FewShot BEST	۰.۶۷۰	۰.۷۵۷	۰.۳۸۶	۰.۳۱۴	۰.۵۰۰	۰.۶۲۸	۰.۰۰۰
Stacked BEST	۰.۷۴۶	۰.۸۲۴	۰.۶۸۷	۰.۶۸۶	۰.۶۹۶	۰.۶۹۸	۰.۳۸۲

۹.۵ مقایسه مدل با بازه‌های اطمینان

جدول ۱۰.۵ بازه‌های اطمینان ۹۵ درصد بوت‌استرپ (۱,۰۰۰ نمونه‌برداری مجدد) را برای مدل‌های برتر فراهم می‌کند. این بازه‌ها عدم قطعیت برآورد را نشان می‌دهند؛ اما برای ادعای برتری آماری جفتی، بردارهای پیش‌بینی هم‌تراز و آزمون‌هایی مانند بوت‌استرپ جفتی، DeLong یا McNemar لازم است. شکل ۷.۵ همه‌ی مدل‌ها را در نمودار میله‌ای مقایسه می‌کند.



شکل ۷.۵: مقایسه اصلی مدل‌ها: AUROC در برابر همه‌ی خطوط پایه و مدل‌های پیشنهادی.

جدول ۱۰.۵: مدل‌های منتخب با بازه‌های مستند؛ سطر RF در Exp1 برآورد نقطه‌ای از تقسیم ثابت است

مدل	معیار	نقطه	بازه
(Exp1) Random Forest	AUROC	۰.۷۶۲	-
	AUROC	۰.۷۴۶	[۰.۶۹۹, ۰.۷۹۷]
Stacked BEST	F1	۰.۶۸۷	-
	AUROC	۰.۶۷۰	[۰.۶۱۲, ۰.۷۲۶]
FewShot BEST	F1	۰.۳۸۶	-
	AUROC	۰.۶۱۱	-
مدل پیشنهادی کم‌نمونه (Exp1)	AUROC	۰.۶۱۱	-

۱۰.۵ خلاصه یافته‌های کلیدی

جدول ۱۱.۵ یافته‌های اصلی اجرای فعلی مخزن را در یک نگاه یکپارچه می‌کند.

جدول ۱۱.۵: خلاصه یافته‌های کلیدی (مجموعه آزمون، همگام‌شده)

دسته	مدل	AUROC	F1	یادداشت
کلاسیک	جدولی SOTA (فاز 4)	۰.۷۴۸	۰.۶۷۴	خروجی منجمد
کلاسیک	(Exp1) Random Forest	۰.۷۶۲	۰.۶۷۹	همان تقسیم Exp1
کلاسیک	(Exp1) Logistic Regression	۰.۷۲۴	۰.۶۸۲	خط پایه خطی
کلاسیک	(Exp1) XGBoost	۰.۶۹۴	۰.۶۳۲	تقویت گرادیانی
ترکیبی	ETHOS-RF Hybrid	۰.۷۱۷	۰.۶۵۲	نهفته‌سازی RF +
انباشتی	Stacked BEST	۰.۷۴۶	۰.۶۸۷	بهترین اجرای انباشتی
کم‌نمونه	FewShot BEST	۰.۶۷۰	۰.۳۸۶	پیش از انباشت
Exp1	مدل پیشنهادی کم‌نمونه	۰.۶۱۱	۰.۵۷۲	پروتکل اصلی Exp1
فدرال	متمرکز	۰.۵۵۲	۰.۵۴۳	مرجع متمرکز
فدرال	فدرال	۰.۵۴۷	۰.۵۴۰	افت ~ 0.005 AUROC

۱۱.۵ معناداری آماری

هرجا اجرای آموزش بازه‌ی اطمینان تولید کرده است، همان بازه‌ها گزارش شده‌اند. Stacked BEST دارای AUROC **۰.۷۴۶** با بازه اطمینان ۹۵ درصد بوت‌استرپ [۰.۶۹۹, ۰.۷۹۷] است و FewShot BEST دارای AUROC ۰.۶۷۰ با بازه [۰.۶۱۲, ۰.۷۳۶] است. فرایند جدولی SOTA برآورد نقطه‌ای AUROC آزمون **۰.۷۴۸** را می‌دهد (جدول ۱۱.۵). مقایسه جفتی رسمی میان این خروجی‌ها به پروتکل نگه‌داشت اختصاصی و بردارهای پیش‌بینی هم‌تراز نیاز دارد. چون همه مدل‌ها تحت پروتکل یکسان و با بردارهای پیش‌بینی هم‌تراز تولید نشده‌اند، مقایسه‌های بین پروتکلی در این پایان‌نامه توصیفی‌اند. ستون‌های بوت‌استرپ Exp1 در خروجی جدولی، به‌دلیل تکرار مقدار اسکالر، برای استنتاج آماری قابل اتکا نیستند؛ بنابراین برای Exp1 از برآوردهای نقطه‌ای تقسیم ثابت در جدول ۳.۵ استفاده می‌شود. کار آینده باید مقایسه‌های جفتی کامل را با بوت‌استرپ جفتی، DeLong، McNemar، مقایسه کالیبراسیون و اعتبارسنجی بیرونی انجام دهد.


۱۲.۵ تفسیرپذیری

شکل ۸.۵ اهمیت ویژگی در Random Forest را نشان می‌دهد. کراتینین، گلوکز و هموگلوبین بالاترین رتبه را دارند و این الگو با شهود بالینی هم‌خوان است. **کراتینین** عملکرد کلیه را بازتاب می‌دهد و مقدار بالای آن معمولاً به AKI و تأخیر در ترخیص ایمن مربوط است. **گلوکز** وضعیت کنترل قند خون را نشان می‌دهد؛ بی‌نظمی قند در بیماران بحرانی شایع است و می‌تواند روند بهبود را تحت تأثیر قرار دهد. **هموگلوبین** نیز نشانگر کم‌خونی یا خونریزی است و مقادیر پایین آن ممکن است نیاز به انتقال خون یا پایش طولانی‌تر ایجاد کند. نمره SOFA و shock index نیز سهم دارند و با نقش اختلال اندام و پایداری همودینامیک در امکان‌پذیری درمان سازگارند.

جدول ۱۲.۵ ویژگی‌های برتر را به معنای بالینی آن‌ها نگاشت می‌کند. شکل ۹.۵ نیز آبشار SHAP را برای یک بیمار نمونه نشان می‌دهد.

جدول ۱۲.۵: تفسیر بالینی ویژگی‌های برتر (جنگل تصادفی)

ویژگی	اهمیت	معنای بالینی
Creatinine	۰.۱۸	عملکرد کلیه؛ بالا $\rightarrow$ AKI، تأخیر ترخیص
Glucose	۰.۱۴	کنترل گلیسمی؛ بی‌نظمی شایع در بیماران بحرانی
Hemoglobin	۰.۱۲	کم‌خونی/خونریزی؛ پایین $\rightarrow$ انتقال خون، اقامت طولانی‌تر
Lactate	۰.۱۱	پرفیوژن بافت؛ بالا $\rightarrow$ شوک، پیش‌آگهی ضعیف
Shock index	۰.۱۰	SBP/HR؛ ناپایداری همودینامیک
SOFA proxy	۰.۰۹	ترکیب اختلال اندام
Abnormal lab count	۰.۰۸	انحراف کلی؛ سهم مقادیر افراطی




شکل ۸.۵: اهمیت ویژگی (جنگل تصادفی). کراتینین، گلوکز، هموگلوبین بالاترین رتبه را دارند.

۱۳.۵ مطالعات موردی بالینی


برای نمایش رفتار مدل، سه مورد نماینده از مجموعه آزمون ارائه می‌کنیم:

مورد ۱ (مثبت واقعی): مرد ۶۲ ساله با سپسیس. کراتینین ۱.۲ mg/dL (نرمال شده ۰.۴)، روند بهبود؛ لاکتات ۱.۸ (۰.۳۵)؛ علائم حیاتی پایدار. RF امکان‌پذیری را ۰.۷۲ پیش‌بینی کرد؛ ترخیص واقعی به بازتوانی. در تحلیل SHAP، کراتینین با اثر ۰.۰۸-، لاکتات با اثر ۰.۰۵-، و SOFA با اثر ۰.۰۴- به تصمیم درست مدل کمک کردند.

مورد ۲ (منفی کاذب): زن ۵۸ ساله با تشخیص قلبی. کراتینین مرزی (۰.۴۵ نرمال شده)؛ RF غیرممکن



شکل ۹.۵: آبشار SHAP برای یک بیمار برتر (جنگل تصادفی). سهم ویژگی‌ها در پیش‌بینی.



شکل ۱۰.۵: منحنی‌های کالیبراسیون: احتمال پیش‌بینی شده در برابر فراوانی مشاهده شده. RF نسبتاً خوب کالیبره است؛ ETHOS گرایش به بیش‌اعتمادی دارد.

(۰.۴۸) پیش‌بینی کرد اما بیمار به منزل ترخیص شد. خطا احتمالاً به دلیل کراتینین در بازه مبهم؛ زمینه اضافی (مثلاً روند بهبود) می‌توانست کمک کند.

مورد ۳ (مثبت کاذب): مرد ۷۱ ساله با نارسایی کلیه. کراتینین بالا (۰.۷۲ نرمال شده)؛ RF امکان‌پذیری را ۰.۵۸ پیش‌بینی کرد اما بیمار نیاز به اقامت طولانی داشت. مدل ممکن است تعامل سن-کراتینین را کم‌وزن کرده باشد.

این موارد برجسته می‌کنند که مقادیر آزمایشگاهی مرزی و زیرگروه‌های نادر همچنان چالش‌زا هستند. در استقرار باید پیش‌بینی‌های با اطمینان پایین برای بازبینی بالینی علامت‌گذاری شوند.

۱۴.۵ تحلیل توزیع اطمینان

توزیع احتمالات پیش‌بینی‌شده از بهترین مدل (RF) را تحلیل کردیم. برای مثبت‌های واقعی: میانه‌ی احتمال پیش‌بینی‌شده ۰.۷۲ (IQR ۰.۵۸-۰.۸۵). برای منفی‌های واقعی: میانه ۰.۳۵ (IQR ۰.۲۲-۰.۴۸). برای مثبت‌های کاذب: میانه ۰.۵۸ (IQR ۰.۵۲-۰.۶۴)؛ این‌ها نزدیک آستانه تصمیم خوشه می‌شوند. برای منفی‌های کاذب: میانه ۰.۴۸ (IQR ۰.۴۲-۰.۵۴). هم‌پوشانی در بازه ۰.۴۵-۰.۵۵ تأیید می‌کند که موارد مرزی دشوارترین‌اند. آستانه اطمینان (مثلاً فقط اقدام برای پیش‌بینی‌های با احتمال کمتر از ۰.۳ یا بیش از ۰.۷) می‌تواند دقت را به‌قیمت پوشش بهبود دهد.

۱۵.۵ معیارهای تفصیلی به تفکیک بیماری

جدول ۱۳.۵ AUROC، F1، Precision، و Recall را برای بهترین مدل (جنگل تصادفی) و مدل پیشنهادی کم‌نمونه به‌ازای هر گره بیماری گزارش می‌کند. مدل RF به‌طور پیوسته از ETHOS در همه‌ی گره‌ها بهتر است؛ بیشترین شکاف برای گره پنجم، یعنی دیابت، دیده می‌شود که ETHOS در آن تنها به AUROC ۰.۵۳ می‌رسد. این نشان می‌دهد عوامل ویژه بیماری ممکن است تعمیم کم‌نمونه را متفاوت از مدل‌های کلاسیک تحت تأثیر قرار دهد.

۱۶.۵ کالیبراسیون و تحلیل حساسیت

خطای کالیبراسیون مورد انتظار (ECE) و بیشینه خطای کالیبراسیون (MCE) را برای RF و ETHOS محاسبه کردیم. RF: ECE ۰.۰۴، MCE ۰.۰۸؛ ETHOS: ECE ۰.۰۹، MCE ۰.۱۵. ETHOS بیش‌اعتمادتر

جدول ۱۳.۵: معیارها به تفکیک بیماری (RF در برابر مدل پیشنهادی کم‌نمونه)

گره	RF				مدل پیشنهادی			
	Rec.	Prec.	F1	AUROC	Rec.	Prec.	F1	AUROC
سپسیس	۰.۷۴	۰.۶۸	۰.۶۶	۰.۷۰	۰.۶۱	۰.۵۶	۰.۵۴	۰.۵۸
قلبی	۰.۷۲	۰.۶۶	۰.۶۴	۰.۶۸	۰.۶۲	۰.۵۸	۰.۵۶	۰.۶۰
تنفسی	۰.۷۰	۰.۶۴	۰.۶۲	۰.۶۶	۰.۶۰	۰.۵۵	۰.۵۳	۰.۵۷
کلیوی	۰.۷۰	۰.۶۵	۰.۶۳	۰.۶۷	۰.۶۰	۰.۵۶	۰.۵۴	۰.۵۸
دیابت	۰.۶۴	۰.۶۰	۰.۵۸	۰.۶۲	۰.۵۳	۰.۵۰	۰.۴۸	۰.۵۲

است؛ بازکالیبراسیون (مثلاً Platt scaling) می‌تواند قابلیت اطمینان احتمالات را بهبود دهد. تاب‌آوری نسبت به تقسیم‌های تصادفی مختلف (بذرهای ۴۲، ۱۲۳، ۴۵۶) نیز ارزیابی شد: 0.76 ± 0.01 AUROC RF؛ 0.62 ± 0.02 ETHOS. نتایج در تقسیم‌ها پایدارند. اهمیت ویژگی (Gini) در اعتبارسنجی متقاطع ۵ لایه نشان می‌دهد ویژگی‌های برتر (کراتینین، گلوکز، هموگلوبین) پایدارند (همبستگی رتبه بزرگتر از ۰.۹ بین دوره‌های اعتبارسنجی).

۱۷.۵ تحلیل خطا به‌ازای ویژگی

تحلیل کردیم کدام ویژگی‌ها با طبقه‌بندی اشتباه بیشتر همراه‌اند. برای مثبت‌های کاذب (امکان‌پذیری پیش‌بینی شده، غیرممکن واقعی): کراتینین و لاکتات اغلب در بازهٔ پایین-نرمال‌اند و مدل را به کم‌برآوردن ریسک سوق می‌دهند. برای منفی‌های کاذب (غیرممکن پیش‌بینی شده، امکان‌پذیر واقعی): سن و نمرهٔ SOFA گاهی بالا هستند با وجود تریس مطلوب؛ مدل ممکن است بیش‌محافظه‌کار باشد. این الگو نشان می‌دهد افزودن اطلاعات روند (بهبود در برابر وخامت) و یادداشت‌های بالینی می‌تواند خطاها را کاهش دهد. بازنمایی فعلی از تجمیع ۲۴ ساعت اول استفاده می‌کند و پویایی زمانی را نمی‌گیرد.

۱۸.۵ تحلیل ROC و دقت-بازخوانی

منحنی ROC نرخ مثبت واقعی (حساسیت) را در برابر نرخ مثبت کاذب ($1 -$ اختصاصیت) در آستانه‌های مختلف نشان می‌دهد. AUROC برابر ۰.۷۶ یعنی در حدود ۷۶٪ موارد، مدل به یک بیمار واقعاً امکان‌پذیر امتیاز بالاتری از یک بیمار واقعاً ناممکن می‌دهد. در دادهٔ نامتعادل، منحنی دقت-بازخوانی نیز اهمیت دارد. در آستانهٔ پیش‌فرض ۰.۵۴، مدل RF دقت ۰.۶۷ و بازخوانی ۰.۶۹ دارد. برای استقرار، آستانه باید بر اساس هزینهٔ مثبت کاذب، مانند

ترخیص زودهنگام، و منفی کاذب، مانند تأخیر در ترخیص، تنظیم شود. آستانه پایین‌تر بازخوانی را افزایش می‌دهد اما هشدارهای کاذب بیشتری تولید می‌کند؛ بنابراین نقطه قابل قبول باید با مشارکت ذی‌نفعان بالینی و بر اساس اولویت‌های هر مؤسسه تعیین شود.

۱۹.۵ منحنی‌های یادگیری و کارایی داده

مجموعه آموزش به ۲۵٪، ۵۰٪، ۷۵٪ و ۱۰۰٪ زیرنمونه‌برداری شد و AUROC آزمون اندازه‌گیری گردید. برای Random Forest مقادیر به‌ترتیب ۰.۶۸، ۰.۷۲، ۰.۷۵ و ۰.۷۶ بود. برای ETHOS همراه با یادگیری کم‌نمونه نیز مقادیر ۰.۵۵، ۰.۵۸، ۰.۶۰ و ۰.۶۲ به‌دست آمد. هر دو مدل از افزایش داده سود می‌برند، اما شیب بهبود RF بیشتر است؛ یعنی در این وظیفه، مدل کلاسیک از داده‌ی موجود کارتر استفاده می‌کند. با تنها ۲۵٪ داده‌ی آموزش، یعنی ۳۲۰ نمونه، RF هنوز به AUROC برابر ۰.۶۸ می‌رسد که برای تنظیمات کم‌داده قابل قبول است. در مقابل، ETHOS برای رسیدن به عملکرد مشابه به داده‌ی بیشتری نیاز دارد. این نتیجه استفاده از مدل‌های کلاسیک را در سناریوهایی که داده‌ی کافی وجود دارد تقویت می‌کند و نقش کم‌نمونه را بیشتر برای سناریوهای فدرال یا واقعاً کم‌داده برجسته می‌سازد.

۲۰.۵ نتایج حساسیت ابرپارامتر

اب‌پارامترهای کلیدی را تغییر دادیم و تغییر AUROC را اندازه گرفتیم. برای ETHOS: بعد نهفته (۶۴، ۱۲۸، ۲۵۶)؛ بهترین ۱۲۸؛ تعداد لایه‌ها (۱، ۲، ۳)؛ بهترین ۲؛ Dropout (۰.۱، ۰.۲، ۰.۳)؛ بهترین ۰.۲ AUROC در این بازه‌ها حدود ۰.۰۲ نوسان داشت. برای Random Forest: max_depth (۱۰، ۲۰، ۲۸، None)؛ بهترین ۲۸؛ n_estimators (۱۰۰، ۲۰۰، ۳۰۰)؛ بهترین ۲۰۰ AUROC از عمق ۱۰ به بالا و با دست‌کم ۲۰۰ برآوردگر، در حد ۰.۰۱ پایدار بود. مدل به تغییرات متوسط ابرپارامتر تاب‌آور است؛ بهترین پیکربندی را برای بازتولیدپذیری گزارش می‌دهیم.

۲۱.۵ تاب‌آوری تقسیم جایگزین

تاب‌آوری نسبت به تقسیم‌های تصادفی مختلف با بذره‌های ۴۲، ۱۲۳، و ۴۵۶ ارزیابی شد. برای هر بذر، تقسیم‌های آموزش/اعتبار/آزمون را دوباره تولید کردیم (طبقه‌بندی‌شده، همان نسبت ۲۰/۱۶/۶۴) و همه‌ی مدل‌ها را دوباره آموزش دادیم. نتایج: AUROC RF 0.76 ± 0.01 ؛ ETHOS 0.62 ± 0.02 ؛ معماری ترکیبی ETHOS

و Random Forest حدود 0.01 ± 0.72 . رتبه‌بندی مدل‌ها در تقسیم‌ها پایدار است. بذر ۴۲ را به‌عنوان نتیجه اصلی برای بازتولیدپذیری گزارش می‌دهیم؛ واریانس کوچک نشان می‌دهد نتیجه‌گیری‌ها به یک تقسیم خاص حساس نیستند.

۲۲.۵ تحلیل معماری مدل تقویت‌شده

به‌صورت سیستماتیک تقویت‌های معماری برای بهبود عملکرد ETHOS همراه با یادگیری کم‌نمونه بررسی شد. جدول ۱۴.۵ تأثیر هر تقویت در چارچوب نمونه‌اولیه اصلی را خلاصه می‌کند.

جدول ۱۴.۵: تحلیل اولیه تقویت معماری برای ETHOS و یادگیری کم‌نمونه (روایت تاریخی توسعه، فقط نمونه‌اولیه)

تقویت	AUROC	F1	AUROC Δ	یادداشت
خط پایه تاریخی	۰.۶۱۹	۰.۵۸۰	-	ارزیابی اپیزودیک، 500 اپیزود
weight decay + AdamW +	۰.۶۱۳	۰.۵۷۶	-۰.۰۰۶	منظم‌سازی
Cosine annealing LR +	۰.۶۱۲	۰.۵۷۸	-۰.۰۰۷	زمان‌بندی LR
+ ارزیابی چنداپیزودی (20)	۰.۶۱۱	۰.۵۷۳	-۰.۰۰۸	میانگین روی 20 اپیزود
+ ارزیابی پشتیبان آموزش کامل	۰.۶۱۱	۰.۵۷۳	-۰.۰۰۸	پروتکل نظارت‌شده
+ ProjectionMLP (64→128)	۰.۶۱۲	۰.۵۷۸	-۰.۰۰۷	فضای متریک
+ Focal + وزن کلاس	۰.۶۱۱	۰.۵۷۶	-۰.۰۰۸	نامتعادلی
+ 1,200 اپیزود	۰.۶۱۰	۰.۵۷۰	-۰.۰۰۹	آموزش بیشتر
بهترین ترکیب تاریخی	۰.۶۱۹	۰.۵۸۰	۰.۰۰۰	چیدمان اصلی

نتایج اولیه نشان داد مدل ETHOS با یادگیری کم‌نمونه به تغییر تک‌جزء تاب‌آور است، اما در چارچوب فقط نمونه‌اولیه در برابر بهبود چشمگیر مقاومت می‌کند. این انگیزه‌ای برای دور دوم تقویت‌های بنیادی‌تر بود.

۲۳.۵ راهبردهای آموزش بهبودیافته

یادداشت خواننده (اسنپ‌شات ارسال). زیربخش‌های زیر مسیر توسعه گسترده V1–

V6 را توسعه توصیف می‌کنند (روش‌شناسی و بنچمارک‌های میانی آن کمپین). **اعدادی**

که برای این پایان‌نامه منجمد شده‌اند جداول همگام شده با مخزن در ابتدای

فصل ۵ است (AUROC آزمون جدولی SOTA ۰.۷۴۸؛ اجرای انباشتی یکپارچه ۰.۷۴۶).

[۰.۶۹۹, ۰.۷۹۷]: مدل پیشنهادی کم‌نمونه در Exp1 با ۰.۶۱۱؛ و غیره) و پیوست د. جایی

که روایت به ۰.۷۳۲، ۰.۷۳۷، ۰.۷۶۰ استناد می‌کند، مگر همان مقدار در آن جداول اولیه ظاهر

شود، آن را خروجی تاریخی کمپین V بدانید.

بر اساس تحلیل محدودیت‌های مدل نمونه‌اولیه، سه راهبرد بهبود مکمل توسعه دادیم. جدول ۱۵.۵ نتایج را خلاصه می‌کند.

۱.۲۳.۵ راهبرد ۱: سر نمونه‌اولیه-رابطه ترکیبی با پیش تنظیم نظارت‌شده

شبکه نمونه‌اولیه شباهت را از راه فاصله کسینوسی تا مرکزهای کلاس محاسبه می‌کند که ضمناً مرزهای محدب کلاس در فضای نهفته فرض می‌کند. برای شل کردن این فرض، **سر شبکه رابطه** (MLP کوچک که تابع شباهت غیرخطی بین بردارهای نهفته پرس‌وجو و نمونه‌های اولیه کلاس یاد می‌گیرد) معرفی شد. معماری نهایی از ترکیب درگاهی هر دو لگاریتم فاصله کسینوسی نمونه‌اولیه و لگاریتم‌های رابطه آموزش‌دیده استفاده می‌کند:

$$\text{logits} = \sigma(g) \cdot \text{logits}_{\text{proto}} + (1 - \sigma(g)) \cdot \text{logits}_{\text{relation}} \quad (۱.۵)$$

که در آن g پارامتر درگاه قابل‌یادگیری و σ تابع سیگموئید است.

همچنین **پیش تنظیم نظارت‌شده رمزگذار** افزودیم: پیش از آموزش اپیزودیک، رمزگذار ETHOS ابتدا با زیان آنتروپی متقاطع نظارت‌شده روی کل مجموعه آموزش (با هموارسازی برچسب ۰.۰۵) آموزش می‌بیند. این به رمزگذار بازنمایی‌های اولیه بهتری برای فاز اپیزودیک بعدی می‌دهد.

جزئیات آموزش در دو مرحله اجرا شد: ابتدا ۴۰ دوره پیش تنظیم نظارت‌شده با AdamW، نرخ یادگیری 5×10^{-4} و وزن‌زدایی 10^{-4} . سپس ۱,۵۰۰ اپیزود آموزش اپیزودیک با افزایش داده اجرا شد (نویز گاوسی $\sigma = 0.03$ ، ماسک ۵٪ ویژگی). ارزیابی از Ensemble ۸۰ اپیزود با مجموعه‌های پشتیبان متفاوت به همراه یک ارزیابی پشتیبان کامل استفاده می‌کند.

۲.۲۳.۵ راهبرد ۲: ترکیبی بهبودیافته (XGBoost + ETHOS)

Random Forest در معماری ترکیبی را با XGBoost جایگزین کردیم، با RandomizedSearchCV ۵۰ آزمون و اعتبارسنجی متقاطع ۵ لایه طبقه‌ای. ترکیب، بردارهای نهفته ۱۲۸ بعدی ETHOS (از رمزگذار پیش تنظیم‌شده نظارت‌شده) را با ویژگی‌های جدولی اصلی ۲۵ بعدی می‌چسباند و ورودی ۱۵۳ بعدی می‌سازد. تقویت گرادینان XGBoost اطلاعات مکمل بین بازنمایی‌های آموزش‌دیده و ویژگی‌های خام را بهتر بهره می‌برد. تنظیم آستانه روی اعتبارسنجی F1 را بیشینه می‌کند.

۳.۲۳.۵ راهبرد ۳: طبقه‌بند نظارت‌شده ETHOS

به عنوان مرز بالای توان رمزگذار ETHOS، سر طبقه‌بند ۳ لایه مستقیماً روی بردارهای نهفته رمزگذار ($128 \rightarrow 128 \rightarrow 64 \rightarrow 2$) با وزن‌دهی کلاس، هموارسازی برچسب، و توقف زودهنگام بر اساس AUROC اعتبارسنجی آموزش دادیم. این پارادایم آموزش اپیزودیک را به‌طور کامل دور می‌زند.

۴.۲۳.۵ راهبرد ۴: مدل کم‌نمونه V2 با SupCon و آموزش چندفازی

با اتکا به بینش‌های راهبردهای ۱-۳، نسخه جامع V2 با پنج نوآوری کلیدی ساخته شد:

۱. **مهندسی ویژگی:** گسترش ویژگی‌های اصلی ۲۲ بعدی با نسبت‌های جفتی، حاصل ضرب‌های تعاملی، و جملات مربع، فضای ویژگی را به ۵۵ بعد می‌رساند. این به رمزگذار سیگنال غنی‌تری برای یادگیری می‌دهد.

۲. **پیش‌آموزش SupCon:** به‌جای آنتروپی متقاطع استاندارد، ابتدا رمزگذار را با زبان مقابله‌ای که صریحاً بردارهای نهفته هم‌کلاس را نزدیک و غیرهم‌کلاس را دور می‌کند آموزش می‌دهیم. این فضای نهفته خوشه‌شده می‌سازد؛ دقیقاً هندسی که شبکه‌های نمونه‌اولیه نیاز دارند.

۳. **آموزش چندفازی:** آموزش در سه فاز انجام می‌شود: (الف) پیش‌آموزش SupCon (۲۵ دوره) $\rightarrow$ (ب) تنظیم دقیق نظارت‌شده با زیان کانونی و وزن‌دهی کلاس (۲۰ دوره با توقف زودهنگام مبتنی بر اعتبارسنجی) $\rightarrow$ (ج) فرا آموزش اپیزودیک (۱,۵۰۰ اپیزود) با افزایش نویز گاوسی و برنامه‌ریزی درسی K .

۴. **پالایش نمونه‌اولیه تراپردی:** در استنتاج، پالایش soft k-means (۱۰ تکرار) با آمار مجموعه پرس‌وجوی بدون برچسب برای تنظیم نمونه‌های اولیه اعمال می‌کنیم و عملاً به توزیع آزمون سازگار می‌شویم.

۵. **تجمیع چندبذری:** دو مدل با بذره‌های متفاوت آموزش‌دیده با پروتکل‌های ارزیابی پشتیبان کامل و اپیزود نمونه‌برداری‌شده ترکیب می‌شوند تا پیش‌بینی تاب‌آور شود.

معماری رمزگذار از تجمیع مبتنی بر توجه (به‌جای توکن CLS) با بردارهای نهفته موقعیتی استفاده می‌کند و سر کم‌نمونه لگاریتم‌های نمونه‌اولیه کسینوسی و شبکه رابطه را از راه درگاه آموزش‌دیده ترکیب می‌کند.

۵.۲۳.۵ راهبرد ۵: مدل کم‌نمونه V3 با تقطیر دانش از جنگل تصادفی

ایده‌ی اصلی در V3 این است که معلم Random Forest با AUROC برابر ۰.۷۶۰ دانشی دارد که می‌تواند از راه تقطیر دانش (KD) به رمزگذار کم‌نمونه منتقل شود. به‌جای یادگیری صرفاً از برچسب‌های سخت، رمزگذار خروجی‌های نرم RF را نیز می‌آموزد و مرزهای تصمیم RF را به فضای نهفته فشرده منتقل می‌کند. V3 نسبت به V2 سه نوآوری افزود:

۱. **تقطیر دانش:** در هر دو فاز SupCon و نظارت‌شده، رمزگذار با زیان ترکیبی آموزش می‌بیند:

$$\mathcal{L} = \mathcal{L}_{\text{task}} + \alpha \cdot \mathcal{L}_{\text{KD}} \quad \text{که} \quad \mathcal{L}_{\text{KD}} = T^2 \cdot \text{KL}(\sigma(\mathbf{z}_s/T) \parallel \sigma(\mathbf{z}_t/T))$$

بین پیش‌بینی‌های نرم شاگرد و معلم در دمای T است. از $T = 3-4$ و $\alpha = 0.4-0.5$ استفاده می‌کنیم.

۲. **مهندسی ویژگی غنی‌تر:** فضای ویژگی از ۲۲ به ۹۲ بعد با نسبت‌های جفتی، حاصل‌ضرب‌ها، جملات

مربع، تبدیل‌های لگاریتمی، و آمار خلاصه به‌ازای نمونه (میانگین، انحراف معیار، میانه، شمار مقادیر بالا/پایین) گسترش یافت.

۳. **افزایش داده در زمان آزمون (TTA):** در ارزیابی، ۵ نسخهٔ افزایش‌یافته از هر نمونهٔ آزمون (نویز

گاوسی $\sigma = 0.015$) ساخته و پیش‌بینی‌ها روی ورودی‌های افزایش‌یافته و اصلی میانگین می‌شوند تا واریانس کاهش یابد.

تجمیع سه‌بذری (بذرهای ۴۲، ۴۹، ۵۵) AUROC پایدار به‌ازای بذر ۰.۷۰۶-۰.۷۰۱ دارد و Ensemble به

۰.۷۱۲ می‌رسد. عملکرد بهترین مدل تکی به‌ازای بذر از قبل با V2 Ensemble (۰.۶۸۹) رقابتی است و نشان می‌دهد تقطیر دانش به‌تنهایی حدود ۰.۰۱۵ بهبود AUROC می‌دهد.

۶.۲۳.۵ راهبرد ۶: مدل کم‌نمونه V4 با Proto-MAML و فرا یادگیر انباشتی

V4 سه تکنیک نوآورانه برای امکان استقرار بالینی معرفی می‌کند:

۱. **Proto-MAML (سازگاری زمان آزمون):** در زمان ارزیابی، مدل آموزش‌دیده را کلون می‌کنیم و

۸ گام گرادیان روی مجموعهٔ پشتیبان پیش از پیش‌بینی روی پرس‌وجو انجام می‌دهیم. این پارامترهای

مدل (به‌ویژه دما، بایاس کلاس، و شبکهٔ رابطه) را به هر وظیفهٔ ارزیابی خاص سازگار می‌کند. Proto-

MAML رویکرد استاندارد در یادگیری کم‌نمونه است و امکان تنظیم دقیق به هر کوهورت بیمار را فراهم

می‌کند. حلقهٔ درونی از SGD با نرخ یادگیری ۰.۰۱ برای پارامترهای سر و 10^{-4} برای رمزگذار با برش

گرادیان ۱.۰ استفاده می‌کند.

۲. **ترنسفورمر ویژگی گروه‌بندی شده:** به جای قالب توکن‌های علائم ETHOS اصلی (که توکن‌های ۴ بعدی خاص می‌طلبد)، از یک رمزگذار ترنسفورمر تمیز استفاده می‌کنیم که ۹۲ ویژگی مهندسی شده را در توکن‌های اندازه ۴ گروه‌بندی می‌کند، بردارهای نهفته موقعیتی آموزش دیده اعمال می‌کند، و از ۲ لایه خودتوجه با تجمیع مبتنی بر توجه عبور می‌دهد. این معماری به قالب ورودی بی‌طرف است و از مکانیزم‌های ضرب شدت و بایاس هم‌وقوعی که رمزگذار ETHOS اصلی را به ساختار توکن خاص محدود می‌کند، اجتناب می‌کند.

۳. **فرا یادگیر انباشتی:** یک رگرسیون لجستیک کالیبره شده (با کالیبراسیون ایزوتونیک، اعتبارسنجی متقاطع ۳ لایه) پنج سیگنال ورودی را ترکیب می‌کند: (الف) احتمالات تجمیع کم‌نمونه، (ب) احتمالات RF، (ج) حاصل ضرب آن‌ها (سیگنال توافق)، (د) قدرمطلق تفاوت (سیگنال اختلاف)، و (ه) ۱۰ مؤلفه اول PCA از بردارهای نهفته میانگین رمزگذار. این فرا یادگیر قوت‌های مکمل کم‌نمونه و کلاسیک را می‌آمیزد: مدل کم‌نمونه هندسه فضای نهفته را می‌گیرد و به ساختار وظیفه سازگار می‌شود، در حالی که RF در افراز مستقیم ویژگی عالی است.

پروتکل ارزیابی استنتاج پشتیبان کامل استاندارد (وزن $2 \times$)، سازگاری پشتیبان کامل Proto-MAML (وزن $3 \times$)، پالایش نمونه اولیه ترابردی (وزن $2 \times$)، ۳ عبور TTA، و ۲۰ اپیزود نمونه‌برداری شده (۳ تا با سازگاری MAML) را ترکیب می‌کند. AUROC به‌ازای بذر از ۰.۶۹۶ تا ۰.۷۱۳ متغیر است. مدل انباشتی به AUROC $0.732 \pm [0.684, 0.783]$ می‌رسد؛ یعنی از نظر توصیفی به خط پایه RF تاریخی همان کمپین (۰.۷۳۵) نزدیک می‌شود، هرچند برای ادعای تساوی آماری به آزمون جفتی روی بردارهای پیش‌بینی هم‌تراز نیاز است.

۷.۲۳.۵ راهبرد ۷: مدل کم‌نمونه V5 با توجه دروازه‌ای و توجه متقاطع

بر پایه V4، نسخه V5 نوآوری معماری در پردازش ویژگی و محاسبه نمونه‌های اولیه را بررسی می‌کند:

۱. **توجه درگاهی به ویژگی (GFA):** با الهام از [Arik and Pfister, 2021] TabNet، V5 مکانیزم انتخاب ویژگی تطبیقی به‌ازای نمونه معرفی می‌کند. به جای یکسان‌رفتار با همه‌ی ویژگی‌ها، درگاه توجه چندگانه یاد می‌گیرد کدام ویژگی‌ها برای هر بیمار مرتبط‌ترند. در هر یک از $S = 3$ گام توجه، ماسک نرم ویژگی $\mathbf{a}_s = \text{softmax}(\mathbf{W}_s \mathbf{h} \odot \mathbf{p}_s)$ محاسبه می‌شود که $\mathbf{p}_s$ پیش‌مقیاس با $\gamma - \mathbf{a}_{s-1}$ کاهش یافته است و ویژگی‌های متفاوت در هر گام تشویق می‌شوند. بازنمایی‌های ویژگی ماسک‌شده در

گام‌ها تجميع و از راه درگاه آموزش دیده با مسير ترنسفورمر می‌آمیزند.

۲. **سر نمونه‌اولیه Cross-Attention**: به‌جای مقایسه پرس‌وجوها با میانگین نمونه‌های اولیه از طریق شباهت کسینوسی (شبکه نمونه‌اولیه استاندارد)، V5 از لایه Cross-Attention چندسر استفاده می‌کند که هر نمونه پرس‌وجو به‌طور هم‌زمان به همه‌ی نمونه‌های اولیه توجه می‌کند. این اجازه می‌دهد مدل توابع شباهت غیرخطی، وابسته به زمینه بین پرس‌وجوها و بازنمایی‌های کلاس یاد بگیرد و ساختار روابط غنی‌تر از معیارهای فاصله ساده بگیرد.

۳. **منظم‌سازی سازگاری**: در آموزش، پایداری پیش‌بینی تحت اختلال‌های کوچک ورودی ($\sigma = 0.02$) با جریمه KL اجبار می‌شود: $\mathcal{L}_{\text{consist}} = \text{KL}(p_{\theta}(\mathbf{x}) \| p_{\theta}(\mathbf{x} + \epsilon))$. این به‌عنوان پیش‌زمینه همواری روی مرز تصمیم عمل می‌کند.

۴. **مهندسی ویژگی گسترده‌شده**: فضای ویژگی از ۹۲ به ۱۳۲ بعد با تعاملات بالینی سه‌جانبه (ترکیب کراتینین، لاکتات، و BUN)، شاخص‌های چارک، و نسبت‌های ویژه حوزه (BUN/کراتینین، ALT/AST، shock index) گسترش یافت.

۵. **تجميع پنج‌بذری**: افزایش از ۳ به ۵ بذر واریانس تجميع را کاهش و تاب‌آوری را بهبود می‌دهد.

نتایج: تجميع کم‌نمونه V5 به AUROC $0.722 \pm [0.669, 0.772]$ با AUROC به‌ازای بذر از $0.703 \pm$ تا $0.737 \pm$ می‌رسد؛ بالاترین AUROC تکی کم‌نمونه مشاهده‌شده در همه‌ی آزمایش‌ها. فرا یادگیر انباشتی V5 به AUROC $0.73 \pm [0.680, 0.778]$ ، F1 0.661 ، و MCC 0.333 می‌رسد. ماژول GFA الگوهای توجه ویژگی معنادار بالینی یاد می‌گیرد: کراتینین، لاکتات، و هموگلوبین وزن‌های توجه بالا و پایدار دریافت می‌کنند، سازگار با رتبه‌بندی اهمیت ویژگی Random Forest.

۸.۲۳.۵ راهبرد ۸: مدل کم‌نمونه V6 با تجميع عمیق و انباشت XGBoost

V6 می‌آزماید آیا تنوع معماری در Ensemble می‌تواند با ترکیب رمزگذارهای ساختاراً متفاوت عملکرد را بیشتر بهبود دهد:

۱. **تجميع معماری ناهمگن**: به‌جای آموزش همان معماری با بذرهای متفاوت، V6 سه معماری بنیاداً متفاوت آموزش می‌دهد: (الف) FT-Transformer؛ بردارهای هفته آموزش دیده به‌ازای ویژگی با تجميع توجه، (ب) GFA-Transformer؛ رمزگذار دومسیره که توجه درگاهی به ویژگی را با ترنسفورمر ویژگی گروه‌بندی شده می‌آمیزد، و (ج) MLP-Mixer؛ معماری بدون توجه با MLP‌های مخلوط‌کننده

توکن و کانال. هر معماری با ۲ بذر آموزش داده می‌شود (۶ مدل).

۲. **انباشت XGBoost:** فرا یادگیر از رگرسیون لجستیک به درخت‌های تقویت‌شده گرادیان (XGBoost) ارتقا می‌یابد که روابط غیرخطی بین پیش‌بینی‌های مدل پایه را می‌گیرد. احتمالات Ensemble به‌ازای هر معماری به‌عنوان ویژگی‌های انباشت جداگانه در کنار پیش‌بینی‌های RF و مؤلفه‌های PCA نهفته‌سازی قرار می‌گیرند.

۳. **پیش‌بینی مطابق (Conformal prediction):** پیش‌بینی مطابق تقسیم شده مجموعه‌های پیش‌بینی معتبر با تضمین پوشش $(1 - \alpha = 0.90)$ فراهم می‌کند. آستانه کالیبراسیون مطابق $\hat{q} = 0.304$ میانگین اندازه مجموعه پیش‌بینی ۱.۴۰ می‌دهد، یعنی ۴۰٪ بیماران هر دو کلاس را در مجموعه پیش‌بینی دریافت می‌کنند (موارد نامطمئن)، در حالی که ۶۰٪ پیش‌بینی تک کلاسه با پوشش حاشیه‌ای ۹۰٪ دارند.

نتایج: تجمیع ناهمگن V6 به AUROC 0.725 [۰.۶۷۶, ۰.۷۷۳] می‌رسد. نتایج به‌ازای معماری تفاوت قابل توجه نشان می‌دهد: FT-Transformer (۰.۷۰۷)، GFA-Transformer (۰.۶۹۲)، و MLP-Mixer (۰.۶۴۲). عملکرد ضعیف‌تر MLP-Mixer، یعنی AUROC ۰.۰۶۵ پایین‌تر از FT-Transformer، نشان می‌دهد مکانیزم‌های خودتوجه برای یادگیری تعامل بین‌ویژگی در داده جدولی بالینی نقش مهمی دارند؛ مخلوط کردن توکن به تنهایی کافی نیست. مدل انباشتی V6 XGBoost (AUROC ۰.۶۸۹) از فرا یادگیر لجستیک V4 (۰.۷۳۲) به‌دلیل بیش‌برازش فرا یادگیر تقویت‌شده گرادیان روی مجموعه اعتبارسنجی کوچک ($n = 320$) عقب می‌ماند.

بینش کلیدی: تنوع معماری به‌طور خودکار عملکرد تجمیع را بهبود نمی‌دهد؛ ضعیف‌ترین معماری (MLP-Mixer) تجمیع را بیش از آن که ناهمگنی کمک کند تخریب می‌کند. رویکرد V4، V5 یعنی تجمیع چندبذری هم‌معماری با انباشت لجستیک کالیبره‌شده برای این مقیاس داده بهینه می‌ماند.

۹.۲۳.۵ تحلیل بهبودها

بهبودهای تدریجی چند یافته‌ی کلیدی را نشان می‌دهند:

۱. **پیش‌آموزش SupCon دگرگون‌کننده است:** بزرگ‌ترین سهم در بهبود V2 پیش‌آموزش مقابله‌ای نظارت‌شده (راهبرد ۴) است. با بهینه‌سازی صریح برای ساختار نهفته‌سازی خوشه‌شده، SupCon دقیقاً هندسه بازنمایی را می‌سازد که شبکه‌های نمونه‌اولیه نیاز دارند. این در تضاد با پیش‌آموزش آنتروپی متقاطع

جدول ۱۵.۵: راهبردهای آموزش بهبودیافته در کمپین تاریخی V0-V6: همه‌ی مدل‌ها روی همان مجموعه‌ی آزمون

راهبرد مدل	AUROC	AUPRC	F1	Prec.	Rec.	Acc.	MCC
اصلی (تاریخی) مدل پیشنهادی کم‌نمونه (نمونه‌اولیه)	۰.۶۱۹	۰.۶۸	۰.۵۸۰	۰.۵۶	۰.۶۰	۰.۶۲۰	۰.۱۸۰
1 + RelationNet SupervisedPreFT	۰.۶۲۶	۰.۷۲	۰.۶۰۲	۰.۶۰	۰.۶۰	۰.۶۲۲	۰.۲۰۵
2 طبقه‌بند نظارت‌شده ETHOS	۰.۶۲۵	۰.۷۰	۰.۶۱۵	۰.۶۳	۰.۶۱	۰.۶۵۸	۰.۲۳۹
3 ترکیبی ETHOS + XGBoost	۰.۷۳۴	۰.۸۰	۰.۶۵۲	۰.۶۵	۰.۶۶	۰.۶۶۳	۰.۳۱۴
4 مدل کم‌نمونه V2 (SupCon+تراپردی)	۰.۶۸۹	۰.۷۵۷	۰.۶۵۴	۰.۶۵۴	۰.۶۵۵	۰.۶۷۵	۰.۳۰۹
5 مدل کم‌نمونه V3 (TTA+SupCon+KD)	۰.۷۱۲	۰.۷۹۰	۰.۶۴۸	۰.۶۵۲	۰.۶۶۲	۰.۶۵۵	۰.۳۱۴
6 مدل کم‌نمونه V4 (Proto-MAML)	۰.۷۱۱	۰.۷۹۰	۰.۶۵۲	۰.۶۵۲	۰.۶۶۲	۰.۶۷۰	۰.۳۰۴
6 انباشتی V4 (Emb+RF+FS)	۰.۷۳۲	۰.۸۱۰	۰.۶۹۳	۰.۶۹۳	۰.۶۹۳	۰.۷۰۸	۰.۳۸۸
7 مدل کم‌نمونه V5 (CrossAttn+GFA)	۰.۷۲۲	۰.۷۹۷	۰.۶۵۱	۰.۶۴۹	۰.۶۵۵	۰.۶۶۸	۰.۳۰۴
7 انباشتی V5 (Emb+RF+FS)	۰.۷۳۰	۰.۸۱۰	۰.۶۶۱	۰.۶۶۱	۰.۶۷۲	۰.۶۷۰	۰.۳۳۳
8 مدل کم‌نمونه V6 (تجمع ناهمگن)	۰.۷۲۵	۰.۷۹۱	۰.۶۵۵	۰.۶۵۸	۰.۶۶۸	۰.۶۶۳	۰.۳۲۶
مرجع RF تنظیم آستانه	۰.۷۶۰	۰.۸۱	۰.۶۸۲	۰.۶۷	۰.۶۹	۰.۷۰۳	۰.۳۶۴

استاندارد (راهبرد ۱) است که تنها بازنمایی‌های کمی بهتر تولید می‌کند.

۲. **مهندسی ویژگی ظرفیت رمزگذار را تقویت می‌کند:** گسترش فضای ویژگی از ۲۲ به ۵۵

بعد از طریق جملات تعاملی، نسبت‌ها، و ویژگی‌های چندجمله‌ای سیگنال غنی‌تری به رمزگذار می‌دهد. ترنسفورمر ETHOS سپس می‌تواند به تعاملات بین‌ویژگی که در ویژگی‌های خام ضمنی‌اند توجه کند.

۳. **استنتاج ترابردی بهبود قابل توجه می‌دهد:** استفاده از آمار مجموعه پرس‌وجو برای پالایش

نمونه‌های اولیه در زمان آزمون (soft k-means، ۱۰ تکرار) مدل را به توزیع محلی آزمون سازگار می‌کند

و AUROC را حدود ۰.۰۳-۰.۰۲ نسبت به ارزیابی غیرترابردی بهبود می‌دهد.

۴. **آموزش چندفازی ضروری است:** آموزش سه‌فازی (SupCon → نظارت‌شده → اپیزودیک) از

هر فاز تکی بهتر عمل می‌کند. هر فاز بر قبلی بنا می‌شود: SupCon ساختار اولیه می‌سازد، آموزش

نظارت‌شده مرزهای تصمیم را صیقل می‌دهد، و آموزش اپیزودیک مدل را با پروتکل ارزیابی کم‌نمونه

سازگار می‌کند.

۵. **تقطیر دانش تأثیرگذارترین نوآوری تکی است:** V3 با تقطیر دانش RF به AUROC برابر

۰.۷۱۲ می‌رسد و نسبت به V2 با مقدار ۰.۶۸۹، بهبود ۰.۰۲۳ دارد. KD مرزهای تصمیم RF را به‌خوبی

به فضای نهفته رمزگذار منتقل می‌کند.

۶. **فاصله تا مدل‌های کلاسیک به‌شدت کم می‌شود:** مدل کم‌نمونه V3 (AUROC ۰.۷۱۲) فاصله

تا بهترین مدل کلاسیک (RF ۰.۷۶۰) را به تنها ۰.۰۴۸ AUROC کاهش می‌دهد (معادل کاهش ۶۶٪

از فاصله اولیه ۰.۱۴۱). بازه‌های اطمینان به‌طور قابل‌توجهی هم‌پوشانی دارند.

۷. **انباشت در کمپین V فاصله را کاهش می‌دهد:** فرا یادگیر انباشتی V4 با AUROC برابر ۰.۷۳۲

بخش زیادی از فاصله تا سطر RF در جدول ۱۵.۵ را می‌بندد. برای ادعاهای اصلی نسخه‌ی ارسال، باید

به اجرای انباشتی منجمد ۰.۷۴۶ در برابر ۰.۷۴۸ استناد شود و در صورت نیاز، آزمون‌های جفتی دوباره

محاسبه شوند.

۸. **Proto-MAML سازگاری زمان آزمون را ممکن می‌کند:** با وجود آن که Proto-MAML

(گام‌های گرادیان زمان آزمون روی پشتیبان) برآورد نقطه‌ای را نسبت به V3 به‌طور محسوس بهبود

نمی‌دهد (۰.۷۱۱ در برابر ۰.۷۱۲)، قابلیت حیاتی برای استقرار بالینی فراهم می‌کند: مدل می‌تواند در زمان

استنتاج بدون آموزش مجدد به توزیع بیماران مؤسسه‌ویژه سازگار شود. این به‌ویژه در تنظیمات فدرال

ارزشمند است که هر بیمارستان جمعیت‌شناسی متفاوتی دارد.

۹. توجه درگاهی به ویژگی بالاترین AUROC تکی کم‌نمونه را ایجاد می‌کند: V5 با GFA

و نمونه‌های Cross-Attention بهترین مدل کم‌نمونه تکی را با بذر ۵۵ و AUROC برابر ۰.۷۳۷ تولید می‌کند. با این حال، میانگین تجمیع پنج‌بذری (۰.۷۲۲) پایین‌تر از انباشتی V4 (۰.۷۳۲) است و نشان می‌دهد GFA به مقداردهی اولیه حساس‌تر است.

۱۰. تنوع معماری در این مقیاس داده کمک نمی‌کند: تجمیع ناهمگن V6 (۰.۷۲۵) از تجمیع‌های

هم‌معماری V4، V5 عقب می‌ماند. معماری MLP-Mixer (AUROC ۰.۶۴۲) فاقد مکانیزم خودتوجه حیاتی برای تعامل بین‌ویژگی است و تجمیع را پایین می‌کشد. این یافته با ادبیات اخیر یادگیری عمیق جدولی هم‌راستا است که معماری‌های مبتنی بر توجه را بر MLP در داده ساخت یافته برتر می‌داند.

۱۱. انباشت لجستیک کالیبره‌شده از انباشت XGBoost بهتر است: روی مجموعه اعتبارسنجی

کوچک ($n = 320$)، فرا یادگیر تقویت‌شده گرادیان در V6 (AUROC ۰.۶۸۹) بیش‌برازش می‌کند، در حالی که رگرسیون لجستیک با کالیبراسیون ایزوتونیک در V4 (AUROC ۰.۷۳۲) خوب تعمیم می‌یابد. این نتیجه نشان می‌دهد برای فرا یادگیرهای آموزش‌دیده روی مجموعه‌های اعتبارسنجی کوچک، مدل‌های خطی منظم‌شده بر روش‌های Ensemble غیرخطی ترجیح دارند.

با وجود این بهبودها، تفاوت‌های باقی‌مانده عملکرد را می‌توان به موارد زیر نسبت داد:

۱. **سربار بازنمایی:** بازنمایی توکن‌های علائم از طریق ترنسفورمر پیچیدگی افزوده دارد، در حالی که

مدل‌های درخت‌بنیاد مستقیماً فضای ویژگی را افزاز می‌کنند. برای داده جدولی متوسط، این سربار تا حدی سود بازنمایی‌های آموزش‌دیده را خنثی می‌کند.

۲. **واریانس ارزیابی اپیزودیک:** حتی با میانگین‌گیری Ensemble و پالایش ترازبندی، پروتکل ارزیابی

اپیزودیک واریانسی معرفی می‌کند که مدل‌های نظارت‌شده از آن اجتناب می‌کنند.

۳. **مقیاس داده:** با ۱,۲۸۰ نمونه آموزش، رمزگذار داده محدودی برای یادگیری بازنمایی‌های قابل تعمیم

دارد. SupCon با بهره‌وری بیشتر از برچسب‌های موجود این را تخفیف می‌دهد اما نمی‌تواند کاملاً جبران کند.

جمع‌بندی (هم‌تراز با جداول اولیه): اجرای انباشتی یکپارچه به AUROC ۰.۷۴۶ می‌رسد، یعنی

حدود ۰.۰۰۲ پایین‌تر از برآورد نقطه‌ای جدولی SOTA (۰.۷۴۸). روایت V1-V6 و جدول ۱۵.۵ همچنان

به‌عنوان نقشه‌راه روش‌شناختی ارزشمند است؛ اما ادعاهای چکیده و خلاصه اجرایی باید ابتدا به جداول اولیه استناد کنند.

۲۴.۵ جمع‌بندی فصل

این فصل نتایج را در چهار سطح گزارش کرد: (۱) سقف جدولی SOTA (AUROC ± 0.748) آزمون؛ (۲) ترکیبی و کم‌نمونه همراه با انباشت (± 0.746 انباشتی، ± 0.670 فقط کم‌نمونه)؛ (۳) مقایسه Exp1 (مدل پیشنهادی کم‌نمونه با ± 0.611 در برابر RF با ± 0.762 روی همان تقسیم)؛ و (۴) فدرال در برابر متمرکز، با شکاف حدود ± 0.005 AUROC، به همراه تحلیل‌های K -شات، حذف تدریجی، و بین‌گره‌ای. همچنین کمپین آموزش گسترده V1-V6 (جدول ۱۵.۵) را برای بازتولیدپذیری و گسترش‌های آینده مستند کردیم. تفسیرپذیری، اشکال کالیبراسیون، و مطالعات موردی خوانش گرایش به استقرار را پشتیبانی می‌کنند مشروط به محدودیت‌های فصل ۷.


فصل ۶

تحلیل داده و یافته‌های اکتشافی

این فصل تصویری منسجم از کوهورت MIMIC-IV ارائه می‌کند: توزیع داده‌ها، همبستگی ویژگی‌ها، کیفیت داده و چند تصویرسازی اکتشافی که مبنای تصمیم‌های مدل‌سازی در فصل‌های بعد هستند.

۱.۶ طرحواره و گردش داده MIMIC-IV

شکل ۱.۶ رابطه جدول‌های MIMIC-IV و روند پیش‌پردازش را به‌صورت خلاصه نشان می‌دهد.



شکل ۱.۶: طرح استخراج MIMIC-IV: جدول‌های منبع، کلیدهای اتصال، و پیش‌پردازش به بازنمایی‌های جدولی و توکنی (نمودار برداری؛ تکرنگ برای چاپ).

جدول ۱.۶ روند استخراج و پیش‌پردازش داده MIMIC-IV را خلاصه می‌کند. ابتدا patients

admissions و icustays بر اساس subject_id و hadm_id به هم متصل می‌شوند؛ سپس labevents و chartevents از طریق stay_id به اقامت‌های ICU پیوند می‌خورند. در مرحله پیش‌پردازش، ۱۵ آزمایش و ۷ علامت حیاتی انتخاب و به بازه [۱،۰] نرمال می‌شوند. سپس ویژگی‌های مهندسی شده ساخته می‌شود و برای هر بیمار یا بردار جدولی ۲۵ بعدی، یا دنباله توکن مناسب رمزگذار ETHOS با بردار نهفته ۱۲۸ بعدی تولید می‌گردد. برای شبیه‌سازی فدرال، کوهورت بر اساس تشخیص اصلی ICD-10 لایه‌بندی می‌شود.

جدول ۱.۶: گردش استخراج و پردازش داده MIMIC-IV

مرحله	ورودی	خروجی
استخراج	patients, admissions, icustays	اقامت‌های ICU با جمعیت‌شناسی
انتخاب	labevents, chartevents (از طریق stay_id)	آزمایشگاه و علائم حیاتی به‌ازای هر اقامت
نرمال‌سازی	15 آزمایش + 7 علامت حیاتی	ItemID ها از d_labitems, d_items
مهندسی	مقادیر خام	[1,0] min-max
بازنمایی	مقادیر نرمال شده	پراکسی SOFA، شاخص شوک، شمار غیرطبیعی
رمزگذاری	ویژگی‌های مهندسی شده	جدولی 25-بعدی دنباله توکن
	دنباله توکن	ETHOS → بردار نهفته 128-بعدی
خروجی: 2,000 بیمار؛ هر کدام 25 ویژگی به‌اضافه‌ی برچسب		

۲.۶ جمعیت‌شناسی کوهورت

جدول ۲.۶ آمار جمعیت‌شناختی کوهورت را نشان می‌دهد. در نمونه ۲,۰۰۰ بیمار، نرخ امکان‌پذیری درمان حدود ۴۲٪ است و ۵۸٪ نمونه‌ها در گروه ناممکن قرار می‌گیرند؛ این عدم‌تعادل نسبی نشان می‌دهد پیش‌بینی ترخیص ICU مسئله‌ای ساده و کاملاً جداپذیر نیست. توزیع سن نیز به سمت سنین بالاتر کشیده شده و بیشتر بیماران در بازه ۶۰ تا ۸۰ سال قرار دارند.

۳.۶ توزیع گره بیماری

جدول ۴.۶ توزیع بیماران را در پنج گره بیماری نشان می‌دهد. برای شفافیت و بازتولیدپذیری، جدول ۳.۶ نیز چند کد نمونه از ICD-10 را برای هر گره فهرست می‌کند. گره‌های سپسیس و قلبی از نظر تعداد نمونه بزرگ‌ترند، در حالی که گره‌های کلیوی و دیابت نمونه‌های کمتری دارند. همین تفاوت اندازه، استفاده از رویکردهای کم‌نمونه و فدرال را برای گروه‌های کم‌داده توجیه می‌کند.

جدول ۲.۶: جمعیت‌شناسی گسترده کوهورت

مقدار	معیار
2,000	کل بیماران
840 (42%)	ممکن (برچسب=1)
1,160 (58%)	ناممکن (برچسب=0)
64.2	میانگین سن (سال)
67	میانه سن (سال)
۱۸-۹۰	دامنه سن
44%	زن
56%	مرد
72.4	میانگین طول اقامت ICU (ساعت)
48	میانه طول اقامت ICU (ساعت)

جدول ۳.۶: نمونه‌هایی از کدهای ICD-10 به تفکیک گره بیماری


گره	کد	شرح
1	A41, A40	استریتوکوک/سپسیس
1	R652	سپسیس شدید
2	I22, I21	انفارکتوس حاد میوکارد
2	I50	نارسایی قلبی
3	J44, J18	پنومونی، COPD
3	J96	نارسایی تنفسی
4	N19, N18, N17	نارسایی حاد/مزمن کلیه
5	E13, E11, E10	دیابت قندی

جدول ۴.۶: توزیع بیماران به تفکیک گره بیماری

گره	گروه تشخیصی	بیماران	درصد ممکن
1	سپسیس (A41, A40, R652)	412	38
2	قلبی (I21, I22, I25, I50 و غیره)	398	45
3	تنفسی (J18, J44, J96 و غیره)	356	41
4	کلیوی (N17, N18, N19)	418	39
5	دیابت (E10, E11, E13)	416	46

۴.۶ همبستگی آزمایشگاه و علائم حیاتی


کراتینین با BUN همبستگی بالایی دارد ($r > 0.7$) و هر دو شاخصی از عملکرد کلیه‌اند. هموگلوبین و پلاکت‌ها نیز بخشی از الگوی خون‌شناختی بیمار را منعکس می‌کنند، و در بیماران بحرانی گلوکز و لاکتات می‌توانند همزمان افزایش یابند. این همبستگی‌ها برای مهندسی ویژگی مهم‌اند، زیرا نشان می‌دهند کدام ویژگی‌ها اطلاعات مکمل دارند و کدام‌ها ممکن است تا حدی افزونه باشند.



شکل ۲.۶: ماتریس همبستگی پیرسون برای آزمایشگاه‌ها و علائم حیاتی (ساختار گویای کوهورت آموزش).

۵.۶ پراکسی SOFA و شدت بالینی

پراکسی SOFA از کراتینین، پلاکت‌ها، SpO₂، و لاکتات محاسبه می‌شود. SOFA بالاتر (اختلال اندام بدتر) با امکان‌پذیری پایین‌تر همبسته است، همان‌طور که بالینی انتظار دارد. میانگین پراکسی SOFA برای بیماران ممکن ۰.۳۵ در برابر ۰.۵۲ برای ناممکن است ($p < 0.001$ ، رتبه‌جمع ویلکاکسون).



شکل ۳.۶: پراکسی SOFA در برابر کراتینین (نرمال‌شده) به تفکیک برچسب امکان‌پذیری؛ SOFA و کراتینین بالاتر با تریخ ناممکن همراه‌اند.

۶.۶ عملکرد لایه‌بندی‌شده بر اساس سن


بیماران ۶۵ سال و بالاتر نرخ امکان‌پذیری پایین‌تری دارند (۳۷٪)؛ این نرخ برای گروه ۱۸ تا ۴۵ سال ۵۱٪ و برای گروه ۴۵ تا ۶۵ سال ۴۴٪ است. AUROC مدل در گروه ۶۵ سال و بالاتر نیز اندکی پایین‌تر از کل کوهورت است (۰.۷۲ در برابر ۰.۷۶). این تفاوت نشان می‌دهد که در صورت استقرار بالینی، ارزیابی انصاف و پایش عملکرد در زیرگروه‌های سنی ضروری است.

۷.۶ تحلیل خطا: کراتینین


کراتینین از ویژگی‌های برتر است. طبقه‌بندی‌های اشتباه در بازه‌های مرزی (کراتینین نرمال شده ۰.۳-۰.۵) خوشه‌بندی می‌شوند، جایی که عملکرد کلیه نه کاملاً طبیعی است و نه شدیداً مختل. در این بازه‌ها نرخ خطا حدود ۴۰٪ در برابر ۲۰٪ در بازه‌های شدید است.

۸.۶ تصویرسازی فضای نهفته (t-SNE)

نمای t-SNE از بردارهای نهفته ETHOS نشان می‌دهد بیماران ممکن و ناممکن تا حدی از هم جدا می‌شوند، اما هم‌پوشانی میان دو کلاس همچنان قابل توجه است. این الگو با عملکرد متوسط مدل کم‌نمونه سازگار است.




شکل ۴.۶: AUROC آزمون لایه‌بندی‌شده بر سن: Random Forest، انباشت V4، و خط پایه ETHOS با یادگیری کم‌نمونه.



شکل ۵.۶: نرخ خطای طبقه‌بندی به‌تفکیک بازه کراتینین (RF در برابر ETHOS) با شمار بیماران.

امتیاز سیلوئت برای پارتیشن دوکلاسه برابر ۰.۱۲ است؛ یعنی ساختار خوشه‌ای ضعیف اما کاملاً تصادفی نیست.




شکل ۹.۶: t-SNE بردارهای نهفته ETHOS (بیماران آزمون): هم‌پوشانی جزئی کلاس‌های ممکن در برابر ناممکن.

۹.۶ تحلیل نمونه


در شبکه‌های نمونه‌ای، برای هر کلاس یک نمونه‌ی اولیه ساخته می‌شود که برابر میانگین بردارهای نهفته مجموعه پشتیبان است. فاصله‌ی اقلیدسی میان دو نمونه اولیه در فضای نهفته ۱۲۸ بعدی برابر ۳.۴۲ است. این فاصله نشان می‌دهد سر کم‌نمونه تا حدی توان تفکیک دارد، اما جداسازی کلاس‌ها قوی نیست. بیماران پرس‌وجو بر اساس نزدیک‌ترین نمونه‌ی اولیه طبقه‌بندی می‌شوند.

۱۰.۶ نمونه خط زمانی بیمار

الگوهای زمانی، مانند کاهش کراتینین یا پایداری علائم حیاتی، برای برآورد امکان‌پذیری ترخیص اطلاعات مهمی فراهم می‌کنند. برای نمونه، بیماری که کراتینین او در ۲۴ ساعت از ۲.۱ به ۱.۴ mg/dL کاهش یافته و هم‌زمان ضربان قلب او در بازه ۷۵ تا ۸۵ bpm و فشار خون سیستولیک او در بازه ۱۲۰ تا ۱۳۰ mmHg پایدار مانده است، احتمال امکان‌پذیری بالاتری دارد (۰.۷۸). توکن‌سازی در این پژوهش چنین مسیرهای زمانی را به بازنمایی با طول ثابت تبدیل می‌کند.



شکل ۷.۶: شماتیک مجموعه‌های پشتیبان، نمونه‌های کلاس، و طبقه‌بندی پرس‌وجو در فضای نهفته (پیش‌نمایش دوبعدی).



شکل ۸.۶: نمونه مسیر ۲۴ ساعت اول ICU: ضربان قلب، فشار خون، و کراتنین (گویای).

۱۱.۶ تعادل کلاس

SMOTE را برای مدیریت عدم تعادل ۵۸/۴۲ بررسی کردیم. در این وظیفه، وزن دهی کلاس در تابع زیان و تنظیم آستانه روی مجموعه اعتبارسنجی کافی بود و SMOTE بهبود پایداری ایجاد نکرد. به نظر می‌رسد شدت عدم تعادل در این کوهورت متوسط است و برای بخش قابل توجهی از نمونه‌ها، مرز تصمیم با روش‌های ساده‌تر نیز قابل یادگیری است.

۱۲.۶ فقدان داده و کیفیت داده

در داده بالینی، مقادیر گم شده پدیده‌ای رایج است؛ زیرا آزمایش‌ها با نظم یکسان برای همه بیماران درخواست نمی‌شوند و نیازهای بالینی هر بیمار متفاوت است. در این کوهورت، مقادیر آزمایشگاهی مانند لاکتات و تروپونین بیشتر از علائم حیاتی معمول مانند ضربان قلب و فشار خون گم می‌شوند. برای توکن‌سازی، در سری‌های زمانی از forward-fill و برای ویژگی‌هایی که کاملاً گم شده‌اند از میانه جمعیت استفاده می‌شود. جدول ۵.۶ نرخ فقدان را به تفکیک دسته‌ی ویژگی خلاصه می‌کند. ویژگی‌هایی با فقدان بیش از ۳۰٪، مانند لاکتات در برخی بیماران غیرسپتیک، در استقرار واقعی به پایش و رسیدگی دقیق‌تری نیاز دارند.

جدول ۵.۶: نرخ فقدان به تفکیک دسته ویژگی (24 ساعت اول)

دسته ویژگی	درصد گم شده	جایگزینی
آزمایشگاه‌های معمول (کراتینین، گلوکز)	۵-۱۲	میانه
آزمایشگاه‌های تخصصی (لاکتات، تروپونین)	۱۸-۳۵	میانه
علائم حیاتی (SpO2, BP, HR)	۲-۸	Forward-fill
مهندسی شده (SOFA, شاخص شوک)	0	مشتق

۱۳.۶ ارزیابی کیفیت داده

کیفیت داده را با چند معیار سنجیدیم: (۱) **کامل بودن**: سهم مقادیر غیرگم شده به ازای هر ویژگی؛ آزمایشگاه‌های معمول (کراتینین، سدیم) بیش از ۹۰٪ کامل هستند؛ آزمایشگاه‌های تخصصی (لاکتات، تروپونین) ۶۵-۸۰٪. (۲) **باورپذیری**: مقادیر در بازه‌های بالینی (مثلاً کراتینین ۰.۱-۳۰ mg/dL)؛ پرت‌ها را برش می‌دهیم. (۳) **سازگاری**: بدون تناقض (مثلاً ترخیص پیش از پذیرش)؛ زمان‌بندی‌ها را اعتبارسنجی کردیم. (۴) **نمایندگی**: کوهورت با توزیع سن و جنس MIMIC-IV هم‌خوان است؛ نمونه‌برداری لایه‌ای ما تعادل بین گره‌های بیماری را تضمین

می‌کند. این بررسی‌ها اعتبار نتایج تجربی را پشتیبانی می‌کنند.

۱۴.۶ الگوهای زمانی

روندهای زمانی در ۲۴ ساعت نخست بستری بررسی شد. بیمارانی که آزمایش‌های آنان مسیر بهبود را نشان می‌دهد، برای مثال کاهش کراتینین یا پایداری گلوکز، معمولاً نرخ امکان‌پذیری بالاتری دارند. پراکسی SOFA محاسبه‌شده از اوج مقادیر ۲۴ ساعت نخست نیز با امکان‌پذیری همبسته است (بخش ۵.۶). در این پژوهش، اطلاعات زمانی به دنباله توکنی با طول ثابت تبدیل می‌شود؛ در کار آینده می‌توان مدل‌سازی زمانی صریح، مانند LSTM روی پنجره‌های ساعتی، را برای ثبت مستقیم‌تر روندها بررسی کرد.

۱۵.۶ توزیع مقادیر آزمایشگاه و علائم حیاتی

توزیع مقادیر کلیدی آزمایشگاه و علائم حیاتی در سراسر کوهورت بررسی شد. میانۀ کراتینین 1.1 mg/dL است (IQR: 0.8 تا 1.8) و 12% بیماران مقداری بالاتر از 2.0 دارند که با اختلال عملکرد کلیه سازگار است. میانۀ گلوکز 140 mg/dL است (IQR: 110 تا 180) و نوسان قند در بیماران بحرانی بالا دیده می‌شود. میانۀ هموگلوبین 9.2 g/dL است (IQR: 7.8 تا 10.5) و 28% بیماران مقدار کمتر از 8.0 دارند. میانۀ لاکتات نیز 1.6 mmol/L است (IQR: 1.0 تا 2.5) و لاکتات بالاتر از 2.0 در 35% بیماران با امکان‌پذیری پایین‌تر همراه است. این توزیع‌ها مبنای مهندسی ویژگی و تفسیر بالینی پیش‌بینی‌های مدل هستند. پراکسی SOFA که از کراتینین، پلاکت‌ها، SpO_2 و لاکتات محاسبه می‌شود، میانۀ 0.42 دارد (IQR: 0.28 تا 0.58)؛ مقادیر بالاتر نشان‌دهنده اختلال اندام بیشتر و نرخ امکان‌پذیری پایین‌تر است.

۱۶.۶ نوع پذیرش و مقصد ترخیص

امکان‌پذیری درمان بر اساس نوع پذیرش و مقصد ترخیص نیز تحلیل شد. پذیرش‌های اورژانسی نسبت به پذیرش‌های انتخابی نرخ امکان‌پذیری پایین‌تری دارند (38% در برابر 48%)، که با شدت بالینی بیشتر سازگار است. در کل کوهورت، 22% بیماران به منزل، 18% به توان‌بخشی، 15% به مراقبت تخصصی پرستاری و 25% به مراقبت حاد دیگر ترخیص شده‌اند؛ مرگ بیمارستانی نیز 8% است. در تعریف برچسب این پژوهش، ترخیص به منزل، مراقبت خانگی و توان‌بخشی در گروه ممکن قرار می‌گیرند و سایر مقاصد در گروه ناممکن. این تعریف دودویی بخشی از ظرافت بالینی را از دست می‌دهد، اما مسئله را برای مدل‌سازی اولیه قابل مدیریت می‌کند.

۱۷.۶ ساختار همبستگی و افزونگی ویژگی

ساختار همبستگی، روابط بالینی مورد انتظار را نیز تأیید می‌کند. کراتینین و BUN همبستگی قوی دارند ($r > 0.7$) و هر دو عملکرد کلیه را بازتاب می‌دهند. هموگلوبین و هماتوکریت نیز همبستگی بسیار بالایی دارند ($r > 0.9$)، بنابراین از دید مدل می‌تواند اطلاعات افزونه ایجاد کنند. سدیم و کلر نیز با یکدیگر همبسته‌اند ($r > 0.6$) و به تعادل الکترولیتی مربوط می‌شوند. این الگوها در انتخاب ویژگی اهمیت دارند؛ زیرا حذف ویژگی‌های بسیار افزونه می‌تواند مدل را ساده‌تر کند، بدون آنکه توان پیش‌بینی به‌طور محسوس کاهش یابد.

۱۸.۶ جمع‌بندی فصل

این فصل کوهورت MIMIC-IV را از چند زاویه بررسی کرد: طر حواره پایگاه داده و روند استخراج، جمعیت‌شناسی، توزیع گره‌های بیماری، همبستگی آزمایش‌ها و علائم حیاتی، پراکسی SOFA، عملکرد به‌تفکیک سن، تحلیل خطا، بردارهای نهفته، تعادل کلاس، الگوهای فقدان، کیفیت داده، روندهای زمانی و ساختار همبستگی. مهم‌ترین یافته‌ها چنین‌اند: (۱) کوهورت میان گره‌های بیماری نسبتاً متعادل است؛ (۲) همبستگی‌های آزمایشگاهی با روابط بالینی شناخته‌شده هم‌خوانی دارد؛ (۳) پراکسی SOFA با امکان‌پذیری درمان رابطه دارد؛ (۴) خطاهای طبقه‌بندی بیشتر در مقادیر مرزی آزمایشگاهی رخ می‌دهند؛ و (۵) بردارهای نهفته ETHOS جداسازی جزئی اما نه کامل میان دو کلاس نشان می‌دهند. این نتایج مبنای انتخاب معماری، مهندسی ویژگی و تفسیر نتایج تجربی در فصل‌های بعد هستند.

فصل ۷

بحث و گفتگو

۱.۷ تفسیر عملکرد

۱.۱.۷ از نتیجه منفی تا نزدیکی به تساوی

یافته کلیدی این پایان نامه این است که خط پایه ساده‌ی کم‌نمونه می‌تواند به‌طور محسوس از مدل‌های جدولی قوی روی همان وظیفه عقب بماند. این موضوع صریح گزارش شده است، زیرا نتایج منفی نیز مرزهای روش را روشن می‌کنند و از تکرار مسیرهای ناموفق جلوگیری می‌نمایند. بر اساس **معیارهای منجمد ارسال**، مدل جدولی SOTA به AUROC آزمون ۰.۷۴۸ می‌رسد، در حالی که اجرای انباشتی یکپارچه مقدار ۰.۷۴۶ [۰.۶۹۹, ۰.۷۹۷] را ثبت می‌کند؛ یعنی تنها حدود ۰.۰۰۲ پایین‌تر از برآورد نقطه‌ای SOTA. بهترین زیرمدل کم‌نمونه به‌تنهایی ۰.۶۷۰ است. مقایسه Exp1 روی تقسیم ثابت نیز شکاف کنترل‌شده را نشان می‌دهد: مدل پیشنهادی کم‌نمونه با ۰.۶۱۱ در برابر RF با ۰.۷۶۲. فصل ۵ علاوه بر این، کمپین V1–V6 را به‌عنوان مسیر تاریخی توسعه مستند می‌کند.

در تفسیر بالینی، امکان‌پذیری درمان در این پایان نامه یک برجسب عملیاتی مبتنی بر پیامد تریخیس/بستری مجدد است، نه توصیه مستقیم درمان یا جایگزین قضاوت پزشک. بنابراین حتی بهترین مدل فقط می‌تواند بیمار را از نظر احتمال قرارگرفتن در مسیر قابل قبول درمان/تریخیس رتبه‌بندی کند و برای کاربرد واقعی به اعتبارسنجی محلی، کالیبراسیون و نظارت بالینی نیاز دارد.

۲.۱.۷ سقف تجربی و بستن تدریجی فاصله

نتایج ما سقف جدولی روشنی برای این کوهورت نشان می‌دهد: AUROC بسته به پروتکل در بازه $۰.۷۶۰-۰.۷۴۸$ قرار دارد. مقدار ۰.۷۶۲ برای Random Forest خروجی پروتکل ثابت Exp1 است، اما مقدار ۰.۷۴۸ مربوط به فرایند منجمد Tabular SOTA است؛ بنابراین این دو عدد را نباید به‌عنوان تناقض خواند. پیکربندی تاریخی آغازین در کمپین توسعه با کم‌نمونه ساده نزدیک ۰.۶۱۹ شروع می‌شود؛ اما این عدد با Exp1 ثابت (۰.۶۱۱) یکسان نیست و نباید جایگزین آن شود. راهبردهای بعدی در همان مسیر توسعه، با انباشت، GFA و آموزش چندمرحله‌ای فاصله را کاهش می‌دهند. نتیجه انباشتی کم‌نمونه که مرجع ارسال است، ۰.۷۴۶ است.

۲.۷ محدودیت‌های فرا یادگیری کم‌نمونه

۱.۲.۷ ناسازگاری اپیزودیک

امکان‌پذیری درمان ممکن است با فرا یادگیری اپیزودیک هم‌راستا نباشد. وظیفه ممکن است به آمار سراسری (مثلاً توزیع آزمایشگاهی جمعیت، عوامل ریسک سطح کوهورت) نیاز داشته باشد نه نمونه‌های اولیه محلی مجموعه پشتیبان. شبکه‌های نمونه‌اولیه فرض می‌کنند هویت کلاس را میانگین چند هفته‌سازی پشتیبان می‌گیرد؛ برای امکان‌پذیری درمان، مرز تصمیم ممکن است به تعاملات غیرخطی پیچیده وابسته باشد که با مرکزهای نمونه‌اولیه خوب تقریب زده نمی‌شوند.

برای تصویرسازی، دو بیمار را در نظر بگیرید: بیمار A کراتینین بالا (۰.۸ نرمال‌شده) و لاکتات نرمال (۰.۲) دارد؛ بیمار B کراتینین نرمال (۰.۲) و لاکتات بالا (۰.۷) دارد. هر دو ممکن است غیرممکن باشند اما به دلایل متفاوت. نمونه‌اولیه کلاس «غیرممکن» این پروفایل‌های متفاوت را میانگین می‌گیرد و مرکزی با کراتینین متوسط (۰.۵) و لاکتات متوسط (۰.۴۵) می‌سازد؛ پروفایلی که هیچ‌کدام از بیماران را خوب نمایندگی نمی‌کند. این مشکل «میانگین‌گیری نمونه‌اولیه» بنیادین برای شبکه‌های نمونه‌اولیه است و وقتی کلاس‌ها توزیع چندوجهی یا ناهمگن دارند تشدید می‌شود. مدل‌های درخت‌بنیاد این وضعیت را طبیعی‌تر از راه افرازهای ویژگی‌محور که زیرجمعیت‌های مختلف را در یک کلاس جدا می‌کنند، مدیریت می‌کنند.

۲.۲.۷ ناسازگاری سوگیری القایی

داده جدولی و تصویر ساختار بنیاداً متفاوتی دارند و سوگیری‌های القایی که کم‌نمونه را در تصویر موفق می‌کند ممکن است به جدول منتقل نشود:

۱. همسایگی فضایی در تصاویر در برابر استقلال ویژگی در جدول. شبکه‌های کانولوشنی از همسایگی فضایی؛ پیکسل‌های نزدیک همبسته؛ برای یادگیری سلسله‌مراتبی بهره می‌برند. ویژگی‌های جدولی این ساختار را ندارند؛ کراتینین و ضربان قلب در هیچ معنای فضایی «مجاور» نیستند. مکانیزم خودتوجه ترنسفورمر می‌تواند تعاملات ویژگی دلخواه یاد بگیرد اما باید از صفر بدون سوگیری فضایی این کار را کند.

۲. شکاف یادگیری انتقالی. در بینش، روش‌های کم نمونه از ستون فقرات‌های ازپیش آموزش دیده (ImageNet) سود می‌برند. ستون فقرات مشابهی برای داده جدولی بالینی وجود ندارد. رمزگذار ETHOS ما از صفر روی ۱,۲۸۰ بیمار آموزش دیده که کیفیت بازنمایی‌های آموخته شده را محدود می‌کند.

۳. مهندسی ویژگی به عنوان دانش ضمنی قبلی. مدل‌های کلاسیک روی ویژگی‌های دست‌ساز مانند shock index و پراکسی SOFA کار می‌کنند؛ ویژگی‌هایی که دهه‌ها دانش بالینی را در خود دارند. رمزگذار ETHOS باید این روابط را از داده محدود دوباره کشف کند. شکاف میان ETHOS تاریخی (۰.۶۱۹) و LR روی ویژگی‌های خام (۰.۷۲۴) نشان می‌دهد فرایند کدگذاری، دست‌کم در پیکربندی‌های اولیه، ممکن است بیش از آنکه از تعاملات آموخته شده سود ببرد بخشی از اطلاعات را از دست بدهد.

۴. تنوع وظیفه در فرا آموزش. بنچمارک‌های کم نمونه (miniImageNet) از صدها کلاس نمونه می‌گیرند و اپیزودهای متنوع می‌سازند. طبقه‌بندی ۲ راه با ۵ گره بیماری تنوع وظیفه محدودی دارد که ممکن است به فرا-بیش‌برازش منجر شود؛ مدل توزیع اپیزود خاص را حل می‌کند نه ترکیب‌های جدید بیمار را تعمیم می‌دهد.

۳.۲.۷ مقیاس داده

۲,۰۰۰ بیمار ممکن است برای فرا یادگیری جهت یادگیری بازنمایی‌های تاب‌آور کافی نباشد. روش‌های کم نمونه اغلب به مجموعه‌های فرا آموزش بزرگ برای شبیه‌سازی وظایف متنوع نیاز دارند. با تنها ۲,۰۰۰ بیمار و ۵ گره بیماری، تنوع اپیزودها محدود است. پیش‌آموزش بزرگ‌تر روی MIMIC-IV یا EHR خارجی می‌تواند عملکرد را بهبود دهد.

رابطه بین اندازه مجموعه فرا آموزش و AUROC مورد انتظار را می‌توان از تحلیل حساسیت K -شات و مقایسه با مدل‌های کلاسیک به صورت کیفی تفسیر کرد. مدل‌های کلاسیک در این کوهورت زودتر پایدار می‌شوند، در حالی که چارچوب ETHOS و یادگیری کم نمونه واریانس بالاتر و عملکرد مطلق پایین‌تر نشان می‌دهد. بنابراین

محتمل است که مسیر کم‌نمونه برای رسیدن به عملکرد مدل‌های جدولی قوی به پیش‌آموزش بزرگ‌تر، داده‌ی چندسایتی و اصلاح گلوگاه بازنمایی نیاز داشته باشد. مقدار دقیق داده‌ی لازم از نتایج حاضر قابل تعیین نیست و باید در آزمایش مقیاس‌پذیری مستقل سنجیده شود.

۴.۲.۷ بازنمایی

توکن‌های علائم ممکن است نسبت به ویژگی‌های جدولی خام اطلاعات را از دست بدهند. مدل‌های کلاسیک بردار کامل ۲۵ بعدی را مستقیماً دریافت می‌کنند؛ ETHOS باید از دنباله‌های توکن اطلاعات مرتبط استخراج کند. سوگیری القایی ترنسفورمر ممکن است با ساختار وظایف پیش‌بینی بالینی هم‌تراز نباشد.

۳.۷ تحلیل تفصیلی: چرا خط پایه اولیه کم‌نمونه ضعیف‌تر بود

شکاف اولیه ۰.۱۴ AUROC بین RF (۰.۷۶۰) و خط پایه ETHOS با یادگیری کم‌نمونه (۰.۶۱۹) نیازمند تحلیل دقیق است. درک این عوامل راهبرد بهبود ما را شکل داد. پنج عامل زیر، با تکیه بر شواهد حذف تدریجی:

۱.۳.۷ عامل ۱: گلوگاه فشردده‌سازی بازنمایی

رمزگذار ETHOS ورودی ۲۵ بعدی را به نهفته‌سازی ۱۲۸ بعدی فشرده می‌کند، سپس سر نمونه‌اولیه آن را به فاصله اسکالر کاهش می‌دهد. با وجود آن که بعد نهفته (۱۲۸) از بعد ورودی (۲۵) بیشتر است، تبدیل بی‌زیان نیست. نتیجه حذف تدریجی: LR روی ۲۵ ویژگی خام AUROC ۰.۷۲۴ دارد، بالاتر از ETHOS روی نهفته‌سازی ۱۲۸ بعدی (۰.۶۱۹)؛ نشان می‌دهد رمزگذار ETHOS صرفاً اطلاعات را حفظ نمی‌کند بلکه فعالانه تبدیل می‌کند و این تبدیل ممکن است ویژگی‌های حیاتی برای مرز طبقه‌بندی را حذف کند.

از دید روش‌شناختی، این نتیجه به‌معنای آن نیست که نهفته‌سازی ETHOS همیشه ضعیف‌تر از ویژگی خام است؛ بلکه نشان می‌دهد در این کوهورت و با این اندازه داده، تبدیل توکنی و سر نمونه‌اولیه‌ای هنوز نتوانسته‌اند تمام سیگنال جدولی لازم برای مرز تصمیم را حفظ کنند. بنابراین تفسیر درست، «گلوگاه بازنمایی» است، نه ناکارآمدی ذاتی معماری.

۲.۳.۷ عامل ۲: هندسه نمونه‌اولیه در فضاها کم‌بعد

شبکه‌های نمونه‌اولیه با نزدیک‌ترین نمونه‌اولیه در فضای نهفته طبقه‌بندی می‌کنند. برای کارایی خوب، فضای نهفته باید: (۱) فشردگی درون‌کلاسی: نمونه‌های هم‌کلاس محکم دور نمونه‌اولیه خوشه شوند؛ و (۲) جداسازی

بین‌کلاسی: نمونه‌های اولیه کلاس‌های مختلف دور از هم باشند. تجسم‌های t-SNE ما (فصل ۵) جداسازی متوسط اما ناقص با هم‌پوشانی قابل توجه در ناحیه تصمیم نشان می‌دهند. به صورت رسمی، نرخ خطای طبقه‌بندی نمونه‌اولیه توسط

$$P(\text{error}) \leq \exp\left(-\frac{d(\mathbf{c}_0, \mathbf{c}_1)^2}{8\sigma^2}\right) \quad (1.7)$$

کران داده می‌شود که در آن $d(\mathbf{c}_0, \mathbf{c}_1)$ فاصله‌ی بین نمونه‌های اولیه و σ^2 واریانس درون کلاسی است. وقتی فاصله‌ی نمونه‌های اولیه کوچک و واریانس درون کلاسی زیاد باشد، مرز تصمیم ناپایدار می‌شود؛ این دقیقاً همان رفتاری است که در نتایج اپیزودیک کم‌دامنه دیده می‌شود. RF برعکس در فضای ویژگی اصلی کار می‌کند و با افرازهای هم‌محور می‌تواند زیرجمعیت‌های بالینی متفاوت را صریح‌تر جدا کند.

۳.۳.۷ عامل ۳: واریانس نمونه‌برداری اپیزودیک

هر اپیزود آموزش K پشتیبان و Q پرس‌وجو به‌ازای هر کلاس نمونه می‌گیرد. با $K = 5$ ، نمونه‌اولیه از ۵ بیمار محاسبه می‌شود؛ برآورد پرنویز از مرکز کلاس. واریانس برآورد نمونه‌اولیه

$$\text{Var}(\mathbf{c}_k) = \frac{\sigma_k^2}{K} \quad (2.7)$$

است که σ_k^2 واریانس درون کلاسی است. با $K = 5$ ، واریانس نمونه‌اولیه $\sigma_k^2/5$ است؛ ۵ برابر بیش از میانگین جمعیت. این نویز به مرز طبقه‌بندی منتقل می‌شود و نرخ خطا را افزایش می‌دهد. در عمل، جاروب K-shot ما فقط تغییرات کوچکی نشان می‌دهد: AUROC اپیزودیک در بازه ۰.۵۶۴-۰.۵۵۷ می‌ماند و بهترین مقدار در $K=3$ دیده می‌شود. بنابراین انتظار نظری کاهش واریانس با K بزرگ‌تر در این وظیفه وجود دارد، اما اثر تجربی آن در مقیاس کنونی ضعیف است.

۴.۳.۷ عامل ۴: مدل‌سازی تعامل ویژگی

Random Forest تعاملات ویژگی را طبیعی از راه افراز درخت می‌گیرد: افراز روی کراتینین و سپس سن، تعامل «کراتینین و سن» را می‌گیرد. RF عمق ۲۸ با ۲۰۰ درخت می‌تواند تعاملات تا مرتبه ۲۸ را مدل کند. ترنسفورمر ETHOS تعاملات را از راه خودتوجه چندسری می‌گیرد، اما با تنها ۲ لایه و ۸ سر، ظرفیت برای تعاملات پیچیده ممکن است ناکافی باشد؛ به‌ویژه با داده آموزش محدود.

تقویت گرادیان، مانند XGBoost و LightGBM، AUROC نزدیک به RF (۰.۷۵-۰.۷۳) به دست می‌آورد. این نتیجه تأیید می‌کند که مدل‌سازی تعاملات با درخت‌ها برای این وظیفه مؤثر است. مدل ترکیبی با AUROC برابر ۰.۷۱۷ نشان می‌دهد ETHOS برخی تعاملات مکمل را می‌گیرد که در ویژگی‌های مهندسی‌شده‌ی ۲۵ بعدی کاملاً دیده نمی‌شوند؛ با این حال، این سیگنال به‌تنهایی برای بستن شکاف کافی نیست.

۵.۳.۷ عامل ۵: منظره بهینه‌سازی

آموزش اپیزودیک یک فرا-هدف (زیان روی اپیزودها) را بهینه می‌کند، نه آنتروپی متقاطع استاندارد روی مجموعه آموزش. فرا-هدف پرنویزتر است (هر اپیزود برآورد تصادفی از فرا-زیان است) و ممکن است منظره بهینه‌سازی متفاوتی داشته باشد. با داده فرا آموزش محدود (۱,۲۸۰ بیمار $\div$ ۵ به‌ازای هر کلاس در هر اپیزود $\approx$ ۱۲۸ اپیزود ممکن پیش از تکرار)، مدل ممکن است منظره زیان را به‌اندازه کافی کاوش نکند. مدل‌های کلاسیک یک هدف واحد واضح روی کل آموزش بهینه می‌کنند و راه‌حل‌های پایدارتر می‌دهند.

۴.۷ معامله‌ها و پیامدهای عملی

۱.۴.۷ چه‌وقت از ETHOS و یادگیری کم‌نمونه استفاده کنیم

در تنظیمات فدرال و کم‌داده که حریم خصوصی حیاتی است و مدل‌های کلاسیک نمی‌توانند به‌صورت متمرکز آموزش ببینند (مثلاً همکاری بین مؤسسه با حاکمیت داده سخت)، رویکرد ما خط پایه عملی ارائه می‌کند. شکاف فدرال در آزمایش گزارش‌شده حدود ۰.۰۰۵ واحد AUROC است؛ بنابراین در این شبیه‌سازی، حریم خصوصی با افت عملکردی محدود به دست آمده است.

۲.۴.۷ چه‌وقت از مدل‌های کلاسیک استفاده کنیم

برای بیشینه دقت روی این وظیفه، Random Forest یا XGBoost تنظیم‌شده ترجیح داده می‌شود. توصیه می‌کنیم پژوهشگران هر دو را گزارش کنند: مدل‌های کلاسیک به‌عنوان مرز بالا، و چارچوب ETHOS با یادگیری کم‌نمونه به‌عنوان خط پایه فدرال/کم‌داده. انتخاب به‌بستر استقرار (متمرکز در برابر فدرال، دسترسی به داده) بستگی دارد. جدول ۱.۷ راهنمای تصمیم ارائه می‌کند.

جدول ۱.۷: راهنمای انتخاب مدل

سناریو	مدل توصیه شده	استدلال
بیشینه دقت، متمرکز جدولی SOTA یا RF تنظیم AUROC در حدود ۰.۷۴۸-۰.۷۶۰ (فصل ۵) آستانه		
بهترین ترکیب کم نمونه + کلاسیک	Stacked BEST	AUROC 0.746 [0.699, 0.797]
بهترین عصبی تکی (کمپین V)	CrossAttn+GFA V5	بهترین بذر 0.737؛ میانگین Ensemble 0.722 (تاریخی)
فدرال، حریم بحرانی	چیدمان فدرال (فصل ۵)	شکاف حدود AUROC 0.005 نسبت به متمرکز
گره جدید کم داده	Proto-MAML FewShot	سازگاری زمان آزمون با پشتیبان کم
استقرار تولید	+ Stacked BEST SHAP + کالبراسیون	نمونه پژوهشی؛ اعتبارسنجی محلی

۳.۴.۷ از ترکیبی به انباشت: مسیر تا تساوی

مدل ETHOS_RF_Hybrid با AUROC ۰.۷۱۷ در کمپین V نشان داد ترکیب بردارهای نهفته ETHOS با ویژگی های جدولی می تواند فاصله تا خطوط پایه کلاسیک را کم کند. انباشت V4 با ۰.۷۳۲ و بهترین بذر V5 با ۰.۷۳۷ نیز نقش هم آمیزی و معماری را بیشتر بررسی کردند. اجرای انباشتی **منجمد ارسال**، یعنی exp_fewshot_best با AUROC ۰.۷۴۶، روایت کم نمونه + کلاسیک را با برآورد نقطه ای SOTA جدولی (۰.۷۴۸) هم تراز می کند.

۵.۷ اعتبارسنجی بالینی و تحلیل علی: چارچوب پیشنهادی

نتایج این پایان نامه ماهیت پیش بینی دارند، نه علی. بنابراین از آن ها نباید نتیجه گرفت که خود مدل باعث کاهش بستری مجدد، کاهش طول اقامت یا بهبود پیامد بالینی می شود. مدل تنها نشان می دهد با استفاده از داده های ۲۴ ساعت نخست می توان بیماران را از نظر امکان پذیری درمان و ترخیص بهتر رتبه بندی کرد. برای تبدیل این یافته به ادعای بالینی، مرحله بعدی باید یک اعتبارسنجی آینده نگر یا نیمه آزمایشی باشد.

۱.۵.۷ مسیر پیشنهادی برای اعتبارسنجی آینده

برای ارزیابی اثر واقعی در محیط بالینی، سه گام پیشنهاد می شود: نخست، خروجی مدل روی کوهورت مستقل و بدون دخالت در تصمیم پزشک ثبت شود تا کالبراسیون و عملکرد زیرگروهی بررسی گردد. دوم، بیماران با ریسک

مشابه از نظر سن، جنس، تشخیص اصلی، شدت بیماری و شاخص‌های آزمایشگاهی با روش‌هایی مانند تطبیق امتیاز گرایش مقایسه شوند. سوم، اگر بیمارستان چند بخش یا چند مرکز با سیاست‌های متفاوت داشته باشد، می‌توان از طرح‌های نیمه‌آزمایشی مانند اختلاف در اختلاف‌ها یا متغیر ابزاری استفاده کرد؛ البته فقط زمانی که فرض‌های شناسایی به‌روشنی برقرار باشند.

۲.۵.۷ مرزبندی ادعا

در نسخه حاضر، ادعای اصلی این است که مدل‌ها توان پیش‌بینی امکان‌پذیری را دارند و در حالت انباشتی به سقف جدولی نزدیک می‌شوند. ادعای علی یا اثر مستقیم بر گردش کار درمانی گزارش نمی‌شود. این مرزبندی برای داوری علمی مهم است، زیرا حتی مدل دقیق نیز بدون مطالعه مداخله‌ای نمی‌تواند به‌تنهایی اثبات کند که تصمیم‌های درمانی را بهتر می‌کند.

۶.۷ یادگیری چندوظیفه‌ای: مسیر توسعه

یک مسیر طبیعی برای ادامه این پژوهش، گسترش رمزگذار ETHOS به یادگیری چندوظیفه‌ای است؛ برای نمونه، امکان‌پذیری درمان، مرگ‌ومیر کوتاه‌مدت، طول اقامت ICU و خطر بستری مجدد می‌توانند سرهای خروجی جداگانه داشته باشند و در یک رمزگذار مشترک آموزش ببینند. انتظار روش‌شناختی این است که وظایف نزدیک به هم، بخشی از سیگنال شدت بیماری و مسیر بهبود را مشترک کنند و در نتیجه بازنمایی پایدارتری بسازند. با این حال، در این نسخه عدد چندوظیفه‌ای به‌عنوان نتیجه اصلی گزارش نمی‌شود؛ زیرا اجرای کامل آن نیازمند تعریف دقیق برجسب‌های ثانویه، توازن زیان‌ها، کنترل نشتی زمانی و اعتبارسنجی جداگانه برای هر پیامد است. بنابراین جایگاه چندوظیفه‌ای در این پایان‌نامه «پیشنهاد توسعه» است، نه ادعای عملکرد.

۷.۷ تحلیل حساسیت

با پیروی از چارچوب تحلیل نظری پیشنهاد، تحلیل‌های حساسیت برای تاب‌آوری یافته‌ها انجام شد.

۱.۷.۷ حساسیت ابرپارامتر

اب‌پارامترهای کلیدی را تغییر دادیم و تغییر AUROC را اندازه گرفتیم. برای ETHOS: بعد نهفته (۶۴، ۱۲۸، ۲۵۶)، تعداد سرها (۲، ۴، ۸)، و Dropout (۰.۱، ۰.۲، ۰.۳). AUROC در حدود ۰.۰۲ بالا یا پایین می‌شد و ترکیب

۱۲۸ بعد و ۴ سر، بهترین توازن را نشان داد. برای Random Forest: max_depth (۲۵-۵) و n_estimators (۵۰۰-۱۰۰۰) بررسی شد. AUROC از عمق ۱۰ به بالا و با دست کم ۲۰۰ برآوردگر، در بازه حدود ۰.۰۱ پایدار ماند.

۲.۷.۷ حساسیت شات پشتیبان K

با تغییر مقدار K در میان ۱، ۳، ۵، ۱۰ و ۱۵ در آزمایش حساسیت K-شات، AUROC در بازه ۰.۵۶۴-۰.۵۵۷. باقی ماند. بهترین میانگین در K=3 با ۰.۵۶۴ دیده شد و K=1 تقریباً همان عملکرد را نشان داد. روند صعودی یکنواختی مشاهده نمی‌شود. مدل منجمد Proposed_FewShot در Exp1 روی ارزیابی ثابت عدد ۰.۶۱۱ دارد؛ بنابراین اختلاف عمده بیشتر از تفاوت پروتکل ارزیابی ناشی می‌شود تا صرفاً شمار شات پشتیبان.

۳.۷.۷ اثر ترکیب ماژول‌ها

سهم هر ماژول را از راه حذف تدریجی leave-one-out (جدول ۷.۵) تحلیل کردیم. حذف وزن دهی شدت AUROC را به ۰.۵۷۷ کاهش داد، در حالی که حذف واگرایی زمانی عملاً تغییری ایجاد نکرد و روی ۰.۵۸۳ باقی ماند. به‌ویژه no_symptom_tokens، یعنی Logistic Regression روی ۲۵ بعد خام، به AUROC ۰.۷۲۴ رسید؛ بالاتر از مدل کامل ETHOS با یادگیری کم‌نمونه با ۰.۵۸۳. این نتیجه نشان می‌دهد بازنمایی مبتنی بر توکن، در مقایسه با ویژگی‌های جدولی خام، ممکن است برای این وظیفه بخشی از اطلاعات را از دست بدهد و رمزگذار ETHOS باید این زیان را جبران کند. همچنین حذف سر کم‌نمونه و جایگزینی آن با سر نظارت‌شده استاندارد به AUROC ۰.۶۴۵ می‌رسد که از مدل کامل بهتر است؛ بنابراین چیدمان اپیزودیک در این مقیاس الزاماً سودمند نیست.

۸.۷ اثر اقتصادی و بازگشت سرمایه‌ی توضیحی (ROI)

تحلیل اقتصادی در این پایان‌نامه به‌صورت چارچوب تصمیم‌گیری مطرح می‌شود، نه محاسبه قطعی بازگشت سرمایه. ROI واقعی به ظرفیت ICU، هزینه‌ی بستری مجدد، درصد پذیرش‌های قابل مداخله، هزینه‌ی اتصال به EHR، بار کاری تیم درمان و سیاست‌های هر مرکز وابسته است. بنابراین به‌جای گزارش یک عدد ثابت، پیشنهاد می‌شود هر مرکز مقدار

$$ROI = \frac{\text{هزینه استقرار و پایش} - \text{صرفه‌جویی ناشی از کاهش خطاهای ترخیص و مدیریت بهتر تخت}}{\text{هزینه استقرار و پایش}}$$

را با داده‌ی محلی خود برآورد کند. نقش نتایج این پژوهش در این محاسبه، فراهم کردن یک مدل رتبه‌بندی و چارچوب پایش است؛ اثبات اثر اقتصادی نیازمند مطالعه‌ی پیاده‌سازی واقعی است.

۹.۷ گسترش سری زمانی: مسیر پیشنهادی

توکن‌سازی ۲۵ توکنی علامت، داده‌های ۲۴ ساعت نخست را به بازنمایی ثابت و قابل تفسیر تبدیل می‌کند؛ اما بخشی از مسیر زمانی بیمار، مانند روند کاهش کراتینین یا پایدار شدن علائم حیاتی، ممکن است در این خلاصه‌سازی از دست برود. از این رو، مسیر بعدی می‌تواند افزودن مدل‌های سری زمانی مانند LSTM، GRU یا ترنسفورمر زمانی روی پنجره‌های چندساعته باشد.

در نسخه‌ی حاضر، مقایسه‌ی کامل و تنظیم‌شده‌ی سری زمانی انجام نشده است؛ بنابراین هیچ برتری عددی برای LSTM یا مدل زمانی دیگر گزارش نمی‌شود. پیام اصلی این بخش آن است که بازنمایی توکنی از نظر تفسیرپذیری، هزینه‌ی محاسباتی و سازگاری با کم‌نمونه/FL مناسب است، اما برای بیشینه‌ی عملکرد آینده باید در کنار ویژگی‌های روندی و مدل‌سازی زمانی ارزیابی شود.

۱۰.۷ تحلیل خطا

جایی که بهترین مدل (جنگل تصادفی) خطا می‌کند را تحلیل کردیم. طبقه‌بندی اشتباه شایع‌تر میان بیماران با کراتینین مرزی (۰.۳-۰.۵ نرمال‌شده) و در گره‌های بیماری با نمونه‌ی آموزش کمتر (کلیه، دیابت) است. کالیبراسیون (شکل ۱۰.۵) نشان می‌دهد احتمالات پیش‌بینی شده برای RF نسبتاً خوب کالیبره‌اند؛ ETHOS گرایش به بیش‌اعتمادی دارد. برای استقرار، نمودارهای قابلیت اطمینان و بازکالیبراسیون (مثلاً Platt scaling) در صورت نیاز توصیه می‌شود.

۱۱.۷ ملاحظات استقرار

برای استقرار تولید توصیه می‌کنیم: (۱) یکپارچه‌سازی: REST API یا HL7 FHIR برای EHR؛ (۲) تأخیر: استنتاج $RF < 10\text{ ms}$ ؛ $ETHOS < 50\text{ ms}$ روی CPU؛ (۳) پایش: ردیابی AUROC، کالیبراسیون، و معیارهای انصاف در زمان؛ (۴) پشتیبان: بازیابی انسانی برای پیش‌بینی‌های کم‌اطمینان (با احتمال کمتر از ۰.۳ یا بیش از ۰.۷)؛ (۵) نسخه‌گذاری: ثبت نسخه‌ی مدل و توزیع داده برای هر پیش‌بینی. مشخصات API در پیوست ز آمده است.

۱۲.۷ مشخصات رابط برنامه‌نویسی کاربردی (API)

برای استقرار و بازتولیدپذیری، مشخصات API (پیوست ز) ارائه شده است. REST API نقاط پایانی برای: (۱) پیش‌بینی امکان‌پذیری (/predict POST)، (۲) فراداده مدل (/model GET)، و (۳) توضیح SHAP (POST) explain دارد. برای مشخصات کامل OpenAPI به پیوست ز مراجعه کنید.

۱۳.۷ تحلیل تفصیلی خطا به تفکیک زیرگروه

نرخ خطا را به تفکیک گروه سنی (۴۵-۱۸، ۶۵-۴۶، ۶۶+)، جنس و نوع پذیرش (انتخابی در برابر اورژانسی) تحلیل کردیم. برای بهترین مدل (RF)، نرخ خطا در گروه ۶۶+ بالاتر است (۲۴٪ در برابر ۱۸٪ برای ۴۵-۱۸)، که با پیچیدگی بالینی بیشتر در سالمندان سازگار است. نرخ خطا به تفکیک جنس مشابه است (۲۰٪ در برابر ۲۱٪). پذیرش‌های اورژانسی نیز نرخ خطای بالاتری دارند (۲۳٪ در برابر ۱۷٪ انتخابی)، که نشان می‌دهد شدت بیماری و ناپایداری مسیر بالینی می‌تواند پیش‌بینی را دشوارتر کند. این تحلیل‌های زیرگروهی برای ارزیابی انصاف مهم‌اند و در استقرار باید عملکرد مدل در گروه‌های جمعیت‌شناختی پایش شود.

۱۴.۷ مقایسه با کار پیشین

۱.۱۴.۷ ادبیات پیش‌بینی ترخیص

کار پیشین روی پیش‌بینی مقصد ترخیص [Caruana et al., 2015, Awad et al., 2017] معمولاً از داده متمرکز و ML کلاسیک استفاده می‌کند. AUROC ۰.۷۶ ما با نتایج گزارش شده برای وظایف مشابه قابل قیاس است. جدول ۲.۷ مقایسه تفصیلی ارائه می‌کند.

نتیجه SOTA/RF در این پژوهش، بسته به پروتکل، در بازه ۰.۷۶۰-۰.۷۴۸ قرار می‌گیرد و با مقادیر گزارش شده برای وظایف مرتبط با ترخیص در داده MIMIC هم‌خوان است. نوآوری این کار در ادعای عبور از همه بنچمارک‌های پیشین نیست؛ بلکه در نشان دادن ظرفیت و محدودیت رویکردهای کم‌نمونه و فدرال برای یک مسئله جدولی بالینی واقعی است.

جدول ۲.۷: مقایسه با نتایج پیشین ترخیص/پیامد

مطالعه وظیفه	مجموعه داده	AUROC	روش کلیدی
Awad 2017 مقصد ترخیص	MIMIC-III	۰.۷۸	RF، متمرکز
Purushotham 2018 مرگ و میر	MIMIC-III	۰.۸۵	LSTM، متمرکز
Rajkomar 2018 بستری مجدد	چندسایتی	۰.۷۶	DNN، متمرکز
Caruana 2015 مرگ و میر	EHR	۰.۸۸	Ensembles
Harutyunyan 2019 چندوظیفه	MIMIC-III	۰.۸۶	LSTM چندوظیفه
ما (SOTA، RF) امکان پذیری	MIMIC-IV	۰.۷۴۸	RF؛ اسکرپت منجمد SOTA
ما (V5 بهترین) امکان پذیری	MIMIC-IV	۰.۷۳۷	CrossAttn+GFA (کمپین V)
ما (انباشت V4) امکان پذیری	MIMIC-IV	۰.۷۳۲	RF+FS (کمپین V)
ما (Stacked BEST) امکان پذیری	MIMIC-IV	۰.۷۴۶	انباشت کم نمونه + کلاسیک
ما (V6) امکان پذیری	MIMIC-IV	۰.۷۲۵	Ensemble ناهمگن (کمپین V)
ما (خط پایه منجمد) امکان پذیری	MIMIC-IV	۰.۶۱۱	مدل پیشنهادی کم نمونه (Exp1)

۲.۱۴.۷ یادگیری کم نمونه در سلامت

یادگیری کم نمونه در تصویربرداری پزشکی، مانند طبقه بندی X-ray با $AUROC > 0.85$ و پوست شناسی با دقت بیش از 80% [Prabhu et al., 2019]، کاربردهای موفقی داشته است؛ اما در پیامدهای جدولی بالینی هنوز کمتر بررسی شده است. نقطه مشترک بسیاری از موفقیت های تصویری، وجود ستون فقرات های کانولوشنی از پیش آموزش دیده است که پیش از سر کم نمونه، ویژگی های غنی استخراج می کنند. نتیجه منفی اولیه در این پژوهش، یعنی ETHOS تاریخی با ۰.۶۱۹ در برابر RF حدود ۰.۷۶۰، نشان می دهد یادگیری کم نمونه جدولی احتمالاً یا به بازنمایی های از پیش آموزش دیده ی قوی تر نیاز دارد یا به معماری هایی که مخصوص داده های جدولی ناهمگن طراحی شده باشند.

جهت های امیدبخش اخیر شامل:

۱. پیش آموزش EHR مقیاس بزرگ: پیش آموزش روی میلیون ها پرونده پیش از تنظیم دقیق کم نمونه،

مشابه پیش آموزش ImageNet برای بینش.

۲. پل های مدل زبانی: استفاده از LLM برای تولید توصیف متنی ویژگی های بیمار، سپس اعمال

روش های کم نمونه مبتنی بر متن (TabLLM [Hegselmann et al., 2023]).

۳. نمونه های اولیه وابسته به وظیفه: یادگیری توابع محاسبه نمونه اولیه ویژه وظیفه به جای میانگین

ساده [Ye et al., 2020].

۳.۱۴.۷ بهداشت فدرال

یادگیری فدرال در سلامت [Duan et al., 2022, Rieke et al., 2020] در چند بستر پژوهشی و عملی امکان پذیر نشان داده شده است. شکاف کوچک فدرال در این پژوهش، حدود ۰.۰۰۵ واحد AUROC، با گزارش های پیشین سازگار است؛ به ویژه زمانی که ناهمگنی داده متوسط باشد. برای نمونه، همکاری Intel–Penn Medicine [Sheller et al., 2020] گزارش کرد که بخش بندی فدرال تومور مغز در ۳۰ مؤسسه به ۹۹٪ عملکرد آموزش متمرکز رسیده است؛ نتیجه ای که امکان پذیری عملی FL در سلامت را تقویت می کند.

تفاوت های کلیدی بین چیدمان فدرال شبیه سازی شده ما و FL دنیای واقعی:

۱. **قابلیت اطمینان ارتباط:** شبیه سازی ما ارتباط همزمان قابل اعتماد فرض می کند. FL واقعی باید خرابی شبکه، timeout، و به روزرسانی های ناهمزمان را مدیریت کند.

۲. **ناهمگنی گره:** گره های ما بر اساس بیماری از هم جدا شده اند؛ اما در محیط واقعی، مؤسسات از نظر سخت افزار، نسخه نرم افزار و روند پردازش داده نیز با هم تفاوت دارند.

۳. **شرکت کنندگان خصمانه:** گره های مخرب یا بی زانسی می توانند مدل سراسری را فاسد کنند. روش های تجمیع تاب آور (مثلاً میانگین هرس شده، Krum [Blanchard et al., 2017]) این را پوشش می دهند اما در خط پایه ما پیاده نشده اند.

۴. **عقب ماندگان:** گره ها با سخت افزار کند یا داده محلی بزرگ ممکن است دورها را به تعویق اندازند. روش های FL ناهمزمان (FedAsync) می توانند این را تخفیف دهند.

۱۵.۷ ملاحظات نظری

۱.۱۵.۷ چرا شبکه های نمونه اولیه ممکن است ضعیف تر عمل کنند

شبکه های نمونه اولیه فرض می کنند هویت کلاس را میانگین بردارهای نهفته پشتیبان می گیرد. برای امکان پذیری درمان، مرز تصمیم ممکن است به تعاملات غیرخطی (مثلاً ترکیب کراتینین و سن، یا ترکیب SOFA و تشخیص) وابسته باشد که با مرکزهای نمونه اولیه خوب تقریب زده نمی شوند. یادگیری متریک ممکن است به توابع فاصله ویژه وظیفه نیاز داشته باشد.

۲.۱۵.۷ کارایی داده

با ۲,۰۰۰ بیمار و ۵ گرۀ بیماری، حدود ۴۰۰ بیمار به‌ازای هر گرۀ داریم. فرا یادگیری کم‌نمونه اغلب از هزاران وظیفه برای نمونه‌برداری اپیزود متنوع سود می‌برد. مقیاس‌دهی به کل کوهورت MIMIC-IV (۲۵۰ هزار + اقامت) یا داده چندسایتی می‌تواند عملکرد ETHOS را بهبود دهد.

۳.۱۵.۷ تهدیدهای اعتبار

چند تهدید اعتبار باید در نظر گرفته شود. از نظر اعتبار درونی، کوهورت از یک مؤسسه (BIDMC) آمده و ممکن است ویژگی‌های همان مرکز را بازتاب دهد. از نظر اعتبار بیرونی، نمونه ۲,۰۰۰ بیمار نسبتاً محدود است و استفاده از کل MIMIC-IV یا داده چندسایتی می‌تواند به نتیجه‌گیری متفاوتی منجر شود. از نظر اعتبار سازه، امکان‌پذیری درمان با مقصد ترخیص و بستری مجدد تعریف شده است؛ تعاریف جایگزین مانند وضعیت عملکردی یا زمان تا ترخیص ممکن است نتایج را تغییر دهند. از نظر اعتبار نتیجه‌گیری نیز، چون همه مدل‌ها بردارهای پیش‌بینی هم‌تراز در یک پروتکل واحد تولید نمی‌کنند، استنتاج آماری جفتی برای همه مقایسه‌ها محدود است. برای کاهش این خطر، بازه‌های اطمینان موجود گزارش شده، از گزارش گزینشی پرهیز شده و مقایسه‌های بین پروتکلی به‌صورت توصیفی تفسیر شده‌اند.

۴.۱۵.۷ گلوگاه بازنمایی: تحلیل عمیق‌تر

توکن‌سازی علائم، فضای جدولی ۲۵ بعدی را به دنباله‌ای از توکن‌های گسسته تبدیل می‌کند. در این تبدیل، بخشی از اطلاعات ممکن است هنگام سطل‌بندی و تجمیع از دست برود. اینکه LR روی ویژگی‌های خام با AUROC برابر ۰.۷۲۴ از ETHOS کامل با ۰.۵۸۳ بهتر عمل می‌کند، این نگرانی را تقویت می‌کند. این گلوگاه از سه منظر بررسی می‌شود:

منظر اطلاع‌نظری. فرایند توکن‌سازی مقادیر پیوسته $x \in [0, 1]$ را به شناسه علامت گسسته (۱-۲۲) و مقدار شدت پیوسته نگاشت می‌کند. با وجود حفظ مقدار نرمال شده توسط شدت، گسسته‌سازی هویت علامت واژگان ثابتی معرفی می‌کند که ممکن است تمایزهای ریز را نگیرد. برای مثال، مقادیر کراتینین ۰.۳۱ و ۰.۶۹ همان شناسه علامت را دارند اما پیامدهای بالینی متفاوت (نرمال در برابر بالا). مدل باید این تمایزها را تنها از بعد شدت یاد بگیرد، در حالی که مدل‌های کلاسیک مستقیماً روی مقدار پیوسته کار می‌کنند.

منظر معماری. مکانیزم خودتوجه ترنسفورمر پیچیدگی محاسباتی $\mathcal{O}(L^2d)$ دارد که در اینجا $L = 25$ طول دنباله است. وقتی دنباله فقط ۲۵ توکن دارد، پنجره زمینه برای توجه محدود است و ممکن است نسبت به معماری‌های ساده‌تر، مانند MLP دولایه روی بردار ۲۵ بعدی صاف شده، مزیت روشنی ایجاد نکند. نتایج حذف تدریجی نیز همین نکته را تأیید می‌کند: جایگزینی ترنسفورمر با یک رمزگذار MLP ساده AUROC را تنها حدود ۰.۰۲ از ETHOS کامل دور می‌کند. بنابراین، برای این طول دنباله و این وظیفه، خودتوجه به‌تنهایی عامل اصلی عملکرد نیست.

راهبردهای تخفیف. بازنمایی‌های جایگزین که می‌توانند گلوگاه را پوشش دهند:

۱. **بردارهای نهفته توکن پیوسته:** جایگزینی شناسه‌های علامت گسسته با بردارهای نهفته پیوسته آموزش دیده به‌ازای هر اندازه‌گیری، تا مدل بازنمایی‌های ویژه وظیفه یاد بگیرد.
۲. **ساختار مبتنی بر گراف:** نمایش روابط آزمایشگاه-علائم حیاتی به‌عنوان گراف (مثلاً یال کراتینین-BUN برای عملکرد کلیه) و استفاده از شبکه‌های عصبی گرافی برای کدگذاری. این ساختار حوزه بالینی را به‌عنوان سوگیری القایی معرفی می‌کند.
۳. **تجمع زمانی چندمقیاس:** به‌جای تجمع تکی ۲۴ ساعته، ویژگی‌ها در پنجره‌های ۴، ۸، ۱۲، و ۲۴ ساعت محاسبه شوند تا بازنمایی زمانی غنی‌تر روندها را بگیرد.
۴. **توکن‌سازی ترکیبی:** ترکیب ویژگی‌های جدولی خام با بازنمایی‌های توکن تا مدل به هر دو قالب دسترسی داشته باشد. معماری ترکیبی ETHOS و Random Forest این راهبرد را تا حدی پیاده می‌کند و به AUROC برابر ۰.۷۱۷ می‌رسد.

۱۶.۷ مقایسه بین حوزه‌ای: یادگیری کم‌نمونه در انواع داده

برای روشن‌تر شدن جایگاه نتایج، عملکرد یادگیری کم‌نمونه در چند نوع داده با هم مقایسه می‌شود. این مقایسه نشان می‌دهد چرا کم‌نمونه جدولی بالینی از نظر بازنمایی و تعمیم با چالش‌های خاصی روبه‌روست.

۱.۱۶.۷ حوزه بینش

روی miniImageNet (۵ راه، ۵ شات)، شبکه‌های نمونه اولیه حدود ۶۸٪ دقت با ستون فقرات CNN ۴ لایه و حدود ۷۴٪ با ستون فقرات ResNet-12 به‌دست می‌آورند [Snell et al., 2017]. عملکرد قوی ناشی از:

(۱) ستون فقرات‌های ازپیش‌آموزش‌دیده قوی با ویژگی‌های غنی و قابل‌انتقال؛ (۲) ساختار فضایی در تصاویر که شبکه‌های کانولوشنی به کارآمد بهره می‌برند؛ (۳) مجموعه‌های فرا آموزش بزرگ (۶۴ کلاس، ~۳۸,۰۰۰ تصویر) که نمونه‌برداری اپیزود متنوع را ممکن می‌کند.

۲.۱۶.۷ حوزه NLP

در طبقه‌بندی متن کم‌نمونه (ARSC, FewRel)، شبکه‌های نمونه‌اولیه ۷۰-۸۵٪ دقت بسته به وظیفه و ستون فقرات به‌دست می‌آورند [Han et al., 2018]. مدل‌های زبانی ازپیش‌آموزش‌دیده (BERT) به‌عنوان ستون فقرات سود چشمگیری می‌دهند، با Proto+BERT تنظیم‌شده با دقت بالاتر از ۸۵٪ روی FewRel. موفقیت ناشی از: (۱) بازنمایی‌های ازپیش‌آموزش‌دیده قوی از متن عظیم؛ (۲) شباهت معنایی که با طبقه‌بندی مبتنی بر فاصله هم‌راستا است.

۳.۱۶.۷ حوزه کشف دارو

در یادگیری کم‌نمونه مولکولی، به‌ویژه در بنچمارک FS-Mol، شبکه‌های نمونه‌اولیه برای پیش‌بینی خاصیت‌ها معمولاً AUROC حدود ۰.۶۰ تا ۰.۷۰ به‌دست می‌آورند [Stanley et al., 2021]. این بازه با خط پایه منجمد Proposed_FewShot در این پژوهش (۰.۶۱۱) قابل مقایسه است. چنین شباهتی نشان می‌دهد پیش‌بینی خاصیت مولکولی و امکان‌پذیری بالینی هر دو با ورودی‌های ناهمگن، مرزهای تصمیم غیرخطی و محدودیت داده پیش‌آموزش روبه‌رو هستند.

۴.۱۶.۷ حوزه جدولی

کار اخیر روی یادگیری کم‌نمونه جدولی [Hegselmann et al., 2023] با بردارهای نهفته مدل زبانی (TabLLM) نتایج متغیر گزارش می‌کند: رقابتی با خطوط پایه در برخی مجموعه‌ها اما ضعیف‌تر در دیگران. یافته کلی آن است که کم‌نمونه جدولی همچنان چالش‌ناز است، سازگار با نتایج ما.

۵.۱۶.۷ ترکیب

جدول ۳.۷ مقایسه بین حوزه‌ای را خلاصه می‌کند.

الگوی کلی روشن است: عملکرد کم‌نمونه زمانی بهتر می‌شود که بازنمایی‌های ازپیش‌آموزش‌دیده قوی وجود داشته باشد و ساختار داده با سوگیری‌های القایی مدل هم‌راستا باشد. داده جدولی بالینی معمولاً هر دو مزیت

جدول ۳.۷: عملکرد یادگیری کم‌نمونه در حوزه‌های مختلف

حوزه	بنچمارک	Proto-Net	بهترین	ازپیش آموزش؟
بینش	miniImageNet 5-way, 5-shot	68% دقت	80%+	بله (ImageNet)
NLP	FewRel 5-way, 5-shot	72% دقت	85%+	بله (BERT)
مولکولی	FS-Mol	۰.۶۵ AUROC	۰.۷۲	جزئی
جدولی (ما)	MIMIC-IV 2-way, 5-shot	۰.۶۱۱ AUROC	۰.۷۴۸ سقف جدولی ۰.۷۳۷ V5	جزئی

را کمتر دارد و همین موضوع بخشی از شکاف عملکرد را توضیح می‌دهد. بنابراین برای کاهش این شکاف، یا باید پیش‌آموزش مقیاس‌بزرگ روی داده‌ی جدولی بالینی انجام شود، مشابه نقشی که ImageNet در بینایی ماشین داشته است، یا باید رویکردهای فرا یادگیری تازه‌ای طراحی شوند که به‌طور خاص با ویژگی‌های جدولی ناهمگن سازگار باشند.

۱۷.۷ پیامدهای بالینی و تحلیل استقرار

۱.۱۷.۷ تأثیر بر گردش کار بالینی

مدل پیش‌بینی امکان‌پذیری درمان می‌تواند در چند نقطه‌ی تصمیم در گردش کار ICU یکپارچه شود:

۱. **ارزیابی ۲۴ ساعته:** پس از ۲۴ ساعت اول پذیرش ICU، مدل امتیاز امکان‌پذیری بر اساس آزمایش‌ها و علائم حیاتی موجود تولید می‌کند. بیماران با امتیاز بالا (بیش از ۰.۷) برای برنامه‌ریزی زودهنگام ترخیص علامت‌گذاری می‌شوند.
۲. **ارزیابی مجدد روزانه:** با دسترسی داده جدید، مدل پیش‌بینی را به‌روز می‌کند. روند امتیاز امکان‌پذیری (صعودی در برابر نزولی) اطلاعات اضافی درباره‌ی مسیر بیمار می‌دهد.
۳. **گردش‌های چندرشته‌ای:** امتیاز امکان‌پذیری همراه داده‌ی بالینی دیگر در گردش‌های صبح ارائه می‌شود و تصمیم‌های مشترک برنامه‌ریزی ترخیص را پشتیبانی می‌کند.
۴. **مدیریت تخت:** پیش‌بینی‌های تجمیعی امکان‌پذیری می‌توانند در برنامه‌ریزی ظرفیت ICU و برآورد دسترسی به تخت به کار روند.

۲.۱۷.۷ اعتماد و پذیرش بالینی

برای پذیرش بالینی، چند عامل باید پوشش داده شوند:

۱. **تفسیرپذیری:** بالینیان باید بفهمند چرا مدل امتیاز خاصی پیش‌بینی می‌کند. توضیحات SHAP (نشان دادن کراتینین بالا و پلاکت پایین پیش‌بینی «غیرممکن» را هدایت می‌کنند) با استدلال بالینی هم‌راستا است و اعتماد می‌سازد. تحلیل اهمیت ویژگی ما تأیید می‌کند ویژگی‌های پیش‌بینی‌کننده برتر (کراتینین، گلوکز، هموگلوبین) با تعیین‌کننده‌های شناخته‌شده ترخیص هم‌خوان‌اند.
۲. **کالیبراسیون:** مدلی که می‌گوید «۷۰٪ احتمال ترخیص امکان‌پذیر» باید تقریباً در ۷۰٪ مواقع درست باشد. تحلیل کالیبراسیون ما نشان می‌دهد RF نسبتاً خوب کالیبره است (Brier ۰.۲۱)، در حالی که ETHOS گرایش به بیش‌اعتمادی دارد. باز کالیبراسیون (Platt scaling یا رگرسیون ایزوتونیک) پیش از استقرار لازم است.
۳. **خستگی هشدار:** اگر مدل برای هر بیمار هشدار تولید کند، بالینیان آن‌ها را نادیده می‌گیرند. انتخاب آستانه باید حساسیت (گرفتن بیماران غیرممکن) و ویژگی (اجتناب از هشدار کاذب) را متعادل کند. RF با آستانه تنظیم‌شده ۰.۵۴ تعادل عمل‌گرایانه‌ای می‌دهد، اما تنظیم ویژه سایت لازم است.
۴. **تخریب تدریجی:** مدل باید داده گم‌شده، پروفایل‌های غیرمعمول، و ورودی‌های خارج از توزیع را بدون پیش‌بینی همراه‌کننده مدیریت کند. امتناع مبتنی بر اطمینان (امتناع از پیش‌بینی وقتی عدم قطعیت مدل بالاست) رویکرد امیدبخشی است.

۳.۱۷.۷ معماری استقرار فدرال

برای استقرار چندمؤسسه‌ای، معماری زیر را تصور می‌کنیم:

۱. هر مؤسسه شرکت‌کننده گره محلی ETHOS را اجرا می‌کند که روی داده خود آموزش دیده است.
۲. سرور تجمع مرکزی (ممکن است توسط طرف سوم بی‌طرف میزبانی شود) دوره‌های FedAvg را هفتگی یا ماهانه هماهنگ می‌کند و مدل سراسری را به‌روز می‌کند.
۳. مدل‌های محلی می‌توانند پس از دریافت به‌روزرسانی سراسری از راه تنظیم دقیق روی داده ویژه سایت شخصی‌سازی شوند و تعمیم سراسری را با سازگاری محلی متعادل کنند.
۴. نسخه‌گذاری مدل و پایش انحراف کمک می‌کند مدل استقرار یافته با تکامل جمعیت بیماران و شیوه‌های

بالینی کالبره بماند.

شکاف محدود فدرال، حدود ۰.۰۰۵ واحد AUROC در آزمایش گزارش شده، این مدل استقرار را پشتیبانی می‌کند: مؤسسات می‌توانند در بهبود مشارکتی مدل شرکت کنند بدون آنکه در این شبیه‌سازی افت بزرگی در عملکرد دیده شود.

۴.۱۷.۷ مسیر نظارتی

استقرار بالینی نیازمند پیمایش چشم‌انداز نظارتی است:

- **FDA (US):** مدل احتمالاً به عنوان نرم‌افزار دستگاه پزشکی رده II (SaMD) طبق برنامه نوآوری سلامت دیجیتال FDA طبقه‌بندی می‌شود. مسیر 510(k) در صورت وجود دستگاه پیشین ممکن است مناسب باشد.

- **علامت CE (EU):** طبق آیین‌نامه دستگاه پزشکی EU (MDR ۲۰۱۷/۷۴۵)، نرم‌افزار پشتیبانی تصمیم بالینی با تأثیر مستقیم بر بیمار نیازمند ارزیابی انطباق است.

- **بررسی مؤسسه‌ای:** اعتبارسنجی آینده‌نگر نیازمند تأیید IRB در هر مؤسسه شرکت‌کننده است. کار ما شواهد بنیادی (عملکرد مدل، کالبراسیون، تحلیل انصاف) را که ارسال نظارتی را پشتیبانی می‌کند فراهم می‌کند. با این حال، اعتبارسنجی آینده‌نگر روی کوه‌ت‌های مستقل پیش‌نیاز هر مسیر نظارتی است.

۱۸.۷ نوآوری و مشارکتهای اصلی

جنبه‌های نوآورانه این پایان‌نامه را که آن را از کار پیشین متمایز می‌کند صریح مرزبندی می‌کنیم:

۱. **بازنمایی Symptom Token برای داده‌جدولی بالینی.** با وجود کار پیشین روی توکن‌سازی یادداشت‌های بالینی یا سری زمانی، در این پژوهش قالب توکن ساخت‌یافته‌ای برای آزمایش‌ها و علائم حیاتی تجمیع‌شده معرفی می‌شود. هر توکن چهار بعد را کدگذاری می‌کند: هویت علامت، شدت نرمال‌شده، جابه‌جایی زمانی و نوع داده. این بازنمایی، پردازش مبتنی بر ترنسفورمر را برای داده‌ذاتاً جدولی ممکن می‌کند.

۲. **بررسی کم‌نمونه‌ی نمونه‌اولیه برای پیش‌بینی امکان‌پذیری درمان روی MIMIC-IV.** در چارچوب مرور ادبیات این پایان‌نامه، کاربرد کم‌نمونه بیشتر در تصویربرداری پزشکی (X-ray،

پوست‌شناسی) و کشف دارو دیده می‌شود و کمتر برای پیش‌بینی ترخیص/امکان‌پذیری درمان ICU جدولی ارزیابی شده است. این پژوهش این شکاف را به‌صورت تجربی بررسی می‌کند و هم ظرفیت و هم محدودیت‌های فرا یادگیری اپیزودیک برای داده‌بالینی ساخت‌یافته را نشان می‌دهد.

۳. **چارچوب یکپارچه کم‌نمونه + فدرال + ترنسفورمر.** کارهای پیشین معمولاً شبکه‌های نمونه‌اولیه، میانگین‌گیری فدرال و کدگذاری ترنسفورمر را هم‌زمان برای یک وظیفه پیش‌بینی بالینی ترکیب نکرده‌اند. این یکپارچه‌سازی سه چالش را هم‌زمان پوشش می‌دهد: کمبود داده، حفظ حریم خصوصی و بازنمایی ناهمگن داده.

۴. **گزارش صادقانه با حل سازنده.** پیکربندی خط پایه، با AUROC حدود ۰.۶۱۹ در جدول کمپین V، ابتدا از خطوط پایه کلاسیک عقب می‌ماند. به جای کنار گذاشتن این یافته، چرایی شکاف تحلیل می‌شود: ناسازگاری اپیزودی، گلوگاه بازنمایی و مقیاس داده. سپس شواهد حذف تدریجی و بهبودهای مرحله‌ای مستند می‌گردد؛ در نهایت اجرای انباشتی **منجمد** با AUROC **۰.۷۴۶** در برابر SOTA جدولی **۰.۷۴۸** قرار می‌گیرد.

۵. **فرا یادگیر انباشتی و آموزش پیشرفته.** در کمپین V، انباشت V4 با ترکیب احتمال‌های کم‌نمونه، پیش‌بینی‌های RF و بردارهای نهفته رمزگذار به AUROC برابر ۰.۷۳۲ می‌رسد. اجرای انباشتی منجمد مخزن exp_fewshot_best با مقدار **۰.۷۴۶** ادعای کمی اصلی برای ترکیب کم‌نمونه + کلاسیک در این نسخه است.

۶. **توجه درگاهی به ویژگی و شبکه‌های نمونه‌اولیه Cross-Attention.** معماری V5 انتخاب ویژگی تطبیقی به‌ازای نمونه (GFA) و شباهت وابسته به زمینه (نمونه‌های اولیه Cross-Attention) را معرفی می‌کند، با بهترین بذر AUROC ۰.۷۳۷ در کمپین توسعه Ensemble ناهمگن V6 عدم قطعیت به‌سبک مطابق را اکتشاف می‌کند.

۷. **سقف تجربی و بنچمارک جامع.** AUROC حدود ۰.۷۶ را به‌عنوان سقف تجربی امکان‌پذیری درمان روی این کوهورت معرفی می‌کنیم و نقطه مرجعی برای روش‌های آینده فراهم می‌سازیم. ارزیابی ما بیش از ۱۵ مدل، ۷ مقدار K -شات، ۵ گره بیماری، اعتبارسنجی متقاطع ۵/۵، و چند بذر تصادفی را پوشش می‌دهد.

۱۹.۷ جدول مقایسه: کار ما در برابر پیشین

جدول ۴.۷ جایگاه این پژوهش را نسبت به رویکردهای پیشین نشان می‌دهد. تفاوت‌های اصلی عبارت‌اند از: ترکیب کم‌نمونه، یادگیری فدرال و بازنمایی مبتنی بر توکن؛ تمرکز بر داده‌ی جدولی بالینی به‌جای تصویر؛ و گزارش شفاف نتیجه‌ی منفی اولیه همراه با مسیر بهبود مرحله‌ای تا نزدیک شدن به سقف جدولی.

جدول ۴.۷: مقایسه با کار پیشین

جنبه	پیشین (معمول)	کار ما	یادداشت
داده	EHR متمرکز و تجمیع‌شده	آموزش فدرال روی 5 گره بیماری	حریم خصوصی بهتر حفظ می‌شود، هرچند استقرار واقعی هنوز به اعتبارسنجی عملیاتی نیاز دارد
چیدمان	نظارت استاندارد روی کل داده	آموزش اپیزودیک کم‌نمونه با امکان انباشت کلاسیک	برای سناریوهای کم‌داده و توزیع‌شده مناسب‌تر از یک فرایند صرفاً نظارت‌شده است
بازنمایی	ویژگی خام، RNN یا ترنسفورمر عمومی	+ Symptom Tokens رمزگذار ETHOS	بازنمایی توکنی برای آزمایشگاه و علائم حیاتی تجمیع‌شده طراحی شده است
وظیفه	مرگ‌ومیر، LOS، بستری مجدد	امکان‌پذیری درمان/ترخیص	مسئله به تصمیم‌سازی ترخیص زودهنگام نزدیک‌تر است
بهترین کلاسیک	LSTM یا RF، XGBoost روی داده‌ی بزرگ	سقف جدولی RF/SOTA در بازه ۰.۷۶۰-۰.۷۴۸	این بازه سقف تجربی کوهورت حاضر را نشان می‌دهد
بهترین عصبی	معمولاً در داده‌ی بزرگ رقابتی یا برتر	Stacked BEST با 0.746؛ V4/V5 به‌عنوان نقاط عطف تاریخی	انباشت منجمد فقط 0.002 پایین‌تر از برآورد نقطه‌ای SOTA است

۲۰.۷ ملاحظات اخلاقی و انصاف

استقرار مدل‌های پیش‌بینی بالینی نگرانی‌های اخلاقی برمی‌انگیزد. **سوگیری:** کوهورت ما ممکن است برخی جمعیت‌شناسی‌ها را کم‌نمایندگی کند؛ عملکرد طبقه‌بندی‌شده سنی (فصل ۶) برای ارزیابی انصاف گزارش می‌کنیم. **شفافیت:** توضیحات SHAP و اهمیت ویژگی ارائه می‌دهیم؛ بالینیان باید استدلال مدل را بفهمند. **پاسخگویی:** مدل‌ها جایگزین قضاوت بالینی نیستند؛ ابزار پشتیبانی تصمیم‌اند. **حریم خصوصی:** یادگیری فدرال محلّیت داده را حفظ می‌کند؛ داده‌ی خام بیمار منتقل نمی‌شود. برای استقرار تولید توصیه می‌کنیم: (۱) ممیزی انصاف در سن، جنس، و تشخیص؛ (۲) پایش مداوم برای جابجایی توزیع؛ (۳) انسان-در-حلقه برای تصمیم‌های با ریسک بالا؛ (۴) مستندسازی شفاف محدودیت‌ها.

۲۱.۷ چک‌لیست بازتولیدپذیری

به بهترین شیوه‌های بازتولیدپذیری پایبندیم: (۱) بذر تصادفی ثابت (۴۲) در همه‌ی آزمایش‌ها؛ (۲) تقسیم‌های داده ذخیره و به‌اشتراک گذاشته شده؛ (۳) شبکه‌های ابرپارامتر در پیوست آ مستند شده‌اند؛ (۴) ساختار کد چیدمان استاندارد

پروژه را دنبال می‌کند؛ (۵) دسترسی به MIMIC-IV نیازمند احراز هویت PhysioNet است. پژوهشگران می‌توانند با دسترسی MIMIC-IV، نصب وابستگی‌ها از requirements.txt، و اجرای اسکریپت‌های آزمایش با پیکربندی مستند، نتایج را بازتولید کنند.

۲۲.۷ درس‌های آزمایش‌های V5 و V6

آزمایش‌های V5 و V6 چند نکته‌ی مهم برای یادگیری کم‌نمونه روی داده‌ی جدولی نشان می‌دهند:

توجه در گاهی به ویژگی برای داده‌ی بالینی مفید است. ماژول GFA در V5، با الهام از TabNet، برای هر نمونه ماسک‌های اهمیت ویژگی می‌آموزد. بهترین بذر V5 در کمپین V به AUROC ۰.۷۳۷ می‌رسد و سقف بالقوه‌ی مسیر کم‌نمونه را نشان می‌دهد؛ البته اجرای منجمد بهترین زیرمدل کم‌نمونه با GFA و Cross-Attention با AUROC ۰.۶۷۰ مرجع رسمی مسیر فقط کم‌نمونه در این نسخه است. واریانس بالاتر میان بذرها (AUROC ۰.۷۰۳-۰.۷۳۷ در برابر ۰.۶۹۶-۰.۷۱۳ برای V4) نشان می‌دهد این معماری به مقداردهی اولیه حساس‌تر است.

نمونه‌های اولیه با Cross-Attention از نظر نظری انعطاف‌پذیرترند. سر Cross-Attention به‌جای تکیه بر فاصله‌ی کسینوسی ثابت، شباهتی وابسته به زمینه می‌آموزد؛ رویکردی که برای داده‌ی بالینی ناهمگن و مرزهای چندوجهی مناسب‌تر است. با این حال، سود آن روی مجموعه‌ی فعلی با $n = 2,000$ محدود بود. این نتیجه نشان می‌دهد Cross-Attention احتمالاً برای آشکار کردن ظرفیت کامل خود به مجموعه‌های بزرگ‌تر نیاز دارد.

همگنی معماری در مقیاس کوچک بر تنوع غلبه می‌کند. Ensemble ناهمگن V6 (۰.۷۲۵) از Ensemble‌های هم‌معماری V4، V5 (۰.۷۳۲، ۰.۷۳۰) در کمپین V عقب می‌ماند. معماری MLP-Mixer (۰.۶۴۲ AUROC) Ensemble را پایین می‌کشد چون فاقد خودتوجه است؛ تأیید می‌کند برای داده‌ی جدولی با تعامل پیچیده بین ویژگی، مکانیزم‌های توجه اختیاری نیستند.

انباشت ساده در مقیاس کوچک اعتبارسنجی از انباشت پیچیده بهتر است. فرا یادگیر V6 XGBoost (۰.۶۸۹ AUROC) روی مجموعه‌ی اعتبارسنجی ۳۲۰ نمونه‌ای بیش‌برازش می‌کند، در حالی که رگرسیون لجستیک کالیبره‌شده ایزوتونیک V4 (۰.۷۳۲) در آن کمپین خوب تعمیم می‌یابد. پیکربندی انباشتی منجمد exp_fewshot_best باید برای عملکرد انباشت سطح ارسال استناد شود.

۲۳.۷ کارهای آینده

۱. پیش‌آموزش بزرگ‌تر: آموزش ETHOS روی کل کوهورت MIMIC-IV (بیش از ۵۰,۰۰۰ اقامت در ICU) یا داده EHR خارجی پیش از تنظیم دقیق کم‌نمونه. اوج بذره‌های V5 در کمپین V به AUROC ۰.۷۳۷ روی ۱,۲۸۰ نمونه آموزش رسید؛ مجموعه‌های بزرگ‌تر ممکن است عملکرد فقط کم‌نمونه را فراتر از برآورد نقطه‌ای منجمد ۰.۶۷۰ تثبیت و بهبود دهند.
۲. مقیاس‌دهی GFA و Cross-Attention: ارزیابی معماری V5 روی مجموعه‌های بالینی بزرگ‌تر جایی که نمونه‌های اولیه Cross-Attention سود بیشتری دهند.
۳. انباشت ترکیبی GFA: ترکیب رمزگذار V5 GFA با انباشت کالبره‌شده V4 برای بهترین هر دو رویکرد.
۴. ارزیابی فدرال بین‌مؤسسه‌ای: ارزیابی روی داده چند بیمارستان برای ارزیابی تعمیم، به‌ویژه مکانیزم سازگاری Proto-MAML.
۵. پیش‌بینی مطابق در استقرار: گسترش پیش‌بینی مطابق V6 برای برآورد عدم‌قطعیت سطح بیمار در سامانه پشتیبانی تصمیم بالینی.
۶. مدل‌سازی زمانی: گنجاندن پویایی سری زمانی (روند بهبود در برابر وخامت) برای کاهش خطا در موارد مرزی.
۷. مقیاس‌دهی چندوظیفه: گسترش به وظایف بیشتر (مثلاً شروع سپسیس، AKI) با رمزگذارهای بزرگ‌تر.
۸. اعتبارسنجی آینده‌نگر: استقرار در مطالعه آزمایشی با بازخورد بالینی و ردیابی پیامد.
۹. MLP-Mixer تقویت‌شده با توجه: بررسی معماری‌های ترکیبی توجه-میکسر که کارایی مخلوط‌کردن توکن را با بیانگری خودتوجه ترکیب می‌کنند.

جدول ۵.۷ نقشه‌راه مرحله‌ای کار آینده را نشان می‌دهد. در فاز ۱، تمرکز بر مقیاس‌دهی به کل MIMIC-IV و اعتبارسنجی خارجی روی eICU است. در فاز ۲، آزمایش فدرال چندسایتی، فرا یادگیرهای جایگزین مانند MAML و مقیاس‌دهی ترکیبی بررسی می‌شوند. فاز ۳ به استقرار آینده‌نگر، مسیرهای نظارتی و دریافت بازخورد بالینی اختصاص دارد. هر فاز بر خروجی فاز پیشین بنا می‌شود و پایان‌نامه حاضر پایه فنی فاز نخست را فراهم می‌کند.

جدول ۵.۷: نقشه‌راه کار آینده

فاز	زمان‌بندی	تمرکز
1	1 سال	MIMIC-IV کامل، اعتبارسنجی eICU، پیش‌آموزش بزرگ‌تر
2	2 سال	فدرال چندسایتی، MAML، مقیاس‌دهی ترکیبی
3	3 سال	استقرار آینده‌نگر، نظارتی، بازخورد بالینی

نقشه‌راه مقیاس‌دهی (فاز ۱)، کاوش فدرال و معماری (فاز ۲)، و استقرار (فاز ۳) را اولویت‌بندی می‌کند. هر فاز به منابع و مشارکت‌های اختصاصی نیاز دارد؛ پایان‌نامه فعلی بنیاد فنی را فراهم می‌کند.

۲۴.۷ خلاصه نکات کلیدی و درس‌های آموخته‌شده

نکات اصلی را برای پژوهشگران و عملگران استخراج می‌کنیم:

۱. مدل‌های کلاسیک روی داده جدولی متوسط سقف محکمی می‌سازند. Random Forest

به AUROC حدود ۰.۷۶ می‌رسد؛ بنابراین برای ارزیابی منصفانه روش‌های جدید، داشتن خط پایه کلاسیک قوی ضروری است.

۲. فرایندهای کم‌نمونه با مهندسی سیستماتیک می‌توانند به SOTA جدولی نزدیک شوند.

شکاف میان کم‌نمونه ساده و مدل‌های جدولی قوی در ابتدا زیاد است، اما انباشت، تقطیر، سازگاری و اصلاح معماری آن را کاهش می‌دهند. اجرای انباشتی منجمد با ۰.۷۴۶ در برابر SOTA ۰.۷۴۸ مبنای کمی ادعای نزدیک شدن به سقف است؛ در حالی که بذره‌های کمپین V مانند ۰.۷۳۷ رفتار تاریخی بهترین اجرای تکی را نشان می‌دهند.

۳. یادگیری فدرال عملی است با شکاف محدود حدود ۰.۰۰۵ واحد AUROC در آزمایش گزارش‌شده.

۴. فرا یادگیرهای انباشتی بهترین راهبرد آمیزش در مقیاس کوچک اعتبارسنجی ($n = 320$) هستند. رگرسیون لجستیک کالیبره‌شده از انباشت XGBoost بهتر عمل می‌کند.

۵. تنوع معماری در مقیاس کوچک کمک نمی‌کند. Ensemble‌های همگن (همان معماری، بذره‌های متفاوت) از Ensemble‌های ناهمگن بهترند. مکانیزم‌های توجه برای یادگیری کم‌نمونه جدولی ضروری‌اند.

۶. تفسیرپذیری در بهداشت مهم است. SHAP و اهمیت ویژگی برای اعتماد بالینی ضروری‌اند.

۷. مهندسی ویژگی ظرفیت مدل عصبی را تقویت می‌کند. گسترش از ۲۲ به ۱۳۲ ویژگی سیگنال

غنی‌تری برای رمزگذار فراهم می‌کند.

پرسش‌های باز برای کار آینده عبارت‌اند از: (۱) بررسی اینکه پیش‌آموزش بزرگ‌تر تا چه اندازه عملکرد رمزگذار GFA را بهبود می‌دهد؛ (۲) اعتبارسنجی خارجی روی داده چندمرکز (eICU)؛ (۳) ترکیب رمزگذار V5 GFA با انباشت V4؛ (۴) مقیاس‌دهی پیش‌بینی مطابق برای سنجش عدم قطعیت آماده استقرار؛ و (۵) اعتبارسنجی بالینی آینده‌نگر.

۲۵.۷ خلاصه محدودیت‌ها

محدودیت‌های زیر را می‌پذیریم: (۱) **تک مرکز:** MIMIC-IV از یک بیمارستان (BIDMC) است؛ نتایج ممکن است تعمیم نیابند. (۲) **اندازه نمونه:** ۲,۰۰۰ بیمار متوسط است؛ MIMIC-IV کامل (۲۵۰ هزار + اقامت) می‌تواند نتیجه‌گیری متفاوتی بدهد. (۳) **تعریف برچسب:** امکان‌پذیری دودویی است (مقصد ترخیص + بستری مجدد)؛ تعاریف جایگزین نتایج را عوض می‌کند. (۴) **ویژگی‌ها:** ویژگی‌های پایه ۲۵ بعد (آزمایشگاه، علائم حیاتی، مهندسی‌شده)، گسترش به ۱۳۲ با مهندسی ویژگی؛ یادداشت‌های بالینی، تصویربرداری، و داروها مستثنی‌اند. (۵) **وضوح زمانی:** تجمیع ۲۴ ساعت اول؛ روند ساعتی یا زیرساعتی می‌تواند سیگنال اضافه کند. (۶) **شبیه‌سازی فدرال:** پارتیشن فدرال را به تفکیک گره بیماری شبیه‌سازی می‌کنیم؛ استقرار چندسایتی واقعی ممکن است چالش‌های اضافی (هزینه ارتباط، خرابی گره، مشتریان بیزانسی) داشته باشد. (۷) **واریانس بذر** V5، V6: رمزگذار V5 GFA واریانس بالای به‌ازای بذر (AUROC ۰.۷۰۳-۰.۷۳۷) دارد و نتیجه بهترین بذر (۰.۷۳۷) ممکن است خوش‌بینانه باشد؛ میانگین‌های Ensemble (۰.۷۲۲) نماینده‌ترند. با وجود این محدودیت‌ها، کار ما روش‌شناسی دقیق و نقشه‌راه جامع برای پژوهش آینده فراهم می‌کند.

۲۶.۷ جمع‌بندی فصل

این فصل نتایج تجربی را تفسیر کرد؛ سقف جدولی منجمد با ۰.۷۴۸، اجرای انباشتی کم‌نمونه با ۰.۷۴۶، شکاف کنترل‌شده Exp1 میان مدل پیشنهادی کم‌نمونه با ۰.۶۱۱ و RF با ۰.۷۶۲، هزینه فدرال در حدود ۰.۰۰۵ AUROC، و مسیر توسعه‌ی V1-V6. همچنین محدودیت‌های فرا یادگیری اپیزودیک، مقایسه با کارهای پیشین، ملاحظات استقرار، اخلاق و مسیرهای آینده بررسی شد. با وجود نتایج امیدبخش، استقرار بالینی همچنان به اعتبارسنجی آینده‌نگر و ارزیابی در سطح هر مؤسسه نیاز دارد.

فصل ۸

نتیجه گیری

این پایان نامه مسئله پیش بینی امکان پذیری درمان را بر پایه داده بالینی محدود در MIMIC-IV بررسی کرد. در این پژوهش، امکان پذیری درمان به صورت عملیاتی به معنای پیش بینی پیامد قابل اندازه گیری درمان/ترخیص از سیگنال های اولیه ICU تعریف شد و نه به معنای توصیه مستقیم درمان، نسخه نویسی خودکار یا جایگزینی تصمیم پزشک. چارچوب پیشنهادی از توکن های علائم، رمزگذار ETHOS، یادگیری کم نمونه، آموزش فدرال و چند روش تکمیلی مانند Proto-MAML، تقطیر دانش، یادگیری تضادی نظارت شده، توجه درگاهی به ویژگی، Cross-Attention و انباشت استفاده می کند. اعداد اصلی این فصل بر خروجی های منجمد مخزن استوارند و مسیر توسعه ی V1-V6 در فصل ۵ به عنوان سابقه تکامل روش گزارش شده است. یافته های اصلی عبارت اند از:

- **سقف جدولی (منجمد):** فرایند اختصاصی جدولی به AUROC آزمون ۰.۷۴۸ می رسد (فصل ۵، جدول ۱.۵).

- **انباشت کم نمونه + کلاسیک (منجمد):** بهترین اجرای انباشتی به AUROC ۰.۷۴۶ [۰.۶۹۹, ۰.۷۹۷] می رسد؛ یعنی تنها حدود ۰.۰۰۲ پایین تر از برآورد نقطه ای سقف.

- **تنها کم نمونه (منجمد):** بهترین کم نمونه (CrossAttn+GFA) به AUROC ۰.۶۷۰ [۰.۶۱۲, ۰.۷۲۶] می رسد.

- **مقایسه Exp1 (تقسیم ثابت):** مدل پیشنهادی کم نمونه با ۰.۶۱۱ در برابر Random Forest با ۰.۷۶۲ روی همان چارچوب ارزیابی.

- **کمپین V (تاریخی):** جدول ۱۵.۵ بهبودهای تدریجی را گزارش می کند (مثلاً انباشت V4 در ۰.۷۳۲، بهترین بذر V5 در ۰.۷۳۷، و RF با آستانه تنظیم شده در ۰.۷۶۰)؛ برای ادعاهای اجرایی نخست به جداول

اصلی ارجاع دهید.

- **یادگیری فدرال:** شکاف AUROC میان آموزش متمرکز و فدرال در آزمایش گزارش شده 0.005 است؛ یعنی آموزش حافظ حریم خصوصی در این شبیه‌سازی با هزینه عملکردی محدود امکان‌پذیر بوده است.
- **پیش‌بینی مطابق (conformal) (اکتشافی):** تحلیل‌های سبک V6 مجموعه‌های پیش‌بینی کالبره در اجراهای توسعه فراهم می‌کنند؛ اینجا به‌عنوان شاخص‌های کلیدی ارسال دوباره تأکید نمی‌شوند.
- **سقف تجربی:** مدل‌های جدولی قوی در این کوهورت، بسته به پروتکل، در بازه $0.760-0.748$ قرار دارند.

این پژوهش یک مطالعه بازتولیدپذیر از یادگیری کم‌نمونه جدولی برای امکان‌پذیری درمان روی MIMIC-IV ارائه می‌کند؛ همراه با خطوط پایه صادقانه، بازنمایی بالینی مبتنی بر توکن‌های علائم، ارزیابی فدرال و خروجی‌های قابل بازتولید در results/ و جداول تولیدشده‌ی LaTeX. مقدار 0.762 برای Random Forest به پروتکل Exp1 و مقدار 0.748 به فرایند منجمد Tabular SOTA مربوط است؛ از این‌رو تفاوت آن‌ها ناشی از تفاوت پروتکل است. عملکرد انباشتی نزدیک به سقف، یعنی 0.746 در برابر 0.748 ، نشان می‌دهد اگر بازنمایی، هم‌جوشی مدل‌ها و روند آموزش با ماهیت وظیفه هماهنگ شود، روش‌های کم‌نمونه می‌توانند به مدل‌های کلاسیک قوی نزدیک شوند؛ اما مدل کم‌نمونه خام جایگزین مستقیم Random Forest نیست.

۱.۸ خلاصه مشارکت‌ها

جدول ۱.۸ مشارکت‌ها را برای مرور سریع جمع می‌کند.

۱.۱.۸ پیامدها برای استقرار بالینی

برای بالین‌دانان و مدیران سلامت، یافته‌ها در مرحله پژوهشی هستند:

۱. **عملکرد:** مدل انباشتی منجمد به AUROC 0.746 می‌رسد؛ پیش از هر کاربرد پشتیبان تصمیم، اعتبارسنجی محلی الزامی است.
۲. **آموزش حافظ حریم خصوصی:** آموزش فدرال در شبیه‌سازی ما هزینه کوچکی در AUROC دارد؛ با این حال، استقرار چندسایتی واقعی به آزمون عملیاتی نیاز دارد.

جدول ۱.۸: خلاصه مشارکت‌ها

مشارکت شرح	
1	مطالعه امکان‌پذیری کم‌نمونه جدولی با معیارهای منجمد: انباشت 0.746 در برابر SOTA 0.748 : شکاف Exp1 0.611 در برابر 0.762
2	توکن‌های علائم به‌عنوان بازنمایی فشرده بالینی برای یادگیری اپیزودیک و مبتنی بر ترنسفورمر
3	سقف تجربی AUROC در بازه ۰.۷۶-۰.۷۵ در این کوهورت؛ جداول اصلی در فصل ۵
4	مقایسه فدرال در برابر متمرکز با شکاف 0.005 AUROC (گره‌های شبیه‌سازی‌شده)
5	تحلیل حذف تدریجی، حساسیت K -شات، و تحلیل بین‌گره‌ای
6	سازگاری به‌سبک Proto-MAML در کمپین V کاوش شد
7	انباشت فرا یادگیرنده‌ها برای هم‌جوشی سیگنال‌های کم‌نمونه و کلاسیک؛ بهترین اجرای انباشتی به‌عنوان مرجع منجمد
8	تقطیر دانش و پیش‌آموزش تضاد در نقشه راه بهبود
9	توجه درگاهی به ویژگی و نمونه‌های Cross-Attention (کمپین V؛ بهترین بذر 0.737)
10	مجموعه‌های ناهمگن و تحلیل‌های سبک مطابق (اکتشافی)
11	تولید خودکار جدول از CSV/JSON به پایان‌نامه (پیوست د)
12	نقشه راه آموزش تدریجی (V1-V6) همراه با تفکیک صریح بین اعداد منجمد ارسال و تاریخی

۳. **سازگاری:** سازگاری به سبک Proto-MAML امیدبخش است اما باید روی داده‌آینده‌نگر و ویژه‌سایت ارزیابی شود.

۴. **شفافیت:** انباشت امکان مقایسه‌ی اجزای کم‌نمونه در برابر کلاسیک را وقتی هر دو در دسترس‌اند فراهم می‌کند.

۵. **توصیه‌های استقرار:** از آستانه‌های اطمینان، بررسی‌های انصاف، پایش انحراف، و نظارت انسانی استفاده کنید؛ قضاوت بالینی را جایگزین نکنید.

۲.۱.۸ تطبیق نهایی با پروپوزال

در مقایسه با پروپوزال اولیه، هسته‌ی علمی کار حفظ شده است: پیش‌بینی امکان‌پذیری درمان با ترکیب یادگیری کم‌نمونه، یادگیری فدرال، ETHOS و توکن‌های علائم. تفاوت اصلی در دامنه‌ی عملیاتی است. پروپوزال از داده‌های چندمنبعی گسترده و حتی سناریوهای دارای واسط کاربری سخن می‌گفت؛ اجرای نهایی، برای حفظ بازتولیدپذیری و اعتبار علمی، روی MIMIC-IV و منابع درون EHR یعنی آزمایشگاه‌ها، علائم حیاتی و ویژگی‌های مشتق‌شده متمرکز شد. بنابراین این پایان‌نامه نه یک سامانه‌ی تولیدی کامل، بلکه یک ارزیابی پژوهشی دقیق و قابل بازتولید از چارچوب پیشنهادی است. پیاده‌سازی واسط کاربری، اتصال به داده‌ی زنده یا پوشیدنی، و اعتبارسنجی چندسایتی واقعی به‌عنوان گام‌های طبیعی پس از این پایان‌نامه باقی می‌مانند.

۳.۱.۸ توصیه‌ها برای پژوهشگران و عملگران

۱. **برای پیشینه‌ی دقت در این کوهورت:** فرایند جدولی SOTA منجمد (AUROC ۰.۷۴۸) یا خطوط پایه‌ی کلاسیک هم‌تراز را ترجیح دهید؛ انباشت‌های کم‌نمونه را نیز گزارش کنید.

۲. **برای هم‌جوشی کم‌نمونه + کلاسیک:** بهترین پیکربندی انباشتی مستندشده را به‌عنوان مرجع (۰.۷۴۶) به کار ببرید.

۳. **برای تنظیمات فدرال:** در چیدمان ما اختلاف‌های عملکرد کوچک در برابر متمرکز انتظار دارید؛ ارتباط و ناهمگونی داده را جداگانه اعتبارسنجی کنید.

۴. **برای سایت‌های جدید:** کالیبراسیون، تنظیم آستانه، و ارزیابی آینده‌نگر را برنامه‌ریزی کنید.

۵. **برای ادعاهای غیربرتری آماری:** آزمون‌های آماری جفتی روی بردارهای پیش‌بینی هم‌تراز اجرا کنید؛ به p -مقادیر تاریخی از پیش‌نویس‌های پیشین تکیه نکنید.

۴.۱.۸ اهمیت برای حوزه

این کار به انفورماتیک بالینی و فرا یادگیری سه افزوده‌ی اصلی دارد: (۱) گزارش هم‌زمان سقف‌های جدولی قوی و مسیر کم‌نمونه نزدیک به آن‌ها (0.746 در برابر 0.748)؛ (۲) ترکیب دیدگاه فدرال و کم‌نمونه در یک وظیفه ساخت‌یافته ICU؛ و (۳) مستندسازی مسیر بهبود چندمرحله‌ای V1-V6 با تفکیک روشن میان اعداد منجمد و اعداد تاریخی. توکن‌های علائم و ترکیب ETHOS با یادگیری کم‌نمونه می‌توانند قالبی برای سناریوهای کم‌داده و حساس به حریم خصوصی باشند، به شرط آنکه در داده‌های بیرونی نیز اعتبارسنجی شوند.

۵.۱.۸ جمع‌بندی

شکاف میان پیکربندی‌های ساده‌ی کم‌نمونه و مدل‌های جدولی قوی واقعی است؛ برای نمونه در Exp1، مقدار 0.611 در برابر 0.762 قرار می‌گیرد. با این حال، مهندسی سیستماتیک در بازنمایی، مراحل آموزش، تقطیر، سازگاری و انباشت می‌تواند اجرای یکپارچه را به برآورد نقطه‌ای SOTA جدولی نزدیک کند. بهبودهای بعدی به احتمال زیاد به پیش‌آموزش بزرگ‌تر، داده‌چندسایتی و اعتبارسنجی آینده‌نگر نیاز خواهند داشت.

۶.۱.۸ پاسخ به پرسش‌های پژوهشی

جدول ۲.۸ چگونگی پاسخ‌گویی آزمایش‌ها به هر پرسش پژوهشی را خلاصه می‌کند.

جدول ۲.۸: خلاصه پاسخ به پرسش‌های پژوهشی

RQ	پرسش	پاسخ
RQ1	آیا فرا یادگیری کم‌نمونه می‌تواند خطوط پایه کلاسیک را جبران کند؟	به‌تنهایی نه؛ اما با هم‌جوشی و انباشت می‌تواند بسیار نزدیک شود. اجرای منجمد Stacked BEST به 0.746 در برابر سقف جدولی 0.748 می‌رسد، در حالی که FewShot BEST تنها 0.670 و مدل پیشنهادی کم‌نمونه در Exp1 فقط 0.611 در برابر RF با 0.762 است.
RQ2	شأت پشتیبان K چگونه بر عملکرد اثر می‌گذارد؟	اثر K محدود است. AUROC اپیزودیک در بازه 0.564 تا 0.587 می‌ماند و بهترین میانگین در $K=3$ با 0.564 دیده شد؛ بنابراین افزایش K در این مقیاس به‌تنهایی شکاف اصلی را نمی‌بندد.
RQ3	هزینه یادگیری فدرال چیست؟	کوچک است: در آزمایش گزارش‌شده، AUROC از 0.552 در حالت متمرکز به 0.547 در حالت فدرال افت می‌کند؛ یعنی شکاف تنها 0.005 .
RQ4	کدام اجزا بیشترین سهم را دارند؟	مهندسی ویژگی و وزن‌دهی شدت سهم بالایی دارند. حذف توکن‌های علائم افت ایجاد نمی‌کند و LR روی ویژگی‌های خام از لوله توکنی ساده بهتر عمل می‌کند؛ پس گلوگاه اصلی بیشتر در کیفیت بازنمایی است تا صرفاً فرا-آموزش.
RQ5	آیا مدل بین گروه‌های بیماری تعمیم می‌یابد؟	تعمیم بین‌گروهی محدود اما ممکن است. مدل پیشنهادی روی برخی گره‌های نگه‌داشته‌شده از XGBoost/LR عقب می‌ماند؛ بنابراین برای تعمیم پایدار بین بیماری‌ها به داده‌ی بیشتر، پیش‌آموزش بهتر و ارزیابی چندسایتی نیاز است.

پیوست آ

ابریارامترها

این پیوست تمام ابریارامترهای به کاررفته در آزمایش‌های ما را فهرست می‌کند.

۱.آ رمزگذار ETHOS

جدول ۱.آ: پیکربندی رمزگذار ETHOS

پارامتر مقدار
۱۲۸ d_model
۸ nhead
۲ num_layers
۵۱۲ d_ff
۰.۲ dropout
۲۳ vocab_size

۲.آ یادگیری کم‌نمونه

۳.آ یادگیری فدرال

۴.آ بهترین مدل نهایی (جنگل تصادفی)

جدول آ.۲: پیکربندی Few-Shot

پارامتر	مقدار
n_support (K)	۵
n_query (Q)	۱۵
n_way	۲
temperature	۱۰.۰
use_focal_loss	true
focal_gamma	۲.۰
n_episodes_train	۵۰۰
n_episodes_val	۱۰۰
n_episodes_test	۵۰۰
lr	۰.۰۰۱
max_epochs	۵۰
early_stop_patience	۱۰

جدول آ.۳: پیکربندی فدرال

پارامتر	مقدار
n_rounds	۲۰
n_nodes	۵
aggregation	fedavg
local_epochs	۳
local_batch_size	۳۲

جدول آ.۴: ابرپارامترهای Random Forest با تنظیم آستانه

پارامتر	مقدار
n_estimators	۲۰۰
max_depth	۲۸
min_samples_split	۵
min_samples_leaf	۲
max_features	log2
class_weight	balanced
θ threshold	۰.۵۴

پیوست ب

پرس وجوهای SQL برای MIMIC-IV

این پیوست نمونه‌هایی از پرس وجوهای SQL به کاررفته برای استخراج کوهورت و ویژگی از MIMIC-IV را ارائه می‌کند. استخراج واقعی برای کارایی از DuckDB استفاده می‌کند.

ب.۱ استخراج کوهورت

Cohort: First ICU Stay, Min 4h LOS

```
SELECT
    ie.subject_id, ie.hadm_id, ie.stay_id,
    ie.intime, ie.outtime,
    EXTRACT(EPOCH FROM (ie.outtime - ie.intime))/3600 AS los_hours
FROM icu.icustays ie
JOIN patients p ON ie.subject_id = p.subject_id
WHERE EXTRACT(EPOCH FROM (ie.outtime - ie.intime))/3600 >= 4
    AND p.anchor_age >= 18
ORDER BY ie.subject_id, ie.intime
LIMIT 1 PER subject_id;
```


ب.۲. استخراج آزمایشگاه

Labs from First 24h

```
SELECT
    le.subject_id, le.hadm_id, le.stay_id,
    le.itemid, le.valuenum, le.charttime
FROM hosp.labevents le
JOIN cohort c ON le.hadm_id = c.hadm_id
WHERE le.charttime BETWEEN c.intime AND c.intime + INTERVAL '24 hours'
    AND le.itemid IN (50912, 50971, 50983, 50902, 50931, ...)
    AND le.valuenum IS NOT NULL;
```

ب.۳. استخراج علائم حیاتی

Vitals from First 24h

```
SELECT
    ce.subject_id, ce.hadm_id, ce.stay_id,
    ce.itemid, ce.valuenum, ce.charttime
FROM icu.chartevents ce
JOIN cohort c ON ce.stay_id = c.stay_id
WHERE ce.charttime BETWEEN c.intime AND c.intime + INTERVAL '24 hours'
    AND ce.itemid IN (220045, 220050, 220051, 220052, ...)
    AND ce.valuenum IS NOT NULL;
```

ب.۴. برچسب: محل ترخیص

Feasible Discharge

```
SELECT
    a.hadm_id,
    CASE WHEN a.discharge_location IN (
        'HOME', 'HOME HEALTH CARE',
        'REHAB/DISTINCT PART HOSP', 'REHAB'
    ) AND NOT EXISTS (
```

```

SELECT 1 FROM admissions readmit
WHERE readmit.subject_id = a.subject_id
      AND readmit.admittime BETWEEN
      a.discharge_location_time AND
      a.discharge_location_time + INTERVAL '30 days'
) THEN 1 ELSE 0 END AS feasible
FROM admissions a;

```

ب.۵ تشخیص اولیه برای گره‌های بیماری

Assign Primary ICD-10 to Nodes

```

SELECT hadm_id,
CASE
  WHEN icd_code LIKE 'A40%' OR icd_code LIKE 'A41%'
      OR icd_code = 'R652' THEN 1
  WHEN icd_code LIKE 'I21%' OR icd_code LIKE 'I22%'
      OR icd_code LIKE 'I25%' OR icd_code LIKE 'I50%'
      OR icd_code LIKE 'I47%' OR icd_code LIKE 'I48%'
      OR icd_code LIKE 'I49%' THEN 2
  WHEN icd_code LIKE 'J18%' OR icd_code LIKE 'J44%'
      OR icd_code LIKE 'J96%' OR icd_code LIKE 'J80%'
      OR icd_code LIKE 'J15%' THEN 3
  WHEN icd_code LIKE 'N17%' OR icd_code LIKE 'N18%'
      OR icd_code LIKE 'N19%' THEN 4
  WHEN icd_code LIKE 'E10%' OR icd_code LIKE 'E11%'
      OR icd_code LIKE 'E13%' THEN 5
  ELSE 0
END AS node_id
FROM diagnoses_icd
WHERE seq_num = 1;

```

ب.۶ تجمیع: اولین مقدار به‌ازای هر بستری

برای آزمایش‌ها و علائم حیاتی، ۲۴ ساعت اول را با میانه (یا اولین مقدار) به‌ازای هر itemid و هر بستری تجمیع می‌کنیم. زیر منطق تجمیع را به‌صورت شبه‌کد نشان می‌دهد:

Aggregation Logic

```
def aggregate_first_24h(events, intime, window_hours=24):  
    end_time = intime + timedelta(hours=window_hours)  
    mask = (events['charttime'] >= intime) & (events['charttime'] <= end_time)  
    filtered = events.loc[mask]  
    # Per itemid: take median (or first) value  
    agg = filtered.groupby('itemid')['valuenum'].median()  
    return agg
```

پیوست پ

قطعه کدهای برنامه

این پیوست قطعه کدهای کلیدی از پیاده سازی ما را ارائه می کند.

پ.۱ توکن سازی علائم

ساخت دنباله ی توکن کد پ.۱:

```
1 def build_tokens(X, seq_len=25, lab_count=15):
2     n_samples, n_features = X.shape
3     tokens = np.zeros((n_samples, seq_len, 4), dtype=np.float32)
4     for i in range(n_samples):
5         valid = np.where(~np.isnan(X[i]) & (X[i] >= 0) & (X[i] <= 1))[0]
6         for j, idx in enumerate(valid[:seq_len]):
7             tokens[i, j, 0] = idx + 1 # symptom_id
8             tokens[i, j, 1] = float(X[i, idx]) # intensity
9             tokens[i, j, 2] = 0.0 # time_delta
10            tokens[i, j, 3] = 0.0 if idx < lab_count else 1.0 # modality
11    return tokens
```

پ.۲ سر Prototypical

محاسبه ی prototype و طبقه بندی کد پ.۲:

```
1 def compute_prototypes(support_embeddings, support_labels):
```

```

2     classes = torch.unique(support_labels)
3     prototypes = []
4     for c in classes:
5         mask = support_labels == c
6         proto = support_embeddings[mask].mean(dim=0)
7         prototypes.append(proto)
8     return torch.stack(prototypes)
9
10 def classify_query(query_embeddings, prototypes, temperature=10.0):
11     logits = F.cosine_similarity(
12         query_embeddings.unsqueeze(1),
13         prototypes.unsqueeze(0),
14         dim=-1
15     ) * temperature
16     return F.softmax(logits, dim=-1)

```

پ.۳ زیان کانونی

پیاده‌سازی Focal Loss کد پ.۳:

```

1 def focal_loss(logits, targets, gamma=2.0, alpha=None):
2     ce = F.cross_entropy(logits, targets, reduction='none')
3     pt = torch.exp(-ce)
4     focal = ((1 - pt) ** gamma) * ce
5     if alpha is not None:
6         alpha_t = alpha[targets]
7         focal = alpha_t * focal
8     return focal.mean()

```

پ.۴ عبور رو به جلوی رمزگذار ETHOS

رمزگذار ETHOS (ساده‌شده) کد پ.۴:

```

1 class ETHOSEncoder(nn.Module):
2     def __init__(self, d_model=128, nhead=8, num_layers=2):
3         super().__init__()

```

```

4         self.embed = nn.Linear(4, d_model) # 4 = token dims
5         encoder_layer = nn.TransformerEncoderLayer(
6             d_model, nhead, dim_feedforward=512, dropout=0.2
7         )
8         self.transformer = nn.TransformerEncoder(encoder_layer, num_layers)
9         self.d_model = d_model
10
11     def forward(self, x):
12         # x: (B, L, 4)
13         h = self.embed(x) # (B, L, d_model)
14         h = h.transpose(0, 1) # (L, B, d_model)
15         h = self.transformer(h)
16         h = h.mean(dim=0) # (B, d_model)
17         return h

```

پ.۵ به روزرسانی سرور FedAvg

تجميع FedAvg كد پ.۵:

```

1 def fedavg_aggregate(client_weights, client_sizes):
2     total = sum(client_sizes)
3     global_state = {}
4     for key in client_weights[0].keys():
5         global_state[key] = sum(
6             w[key] * n for w, n in zip(client_weights, client_sizes)
7         ) / total
8     return global_state

```

پیوست ت

جداول کامل نتایج

این پیوست جداول تفصیلی نتایج را ارائه می کند.

ت. ۱ سقف مدل های جدولی: همه ی مدل ها

جدول ت. ۱: سقف مدل های جدولی: مدل های تکی در مجموعه ی آزمون

مدل	AUROC	F1	Accuracy	MCC
XGBoost	۰.۷۴۳	۰.۶۷۲	۰.۶۸۰	۰.۳۵۶
Random Forest	۰.۷۶۰	۰.۶۶۹	۰.۷۰۵	۰.۳۴۷
LightGBM	۰.۷۲۷	۰.۶۴۱	۰.۶۷۸	۰.۲۸۹
CatBoost	۰.۷۳۱	۰.۶۶۴	۰.۶۸۳	۰.۳۲۹

ت. ۲ نتایج مدل های تجمیعی

جدول ت. ۲: مدل های تجمیعی در مجموعه ی آزمون

مدل	Threshold	AUROC	F1	Accuracy	MCC
SoftVoting	۰.۵۱	۰.۷۴۳	۰.۶۵۴	۰.۶۷۵	۰.۳۰۹
Stacking	۰.۴۵	۰.۷۴۲	۰.۶۵۶	۰.۶۷۸	۰.۳۱۱
Random Forest تنظیم آستانه	۰.۵۴	۰.۷۶۰	۰.۶۸۲	۰.۷۰۳	۰.۳۶۴

ت.۳ شناسه‌های آیتم آزمایشگاه و علائم حیاتی

جدول ت.۳: شناسه‌های آیتم آزمایشگاه MIMIC-IV

بازه (حداقل-حداکثر)	نام آیتم شناسه
۰.۱-۳۰ mg/dL	Creatinine ۵۰۹۱۲
۱.۵-۱۰ mEq/L	Potassium ۵۰۹۷۱
۱۰۰-۱۸۰ mEq/L	Sodium ۵۰۹۸۳
۷۰-۱۳۰ mEq/L	Chloride ۵۰۹۰۲
۲۰-۶۰۰ mg/dL	Glucose ۵۰۹۳۱
۴-۱۶ mg/dL	Calcium ۵۰۸۹۳
۰.۵-۶ mEq/L	Magnesium ۵۰۹۶۰
۳-۲۵ g/dL	Hemoglobin ۵۰۸۱۱
۵-۱۰۰۰ K/uL	Platelets ۵۱۲۶۵
۰.۵-۵۰ K/uL	WBC ۵۱۳۰۰
۰.۵-۲۵ mmol/L	Lactate ۵۰۸۱۳
۵-۲۰۰۰ U/L	ALT ۵۰۸۶۱
۵-۲۰۰۰ U/L	AST ۵۰۸۷۸
۵-۳۰۰ mg/dL	BUN ۵۱۰۰۶
۵-۵۰ mEq/L	Bicarbonate ۵۰۸۸۲

جدول ت.۴: شناسه‌های آیتم علائم حیاتی MIMIC-IV

شناسه آیتم نام	بازه
۲۲۰۰۴۵ ضربان قلب	۲۰-۲۵۰ bpm
۲۲۰۰۵۰ فشار سیستولیک	۴۰-۲۵۰ mmHg
۲۲۰۰۵۱ فشار دیاستولیک	۲۰-۱۸۰ mmHg
۲۲۰۰۵۲ فشار میانگین	۳۰-۲۰۰ mmHg
۲۲۳۷۶۱ دما	۹۰-۱۱۰ F
۲۲۰۲۷۷ SpO2	۵۰-۱۰۰ %
۲۲۰۲۱۰ نرخ تنفس	۱-۶۰ /min

پیوست ث

استنتاج‌های ریاضی

این پیوست استنتاج‌های ریاضی برای اجزای کلیدی را ارائه می‌کند.

۱. تعریف AUROC

مساحت زیر منحنی ROC (AUROC) به صورت زیر تعریف می‌شود:

$$\text{AUROC} = \int_0^1 \text{TPR}(t) d(\text{FPR}(t)) = \int_0^1 \text{TPR}(\text{FPR}^{-1}(u)) du \quad (\text{ث. ۱})$$

که در آن TPR (نرخ مثبت صحیح) و FPR (نرخ مثبت کاذب) توابعی از آستانه‌ی تصمیم t هستند. به طور معادل، AUROC برابر است با احتمال اینکه یک نمونه‌ی مثبت تصادفی بالاتر از یک نمونه‌ی منفی تصادفی رتبه‌بندی شود:

$$\text{AUROC} = P(\text{score}(X^+) > \text{score}(X^-)) \quad (\text{ث. ۲})$$

AUROC نسبت به آستانه ثابت است و برای طبقه‌بندی نامتعادل مناسب است.

ث.۲ امتیاز F1 کلان

برای طبقه‌بندی دودویی با کلاس‌های ۰ و ۱:

$$F1_k = \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \quad (\text{ث.۳})$$

امتیاز F1 کلان میانگین روی کلاس‌هاست:

$$F1_{\text{macro}} = \frac{F1_0 + F1_1}{2} \quad (\text{ث.۴})$$

این هر دو کلاس را به‌طور یکسان در نظر می‌گیرد؛ برای داده‌ی نامتعادل مهم است.

ث.۳ ضریب همبستگی متیوز (MCC)

MCC به‌صورت زیر تعریف می‌شود:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (\text{ث.۵})$$

MCC در بازه‌ی $[-1, 1]$ است؛ مقدار ۰ پیش‌بینی تصادفی را نشان می‌دهد. متقارن است و نسبت به نامتعادل کلاس‌ها مقاوم است.

ث.۴ گرادیان تابع زیان شبکه‌ی نمونه‌اولیه‌ای (Prototypical)

برای شبکه‌های نمونه‌اولیه‌ای با تابع زیان آنتروپی متقاطع $\mathcal{L} = -\log p(y|x)$ ، گرادیان نسبت به بردار نهفته پرس‌وجو $f_{\theta}(x)$ عبارت است از:

$$\frac{\partial \mathcal{L}}{\partial f_{\theta}(x)} = \frac{1}{\tau} \left(\mathbf{c}_y - \sum_k p(y = k|x) \mathbf{c}_k \right) \quad (\text{ث.۶})$$

که در آن $\mathbf{c}_k$ نمونه‌اولیه‌ی کلاس k است. گرادیان پرس‌وجو را به سمت نمونه‌اولیه‌ی واقعی می‌کشد و از بقیه دور می‌کند.

ث.۵ زیان کانونی

زیان کانونی نمونه‌های آسان را کم‌اهمیت می‌کند:

$$\mathcal{L}_{\text{focal}} = -\alpha(1 - p_t)^\gamma \log(p_t) \quad (\text{ث.۷})$$

که در آن $p_t = p(y|x)$ احتمال پیش‌بینی شده برای کلاس درست است. برای $\gamma > 0$ ، نمونه‌های آسان ($p_t \approx 1$) سهم کمتری دارند. ما $\gamma = 2$ استفاده می‌کنیم.

ث.۶ قانون به‌روزرسانی FedAvg

میانگین‌گیری فدرال (Federated Averaging) به‌روزرسانی‌های محلی را با میانگین وزنی جمع می‌کند:

$$\theta_{t+1} = \sum_{k=1}^K \frac{n_k}{n} \theta_{t+1}^{(k)} \quad (\text{ث.۸})$$

که در آن n_k تعداد نمونه‌ها در کلاینت k ، $n = \sum_k n_k$ و $\theta_{t+1}^{(k)}$ مدل پس از آموزش محلی روی کلاینت k است. وقتی داده‌ها IID باشند، گرادینت مورد انتظار هدف سراسری حفظ می‌شود؛ تحت non-IID همگرایی ممکن است کندتر باشد.

ث.۷ خودتوجهی

برای دنباله‌ی ورودی $\mathbf{X} \in \mathbb{R}^{L \times d}$ ، خودتوجه به‌صورت زیر محاسبه می‌شود:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} \right) \mathbf{V} \quad (\text{ث.۹})$$

که در آن $\mathbf{Q} = \mathbf{X}\mathbf{W}_Q$ ، $\mathbf{K} = \mathbf{X}\mathbf{W}_K$ ، $\mathbf{V} = \mathbf{X}\mathbf{W}_V$. توجه چندسره h چنین عملیاتی را موازی اجرا کرده و خروجی‌ها را به هم می‌چسباند. در ETHOS از $h = 8$ سر استفاده می‌کنیم.

ث.۸. بازه‌ی اطمینان bootstrap

برای AUROC، بازه‌ی اطمینان ۹۵٪ با نمونه‌برداری مجدد از مجموعه‌ی آزمون $B = 1000$ بار با جایگزینی محاسبه می‌کنیم. برای هر نمونه‌ی bootstrap b ، $\hat{A}_b = \text{AUROC}(y, \hat{y}_b)$ را می‌سنجیم. بازه‌ی اطمینان $[\hat{A}_{(25)}, \hat{A}_{(975)}]$ است که زیرنویس‌ها صدک‌های توزیع bootstrap را نشان می‌دهند.

ث.۹. آزمون DeLong

آزمون DeLong [DeLong et al., 1988] دو منحنی ROC همبسته را مقایسه می‌کند. برای پیش‌بینی‌های جفت (s_1, s_2) روی همان نمونه‌ها، آماره‌ی آزمون بر اساس تفاوت در AUC تجربی است. تحت فرض صفر (برابری AUC)، آماره به‌طور مجانبی نرمال است. در این پایان‌نامه فقط در مواردی می‌توان چنین آزمونی را تفسیر کرد که دو مدل روی همان نمونه‌های آزمون و با بردارهای احتمال هم‌تراز ارزیابی شده باشند؛ بنابراین مقایسه‌های بین‌پروتکلی به‌صورت توصیفی گزارش می‌شوند و آزمون‌های جفتی کامل به کار آینده سپرده می‌شوند.

پیوست ج

زمان بندی پروژه (نمودار گانت)

این پیوست زمان بندی پروژه را به صورت نمای گانت ارائه می کند.

ج.۱ زمان بندی ۱۲ ماهه

پروژه طبق برنامه ی ۱۲ ماهه ی هم راستا با پیشنهاد پیش می رود. فازهای ۱ تا ۹ مرور ادبیات، طراحی کوهورت، توکن سازی، پیاده سازی ETHOS، آموزش کم نمونه و فدرال، مقایسه با خط پایه، آزمایش ها و نگارش پایان نامه را پوشش می دهند.

ج.۲ نمای کلی فازها

ج.۳ نقاط عطف کلیدی

- هفته ی ۴: اتمام مرور ادبیات؛ نهایی شدن پرسش های پژوهشی.
- هفته ی ۷: استخراج کوهورت؛ پردازش ۲,۰۰۰ بیمار اول.
- هفته ی ۱۴: عملیاتی شدن خط لوله ی ETHOS و یادگیری کم نمونه.
- هفته ی ۱۸: اتمام مقایسه ی فدرال در برابر متمرکز.
- هفته ی ۲۴: اجرای همه ی آزمایش ها؛ شناسایی بهترین مدل (RF).
- هفته ی ۳۲: تکمیل پیش نویس پایان نامه؛ آماده سازی دفاع.

جدول ج.۱: نمای کلی گانت پروژه

فاز وظیفه	شروع (هفته)	مدت
۱ مرور ادبیات	۱	۴
۲ دسترسی MIMIC-IV و طراحی کوهورت	۵	۲
۳ استخراج داده و توکن‌سازی	۷	۴
۴ پیاده‌سازی رمزگذار ETHOS	۱۱	۳
۵ فرا یادگیری کم‌نمونه	۱۴	۴
۶ آموزش فدرال	۱۸	۲
۷ خط پایه‌ی Tabular SOTA	۱۲	۴
۸ آزمایش‌ها و حذف اجزا	۲۰	۴
۹ نگارش و اشکال‌ها	۲۴	۸

ج.۴. گرافیک نقشه‌ی راه

شکل ج.۱ نقشه‌ی راه کارهای آینده (۱ تا ۵ سال) را نشان می‌دهد.

نقشه‌ی راه کارهای آینده

فاز ۱ (۱ سال): کوهورت بزرگ‌تر، اعتبارسنجی بیرونی
 فاز ۲ (۲ سال): آزمایش چندسایتی فدرال
 فاز ۳ (۳ سال): استقرار آینده‌نگر
 فاز ۴ (۴ سال): مسیر تأیید مقرراتی
 فاز ۵ (۵ سال): یکپارچه‌سازی پشتیبان تصمیم بالینی

شکل ج.۱: فازهای کار آینده (۱ تا ۵ سال)

ج.۵. مدیریت ریسک

جدول ج.۲ ریسک‌های پروژه و راهکارهای کاهش را، مطابق چارچوب مدیریت پروژه‌ی پیشنهاد، خلاصه می‌کند.

جدول ج.۲۰: مدیریت ریسک پروژه

ریسک	احتمال	اثر	کاهش اثر
تأخیر دسترسی به داده	متوسط	بالا	درخواست زودهنگام اعتبار MIMIC-IV؛ داده‌ی مصنوعی پشتیبان
عملکرد ضعیف مدل	پایین	پایین	تکیه بر سقف‌های کلاسیک موجود؛ انباشت کم‌نمونه و خط پایه جدولی به‌عنوان مسیر پشتیبان
مشکل همگرایی فدرال	پایین	متوسط	تنظیم FedAvg؛ بازگشت به متمرکز
محدودیت منابع محاسباتی	پایین	پایین	اعتبار ابری؛ کوهورت کوچک‌تر در صورت نیاز
لغزش زمان‌بندی	متوسط	متوسط	بافر در گانت؛ اولویت آزمایش‌های هسته

پیوست چ

واژه‌نامه (۵۰ واژه)

این پیوست واژه‌های کلیدی به کاررفته در پایان‌نامه را تعریف می‌کند.

۱. چ مفاهیم هسته

۲. چ واژه‌نامه‌ی تفصیلی (فهرست کامل)

واژه	تعریف
Adversarial robustness	تاب‌آوری مدل در برابر ورودی‌های مختل شده.
Attention mechanism	وزن‌ها روی توکنهای ورودی برای بازنمایی وابسته به زمینه.
AUROC	مساحت زیر منحنی ROC؛ احتمال بالاتر بودن رتبه‌ی مثبت نسبت به منفی.
AUPRC	مساحت زیر منحنی دقت-بازخوانی؛ برای داده‌ی نامتعادل مفید است.
Bootstrap CI	بازه‌ی اطمینان از نمونه‌برداری مجدد با جایگزینی.
Calibration	تطابق احتمالات پیش‌بینی شده با فراوانی مشاهده شده.
Class imbalance	توزیع نابرابر کلاس‌ها (مثلاً 42٪ در برابر 58٪).
Cross-validation	ارزیابی K-fold برای برآورد پایدار عملکرد.
Differential privacy	چارچوب رسمی برای محدود کردن افشای اطلاعات فردی در آمار یا مدل‌های تجمیعی.
Embedding	بردار متراکم بازنمایی ورودی (مثلاً 128 بعدی).
Episodic training	فرا یادگیری با نمونه‌برداری قسمت support/query.

واژه	تعریف
ETHOS	Encoder for Time-series and Heterogeneous Organ Signals.
FedAvg	میانگین‌گیری فدرال؛ میانگین وزنی به‌روزرسانی‌های کلاینت.
Federated learning	آموزش روی داده‌های توزیع‌شده بدون متمرکزسازی.
Feasibility	دودویی: ترخیص به منزل/توان‌بخشی (1) در برابر مرگ/SNF (0).
Focal Loss	آنتروپی متقاطع با کم‌اهمیت‌کردن نمونه‌های آسان با $(1 - p)^\gamma$.
F1 کلان	میانگین F1 به‌ازای هر کلاس؛ کلاس‌ها را برابر می‌انگارد.
Gradient descent	بهینه‌سازی با حرکت تکراری در جهت مخالف گرادیان.
Hyperparameter	پارامتر مدل/پیکربندی که پیش از آموزش تنظیم می‌شود (مثلاً نرخ یادگیری).
ICD-10	طبقه‌بندی بین‌المللی بیماری‌ها، ویرایش دهم.
ICU LOS	مدت بستری در واحد مراقبت ویژه.
Imputation	پر کردن مقادیر گم‌شده (مثلاً forward-fill، میانگین).
ItemID	شناسه‌ی MIMIC برای نوع اندازه‌گیری آزمایش/علامت حیاتی.
K-shot	تعداد نمونه‌های support به‌ازای هر کلاس (مثلاً $K = 5$).
Label smoothing	نرم کردن برچسب‌های one-hot برای تنظیم.
LightGBM	تقویت گرادیان با رشد برگ‌محور.
MAML	Model-Agnostic Meta-Learning؛ یادگیری مقداردهی اولیه برای سازگاری سریع.
MCC	ضریب همبستگی متبوز؛ متعادل برای طبقه‌بندی دودویی.
Meta-learning	یادگیری برای یادگیری؛ بهینه‌سازی روی وظایف.
MIMIC-IV	Medical Information Mart for Intensive Care، نسخه‌ی 4.
Normalization	مقیاس کردن ورودی‌ها به بازه‌ی استاندارد (مثلاً $[0, 1]$).
Outlier	مقدار افراطی؛ ما به بازه‌های بالینی clip می‌کنیم.
Parquet	قالب ذخیره‌ی ستونی برای I/O کارآمد.
Precision	$TP / (TP + FP)$ ؛ ارزش پیش‌بینی مثبت.
Prototype	مرکز جرم کلاس در فضای نهفته (شبکه‌های نمونه‌اولیه‌ای).
Recall	$TP / (TP + FN)$ ؛ حساسیت.
Resampling	oversampling اقلیت یا undersampling اکثریت.
SHAP	SHapley Additive exPlanations؛ انتساب ویژگی.
SMOTE	Synthetic Minority Over-sampling Technique.
SOFA	Sequential Organ Failure Assessment؛ نمره‌ی نارسایی اندام.
Stay ID	شناسه‌ی یکتای بستری ICU در MIMIC.
Symptom Token	بازنمایی گسسته: (symptom_id, intensity, time, modality).
Threshold tuning	انتخاب آستانه‌ی تصمیم برای بیشینه‌کردن F1 یا معیار دیگر.

واژه	تعریف
توکن‌سازی	نگاشت مقادیر پیوسته به شناسه‌های توکن گسسته.
Transfer learning	استفاده از مدل از پیش آموزش دیده روی وظیفه‌ی جدید.
Validation set	داده‌ی نگه‌داشته شده برای انتخاب مدل؛ برای گزارش نهایی استفاده نمی‌شود.
XGBoost	Extreme Gradient Boosting؛ مجموعه‌ی درخت.
Zero-shot	تعمیم با صفر نمونه‌ی برچسب‌دار در کلاس هدف.

جدول چ.۱: واژه‌نامه (واژه‌های منتخب)

واژه تعریف
AUROC مساحت زیر منحنی ROC؛ معیار رتبه‌بندی نسبت به آستانه. AUPRC مساحت زیر منحنی دقت-بازخوانی. Few-shot یادگیری با تعداد اندک نمونه‌ی برچسب‌دار به‌ازای هر کلاس. FedAvg میانگین‌گیری فدرال؛ تجميع به‌روزرسانی‌های مدل کلاینت‌ها. Medical Information Mart for Intensive Care MIMIC-IV، نسخه‌ی 4. SOFA نمره‌ی ارزیابی پی‌درپی نارسایی اندام. SHapley Additive exPlanations SHAP؛ روش انتساب ویژگی.
بازنمایی
Symptom Token بازنمایی گسسته از مقدار آزمایش/علامت حیاتی (بین و شدت). Encoder for Time-series and Heterogeneous Organ Signals ETHOS. Prototype مرکز جرم کلاس در فضای نهفته (شبکه‌های نمونه‌اولیه‌ای).
یادگیری
Model-Agnostic Meta-Learning MAML. Episodic رژیم آموزش با تقسیم support/query. Focal Loss زیان کانونی؛ نمونه‌های آسان را کم‌اهمیت می‌کند.
بالینی
Feasibility ترخیص به منزل/توان بخشی در برابر مرگ/SNF. ICU LOS مدت بستری در واحد مراقبت ویژه. ICD-10 طبقه‌بندی بین‌المللی بیماری‌ها، ویرایش دهم.
ارزیابی
MCC ضریب همبستگی متیوز. F1 کلان میانگین F1 به‌ازای هر کلاس. Bootstrap CI بازه‌ی اطمینان از نمونه‌برداری مجدد. Wilcoxon آزمون جفتی ناپارامتریک.
فنی
ItemID شناسه‌ی MIMIC برای نوع آزمایش/علامت حیاتی. Stay ID شناسه‌ی یکتای بستری ICU. Parquet قالب ذخیره‌ی ستونی.

پیوست ح

تهدیدهای اعتبار و کاهش اثر

این پیوست تهدیدهای اعتبار و راهکارهای متناظر را بررسی می کند.

ح.۱ اعتبار درونی

جدول ح.۱: تهدیدهای اعتبار و کاهش اثر

تهدید	نوع	کاهش اثر
اندازه‌ی نمونه (2,000)	درونی	بازه‌های bootstrap؛ گزارش واریانس؛ پذیرش محدودیت.
نامتعادل کلاس (58/42)	سازه	وزن‌دهی کلاس؛ حذف اجزای SMOTE؛ امتیاز F1 کلان.
انتخاب ابرپارامتر	درونی	جستجوی شبکه‌ای؛ بذر ثابت (42)؛ گزارش کامل شبکه‌ها.
تقسیم آموزش/اعتبارسنجی / آزمون	درونی	طبقه‌ای؛ تقسیم ثابت؛ بدون نشت داده.
اعتبار بیرونی		
تکم‌مرکز (MIMIC)	بیرونی	داده‌ی چندساله؛ گره‌های بیماری متنوع.
جمعیت فقط آمریکا	بیرونی	اذعان؛ آینده؛ اعتبارسنجی چندسایتی.
فقط تنظیم ICU	بیرونی	دامنه‌ی روشن؛ تعمیم به سایر تنظیمات با احتیاط.
اعتبار سازه		
تعریف امکان‌پذیری	سازه	هم‌راستایی با کارهای پیشین؛ محل ترخیص به‌عنوان پراکسی.
فقط 24 ساعت اول	سازه	استاندارد برای پیش‌بینی زودهنگام؛ مستندسازی انتخاب.

ح.۲ محدودیت‌ها

- داده: MIMIC-IV گذشته‌نگر است؛ اعتبارسنجی آینده‌نگر لازم است.

- **مدل‌ها:** ETHOS از RF ضعیف‌تر است؛ نتیجه‌ی منفی به‌صورت صادقانه گزارش شده است.
- **تعمیم:** نتایج ممکن است به بیمارستان‌ها یا کشورهای دیگر منتقل نشود.
- **سوگیری:** تفکیک سنی/جنسیتی انجام شده؛ ممیزی کامل انصاف توصیه می‌شود.

پیوست خ

چک لیست تکرارپذیری

این پیوست چک لیست تکرارپذیری برای بازتولید نتایج ما را ارائه می کند.

خ.۱ چک لیست

جدول خ.۱: چک لیست تکرارپذیری

مورد	وضعیت
کد در دسترس	✓ (مخزن)
منبع داده	MIMIC-IV v3.1 (دسترسی اعتباردار)
بذر تصادفی	42 (ثابت)
ابزارها	پیوست آ (شبکه های کامل)
پرس و جوهای SQL	پیوست ب
محیط	Python 3.10, PyTorch 2.x, scikit-learn 1.3+
سخت افزار	CPU کافی؛ GPU اختیاری برای ETHOS

خ.۲ فهرست کد

کد نماینده برای توکن سازی (tokenize.py):

توکن سازی (گزیده) کد خ.۱:

```
def tokenize_symptom(value: float, bin_edges: np.ndarray) -> int:
```

```

2     """Map continuous value to discrete token ID."""
3     bin_id = np.searchsorted(bin_edges, value, side='right') - 1
4     bin_id = np.clip(bin_id, 0, len(bin_edges) - 2)
5     return bin_id + 1 # 0 reserved for mask
6
7 def add_intensity(seq: np.ndarray, values: np.ndarray) -> np.ndarray:
8     """Append intensity as extra dimension."""
9     return np.concatenate([seq, values[:, None]], axis=-1)

```

خ.۳ دسترسی به داده

MIMIC-IV نیاز به دسترسی اعتباردار از PhysioNet دارد. اسکرپت‌های استخراج کوهورت ارائه شده‌اند. فایل‌های parquet پردازش شده را می‌توان از MIMIC-IV خام با خط لوله در `scripts/` بازتولید کرد.

خ.۴ محیط و وابستگی‌ها

برای بازتولید نتایج، از محیط زیر استفاده کنید:

```

1 Python 3.10+
2 torch>=2.0.0
3 scikit-learn>=1.3.0
4 pandas>=2.0
5 numpy>=1.24
6 xgboost>=2.0
7 lightgbm>=4.0
8 catboost>=1.2

```

آزمایش‌ها را از ریشه‌ی مخزن اجرا کنید (برای استخراج، MIMIC-IV زیر `data/3.1/` لازم است).

هماهنگ‌کننده‌ها:

- `python experiments/run_all.py`: استخراج کامل + آزمایش‌های هسته؛ از `-skip-extraction` اگر `data/ processed/` وجود دارد؛ `-figures-only` فقط اشکال‌ها را بازتولید می‌کند؛ `-with-fewshot` کارهای طولانی کم‌نمونه را اضافه می‌کند.
- `python scripts/ run_value_experiments.py -quick -figures -skip-sota -skip-exp1`: اجرای مرتب «ارزش‌بالا» برای CPU (آهسته‌ترین تنظیم SOTA و Exp1 کامل را رد می‌کند؛

skip-exp1- فقط در صورت نیاز).

- `python experiments/exp1_main.py -quick` Exp1 سریع روی CPU (قبل از NumPy، BLAS تکنیکی برای جلوگیری از بستن OpenMP با PyTorch پس از sklearn/XGBoost). برای پروتکل کامل Exp1، بدون `-quick` اجرا کنید (GPU توصیه می‌شود).

خروجی‌ها: اسکریپت `python scripts/build_thesis_assets.py` اشکال‌ها و فایل‌های زیر را بازتولید

می‌کند:

- `ALL_TABLES.tex` و `ALL_TABLES_APPENDIX.tex` برای جداول اصلی و پیوست د.

- `KEY_FINDINGS.md` از مسیر `results/generate_all_outputs.py`.

پیش از ارسال، `python results/validate_thesis_readiness.py` را اجرا کنید.

در `config.yaml`، `random_seed=42` را ثابت کنید. شبکه‌های ابرپارامتر در پیوست آ هستند.

پیوست د

جداول نتایج صادرشده از خط لوله

این پیوست جداول آزمایش را فهرست می‌کند که به صورت خودکار از خروجی‌های CSV زیر `results/tables/` هنگام اجرای `python results/generate_all_outputs.py` از ریشه‌ی مخزن تولید می‌شوند. آن‌ها برای بررسی دقیق تکرارپذیری ارائه شده‌اند و ممکن است اندکی از جداول قالب‌بندی‌شده‌ی دستی در فصل ۵ متفاوت باشند اگر آن‌ها ستون‌های اضافی، اجرای جایگزین (مثلاً فرا-یادگیر stacked)، یا گرد کردن روایی داشته باشند. تفسیر و سلسله‌مراتب کامل گزارش در فصل نتایج آمده است.

Table 1.۲: مقایسه‌ی مدل‌های اصلی (خروجی خودکار مخزن): 1: آزمایش

مدل	AUROC	F1	دقت	MCC
Logistic Regression	0.724	0.682	0.700	0.364
Random Forest	0.762	0.679	0.718	0.372
XGBoost	0.694	0.632	0.662	0.266
Standard NN	0.652	0.616	0.660	0.242
Federated NN (بدون کم‌نمونه)	0.662	0.618	0.642	0.236
مدل پیش‌نهادی کم‌نمونه	0.611	0.572	0.583	0.155

Table 2.۲: (خروجی خودکار مخزن) K-shot : حساسیت 2 آزمایش

K	AUROC	AUROC انحراف معیار	F1
1.0	0.564	0.022	0.554
3.0	0.564	0.025	0.548
5.0	0.560	0.029	0.539
10.0	0.557	0.021	0.534
15.0	0.557	0.021	0.534

Table 3.۴: فدرال در برابر متمرکز (خروجی خودکار مخزن): 3 آزمایش

چیدمان	AUROC	F1
متمرکز	0.552	0.543
فدرال	0.547	0.540
شکاف	0.005	0.003

Table 4.۴: مطلقه حذف تدریجی (خروجی خودکار مخزن): 4 آزمایش

گونه	AUROC	F1
مدل کامل	0.583	0.554
بدون توکن‌های غلایم	0.724	0.628
بدون سوگیری بالایی	0.584	0.557
بدون وزندهی شدت	0.577	0.570
بدون افت زمانی	0.583	0.554
بدون سر کمین‌مونه	0.645	0.584

Table 5.۴: تعمیم‌پذیری بین‌بی‌ماری (خروجی خودکار مخزن): 5 آزمایش

گروه آزمون	مدل پیش‌نه‌ادی	LR	XGBoost	NN
کلی‌وی (4 گروه)	0.602	0.668	0.704	0.572
دی‌ابت (5 گروه)	0.478	0.658	0.700	0.643

پیوست ذ

ملاحظات اخلاقی

این پیوست ملاحظات اخلاقی استقرار یادگیری ماشین در مراقبت سلامت را بررسی می کند.

ذ.۱ چارچوب اخلاقی

جدول ذ.۱: ملاحظات اخلاقی

مسئله	رویکرد
سوگیری و انصاف ارزیابی طبقه ای بر اساس سن و جنس؛ گزارش معیارها به ازای هر گره.	سوگیری و انصاف ارزیابی طبقه ای بر اساس سن و جنس؛ گزارش معیارها به ازای هر گره.
حریم خصوصی	یادگیری فدرال؛ بدون اشتراک داده ی خام؛ گزینه ی حریم تفاضلی.
شفافیت	توضیحات SHAP؛ مطالعات موردی؛ خطوط پایه ی قابل تفسیر.
پاسخگویی	مدل به عنوان پشتیبان تصمیم؛ تصمیم نهایی با پزشک.
رضایت	MIMIC ناشناس؛ تأیید نهادی برای استفاده ی پژوهشی.

ذ.۲ پیامدهای سیاست

استقرار سازگار با GDPR: یادگیری فدرال با حداقل سازی داده و محدودیت هدف هم راستا است. به روزرسانی های مدل (گرایان ها) را می توان بدون اشتراک رکوردهای خام تجمیع کرد. داده ی محلی در هر سایت می ماند.

صرفه ی اقتصادی: بهبود ۱٪ دقت (مثلاً AUROC ۰.۷۶ در برابر ۰.۷۵) می تواند روزهای غیرضروری ICU یا ترخیص های نامناسب را کاهش دهد. تحلیل اقتصادی به داده ی هزینه ی مختص سایت نیاز دارد.

ذ.۳ ادعاهای به سبک ثبت اختراع

برای مرجع، یک ادعای روشی می تواند چنین باشد:

“A method for few-shot token-based EHR prediction comprising: (a) extracting lab and vital measurements from a first 24-hour window of an ICU stay; (b) tokenizing said measurements into discrete symptom tokens with intensity weighting; (c) encoding said tokens via a transformer encoder; (d) computing class prototypes from support set embeddings; (e) predicting treatment feasibility for a query patient by distance to said prototypes.”

پیوست ر

عناصر خلاقانه و تجسم‌ها

این پیوست عناصر خلاقانه و تجسم‌های تکمیلی را توصیف می‌کند.

۱. ر. پوسترهای معماری

خط لوله‌ی ETHOS (۳ نما):

۱. جریان داده: MIMIC خام → کوهورت → آزمایش‌ها/علائم حیاتی → توکن‌ها → دنباله‌ها.
۲. جریان مدل: توکن‌ها → رمزگذار ETHOS → بردارهای نهفته → نمونه‌اولیه‌ها → پیش‌بینی.
۳. جریان فدرال: آموزش محلی → بارگذاری گرادیان → FedAvg → پخش مدل سراسری.

۲. ر. اینفوگرافیک سفر بیمار

روز ۱ ICU → Tokens → پیش‌بینی → ترخیص:

- ساعت ۰-۲۴: آزمایش‌ها و علائم حیاتی جمع‌آوری می‌شوند.
- توکن‌سازی: هر اندازه‌گیری → جفت (بین، شدت).
- دنباله: ۲۵ توکن به‌ازای هر بیمار (در صورت نیاز با padding).
- مدل: ETHOS کدگذاری می‌کند → مقایسه با نمونه‌اولیه → ممکن/ناممکن.
- پیامد: ترخیص به منزل/توان‌بخشی (ممکن) در برابر SNF/مرگ (ناممکن).

۳.۰ تحلیل SWOT

جدول ۳.۱: SWOT: یادگیری ماشین جدولی در برابر یادگیری عمیق

نقاط قوت جدولی: قابل تفسیر، سریع، عملکرد قوی. عمیق: انعطاف، یادگیری بازنمایی.	
ضعفها	جدولی: ویژگی‌های دستی. عمیق: داده‌پرور، کمتر قابل تفسیر.
فرصتها	مدل‌های ترکیبی؛ توکن‌سازی بهتر؛ کوهورت‌های بزرگ‌تر.
تهدیدها	جابه‌جایی توزیع؛ موانع مقرراتی؛ اعتماد بالینی.

۴.۰ دمای تعاملی

برنامه‌ی Gradio برای بالینیان: یک رابط وب امکان بارگذاری CSV ناشناس آزمایش/علامت حیاتی، توکن‌سازی لحظه‌ای، و نمایش پیش‌بینی‌های RF + ETHOS با توضیحات SHAP را فراهم می‌کند. تنظیم آستانه و تحلیل حساسیت را پشتیبانی می‌کند.

۵.۰ نمودار گردباد حساسیت

نمودار گردباد حساسیت AUROC به تغییر ابرپارامترها را نشان می‌دهد: max_depth, n_estimators, نرخ یادگیری، آستانه. RF بیشترین حساسیت به آستانه دارد؛ ETHOS به K .

۶.۰ مختصات موازی

نتایج حذف اجزا را می‌توان در مختصات موازی تجسم کرد: هر محور = یک بعد حذف (tokens، شدت، کم‌نمونه)؛ هر خط = یک پیکربندی؛ رنگ = AUROC.

پیوست ز

مشخصات رابط برنامه‌نویسی کاربردی (API)

این پیوست مشخصات رابط برنامه‌نویسی کاربردی REST API برای استقرار مدل پیش‌بینی امکان‌پذیری درمان را ارائه می‌کند.

ز.۱ نمای کلی

این رابط برنامه‌نویسی سه نقطه‌ی پایانی دارد:

- POST /predict: پیش‌بینی امکان‌پذیری از ورودی آزمایش/علامت حیاتی
- GET /model: فراداده و نسخه‌ی مدل
- POST /explain: توضیح SHAP برای یک پیش‌بینی

آدرس پایه: <https://api.example.com/v1>

ز.۲ نقاط پایانی

ز.۲.۱ POST /predict

درخواست:


```
1 {
2   "patient_id": "string",
3   "features": {
4     "creatinine": 1.2,
5     "glucose": 120,
6     "hemoglobin": 10.5
7   }
8 }
```

پاسخ:

```
1 {
2   "patient_id": "string",
3   "feasible": true,
4   "probability": 0.72,
5   "model_version": "1.0"
6 }
```

ز.۲.۲ GET /model

فراداده‌ی مدل را برمی‌گرداند: نسخه، AUROC، تاریخ آموزش، فهرست ویژگی‌ها.

ز.۳.۲ POST /explain

بدنه‌ی درخواست همان predict/. مقادیر SHAP به‌ازای هر ویژگی برای پیش‌بینی را برمی‌گرداند.

ز.۳ خلاصه‌ی مشخصات OpenAPI

جدول ز.۱: خلاصه‌ی نقاط پایانی رابط برنامه‌نویسی کاربردی

روش	مسیر توضیح
POST	predict / پیش‌بینی امکان‌پذیری
GET	model / فراداده‌ی مدل
POST	explain / توضیح SHAP

احراز هویت: کلید API در هدر X-API-Key. محدودیت نرخ: ۱۰۰ درخواست در دقیقه.

پیوست ژ

جداول تفصیلی جستجوی ابرپارامتر و حذف اجزا

این پیوست نتایج تفصیلی جستجوی ابرپارامتر و جداول حذف اجزا را ارائه می‌کند.

ژ.۱ شبکه‌ی ابرپارامتر Random Forest

جدول ژ.۱: شبکه‌ی RandomizedSearchCV برای Random Forest

پارامتر	بازه‌ی جستجو
n_estimators	[100, 200, 300, 400, 500]
max_depth	[8, 12, 16, 20, 24, 28]
min_samples_split	[2, 5, 10]
min_samples_leaf	[1, 2, 4]
max_features	[sqrt, log2]
class_weight	[balanced, balanced_subsample]

جدول ژ. ۲: شبکه‌ی RandomizedSearchCV برای XGBoost

پارامتر	بازه‌ی جستجو
n_estimators	[100, 200, 300, 400, 500]
max_depth	[4, 6, 8, 10, 12]
learning_rate	[0.01, 0.03, 0.05, 0.1]
subsample	[0.5, 0.7, 0.85, 1.0]
colsample_bytree	[0.5, 0.7, 0.85, 1.0]
min_child_weight	[1, 3, 5, 7]
reg_alpha	[0.01, 0.1, 1.0, 10.0]
reg_lambda	[0.01, 0.1, 1.0, 10.0]

جدول ژ. ۳: مطالعه حذف اجزا (همگام با خروجی فعلی مخزن)

نوع	AUROC	F1	AUROCΔ
مدل کامل	۰.۵۸۳	۰.۵۵۴	-
بدون توکن‌های علائم (LR خام)	۰.۷۲۴	۰.۶۲۸	+۰.۱۴۰
بدون سوگیری بالینی	۰.۵۸۴	۰.۵۵۷	+۰.۰۰۱
بدون وزن‌دهی شدت	۰.۵۷۷	۰.۵۷۰	-۰.۰۰۶
بدون افت زمانی	۰.۵۸۳	۰.۵۵۴	۰.۰۰۰
بدون سر کم‌نمونه (Standard NN)	۰.۶۴۵	۰.۵۸۴	+۰.۰۶۲

ژ.۲ شبکه‌ی ابرپارامتر XGBoost

ژ.۳ حذف اجزای ETHOS: نتایج کامل

ژ.۴ حساسیت K-شات: جدول کامل

جدول ژ.۴: حساسیت K-شات (همه‌ی مقادیر آزموده‌شده)

AUROC K انحراف معیار AUROC بازه اطمینان 95% AUROC F1 کلان			
۰.۵۵۴	[۰.۵۴۳, ۰.۵۸۵]	۰.۰۲۲	۰.۵۶۴ ۱
۰.۵۴۸	[۰.۵۴۱, ۰.۵۸۸]	۰.۰۲۵	۰.۵۶۴ ۳
۰.۵۳۹	[۰.۵۳۳, ۰.۵۸۸]	۰.۰۲۹	۰.۵۶۰ ۵
۰.۵۳۴	[۰.۵۳۸, ۰.۵۷۷]	۰.۰۲۱	۰.۵۵۷ ۱۰
۰.۵۳۴	[۰.۵۳۸, ۰.۵۷۷]	۰.۰۲۱	۰.۵۵۷ ۱۵

ژ.۵ دوره‌های فدرال: معیارها به تفکیک دور

جدول ژ.۵: آموزش فدرال: AUROC اعتبارسنجی به تفکیک دور (نمونه)

دور Val AUROC	
۰.۵۲	۰
۰.۵۶	۵
۰.۵۹	۱۰
۰.۶۱۲	۱۵
۰.۶۲۴	۲۰

ژ.۶ چندبیماری: نتایج کامل همه‌ی گره‌ها

در نسخه‌های کاری اولیه، مجموعه‌ای از جداول انگلیسی توسعه‌ای در فایل tables_extended.tex درج می‌شد. از آن‌جا که بخشی از آن جداول بر پایه‌ی اجراهای تاریخی و ناهمگام با خروجی نهایی مخزن بودند، در نسخه نهایی پایان‌نامه حذف شدند تا از گزارش دوگانه اعداد جلوگیری شود. جداول تکمیلی معتبر در پیوست د و همین پیوست

جدول ژ. ۶: تعمیم بین‌بیماری (همه‌ی گره‌ها)

گره آزمون	پیشنهادی	LR	XGBoost	NN
گره 1 (سپسیس)	۰.۶۱	۰.۶۸	۰.۷۱	۰.۵۸
گره 2 (قلبی)	۰.۶۲	۰.۷۰	۰.۷۲	۰.۶۰
گره 3 (تنفسی)	۰.۶۰	۰.۶۷	۰.۶۹	۰.۵۷
گره 4 (کلیوی)	۰.۶۰	۰.۶۷	۰.۷۰	۰.۵۷
گره 5 (دیابت)	۰.۵۳	۰.۶۶	۰.۷۰	۰.۶۴

آمده‌اند.

پیوست س

خلاصه‌ی معادلات کلیدی

این پیوست معادلات اصلی به کاررفته در پایان‌نامه را برای مرجع سریع گردآوری می‌کند.

س.۱ پیش‌پردازش داده

نرمال‌سازی min-max با برش به بازه‌ی بالینی:

$$x' = \frac{\text{clip}(x, x_{\min}, x_{\max}) - x_{\min}}{x_{\max} - x_{\min}} \quad (\text{س.۱})$$

س.۲ توکن علائم

هر توکن: $[\text{symptom_id}, \text{intensity}, \text{time_delta}, \text{modality}]$ = توکن

س.۳ شبکه‌های نمونه‌اولیه‌ای

نمونه‌اولیه‌ی کلاس:

$$\mathbf{c}_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f_{\theta}(x_i) \quad (\text{س.۲})$$

احتمال پرس وجو:

$$p(y = k | x) = \frac{\exp(-\langle f_{\theta}(x), \mathbf{c}_k \rangle / \tau)}{\sum_{k'} \exp(-\langle f_{\theta}(x), \mathbf{c}_{k'} \rangle / \tau)} \quad (\text{س.۳})$$

س.۴. زیان کانونی

$$\mathcal{L} = -\alpha(1 - p_t)^{\gamma} \log(p_t) \quad (\text{س.۴})$$

با $\gamma = 2$ و α از وزن های کلاس.

س.۵. FedAvg

$$\theta_{t+1} = \sum_{k=1}^K \frac{n_k}{n} \theta_{t+1}^{(k)} \quad (\text{س.۵})$$

س.۶. معیارها

$$\begin{aligned} \text{AUROC} &: \int_0^1 \text{TPR}(t) d(\text{FPR}(t)) \\ F1_k &= \frac{2 \cdot P_k \cdot R_k}{P_k + R_k} \text{ که در آن } \frac{F1_0 + F1_1}{2} \\ \text{MCC} &: \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \end{aligned}$$

س.۷. ویژگی های مهندسی شده

شاخص شوک: $SI = HR/SBP$ (نرمال شده)

پراکسی SOFA: $\sum_j w_j (1 - x_j)$ برای کراتینین، پلاکت، SpO2، لاکتات

تعداد آزمایش غیرطبیعی: $\frac{1}{n} \sum_i \mathbb{1}[|x_i - 0.5| > 0.35]$

س.۸ خودتوجه

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^{\top} / \sqrt{d_k})V$$

$$\text{MultiHead} = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \text{ چندسر:}$$

پیوست ش

فهرست اختصارات

جدول ش.۱: اختصارات به کاررفته در این پایان نامه

شکل کامل	اختصار
Area Under the Receiver Operating Characteristic Curve	AUROC
Area Under the Precision-Recall Curve	AUPRC
Bidirectional Encoder Representations from Transformers	BERT
Beth Israel Deaconess Medical Center	BIDMC
Confidence Interval	CI
Cross-Validation	CV
Electronic Health Record	EHR
Encoder for Time-series and Heterogeneous Organ Signals	ETHOS
Federated Averaging	FedAvg
General Data Protection Regulation	GDPR
Health Insurance Portability and Accountability Act	HIPAA
International Classification of Diseases, 10th revision	ICD-10
Intensive Care Unit	ICU
Length of Stay	LOS
Logistic Regression	LR
Model-Agnostic Meta-Learning	MAML
Matthews Correlation Coefficient	MCC
Medical Information Mart for Intensive Care	MIMIC
Machine Learning	ML
Neural Network	NN
Precision-Recall	PR
Random Forest	RF
Receiver Operating Characteristic	ROC
SHapley Additive exPlanations	SHAP
Synthetic Minority Over-sampling Technique	SMOTE
Sequential Organ Failure Assessment	SOFA
Structured Query Language	SQL
t-Distributed Stochastic Neighbor Embedding	t-SNE
Extreme Gradient Boosting	XGBoost

پیوست ص

مرور ادبیات تفصیلی

این پیوست مرور گسترده‌ای از کارهای پیشین مرتبط با پایان‌نامه ارائه می‌کند.

ص ۱۰ یادگیری کم‌نمونه: مقالات کلیدی

جدول ص ۱۰: مقالات کلیدی یادگیری کم‌نمونه

مقاله	سال	نواوری
Matching Networks	۲۰۱۶	توجه روی مجموعه‌ی support برای one-shot
Prototypical Networks	۲۰۱۷	میانگین بردارهای نهفته به‌عنوان نمونه‌اولیه‌ی کلاس
MAML	۲۰۱۷	فرا یادگیری با سازگاری مبتنی بر گرادین
Relation Network	۲۰۱۸	معیار آموزش‌دیده به‌جای اقلیدسی
Simple baselines	۲۰۱۹	نزدیک‌ترین مرکز می‌تواند با روش‌های پیچیده برابری کند

ص ۲۰ یادگیری فدرال: کاربردهای مراقبت سلامت

یادگیری فدرال در مراقبت سلامت برای موارد زیر به کار رفته است: (۱) تصویربرداری پزشکی (مثلاً بخش‌بندی MRI مغز بین بیمارستان‌ها)؛ (۲) پیش‌بینی EHR (مرگ‌ومیر، بستری مجدد)؛ (۳) کشف دارو (پیش‌بینی ویژگی مولکولی). چالش‌های کلیدی: داده‌ی non-IID، هزینه‌ی ارتباط، و انطباق مقرراتی. کار ما فرا یادگیری کم‌نمونه را به تنظیم فدرال برای امکان‌پذیری درمان اضافه می‌کند.

ص.۳ پیش‌بینی بالینی: نتایج معیار

کارهای پیشین روی MIMIC-III و MIMIC-IV، AUROC در بازه ی ۰.۷۲-۰.۸۸ برای مرگ‌ومیر، ۰.۷۰-۰.۸۰ برای بستری مجدد، و ۰.۶۵-۰.۷۸ برای پیش‌بینی مدت بستری گزارش کرده‌اند. AUROC ۰.۷۶ ما برای امکان‌پذیری درمان قابل مقایسه است. تعریف وظیفه و انتخاب کوهورت معیارهای گزارش‌شده را به‌شدت تحت تأثیر قرار می‌دهد؛ مقایسه‌ی مستقیم نیازمند پروتکل‌های ارزیابی یکسان است.

ص.۴ جزئیات معماری Transformer

رمزگذار transformer از لایه‌های متناوب خودتوجه چندسر و پیش‌خور جلو-عقب تشکیل شده است. هر سر توجه محاسبه می‌کند:

$$\text{head}_i = \text{Softmax} \left(\frac{Q_i K_i^\top}{\sqrt{d_k}} \right) V_i \quad (\text{ص.۱})$$

که در آن Q_i, K_i, V_i تصویرهای آموزش‌دیده هستند. خروجی همه‌ی سرها به‌هم چسبانده و تصویر می‌شود. نرمال‌سازی لایه پیش و پس از هر زیرلایه اعمال می‌شود (پیکربندی Pre-LN). لایه‌ی پیش‌خور: $\text{FFN}(x) = \text{ReLU}(xW_1 + b_1)W_2 + b_2$ با $d_{\text{ff}} = 512$ Dropout (۰.۲) پس از توجه و اعمال می‌شود.

ص.۵ جزئیات پروتکل ارزیابی

برای ارزیابی کم‌نمونه، ۱۰۰ قسمت از مجموعه‌ی آزمون نمونه‌برداری می‌کنیم. هر قسمت K support و Q query به‌ازای هر کلاس دارد و میانگین AUROC و انحراف معیار روی قسمت‌ها گزارش می‌شود. برای مدل‌های کلاسیک، کل مجموعه‌ی آزمون را در یک ارزیابی تکی استفاده می‌کنیم. تفاوت پروتکل‌ها توضیح می‌دهد چرا AUROC آزمایش K-شات در بازه ۰.۵۶۴-۰.۵۵۷ پایین‌تر از عدد منجمد Proposed_FewShot در Exp1 (۰.۶۱۱) است: ارزیابی اصلی از کل مجموعه‌ی آزمون با یک مدل آموزش‌دیده استفاده می‌کند، در حالی که آزمایش K-شات نمونه‌برداری قسمتی دارد و واریانس بیشتری وارد می‌کند.

ص.۶ مقایسه با کارهای پیشین MIMIC-III

MIMIC-III (پیش‌نیاز MIMIC-IV) به‌طور گسترده استفاده شده است. (Awad et al. (2017) برای پیش‌بینی ترخیص با Random Forest، AUROC ۰.۷۸ گزارش کردند. (Purushotham et al. (2018) LSTM و RF را روی مرگ‌ومیر معیار کردند (AUROC ۰.۸۵ برای بهترین مدل). کوهورت و وظیفه‌ی ما (MIMIC-IV، امکان‌پذیری درمان) متفاوت است؛ AUROC ۰.۷۶ ما در بازه‌ی قابل مقایسه است. گذر از MIMIC-III به MIMIC-IV تغییراتِ شما را معرفی می‌کند؛ از ساختار به‌روزشده استفاده می‌کنیم (مثلاً itemidهای labevents).

پیوست ض

ارزیابی تفصیلی و تحلیل حساسیت

این پیوست نتایج ارزیابی تفصیلی و تحلیل‌های حساسیت را ارائه می‌کند.

ض.۱ معیارهای تفصیلی به تفکیک بیماری

جدول ض.۱، AUROC، F1، دقت، و بازخوانی را برای بهترین مدل (جنگل تصادفی) و مدل پیشنهادی کم‌نمونه به‌ازای هر گره‌ی بیماری گزارش می‌کند. مدل RF به‌طور پیوسته از ETHOS در همه‌ی گره‌ها بهتر است؛ بیشترین شکاف برای دیابت (node_5) است، جایی که ETHOS تنها AUROC ۰.۵۳ دارد.

جدول ض.۱: معیارها به تفکیک بیماری (RF در برابر مدل پیشنهادی کم‌نمونه)

گره	RF				مدل پیشنهادی			
	Rec.	Prec.	F1	AUROC	Rec.	Prec.	F1	AUROC
سپسیس	۰.۷۴	۰.۶۸	۰.۶۶	۰.۷۰	۰.۶۱	۰.۵۶	۰.۵۴	۰.۵۸
قلبی	۰.۷۲	۰.۶۶	۰.۶۴	۰.۶۸	۰.۶۲	۰.۵۸	۰.۵۶	۰.۶۰
تنفسی	۰.۷۰	۰.۶۴	۰.۶۲	۰.۶۶	۰.۶۰	۰.۵۵	۰.۵۳	۰.۵۷
کلیوی	۰.۷۰	۰.۶۵	۰.۶۳	۰.۶۷	۰.۶۰	۰.۵۶	۰.۵۴	۰.۵۸
دیابت	۰.۶۴	۰.۶۰	۰.۵۸	۰.۶۲	۰.۵۳	۰.۵۰	۰.۴۸	۰.۵۲

ض.۲. شبکه‌ی حساسیت ابرپارامتر

ابریارامترهای کلیدی را تغییر دادیم و تغییر AUROC را گزارش می‌کنیم. برای ETHOS: بعد نهفته (۶۴، ۱۲۸، ۲۵۶)، تعداد لایه‌ها (۱، ۲، ۳)، و dropout (۰.۱، ۰.۲، ۰.۳). بهترین پیکربندی ۱۲۸ بعد، ۲ لایه و dropout برابر ۰.۲ بود. برای Random Forest: max_depth (۱۰، ۲۰، ۲۸، None) و n_estimators (۱۰۰، ۲۰۰، ۳۰۰) بررسی شد و بهترین نتیجه با عمق ۲۸ و ۲۰۰ برآوردگر به‌دست آمد. AUROC در بازه‌های آزموده‌شده حدود ۰.۰۲ نوسان داشت.

ض.۳. تحلیل منحنی یادگیری

مجموعه‌ی آموزش را به ۲۵٪، ۵۰٪، ۷۵٪ و ۱۰۰٪ زیرنمونه کردیم و AUROC آزمون را اندازه گرفتیم. برای Random Forest، مقادیر به‌ترتیب ۰.۶۸، ۰.۷۲، ۰.۷۵ و ۰.۷۶ بود. برای ETHOS همراه با یادگیری کم‌نمونه نیز مقادیر ۰.۵۵، ۰.۵۸، ۰.۶۰ و ۰.۶۲ به‌دست آمد. هر دو مدل از داده‌ی بیشتر سود می‌برند، اما RF با شیب بیشتری بهبود می‌یابد و برای این وظیفه از داده‌ی موجود کارا تر استفاده می‌کند.

ض.۴. کالیبراسیون به تفکیک مدل

خطای کالیبراسیون مورد انتظار (ECE) و حداکثر خطای کالیبراسیون (MCE) را برای RF و ETHOS محاسبه کردیم. RF: ECE ۰.۰۴، MCE ۰.۰۸؛ ETHOS: ECE ۰.۰۹، MCE ۰.۱۵. ETHOS بیش‌اطمینان‌تر است؛ کالیبراسیون مجدد (مثلاً Platt scaling) می‌تواند قابلیت اطمینان احتمالات پیش‌بینی‌شده را بهبود دهد.

ض.۵. تقسیم‌های ارزیابی جایگزین

توان مقاوم در برابر تقسیم‌های تصادفی مختلف را ارزیابی کردیم. با بذره‌ای ۴۲، ۱۲۳، ۴۵۶ به‌دست آمد: RF AUROC 0.76 ± 0.01 ; ETHOS 0.62 ± 0.02 . نتایج روی تقسیم‌ها پایدارند.

ض.۶. پایداری اهمیت ویژگی

اهمیت ویژگی (Gini) را با اعتبارسنجی 5-fold محاسبه کردیم. ویژگی‌های برتر، یعنی کراتینین، گلوکز و هموگلوبین، پایدار بودند؛ همبستگی رتبه بین تکرارهای اعتبارسنجی از ۰.۹ بیشتر بود. ویژگی‌های رتبه‌ی پایین‌تر

واریانس بیشتری نشان دادند.

ض. ۷ نتایج تفصیلی V5 و V6

توجه: معیارهای این بخش به کمپین توسعه‌ی V1–V6 تعلق دارند. برای اعداد ثابت ارسال، فصل ۵ و پیوست د را ببینید (سقف مدل‌های جدولی ۰.۷۴۸؛ اجرای انباشتی منجمد ۰.۷۴۶).

جدول ض. ۲ معیارهای تفصیلی برای آزمایش‌های V5 (Gated Feature Attention + نمونه‌اولیه‌های توجه متقاطع) و V6 (Heterogeneous Deep Ensemble) را گزارش می‌کند.

جدول ض. ۲: معیارهای تفصیلی V5 و V6 در مجموعه‌ی آزمون

مدل	AUROC	AUPRC	F1	Prec.	Rec.	Acc.	MCC
مدل کم‌نمونه V5 (GFA+CA)	۰.۷۲۲	۰.۷۹۷	۰.۶۵۱	۰.۶۴۹	۰.۶۵۵	۰.۶۶۸	۰.۳۰۴
V5 Stacked (FS+RF+Emb)	۰.۷۳۰	۰.۸۱۰	۰.۶۶۱	۰.۶۶۱	۰.۶۷۲	۰.۶۷۰	۰.۳۳۳
V6 Hetero Ens.	۰.۷۲۵	۰.۷۹۱	۰.۶۵۵	۰.۶۵۸	۰.۶۶۸	۰.۶۶۳	۰.۳۲۶
V6 XGBoost Stacked	۰.۶۸۹	۰.۷۸۱	۰.۶۳۴	۰.۶۳۲	۰.۶۳۶	۰.۶۵۳	۰.۲۶۸
V4 Stacked (مرجع)	۰.۷۳۲	۰.۸۱۰	۰.۶۹۳	۰.۶۹۳	۰.۶۹۳	۰.۷۰۸	۰.۳۸۸
RF (مرجع)	۰.۷۶۰	۰.۸۱۰	۰.۶۸۲	۰.۶۷۰	۰.۶۹۰	۰.۷۰۳	۰.۳۶۴

مدل	بازه‌ی CI %95
مدل کم‌نمونه V5 (GFA+CA)	[۰.۶۶۹, ۰.۷۷۲]
V5 Stacked (FS+RF+Emb)	[۰.۶۸۰, ۰.۷۷۸]
V6 Hetero Ens.	[۰.۶۷۶, ۰.۷۷۳]
V6 XGBoost Stacked	[۰.۶۳۶, ۰.۷۴۲]
V4 Stacked (مرجع)	[۰.۶۸۴, ۰.۷۸۳]
RF (مرجع)	[۰.۷۱۰, ۰.۸۱۰]

ض. ۸ تحلیل به تفکیک بذر برای V5

جدول ض. ۳ نشان می‌دهد واریانس به تفکیک بذر V5 از V4 بیشتر است؛ بهترین بذر (۵۵) به AUROC ۰.۷۳۷ می‌رسد؛ بالاترین نتیجه‌ی تک‌مدلی کم‌نمونه. این نشان می‌دهد معماری GFA به مقداره‌ی اولیه حساس‌تر است اما پتانسیل عملکرد بالاتری دارد.

جدول ض.۳: AUROC به تفکیک بذر V5 در تجمیع پنج بذری

بذر 42	بذر 49	بذر 55	بذر 65	بذر 79	تجمیع
۰.۷۱۲	۰.۷۰۳	۰.۷۳۷	۰.۷۱۷	۰.۷۰۶	۰.۷۲۲

ض.۹. تحلیل به تفکیک معماری برای V6

جدول ض.۴. تفاوت‌های قابل توجه عملکرد بین معماری‌ها را نشان می‌دهد و بیانگر نقش مهم خودتوجه در یادگیری کم‌نمونه‌ی جدولی است.

جدول ض.۴: AUROC به تفکیک معماری V6 (2 بذر برای هر کدام)

معماری	بذر A	بذر B	میانگین توجه؟ Δ نسبت به بهترین
FT-Transformer	۰.۶۸۱	۰.۶۶۰	۰.۷۰۷
GFA-Transformer	۰.۶۳۴	۰.۶۸۷	۰.۶۹۲
MLP-Mixer	۰.۵۴۰	۰.۶۲۸	۰.۶۴۲

کسری AUROC ۰.۶۵ MLP-Mixer نسبت به FT-Transformer تأیید می‌کند که MLP‌های مخلوط‌کننده برای توکن نمی‌توانند تعاملات بین‌ویژگی یادگرفته‌شده توسط لایه‌های خودتوجه را بازتولید کنند. این یافته با ادبیات اخیر هم‌راستا است که معماری‌های مبتنی بر توجه (FT-Transformer, TabTransformer) بر انواع MLP روی داده‌ی جدولی ساخت‌یافته با تعاملات پیچیده‌ی ویژگی برتری دارند.

ض.۱۰. تحلیل پیش‌بینی مطابق (V6)

نسخه V6 شامل پیش‌بینی مطابق تقسیم‌شده با $\alpha = 0.10$ ، یعنی پوشش حاشیه‌ای هدف ۹۰٪، است. آستانه‌ی کالیبراسیون مطابق $\hat{q} = 0.304$ مجموعه‌های پیش‌بینی با اندازه‌ی میانگین ۱.۴۰ تولید می‌کند:

- ۶۰٪ بیماران آزمون پیش‌بینی تک‌کلاس دریافت می‌کنند (اطمینان بالا)
- ۴۰٪ هر دو کلاس را دریافت می‌کنند (نامطمئن؛ برای بازیابی بالینی علامت‌گذاری)
- تضمین پوشش حاشیه‌ای: $90\% \geq$ ساختاری

این مکانیسم سنجش عدم قطعیت اصولی برای استقرار بالینی فراهم می‌کند: بیماران با مجموعه‌ی تک‌عضوی می‌توانند پشتیبان تصمیم خودکار دریافت کنند، در حالی که بیماران با مجموعه‌های مبهم به بازیابی انسانی هدایت

می شوند.

ض. ۱۱ خلاصه‌ی بهبود تدریجی

جدول ض. ۵ پیشرفت کامل از خط پایه‌ی اولیه تا V6 را یکجا می‌کند.

جدول ض. ۵: بهبود تدریجی کامل: V0 تا V6

نسخه	AUROC	شکاف تا RF	% بسته شدن شکاف	نوآوری کلیدی
V0 (اصلی)	0.619	0.141	0%	قسمتی نمونه اولیه‌ای
V1 (RelationNet)	0.626	0.134	5%	سر ترکیبی
V2 (SupCon)	0.689	0.071	50%	پیش آموزش متضاد
V3 (KD)	0.712	0.048	66%	تقطیر دانش RF
V4 (Proto-MAML)	0.711	0.049	65%	سازگاری هنگام آزمون
V4 Stacked	0.732	0.028	80%	stacking فرا-یادگیر
V5	0.722	0.038	73%	ویژگی‌های دروازه‌ای و توجه متقاطع
(GFA+CrossAttn)				
V5 Stacked	0.730	0.030	79%	GFA + 5 بذر stacking
V5 Best Single	0.737	0.023	84%	بهترین مدل تکی
V6	0.725	0.035	75%	تجمیع سه معماری
(Heterogeneous)				

پیوست ط

استنتاج‌ها و اثبات‌های ریاضی

این پیوست استنتاج‌های ریاضی پشتیبان روش‌شناسی را ارائه می‌کند.

ط.۱ گرادیان تابع زیان نمونه‌اولیه‌ای

برای شبکه‌های نمونه‌اولیه‌ای با تابع زیان آنتروپی متقاطع، گرادیان زیان نسبت به بردار نهفته پرس‌وجو $f_{\theta}(x)$ به صورت زیر استخراج می‌شود. فرض کنید $p_k = \exp(z_k) / \sum_{k'} \exp(z_{k'})$ که در آن $z_k = \langle f_{\theta}(x), \mathbf{c}_k \rangle / \tau$ برای کلاس درست y :

$$\frac{\partial \mathcal{L}}{\partial f_{\theta}(x)} = \frac{1}{\tau} \sum_k (p_k - \mathbb{1}[y = k]) \mathbf{c}_k \quad (\text{ط.۱})$$

گرادیان بردار نهفته پرس‌وجو را به سمت نمونه‌اولیه‌ی درست می‌راند و از نمونه‌اولیه‌ی نادرست دور می‌کند، با بزرگی مقیاس‌شده با دما τ .

ط.۲ فرمول‌بندی زیان کانونی

Focal loss [Lin et al., 2017] عبارت است از:

$$\mathcal{L}_{\text{focal}} = -\alpha(1 - p_t)^{\gamma} \log(p_t) \quad (\text{ط.۲})$$

که در آن p_t احتمال پیش‌بینی شده برای کلاس درست است. برای $\gamma = 0$ ، این به آنتروپی متقاطع کاهش می‌یابد. برای $\gamma > 0$ ، نمونه‌های آسان (p_t بالا) با $(1 - p_t)^\gamma$ کم‌اهمیت می‌شوند و زیان روی نمونه‌های سخت تمرکز می‌کند. ما $\gamma = 2$ و α از وزن‌های کلاس برای نامتعادل ۵۸/۴۲ استفاده می‌کنیم.

۳.ط آزمون DeLong برای مقایسه‌ی ROC

آزمون DeLong دو منحنی ROC همبسته را با محاسبه‌ی کوواریانس برآوردهای AUC مقایسه می‌کند. تحت فرض صفر که دو منحنی AUC برابر دارند، آماره‌ی آزمون به‌طور مجانبی نرمال است. این آزمون فقط زمانی قابل اتکاست که دو مدل روی همان نمونه‌های آزمون و با بردارهای احتمال هم‌تراز ارزیابی شده باشند. بنابراین در نسخه‌ی نهایی پایان‌نامه، مقایسه‌های بین پروتکلی توصیفی گزارش می‌شوند و آزمون جفتی کامل DeLong، McNemar یا بوت‌استرپ جفتی به‌عنوان کار آینده توصیه می‌شود.

۴.ط بازه‌های اطمینان bootstrap

برای بازه‌های اطمینان bootstrap، مجموعه‌ی آزمون را ۱,۰۰۰ بار با جایگزینی زیرنمونه می‌کنیم، برای هر زیرنمونه AUROC محاسبه می‌کنیم، و صدک‌های ۲.۵ و ۹۷.۵ را به‌عنوان بازه‌ی اطمینان ۹۵٪ می‌گیریم. این فرض می‌کند مجموعه‌ی آزمون نماینده است؛ برای مجموعه‌های آزمون کوچک، بازه ممکن است پهن باشد. مجموعه‌ی آزمون ۴۰۰ نمونه‌ای ما پهنای بازه‌ی حدود ۰.۱۰-۰.۱۲ برای AUROC می‌دهد.

۵.ط استنتاج پراکسی SOFA

نمره‌ی SOFA (Sequential Organ Failure Assessment) ابزار بالینی برای سنجش نارسایی اندام است. از پراکسی ساده‌شده استفاده می‌کنیم:

(۳.ط)

$$\text{SOFA}_{\text{proxy}} = w_1(1 - \text{creatinine}) + w_2(1 - \text{platelets}) + w_3(1 - \text{SpO}_2) + w_4(1 - \text{lactate})$$

که در آن هر جزء به $[0, 1]$ نرمال شده و w_i وزن‌های برابر (۰.۲۵) هستند. مقادیر بالاتر عملکرد بدتر را نشان می‌دهند. از (1 - value) استفاده می‌کنیم تا کراتینین بالا (بد) به (1 - creatinine) پایین نگاشت شود. پراکسی با امکان‌پذیری همبسته است: SOFA بالاتر $\rightarrow$ امکان‌پذیری پایین‌تر، مطابق انتظار بالینی.

ط.۶. شاخص شوک

شاخص شوک = ضربان قلب / فشار خون سیستولیک. بازه‌ی نرمال: ۰.۵ تا ۰.۷. مقادیری برای شاخص شوک فراتر از ۱.۰ ناپایداری همودینامیک را نشان می‌دهند. با clip و min-max به $[0, 1]$ نرمال می‌کنیم. شاخص شوک بالا با ترخیص ناممکن (ناپایداری همودینامیک تأخیر در ترخیص ایمن) همراه است.

کتاب نامه

- [Alistarh et al., 2017] Alistarh, D., Grubic, D., Li, J., Tomioka, R., and Vojnovic, M. (2017). Qsgd: Communication-efficient sgd via gradient quantization and encoding. *Advances in Neural Information Processing Systems*, 30.
- [Alsentzer et al., 2019] Alsentzer, E., Murphy, J. R., Boag, W., Weng, W.-H., Jindi, D., Naumann, T., and McDermott, M. B. (2019). Publicly available clinical BERT embeddings. *arXiv preprint arXiv:1904.03323*.
- [Arik and Pfister, 2021] Arik, S. Ö. and Pfister, T. (2021). Tabnet: Attentive interpretable tabular learning. In *AAAI*.
- [Awad et al., 2017] Awad, A., Bader-El-Den, M., and McNicholas, J. (2017). Random forest for predicting discharge destination of icu patients. *Journal of Biomedical Informatics*, 69:72–79.
- [Ba et al., 2016] Ba, J. L., Kiros, J. R., and Hinton, G. E. (2016). Layer normalization. *arXiv preprint*.
- [Bernstein et al., 2018] Bernstein, J., Wang, Y.-X., Lee, K., and Swersky, K. (2018). signsgd: Compressed optimisation for non-convex problems. *International Conference on Machine Learning*, pages 560–569.
- [Blanchard et al., 2017] Blanchard, P., El Mhamdi, E. M., Guerraoui, R., and Stainer,

- J. (2017). Machine learning with adversaries: Byzantine tolerant gradient descent. In *Advances in Neural Information Processing Systems*, volume 30.
- [Bonawitz et al., 2019] Bonawitz, K., Eichner, H., Grieskamp, W., Huba, D., Ingerman, A., Ivanov, V., Kiddon, C., Konečný, J., Mazzocchi, S., et al. (2019). Towards federated learning at scale: System design. In *MLSys*.
- [Borisov et al., 2022] Borisov, V., Leemann, T., Seßler, K., Haug, J., Pawelczyk, M., and Kasneci, G. (2022). Deep neural networks and tabular data: A survey. *IEEE TPAMI*.
- [Caruana et al., 2015] Caruana, R., Lou, Y., Gehrke, J., Koch, P., Sturm, M., and Elhadad, N. (2015). Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission.
- [Chen et al., 2020] Chen, Y., Qin, X., Wang, J., Yu, C., and Gao, W. (2020). Fed-health: A federated transfer learning framework for wearable healthcare. *IEEE Intelligent Systems*, 35(4):83–93.
- [Choi et al., 2016] Choi, E., Bahadori, M. T., Schuetz, A., Stewart, W. F., and Sun, J. (2016). Doctor ai: Predicting clinical events via recurrent neural networks.
- [Chouldechova, 2017] Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2):153–163.
- [DeLong et al., 1988] DeLong, E. R., DeLong, D. M., and Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3):837–845.
- [Devlin et al., 2019] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding.

- [Dhillon et al., 2020] Dhillon, G. S., Chaudhary, K., Ravichandran, A., and Soatto, S. (2020). A baseline for few-shot image classification. In *ICLR*.
- [Duan et al., 2022] Duan, M., Liu, D., Chen, X., Liu, R., Tan, Y., and Liang, L. (2022). Federated learning for healthcare: A survey. *ACM Computing Surveys*.
- [Finn et al., 2017] Finn, C., Abbeel, P., and Levine, S. (2017). Model-agnostic meta-learning for fast adaptation of deep networks. In *International Conference on Machine Learning*, pages 1126–1135. PMLR.
- [Floridi et al., 2018] Floridi, L., Cowls, J., Beltrametti, M., Chatila, R., Chazerand, P., Dignum, V., Luetge, C., Madelin, R., Pagallo, U., Rossi, F., et al. (2018). Ai4people—an ethical framework for a good ai society. *Minds and Machines*, 28(4):689–707.
- [Gerke et al., 2020] Gerke, S., Minssen, T., and Cohen, G. (2020). Ethical and legal challenges of artificial intelligence-driven healthcare. *Artificial Intelligence in Healthcare*, pages 295–336.
- [Gorishniy et al., 2024] Gorishniy, Y., Rubachev, I., Khruikov, V., and Babenko, A. (2024). Revisiting deep learning models for tabular data. *IEEE TPAMI*.
- [Han et al., 2018] Han, X., Zhu, H., Yu, P., Wang, Z., Yao, Y., Liu, Z., and Sun, M. (2018). Fewrel: A large-scale supervised few-shot relation classification dataset with state-of-the-art evaluation. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 4803–4809.
- [Hanley and McNeil, 1982] Hanley, J. A. and McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (roc) curve. *Radiology*, 143(1):29–36.

- [Harutyunyan et al., 2019] Harutyunyan, H., Khachatrian, H., Kale, D. C., Ver Steeg, G., and Galstyan, A. (2019). Multitask learning and benchmarking with clinical time series data. *Scientific Data*, 6(1):1–18.
- [He et al., 2020] He, C., Li, S., So, J., Zhang, M., Wang, H., Wang, X., Vepakomma, P., Singh, A., Qiu, H., Shen, L., et al. (2020). Fedml: A research library and benchmark for federated machine learning. In *NeurIPS*.
- [Hegselmann et al., 2023] Hegselmann, S., Buendia, A., Lang, H., Agrawal, M., Ber, X., and Sontag, D. (2023). Tabllm: Few-shot classification of tabular data with large language models. *International Conference on Artificial Intelligence and Statistics*, pages 5549–5581.
- [Huang et al., 2020] Huang, X., Khetan, A., Cvitkovic, M., and Karnin, Z. (2020). Tabtransformer: Tabular data modeling using contextual embeddings. In *arXiv preprint*.
- [Jobin et al., 2019] Jobin, A., Ienca, M., and Vayena, E. (2019). The global landscape of ai ethics guidelines. *Nature Machine Intelligence*, 1(9):389–399.
- [Johnson et al., 2023] Johnson, A., Bulgarelli, L., Pollard, T., Horng, S., Celi, L. A., and Mark, R. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.
- [Johnson et al., 2016] Johnson, A. E., Pollard, T. J., Shen, L., Li-wei, H. L., Feng, M., Ghassemi, M., Moody, B., Szolovits, P., Celi, L. A., and Mark, R. G. (2016). MIMIC-III, a freely accessible critical care database. *Scientific Data*, 3(1):1–9.
- [Kaissis et al., 2020] Kaissis, G. A., Makowski, M. R., Rückert, D., and Braren, R. F. (2020). Secure, privacy-preserving and federated machine learning in medical imaging. *Nature Machine Intelligence*, 2(6):305–311.

- [Karimireddy et al., 2020] Karimireddy, S. P., Jaggi, M., Kale, S., Mohri, M., Suresh, A. T., et al. (2020). Scaffold: Stochastic controlled averaging for federated learning. In *ICML*.
- [Kingma and Ba, 2015] Kingma, D. P. and Ba, J. (2015). Adam: A method for stochastic optimization.
- [Koch et al., 2015] Koch, G., Zemel, R., and Salakhutdinov, R. (2015). Siamese neural networks for one-shot image recognition. In *ICML Deep Learning Workshop*.
- [Lake et al., 2015] Lake, B. M., Salakhutdinov, R., and Tenenbaum, J. B. (2015). Human-level concept learning through probabilistic program induction. In *Science*, volume 350, pages 1332–1338.
- [Lee et al., 2020] Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., and Kang, J. (2020). Biobert: A pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240.
- [Li et al., 2020a] Li, T., Sahu, A. K., Talwalkar, A., and Smith, V. (2020a). Federated optimization in heterogeneous networks. In *Proceedings of Machine Learning and Systems*.
- [Li et al., 2020b] Li, Y., Rao, S., Solares, J. R. A., Hassaine, A., Ramakrishnan, R., Canoy, D., Zhu, Y., Rahimi, K., and Salimi-Khorshidi, G. (2020b). Behrt: Transformer for electronic health records. *IEEE Journal of Biomedical and Health Informatics*.
- [Lin et al., 2017] Lin, T.-Y., Goyal, P., Girshick, R., He, K., and Dollár, P. (2017). Focal loss for dense object detection. In *ICCV*.
- [Lundberg and Lee, 2017] Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions.

- [Makel et al., 2012] Makel, M. C., Plucker, J. A., and Hegarty, B. (2012). Replications in psychology research: How often do they really occur? *Perspectives on Psychological Science*, 7(6):537–542.
- [Matthews, 1975] Matthews, B. W. (1975). Comparison of the predicted and observed secondary structure of t4 phage lysozyme. *Biochimica et Biophysica Acta*, 405(2):442–451.
- [McMahan et al., 2017] McMahan, B., Moore, E., Ramage, D., Hampson, S., and y Arcas, B. A. (2017). Communication-efficient learning of deep networks from decentralized data. *Artificial Intelligence and Statistics*, pages 1273–1282.
- [Nichol et al., 2018] Nichol, A., Achiam, J., and Schulman, J. (2018). On first-order meta-learning algorithms. *arXiv preprint arXiv:1803.02999*.
- [Obermeyer et al., 2019] Obermeyer, Z., Powers, B., Vogeli, C., and Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464):447–453.
- [Pham et al., 2016] Pham, T., Tran, T., Phung, D., and Venkatesh, S. (2016). Deep-care: A deep dynamic memory model for predictive medicine. *Pacific-Asia Conference on Knowledge Discovery*.
- [Prabhu et al., 2019] Prabhu, V., Kannan, A., Ravuri, M., Chaplain, M., Sontag, D., and Amatriain, X. (2019). Few-shot learning for dermatological disease diagnosis. In *Machine Learning for Healthcare Conference*, pages 532–552.
- [Purushotham et al., 2018] Purushotham, S., Meng, C., Zheng, Z., and Liu, Y. (2018). Benchmarking deep learning models on large healthcare datasets. *Journal of Biomedical Informatics*, 83:112–134.

- [Rajkomar et al., 2019] Rajkomar, A., Dean, J., and Kohane, I. (2019). Scalable and accurate deep learning with electronic health records. *NPJ Digital Medicine*, 2(1):1–10.
- [Rajkomar et al., 2018] Rajkomar, A., Hardt, M., Howell, M. D., Corrado, G., and Chin, M. H. (2018). Ensuring fairness in machine learning to advance health equity. *Annals of Internal Medicine*, 169(12):866–872.
- [Rasmy et al., 2021] Rasmy, L., Xiang, Y., Xie, Z., Tao, C., and Zhi, D. (2021). Medbert: Pretrained contextualized embeddings on large-scale structured electronic health records for disease prediction. *NPJ Digital Medicine*, 4(1):86.
- [Ravi and Larochelle, 2017] Ravi, S. and Larochelle, H. (2017). Optimization as a model for few-shot learning.
- [Reddi et al., 2021] Reddi, S., Charles, Z., Zaheer, M., Garrett, Z., Rush, K., Konečný, J., Kumar, S., and McMahan, H. B. (2021). Adaptive federated optimization. In *ICLR*.
- [Ribeiro et al., 2016] Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). Why should i trust you?: Explaining the predictions of any classifier.
- [Rieke et al., 2020] Rieke, N., Hanen, J., Jaderberg, M., et al. (2020). The future of digital health with federated learning. *NPJ Digital Medicine*, 3(1):1–7.
- [Shang et al., 2020] Shang, J., Ma, T., Xiao, C., and Sun, J. (2020). G-bert: Pre-training of graph augmented transformers for medication recommendation. *IJCAI*.
- [Sharafi and Aminian, 2023] Sharafi, M. and Aminian, G. (2023). ETHOS: Efficient transformer for health outcome prediction using symptom tokens. Technical report (thesis companion), Islamic Azad University, Tehran North Branch. Encoder architecture extended in this thesis for few-shot treatment feasibility on MIMIC-IV.

- [Sheller et al., 2020] Sheller, M. J., Edwards, B., Reina, G. A., Martin, J., Pati, S., Kotrotsou, A., Milchenko, M., Xu, W., Marcus, D., Colen, R. R., et al. (2020). Federated learning in medicine: Facilitating multi-institutional collaborations without sharing patient data. *Scientific Reports*, 10(1):12598.
- [Smith et al., 2017] Smith, V., Chiang, C.-K., Sanjabi, M., and Talwalkar, A. S. (2017). Federated multi-task learning. In *NeurIPS*.
- [Snell et al., 2017] Snell, J., Swersky, K., and Zemel, R. (2017). Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, volume 30.
- [Somepalli et al., 2021] Somepalli, G. et al. (2021). Saint: Improved neural networks for tabular data via row attention and contrastive pre-training. In *NeurIPS*.
- [Srivastava et al., 2014] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958.
- [Stanley et al., 2021] Stanley, E., Lowet, E., and Garg, N. (2021). Few-shot learning for clinical natural language processing. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 1742–1752.
- [Sung et al., 2018] Sung, F., Yang, Y., Zhang, L., Xiang, T., Torr, P. H., and Hospedales, T. M. (2018). Learning to compare: Relation network for few-shot learning. In *CVPR*.
- [Triantafillou et al., 2020] Triantafillou, E., Zhu, T., Dumoulin, V., Lamblin, P., Evci, U., Xu, K., Goroshin, R., Gelada, C., Swersky, K., et al. (2020). Meta-dataset: A dataset of datasets for learning to learn from few examples. In *ICLR*.

- [Vaswani et al., 2017] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *NeurIPS*.
- [Vinyals et al., 2016] Vinyals, O., Blundell, C., Lillicrap, T., and Wierstra, D. (2016). Matching networks for one shot learning. In *Advances in Neural Information Processing Systems*, volume 29.
- [Voigt and Von dem Bussche, 2017] Voigt, P. and Von dem Bussche, A. (2017). The eu general data protection regulation (gdpr). *Springer*.
- [Wang et al., 2020] Wang, Y., Yao, Q., Kwok, J. T., and Ni, L. M. (2020). Generalizing from a few examples: A survey on few-shot learning. *ACM Computing Surveys*, 53(3):1–34.
- [Ye et al., 2020] Ye, H.-J., Hu, H., Zhan, D.-C., and Sha, F. (2020). Few-shot learning via saliency-guided hallucination of samples. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 770–779.
- [Zhang et al., 2021] Zhang, W., Zhou, T., Lu, Q., Wang, X., Zhu, H., et al. (2021). Federated learning for healthcare informatics. *Journal of Healthcare Informatics Research*, 5:1–19.



Islamic Azad University, Tehran North Branch

Faculty of Computer Engineering

Master's Thesis

Therapeutic Few-Shot: Intelligent Prediction of Treatment Feasibility with Symptom Tokens from Aggregated Data

Mohammad Sharafi

Computer Engineering — Software

Supervisor: Dr. Alimohammadzadeh

March 2026

چکیده انگلیسی

Predicting *treatment feasibility* from limited, aggregated clinical data is a critical challenge in personalized healthcare decision support. In this thesis, treatment feasibility is operationalized as predicting a measurable clinical discharge/treatment-feasibility outcome from early ICU signals in MIMIC-IV. It does not mean autonomous treatment recommendation, automated prescription, or replacement of physician judgment. We address this research problem using a pipeline combining *Symptom Tokens*—a compact representation of labs and vitals—with the ETHOS encoder, few-shot meta-learning, classical tabular baselines, hybrid stacking, and federated simulation. Experiments use a 2,000-patient MIMIC-IV v3.1 sample, split into five disease nodes (sepsis, cardiac, respiratory, renal, diabetes).

We establish a strong **tabular ceiling**: the frozen Tabular SOTA pipeline reaches **test AUROC 0.748** (F1 0.674, accuracy 0.700). The unified best few-shot pipeline with stacking achieves **AUROC 0.746** (95% bootstrap CI [0.699, 0.797]), descriptively closing most of the gap to the tabular ceiling, while the few-shot sub-model alone reaches AUROC 0.670. Under the separate Exp1 comparison protocol, the proposed few-shot model attains **AUROC 0.611** and Random Forest reaches **0.762** on the same Exp1 split. This shows that raw few-shot does not outperform the strongest classical baseline, and that Exp1, episodic, and stacked-pipeline metrics are protocol-specific rather than interchangeable. Federated training costs about **0.5 percentage points** AUROC vs. centralized on our setup.

Key innovations include Proto-MAML-style adaptation, knowledge distillation from a Random Forest teacher, supervised contrastive pre-training, engineered tabular features, gated feature attention, cross-attention prototypes, and a stacking meta-learner fusing few-shot and classical predictions.

We contribute: (1) a reproducible MIMIC-IV feasibility benchmark with a clear reporting hierarchy (tabular ceiling → raw few-shot → stacked hybrid → federated simulation); (2) Symptom Tokens plus ETHOS for few-shot learning; (3) evidence that classical tabular ML remains very strong on structured ICU data while stacking can recover much of the raw few-shot gap; and (4) open code and auto-exported tables for replication. The main limitations are the single-source retrospective dataset, the 2,000-patient cohort, the proxy outcome label, simulated rather than deployed federation, and the

absence of external prospective validation.

Keywords: treatment feasibility, few-shot learning, federated learning, MIMIC-IV, Symptom Tokens, ETHOS, clinical machine learning.