



دانشگاه آزاد اسلامی

واحد تهران شمال

دانشکده برق و کامپیوتر، گروه مهندسی کامپیوتر

پایان نامه کارشناسی ارشد

رشته: مهندسی کامپیوتر

گرایش: نرم افزار

عنوان:

فیوژنات درمانی:

پیش بینی هوشمند قابلیت درمان با توکن های علائم از داده های تجمیع شده

مطالعه گذشته نگر تمام کوهورت بر نشانگر جانشین امکان پذیری ترخیص از ICU در

MIMIC-IV

استاد راهنما: جناب آقای دکتر علی محمدزاده

محمد شرفی

نگارش:

اسفند ۱۴۰۴

تعهدنامه‌ی اصالت رساله یا پایان نامه

اینجانب **محمد شرفی**، دانش‌آموخته‌ی مقطع کارشناسی ارشد ناپیوسته در رشته‌ی **مهندسی کامپیوتر**،
گرایش **نرم‌افزار**، که در تاریخ از پایان‌نامه‌ی خود تحت عنوان

فیوضات درمانی:

پیش‌بینی هوشمند قابلیت درمان با توکن‌های علائم از داده‌های تجمیع‌شده

با کسب نمره‌ی و درجه‌ی دفاع نموده‌ام، بدین‌وسیله متعهد می‌شوم:

- این پایان‌نامه حاصل تحقیق و پژوهش انجام‌شده توسط اینجانب بوده و در مواردی که از دستاوردهای علمی و پژوهشی دیگران، اعم از پایان‌نامه، کتاب، مقاله، گزارش، نرم‌افزار یا مجموعه‌داده، استفاده کرده‌ام، مطابق ضوابط و رویه‌ی موجود، نام منبع مورد استفاده و سایر مشخصات آن را در فهرست مربوطه ذکر و درج کرده‌ام.
- این پایان‌نامه پیش‌تر برای دریافت هیچ مدرک تحصیلی، در همین سطح یا سطوح پایین‌تر و بالاتر، در سایر دانشگاه‌ها و مؤسسات آموزش عالی ارائه نشده است.
- چنانچه پس از فراغت از تحصیل قصد استفاده یا هرگونه بهره‌برداری، اعم از چاپ کتاب، انتشار مقاله، ثبت اختراع، توسعه‌ی نرم‌افزار یا کاربرد اجرایی از این پایان‌نامه را داشته باشم، مجوزهای لازم را از حوزه‌ی معاونت پژوهشی واحد دانشگاهی اخذ خواهم کرد.
- چنانچه در هر مقطع زمانی خلاف موارد فوق ثابت شود، عواقب ناشی از آن را می‌پذیرم و واحد دانشگاهی مجاز است مطابق ضوابط و مقررات با اینجانب رفتار نماید. در صورت ابطال مدرک تحصیلی نیز هیچ‌گونه ادعایی نخواهم داشت.

محمد شرفی

نام و نام خانوادگی:

.....

امضا:

.....

تاریخ:

تقديم

به خانواده‌ام که همواره پشتیبان من بودند.

سپاسگزاری

این پایان نامه نتیجه مسیری پژوهشی است که از دغدغه دسترسی محدود به داده سلامت، حریم خصوصی بیمار، و نیاز به ارزیابی صادقانه مدل های یادگیری ماشین بالینی آغاز شد. از استاد راهنما، دکتر علی محمدزاده، برای راهنمایی و حمایت علمی، و از خانواده ام برای همراهی در مسیر طولانی بازنگری، صمیمانه سپاسگزارم.

فهرست مطالب

چ	چکیده
خ	فهرست اختصارات
ذ	مقدمه
۱	۱ کلیات تحقیق
۱	۱.۱ بیان مسئله
۱	۲.۱ تعریف عملیاتی امکان‌پذیری
۲	۳.۱ انگیزه و اهمیت
۲	۴.۱ شکاف پژوهشی
۲	۵.۱ پرسش‌های پژوهش
۳	۶.۱ مشارکت‌ها
۳	۷.۱ ساختار پایان‌نامه
۵	۲ پیشینه و مبانی نظری
۵	۱.۲ پرونده الکترونیک سلامت و داده‌های مراقبت ویژه
۵	۲.۲ مدل‌های پیش‌بینی بالینی
۶	۳.۲ مدل‌های جدولی کلاسیک و درختی
۶	۴.۲ یادگیری چندنمونه‌ای
۶	۵.۲ توکن‌های علائم
۷	۶.۲ یادگیری فدرال در سلامت
۷	۷.۲ جایگاه این پایان‌نامه

۳	روش‌شناسی	۸
۱.۳	طراحی مطالعه	۸
۲.۳	منبع داده و کامل بودن داده خام	۸
۳.۳	تعریف کوهورت	۸
۴.۳	تعریف برچسب	۹
۵.۳	استخراج ویژگی	۹
۶.۳	توکن‌های علائم	۹
۷.۳	مدل‌ها	۹
۸.۳	تقسیم داده و معیارهای ارزیابی	۱۰
۹.۳	بازتولیدپذیری و اخلاق	۱۰
۴	آزمایش‌ها و نتایج	۱۱
۱.۴	خلاصه کوهورت کامل	۱۱
۲.۴	جدول اصلی عملکرد مدل‌ها	۱۲
۳.۴	نتایج تفکیک	۱۲
۴.۴	کالیبراسیون و خطای احتمال	۱۴
۵.۴	مدل‌های چندنمونه‌ای و توکن‌محور	۱۴
۶.۴	شبیه‌سازی فدرال	۱۵
۷.۴	ماتریس درهم‌ریختگی	۱۵
۸.۴	مقایسه با بنچمارک تاریخی ۲,۰۰۰ بستری	۱۵
۹.۴	پاسخ مستقیم به پرسش‌های پژوهش	۱۶
۵	بحث	۱۸
۱.۵	یافته‌های اصلی	۱۸
۲.۵	چرا XGBoost مدل اصلی قابل دفاع‌تر است؟	۱۸
۳.۵	چرا Few-Shot ETHOS ضعیف‌تر بود؟	۱۸
۴.۵	پیامدهای مدل هیبریدی و انباشتی	۱۹
۵.۵	یادگیری فدرال	۱۹

۶.۵	رابطه با عنوان پایان نامه	۱۹
۷.۵	نقاط قوت	۲۰
۸.۵	محدودیت‌ها	۲۰
۹.۵	کارهای آینده	۲۰

۶ نتیجه‌گیری ۲۱

۲۲	پیوست بازتولیدپذیری و ممیزی نتایج	۲۲
۱.آ	مسیرهای اصلی	۲۲
۲.آ	فرمان‌های استخراج	۲۲
۳.آ	فرمان‌های مدل‌سازی	۲۲
۴.آ	کنترل ادعاها	۲۳

چکیده انگلیسی ۲۹

فهرست جداول

۱.۴	خلاصه کوهورت کامل مدل‌سازی	۱۱
۲.۴	عملکرد مدل‌ها روی کوهورت کامل	۱۲
۳.۴	معیارهای کالیبراسیون و آستانه	۱۴
۴.۴	مقایسه توصیفی کوهورت کامل با بنچمارک تاریخی	۱۶

فهرست تصاویر

۱.۳	جریان کلی استخراج داده، ساخت توکن‌ها و ارزیابی مدل‌ها	۱۰
-----	---	----

۱۲	توزیع برچسب نشانگر جانشین امکان‌پذیری ترخیص از ICU در کوهورت کامل	۱.۴
۱۳	مقایسه AUROC مدل‌ها روی کوهورت کامل	۲.۴
۱۳	مقایسه AUPRC مدل‌ها روی کوهورت کامل	۳.۴
۱۵	مقایسه امتیاز بریر و ECE؛ مقدار کمتر بهتر است	۴.۴
۱۶	ماتریس درهم‌ریختگی مدل XGBoost روی مجموعه آزمون	۵.۴
۱۷	مقایسه توصیفی AUROC کوهورت کامل با بنچمارک تاریخی ۲,۰۰۰ بستری	۶.۴

چکیده

این پایان نامه یک مطالعه گذشته‌نگر یادگیری ماشین بالینی بر پایه پایگاه داده MIMIC-IV v3.1 است. عنوان پژوهش از مفهوم «فیوشات درمانی» و پیش‌بینی قابلیت درمان با توکن‌های علائم آغاز می‌شود، اما در اجرای نهایی، این مفهوم به صورت دقیق و محدود به یک نشانگر جانشین امکان‌پذیری ترخیص از ICU عملیاتی شده است. این نشانگر برابر یک پیامد دودویی است که از سه شرط استخراج می‌شود: زنده ماندن تا ترخیص بیمارستانی، ترخیص به مقصد مطلوب، و طول اقامت ICU کمتر از ۷۲۰ ساعت. بنابراین مدل‌ها آمادگی واقعی ترخیص، توصیه درمان، یا قابلیت استقرار بالینی را پیش‌بینی نمی‌کنند؛ بلکه یک پیامد گذشته‌نگر و قابل‌بازتولید را برای پژوهش انفورماتیک پزشکی مدل می‌کنند.

کوهورت نهایی شامل ۳۲,۳۹۹ بستری نخست بزرگسال در ICU بود. همه نمونه‌های واجد شرایط پس از معیارهای ورود و خروج استفاده شدند و سقف نمونه‌گیری برابر null بود. توزیع برچسب شامل ۱۲,۱۰۲ نمونه ناممکن و ۲۰,۲۹۷ نمونه ممکن بود. از داده‌های آزمایشگاهی و علائم حیاتی در ۲۴ ساعت نخست بستری، ۲۲ ویژگی جدولی و تانسور توکن با شکل (4, 25, 32399) ساخته شد.

مدل‌های ارزیابی‌شده شامل رگرسیون لجستیک، جنگل تصادفی، XGBoost، LightGBM، CatBoost، خط پایه عصبی، Few-Shot ETHOS، مدل هیبریدی توکن-جدولی، مدل انباشتی کلاسیک، و شبیه‌سازی فدرال بودند. بهترین AUROC مربوط به مدل Stacked Classical با مقدار ۰.۷۵۵ بود؛ اما XGBoost با AUROC ۰.۷۵۳، AUPRC ۰.۸۲۵، امتیاز بریر ۰.۱۸۹ و ECE ۰.۰۲۰ از نظر توازن تفکیک و کالیبراسیون، مدل اصلی قابل‌دفاع‌تر برای تفسیر پژوهشی بود. مدل Few-Shot ETHOS با AUROC ۰.۵۹۰ از مدل‌های جدولی ضعیف‌تر عمل کرد؛ این نتیجه پنهان نشده و به عنوان یافته‌ای مهم درباره محدودیت یادگیری کم‌نمونه خام در داده‌های ساخت یافته EHR گزارش می‌شود.

نتایج نشان دادند که در این وظیفه ساخت یافته، مدل‌های درختی و گرادیان بوستینگ همچنان قوی‌ترین خط پایه را تشکیل می‌دهند. با این حال، عملکرد نزدیک مدل Token Hybrid RF به مدل‌های جدولی نشان می‌دهد که توکن‌های علائم در ترکیب با مدل‌های کلاسیک می‌توانند سیگنال مکمل فراهم کنند. شبیه‌سازی فدرال نیز

نشان داد که تجميع گره‌ای مبتنی بر رگرسیون لجستیک می‌تواند عملکردی نزدیک به رگرسیون لجستیک متمرکز حفظ کند، هرچند به مدل‌های درختی نزدیک نشد. محدودیت‌های اصلی شامل ماهیت گذشته‌نگر تک‌پایگاهی، جانشین بودن برچسب، نبود اعتبارسنجی خارجی یا آینده‌نگر، شبیه‌سازی بودن یادگیری فدرال، و محدودیت‌های بازتوزیع داده MIMIC-IV است.

کلیدواژه‌ها: یادگیری ماشین بالینی؛ MIMIC-IV؛ نشانگر جانشین امکان‌پذیری ترخیص از ICU؛ توکن‌های علائم؛ یادگیری چندنمونه‌ای؛ یادگیری فدرال؛ کالیبراسیون.

فهرست اختصارات

شرح	اختصار
بخش مراقبت‌های ویژه	ICU
پرونده الکترونیک سلامت	EHR
Medical Information Mart for Intensive Care IV پایگاه داده مراقبت ویژه	MIMIC-IV
سطح زیر منحنی مشخصه عملکرد گیرنده	AUROC
سطح زیر منحنی دقت-بازخوانی	AUPRC
خطای کالیبراسیون مورد انتظار	ECE
امتیاز بربر برای خطای احتمال پیش‌بینی شده	Brier
رمزگذار توکنی علائم استفاده شده در چارچوب پژوهش	ETHOS
جنگل تصادفی	RF

مقدمه

این نسخه بازنگری شده پایان نامه بر پایه اجرای کامل کوهورت واجد شرایط در MIMIC-IV v3.1 نوشته شده است. در نسخه های مقدماتی، بخشی از آزمایش ها روی زیرمجموعه نمونه گیری شده انجام شده بود؛ اما شواهد اصلی این متن اکنون به کوهورت کامل پس از معیارهای ورود و خروج، شامل ۳۲,۳۹۹ بستری نخست بزرگسال در ICU، متکی است.

هدف متن حاضر نه دفاع از برتری یک روش خاص، بلکه گزارش صادقانه یک مسیر پژوهشی است: ایده اولیه بررسی یادگیری چندنمونه ای و توکن های علائم بود؛ اجرای کامل نشان داد مدل های جدولی و درختی در این وظیفه ساخت یافته بالینی همچنان بسیار قوی اند. همین نتیجه، ارزش علمی کار را افزایش می دهد، زیرا مرز واقع بینانه روش های نوین را در برابر خط پایه های قوی نشان می دهد.

فصل ۱

کلیات تحقیق

۱.۱ بیان مسئله

بخش مراقبت‌های ویژه (ICU) یکی از داده‌محورترین و در عین حال پرخطرترین محیط‌های نظام سلامت است. در ساعات نخست بستری، داده‌های آزمایشگاهی، علائم حیاتی، سن، مسیر پذیرش و تشخیص‌های اولیه به تدریج تصویری از وضعیت بیمار می‌سازند. پژوهش‌های یادگیری ماشین می‌کوشند از همین داده‌های اولیه برای تخمین خطر، پیامد، و مسیر احتمالی بیمار استفاده کنند. با این حال، هر مدل بالینی باید با دقت تعریف کند که دقیقاً چه چیزی را پیش‌بینی می‌کند و از چه چیزی نمی‌توان نتیجه گرفت.

این پایان‌نامه از ایده «فیوژن درمانی» آغاز شد: آیا می‌توان با استفاده از توکن‌های علائم و یادگیری چندنمونه‌ای (Few-Shot Learning) از داده‌های محدود و حساس بالینی مدلی ساخت که به پیش‌بینی امکان‌پذیری درمان کمک کند؟ در اجرای نهایی و بازنگری شده، این ایده به یک مسئله قابل بازتولید و محدودتر تبدیل شد: پیش‌بینی نشانگر جانشین امکان‌پذیری ترخیص از ICU در پایگاه داده MIMIC-IV v3.1. این نشانگر جایگزین قضاوت پزشک، آمادگی واقعی ترخیص، یا توصیه درمان نیست. هدف، ارزیابی پژوهشی مدل‌ها روی یک برچسب گذشته‌نگر و شفاف است.

۲.۱ تعریف عملیاتی امکان‌پذیری

در این پژوهش، برچسب مثبت زمانی به بیمار داده می‌شود که سه شرط برقرار باشد: بیمار تا ترخیص بیمارستانی زنده مانده باشد؛ مقصد ترخیص در گروه مقصدهای مطلوب تعریف شده باشد؛ و طول اقامت در ICU کمتر از ۷۲۰

ساعت باشد. این تعریف از روی داده‌های ساخت‌یافته MIMIC-IV قابل استخراج است و امکان بازتولید دارد، اما یک برچسب جانشین است. بنابراین، در سراسر پایان‌نامه از اصطلاح «نشانگر جانشین امکان‌پذیری ترخیص از ICU» استفاده می‌شود.

۳.۱ انگیزه و اهمیت

تصمیم‌های مرتبط با مسیر مراقبت و ترخیص در ICU پیامدهای مستقیم برای بیمار، تخت‌های مراقبت ویژه، هزینه و برنامه‌ریزی بیمارستان دارند. اگر مدلی بتواند از داده‌های ۲۴ ساعت نخست سیگنالی قابل‌اعتماد درباره پیامد جانشین تولید کند، می‌تواند در آینده به پژوهش‌های پشتیبان تصمیم، اولویت‌بندی پایش، یا طراحی مطالعات آینده‌نگر کمک کند. اما چنین مدلی تنها زمانی ارزشمند است که با خط پایه‌های قوی مقایسه شود، کالیبراسیون آن بررسی گردد، و محدودیت‌های برچسب و داده آشکارا بیان شود.

انگیزه دوم، حریم خصوصی و محدودیت دسترسی به داده‌های سلامت است. پایگاه‌هایی مانند MIMIC-IV با وجود ارزش پژوهشی بالا، طبق مقررات سخت‌گیرانه و پس از احراز صلاحیت در دسترس قرار می‌گیرند [Goldberger et al., 2000, Johnson et al., 2023]. در دنیای واقعی، داده‌های بیمارستانی معمولاً میان مراکز قابل‌انتقال نیستند. به همین دلیل، این پایان‌نامه علاوه بر مدل‌های متمرکز، یک شبیه‌سازی یادگیری فدرال (Federated Learning) را نیز بررسی می‌کند [Li et al., 2020, McMahan et al., 2017].

۴.۱ شکاف پژوهشی

مطالعات زیادی نشان داده‌اند که مدل‌های یادگیری ماشین می‌توانند از داده‌های EHR برای پیش‌بینی پیامدهای بالینی استفاده کنند [Rajkomar et al., 2018]. با این حال، سه شکاف در این حوزه باقی است. نخست، بسیاری از مطالعات، خط پایه‌های کلاسیک قوی و مدل‌های نوین را در یک چارچوب یکسان و با گزارش کالیبراسیون مقایسه نمی‌کنند. دوم، یادگیری چندنمونه‌ای در داده‌های جدولی ساخت‌یافته، برخلاف تصویر و زبان، همیشه مزیت روشن ندارد و نیازمند ارزیابی صادقانه است [Vinyals et al., 2016, Snell et al., 2017]. سوم، کاربرد بازنمایی‌های توکنی علائم در کنار مدل‌های جدولی و شبیه‌سازی فدرال هنوز نیازمند بنچمارک‌های بازتولیدپذیر است.

۵.۱ پرسش‌های پژوهش

این پایان‌نامه به پنج پرسش پاسخ می‌دهد:

۱. آیا ویژگی‌های آزمایشگاهی و علائم حیاتی ۲۴ ساعت نخست ICU می‌توانند نشانگر جانشین امکان‌پذیری ترخیص را در MIMIC-IV پیش‌بینی کنند؟
۲. مدل‌های کلاسیک و درختی جدولی در مقایسه با مدل Few-Shot ETHOS چگونه عمل می‌کنند؟
۳. آیا بازنمایی توکن‌های علائم، به‌ویژه در مدل‌های هیبریدی، سیگنال مکمل فراهم می‌کند؟
۴. آیا شبیه‌سازی فدرال می‌تواند عملکردی نزدیک به خط پایه متمرکز هم‌خانواده حفظ کند؟
۵. کدام مدل بهترین توازن میان تفکیک (AUROC/AUPRC) و کالیبراسیون (Brier/ECE) را دارد؟

۶.۱ مشارکت‌ها

مشارکت‌های اصلی پژوهش عبارت‌اند از:

۱. ساخت و اعتبارسنجی یک کوهورت کامل MIMIC-IV شامل ۳۲,۳۹۹ بستری نخست بزرگسال در ICU.
۲. تعریف شفاف یک نشانگر جانشین امکان‌پذیری ترخیص از ICU و تفکیک آن از آمادگی واقعی ترخیص یا توصیه درمان.
۳. ساخت بازنمایی توکن‌های علائم برای داده‌های آزمایشگاهی و علائم حیاتی ۲۴ ساعت نخست.
۴. مقایسه مدل‌های رگرسیون لجستیک، جنگل تصادفی، گرادیان بوستینگ، خط پایه عصبی، Few-Shot ETHOS، مدل هیبریدی، مدل انباشتی، و شبیه‌سازی فدرال.
۵. نشان دادن اینکه در این وظیفه، مدل‌های درختی و جدولی از Few-Shot ETHOS خام قوی‌ترند، در حالی که توکن‌های علائم در حالت هیبریدی می‌توانند به عملکرد نزدیک به مدل‌های قوی برسند.
۶. گزارش معیارهای کالیبراسیون در کنار معیارهای تفکیک، و انتخاب XGBoost به عنوان مدل اصلی قابل دفاع‌تر از نظر توازن عملکرد.

۷.۱ ساختار پایان‌نامه

فصل دوم پیشینه علمی را مرور می‌کند. فصل سوم روش‌شناسی، داده، برچسب، ویژگی‌ها، توکن‌ها، مدل‌ها، تقسیم داده و معیارهای ارزیابی را توضیح می‌دهد. فصل چهارم نتایج کامل کوهورت، جداول و شکل‌ها را گزارش می‌کند.

فصل پنجم یافته‌ها، محدودیت‌ها و پیامدها را بحث می‌کند و فصل ششم جمع‌بندی نهایی و مسیرهای آینده را ارائه می‌دهد.

فصل ۲

پیشینه و مبانی نظری

۱.۲ پرونده الکترونیک سلامت و داده‌های مراقبت ویژه

پرونده الکترونیک سلامت (EHR) شامل مجموعه‌ای ناهمگون از داده‌هاست: آزمایش‌ها، علائم حیاتی، تشخیص‌ها، داروها، اقدامات، یادداشت‌ها و اطلاعات جمعیت‌شناختی. در ICU، این داده‌ها با چگالی زمانی بالاتری ثبت می‌شوند و برای پژوهش‌های پیش‌بینی پیامد ارزش ویژه دارند. با این حال، ناهمگونی ثبت، خطاهای اندازه‌گیری، مقادیر گم‌شده، تغییر الگوهای مراقبت و تفاوت مراکز باعث می‌شود مدل‌سازی این داده‌ها دشوار باشد.

پایگاه MIMIC-IV یکی از مهم‌ترین منابع باز اما کنترل‌شده پژوهش مراقبت ویژه است [Johnson et al., 2023]. این پایگاه شامل داده‌های بیماران بستری در مرکز Beth Israel Deaconess Medical Center است و از طریق PhysioNet پس از آموزش و تعهدنامه استفاده از داده در دسترس قرار می‌گیرد [Goldberger et al., 2000]. استفاده از این داده‌ها امکان بازتولید پژوهش را فراهم می‌کند، اما به دلیل تک‌مرکزی و گذشته‌نگر بودن، نباید با اعتبارسنجی خارجی یا آمادگی استقرار بالینی اشتباه گرفته شود.

۲.۲ مدل‌های پیش‌بینی بالینی

مدل پیش‌بینی بالینی باید یک جمعیت هدف، زمان پیش‌بینی، پیامد، ویژگی‌ها و معیارهای ارزیابی روشن داشته باشد. راهنماهایی مانند TRIPOD و ابزارهایی مانند PROBAST بر شفافیت در تعریف کوهورت، برچسب، اعتبارسنجی و خطر سوگیری تأکید می‌کنند [Wolff et al., 2019, Collins et al., 2015]. در این پایان‌نامه، زمان پیش‌بینی ۲۴ ساعت نخست ICU و پیامد، نشانگر جان‌نجات ترخیص است.

۳.۲ مدل‌های جدولی کلاسیک و درختی

داده‌های ساخت‌یافته EHR اغلب جدولی‌اند. در چنین داده‌هایی، مدل‌های کلاسیک مانند رگرسیون لجستیک و جنگل تصادفی [Breiman, 2001] همچنان خط پایه‌های مهمی هستند. گرادیان بوستینگ، به‌ویژه XGBoost [Chen and Guestrin, 2016]، LightGBM [Ke et al., 2017] و CatBoost [Prokhorenkova et al., 2018]، معمولاً روی داده‌های جدولی عملکرد قوی دارند. این مدل‌ها روابط غیرخطی و تعامل ویژگی‌ها را بدون نیاز به معماری‌های عصبی پیچیده یاد می‌گیرند. از منظر پزشکی، تنها AUROC کافی نیست. مدلی که احتمال‌های بدکالبره تولید کند، حتی با تفکیک مناسب، برای تفسیر خطر قابل‌اعتماد نیست. به همین دلیل، امتیاز بریر و خطای کالبراسیون مورد انتظار (ECE) نیز باید بررسی شود [Van Calster et al., 2019, Steyerberg, 2019].

۴.۲ یادگیری چندنمونه‌ای

یادگیری چندنمونه‌ای (Few-Shot Learning) به دنبال یادگیری از تعداد اندک نمونه برچسب‌دار برای هر کلاس است. شبکه‌های تطبیقی و نمونه‌محور مانند Matching Networks و Prototypical Networks در حوزه‌هایی مانند تصویر و زبان موفق بوده‌اند [Snell et al., 2017, Vinyals et al., 2016]. ایده اصلی این است که مدل به‌جای یادگیری یک مرز تصمیم ثابت برای یک مجموعه بزرگ، بازنمایی‌ای بیاموزد که با چند نمونه پشتیبان بتواند نمونه‌های جدید را دسته‌بندی کند.

بالین‌حال، انتقال این منطق به داده‌های جدولی بالینی ساده نیست. ویژگی‌های آزمایشگاهی و علائم حیاتی معمولاً تعداد کمی بعد دارند، معنای بالینی مستقیم دارند و مدل‌های درختی روی آن‌ها قوی‌اند. بنابراین، مزیت یادگیری چندنمونه‌ای باید تجربی و در برابر خط پایه‌های قوی نشان داده شود. در این پایان‌نامه، Few-Shot ETHOS به‌عنوان یک مسیر پژوهشی بررسی می‌شود، اما اگر ضعیف‌تر از مدل‌های جدولی باشد، این نتیجه صریحاً گزارش می‌شود.

۵.۲ توکن‌های علائم

توکن‌های علائم (Symptom Tokens) تلاشی برای تبدیل داده‌های ناهمگون آزمایشگاهی و علائم حیاتی به قالبی فشرده و قابل‌پردازش هستند. هر توکن می‌تواند شناسه ویژگی، شدت، جهت تغییر یا وضعیت نرمال/غیرنرمال را رمزگذاری کند. چنین بازنمایی‌ای از نظر مفهومی به مدل‌های توکنی در پردازش زبان نزدیک است.

[Vaswani et al., 2017]، اما در اینجا بر داده‌های ساخت‌یافته بالینی اعمال می‌شود.

ارزش توکن‌ها ممکن است در دو سطح ظاهر شود. نخست، به‌عنوان ورودی مدل چندنمونه‌ای؛ دوم، به‌عنوان ویژگی مکمل در مدل‌های هیبریدی. نتایج این پایان‌نامه نشان می‌دهد سطح دوم در کوهورت کامل امیدوارکننده‌تر بوده است.

۶.۲ یادگیری فدرال در سلامت

یادگیری فدرال (Federated Learning) اجازه می‌دهد مدل‌ها بدون انتقال مستقیم داده‌های خام میان گره‌ها آموزش ببینند [Yang et al., 2019, McMahan et al., 2017]. در سلامت، این ایده با محدودیت‌های حریم خصوصی، مالکیت داده و مقررات سازگار است. بالاین‌حال، فدرال بودن به‌تنهایی تضمین‌کننده عملکرد یا ایمنی نیست. ناهمگونی گره‌ها، اندازه نمونه، ارتباطات، امنیت و اعتبارسنجی محلی باید جداگانه بررسی شوند [Bonawitz et al., 2019, Li et al., 2020].

در این پژوهش، یادگیری فدرال به‌صورت شبیه‌سازی‌شده انجام شد. هدف، ادعای استقرار چندمرکزی نبود، بلکه سنجش این بود که آیا یک مدل لجستیک گره‌ای می‌تواند نسبت به رگرسیون لجستیک متمرکز عملکرد قابل‌مقایسه حفظ کند یا نه.

۷.۲ جایگاه این پایان‌نامه

این پایان‌نامه در مرز میان انفورماتیک مراقبت ویژه، مدل‌سازی جدولی، بازنمایی توکنی، یادگیری چندنمونه‌ای و یادگیری فدرال قرار می‌گیرد. دستاورد اصلی آن یک ادعای اغراق‌آمیز درباره برتری روش نوین نیست؛ بلکه یک ارزیابی تمام‌کوهورت و قابل‌بازتولید است که نشان می‌دهد کدام روش‌ها در این وظیفه واقعاً قوی‌اند، کدام روش‌ها نیازمند بهبودند، و کدام معیارها برای تفسیر بالینی مهم‌اند.

فصل ۳

روشن‌شناسی

۱.۳ طراحی مطالعه

این پژوهش یک مطالعه گذشته‌نگر مبتنی بر داده‌های ساخت‌یافته MIMIC-IV v3.1 است. هدف، پیش‌بینی نشانگر جانشین امکان‌پذیری ترخیص از ICU با استفاده از داده‌های ۲۴ ساعت نخست بستری است. تحلیل روی کوهورت کامل واجد شرایط انجام شد و هیچ سقف نمونه‌گیری فعال نبود.

۲.۳ منبع داده و کامل بودن داده خام

داده‌های خام از مسیر محلی `mimic-iv-3.1/` خوانده شدند. اعتبارسنجی نهایی نشان داد فایل‌های `diagnoses_icd.csv.gz`، `admissions.csv.gz`، `patients.csv.gz`، `icustays.csv.gz`، `labevents.csv.gz` و `chartevents.csv.gz` موجود بودند. گزارش اعتبارسنجی شامل ۳۳ ورودی در مانیفست و ۳۳ فایل موجود بود؛ بنابراین مانیفست کامل تأیید شد.

۳.۳ تعریف کوهورت

کوهورت شامل بستری نخست بزرگسال در ICU پس از معیارهای ورود و خروج مطالعه بود. ردیف‌های خارج از این کوهورت وارد مدل‌سازی نشدند. مجموعه نهایی دارای ۳۲,۳۹۹ ردیف، ۲۹ ستون، ۲۲ ستون ویژگی، ۳۲,۳۹۹ بستری یکتای ICU و ۳۲,۳۹۹ بیمار یکتا بود. همه ردیف‌ها پس از معیارهای مطالعه استفاده شدند و مقدار `max_cohort_sample` برابر `null` بود.

۴.۳ تعریف برچسب

برچسب مثبت نشان می‌دهد بیمار طبق تعریف جانشین، پیامد امکان‌پذیر داشته است. سه شرط هم‌زمان لازم بود: زنده ماندن تا ترخیص بیمارستان، مقصد ترخیص مطلوب، و طول اقامت ICU کمتر از ۷۲۰ ساعت. این تعریف از داده‌های ساخت‌یافته استخراج می‌شود و به معنای آمادگی واقعی ترخیص یا تصمیم درمانی نیست. توزیع نهایی برچسب‌ها چنین بود: ۱۲,۱۰۲ نمونه در کلاس ۰ و ۲۰,۲۹۷ نمونه در کلاس ۱. نسبت کلاس مثبت حدود ۶۲.۶٪ بود.

۵.۳ استخراج ویژگی


ویژگی‌ها از پنجره ۲۴ ساعت نخست بستری ICU استخراج شدند. این ویژگی‌ها شامل خلاصه‌های آزمایشگاهی، علائم حیاتی، و متغیرهای مشتق‌شده بودند. پیش از جایگذاری، میانگین درصد گمشده‌ها ۰.۲۵۲ و بیشترین درصد گمشده‌ها ۰.۹۹۸ بود. پس از جایگذاری، تعداد سلول‌های گمشده در داده مدل‌سازی صفر گزارش شد.

۶.۳ توکن‌های علائم

در کنار ویژگی‌های جدولی، بازنمایی توکنی علائم ساخته شد. خروجی نهایی در فایل data/pro-cessed_full_cohort/tokens.npy ذخیره شد و شکل آن (4, 25, 32399) بود. هر نمونه دارای ۲۵ گام توکنی و ۴ بعد رمزگذاری بود. این توکن‌ها برای مدل Few-Shot ETHOS و مدل هیبریدی استفاده شدند.

۷.۳ مدل‌ها

مدل‌های اصلی عبارت بودند از رگرسیون لجستیک، جنگل تصادفی، XGBoost، LightGBM، CatBoost، خط پایه عصبی، Few-Shot ETHOS، Token Hybrid RF، مدل انباشتی کلاسیک، و Federated LR، Node Ensemble. مدل انباشتی پیش‌بینی‌های مدل‌های کلاسیک تکمیل‌شده را با یک فرا-یادگیر ترکیب کرد. مدل فدرال با تقسیم گره‌ای شبیه‌سازی‌شده آموزش داده شد و خروجی گره‌ها را تجمیع کرد.



شکل ۱.۳: جریان کلی استخراج داده، ساخت توکن‌ها و ارزیابی مدل‌ها

۸.۳ تقسیم داده و معیارهای ارزیابی

داده به سه بخش آموزش، اعتبارسنجی و آزمون تقسیم شد: ۲۰,۷۳۵ ردیف آموزش، ۵,۱۸۴ ردیف اعتبارسنجی و ۶,۴۸۰ ردیف آزمون. آستانه‌ها با استفاده از مجموعه اعتبارسنجی تنظیم شدند و گزارش نهایی بر مجموعه آزمون نگه‌داشته شده انجام شد.

معیارهای گزارش شده شامل AUROC، AUPRC، دقت، بازخوانی یا حساسیت، ویژگی، F1، امتیاز بریر، ECE، عرض از مبدأ و شیب کالیبراسیون، و ماتریس درهم‌ریختگی بودند. استفاده از معیارهای کالیبراسیون برای جلوگیری از تفسیر بیش‌ازحد AUROC ضروری است [Van Calster et al., 2019, Steyerberg, 2019].

۹.۳ بازتولیدپذیری و اخلاق

کد استخراج و مدل‌سازی مسیرهای جداگانه `data/processed_full_cohort/` و `results/full_cohort/` را استفاده می‌کند. داده خام MIMIC-IV قابل بازتوزیع نیست و فقط نتایج تجمیعی، کد و پیکربندی قابل اشتراک‌اند. داده‌ها بی‌نام‌سازی شده‌اند، دسترسی نیازمند احراز صلاحیت PhysioNet و توافق‌نامه استفاده از داده است، تماس مستقیم با بیمار وجود نداشت، و هیچ تلاشی برای بازشناسایی بیماران انجام نشد. وضعیت معافیت یا تأیید نهاد اخلاق دانشگاهی باید توسط نویسنده با مقررات محلی تأیید شود.

فصل ۴


آزمایش‌ها و نتایج

۱.۴ خلاصه کوهورت کامل

جدول ۱.۴ خلاصه داده را نشان می‌دهد. این جدول مبنای تمام نتایج اصلی پایان‌نامه است و جایگزین زیرمجموعه قدیمی ۲,۰۰۰ بستری شده است.

جدول ۱.۴: خلاصه کوهورت کامل مدل‌سازی

مولفه مقدار
ردیف‌های نهایی 32,399
ستون‌های نهایی 29
ستون‌های ویژگی 22
بستری یکتای ICU 32,399
بیمار یکتا 32,399
کلاس 0: ناممکن 12,102
کلاس 1: ممکن 20,297
شکل تانسور توکن (32399, 25, 4)
سقف نمونه‌گیری null



شکل ۱.۴: توزیع برچسب نشانگر جانشین امکان‌پذیری ترخیص از ICU در کوهورت کامل

۲.۴ جدول اصلی عملکرد مدل‌ها


جدول ۲.۴ نتایج کامل مدل‌ها را روی آزمون نگه‌داشته‌شده نشان می‌دهد. همه مدل‌های برنامه‌ریزی‌شده اجرا شدند و هیچ مدل اصلی به دلیل ناپایداری حذف نشد.

جدول ۲.۴: عملکرد مدل‌ها روی کوهورت کامل


Model	Split	AUROC	AUPRC	Acc	Recall	Spec	F1	Brier	ECE
Stacked Classical	20735/5184/6480	0.755	0.825	0.699	0.769	0.583	0.677	0.202	0.109
XGBoost	20735/5184/6480	0.753	0.825	0.697	0.761	0.589	0.675	0.189	0.020
CatBoost	20735/5184/6480	0.753	0.823	0.703	0.790	0.558	0.677	0.200	0.100
LightGBM	20735/5184/6480	0.751	0.823	0.690	0.730	0.623	0.674	0.199	0.090
Token Hybrid RF	20735/5184/6480	0.749	0.820	0.698	0.772	0.573	0.674	0.192	0.031
Random Forest	20735/5184/6480	0.748	0.820	0.689	0.742	0.601	0.670	0.192	0.028
Neural Baseline	20735/5184/6480	0.739	0.814	0.675	0.682	0.663	0.664	0.194	0.015
Federated LR Node Ensemble	20735/5184/6480	0.709	0.778	0.678	0.746	0.565	0.656	0.215	0.109
Logistic Regression	20735/5184/6480	0.709	0.778	0.680	0.754	0.556	0.656	0.215	0.109
Few-Shot ETHOS	20735/5184/6480	0.590	0.668	0.590	0.642	0.504	0.570	0.250	0.127

۳.۴ نتایج تفکیک

بالاترین AUROC به مدل Stacked Classical با مقدار ۰.۷۵۵ تعلق داشت. CatBoost و XGBoost تقریباً همان سطح عملکرد را با AUROC ۰.۷۵۳ و ۰.۷۵۳ نشان دادند. فاصله میان مدل انباشتی و XGBoost



شکل ۲.۴: مقایسه AUROC مدل‌ها روی کوهورت کامل



شکل ۳.۴: مقایسه AUPRC مدل‌ها روی کوهورت کامل

از نظر AUROC بسیار کوچک بود، بنابراین انتخاب مدل تنها بر اساس رتبه AUROC کافی نیست.

۴.۴ کالیبراسیون و خطای احتمال


جدول ۳.۴ معیارهای کالیبراسیون را خلاصه می‌کند. XGBoost با امتیاز بریر ۰.۱۸۹ و ECE ۰.۰۲۰ یکی از بهترین توازن‌ها را میان تفکیک و کالیبراسیون داشت. مدل انباشتی اگرچه بالاترین AUROC را داشت، ECE بالاتری نشان داد. از این رو، در این پایان‌نامه XGBoost مدل اصلی قابل دفاع‌تر برای تفسیر پژوهشی معرفی می‌شود.

جدول ۳.۴: معیارهای کالیبراسیون و آستانه

Model	Threshold	Brier	ECE	Intercept	Slope
XGBoost	0.595	0.189	0.020	-0.002	1.016
Token Hybrid RF	0.545	0.192	0.031	0.045	1.175
Random Forest	0.565	0.192	0.028	0.033	1.151
Neural Baseline	0.645	0.194	0.015	-0.005	0.927
LightGBM	0.490	0.199	0.090	0.464	0.975
CatBoost	0.445	0.200	0.100	0.498	1.060
Stacked Classical	0.435	0.202	0.109	0.551	0.958
Federated LR Node Ensemble	0.500	0.215	0.109	0.514	0.965
Logistic Regression	0.495	0.215	0.109	0.517	0.941
Few-Shot ETHOS	0.500	0.250	0.127	0.517	0.000

۵.۴ مدل‌های چندنمونه‌ای و توکن‌محور

مدل Few-Shot ETHOS با AUROC ۰.۵۹۰، AUPRC ۰.۶۶۸ و F1 ۰.۵۷۰ از مدل‌های جدولی ضعیف‌تر بود. این نتیجه نشان می‌دهد که در وظیفه فعلی، توکن‌سازی و یادگیری چندنمونه‌ای خام به‌تنهایی برای رقابت با مدل‌های درختی کافی نیستند. با این حال، مدل Token Hybrid RF با AUROC ۰.۷۴۹ به جنگل تصادفی و مدل‌های گرادیان‌بوستینگ نزدیک شد. بنابراین توکن‌ها در نقش مکمل برای مدل هیبریدی امیدوارکننده‌تر از استفاده مستقل بودند.



شکل ۴.۴: مقایسه امتیاز بریر و ECE؛ مقدار کمتر بهتر است

۶.۴ شبیه‌سازی فدرال


مدل Federated LR Node Ensemble با AUROC ۰.۷۰۹ تقریباً هم‌سطح رگرسیون لجستیک متمرکز با AUROC ۰.۷۰۹ بود. این نتیجه نشان می‌دهد که در خانواده مدل‌های لجستیک، شبیه‌سازی فدرال می‌تواند عملکرد نزدیک به مدل متمرکز حفظ کند. با این حال، هر دو مدل لجستیک از مدل‌های درختی ضعیف‌تر بودند. بنابراین یادگیری فدرال در این پژوهش به‌عنوان مسیر حفظ حریم خصوصی بررسی می‌شود، نه راهی برای افزایش عملکرد.

۷.۴ ماتریس درهم‌ریختگی

شکل ۵.۴ ماتریس درهم‌ریختگی XGBoost را نشان می‌دهد. این مدل روی آزمون ۶,۴۸۰ نمونه‌ای، ۳,۰۹۱ مثبت درست و ۱,۴۲۵ منفی درست داشت. بازخوانی بالاتر از ویژگی بود؛ یعنی مدل در شناسایی کلاس مثبت حساس‌تر از رد کلاس منفی عمل کرد.

۸.۴ مقایسه با بنچمارک تاریخی ۲,۰۰۰ بستری

زیرمجموعه قدیمی ۲,۰۰۰ بستری فقط به‌عنوان زمینه تاریخی استفاده می‌شود و مبنای ادعاهای اصلی نیست. جدول ۴.۴ و شکل ۶.۴ نشان می‌دهند که برخی مدل‌ها در کوهورت کامل بهبود داشته‌اند و برخی اندکی کاهش



شکل ۵.۴: ماتریس درهم‌ریختگی مدل XGBoost روی مجموعهٔ آزمون

نشان داده‌اند. به‌دلیل تفاوت پروتکل‌ها، این مقایسه باید توصیفی تفسیر شود.

جدول ۴.۴: مقایسهٔ توصیفی کوهورت کامل با بنچمارک تاریخی

Model	Full AUROC	Old AUROC	Delta	Source
Stacked Classical	0.755	0.746	0.009	2,000-stay stacked BEST
XGBoost	0.753	0.694	0.059	2,000-stay Exp1
CatBoost	0.753	NA	NA	No directly comparable old benchmark metric
LightGBM	0.751	NA	NA	No directly comparable old benchmark metric
Token Hybrid RF	0.749	0.717	0.032	2,000-stay ETHOS-RF hybrid
Random Forest	0.748	0.762	-0.015	2,000-stay Exp1
Neural Baseline	0.739	0.652	0.087	2,000-stay Exp1
Federated LR Node Ensemble	0.709	0.547	0.162	2,000-stay federated experiment
Logistic Regression	0.709	0.724	-0.015	2,000-stay Exp1
Few-Shot ETHOS	0.590	0.611	-0.022	2,000-stay Exp1


۹.۴ پاسخ مستقیم به پرسش‌های پژوهش

۱. ویژگی‌های ۲۴ ساعت نخست توان پیش‌بینی متوسط تا خوب برای برچسب جانشین داشتند؛ بهترین

AUROC برابر ۰.۷۵۵ بود.

۲. مدل‌های جدولی و درختی از Few-Shot ETHOS خام قوی‌تر بودند.

۳. توکن‌ها در مدل هیبریدی مفیدتر از حالت مستقل ظاهر شدند.



شکل ۶.۴: مقایسه توصیفی AUROC کوهورت کامل با بنچمارک تاریخی ۲,۰۰۰ بستری

۴. شبیه‌سازی فدرال عملکردی نزدیک به رگرسیون لجستیک متمرکز حفظ کرد، اما به مدل‌های درختی نرسید.

۵. XGBoost بهترین توازن میان تفکیک و کالیبراسیون را داشت و برای گزارش اصلی پژوهش مناسب‌تر بود.

فصل ۵

بحث

۱.۵ یافته‌های اصلی

این پایان‌نامه نشان داد که در کوهورت کامل MIMIC-IV، داده‌های ۲۴ ساعت نخست ICU می‌توانند نشانگر جانشین امکان‌پذیری ترخیص را با عملکرد قابل‌توجه اما نه قطعی پیش‌بینی کنند. بالاترین AUROC متعلق به مدل انباشتی کلاسیک بود، اما XGBoost از نظر کالیبراسیون و امتیاز بریر قابل‌دفاع‌تر بود. این تمایز مهم است، زیرا در پژوهش‌های سلامت، احتمال خروجی مدل تنها زمانی مفید است که تا حد امکان با خطر مشاهده‌شده هم‌خوان باشد.

۲.۵ چرا XGBoost مدل اصلی قابل‌دفاع‌تر است؟

مدل انباشتی با AUROC ۰.۷۵۵ اندکی بالاتر از XGBoost بود، اما ECE آن ۰.۱۰۹ بود. در مقابل، XGBoost با AUROC ۰.۷۵۳ و ECE ۰.۰۲۰ توازن بهتری ارائه کرد. در یک سناریوی پژوهشی نزدیک به پشتیبان تصمیم، چنین توازنی مهم‌تر از بهبود بسیار کوچک AUROC است. به همین دلیل، این پایان‌نامه XGBoost را مدل اصلی قابل‌دفاع‌تر می‌داند، نه الزاماً مدل با بیشترین عدد در یک معیار واحد.

۳.۵ چرا Few-Shot ETHOS ضعیف‌تر بود؟

نتیجه ضعیف‌تر Few-Shot ETHOS یافته‌ای منفی اما ارزشمند است. یادگیری چندنمونه‌ای در حوزه‌هایی موفق است که بازنمایی‌های پرفریت و ساختارهای شباهت پیچیده سودمند باشند. در این وظیفه، داده‌ها جدولی، کم‌بعد

و دارای معنای مستقیم بالینی بودند. مدل‌های درختی می‌توانستند آستانه‌ها، تعامل‌ها و غیرخطی‌ها را به خوبی استخراج کنند. از سوی دیگر، توکن‌سازی فشرده ممکن است بخشی از شدت و پیوستگی مقادیر آزمایشگاهی را کاهش داده باشد. بنابراین، ETHOS خام نتوانست با مدل‌های جدولی رقابت کند.

این نتیجه به معنای بی‌ارزش بودن توکن‌ها نیست. عملکرد Token Hybrid RF نشان داد وقتی توکن‌ها در کنار ویژگی‌های جدولی استفاده شوند، می‌توانند سیگنال مکمل داشته باشند. مسیر آینده باید بر آموزش نظارت‌شده بهتر توکن‌ها، اپیزودهای بالینی معنادارتر، و هم‌جوشی کالیبراسیون محور تمرکز کند.

۴.۵ پیامدهای مدل هیبریدی و انباشتی

مدل هیبریدی و مدل انباشتی نشان دادند ترکیب بازنمایی‌ها می‌تواند مفید باشد. با این حال، بهبود مدل انباشتی باید با احتیاط تفسیر شود؛ زیرا کالیبراسیون آن از XGBoost ضعیف‌تر بود. در کاربردهای پژوهشی، مدل انباشتی می‌تواند برای رتبه‌بندی خطر مناسب باشد، اما برای گزارش احتمال، نیازمند کالیبراسیون جداگانه است.

۵.۵ یادگیری فدرال

شبیه‌سازی فدرال نشان داد مدل گره‌ای لجستیک می‌تواند به رگرسیون لجستیک متمرکز نزدیک بماند. این یافته برای حریم خصوصی مهم است، زیرا نشان می‌دهد اگر هدف یک مدل ساده و قابل توضیح باشد، توزیع گره‌ای الزاماً افت شدید ایجاد نمی‌کند. اما این نتیجه نباید به استقرار واقعی تعمیم داده شود. در بیمارستان‌های واقعی، گره‌ها ناهمگن‌ترند، اندازه نمونه‌ها متفاوت است، ارتباطات محدود است و نیاز به ارزیابی امنیت، انصاف و پایش انحراف وجود دارد.

۶.۵ رابطه با عنوان پایان‌نامه

عنوان پایان‌نامه از «فیوشات درمانی» و «قابلیت درمان» سخن می‌گوید. بازنگری علمی متن لازم داشت که این عنوان با اجرای واقعی همسو شود. بنابراین، «قابلیت درمان» در این پایان‌نامه به صورت «نشانگر جان‌نشین امکان‌پذیری ترخیص از ICU» تعریف شده است. این شفاف‌سازی از بیش‌ادعایی جلوگیری می‌کند و نشان می‌دهد پژوهش یک سامانه درمان‌گر یا توصیه‌گر درمان نیست، بلکه یک مطالعه مدل‌سازی گذشته‌نگر است.

۷.۵ نقاط قوت

نقاط قوت پژوهش شامل استفاده از کوهورت کامل واجد شرایط، حذف سقف نمونه‌گیری، استفاده از داده خام کامل و مانیفست تأییدشده، مقایسه چند خانواده مدل، گزارش کالبراسیون، و تفکیک روشن میان نتایج اصلی و بنچمارک تاریخی است. همچنین متن حاضر نتایج منفی را پنهان نکرده و نشان داده است که مدل‌های کلاسیک در داده‌های جدولی بالینی همچنان باید جدی گرفته شوند.

۸.۵ محدودیت‌ها

محدودیت‌های اصلی عبارت‌اند از:

۱. مطالعه گذشته‌نگر و مبتنی بر یک پایگاه داده است.
۲. برچسب، جانشین است و توسط متخصصان به عنوان آمادگی ترخیص یا امکان‌پذیری واقعی درمان داوری نشده است.
۳. اعتبارسنجی خارجی روی بیمارستان دیگر انجام نشده است.
۴. اعتبارسنجی آینده‌نگر یا مداخله‌ای وجود ندارد.
۵. ویژگی‌های ۲۴ ساعت نخست مسیرهای دیرتر بیماری را کامل نشان نمی‌دهند.
۶. احتمال مخدوش‌سازی باقیمانده وجود دارد.
۷. یادگیری فدرال شبیه‌سازی شده و در شبکه واقعی بیمارستانی اجرا نشده است.
۸. Few-Shot ETHOS در این نسخه ضعیف‌تر از مدل‌های جدولی بود و نیاز به بهبود دارد.
۹. کالبراسیون میان مدل‌ها متفاوت است و AUROC به‌تنهایی کافی نیست.
۱۰. داده خام MIMIC-IV طبق محدودیت‌های استفاده قابل بازتوزیع نیست.

۹.۵ کارهای آینده

مسیرهای آینده شامل اعتبارسنجی خارجی، اعتبارسنجی آینده‌نگر، مدل‌سازی سری زمانی غنی‌تر، آموزش نظارت‌شده توکن‌ها، ساخت اپیزودهای بالینی معنادارتر برای یادگیری چندنمونه‌ای، آموزش کالبراسیون‌محور، تحلیل انصاف و زیرگروه، فدرال واقعی چندمرکزی، و ارزیابی انسان-در-حلقه با بالین‌گران است.

فصل ۶

نتیجه‌گیری

این پایان‌نامه یک ارزیابی تمام‌کوهورت و گذشته‌نگر از پیش‌بینی نشانگر جانشین امکان‌پذیری ترخیص از ICU در MIMIC-IV v3.1 ارائه کرد. نسخه نهایی از ۳۲,۳۹۹ بستری نخست بزرگسال استفاده کرد و دیگر بر زیرمجموعه ۲,۰۰۰ بستری به‌عنوان تحلیل اصلی متکی نیست.

پرسش نخست پژوهش پاسخ مثبت مشروط گرفت: داده‌های ۲۴ ساعت نخست ICU توان پیش‌بینی متوسط تا خوب برای برچسب جانشین داشتند. پرسش دوم نشان داد مدل‌های جدولی و درختی از Few-Shot ETHOS خام قوی‌تر بودند. پرسش سوم نشان داد توکن‌های علائم در حالت هیبریدی مفیدتر از حالت مستقل‌اند. پرسش چهارم نشان داد فدرال شبیه‌سازی شده می‌تواند به خط پایه لجستیک متمرکز نزدیک بماند. پرسش پنجم نشان داد XGBoost بهترین توازن عملی میان تفکیک و کالیبراسیون را فراهم کرد، هرچند مدل انباشتی بالاترین AUROC را داشت.

جمع‌بندی علمی کار این است که نوآوری روش‌شناختی باید در برابر خط پایه‌های قوی آزموده شود. در این وظیفه ساخت یافته EHR، روش چندنمونه‌ای خام برتری نداشت؛ اما همین نتیجه پایان‌نامه را صادقانه‌تر و مفیدتر می‌کند. مدل‌های درختی، به‌ویژه XGBoost، برای داده‌های جدولی بالینی بسیار رقابتی باقی ماندند. توکن‌های علائم و یادگیری فدرال نیز مسیرهای پژوهشی قابل پیگیری هستند، به شرط آنکه در مطالعات آینده با برچسب‌های بالینی دقیق‌تر، داده‌های چندمرکزی و اعتبارسنجی آینده‌نگر ارزیابی شوند.

بنابراین، دستاورد اصلی پایان‌نامه یک سامانه آماده استقرار نیست؛ بلکه یک بنچمارک تمام‌کوهورت، شفاف و بازتولیدپذیر است که نشان می‌دهد در مسئله پیش‌بینی جانشین امکان‌پذیری ترخیص از ICU، کدام رویکردها اکنون قوی‌ترند و کدام مسیرها برای پژوهش‌های بعدی باید بهبود یابند.

پیوست آ

پیوست بازتولیدپذیری و ممیزی نتایج

۱.آ مسیرهای اصلی

- داده پردازش شده: data/processed_full_cohort/thesis_dataset.parquet
- توکن ها: data/processed_full_cohort/tokens.npy
- نتایج: results/full_cohort/
- جدول اصلی مدل ها: results/full_cohort/tables/full_cohort_model_results.csv

۲.آ فرمان های استخراج

```
python extraction/01_cohort.py
python extraction/02_symptoms.py
python extraction/03_labels.py
python extraction/04_tokenize.py
python extraction/05_federated_split.py
```

۳.آ فرمان های مدل سازی

```
python scripts/validate_full_cohort.py
```

```
python scripts/run_full_cohort_models.py --fewshot-episodes 40
```

آ.۴ کنترل ادعاها

در نگارش نهایی، بنچمارک ۲,۰۰۰ بستری فقط به عنوان سابقه تاریخی گزارش شده است. هیچ نتیجه‌ای از آن به عنوان نتیجه کوهورت کامل استفاده نشده است. مدل‌های ضعیف‌تر، از جمله Few-Shot ETHOS، از جدول اصلی حذف نشده‌اند و نتیجه آن‌ها صریحاً گزارش شده است.

کتاب نامه

- [Bonawitz et al., 2019] Bonawitz, K., Eichner, H., Grieskamp, W., Huba, D., Ingerman, A., Ivanov, V., Kiddon, C., Konečný, J., Mazzocchi, S., et al. (2019). Towards federated learning at scale: System design. In *MLSys*.
- [Breiman, 2001] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- [Chen and Guestrin, 2016] Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system.
- [Collins et al., 2015] Collins, G. S., Reitsma, J. B., Altman, D. G., and Moons, K. G. M. (2015). Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): the TRIPOD statement. *Annals of Internal Medicine*, 162(1):55–63.
- [Goldberger et al., 2000] Goldberger, A. L., Amaral, L. A., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., Mietus, J. E., Moody, G. B., Peng, C.-K., and Stanley, H. E. (2000). Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals. *Circulation*, 101(23):e215–e220.
- [Johnson et al., 2023] Johnson, A., Bulgarelli, L., Pollard, T., Horng, S., Celi, L. A., and Mark, R. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data*, 10(1):1.

- [Ke et al., 2017] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). Lightgbm: A highly efficient gradient boosting decision tree.
- [Li et al., 2020] Li, T., Sahu, A. K., Talwalkar, A., and Smith, V. (2020). Federated learning: Challenges, methods, and future directions. *IEEE Signal Processing Magazine*, 37(3):50–60.
- [McMahan et al., 2017] McMahan, B., Moore, E., Ramage, D., Hampson, S., and y Arcas, B. A. (2017). Communication-efficient learning of deep networks from decentralized data. *Artificial Intelligence and Statistics*, pages 1273–1282.
- [Prokhorenkova et al., 2018] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., and Gulin, A. (2018). Catboost: unbiased boosting with categorical features. In *NeurIPS*.
- [Rajkomar et al., 2018] Rajkomar, A., Hardt, M., Howell, M. D., Corrado, G., and Chin, M. H. (2018). Scalable and accurate deep learning with electronic health records. *NPJ Digital Medicine*, 1(1):18.
- [Snell et al., 2017] Snell, J., Swersky, K., and Zemel, R. (2017). Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, volume 30.
- [Steyerberg, 2019] Steyerberg, E. W. (2019). *Clinical Prediction Models: A Practical Approach to Development, Validation, and Updating*. Springer, 2 edition.
- [Van Calster et al., 2019] Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., and Steyerberg, E. W. (2019). Calibration: the Achilles heel of predictive analytics. *BMC Medicine*, 17(1):230.
- [Vaswani et al., 2017] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L.,

Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. In *NeurIPS*.

[Vinyals et al., 2016] Vinyals, O., Blundell, C., Lillicrap, T., and Wierstra, D. (2016). Matching networks for one shot learning. In *Advances in Neural Information Processing Systems*, volume 29.

[Wolff et al., 2019] Wolff, R. F., Moons, K. G. M., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., Reitsma, J. B., Kleijnen, J., and Mallett, S. (2019). PROBAST: A tool to assess the risk of bias and applicability of prediction model studies. *Annals of Internal Medicine*, 170(1):51–58.

[Yang et al., 2019] Yang, Q., Liu, Y., Chen, T., and Tong, Y. (2019). Federated machine learning: Concept and applications. *ACM TIST*, 10(2):1–19.



Islamic Azad University, Tehran North Branch

Faculty of Computer Engineering

Master's Thesis

**Therapeutic Few-Shot: Intelligent Prediction
of Treatment Feasibility
with Symptom Tokens from Aggregated Data**

Full-Cohort Retrospective ICU Discharge-Feasibility Proxy Modelling in MIMIC-IV

Mohammad Sharafi

Computer Engineering — Software

Supervisor: Dr. Alimohammadzadeh

March 2026

چکیده انگلیسی

This thesis reports a retrospective full-cohort clinical machine-learning study using MIMIC-IV v3.1. The thesis title refers to therapeutic few-shot learning and symptom tokens; in the implemented study, this concept is operationalized conservatively as prediction of an ICU discharge-feasibility proxy, defined by in-hospital survival, favourable discharge destination, and ICU length of stay below 720 hours. The task is a reproducible retrospective proxy-modelling study, not a bedside readiness tool or clinical product.

The final modelling dataset included 32,399 eligible adult first ICU stays, with 12,102 proxy-negative and 20,297 proxy-positive cases. The token tensor had shape (32399, 25, 4), and all eligible data after the study inclusion and exclusion criteria were used.

Models evaluated on a fixed train/validation/test split included Logistic Regression, Random Forest, XGBoost, LightGBM, CatBoost, a neural baseline, Few-Shot ETHOS, a token-hybrid Random Forest, stacked classical modelling, and a simulated federated logistic-regression node ensemble. Stacked Classical achieved the highest AUROC (0.755), while XGBoost achieved a nearly identical AUROC (0.753) with stronger Brier score (0.189) and ECE (0.020). Therefore, XGBoost is treated as the most defensible primary model when discrimination and calibration are considered together. Pure Few-Shot ETHOS underperformed the classical tabular models (AUROC 0.590), an important empirical finding in this structured EHR task.

The study contributes a full-cohort MIMIC-IV ICU discharge-feasibility proxy dataset, a symptom-token representation, a comparative benchmark of classical, neural, few-shot, hybrid, stacked, and simulated federated models, and a transparent discussion of where few-shot/token methods helped and where classical tabular models remained stronger. Limitations include the retrospective single-database design, the proxy nature of the outcome, lack of external or prospective validation, simulated rather than deployed federation, and MIMIC-IV data-use restrictions.

Keywords: clinical machine learning, MIMIC-IV, ICU discharge-feasibility proxy, symptom tokens, few-shot learning, federated learning, calibration.

